第一章 P Quant：统计方法与量化策略

Q Quant 在风险中性测度 $\mathbb{Q}$ 下为衍生品定价，P Quant 则在真实测度 $\mathbb{P}$ 下回答一个更朴素、也更难的问题：未来实际会发生什么？本章沿「数据 → 信号 → 因子 → 组合 → 执行 → 验证」这条主线展开，把因子投资、机器学习选股、回测统计校验与市场微观结构串成一个完整工作流，并始终追问同一个问题：这个结论在样本外还剩多少。

1.1 P Quant 的工作面

P Quant 得名于真实世界测度 $\mathbb{P}$。它不假定无套利已经把所有价格钉死，而是承认价格里既有风险补偿，也有错误定价，并用统计方法把其中可重复的部分提取出来。

核心要点 1.1　P Quant 与 Q Quant 的分工

P Quant 问的是“实际会发生什么”，因此它的核心资产是可重复的预测与可控制的风险暴露；Q Quant 问的是“在无套利世界应该值多少”，核心资产是复制组合与校准精度。两者的失效条件不同：P Quant 死于样本外失效，Q Quant 死于模型设定与流动性假设。

直觉理解　为什么 P Quant 更依赖统计纪律

在风险中性世界里，只要复制组合正确，价格就是唯一的；在真实测度下不存在这样的唯一性定理，任何“我发现了一个规律”的结论都必须与“我试了多少次才找到它”一起汇报。这正是本章后半部分反复讨论多重检验与回测过拟合的原因。

表 1.1　P Quant 工作流的六个环节与产出物

环节	输入	产出物	主要失效模式
数据清洗	原始行情与财务	干净面板	幸存者偏差、复权错误
信号构建	面板数据	原始信号	前视偏差、极端值污染
中性化	原始信号与风险暴露	纯净因子	过度中性化削减 Alpha
组合优化	因子与协方差	目标权重	估计误差放大
执行	目标权重与订单簿	成交明细	冲击成本、时滞
验证	全部历史	可信的绩效结论	数据窥探、过拟合

表 1.1 的第三列提醒我们：每一步都有明确的交付物，而不是“感觉不错”的曲线。后文各节依次深入这六个环节。

1.2 因子构建全流程

1.2.1 从原始信号到可用因子

一个因子在进入组合之前，必须走完一条标准化流水线。缺失这三步中的任何一步，都可能让一个真实有效的信号在实证中表现平庸，或让一个无效信号表现得过于优秀。

定义 1.1 因子构建流水线

给定 t 时刻的横截面信号 $\{s_{i,t}\}_{i=1}^{n}$，因子构建流水线依次执行：

1. **去极值**（Winsorize）：把 $s_{i,t}$ 截断到 $[\text{med} - k \cdot \text{MAD},\ \text{med} + k \cdot \text{MAD}]$；
2. **标准化**（Standardize）：减去横截面均值、除以横截面标准差，得到 $z_{i,t}$；
3. **缺失值处理**：剔除停牌与无数据股票，或按行业均值填补；
4. **中性化**（Neutralize）：对 $z_{i,t}$ 回归掉行业哑变量与风格暴露，取残差。

其中 med 为横截面中位数，MAD 为中位数绝对偏差，k 常取 3；i 为股票编号，t 为交易日。

⚠ 风险警示 为什么必须先去极值

若先标准化再去极值，一个 10 倍标准差的观测会把横截面标准差本身抬高约 $\sqrt{1 + 100/n}$，在 $n = 500$ 时约抬高 10%，于是同一天内其余 499 只股票的标准分被系统性压缩，因子横截面分布的形状被单只股票扭曲。顺序错误引入的不是随机噪声，而是可预测的偏差。

1.2.2 行业与风格中性化

中性化的目的是把一个“可能只是市值或行业押注”的信号，还原成纯粹的特质信息。做法是横截面回归

$$z_{i,t} = \alpha_t + \sum_{g=1}^{G} \beta_{g,t} I_{i,g} + \sum_{j=1}^{K} \gamma_{j,t} x_{i,j,t} + \tilde{z}_{i,t} \tag{1.1}$$

其中 $z_{i,t}$ 为标准化后的原始信号，$I_{i,g}$ 为股票 i 属于行业 g 的哑变量（共 G 个行业），$x_{i,j,t}$ 为第 j 个风格暴露（如对数市值、60 日波动率），$\tilde{z}_{i,t}$ 为回归残差，也就是中性化后的因子值。若采用加权最小二乘，权重常取 $\sqrt{\text{自由流通市值}}$，理由是大市值股票的因子暴露估计更稳定，而市值本身又是最重要的风格维度。

ℹ 补充说明 中性化的代价

行业与风格暴露合计可能解释原始信号方差的 30% 至 60%。中性化在削掉这些“搭车”收益的同时，也削掉了与它们相关的真实 Alpha。实务中的做法是保留两版因子（原始版与中性版）分别回测，只有当两版的 IC 同号且中性版的信息比率更高时，才认定信号本身有效。

表 1.2 Barra 风格因子的经济含义与典型构建方式

因子	方向	经济含义与构建要点
Size	负	对数自由流通市值。小盘股长期有溢价，但流动性与容量受限
Value	正	账面市值比、盈利收益率、现金流价格比的合成，需行业中性
Momentum	正	过去 12 个月收益剔除最近 1 个月，短期反转会污染该因子
Volatility	负	残差波动率与日收益标准差，低波动异象在多数市场存在
Liquidity	负	换手率与 Amihud 非流动性，高流动性股票风险调整收益更高
Leverage	负	资产负债率与账面杠杆，高杠杆公司在信用收缩期表现更差
Growth	负	盈利与营收增速，高成长预期往往伴随估值回落

表 1.2 中七个风格因子构成多数商业风险模型的主干。它们的共同特征是：暴露可由公开数据在每月末一次性计算，因此可以被所有参与者同时观测，属于“共同知识型”风险维度。

1.2.3 风险模型的截面估计

Barra 型风险模型假设个股收益由因子收益与特质收益线性生成

$$r_{i,t} = \sum_{j=1}^{K} X_{i,j,t-1} f_{j,t} + u_{i,t} \tag{1.2}$$

其中 $r_{i,t}$ 为股票 i 在 t 期的收益，$X_{i,j,t-1}$ 为期初已知的因子暴露，$f_{j,t}$ 为待估因子收益，$u_{i,t}$ 为特质收益。写成矩阵形式 $r_t = X_{t-1} f_t + u_t$，加权最小二乘估计为

$$\hat{f}_t = \left(X_{t-1}^{\top} W_t X_{t-1} \right)^{-1} X_{t-1}^{\top} W_t \, r_t \tag{1.3}$$

其中 $W_t = \mathrm{diag}(w_{1,t}, \dots, w_{n,t})$ 为权重矩阵。当 W_t 正比于特质方差矩阵的逆时，式 (1.3) 即为广义最小二乘，估计量达到最小方差；实务中用市值平方根近似这一理想权重。

因子收益序列存在自相关与异方差，因此因子协方差矩阵的估计需要稳健化。Newey–West 估计量为

$$\hat{\Sigma}_f = \hat{\Gamma}_0 + \sum_{l=1}^{L} \left(1 - \frac{l}{L+1} \right) \left(\hat{\Gamma}_l + \hat{\Gamma}_l^{\top} \right) \tag{1.4}$$

其中 $\hat{\Gamma}_l = \frac{1}{T}\sum_{t=l+1}^{T} \hat{f}_t \hat{f}_{t-l}^{\top}$ 为滞后 l 阶自协方差，L 为带宽（月度数据常取 $L = 2$ 至 5）。括号内的线性衰减是 Bartlett 核，它保证 $\hat{\mathbf{\Sigma}}_f$ 半正定。最后仍需做特征值调整，把过小的特征值抬到安全下界，因为组合优化器会精确地利用任何被低估的风险方向。

1.3 信息系数与因子评价

1.3.1 IC、Rank IC 与衰减

信息系数度量因子在横截面上的预测能力

$$IC_t = \mathrm{Corr}(s_{i,t},\ r_{i,t+1}), \qquad RankIC_t = \mathrm{Corr}(\mathrm{rank}(s_{i,t}),\ \mathrm{rank}(r_{i,t+1})) \tag{1.5}$$

其中 $s_{i,t}$ 为 t 期末已知的因子值，$r_{i,t+1}$ 为下一期收益，$\mathrm{rank}(\cdot)$ 为横截面秩。Rank IC 即 Spearman 秩相关，对极端值稳健，因此是行业内的默认报告口径。

单期 IC 是极不稳定的统计量。若横截面有 n 只股票，IC_t 的标准误约为 $1/\sqrt{n-3}$；在 $n = 500$ 时约为 0.045。这意味着单日 $IC = 0.05$ 完全可能是噪声。判断因子有效性应看长期平均

$$\overline{IC} = \frac{1}{T}\sum_{t=1}^{T} IC_t, \qquad \mathrm{SE}(\overline{IC}) = \frac{\mathrm{sd}(IC_t)}{\sqrt{T/\tau}} \tag{1.6}$$

其中 τ 为 IC 序列的自相关时间（自相关衰减到 $1/\mathrm{e}$ 所需的期数），T/τ 可理解为*有效独立期数*。例：月度 IC 均值 0.04、月度标准差 0.09、自相关半衰期约 1 个月，则 $\tau \approx 1.44$，十年 120 期的有效样本约 83，$\mathrm{SE}(\overline{IC}) \approx 0.0099$，$t$ 值约 4.0，在 1% 水平显著。若忽略自相关直接取 $\mathrm{SE} = 0.09/\sqrt{120} = 0.0082$，会把 t 值夸大到 4.9。

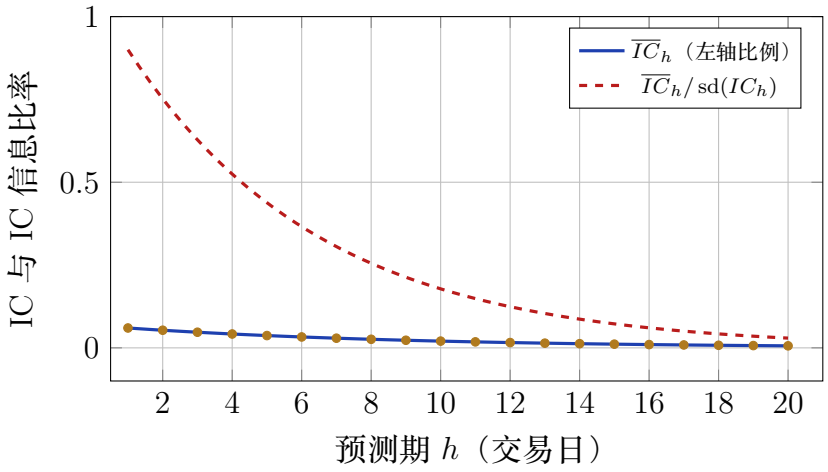


图 1.1 因子 IC 与 IC 信息比率随预测期的衰减：指数衰减意味着半衰期约 5.8 个交易日，持仓周期应与衰减速度匹配

图 1.1 画出一条典型量价因子的衰减曲线。IC 从 $h = 1$ 的 0.06 衰减到 $h = 10$ 的 0.020 左右，半衰期 $h_{1/2} = \ln 2/0.12 \approx 5.8$ 个交易日。若持仓周期取 20 天，虽然单次交易的

信号仍在，但信号已衰减到峰值的约 10%，大部分持仓期是在“无信息”状态下承担风险。这解释了为什么高换手因子必须配高频调仓，也解释了交易成本为什么会吃掉大部分毛收益。

1.3.2 分层回测与多空组合

把股票按因子值排序等分为 Q 层，计算每层等权或市值加权的下期收益，若因子有效则单调性应当明显。用最高层与最低层构造多空组合

$$r_t^{\mathrm{LS}} = \frac{1}{|Q^+|}\sum_{i\in Q^+} r_{i,t} - \frac{1}{|Q^-|}\sum_{i\in Q^-} r_{i,t} \tag{1.7}$$

其中 Q^+ 与 Q^- 分别为因子值最高与最低的一层。多空收益序列的年化信息比率为

$$IR^{\mathrm{LS}} = \frac{\mathbb{E}\left[r_t^{\mathrm{LS}}\right]}{\mathrm{sd}\left(r_t^{\mathrm{LS}}\right)}\sqrt{A} \tag{1.8}$$

其中 A 为年化期数（日频取 252，月频取 12）。注意这里用总波动而非超额收益跟踪误差，因此 IR^{LS} 是可比的“因子强度”指标，与组合层面的 IR 并不等价。

例 1.1 单调性与换手率的联合判读

某月频因子在 3000 只股票上分为五层，过去十年（120 期）的年化超额收益依次为 $Q_1=-6.1\%$、$Q_2=-1.8\%$、$Q_3=0.4\%$、$Q_4=3.6\%$、$Q_5=7.9\%$，多空组合年化收益 14.0%、年化波动 7.5%，故 $IR^{\mathrm{LS}}=1.87$。同时统计因子换手率：期均单边换手率 28%，按 10 个基点的双边成本计，年成本约 $0.28\times 2\times 12\times 0.0010=6.7\%$，扣费后多空收益降至约 7.3%，$IR^{\mathrm{LS}}$ 降至约 0.98。若分层单调性存在但换手率超过 60%，则成本将吞掉全部多空收益，此时应先做信号平滑降低换手，而不是加杠杆放大毛收益。

1.3.3 因子评价清单

实务应用 因子拥挤度的三种度量

业界常用三种信号判断因子是否过度拥挤：一是该因子多空组合的管理规模估算，二是因子收益与因子波动率之比在近两年的异常抬升，三是同因子不同数据供应商版本的收益相关性上升。三者同时触发时，通常意味着该因子的 Alpha 已被套利掉大半，应降低暴露并提高分散度。

1.4 主动管理基本定律

1.4.1 定律的推导

主动管理基本定律把信息质量、下注广度与信息比率联系起来。设组合由 N 个相互独立的下注构成，第 k 个下注的主动权重为 w_k，残差收益为 r_k，并假定每个下注具备相

表 1.3 因子评价指标与判读门槛

指标	典型门槛	判读要点
平均 IC	$\lvert\overline{IC}\rvert > 0.02$	日频 0.02 已属可用，月频可达 0.04
IC 信息比率	> 0.3	均值与标准差之比，衡量信号稳定性
分层单调性	五层单调	非单调常意味着信号与风险暴露纠缠
换手率	与衰减匹配	日频 $< 30\%$、月频 $< 50\%$ 较现实
容量	覆盖多只股票	容量受流动性与冲击成本约束
多空最大回撤	小于年化收益	回撤深于年化收益说明尾部风险集中
因子相关性	与已知因子 < 0.5	相关性过高只是重复暴露，不贡献增量信息

同的预测能力：$\mathrm{Corr}(w_k, r_k) = IC$，且各下注收益的残差波动为 σ。

在主动风险预算 σ_{active} 的约束下，最大化 $\sum_k w_k \mathbb{E}[r_k]$。把残差收益分解为可预测部分与噪声 $r_k = \mathbb{E}[r_k] + \varepsilon_k$，预测误差方差为 ω^2，则最优下注为 $w_k = \mathbb{E}[r_k]/\omega$，即对残差收益的贝叶斯收缩。

命题 1.1 (主动管理基本定律) 在上述独立同分布假设下，最优组合的信息比率为

$$IR \approx IC \cdot \sqrt{N} \tag{1.9}$$

其中 IC 为单个下注的信息系数，N 为独立下注次数（Breadth）。

证明. 记第 k 个下注的主动收益为 $w_k r_k$。预测能力 IC 意味着 $\mathbb{E}[r_k \mid s_k] = IC \cdot \sigma \cdot \tilde{s}_k$，其中 $\tilde{s}_k$ 为标准化信号，σ 为残余波动。选择 $w_k = \mathbb{E}[r_k \mid s_k]/\sigma^2$ 以最大化 $\sum_k \mathbb{E}[w_k r_k]$，主动收益均值为 $\sum_k \mathbb{E}[w_k r_k] = \sum_k \mathbb{E}\big[(\mathbb{E}[r_k \mid s_k]/\sigma^2)\mathbb{E}[r_k \mid s_k]\big] = N \cdot IC^2$。主动风险为 $\sqrt{\sum_k w_k^2 \sigma^2} = \sqrt{N \cdot IC^2} = IC\sqrt{N}$。两者相除即得 $IR \approx IC\sqrt{N}$。 ■

1.4.2 现实修正

式 (1.9) 的两个假设都不成立：下注并非独立，约束也阻止我们把所有信念表达出来。修正形式为

$$IR \approx IC \cdot \sqrt{N_{\text{eff}}} \cdot TC \tag{1.10}$$

其中 $N_{\text{eff}} = N/(1 + (N-1)\bar{\rho})$ 为有效下注数，$\bar{\rho}$ 为下注间平均相关系数，TC 为转移系数（Transfer Coefficient），即组合权重与理想主动权重的相关系数，取值于 $[-1, 1]$，反映约束、行业限制与做空限制带来的损耗。

直觉理解 广度的数量级直觉

$\bar{\rho}=0.1$ 且 $N=500$ 时，$N_{\text{eff}}\approx 500/50.9\approx 9.8$，$\sqrt{N_{\text{eff}}}\approx 3.1$，仅为 $\sqrt{500}\approx 22.4$ 的 14%。这说明“多下注”必须真的独立；在同一风格内增加 100 只股票，并不提供 100 份独立信息，只提供约 2 份。

例 1.2 年化 IR 的完整推算

某日频多因子模型的单期 $IC=0.03$，每日持有 400 只股票的横截面信号，调仓 20 次因此 $N=400\times 20=8000$。取 $\bar{\rho}=0.15$，则 $N_{\text{eff}}=8000/(1+7999\times 0.15)\approx 6.7$，$\sqrt{N_{\text{eff}}}\approx 2.58$。设 $TC=0.7$，代入 式 (1.10) 得 $IR\approx 0.03\times 2.58\times 0.7\approx 0.054$，这是单期（约 12.6 个交易日）的信息比率。按每年约 20 个这样的持有期折算，年化 $IR\approx 0.054\times\sqrt{20}\approx 0.24$。若天真地用 $IR\approx IC\sqrt{N}$，会得到 $0.03\times 89.4\approx 2.68$，夸大十倍以上——这正是许多内部研究报告中“理论 IR”与实际绩效差距的主要来源。

1.5 机器学习选股

1.5.1 适用场景与模型选择

机器学习在量化选股中的价值不在于替代经济学直觉，而在于用高维特征去逼近非线性条件期望 $\mathbb{E}[r_{i,t+1}\mid \mathbf{x}_{i,t}]$。三类模型各有明确的适用场景。

表 1.4 机器学习选股模型的适用场景与注意事项

模型	适用场景	主要风险
线性回归	少量经济含义明确的因子	无法捕捉交互项与非线性
GBDT	截面样本多、特征含类别变量	对时序漂移敏感，需频繁重训
随机森林	特征噪声大、需要稳健基线	外推能力弱，难以预测极端收益
神经网络	特征维度极高、样本量足够	参数量大，样本外衰减快
集成组合	追求稳定性与低相关性	训练与维护成本高

1.5.2 样本权重与标签设计

金融面板数据的样本并非等质量，可用三类权重区分。

- **唯一性权重**：重叠标签（如持有期为 20 天但每日采样）会重复使用同一段收益，应给每个标签按重叠次数倒数赋权；
- **时间衰减权重**：越久远的样本市场结构差异越大，用半衰期 1 至 2 年的指数权重降权；
- **收益幅度权重**：以绝对收益或波动率倒数加权，可降低高波动期的杠杆式主导。

标签设计同样重要。回归标签（下一期收益）保留幅度信息但受极端值支配；分类标签（收益三分位或是否跑赢基准）稳健但丢失幅度；三重障碍法（Triple Barrier）同时设定止盈、止损与时间上限，把路径信息纳入标签，更适合日内与短周期策略。

1.5.3 时序交叉验证与泄漏防控

标准 k-折交叉验证在金融面板上必然泄漏：训练集与测试集在时间上交错，而标签本身跨越多个交易日。正确做法是 Purged k-折加 embargo：先按时间切分为 k 个连续块，然后把与测试块标签区间重叠的训练样本剔除（Purging），再在测试块之后额外丢弃 h 天的样本（Embargo），其中 h 为标签持有期。

算法 1.1 Purged k-折交叉验证与 embargo

输入： 样本时间戳 t_i，标签区间 $[t_i, t_i + h]$，折数 k，禁运长度 e
输出： 每折的训练索引与测试索引

1: 按时间排序样本，等分为 k 个连续块 $B_1, \dots, B_k$
2: **for** $j = 1$ 到 k **do**
3: 测试集置为 B_j
4: 对每个候选训练样本，若其标签区间与 B_j 的时间区间相交则剔除
5: 再剔除时间落在 B_j 结束之后 e 天内的样本
6: **return** 该折的（训练集，测试集）
7: **end for**

风险警示 特征重要性不等于因果关系

用 GBDT 的增益或置换重要性排序特征，很容易被前视型特征主导。典型例子：用当日收盘价与当日成交量之比构造“量价背离”特征，再用当日收益作标签，重要性极高但完全无法交易。检查方法是对每个高重要性特征追问两个问题：该特征在 t 时刻的真实可得时间戳是什么？把它整体滞后一天后重要性还剩多少？

1.6 回测方法论

1.6.1 偏差清单

回测是量化研究中最容易产生虚假结论的环节。下表把常见偏差按可检测性排列。

1.6.2 多重检验的三个层次

假设我们测试了 m 个策略变体，得到一个 Sharpe 比率最高的版本。问题是：这个最大值有多少来自真实信号，多少来自噪声？

第一层：**Bonferroni** 校正把单次显著性水平除以试验次数，$p_i^{\text{Bonf}} = \min(m p_i, 1)$，控制族错误率（FWER）。它过于保守，当 $m = 100$ 时要求单个 p 值小于 0.0005。

第二层：**Benjamini–Hochberg FDR** 控制假发现比例。把 p 值升序排列 $p_{(1)} \le \cdots \le p_{(m)}$，取最大的 i 满足

表 1.5 回测偏差清单与检测方法

偏差	后果	检测与修正
幸存者偏差	高估收益	使用含退市股票的完整历史成分
前视偏差	严重高估	特征打时间戳，财报按公告日而非报告期对齐
复权错误	收益失真	用前复权价计算收益，除权日用总收益口径
数据窥探	显著性失效	记录全部试验次数，做多重检验校正
交易成本忽视	高估净收益	加入冲击成本与延迟，做容量测试
参数过拟合	样本外崩塌	Purged k-折、DSR、PBO 检验
不可交易性	收益不可实现	剔除涨跌停、停牌与低流动性标的

$$p_{(i)} \le \frac{i}{m}\,\alpha \tag{1.11}$$

并拒绝前 i 个假设。其中 α 为目标 FDR 水平（常取 5%）。当 $m=100$、$\alpha=0.05$ 时，最小的 p 值只需小于 0.0005 看似相同，但第 10 个只需小于 0.005，比 Bonferroni 宽松得多，因此在因子筛选中更实用。

第三层：对最大 Sharpe 比率本身做校正。Deflated Sharpe Ratio 给出

$$DSR = \Phi\left(\frac{\left(\widehat{SR} - SR_0\right)\sqrt{T-1}}{\sqrt{1-\hat{\gamma}_3\widehat{SR}+\frac{\hat{\gamma}_4-1}{4}\widehat{SR}^2}}\right) \tag{1.12}$$

其中 $\widehat{SR}$ 为观测到的（非年化）Sharpe 比率，T 为样本长度，$\hat{\gamma}_3$ 为收益偏度，$\hat{\gamma}_4$ 为收益峰度，SR_0 为多重检验下的期望最大值

$$SR_0 = \sqrt{\mathrm{Var}(\widehat{SR})}\left[(1-\gamma)\,\Phi^{-1}\!\left(1-\frac{1}{m}\right)+\gamma\,\Phi^{-1}\!\left(1-\frac{1}{me}\right)\right] \tag{1.13}$$

其中 $\gamma \approx 0.5772$ 为 Euler–Mascheroni 常数，$\mathrm{Var}(\widehat{SR})$ 为不同试验间 Sharpe 比率的方差。

例 1.3 DSR 的实际杀伤力

设某策略日频 Sharpe 比率 $\widehat{SR}=0.08$（年化约 1.27），样本 $T=1000$ 天，偏度 $\hat{\gamma}_3=-0.3$，峰度 $\hat{\gamma}_4=6$。研究者共试验 $m=50$ 个变体，变体间 Sharpe 比率的标准差为 0.05。代入 式 (1.13)：$\Phi^{-1}(1-1/50)=2.054$，$\Phi^{-1}(1-1/(50\mathrm{e}))=\Phi^{-1}(0.99264)=2.44$，故 $SR_0=0.05\times(0.4228\times2.054+0.5772\times2.44)=0.05\times(0.868+1.409)=0.114$。由于 $\widehat{SR}<SR_0$，式 (1.12) 的分子为负，$DSR\approx\Phi(-2.2)\approx1.4\%$。也就是说，在 50 次试验的背景下，这个看起来年化 Sharpe 1.27 的策略连 5% 的显著性都达不到。

补充工具：White's Reality Check 用 bootstrap 检验"最优策略的真实绩效是否为零"，对策略集合的最大值做数据挖掘矫正；PBO（Probability of Backtest Overfitting）则用组合对称交叉验证（CSCV）估计"样本内最优策略在样本外落到中位数以下"的概率，$PBO > 0.5$ 是明确的过拟合警报。

⚠ 风险警示　回测过拟合的数学本质

若研究者测试 m 个真实绩效为零的策略，最优样本 Sharpe 比率的期望约为 $\sqrt{\mathrm{Var}(\widehat{SR})} \cdot \mathbb{E}[\max_m Z] \approx 0.05 \times 2.1 = 0.105$（$m = 50$ 时），对应年化 1.66。也就是说，*只要试验次数足够多，在完全没有 Alpha 的数据上也能稳定找到年化 Sharpe 超过 1.6 的策略*。回测报告若不披露试验次数，其 Sharpe 比率没有统计意义。

1.6.3 实施缺口与交易成本

回测与实盘的差距称为实施缺口（Implementation Shortfall），由四部分组成：决策价格与下单价格之间的延迟成本、买卖价差成本、市场冲击成本与机会成本（未成交部分）。冲击成本的常用模型为平方根律

$$\text{Impact} \approx \eta\, \sigma_{\text{daily}} \sqrt{\frac{Q}{V_{\text{daily}}}} \tag{1.14}$$

其中 Q 为下单股数，V_{daily} 为该股票日均成交量，σ_{daily} 为日波动率，η 为经验常数（美股大盘股常用 0.3 至 0.8）。例：$\eta = 0.5$、$\sigma_{\text{daily}} = 2\%$、$Q/V = 10\%$，则冲击成本约 $0.5 \times 0.02 \times 0.316 = 0.32\%$，单边成本已超过日频因子单期预期收益 $IC \cdot \sigma = 0.03 \times 2\% = 0.06\%$ 的五倍。这是容量约束的核心来源：规模越大，越只能交易低频、低换手的因子。

1.7 市场微观结构与最优执行

1.7.1 订单簿与价差分解

限价订单簿（Limit Order Book）在每个价位维护价格、数量与队列优先级。由它派生的三个量最常用：买卖价差 $s = p^a - p^b$；中间价 $m = (p^a + p^b)/2$；订单流不平衡 $\mathrm{OFI}_t = \Delta V_t^b - \Delta V_t^a$，其中 V^b、V^a 为最优买卖档的挂单量。OFI 对短期价格变动有显著预测力，是日内做市与执行算法的核心输入。

价差可分解为三部分：订单处理成本、存货持有成本与逆向选择成本。在 Glosten–Milgrom 模型里，做市商面对一部分知情交易者，每笔成交都包含信息含量，因此必须用价差补偿与知情者交易的损失，均衡价差满足

$$s = \frac{2\mu}{1-\mu}\,(\theta - \bar{v}) \tag{1.15}$$

其中 μ 为知情交易者比例，θ 为知情者眼中的资产价值，$\bar{v}$ 为做市商的先验均值。当 $\mu \to 0$ 时价差趋于零，市场近似无摩擦。

1.7.2 Kyle 模型的均衡推导

Kyle(1985)模型用一个交易日刻画信息如何被逐步定价。设资产清算价值 $v \sim \mathcal{N}(v_0, \Sigma_0)$，知情交易者知道 v，提交市价单数量 x；噪声交易者提交 $u \sim \mathcal{N}(0, \sigma_u^2)$，与 v 独立；做市商只观测到总订单流 $y = x + u$，并按线性规则定价，且赚取零期望利润。

定理 1.1 (Kyle 模型的线性均衡) 若做市商定价 $p = v_0 + \lambda y$，知情交易者提交 $x = \beta(v - v_0)$，则唯一线性均衡为

$$\beta = \frac{\sigma_u}{\sqrt{\Sigma_0}}, \qquad \lambda = \frac{1}{2}\sqrt{\frac{\Sigma_0}{\sigma_u^2}} = \frac{1}{2\sigma_u}, \qquad \mathbb{E}[\pi_{\text{insider}}] = \frac{1}{2}\sigma_u\sqrt{\Sigma_0} \tag{1.16}$$

其中 λ 为价格冲击系数（Kyle's Lambda），即每单位订单流引起的价格变动。

证明. 先给定 λ，求解知情者的最优下单量。其期望利润为

$$\mathbb{E}[\pi \mid v] = \mathbb{E}\big[(v - v_0 - \lambda(x+u))\,x \mid v\big] = x(v - v_0) - \lambda x^2$$

对 x 求导并令其为 0，得 $x^* = (v - v_0)/(2\lambda)$，故 $\beta = 1/(2\lambda)$。

再做市商的零利润条件要求 $p = \mathbb{E}[v \mid y]$。由正态投影公式 $\mathbb{E}[v \mid y] = v_0 + \frac{\mathrm{Cov}(v,y)}{\mathrm{Var}(y)}(y - \mathbb{E}[y])$，且 $\mathrm{Cov}(v, y) = \mathrm{Cov}\big(v, \beta(v - v_0) + u\big) = \beta\Sigma_0$，$\mathrm{Var}(y) = \beta^2\Sigma_0 + \sigma_u^2$，因此 $\lambda = \dfrac{\beta\Sigma_0}{\beta^2\Sigma_0 + \sigma_u^2}$。

把 $\beta = 1/(2\lambda)$ 代入并化简：分母为 $\frac{\Sigma_0}{4\lambda^2} + \sigma_u^2$，故 $\lambda = \dfrac{\Sigma_0/(2\lambda)}{\Sigma_0/(4\lambda^2) + \sigma_u^2}$，两边同乘分母得 $\frac{\Sigma_0}{4\lambda} + \lambda\sigma_u^2 = \frac{\Sigma_0}{2\lambda}$，即 $\lambda\sigma_u^2 = \frac{\Sigma_0}{4\lambda}$，于是 $\lambda^2 = \frac{\Sigma_0}{4\sigma_u^2}$，取正根得 $\lambda = \frac{1}{2}\sqrt{\Sigma_0/\sigma_u^2} = 1/(2\sigma_u)$，从而 $\beta = \sigma_u/\sqrt{\Sigma_0}$。最后把 x^* 代回期望利润即得 $\mathbb{E}[\pi] = \frac{\beta\Sigma_0}{2} = \frac{1}{2}\sigma_u\sqrt{\Sigma_0}$。 ■

直觉理解　Kyle's Lambda 的读法

λ 同时是三个东西：市场的价格冲击系数（每 1 单位订单流推动价格多少）、流动性深度的倒数（λ 越小越深）、以及知情者信息的"税率"。当噪声交易量 σ_u 上升时 λ 下降，因为知情者的订单更容易被噪声淹没；当信息不确定性 $\sqrt{\Sigma_0}$ 上升时 λ 上升，因为做市商更怕与知情者成交。

例 1.4　Kyle 均衡的数值计算

设 $v_0 = 50$ 元、$\Sigma_0 = 4$（即事前价格标准差 2 元）、噪声订单量标准差 $\sigma_u = 10000$ 股。代入 式 (1.16) 得 $\lambda = \frac{1}{2}\sqrt{4/10^8} = \frac{1}{2} \times 2 \times 10^{-4} = 1.0 \times 10^{-4}$ 元/股，即每 1 万股净买入推动价格上涨 1 元；$\beta = 10^4/2 = 5000$ 股/元。若真实价值高于事前均值 1 元，知情者最优下单 $x^* = 1/(2\lambda) = 5000$ 股，期望利润 $\mathbb{E}[\pi] = \frac{1}{2} \times 10^4 \times 2 = 10^4$ 元。注意知情者的期望利润只依赖于 σ_u 与 $\sqrt{\Sigma_0}$，与其私有信息的实现值无关——这是竞争性噪声环境下的一个反直觉但深刻的结论。

1.7.3 Almgren–Chriss 最优执行

执行问题问的是：给定要在 T 时间内卖出 X_0 股，如何分配下单节奏？卖掉越快，冲击成本越高；卖得越慢，价格波动风险越大。Almgren–Chriss 把这个权衡写成期望成本加风险惩罚的最小化问题。设 $t_k = k\tau$，持仓 x_k，每期卖出 $n_k = x_{k-1} - x_k$，价格满足

$$S_k = S_{k-1} + \sigma\sqrt{\tau}\,\xi_k - \gamma\, n_k, \qquad \tilde{S}_k = S_{k-1} - \frac{1}{2}s\,\operatorname{sgn}(n_k) - \eta\,\frac{n_k}{\tau} \tag{1.17}$$

其中 σ 为价格波动率，γ 为永久冲击系数，η 为临时冲击系数，s 为买卖价差，$\tilde{S}_k$ 为实际成交价。实现价差为 $C = \sum_{k=1}^{N} n_k(S_0 - \tilde{S}_k)$，目标是最小化 $\mathbb{E}[C] + \kappa_r \operatorname{Var}(C)$，其中 κ_r 为风险厌恶系数。

定理 1.2 (线性冲击下的最优执行轨迹) 在上述设定下，若忽略价差项 s，最优持仓路径为指数衰减

$$x_k = X_0\,\frac{\sinh\big(\kappa(T - t_k)\big)}{\sinh(\kappa T)}, \qquad \kappa \approx \sqrt{\frac{\kappa_r \sigma^2}{\eta}} \tag{1.18}$$

其中 sinh 为双曲正弦，κ 为执行速率（单位 1/ 时间）。当 $\kappa T \to 0$ 时轨迹退化为匀速卖出（TWAP），即最小化冲击成本；当 κT 很大时轨迹前重后轻，即优先压缩风险暴露。

证明思路. 把 x_k 视为决策变量，期望成本可写成二次型 $\mathbb{E}[C] = \frac{1}{2}\gamma X_0^2 + \eta\sum_{k=1}^{N}\frac{n_k^2}{\tau}$，方差为 $\operatorname{Var}(C) = \sigma^2\tau\sum_{k=1}^{N} x_{k-1}^2$。目标函数对 x_k 是凸二次函数，一阶条件给出二阶线性差分方程 $\frac{\eta}{\tau}(x_{k+1} - 2x_k + x_{k-1}) = \kappa_r\sigma^2\tau\, x_k$，边界条件为 $x_0 = X_0$、$x_N = 0$。该方程的通解为 $x_k = A\mathrm{e}^{\kappa t_k} + B\mathrm{e}^{-\kappa t_k}$，代入边界条件即得 式 (1.18)，其中 $\cosh(\kappa\tau) = 1 + \frac{\kappa_r\sigma^2\tau^2}{2\eta}$，在小步长下近似为 $\kappa \approx \sqrt{\kappa_r\sigma^2/\eta}$。 ■

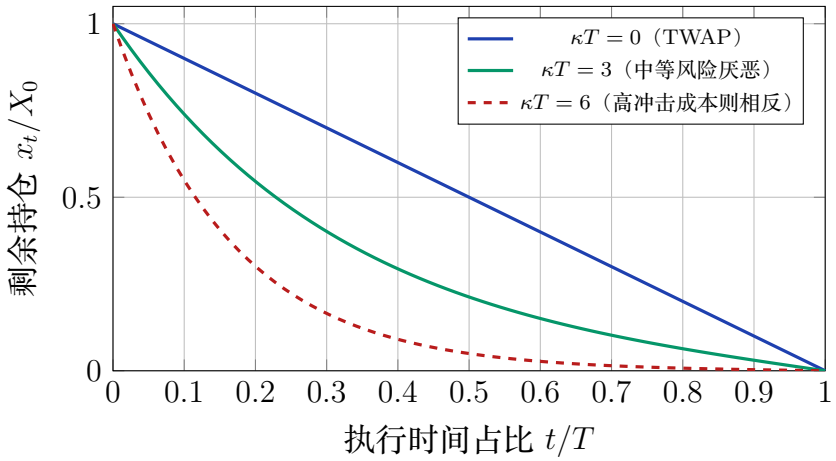


图 1.2 Almgren–Chriss 最优执行轨迹：κ 越大越前重后轻，把风险暴露集中在执行早期

图 1.2 给出三条轨迹。$\kappa T = 0$ 是 TWAP，最小化冲击成本但全程承担价格风险；$\kappa T = 6$ 时前 20% 的时间就完成了约 70% 的卖出量。决定 κ 大小的关键是比率 $\kappa_r\sigma^2/\eta$：波动率越高、风险厌恶越强、临时冲击越便宜，就越应当快速执行。

例 1.5 五年期对冲基金的执行成本权衡

某基金需在 5 个交易日内卖出 $X_0 = 10^6$ 股某美股，当前价 $S_0 = 50$ 元，日波动率 $\sigma_{\text{daily}} = 2\%$，临时冲击 $\eta = 2.0\times10^{-6}$ 元 · 日/股 ^{2}，永久冲击 $\gamma = 1.0\times10^{-7}$ 元/股。取风险厌恶 κ_r 使 $\kappa_r\sigma^2 = 0.4$（单位：元/股 ^{2}/日），则 $\kappa = \sqrt{0.4/2.0\times10^{-6}} \approx 447$ /日，$\kappa T \approx 2235 \gg 1$。这意味着在纯二次冲击模型下，最优解会把绝大部分股票在极短时间内抛出。现实中这种情况不会发生，因为冲击成本函数在快速交易时迅

速非线性上升，因此实务上必须在 式 (1.17) 中加入幂律冲击项或参与率上限约束，把 κT 压回 1 至 5 的区间，再按 式 (1.18) 生成日内曲线。

表 1.6　执行算法比较

算法	目标	优点	主要缺陷
TWAP	均匀成交	简单、低冲击	不响应流动性变化
VWAP	跟随成交量	降低冲击	需成交量预测，易被识别
POV	固定参与率	控制冲击	完成时间不确定
IS	最小化实施缺口	显式权衡风险	需波动率与冲击参数标定
自适应	动态学习	应对流动性突变	参数不稳定，过拟合风险

⚠ 风险警示　微观结构模型的失效条件

Kyle 与 Almgren–Chriss 的共同假设是：冲击对订单流近似线性、噪声交易量平稳、做市商竞争充分。在以下情形它们会显著低估成本：一是订单流本身包含大量同向的机构订单（“订单流毒性”上升，λ 非线性放大）；二是市场出现跳跃或新闻冲击，波动率参数突然抬升数倍；三是标的流动性极差（小盘股、部分转债），此时冲击函数近似阶跃而非线性，模型给出的 TWAP 曲线会造成严重的价格崩塌。

1.8 代码实现：中性化与 IC 计算

Listing 1.1　因子去极值、标准化、行业与风格中性化及 IC 计算

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
from scipy.stats import spearmanr

rng = np.random.default_rng(7)
dates = pd.date_range("2020-01-01", periods=60, freq="B")
industries = ["tech", "fin", "health", "energy", "cons"]

rows = []
for d in dates:
    n = 300
    ind = rng.choice(industries, size=n)
    logmcap = rng.normal(10.0, 1.2, size=n)
    vol60 = np.abs(rng.normal(0.25, 0.06, size=n))
    signal = 0.3 * logmcap - 0.5 * vol60 + rng.normal(0, 1.0, size=n)
    fwd_ret = 0.01 * signal + 0.02 * logmcap + rng.normal(0, 0.03, size=n
        )
    rows.append(pd.DataFrame({"date": d, "industry": ind, "logmcap":
        logmcap,
                              "vol60": vol60, "signal": signal, "fwd_ret"
                                  : fwd_ret}))
```

```
panel = pd.concat(rows, ignore_index=True)

def winsorize(s, k=3.0):
    med = s.median()
    mad = (s - med).abs().median()
    lo, hi = med - k * 1.4826 * mad, med + k * 1.4826 * mad
    return s.clip(lo, hi)

def neutralize(df):
    z = winsorize(df["signal"])
    z = (z - z.mean()) / z.std()
    dummies = pd.get_dummies(df["industry"], drop_first=True).astype(
        float)
    X = pd.concat([dummies, df[["logmcap", "vol60"]]], axis=1)
    X = sm.add_constant(X)
    res = sm.OLS(z.values, X.values).fit()
    return z.values - res.fittedvalues

panel["factor"] = panel.groupby("date", group_keys=False).apply(
    neutralize)
ic = panel.groupby("date").apply(
    lambda g: spearmanr(g["factor"], g["fwd_ret"])[0])
print("mean rank IC = %.4f" % ic.mean(), "| IC IR = %.3f" % (ic.mean() /
    ic.std()))
```

Listing 1.2 分层回测与多重检验（Benjamini–Hochberg FDR）调整

```
import numpy as np
import pandas as pd
from scipy.stats import norm, spearmanr

rng = np.random.default_rng(11)

def layered_backtest(factor, fwd_ret, n_layers=5):
    df = pd.DataFrame({"factor": factor, "fwd_ret": fwd_ret})
    df["layer"] = pd.qcut(df["factor"].rank(method="first"), n_layers,
        labels=False)
    layer_ret = df.groupby("layer")["fwd_ret"].mean()
    ls = layer_ret.iloc[-1] - layer_ret.iloc[0]
    return layer_ret, ls

n_days, n_stocks = 800, 400
panel_factor = rng.normal(size=(n_days, n_stocks))
panel_ret = 0.03 * panel_factor + rng.normal(scale=0.03, size=(n_days,
    n_stocks))
layer_hist = np.array([layered_backtest(panel_factor[t], panel_ret[t])[1]
                       for t in range(n_days)])
ir = layer_hist.mean() / layer_hist.std() * np.sqrt(252)
print("long-short annualized IR = %.2f" % ir)

def bh_fdr(pvals, alpha=0.05):
```

```
    pvals = np.asarray(pvals)
    order = np.argsort(pvals)
    m = pvals.size
    thresh = alpha * (np.arange(1, m + 1)) / m
    passed = pvals[order] <= thresh
    k = np.max(np.flatnonzero(passed)) + 1 if passed.any() else 0
    rejected = np.zeros(m, dtype=bool)
    rejected[order[:k]] = True
    return rejected

# 200 trials with a genuinely zero signal: report how many look
    significant
pvals = []
for _ in range(200):
    noise = rng.normal(size=(n_days, n_stocks))
    ret = rng.normal(scale=0.03, size=(n_days, n_stocks))
    ics = [spearmanr(noise[t], ret[t])[0] for t in range(n_days)]
    tstat = np.mean(ics) / (np.std(ics, ddof=1) / np.sqrt(n_days))
    pvals.append(2 * (1 - norm.cdf(abs(tstat))))
print("raw p<0.05 count =", int(np.sum(np.array(pvals) < 0.05)),
      "| BH FDR survivors =", int(bh_fdr(pvals).sum()))
```

listings 1.1 and 1.2 给出两段可直接运行的实现。前者展示了 小节 1.2.1 的完整流水线，注意中性化必须按交易日分组进行，绝不能在全样本上做标准化，否则会用未来信息估计横截面均值与标准差。后者的最后一段刻意用纯噪声生成 200 个策略：在 5% 水平上通常有 8 至 12 个“显著”，而 Benjamini–Hochberg 调整后基本全部被剔除。这是式 (1.11) 最直观的演示。

核心要点 1.2 P Quant 的两条铁律

第一，任何信号在进入组合之前必须完成去极值、标准化与中性化，并且按日分组计算，否则回测结果不可解释。第二，任何绩效结论必须与试验次数、成本假设和样本外检验方式一起报告；缺少这三项的 Sharpe 比率不能作为决策依据。

本章小结

- 因子构建流水线为去极值、标准化、缺失值处理、行业与风格中性化四步，顺序不可调换；中性化用横截面回归 式 (1.1) 取残差，权重常取市值平方根。
- Barra 型风险模型把收益分解为 $Xf+u$，因子收益用加权最小二乘估计 式 (1.3)，因子协方差需用 Newey–West 与特征值调整稳健化。
- IC 与 Rank IC 衡量横截面预测能力，其信噪比必须用有效独立期数折算；持仓周期应与 IC 半衰期匹配。
- 主动管理基本定律 $IR \approx IC\sqrt{N}$，现实修正为 $IC\sqrt{N_{\text{eff}}}TC$，下注相关性会摧毁广度带来的全部优势。
- 机器学习选股必须配 Purged k-折与 embargo、样本权重与标签区间管理，否则

特征重要性与样本外绩效均不可信。

- 回测的三层多重检验校正分别是 Bonferroni、Benjamini–Hochberg FDR 与 DSR/PBO；不披露试验次数的回测报告没有统计意义。
- 微观结构层面，Kyle 模型给出 $\lambda = \frac{1}{2}\sqrt{\Sigma_0/\sigma_u^2}$，Almgren–Chriss 给出指数衰减的最优执行轨迹，二者共同决定策略的容量上限。

练习与思考

1. 设某月频因子在 2000 只股票上的月均 Rank IC 为 0.035，IC 序列标准差为 0.08，自相关时间 $\tau = 1.5$ 个月。样本共 96 个月。请计算 $\overline{IC}$ 的标准误与 t 值，并判断该因子在 5% 水平上是否显著。若不考虑自相关，t 值会被高估多少？
2. 推导 命题 1.1 时假定各下注收益独立。若下注分为 10 个行业组，组内相关系数 0.3、组间相关系数 0，每组 50 个下注，求 N_{eff} 与信息比率相对独立情形的衰减比例。
3. 在 Kyle 模型中，取 $\Sigma_0 = 9$、$\sigma_u = 30000$。求 λ、β 与知情者期望利润；若噪声交易量翻倍，λ 与期望利润各如何变化？请解释为什么知情者的期望利润会随噪声交易量上升。
4. 用 式 (1.18) 计算 $X_0 = 2 \times 10^6$ 股、$T = 1$ 日、$\kappa = 5$ /日条件下的最优持仓路径（取 $N = 5$ 段），并与 TWAP 比较前两段的卖出量差异。
5. 编写代码复现 listing 1.2 中 200 个纯噪声策略的检验，分别统计未校正、Bonferroni 与 Benjamini–Hochberg 三种方法下的“显著”策略数，并解释三者差异。
6. 某策略在 60 次参数试验中取得最优年化 Sharpe 1.5，样本 750 天，试验间 Sharpe 标准差 0.06。用 式 (1.13) 与 式 (1.12) 计算 DSR，并讨论该策略是否值得实盘配置。

延伸阅读

- Grinold, R., and Kahn, R., *Active Portfolio Management*, 2nd ed., McGraw-Hill, 2000.（第 6 章给出主动管理基本定律的完整推导与转移系数的实务讨论）
- Ang, A., *Asset Management: A Systematic Approach to Factor Investing*, Oxford University Press, 2014.（把因子投资、风险模型与组合构建放在统一框架下，适合建立全局图景）
- Kyle, A., “Continuous Auctions and Insider Trading”, *Econometrica*, 1985.（微观结构领域的奠基论文，模型虽短但均衡推导值得逐行复现）
- Almgren, R., and Chriss, N., “Optimal Execution of Portfolio Transactions”, *Journal of Risk*, 2000.（最优执行的经典参考，含离散与连续两种推导与成本分解）
- López de Prado, M., *Advances in Financial Machine Learning*, Wiley, 2018.（Purged k-折、DSR 与 PBO 的原始出处，回测方法论章节最实用）
- Bailey, D., and López de Prado, M., “The Deflated Sharpe Ratio”, *Journal of Portfolio Management*, 2014.（多重检验下绩效显著性校正的标准文献，附完整公式与数值示例）