第一章 金融概率与统计分析

金融数据与教科书里的独立同分布样本有一段距离：收益的尾部比正态厚得多，波动率会成簇出现，横截面上的个体差异与时间效应纠缠在一起，而研究者又往往在同一个数据集上反复试验。本章按「分布假定—估计—检验—回归—贝叶斯—尾部」的顺序铺设 P Quant 的统计基础设施，并在每一个环节标出金融数据的特殊之处。

1.1 概率论基础与分布族

1.1.1 随机变量、矩与特征函数

随机变量 X 的分布由累积分布函数 $F_X(x)=\mathbb{P}(X\le x)$ 完全刻画，若 F_X 绝对连续则概率密度为 $f_X(x)=\mathrm{d}F_X(x)/\mathrm{d}x$。分布的形态由矩与特征函数描述

$$\mu'_k=\mathbb{E}\left[X^k\right],\qquad \mu_k=\mathbb{E}\left[(X-\mathbb{E}[X])^k\right],\qquad \gamma_1=\frac{\mu_3}{\mu_2^{3/2}},\qquad \gamma_2=\frac{\mu_4}{\mu_2^2}-3 \tag{1.1}$$

其中 μ'_k 为 k 阶原点矩，μ_k 为 k 阶中心矩，γ_1 为偏度，γ_2 为超额峰度（正态分布下为 0）。$\gamma_2>0$ 意味着肥尾：极端事件比正态预测的更频繁。以标准正态为基准，$|Z|>3$ 的概率约为 0.27%；而自由度 $\nu=5$ 的 t 分布对应概率约为 1.9%，是正态的 7 倍。这正是风险管理不能简单套用正态假设的原因。

⚠ 风险警示　厚尾下样本矩的失效

当 $\nu\le 4$ 时 t 分布的四阶矩不存在，样本峰度的期望不收敛，用有限样本估计的峰度会随样本长度剧烈跳动，且系统性低估真实尾部厚度。当 $\nu\le 2$ 时连方差都不存在，样本标准差不再是有效的离散度度量。因此对高频收益，宁可报告分位数与分位数间距，也不要报告标准差。

矩母函数 $M_X(t)=\mathbb{E}[\mathrm{e}^{tX}]$ 并非总存在（厚尾分布常常没有），而特征函数 $\phi_X(t)=\mathbb{E}[\mathrm{e}^{\mathrm{i}tX}]$ 对任意分布都存在，且唯一决定分布。这一性质是 Fourier 变换类期权定价方法的基础：只要知道标的对数价格的特征函数，就能通过数值积分反演密度或直接计算期权价格。常用性质包括 $\phi_{aX+b}(t)=\mathrm{e}^{\mathrm{i}bt}\phi_X(at)$，以及独立随机变量和的特征函数等于各自特征函数之积。

1.1.2 金融收益的分布族

表 1.1 中最常用的两个是学生 t 分布与广义误差分布。t 分布的密度为

表 1.1 金融收益建模常用的分布族对比

分布	尾部行为	典型参数	适用与局限
正态	指数衰减	μ, σ	基准模型；对日频收益严重低估尾部
对数正态	指数衰减	μ, σ	适用于价格；收益仍非正态
学生 t	幂律	ν	日频收益首选；ν 常估在 3 至 6
偏 t	幂律且不对称	ν, λ	刻画下跌尾部更厚；参数估计较难
GED	幂律可变	ν	$\nu<2$ 厚尾、$\nu>2$ 薄尾
稳定分布	幂律	$\alpha,\beta,\gamma,\delta$	方差可能无穷；α 常估在 1.6 至 1.9
GEV	幂律	ξ, μ, σ	建模极值块最大值
GPD	幂律	ξ, β	超阈值超额损失，EVT 风险度量核心

$$f(x;\nu)=\frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)}\left(1+\frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}} \tag{1.2}$$

其中 $\nu>0$ 为自由度，$\Gamma(\cdot)$ 为 Gamma 函数。当 $\nu\to\infty$ 时 $f(x;\nu)$ 逐点收敛到标准正态密度；ν 越小尾部越厚。GED 的密度为

$$f(x;\nu)=\frac{\nu\,\exp\left(-\frac{1}{2}\left|x/\lambda\right|^{\nu}\right)}{\lambda\,2^{1+1/\nu}\,\Gamma(1/\nu)},\qquad \lambda=\left(\frac{2^{-2/\nu}\,\Gamma(1/\nu)}{\Gamma(3/\nu)}\right)^{1/2} \tag{1.3}$$

其中 ν 控制尾部形状（$\nu=2$ 退化为正态），λ 为尺度参数，其取值由方差归一化条件决定。GED 在 GARCH 族的实证中比正态显著改善对数似然，且在 $\nu>2$ 时可以刻画比正态更薄的尾部，因此适用范围比 t 分布更宽。

图 1.1 用对数密度作图，因为直接画密度时尾部差异在视觉上会被完全压缩。在 $|x|=6$ 处，正态的对数密度约为 -18.4，而 $t(5)$ 的对应值约为 -11.2，二者相差约 7.2，即概率相差约 $\mathrm{e}^{7.2}\approx 1300$ 倍。把这一差异代入日频 VaR：若日波动率为 2%，正态假设下 99.9% 的 VaR 约为 $2\%\times 3.09=6.2\%$，而 $t(5)$ 假设下同一分位数对应的倍数约为 5.9，VaR 约为 11.8%，几乎翻倍。低估的这 5.6 个百分点在压力期就是真实的资本缺口。

1.2 估计方法

1.2.1 极大似然估计与渐近正态性

设样本 $x_1,\dots,x_n$ 独立同分布，密度为 $f(x;\theta)$，$\theta\in\Theta\subset\mathbb{R}^p$。对数似然为 $\ell(\theta)=\sum_{i=1}^{n}\ln f(x_i;\theta)$，极大似然估计为

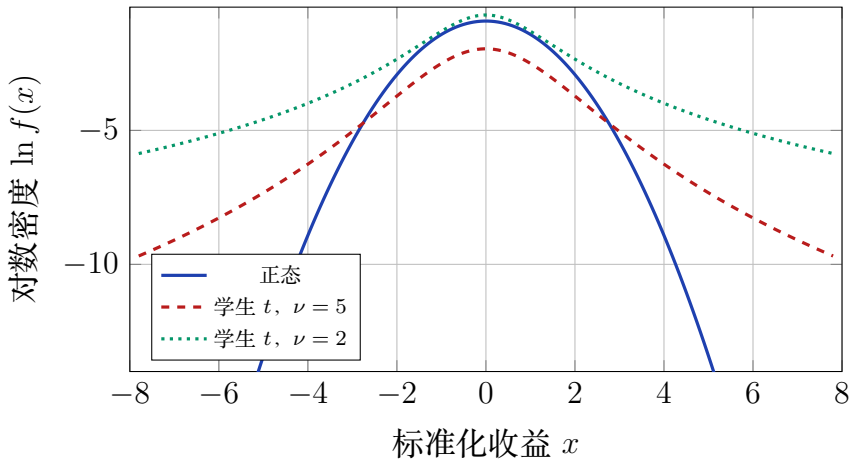


图 1.1 正态分布与 t 分布的尾部对比：在 $|x|=6$ 处，$t(5)$ 的对数密度比正态高约 7 个自然对数单位，对应概率相差千倍

$$\hat{\theta}_{\mathrm{MLE}} = \arg\max_{\theta\in\Theta} \ell(\theta) \tag{1.4}$$

在正则条件下，$\hat{\theta}_{\mathrm{MLE}}$ 具有一致性与渐近正态性

$$\sqrt{n}\left(\hat{\theta}_{\mathrm{MLE}} - \theta_0\right) \xrightarrow{\mathrm{d}} \mathcal{N}\!\left(0,\ \mathcal{I}(\theta_0)^{-1}\right), \qquad \mathcal{I}(\theta) = -\mathbb{E}\!\left[\frac{\partial^2 \ln f(X;\theta)}{\partial \theta^2}\right] \tag{1.5}$$

其中 $\mathcal{I}(\theta)$ 为 Fisher 信息矩阵，θ_0 为真值。由 Cramér–Rao 下界，任何无偏估计量的方差都不小于 $\mathcal{I}(\theta_0)^{-1}/n$，因此 MLE 渐近达到最小方差。实务中用观测信息矩阵 $\hat{\mathcal{I}} = -\frac{1}{n}\sum_{i} \frac{\partial^2 \ln f(x_i;\hat\theta)}{\partial\theta^2}$ 或外积形式 $\frac{1}{n}\sum_i \left(\frac{\partial \ln f(x_i;\hat\theta)}{\partial\theta}\right)\left(\frac{\partial \ln f(x_i;\hat\theta)}{\partial\theta}\right)^{\top}$ 代入即可得到标准误。

例 1.1 学生 t 分布自由度的矩估计与 MLE

对某指数 3000 个日对数收益做标准化后，样本超额峰度为 4.8。由 $t(\nu)$ 的超额峰度公式 $\gamma_2 = 6/(\nu-4)$ $(\nu>4)$，矩估计给出 $\nu \approx 4 + 6/4.8 = 5.25$。经验上 t 分布的 MLE 在 ν 较小时会给出比矩估计略大的值，本例中若 MLE 输出 $\hat\nu = 5.6$，则对应的理论超额峰度为 $6/1.6 = 3.75$，低于样本峰度 4.8。这一差异并不矛盾：样本峰度本身方差极大，MLE 是在整个似然面上做权衡，而不是硬性匹配四阶矩。listing 1.1 给出可直接运行的实现。

1.2.2 广义矩方法与最优权重

当密度难以写出但矩条件明确时，GMM 更合适。设矩条件为 $\mathbb{E}[g(X_i,\theta_0)] = 0$，$g \in \mathbb{R}^q$ 且 $q \ge p$，样本矩为 $\bar g_n(\theta) = \frac{1}{n}\sum_{i=1}^{n} g(X_i,\theta)$，则

$$\hat{\theta}_{\mathrm{GMM}} = \arg\min_{\theta\in\Theta}\ \bar g_n(\theta)^{\top} W_n\, \bar g_n(\theta) \tag{1.6}$$

其中 W_n 为 $q\times q$ 的权重矩阵。若取 $W_n = S^{-1}$，$S = \mathbb{E}[g(X_i,\theta_0)g(X_i,\theta_0)^{\top}]$ 为矩条件的协方差矩阵，则 $\hat\theta_{\mathrm{GMM}}$ 是渐近有效的，其渐近方差为 $(G^{\top}S^{-1}G)^{-1}$，$G = \mathbb{E}[\frac{\partial g(X_i,\theta_0)}{\partial\theta}]$。实

践中的两步法：第一步用 $W_n = I$ 得到一致估计 $\hat{\theta}_1$，用它估计 $\hat{S}$，第二步用 $W_n = \hat{S}^{-1}$ 重新最小化。

矩条件个数超过参数个数（$q > p$）时模型存在过度识别，可用 J 检验考察矩条件是否成立

$$J = n\,\bar{g}_n(\hat{\theta})^\top \hat{S}^{-1} \bar{g}_n(\hat{\theta}) \xrightarrow{\mathrm{d}} \chi^2_{q-p} \tag{1.7}$$

其中 χ^2_{q-p} 为自由度 $q-p$ 的卡方分布。J 统计量过大意味着数据拒绝了模型隐含的矩关系，例如在资产定价中意味着因子无法解释横截面收益。

1.3 假设检验与多重检验

1.3.1 三种渐近等价检验

设原假设 $H_0 : \theta = \theta_0$ 把参数约束到 $p-r$ 维子空间，无约束 MLE 为 $\hat{\theta}$，约束 MLE 为 $\tilde{\theta}$。三种经典检验为

$$LR = 2\left(\ell(\hat{\theta}) - \ell(\tilde{\theta})\right) \xrightarrow{\mathrm{d}} \chi^2_r \tag{1.8}$$

$$W = n\left(\hat{\theta} - \theta_0\right)^\top \hat{\mathcal{I}}\left(\hat{\theta} - \theta_0\right) \xrightarrow{\mathrm{d}} \chi^2_r \tag{1.9}$$

$$S = n\,\bar{s}(\theta_0)^\top \hat{\mathcal{I}}^{-1} \bar{s}(\theta_0) \xrightarrow{\mathrm{d}} \chi^2_r, \qquad \bar{s}(\theta) = \frac{1}{n}\sum_{i=1}^{n} \frac{\partial \ln f(x_i;\theta)}{\partial \theta} \tag{1.10}$$

其中 $\bar{s}(\theta)$ 为得分函数（score），r 为约束个数，$\hat{\mathcal{I}}$ 为观测信息矩阵。三者在 H_0 下渐近同分布，有限样本中的表现不同：Wald 检验对参数的重新参数化不敏感（不满足不变性），Score 检验只需在 H_0 下估计，适合约束估计困难的场景；LR 检验通常最稳健，但需要同时求解两个优化问题。

表 1.2 三种经典检验在金融应用中的选择

检验	需要的估计	优点	典型金融用途
LR	无约束与约束 MLE	最优不变性	检验 GARCH 参数约束、模型阶数
Wald	无约束 MLE	计算最简便	检验因子载荷是否为零、Granger 因果
Score	仅约束下估计	只需估一次	检验附加因子是否提供增量信息

1.3.2 多重检验与 FDR

因子研究几乎总是在同一数据集上试验大量假设。若对 m 个真实无效的信号逐一用 5% 水平检验，期望假发现数为 $0.05m$；当 $m = 200$ 时约 10 个。控制假发现比例（FDR）

的 Benjamini–Hochberg 程序把 p 值排序后取

$$k = \max\left\{ i : \; p_{(i)} \le \frac{i}{m}\,\alpha \right\} \tag{1.11}$$

并拒绝前 k 个假设，其中 α 为目标 FDR。与原假设全为真时的 Bonferroni 校正 $p_{(i)} \le \alpha/m$ 相比，BH 在备择假设较多时严格更宽松。两个程序的差别在 表 1.3 中用一个 $m = 200$ 的例子说明。

表 1.3　$m = 200$ 次真实无效检验下的假发现控制对比（$\alpha = 5\%$，均为期望值）

控制程序	最小 p 值门槛	第 10 小 p 值门槛	期望假发现数
不校正	0.0500	0.0500	10.0
Bonferroni（FWER）	0.00025	0.00025	0.05
Benjamini–Hochberg（FDR）	0.00025	0.00250	≤ 0.10

表 1.3 显示 BH 的判据随序位放宽，因此在因子筛选中能保留更多真信号。需要强调的是：FDR 控制的是被拒绝假设中假发现的比例期望，它不保证每一个被选中的因子都真实有效，因此在实盘配置前仍需样本外验证与成本核算。

实务应用　极值理论在银行内部模型中的实际用法

按巴塞尔市场风险框架，银行内部模型需同时报告 97.5% 的 ES 与压力情景下的损失。实务流程是：先用 GARCH 类模型得到条件波动率的过滤序列（把波动率聚集剥离），再对标准化残差做 POT/GPD 拟合，最后把 GPD 分位数乘回当期波动率，得到随市场状态调整的 EVT-VaR 与 EVT-ES。这样做的好处是 99.9% 这类极端分位不再依赖单一的历史窗口，同时保留了波动的时变特征。

风险警示　多重检验导致的假发现

若研究者不记录试验次数，FDR 与 DSR 类校正都无从实施。更隐蔽的问题是“隐式多重检验”：试用多个数据供应商、多个预处理方式、多个回测区间，每次只报告最好的一次。控制这类偏差的唯一办法是在项目开始时就登记全部试验配置，并在报告中披露总试验次数。

1.4 Bootstrap 与重抽样

Bootstrap 用重抽样模拟统计量的抽样分布，无需假定分布的解析形式。独立同分布情形下有两种基本做法：非参数 bootstrap 从原始样本中有放回抽取 n 个观测；参数 bootstrap 从拟合分布 $\hat{F}$ 中抽样。对统计量 $\hat{\theta}$，其标准误由 B 次重抽样估计

$$\widehat{\mathrm{SE}}_{\mathrm{boot}}(\hat{\theta}) = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}\left(\hat{\theta}^{(b)} - \bar{\theta}^{*}\right)^{2}}, \qquad \bar{\theta}^{*} = \frac{1}{B}\sum_{b=1}^{B}\hat{\theta}^{(b)} \tag{1.12}$$

其中 $\hat{\theta}^{(b)}$ 为第 b 次重抽样得到的估计值，B 常取 1000 至 10000。百分位置信区间直接取 $\{\hat{\theta}^{(b)}\}$ 的 $\alpha/2$ 与 $1-\alpha/2$ 分位数。

金融时间序列不满足独立性，直接对单点重抽样会破坏自相关结构，因此需要块方法：移动块 bootstrap 把序列切成等长块 L 后对有放回的块序列拼接；平稳 bootstrap 的块长服从几何分布（期望 $1/q$），在保持平稳性的同时避免块边界的生硬拼接。块长 L 的选取遵循 $L \propto n^{1/3}$ 的经验法则，更严谨的做法是用 Politis–White 自动选择程序。对波动率、自相关与 Sharpe 比率这类依赖序列结构的统计量，块 bootstrap 与独立 bootstrap 的置信区间宽度可以相差一倍以上。

补充说明　bootstrap 的三个适用边界

第一，样本量太小时 bootstrap 会复制原始样本的偶然特征，$n < 30$ 时结论不可靠；第二，统计量不连续或依赖极端分位数（如最大值、极值指数）时，普通 bootstrap 会系统性低估不确定性，需要用 m 折 bootstrap 或子抽样；第三，序列存在结构突变（regime shift）时，重抽样会把两个不同机制的数据混合，得到无意义的区间。

1.5 回归分析

1.5.1 OLS 的代数与几何

对模型 $y = X\beta + \varepsilon$，$\mathbb{E}[\varepsilon \mid X] = 0$，最小化残差平方和 $\|y - X\beta\|^2$ 得一阶条件 $X^\top (y - X\hat{\beta}) = 0$，即正规方程

$$X^\top X\hat{\beta} = X^\top y, \qquad \hat{\beta} = (X^\top X)^{-1} X^\top y, \qquad \hat{y} = Py, \quad P = X(X^\top X)^{-1}X^\top \tag{1.13}$$

其中 P 为投影矩阵，它把 y 正交投影到 X 的列空间上，残差 $e = (I - P)y$ 与 X 的每一列正交。几何上 OLS 就是找列空间中离 y 最近的点，而 $R^2 = 1 - \|e\|^2 / \|y - \bar{y}\mathbf{1}\|^2$ 度量这个投影解释了多少变异。若 X 列满秩且 $\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I$，则 $\mathrm{Var}(\hat{\beta} \mid X) = \sigma^2 (X^\top X)^{-1}$，$\hat{\sigma}^2 = \|e\|^2 / (n - k)$。

定理 1.1 (Gauss–Markov) 在 $\mathbb{E}[\varepsilon \mid X] = 0$ 与 $\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I$ 下，OLS 估计量 $\hat{\beta}$ 是 β 的最佳线性无偏估计（BLUE）：任何其他线性无偏估计量 $\tilde{\beta} = Cy$ 都满足 $\mathrm{Var}(\tilde{\beta} \mid X) - \mathrm{Var}(\hat{\beta} \mid X) \succeq 0$。

证明思路. 无偏性要求 $CX = I$。把 C 写成 $C = (X^\top X)^{-1} X^\top + D$，由 $CX = I$ 得 $DX = 0$。于是 $\mathrm{Var}(\tilde{\beta} \mid X) = \sigma^2 CC^\top = \sigma^2 \left[(X^\top X)^{-1} + DD^\top\right] = \mathrm{Var}(\hat{\beta} \mid X) + \sigma^2 DD^\top$，其中交叉项因 $DX = 0$ 而消失，而 $DD^\top$ 半正定，故结论成立。 ∎

注意证明完全依赖 $\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I$：一旦存在异方差或自相关，右端多出的 $DD^\top$ 可以被选得为负，OLS 就不再是最优的，这正是 表 1.4 中稳健标准误与 GLS 存在的理由。

1.5.2 稳健标准误与 HAC

金融回归几乎必然违反同方差与无自相关假设。White 异方差一致性估计量为

$$\widehat{\mathrm{Var}}_{\mathrm{White}}(\hat{\beta}) = (X^\top X)^{-1} \left(\sum_{i=1}^{n} e_i^2 \, x_i x_i^\top \right) (X^\top X)^{-1} \tag{1.14}$$

其中 x_i 为第 i 个观测的解释变量行向量，e_i 为残差。存在自相关时改用 Newey–West 的 HAC 形式

$$\hat{S}_{\mathrm{HAC}} = \hat{\Gamma}_0 + \sum_{l=1}^{L} \left(1 - \frac{l}{L+1}\right) \left(\hat{\Gamma}_l + \hat{\Gamma}_l^\top\right), \qquad \hat{\Gamma}_l = \frac{1}{n} \sum_{t=l+1}^{n} e_t x_t \, e_{t-l} x_{t-l}^\top \tag{1.15}$$

其中 L 为带宽，常按 $L \approx 4(n/100)^{2/9}$ 的经验公式选取，$\hat{S}_{\mathrm{HAC}}$ 再代入三明治公式 $(X^\top X)^{-1} \hat{S}_{\mathrm{HAC}} (X^\top X)^{-1}$。系数标准误在 HAC 修正下通常会变大，因为正自相关意味着有效样本量小于名义样本量。

表 1.4 回归标准误的选择指南

设定	估计量	使用条件与代价
经典	$\hat{\sigma}^2 (X^\top X)^{-1}$	同方差且无自相关；金融数据中很少成立
White	三明治形式	异方差但无自相关；样本小时偏乐观
Newey–West	HAC 三明治	兼有异方差与自相关；带宽选择影响结果
聚类	按个体或时间聚类	组内任意相关；组数太少时失效

例 1.2 聚类标准误对显著性的影响

某面板回归估计市值因子对下期收益的系数为 0.0042，按个体聚类的标准误为 0.0009（$t = 4.7$），按时间聚类（月度，共 120 个时间点）的标准误为 0.0021（$t = 2.0$）。两者相差一倍以上，原因是残差在时间维度上高度相关：同一月的所有股票共享市场冲击，个体聚类无法捕捉这一共同成分。若因子只在少数几个月贡献收益，正确的标准误应接近后者，结论也会从“强显著”退化为“边际显著”。报告回归结果时，必须说明标准误的聚类维度，并优先报告更保守的版本。

1.5.3 面板数据与固定效应

面板数据同时具有个体维度 i 与时间维度 t。若遗漏的个体特征 α_i 与解释变量相关，混合 OLS 会产生遗漏变量偏误。固定效应模型通过组内变换消除 α_i

$$y_{it} - \bar{y}_i = \beta^\top (x_{it} - \bar{x}_i) + (\varepsilon_{it} - \bar{\varepsilon}_i), \qquad \bar{y}_i = \frac{1}{T} \sum_{t=1}^{T} y_{it} \tag{1.16}$$

其中 $\bar{y}_i$、$\bar{x}_i$ 为个体时间均值。这一变换等价于为每个个体加一个哑变量，代价是损失 n 个自由度并抹掉所有不随时间变化的变量（如行业归属）的系数。随机效应模型则假定 α_i 与 x_{it} 不相关，用 GLS 提高效率；Hausman 检验通过比较两套系数的差异来判断该假定是否成立，拒绝则使用固定效应。金融应用的常见折中是双向固定效应：同时加入个体效应与时间效应，时间效应自动吸收市场层面的共同冲击。

1.5.4 Fama–MacBeth 回归

资产定价实证的标准做法是 Fama–MacBeth 两步法，它把横截面溢价与横截面相关性同时纳入推断。

1. 对每只资产 i 做时间序列回归 $r_{it} = \alpha_i + \beta_i^{\top} f_t + \varepsilon_{it}$，得到载荷估计 $\hat{\beta}_i$；
2. 对每期 t 做横截面回归 $r_{it} = \lambda_{0t} + \lambda_t^{\top} \hat{\beta}_i + \eta_{it}$，得到因子溢价的逐期估计 $\hat{\lambda}_t$；
3. 对 $\{\hat{\lambda}_t\}$ 取时间平均 $\bar{\lambda} = \frac{1}{T}\sum_t \hat{\lambda}_t$，标准误为 $\mathrm{sd}(\hat{\lambda}_t)/\sqrt{T}$（可再用 Newey–West 修正自相关）。

该方法的关键优点是它自动处理横截面残差的相关性：因为每期只做一次横截面回归，残差在时间上取平均后，横截面相关被“折叠”进 $\hat{\lambda}_t$ 的方差中，不需要估计巨大的横截面协方差矩阵。其代价是忽略了载荷的估计误差（errors-in-variables），在资产数较少或 β 估计不精确时会低估真实标准误。

例 1.3 Fama–MacBeth 数值示例

对 500 只股票、240 个月的样本，按上述步骤得到某因子的逐期溢价序列，月均溢价 $\bar{\lambda} = 0.42\%$，逐期溢价的标准差 $\mathrm{sd}(\hat{\lambda}_t) = 2.6\%$。则标准误为 $2.6\%/\sqrt{240} = 0.168\%$，$t$ 值为 $0.42/0.168 = 2.5$，在 5% 水平上显著。若逐期溢价存在一阶自相关 $\rho = 0.25$，有效样本量降为 $240 \times \frac{1-0.25}{1+0.25} \approx 144$，修正后的标准误为 $2.6\%/\sqrt{144} = 0.217\%$，$t$ 值降至 1.9，显著性恰好消失。这个例子再次说明：时间序列相关是金融实证中最重要的标准误来源之一。

1.6 贝叶斯方法

1.6.1 共轭先验与后验推导

贝叶斯推断把参数视为随机变量，通过贝叶斯定理更新信念

$$\pi(\theta \mid D) = \frac{\mathcal{L}(D \mid \theta)\,\pi(\theta)}{\int \mathcal{L}(D \mid \theta')\,\pi(\theta')\,\mathrm{d}\theta'} \propto \mathcal{L}(D \mid \theta)\,\pi(\theta) \tag{1.17}$$

其中 $\pi(\theta)$ 为先验，$\mathcal{L}(D \mid \theta)$ 为似然，$\pi(\theta \mid D)$ 为后验，分母为边缘似然（证据），与 θ 无关，因此在推断中可以只保留比例关系。

最常用的共轭结构是正态—正态。设 $x_1, \dots, x_n \mid \mu \sim \mathcal{N}(\mu, \sigma^2)$，$\sigma^2$ 已知，先验 $\mu \sim \mathcal{N}(\mu_0, \tau_0^2)$，则后验仍为正态

$$\mu \mid D \sim \mathcal{N}\big(\mu_n,\ \tau_n^2\big)\,, \qquad \mu_n = \frac{\frac{1}{\tau_0^2}\mu_0 + \frac{n}{\sigma^2}\bar{x}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \qquad \frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2} \tag{1.18}$$

其中 $\bar{x}$ 为样本均值。后验均值是先验均值与样本均值的*精度加权平均*，精度（方差的倒数）直接相加。这一形式正是贝叶斯收缩的来源：当 n 小时后验靠近先验，当 n 大时后验靠近样本均值，收缩强度由信噪比 $n\tau_0^2/\sigma^2$ 自动决定。

例 1.4　基金收益均值的贝叶斯收缩

某基金过去 36 个月的月均超额收益为 $\bar{x} = 0.55\%$，月度收益标准差为 $\sigma = 4\%$，故样本均值的标准误为 $4\%/\sqrt{36} = 0.67\%$。若行业先验设定为“真正具备选股能力的基金月均超额收益为 $\mu_0 = 0.10\%$、跨基金标准差 $\tau_0 = 0.30\%$”，代入 式 (1.18)：样本精度 $n/\sigma^2 = 36/16 = 2.25$，先验精度 $1/\tau_0^2 = 11.1$，后验均值 $\mu_n = (11.1 \times 0.10 + 2.25 \times 0.55)/(11.1 + 2.25) = (1.11 + 1.24)/13.35 = 0.176\%$。后验均值只有样本均值的 32%。这一收缩与“三年业绩不足以证明能力”的直觉一致，也与 式 (1.18) 的精度加权逻辑一致。

1.6.2　可信区间与置信区间

频率派的 95% 置信区间含义是：重复抽样中有 95% 的区间包含真值，真值本身是固定的。贝叶斯 95% 可信区间的含义是：给定数据与先验，θ 落在该区间的后验概率为 95%。在平坦先验下两者数值常接近，但在小样本、有信息先验或存在边界约束时差异显著。风险管理中需要回答“亏损超过阈值的主观概率是多少”，这类问题只有可信区间能直接作答，因此贝叶斯方法在压力测试与情景分析中更自然。

1.6.3　Black–Litterman 模型

Black–Litterman 模型把市场均衡隐含收益与投资者主观观点融合，是贝叶斯收缩在组合构建中最成功的应用。其推导分三步。

第一步：由市场均衡反推隐含收益。若市场组合就是均值—方差最优组合，则其权重 w_{mkt} 必满足一阶条件，于是

$$\Pi = \delta\, \boldsymbol{\Sigma}\, w_{\text{mkt}} \tag{1.19}$$

其中 Π 为隐含均衡收益向量，$\boldsymbol{\Sigma}$ 为收益协方差矩阵，w_{mkt} 为市值权重，δ 为风险厌恶系数（常用市场 Sharpe 比率反解）。这一先验的好处是它与市场组合自洽，因此不会在无观点时给出极端权重。

第二步：把观点写成线性约束。观点表示为

$$P\,\mu = Q + \epsilon, \qquad \epsilon \sim \mathcal{N}(0, \Omega) \tag{1.20}$$

其中 P 为 $k \times n$ 的观点选择矩阵，Q 为观点收益向量，Ω 为观点不确定性的对角矩阵。例如“科技板块将跑赢大盘 2%”对应 P 的一行在科技板块权重为 1、其余为 0，$Q = 0.02$；“资

产 A 比资产 B 多涨 1%”对应一行为 1 与 -1。

第三步：正态—正态共轭给出后验。把 μ 的先验取为 $\mathcal{N}(\Pi, \tau\Sigma)$，观点似然为 $\mathcal{N}(P\mu, \Omega)$，直接套用 式 (1.18) 的矩阵形式即得

$$\mathbb{E}[\mu \mid \text{views}] = \Pi + \tau\Sigma P^{\top}\left(P\,\tau\Sigma\,P^{\top} + \Omega\right)^{-1}(Q - P\Pi) \tag{1.21}$$

$$\mathrm{Cov}(\mu \mid \text{views}) = \Sigma + \tau\Sigma - \tau\Sigma P^{\top}\left(P\,\tau\Sigma\,P^{\top} + \Omega\right)^{-1} P\,\tau\Sigma \tag{1.22}$$

其中 τ 为刻画先验不确定性的标量（常取 0.02 至 0.10）。式 (1.21) 的结构非常直观：后验均值等于先验加上“观点与先验的偏离”乘以一个增益矩阵；当观点不确定性 $\Omega \to 0$（极度自信）时，后验均值趋向满足 $P\mu = Q$ 的最小调整解；当 $\Omega \to \infty$（完全不信）时后验回到 Π。

直觉理解　Black–Litterman 为什么比直接给预期收益稳健

直接给主观预期收益，等价于在均值—方差优化器中输入一组未被协方差结构约束的数字，优化器会把这些数字放大成极端权重。BL 的做法是先给市场均衡一个基准，再把观点作为对基准的偏离输入，偏离的幅度由 Ω 与 τ 共同封顶。因此 BL 组合的权重对观点强度不敏感，这正是它在实务中被广泛采用的原因。

1.6.4 马尔可夫链蒙特卡洛

当后验没有解析形式时，MCMC 通过构造以后验为平稳分布的马尔可夫链来抽样。Metropolis–Hastings 算法给定当前状态 θ 与提议分布 $q(\theta' \mid \theta)$，以概率

$$a(\theta, \theta') = \min\left\{1,\ \frac{\pi(\theta' \mid D)\, q(\theta \mid \theta')}{\pi(\theta \mid D)\, q(\theta' \mid \theta)}\right\} \tag{1.23}$$

接受提议 θ'，否则保持在 θ。其中 $\pi(\theta \mid D)$ 为目标后验，比例形式使归一化常数自动消去，这是 MH 能够在高维下工作的关键。Gibbs 抽样是 MH 的特例：轮流从各分量的完全条件分布 $\pi(\theta_j \mid \theta_{-j}, D)$ 中抽样，接受概率恒为 1，在条件分布可解析抽样时效率极高。

Hamiltonian Monte Carlo（HMC）引入辅助动量变量，利用后验对数的梯度沿哈密顿动力学模拟轨迹，再由 MH 步骤校正数值误差。相比随机游走型 MH，HMC 在高维参数空间中能以更少的步数获得低自相关的样本。NUTS（No-U-Turn Sampler）自动选择轨迹长度，是 Stan 与 PyMC 的默认采样器。判断 MCMC 是否收敛的标准做法是运行多条链并计算 $\hat{R}$ 统计量（要求 $\hat{R} < 1.01$）与有效样本量（ESS）。

1.7 惩罚回归

高维特征下普通最小二乘会过拟合。惩罚回归在损失函数中加入系数惩罚项

$$\hat{\beta}^{\text{Ridge}} = \arg\min_{\beta} \ \|y - X\beta\|^2 + \lambda \|\beta\|_2^2 \tag{1.24}$$

$$\hat{\beta}^{\text{Lasso}} = \arg\min_{\beta} \ \|y - X\beta\|^2 + \lambda \|\beta\|_1 \tag{1.25}$$

$$\hat{\beta}^{\text{ENet}} = \arg\min_{\beta} \ \|y - X\beta\|^2 + \lambda \left(\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right) \tag{1.26}$$

其中 $\lambda \geq 0$ 控制惩罚强度，$\alpha \in [0,1]$ 在 Lasso 与 Ridge 之间插值。Ridge 的解为 $\hat{\beta}^{\text{Ridge}} = (X^\top X + \lambda I)^{-1} X^\top y$，它把系数向零收缩但不置零，因此不做变量选择；Lasso 的 L_1 惩罚在零点不可微，使得解在 λ 足够大时恰好稀疏。几何解释是：L_1 球的顶点落在坐标轴上，等高线与球的切点大概率在顶点，而 L_2 球是光滑的，切点不会精确落在坐标轴上。

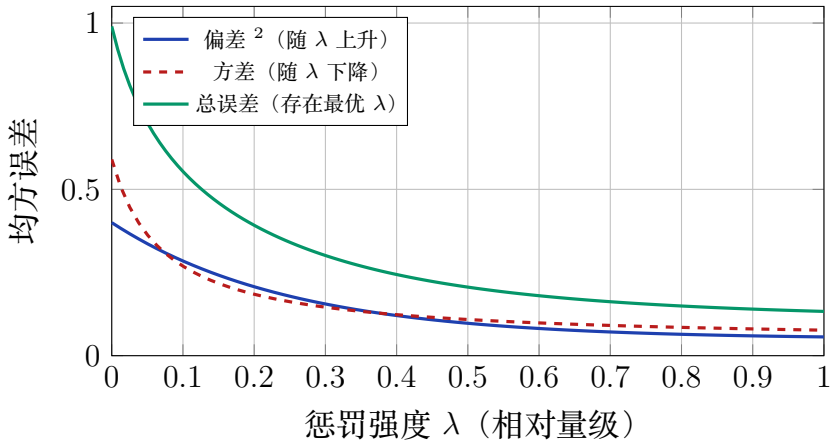


图 1.2　惩罚回归的偏差—方差权衡：总误差在中间某个 λ^* 处最小，两端分别对应过拟合与欠拟合

图 1.2 展示权衡的全貌。$\lambda \to 0$ 时方差大、偏差小；$\lambda \to \infty$ 时系数全被压向零，偏差主导。实践中的 λ 通过时间序列交叉验证选取，并且必须使用与机器学习选股相同的 Purged k-折结构，否则验证集误差会被信息泄漏压低，选出的 λ 偏小、模型偏复杂。

⚠ 风险警示　惩罚回归在因子研究中的两个陷阱

第一，惩罚项不区分因果与相关：若把未来收益相关的特征（如未来披露的财务数据）放入 X，Lasso 会稳定地把它选出来，稀疏性反而强化了前视偏差。第二，λ 与 α 的调参本身构成多重检验，在 表 1.3 的意义下会把样本内的最优惩罚参数“挑选”得更乐观，因此最终绩效必须在独立的样本外区间上重新评估。

1.8 极值理论与尾部风险

1.8.1　GEV 与 GPD

极值理论（EVT）专门研究样本极端值的分布极限。Fisher–Tippett 定理指出，若适当标准化后的块最大值收敛，则极限必为广义极值分布

$$G(z)=\exp\left\{-\left(1+\xi\frac{z-\mu}{\sigma}\right)^{-1/\xi}\right\},\qquad 1+\xi\frac{z-\mu}{\sigma}>0 \tag{1.27}$$

其中 μ 为位置参数，$\sigma>0$ 为尺度参数，ξ 为形状参数。$\xi>0$ 对应 Fréchet 型（幂律尾，金融收益的典型情形），$\xi=0$ 对应 Gumbel 型（指数尾），$\xi<0$ 对应 Weibull 型（有界尾）。

比块最大值更节省数据的是超阈值法（POT）。Pickands–Balkema–de Haan 定理指出，对足够大的阈值 u，超额损失 $Y=X-u$ 的条件分布近似为广义 Pareto 分布

$$\bar{F}_u(y)=\mathbb{P}(X-u>y\mid X>u)=\left(1+\frac{\xi y}{\beta}\right)^{-1/\xi},\qquad y>0,\ \beta>0 \tag{1.28}$$

其中 β 为尺度参数，ξ 与 式 (1.27) 中的形状参数含义一致。由 式 (1.28) 可反解任意高水平的 VaR 与 ES。设 n 为样本总量，N_u 为超过阈值的观测数，则

$$\widehat{\mathrm{VaR}}_q=u+\frac{\hat\beta}{\hat\xi}\left[\left(\frac{n}{N_u}(1-q)\right)^{-\hat\xi}-1\right] \tag{1.29}$$

$$\widehat{\mathrm{ES}}_q=\frac{\widehat{\mathrm{VaR}}_q}{1-\hat\xi}+\frac{\hat\beta-\hat\xi u}{1-\hat\xi},\qquad \hat\xi<1 \tag{1.30}$$

其中 q 为置信水平（如 0.999）。式 (1.30) 要求 $\hat\xi<1$，否则 ES 发散——这提醒我们，若估计出的形状参数接近或超过 1，数据的尾部厚到使一阶矩不存在，任何基于均值的风险度量都失去意义。

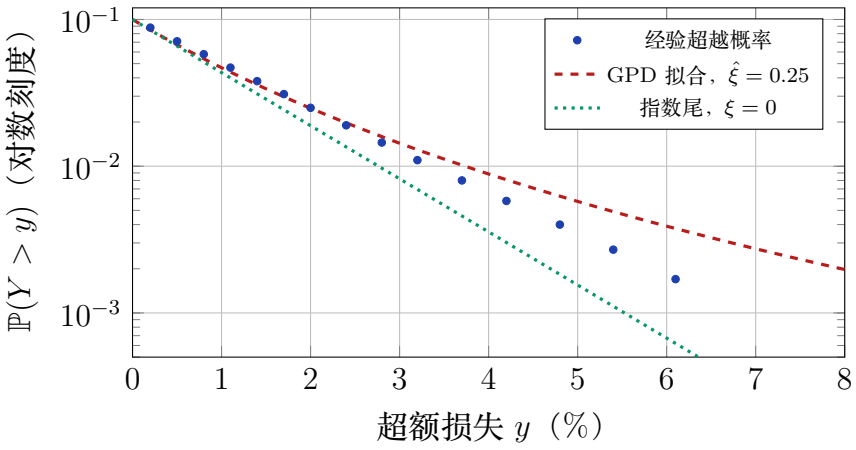


图 1.3 POT 方法的 GPD 尾拟合：对数刻度下幂律尾（直线）与指数尾（弯曲）的差异在 $y>3\%$ 后清晰可见

图 1.3 的关键读法是对数刻度下的形状：GPD 的超越概率 $\bar{F}_u(y)\propto y^{-1/\xi}$，取对数后是斜率为 $-1/\xi$ 的直线。若经验点在这张图上明显向上偏离指数尾的曲线，就说明尾部是幂律而非指数，用正态或指数模型度量极高分位的风险会系统性低估。

1.8.2 Hill 估计与阈值选择

在 $\xi > 0$ 的假设下，Hill 估计量给出形状参数的非参数估计

$$\hat{\xi}^{\text{Hill}} = \frac{1}{k}\sum_{j=1}^{k} \ln X_{(n-j+1)} - \ln X_{(n-k)}, \qquad k = N_u \tag{1.31}$$

其中 $X_{(1)} \le \cdots \le X_{(n)}$ 为顺序统计量，k 为使用的最大观测个数。Hill 估计量对 k 敏感：k 太小时方差大，k 太大时混入非尾部分布造成偏差，实践中通过 Hill 图寻找 $\hat{\xi}$ 对 k 相对平稳的平台区间。阈值 u 的选择是 POT 方法的核心难点，常用诊断手段包括平均超额函数图（均值余函数在阈值以上应呈线性）与参数稳定性图（$\hat{\xi}$ 与 $\hat{\beta}$ 随 u 变化平稳）。

例 1.5 POT 拟合与 EVT-VaR/ES 计算

某股票指数 2500 个交易日（约十年）的日对数收益，取 5% 分位对应的损失为阈值 $u = 2.0\%$，超过阈值的观测 $N_u = 125$。用 GPD 拟合超额损失得 $\hat{\xi} = 0.25$、$\hat{\beta} = 1.2\%$。计算 $q = 99.9\%$ 水平的 VaR：$(n/N_u)(1-q) = (2500/125)\times 0.001 = 0.02$，$0.02^{-0.25} = \mathrm{e}^{0.25\times 3.912} = \mathrm{e}^{0.978} = 2.66$，故 $\widehat{\mathrm{VaR}}_{0.999} = 2.0\% + \frac{1.2\%}{0.25}(2.66-1) = 2.0\% + 4.8\% \times 1.66 = 9.97\%$。再算 ES：$\widehat{\mathrm{ES}}_{0.999} = \frac{9.97\%}{0.75} + \frac{1.2\% - 0.25\times 2.0\%}{0.75} = 13.29\% + \frac{0.70\%}{0.75} = 13.29\% + 0.93\% = 14.22\%$。作为对照，若假定正态且日波动率 1.2%，99.9% 的 VaR 约为 $1.2\% \times 3.09 = 3.7\%$，ES 约为 $1.2\% \times 4.06 = 4.9\%$。EVT 给出的 ES 是正态假设的近三倍。在组合规模 100 亿元的情形下，两者对应的尾部损失相差约 9.3 亿元——这解释了为什么监管资本计量与内部压力测试都要求使用厚尾模型。

1.9 数据清洗与平稳性

1.9.1 去极值与缺失值

金融面板的极端值既可能是错误数据，也可能是真实的风险事件，处理时必须区分。中位数绝对偏差为

$$\mathrm{MAD} = \mathrm{median}\left(|x_i - \mathrm{median}(x)|\right), \qquad \hat{\sigma}_{\text{robust}} = 1.4826\,\mathrm{MAD} \tag{1.32}$$

其中常数 1.4826 使 $\hat{\sigma}_{\text{robust}}$ 在正态数据下与样本标准差一致。与标准差相比，MAD 的崩溃点是 50%，即接近一半的观测被污染后仍然稳健，而标准差的崩溃点是 0%。缩尾（Winsorize）把超出 $[\mathrm{median} - k\hat{\sigma}_{\text{robust}},\ \mathrm{median} + k\hat{\sigma}_{\text{robust}}]$ 的值替换为边界值，通常取 $k = 3$，从而在保留样本量的同时限制单个观测的影响力。

缺失值的处理方式取决于缺失机制。完全随机缺失可用均值或中位数填补；与可观测变量相关的缺失适合用回归或 k 近邻填补；与缺失值本身相关的非随机缺失（如业绩差的基金停止披露）则任何填补都会引入偏差，只能通过敏感性分析量化。多重插补通过对填补模型加入随机扰动生成 M 个完整数据集（M 常取 5 至 20），分别估计后再用 Rubin 规则合并，从而把填补的不确定性计入标准误。链式方程多重插补（MICE）允许每个变量使用不同的条件模型，是目前处理混合类型金融面板的默认方法。

1.9.2 平稳性与单位根

平稳性是用时间序列做统计推断的前提。弱平稳要求均值与方差不随时间变化、自协方差只依赖于时间间隔。ADF 检验回归

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^{p} \delta_i \Delta y_{t-i} + \varepsilon_t \tag{1.33}$$

原假设为 $H_0 : \gamma = 0$（存在单位根），备择假设为 $\gamma < 0$（平稳）。注意该检验的分布是非标准的 Dickey–Fuller 分布，不能直接用正态临界值；滞后阶数 p 通常按 AIC 或 BIC 选取。KPSS 检验的逻辑正好相反：原假设为平稳（趋势平稳），因此“ADF 不拒绝 + KPSS 拒绝”支持单位根，“ADF 拒绝 + KPSS 不拒绝”支持平稳，两者都拒绝通常意味着存在结构突变。Phillips–Perron 检验则通过非参数修正处理残差自相关，无需设定滞后阶数。

补充说明 价格、收益与波动率序列的平稳性差异

价格序列通常含单位根（$I(1)$），收益序列通常平稳（$I(0)$），而波动率序列虽然平稳但自相关极强，接近长记忆过程。这一层次差异决定了建模顺序：先对价格差分得到收益，再对收益建模均值方程，最后对残差平方建模波动率方程。若跳过差分直接对价格回归，即使两个独立的价格序列也会给出高 R^2 与显著 t 值，这就是伪回归（spurious regression）。

1.10 因果推断简介

相关性不足以支撑“某因素导致了某收益”的结论。金融中常用两类准实验方法。双重差分（DID）比较处理组与对照组在政策前后的变化差

$$y_{it} = \alpha + \beta_1 \mathrm{Treat}_i + \beta_2 \mathrm{Post}_t + \delta \left(\mathrm{Treat}_i \times \mathrm{Post}_t\right) + \varepsilon_{it} \tag{1.34}$$

其中 δ 为政策效应。DID 成立的关键假设是平行趋势：若无政策，处理组与对照组的时间趋势应当一致，这一假设需要用政策前的数据检验。合成控制法在只有一个处理单位（如某国、某交易所）时更适用：用其他单位的加权组合构造一个“合成对照组”，使它在政策前尽可能贴合处理单位的路径，然后把政策后的差异归因于处理。两类方法的共同弱点是都无法排除与处理同时发生的其他冲击，因此在解读金融领域的自然实验时必须同时报告替代解释。

1.11 代码实现：t 分布 MLE 与 POT/GPD

Listing 1.1 用极大似然估计学生 t 分布自由度并与矩估计对比

```
import numpy as np
import pandas as pd
from scipy import stats, optimize
```

```

rng = np.random.default_rng(3)
returns = stats.t.rvs(df=5.0, size=3000, random_state=7) * 0.012
returns = returns - returns.mean()

def neg_loglik(params, x):
    nu, loc, scale = params
    if nu <= 2.05 or scale <= 0:
        return 1e10
    return -np.sum(stats.t.logpdf(x, df=nu, loc=loc, scale=scale))

fit = optimize.minimize(neg_loglik, x0=np.array([6.0, 0.0, 0.01]),
                        args=(returns,), method="Nelder-Mead",
                        options={"xatol": 1e-6, "fatol": 1e-8, "maxiter":
                            4000})
nu_hat, loc_hat, scale_hat = fit.x
print("MLE df = %.2f  loc = %.5f  scale = %.5f" % (nu_hat, loc_hat,
    scale_hat))

excess_kurt = stats.kurtosis(returns, fisher=True, bias=False)
nu_moment = 4.0 + 6.0 / excess_kurt if excess_kurt > 0 else np.inf
print("sample excess kurtosis = %.2f -> moment df = %.2f" % (excess_kurt,
     nu_moment))
normal_ll = np.sum(stats.norm.logpdf(returns, loc=returns.mean(), scale=
    returns.std()))
print("loglik gain over normal = %.1f" % (-fit.fun - normal_ll))
```

Listing 1.2 POT 方法拟合 GPD 并计算极端分位的 VaR 与 ES

```
import numpy as np
from scipy import stats

rng = np.random.default_rng(21)
n = 2500
losses = np.abs(stats.t.rvs(df=4.0, size=n, random_state=5)) * 0.012
u = np.quantile(losses, 0.95)
excess = losses[losses > u] - u
n_u = excess.size
print("threshold = %.4f  exceedances = %d" % (u, n_u))

xi, loc, beta = stats.genpareto.fit(excess, floc=0.0)
print("GPD xi = %.3f  beta = %.4f" % (xi, beta))

def evt_var_es(losses, u, xi, beta, q=0.999):
    n, n_u = losses.size, int(np.sum(losses > u))
    factor = (n / n_u * (1.0 - q)) ** (-xi)
    var_q = u + beta / xi * (factor - 1.0)
    es_q = var_q / (1.0 - xi) + (beta - xi * u) / (1.0 - xi)
    return var_q, es_q

var_999, es_999 = evt_var_es(losses, u, xi, beta, 0.999)
```

```
sigma = losses.std()
print("EVT  VaR99.9 = %.4f  ES99.9 = %.4f" % (var_999, es_999))
print("Normal VaR99.9 = %.4f  ES99.9 = %.4f"
      % (sigma * 3.0902, sigma * stats.norm.pdf(3.0902) / 0.001))
print("empirical worst 5 losses:", np.sort(losses)[-5:])
```

listings 1.1 and 1.2 给出两段可直接运行的实现。第一段把 MLE 与 小节 1.2.1 的矩估计并排比较，并报告相对正态分布的对数似然增益——这是判断是否需要厚尾模型的直接依据。第二段实现 式 (1.29) 与 式 (1.30)，并与正态假设下的结果以及经验最差损失对照。若 EVT 的 $\widehat{\mathrm{ES}}$ 明显小于经验最差损失，说明阈值取得太高、超越观测太少，应下调阈值重新拟合。

核心要点 1.1 统计推断在金融数据上的三条纪律

第一，先看尾部再谈均值：报告的每一个均值与 Sharpe 比率都应附上基于厚尾或 EVT 的区间；第二，标准误必须稳健：面板数据用双向聚类，时间序列用 HAC，极值用 bootstrap；第三，区分统计显著与经济显著：一个 t 值为 2.5 的因子，若扣掉交易成本后收益归零，它在经济上不显著。

本章小结

- 金融收益的尾部远厚于正态：$\nu = 5$ 的 t 分布在 $|x| = 6$ 处的概率密度比正态高约三个数量级，直接决定极高分位风险度量的准确性。
- MLE 在正则条件下渐近正态且达到 Cramér–Rao 下界；GMM 在矩条件框架下以 $W_n = S^{-1}$ 达到渐近有效，J 检验用于诊断过度识别。
- LRT、Wald 与 Score 检验渐近等价但有限样本表现不同；多重检验必须用 Bonferroni 或 Benjamini–Hochberg FDR 校正，前提是如实记录试验次数。
- bootstrap 需按数据结构选择：独立数据用普通 bootstrap，时间序列用移动块或平稳 bootstrap，权重的选择直接决定区间宽度。
- 回归推断的关键在于标准误：White 处理异方差，Newey–West 处理自相关，聚类处理组内相关；Fama–MacBeth 用逐期横截面回归绕开协方差矩阵估计。
- 贝叶斯方法的核心是共轭更新 式 (1.18) 的精度加权，Black–Litterman 是它在组合构建中的成功应用，MCMC 解决后验无解析形式的情形。
- 极值理论用 GPD 拟合超阈值超额损失，给出远超正态假设的 VaR 与 ES，是监管资本与压力测试的必备工具。

练习与思考

1. 设某资产日收益服从 t 分布，自由度 $\nu = 4$。请说明为何其四阶矩不存在，并解释这对样本峰度估计意味着什么。若把 ν 改为 6，结论如何变化？
2. 用 式 (1.18) 计算：先验 $\mu \sim \mathcal{N}(0.05, 0.10^2)$（年化收益），样本 $n = 200$ 天的日均收

益 0.06%、日标准差 1.5%。求后验均值与后验标准差，并解释收缩幅度为何与你预期的一致。

3. 在小节 1.8.2 中，若阈值下调为 $u = 1.5\%$、$N_u = 250$，重新拟合得 $\hat{\xi} = 0.22$、$\hat{\beta} = 1.1\%$。重算 $q = 99.9\%$ 的 VaR 与 ES，并讨论阈值变化对结果的影响方向。

4. 对 Black–Litterman 模型，设两只资产的协方差矩阵为 $\mathbf{\Sigma} = \begin{pmatrix} 0.04 & 0.01 \\ 0.01 & 0.09 \end{pmatrix}$，市场权重各 50%，$\delta = 2.5$。求 Π；再设观点为“资产 1 比资产 2 多涨 3%”，$\Omega = 0.0001$、$\tau = 0.05$，用式 (1.21) 求后验均值。

5. 解释为什么 Ridge 回归不产生稀疏解而 Lasso 会产生，并用 L_1、L_2 球的几何图形说明。若特征高度相关，Elastic Net 相比 Lasso 有什么优势？

6. 写出检验“某因子月均溢价为零”的三种检验统计量形式，并说明在只有 60 个月样本、残差存在自相关时应优先选择哪一种，理由是什么。

延伸阅读

- Greene, W., *Econometric Analysis*, 8th ed., Pearson, 2018. （假设检验、面板数据与稳健标准误的标准教材，推导完整且例子丰富）
- McNeil, A., Frey, R., and Embrechts, P., *Quantitative Risk Management*, 2nd ed., Princeton University Press, 2015. （第 7 章系统讲解 EVT、POT 与 EVT-VaR/ES，是尾部风险建模的权威参考）
- Efron, B., and Tibshirani, R., *An Introduction to the Bootstrap*, Chapman and Hall, 1993. （bootstrap 的原始系统论述，块方法与置信区间的构造讲得最清楚）
- Gelman, A., Carlin, J., Stern, H., Dunson, D., Vehtari, A., and Rubin, D., *Bayesian Data Analysis*, 3rd ed., CRC Press, 2013. （贝叶斯推断与 MCMC 的标准参考，包含收敛诊断与模型检验）
- Black, F., and Litterman, R., “Global Portfolio Optimization”, *Financial Analysts Journal*, 1992. （Black–Litterman 模型的原始文献，推导简洁，直觉解释至今最清晰）
- Harvey, C., Liu, Y., and Zhu, H., “...and the Cross-Section of Expected Returns”, *Review of Financial Studies*, 2016. （用多重检验框架重估因子显著性，是理解 FDR 在因子研究中作用的必读文献）