

量化金融工程

Quantex

2026 年 7 月 29 日

目录

第一章 时间序列分析	1
1.1 经典时间序列模型	1
1.1.1 平稳性与自相关	1
1.1.2 AR(p) 模型	1
1.1.3 MA(q) 模型	1
1.1.4 ARMA(p,q) 模型	2
1.1.5 ARIMA(p,d,q) 模型	2
1.1.6 SARIMA	2
1.2 波动率建模 (GARCH 族)	2
1.2.1 ARCH 模型	2
1.2.2 GARCH(p,q) 模型	3
1.2.3 GARCH 扩展	3
1.3 深度学习时间序列模型	3
1.3.1 循环神经网络 (RNN)	3
1.3.2 长短期记忆网络 (LSTM)	4
1.3.3 门控循环单元 (GRU)	4
1.3.4 Transformer 时间序列模型	4
1.3.5 金融时间序列的 Transformer 应用	5
1.4 协整与误差修正模型	5
1.4.1 协整 (Cointegration)	5
1.4.2 误差修正模型 (ECM)	6

1.4.3	Johansen 检验	6
1.5	模型评估	6
1.5.1	预测评估指标	6
1.5.2	Diebold-Mariano 检验	6
1.5.3	回测 VaR (Backtesting)	7
1.6	小结	7

第一章 时间序列分析

1.1 经典时间序列模型

1.1.1 平稳性与自相关

弱平稳条件：

- 均值恒定： $\mathbb{E}[y_t] = \mu$
- 自协方差仅依赖于滞后： $\text{Cov}(y_t, y_{t-k}) = \gamma_k$

样本自相关函数（ACF）：

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2} \quad (1.1)$$

偏自相关函数（PACF）用于辨识 AR 模型的阶数。

1.1.2 AR(p) 模型

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t \quad (1.2)$$

平稳性条件：特征方程 $1 - \phi_1 z - \cdots - \phi_p z^p = 0$ 的根均在单位圆外。

1.1.3 MA(q) 模型

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} \quad (1.3)$$

MA 过程始终平稳，有限阶 MA 具有截尾的 ACF。

1.1.4 ARMA(p,q) 模型

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j} \quad (1.4)$$

使用滞后算子 L :

$$\phi(L)y_t = c + \theta(L)\varepsilon_t \quad (1.5)$$

其中 $\phi(L) = 1 - \phi_1 L - \cdots - \phi_p L^p$, $\theta(L) = 1 + \theta_1 L + \cdots + \theta_q L^q$ 。

1.1.5 ARIMA(p,d,q) 模型

$$\phi(L)(1-L)^d y_t = c + \theta(L)\varepsilon_t \quad (1.6)$$

$(1-L)^d$ 为 d 阶差分算子, 使非平稳序列变为平稳。

Box-Jenkins 方法: 识别 (ACF/PACF 判断 p,q) $\rightarrow$ 估计 $\rightarrow$ 诊断检验 (残差白噪声检验) $\rightarrow$ 预测。

1.1.6 SARIMA

季节性 ARIMA: $\text{SARIMA}(p, d, q)(P, D, Q)_s$

$$\phi(L)\Phi(L^s)(1-L)^d(1-L^s)^D y_t = \theta(L)\Theta(L^s)\varepsilon_t \quad (1.7)$$

1.2 波动率建模 (GARCH 族)

1.2.1 ARCH 模型

Engle (1982) 的自回归条件异方差模型:

$$r_t = \mu_t + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim \text{i.i.d.}(0, 1) \quad (1.8)$$

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 \quad (1.9)$$

1.2.2 GARCH(p,q) 模型

Bollerslev (1986) 的推广：

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (1.10)$$

GARCH(1,1) 是金融中最常用的波动率模型：

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \quad (1.11)$$

无条件方差： $\mathbb{E}[\sigma^2] = \omega / (1 - \alpha - \beta)$ ，要求 $\alpha + \beta < 1$ 。

1.2.3 GARCH 扩展

- **EGARCH**: 对 $\log \sigma_t^2$ 建模，捕捉杠杆效应（好消息与坏消息对波动率的非对称影响）
- **GJR-GARCH**: 在方差方程中引入负收益指示变量，直接捕捉非对称
- **FIGARCH**: 长记忆波动率模型（分数阶差分）
- **DCC-GARCH**: 动态条件相关——多变量波动率模型

核心要点 1

金融收益率的“程式化事实”（Stylized Facts）：肥尾（Leptokurtosis）、波动率聚集（Volatility Clustering）、杠杆效应（Leverage Effect）、长记忆性。GARCH 族模型正是为了捕捉这些特征而发展。

1.3 深度学习时间序列模型

1.3.1 循环神经网络 (RNN)

RNN 核心递归：

$$h_t = \tanh(W_h h_{t-1} + W_x x_t + b) \quad (1.12)$$

RNN 的梯度消失/爆炸问题阻碍了长序列学习。

1.3.2 长短期记忆网络 (LSTM)

LSTM 通过门控机制解决长期依赖问题:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{遗忘门}) \quad (1.13)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (\text{输入门}) \quad (1.14)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (\text{候选记忆}) \quad (1.15)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (\text{记忆单元更新}) \quad (1.16)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (\text{输出门}) \quad (1.17)$$

$$h_t = o_t \odot \tanh(C_t) \quad (\text{隐状态}) \quad (1.18)$$

金融应用:

- 波动率预测: LSTM-GARCH 混合模型, LSTM 捕捉非线性动态
- Alpha 信号生成: 多变量金融时间序列 $\rightarrow$ LSTM $\rightarrow$ 收益预测
- 高频交易: 订单簿数据 $\rightarrow$ LSTM $\rightarrow$ 短期价格方向

1.3.3 门控循环单元 (GRU)

GRU 是 LSTM 的简化变体 (合并记忆单元和隐状态):

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t]) \quad (\text{更新门}) \quad (1.19)$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t]) \quad (\text{重置门}) \quad (1.20)$$

$$\tilde{h}_t = \tanh(W \cdot [r_t \odot h_{t-1}, x_t]) \quad (1.21)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (1.22)$$

1.3.4 Transformer 时间序列模型

Transformer 的自注意力机制为金融时间序列带来了范式创新:

缩放点积注意力:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (1.23)$$

多头注意力:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (1.24)$$

其中 $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$ 。

位置编码:

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{\text{model}}}) \quad (1.25)$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{\text{model}}}) \quad (1.26)$$

金融 Transformer 变体:

- **Informer**: ProbSparse 自注意力, $O(L \log L)$ 复杂度, 适合长序列
- **Autoformer**: 自相关机制替代自注意力, 分解季节性和趋势成分
- **PatchTST**: 将时间序列分割为 Patch (类似 ViT), 独立通道建模
- **Temporal Fusion Transformer (TFT)**: 可解释的多水平时间序列预测, 支持静态协变量

1.3.5 金融时间序列的 Transformer 应用

1. 多资产收益预测: 跨资产注意力捕捉资产间的领先-滞后关系
2. 组合管理: Attention 权重解释资产间的时变相关性
3. 异常检测: Transformer 重构误差用于识别市场异常
4. 文本驱动预测: 融合新闻/社交媒体与价格数据 (跨模态 Transformer)

1.4 协整与误差修正模型

1.4.1 协整 (Cointegration)

若 y_t 和 x_t 均为 $I(1)$ (一阶单整), 但存在 β 使得:

$$u_t = y_t - \beta x_t \sim I(0) \quad (1.27)$$

则 y_t 和 x_t 协整, 具有长期均衡关系。这是配对交易策略的数学基础。

1.4.2 误差修正模型 (ECM)

$$\Delta y_t = \alpha_y(y_{t-1} - \beta x_{t-1}) + \sum \gamma_i \Delta y_{t-i} + \sum \delta_i \Delta x_{t-i} + \varepsilon_t \quad (1.28)$$

其中误差修正项 $\alpha_y(y_{t-1} - \beta x_{t-1})$ 将短期动态拉回长期均衡。

1.4.3 Johansen 检验

向量误差修正模型 (VECM):

$$\Delta Y_t = \Pi Y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta Y_{t-i} + \varepsilon_t \quad (1.29)$$

$\Pi = \alpha\beta^T$ 的秩决定了协整关系的数量。迹检验和最大特征值检验是最常用的 Johansen 检验。

1.5 模型评估

1.5.1 预测评估指标

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1.30)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (1.31)$$

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (1.32)$$

1.5.2 Diebold-Mariano 检验

用于比较两个预测模型的准确性差异是否显著:

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}} \quad (1.33)$$

其中 d_t 为两模型预测误差差异的时间序列。

1.5.3 回测 VaR (Backtesting)

Kupiec 检验（无条件覆盖）：

$$LR_{UC} = -2 \ln \left[\frac{(1-p)^{N-x} p^x}{(1-x/N)^{N-x} (x/N)^x} \right] \sim \chi_1^2 \quad (1.34)$$

Christoffersen 检验还检查异常值的独立性（条件覆盖），防止波动率聚集导致的违规聚类。

1.6 小结

时间序列分析是量化金融的脊椎——从经典的 ARIMA/GARCH 到现代的 LSTM/-Transformer，模型复杂度与日俱增，但核心目标不变：提取序列中的可预测信号。传统模型可解释性强、参数少、适合低频宏观数据；深度学习方法适合高维、非线性、多频率的数据环境。实践中应权衡模型复杂度与泛化能力。