第一章 时间序列分析

金融数据几乎全部以时间序列的形式出现：日收益率、分钟级成交价、逐笔订单流、宏观月度指标。时间序列分析的任务，是从这些带有序结构的观测中分离出三类成分——可预测的动态（趋势、周期、自回归结构）、可建模的波动率（条件异方差）、以及不可约的噪声。本章按「线性均值模型 → 条件波动率模型 → 高频与状态空间 → 协整与因果 → 深度学习 → 评估与回测」的顺序展开，并始终强调一个原则：模型复杂度必须由样本外表现与失效条件来约束，而不是由样本内拟合优度来驱动。

1.1 平稳性与模型识别

1.1.1 平稳性的两种定义

定义 1.1 严平稳与弱平稳

若对任意 k 与任意时刻集合 $t_1 < \cdots < t_k$，联合分布 $(y_{t_1}, \ldots, y_{t_k})$ 与 $(y_{t_1+h}, \ldots, y_{t_k+h})$ 相同，则称 $\{y_t\}$ 为**严平稳**（strictly stationary）。若仅要求前两阶矩满足

$$\mathbb{E}[y_t] = \mu, \qquad \operatorname{Cov}(y_t, y_{t-k}) = \gamma_k \quad (\text{不依赖 } t) \tag{1.1}$$

则称 $\{y_t\}$ 为**弱平稳**（weakly stationary）或协方差平稳，其中 μ 为常数均值、γ_k 为滞后 k 阶的自协方差、$\gamma_0 = \operatorname{Var}(y_t)$ 为常数方差。

弱平稳是绝大多数线性时间序列模型的建模前提，也是假设检验的对象。实践中常见的偏离有三类：确定性趋势（如名义 GDP）、随机趋势（单位根，如股价对数）、季节性与结构突变。三类偏离的处理方式完全不同：趋势可以用回归或差分消除，单位根需要差分并检验，而结构突变会污染参数估计。小节 1.1.1 中的 γ_k 只依赖于滞后阶数 k 而不依赖绝对时刻 t，这正是「时间平移不变」含义在二阶矩层面的体现。

1.1.2 自相关函数与偏自相关函数

把自协方差标准化即得**自相关函数**（autocorrelation function, ACF）：

$$\rho_k = \frac{\gamma_k}{\gamma_0}, \qquad \hat{\rho}_k = \frac{\sum_{t=k+1}^{T} (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{T} (y_t - \bar{y})^2} \tag{1.2}$$

其中 T 为样本量、$\bar{y}$ 为样本均值、$\hat{\rho}_k$ 为滞后 k 阶的样本自相关。在「序列为白噪声」的原假设下，$\hat{\rho}_k$ 的近似标准差为 $\mathrm{SE}(\hat{\rho}_k) \approx 1/\sqrt{T}$，因此 95% 置信带约为 $\pm 1.96/\sqrt{T}$；当 $T = 1000$ 时该带宽约为 ± 0.062，凡是超出这条带子的 $\hat{\rho}_k$ 都值得进一步追究。

偏自相关函数（partial ACF, PACF）度量剔除中间滞后项之后的「直接」相关：

$$\alpha_k = \operatorname{Corr}\left(y_t,\, y_{t-k} \,\middle|\, y_{t-1}, \ldots, y_{t-k+1}\right) \tag{1.3}$$

其样本版本可由 Yule–Walker 方程配合 Durbin–Levinson 递推 $O(Tk)$ 计算。ACF 与 PACF 的联合使用构成了线性模型定阶的经典工具，具体模式见表 1.1。

表 1.1 ACF 与 PACF 的识别模式（模型定阶的第一步）

模型	理论 ACF	理论 PACF
AR(p)	拖尾（指数或振荡衰减）	p 阶后截尾
MA(q)	q 阶后截尾	拖尾
ARMA(p,q)	拖尾	拖尾
ARIMA(p,d,q)	差分后同 ARMA	差分后同 ARMA

直觉理解 ACF 与 PACF 的分工

ACF 回答「相隔 k 期的两个观测有多像」，PACF 回答「在已知最近 $k-1$ 期的情况下，第 k 期滞后还能额外提供多少信息」。若 y_t 由 y_{t-1} 驱动、y_{t-1} 又由 y_{t-2} 驱动，则 ACF 会一路衰减下去（拖尾），而 PACF 在第 2 阶就截断为零——因为第 2 阶滞后被 y_{t-1} 完全「解释」掉了。这正是 AR(1) 的 ACF 拖尾、PACF 一阶截尾的原因。

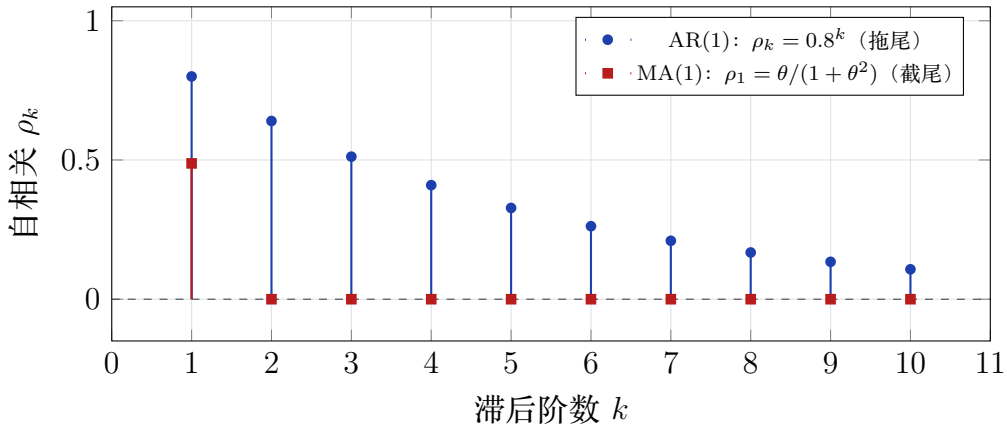


图 1.1 AR(1) 与 MA(1) 的自相关函数对比（$\phi = 0.8$，$\theta = 0.8$）

图 1.1 直观展示了识别逻辑：AR(1) 的 ACF 以几何速度 0.8^k 拖尾，MA(1) 的 ACF 在 $k \geq 2$ 处严格为零。注意 MA(1) 的 $\rho_1 = \theta/(1+\theta^2)$ 关于变换 $\theta \mapsto 1/\theta$ 不变，因此单看 ACF 无法区分 $\theta = 0.8$ 与 $\theta = 1.25$——这正是需要**可逆性**条件的原因。

1.1.3 单位根检验：三种检验的逻辑差异

差分是否必要，取决于序列是否存在单位根。三类检验的原假设不同，混用会导致结论互相矛盾：

- **ADF 检验**（Augmented Dickey–Fuller）回归 $\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^{k} \delta_i \Delta y_{t-i} + \varepsilon_t$，原假设 $H_0 : \gamma = 0$（存在单位根），备择为平稳。t 统计量的临界值来自 Dickey–Fuller 分布而非正态分布，5% 临界值约 -2.86（无趋势）与 -3.41（含趋势）。
- **KPSS 检验**把原假设反过来：H_0 为（趋势）平稳。因此 ADF 与 KPSS 同时不拒绝是常见结果，说明样本对「接近单位根」这一区域没有足够分辨力。
- **PP 检验**（Phillips–Perron）用非参数方式修正残差中的序列相关与异方差，避免 ADF 中滞后阶数选择的主观性，但在强负相关 MA 误差下容易过度拒绝。

⚠ 风险警示　伪回归：高 R^2 也可能是假象

Granger 与 Newbold（1974）的模拟显示：让两条*相互独立*的随机游走做 OLS 回归，R^2 常常超过 0.8，t 统计量动辄大于 4，但 Durbin–Watson 统计量接近 0。原因是一阶单整序列的样本矩以非标准速率发散，常规的 t 与 F 分布完全失效。因此在做任何跨资产的回归之前，必须先检验单整阶数；若被解释变量与解释变量都是 $I(1)$，则要么差分建模，要么检验协整（见后文）。

1.1.4　结构突变

结构突变（structural break）指数据生成过程的参数在某个时点发生跳变，如 2008 年金融危机、2020 年 3 月流动性枯竭、监管规则变更。常见检验包括已知断点下的 Chow 检验，以及未知断点下的 Bai–Perron 多断点检验。Perron（1989）指出一个关键事实：若真实过程是「趋势平稳 + 一次大的水平突变」，而研究者忽略该突变直接做 ADF，检验会系统性地不拒绝单位根——把确定性突变误判为随机趋势。这意味着单位根结论必须与结构突变检验联合解读，否则极易得到错误的差分阶数。

1.2 ARMA 模型族：平稳性与可逆性

1.2.1　AR 模型与平稳性条件

p 阶自回归模型 AR(p) 写作

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t \tag{1.4}$$

其中 c 为常数项、ϕ_i 为自回归系数、ε_t 为白噪声（$\mathbb{E}[\varepsilon_t] = 0$、$\mathrm{Var}(\varepsilon_t) = \sigma^2$、$\mathrm{Cov}(\varepsilon_t, \varepsilon_s) = 0$ 当 $t \neq s$）。引入滞后算子 L（$L y_t = y_{t-1}$）可写成 $\phi(L) y_t = c + \varepsilon_t$，其中 $\phi(L) = 1 - \phi_1 L - \cdots - \phi_p L^p$。

核心要点 1.1　平稳性条件与可逆性条件的对偶

AR 部分的多项式 $\phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p$ 的*全部根*都落在单位圆外时，AR(p) 才是弱平稳的；MA 部分的多项式 $\theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$ 的全部根都落在单位圆外时，MA(q) 才是*可逆*的。平稳性保证「现在可以写成过去冲击的收敛加权和」，可逆性保证「冲击可以写成现在与过去的收敛加权和」——两者是同一枚硬币的两

面，都对应把 z 的幂级数在 $|z|\le 1$ 内展开。

以 AR(1) 为例可以看清条件的作用。把 $y_t = c + \phi y_{t-1} + \varepsilon_t$ 向前迭代：

$$y_t = \frac{c}{1-\phi} + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j} \tag{1.5}$$

该 MA(∞) 表示收敛（从而二阶矩有限）当且仅当 $|\phi|<1$，此时

$$\mathbb{E}[y_t] = \frac{c}{1-\phi}, \qquad \gamma_0 = \frac{\sigma^2}{1-\phi^2}, \qquad \rho_k = \phi^k \tag{1.6}$$

其中 γ_0 由 Yule–Walker 方程 $\gamma_0 = \phi\gamma_1 + \sigma^2$ 与 $\gamma_1 = \phi\gamma_0$ 联立得到，而 $\rho_k = \phi^k$ 直接来自 $\gamma_k = \phi\gamma_{k-1}$ 的递推。式 (1.6) 给出一个可操作的数量级直觉：自相关衰减到一半所需期数为

$$h_{1/2} = \frac{\ln 0.5}{\ln |\phi|} \tag{1.7}$$

当 $\phi = 0.9$ 时 $h_{1/2}\approx 6.6$ 期，$\phi = 0.8$ 时 $h_{1/2}\approx 3.1$ 期。换句话说，日频 AR(1) 系数从 0.8 提高到 0.9，冲击的记忆长度几乎翻倍。

1.2.2 MA 模型与可逆性

q 阶移动平均模型 MA(q) 定义为

$$y_t = \mu + \varepsilon_t + \theta_1\varepsilon_{t-1} + \cdots + \theta_q\varepsilon_{t-q} \tag{1.8}$$

其中 μ 为均值、θ_j 为移动平均系数。有限阶 MA 过程永远是弱平稳的——它是有限个白噪声的线性组合，前两阶矩不随 t 变化，无需任何参数约束。对 MA(1)：$\gamma_0 = \sigma^2(1+\theta^2)$、$\gamma_1 = \sigma^2\theta$、$\gamma_k = 0$ $(k\ge 2)$，故

$$\rho_1 = \frac{\theta}{1+\theta^2}, \qquad \rho_k = 0 \quad (k\ge 2) \tag{1.9}$$

可逆性要求 $|\theta|<1$，即 $\theta(z) = 1+\theta z$ 的根 $z = -1/\theta$ 落在单位圆外。由于 θ 与 $1/\theta$ 产生完全相同的 ACF，若不施加可逆性约束，参数将不可识别；统计软件默认报告可逆的那个根，因此「$\theta = 1.25$」的估计通常会被改写成「$\theta = 0.8$」。

1.2.3 ARMA 与 ARIMA

把 AR 与 MA 合并即得 ARMA(p,q)：

$$\phi(L) y_t = c + \theta(L)\varepsilon_t, \qquad \phi(L) = 1 - \sum_{i=1}^{p}\phi_i L^i, \quad \theta(L) = 1 + \sum_{j=1}^{q}\theta_j L^j \tag{1.10}$$

ARMA 的平稳性完全由 $\phi(z)$ 决定，可逆性完全由 $\theta(z)$ 决定，两者互不干扰。对 ARMA(1,1)，其一阶自相关为

$$\rho_1 = \frac{(1+\phi\theta)(\phi+\theta)}{1+2\phi\theta+\theta^2} \tag{1.11}$$

而对 $k \geq 2$ 有 $\rho_k = \phi\rho_{k-1}$——即 ACF 在 1 阶之后呈现纯 AR(1) 的几何衰减。例如 $\phi = 0.6$、$\theta = 0.3$ 时 $\rho_1 = 1.062/1.45 \approx 0.732$，$\rho_2 \approx 0.439$。

对非平稳但差分后平稳的序列，采用 ARIMA(p, d, q)：

$$\phi(L)(1-L)^d y_t = c + \theta(L)\varepsilon_t \tag{1.12}$$

其中 d 为差分阶数，$(1-L)^d$ 为 d 阶差分算子，$(1-L)y_t = \Delta y_t$。差分阶数并非越大越好：若序列其实已平稳而仍然差分，会在 MA 部分引入一个接近 -1 的根，即「过差分」，使 $\theta(z)$ 出现单位根、可逆性被破坏，并放大高频噪声。**判断原则**：以单位根检验与原序列 ACF 的衰减速度交叉验证，通常 $d \leq 2$。

1.2.4 季节模型 SARIMA

季节性 ARIMA 记作 SARIMA$(p, d, q)(P, D, Q)_s$，其形式为

$$\phi(L)\Phi(L^s)(1-L)^d(1-L^s)^D y_t = \theta(L)\Theta(L^s)\varepsilon_t \tag{1.13}$$

其中 s 为季节周期（月度数据 $s = 12$、季度数据 $s = 4$）、$\Phi(L^s)$ 与 $\Theta(L^s)$ 分别为季节自回归与季节移动平均多项式、D 为季节差分阶数。以电力消费的月度数据为例，$(1-L^{12})$ 消除「同月同比」之外的年内周期，$D = 1$ 即可让季节 ACF 上 $12, 24, 36$ 处的尖峰消失。金融日频数据的季节结构远弱于宏观数据，但日内效应（开盘与收盘的波动率尖峰）可以用 $s = 48$（半小时采样）的同类模型刻画。

1.3 Box–Jenkins 建模流程

Box–Jenkins 方法把建模拆成四步闭环，其价值在于把「模型选择」从一次性判断变成可迭代的诊断过程。

算法 1.1 的第 7–9 步是最容易被跳过、却最能决定成败的部分：均值方程残差若仍含 ARCH 效应，则普通最小二乘的标准误被低估、置信区间过窄、t 检验偏激进。诊断阶段的核心统计量是 Ljung–Box Q 检验

$$Q = T(T+2)\sum_{k=1}^{m}\frac{\hat{\rho}_k^2}{T-k} \;\sim\; \chi^2_{m-p-q} \tag{1.14}$$

其中 m 为考察的最大滞后阶数（经验取法 $m \approx \min(20, T/5)$）、$\hat{\rho}_k$ 为残差自相关。Q 显著说明还有结构没有提取干净。

阶数选择常用信息准则：

$$\mathrm{AIC} = -2\ln\hat{L} + 2k, \qquad \mathrm{BIC} = -2\ln\hat{L} + k\ln T, \qquad \mathrm{HQ} = -2\ln\hat{L} + 2k\ln\ln T \tag{1.15}$$

其中 $\hat{L}$ 为极大似然值、k 为待估参数个数。BIC 的惩罚随 $\ln T$ 增长，因此比 AIC 更保守、更倾向于简约模型；当两个模型 AIC 相差小于 2 时，可以认为它们在样本内表现上无法区分。

算法 1.1 Box–Jenkins 四步建模流程

输入： 平稳化后的序列 $y_1, \dots, y_T$，最大阶数 $p_{\max}, q_{\max}$
输出： 通过诊断检验的模型 $\widehat{\mathrm{ARMA}}(p, q)$

识别：计算 ACF/PACF，结合 AIC/BIC 在 $p \le p_{\max}, q \le q_{\max}$ 内搜索
估计：用条件极大似然或精确极大似然估计 $(\phi, \theta, \sigma^2, c)$
while 诊断未通过 **do**
    诊断：检验残差 $\hat{\varepsilon}_t$ 是否为白噪声（Ljung–Box Q 检验）
        并检查残差方差的 ARCH 效应（$\hat{\varepsilon}_t^2$ 的 ACF）
    if 存在显著自相关 **then**
        调整 p, q（或引入季节项、结构突变虚拟变量）后重新估计
    else if 存在显著 ARCH 效应 **then**
        转波动率建模（表 1.2），对均值方程残差拟合 GARCH 族
    end if
end while
预测：递推条件均值 $\hat{y}_{T+h|T}$ 并给出预测区间
return $(\hat{\phi}, \hat{\theta}, \hat{\sigma}^2)$ 与 h 步预测

实务应用　实务中的默认配置

多数卖方与买方研究在日频资产收益率上都使用「常数均值 + 低阶结构」的配置：均值方程取 AR(1) 或纯常数，波动率方程取 GARCH(1, 1) 或 GJR，分布取学生 t。原因有三：日收益率自相关的经济幅度极小（$|\phi| < 0.1$，扣掉交易成本后基本不可交易）；高阶模型在滚动窗口中的参数不稳定性抵消了样本内增益；而波动率部分的自相关是真实且稳健的，值得投入建模预算。

1.4 波动率建模：ARCH 与 GARCH 族

1.4.1 ARCH 模型

Engle（1982）注意到收益率的平方存在显著自相关，于是把方差设为过去冲击的函数：

$$r_t = \mu_t + \varepsilon_t, \qquad \varepsilon_t = \sigma_t z_t, \qquad z_t \sim \text{i.i.d.}(0, 1) \tag{1.16}$$

$$\sigma_t^2 = \omega + \sum_{i=1}^{q} \alpha_i \varepsilon_{t-i}^2 \tag{1.17}$$

其中 r_t 为收益率、μ_t 为条件均值、σ_t^2 为条件方差、z_t 为标准化新息（常取标准正态或标准化学生 t）、$\omega > 0$ 为基准方差、$\alpha_i \ge 0$ 度量第 i 阶冲击对当前方差的影响。ARCH 的实质是：今天的方差由最近 q 期「意外的大小」决定。其缺陷在于记忆太短——要让波动率冲击衰减得足够慢，往往需要 $q > 10$ 甚至几十个参数。

1.4.2 GARCH 模型与长期方差

Bollerslev（1986）用「方差的滞后项」替代大量冲击滞后项：

$$\sigma_t^2 = \omega + \sum_{i=1}^{q} \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^{p} \beta_j \sigma_{t-j}^2 \tag{1.18}$$

其中 β_j 为方差自回归系数。金融实践中最常用的是 GARCH(1, 1)：

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \tag{1.19}$$

只需三个参数就能刻画「大波动跟着大波动」的聚集现象。取无条件期望可得**长期方差**

$$\bar{\sigma}^2 = \mathbb{E}[\sigma_t^2] = \frac{\omega}{1-\alpha-\beta}, \qquad \text{要求} \alpha+\beta<1 \tag{1.20}$$

其中 $\alpha+\beta$ 称为**持续性**（persistence），度量一次波动率冲击的衰减速度；$\alpha+\beta \to 1$ 时长期方差发散，对应 IGARCH 模型（波动率冲击永不衰减）。把式 (1.19) 反复代入可得到 ARCH(∞) 表示

$$\sigma_t^2 = \frac{\omega}{1-\beta} + \alpha \sum_{j=0}^{\infty} \beta^j \varepsilon_{t-1-j}^2 \tag{1.21}$$

这说明 GARCH(1,1) 其实是一个几何衰减的记忆核，β 就是核的衰减率。冲击的半衰期由持续性直接给出：

$$h_{1/2} = \frac{\ln 0.5}{\ln(\alpha+\beta)} \tag{1.22}$$

例 1.1 GARCH(1,1) 的长期波动率、半衰期与预测

设日频参数为 $\omega = 0.01$、$\alpha = 0.08$、$\beta = 0.90$（收益率以百分数计，故方差单位为「百分数平方」）。(1) 持续性 $\alpha+\beta = 0.98$，由式 (1.20) 得长期方差 $\bar{\sigma}^2 = 0.01/0.02 = 0.50$，长期日波动率 $\bar{\sigma} = 0.707\%$；按 252 个交易日年化得 $0.707 \times \sqrt{252} \approx 11.2\%$。(2) 由式 (1.22)，半衰期 $h_{1/2} = \ln 0.5 / \ln 0.98 \approx 34.3$ 个交易日，即一次波动率冲击约需 34 天衰减一半，正好对应图 1.2 中长达数周的「高位平台」。(3) h 步方差预测为

$$\mathbb{E}_t[\sigma_{t+h}^2] = \bar{\sigma}^2 + (\alpha+\beta)^{h-1}\big(\sigma_{t+1}^2 - \bar{\sigma}^2\big) \tag{1.23}$$

若当前 $\sigma_{t+1} = 1.4\%$（即 $\sigma_{t+1}^2 = 1.96$），则 1 天后方差预测为 $0.50 + 0.98^0 \times (1.96 - 0.50) = 1.96$，10 天后为 $0.50 + 0.98^9 \times 1.46 \approx 0.50 + 1.216 = 1.72$，对应波动率 1.31%；预测值以半衰期速度回归长期水平。

式 (1.23) 的推导只用到一步。把方差方程推进一步并取条件期望：

$$\sigma_{t+h}^2 = \omega + (\alpha+\beta)\sigma_{t+h-1}^2 + \alpha\sigma_{t+h-1}^2\big(z_{t+h-1}^2 - 1\big) \tag{1.24}$$

其中最后一项的条件期望为零（z_{t+h-1} 与 $\mathcal{F}_{t+h-2}$ 独立且均值为零，故 $\mathbb{E}_t[\sigma_{t+h-1}^2(z_{t+h-1}^2-1)] = 0$），于是得到以一阶线性差分方程递推的预测公式 (1.23)：每一期的方差预测值按比例 $(\alpha+\beta)$ 向长期方差 $\bar{\sigma}^2$ 收缩。

图 1.2 是「波动率聚集」最直接的图示：第 35–50 个交易日附近，$|r_t|$ 的散点明显变密变大，而条件波动率 σ_t 相应抬升并缓慢回落。注意 σ_t 是平滑的（它由递推产生），而 $|r_t|$ 是噪声的——这正是「波动率可预测、收益率方向不可预测」这一经验规律的可视化。

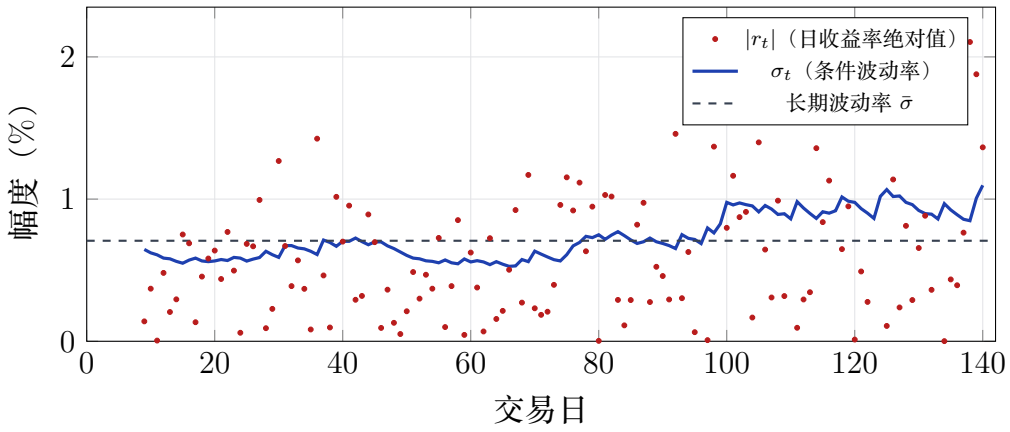


图 1.2 GARCH(1,1) 模拟：$\omega = 0.01$、$\alpha = 0.08$、$\beta = 0.90$ 下的波动率聚集

1.4.3 GARCH 族的扩展

表 1.2 主要 GARCH 族模型对比

模型	方差方程的核心形式	主要捕捉的特征	额外参数
ARCH(q)	$\sigma_t^2 = \omega + \sum \alpha_i \varepsilon_{t-i}^2$	波动率聚集	q 个
GARCH(1,1)	$\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$	聚集 + 长记忆	0
EGARCH	$\ln\sigma_t^2 = \omega + \beta\ln\sigma_{t-1}^2 + \gamma z_{t-1} + \alpha(\lvert z_{t-1}\rvert - \mathbb{E}\lvert z\rvert)$	杠杆效应（对数形式，无符号约束）	1
GJR-GARCH	$\sigma_t^2 = \omega + (\alpha + \gamma\mathbf{1}_{\{\varepsilon_{t-1}<0\}})\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$	杠杆效应（直接形式）	1
FIGARCH	$(1-\phi L)(1-L)^d\varepsilon_t^2 = \omega + (1-\beta L)v_t$	长记忆（d 分数阶）	1
DCC-GARCH	分两步：单变量 GARCH + 动态相关矩阵 Q_t	时变相关性（多资产）	多于 1

表 1.2 中的非对称模型针对的是「杠杆效应」：股价下跌时波动率上升的幅度大于同等幅度上涨时的上升。在 GJR 形式下，$\gamma > 0$ 表示负冲击的额外影响；其平稳性条件相应改为 $\alpha + \gamma/2 + \beta < 1$（若 z_t 对称，负冲击概率为 1/2）。EGARCH 用对数方差建模，天然保证 $\sigma_t^2 > 0$，且无需对参数施加非负约束，但代价是 σ_t^2 的解析多步预测不可得，需要模拟。FIGARCH 通过分数阶差分 $d \in (0,1)$ 刻画「长记忆」：冲击的自相关以 k^{2d-1} 的幂律速度衰减而非几何速度衰减，半衰期的概念在此不再适用（记忆长度是尺度依赖的）。

⚠ 风险警示 GARCH 的三条失效边界

（1）**结构突变**：GARCH 把波动率水平的变化解释为「持续性冲击」，但若真实原因是机制切换（如 2020 年 3 月的流动性危机、波动率目标型基金的被动抛售），估计出的 $\alpha + \beta$ 会接近 1（伪高持续性），而模型对下一次突变毫无预警。Lamoureux 与 Lastrapes（1990）证明，忽略结构突变会系统性高估持续性。（2）**非对称与跳跃**：GARCH 的方差方程只含 ε^2，天生对称；遇到跳跃型事件（单日 $\pm 10\%$）时，一次

巨大残差会把 σ_t 抬得很高并缓慢衰减，而这与真实的「事件驱动、快速回落」形态不符。(3) **数据频率**：参数估计高度依赖采样频率。日频估出的 $\alpha+\beta$ 与 5 分钟频估出的值不可直接比较；把日频参数套用到日内波动率预测上会严重高估日内方差。

1.5 已实现波动率与 HAR 模型

1.5.1 已实现波动率

当高频数据可得时，我们不必再「用模型推断波动率」，而可以直接度量它。把一天分成 M 个等间隔区间，第 i 个区间的高频收益率为 $r_{t,i}$，则**已实现波动率**（realized volatility, RV）定义为

$$\mathrm{RV}_t = \sum_{i=1}^{M} r_{t,i}^2 \xrightarrow[M\to\infty]{} \int_t^{t+1} \sigma_s^2 \,\mathrm{d}s =: \mathrm{IV}_t \tag{1.25}$$

其中 IV_t 为积分方差（integrated variance）。收敛的数学依据是二次变差理论（详见第 10 章）：连续半鞅的已实现二次变差依概率收敛到其二次变差过程。在理想的无摩擦、无跳跃市场里，RV_t 是 IV_t 的一致估计量。

现实中 M 的选择是一个偏差–方差权衡：M 太小则度量误差大（方差高），M 太大则微观结构噪声（买卖价差跳动、不同步报价、离散价格）主导，使 RV 上偏且自相关被污染。实用折中通常是 5 分钟采样（$M\approx 78$，对应 6.5 小时交易时段），或采用 5 分钟 RV 加「已实现核」「预平均」等噪声稳健估计量。

1.5.2 HAR 模型

HAR（Heterogeneous AutoRegressive）模型由 Corsi（2009）提出，用一个简单的线性回归概括「不同时间尺度的市场参与者」这一直觉：

$$\mathrm{RV}_t^{(d)} = c + \beta_d \,\mathrm{RV}_{t-1}^{(d)} + \beta_w \,\mathrm{RV}_{t-1}^{(w)} + \beta_m \,\mathrm{RV}_{t-1}^{(m)} + u_t \tag{1.26}$$

其中 $\mathrm{RV}^{(d)}$ 为日度 RV、$\mathrm{RV}^{(w)} = \frac{1}{5}\sum_{j=1}^{5}\mathrm{RV}_{t-j}^{(d)}$ 为周度均值、$\mathrm{RV}^{(m)} = \frac{1}{22}\sum_{j=1}^{22}\mathrm{RV}_{t-j}^{(d)}$ 为月度均值、u_t 为扰动项。三类参与者（日内投机者、周度调仓者、月度机构）分别对应三个尺度，因此模型只需三个参数就能逼近长记忆行为。

表 1.3　HAR 模型的三个时间尺度

频率	记号	计算方式	经济含义
日	$\mathrm{RV}^{(d)}$	当日 5 分钟收益平方和	日内交易者的当日信息
周	$\mathrm{RV}^{(w)}$	过去 5 日 RV 均值	周度调仓者的风险预算
月	$\mathrm{RV}^{(m)}$	过去 22 日 RV 均值	长期机构的波动率目标

表 1.3 中的三个成分相加构成了「波动率的三层记忆」。典型估计结果满足 β_w 与 β_m 都显著为正，且三者之和接近 1（如 $0.36+0.42+0.20=0.98$），这正是长记忆特征的参数

化体现；日度回归的 R^2 通常在 0.5–0.65 区间，远高于收益率方向预测的 R^2（后者常在 0.01 以下，见后文关于低信噪比的讨论）。由于 u_t 存在异方差与序列相关，HAR 的推断必须使用 HAC（Newey–West）稳健标准误。

Listing 1.1 用 arch 拟合 GARCH(1,1) 并做波动率预测

```python
import numpy as np
from arch import arch_model

rng = np.random.default_rng(42)
n, omega, alpha, beta = 2000, 0.01, 0.08, 0.90
sigma2 = np.empty(n)
eps = np.empty(n)
sigma2[0] = omega / (1.0 - alpha - beta)
z = rng.standard_normal(n)
for t in range(1, n):
    sigma2[t] = omega + alpha * eps[t - 1] ** 2 + beta * sigma2[t - 1]
    eps[t] = np.sqrt(sigma2[t]) * z[t]

am = arch_model(eps, mean="Constant", vol="Garch", p=1, q=1, dist="t")
res = am.fit(disp="off")
print(res.params)

persistence = res.params["alpha[1]"] + res.params["beta[1]"]
print("persistence =", round(persistence, 4))
print("half life   =", round(np.log(0.5) / np.log(persistence), 2))
print("long run sd =", round(np.sqrt(res.params["omega"] / (1 -
    persistence)), 4))

fc = res.forecast(horizon=10, reindex=False)
print(np.sqrt(fc.variance.values[-1]))
```

listing 1.1 中的长期波动率由 $\sqrt{\hat{\omega}/(1-\hat{\alpha}-\hat{\beta})}$ 计算，与 式 (1.20) 一致；参数 `dist="t"` 让新息服从标准化学生 t 分布，这对金融收益率是必要的——正态新息会低估尾部风险，也会使 ω 的估计有偏。注意代码用的是模拟数据，便于复现；换成真实收益率序列时，只需把 `eps` 替换为 `100 * np.diff(np.log(prices))`（乘以 100 是为了数值稳定）。

Listing 1.2 HAR 回归与 HAC 稳健标准误

```python
import numpy as np
import pandas as pd
import statsmodels.api as sm

rng = np.random.default_rng(7)
n = 1500
r = 0.01 * rng.standard_normal(n)
rv = np.abs(r) + 0.2 * rng.random(n)          # daily realized volatility
    proxy

df = pd.DataFrame({"rv": rv})
df["rv_d"] = df["rv"].shift(1)
```

```
df["rv_w"] = df["rv"].rolling(5).mean().shift(1)
df["rv_m"] = df["rv"].rolling(22).mean().shift(1)
df = df.dropna()

y = np.log(df["rv"])                                  # log transform keeps rv
    positive
X = sm.add_constant(df[["rv_d", "rv_w", "rv_m"]])
res = sm.OLS(y, X).fit(cov_type="HAC", cov_kwds={"maxlags": 10})
print(res.params)
print(res.bse)
print(res.rsquared)
```

listing 1.2 用对数变换保证预测值非负，并用 `maxlags=10` 的 HAC 协方差修正残差自相关导致的低估标准误。若要复现 式 (1.26) 中「三尺度」的解释，可把 `rv_w` 与 `rv_m` 换成用真实高频数据构造的周、月均值；若只关心预测精度，把被解释变量换成 RV_t 与「已实现半方差」（上涨与下跌分开）往往还能再提升。

1.6 状态空间模型与卡尔曼滤波

线性均值与波动率模型都假定参数在样本期内固定。但很多金融关系本身是时变的：对冲比率随市场状态漂移、因子暴露随风格轮动变化、潜在增长率缓慢漂移。状态空间模型把这类「不可观测的时变参数」显式写成状态变量，卡尔曼滤波则给出在线递推解。

1.6.1 局部水平模型

最简单也最常用的状态空间模型是**局部水平模型**（local level model）：

$$y_t = \underbrace{x_t}_{\text{潜在水平}} + v_t, \qquad v_t \sim \mathcal{N}(0, R) \tag{1.27}$$

$$x_t = x_{t-1} + w_t, \qquad w_t \sim \mathcal{N}(0, Q) \tag{1.28}$$

其中 y_t 为观测值（如某只 ETF 的每日对数价格）、x_t 为不可观测的随机游走水平、v_t 为观测噪声（波动率 R）、w_t 为状态噪声（波动率 Q）、二者相互独立。信号–噪声比 Q/R 决定滤波器对观测的信任程度。

1.6.2 卡尔曼滤波递推的推导

记 $x_{t|t-1} = \mathbb{E}[x_t \mid y_1, \dots, y_{t-1}]$、$P_{t|t-1} = \mathrm{Var}(x_t \mid y_1, \dots, y_{t-1})$，带 $t|t$ 的量同理。由式 (1.28) 与全期望、全方差公式立即得到**预测步**：

$$x_{t|t-1} = x_{t-1|t-1}, \qquad P_{t|t-1} = P_{t-1|t-1} + Q \tag{1.29}$$

关键在于**更新步**。给定 $y_1, \dots, y_{t-1}$，条件联合分布中 (x_t, y_t) 是二维正态，其中 $y_t = x_t + v_t$，故 $\mathrm{Cov}(x_t, y_t \mid \mathcal{F}_{t-1}) = P_{t|t-1}$，$\mathrm{Var}(y_t \mid \mathcal{F}_{t-1}) = P_{t|t-1} + R$。对联合正态而言，条件期望就是线性回归，回归系数为 Cov / Var，于是

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + R}, \qquad x_{t|t} = x_{t|t-1} + K_t \underbrace{(y_t - x_{t|t-1})}_{\text{新息}}, \qquad P_{t|t} = (1 - K_t) P_{t|t-1} \tag{1.30}$$

其中 K_t 为**卡尔曼增益**（Kalman gain）。第二式的含义是：把预测误差按增益比例回写到状态上；第三式是「条件方差 = 先验方差 × 残差比例」。式 (1.29) 与 (1.30) 交替迭代即得整个滤波路径。

例 1.2 卡尔曼增益的稳态解

设 $Q=R=1$。稳态时 $P_{t|t-1}=P$ 为常数，代入 式 (1.30) 的第三式并以式 (1.29) 更新一步，得 $P=\big(1-\frac{P}{P+R}\big)(P+Q)=\frac{PR}{P+R}+Q$。以 $Q=R=1$ 代入得 $P^2+P-1=0$，取正根 $P=(\sqrt{5}-1)/2\approx 0.618$。于是稳态增益 $K^*=P/(P+R)=0.618/1.618\approx 0.382$。经济含义：当状态噪声与观测噪声等大时，滤波器每次只把 38.2% 的新息写进状态，其余 61.8% 视为噪声丢弃。Q/R 越大（状态越活跃）K^* 越接近 1；$Q/R\to 0$（状态近乎常数）时 $K^*\to 0$，滤波器退化为「取全样本平均」。

小节 1.6.2 中的 0.382 与 0.618 恰是黄金分割的两个倒数关系，这并非巧合，而是二次方程 $P^2+QP-QR=0$ 在 $Q=R$ 时的自然结果。滤波的另一个副产品是似然函数：新息 $y_t-x_{t|t-1}$ 的方差为 $P_{t|t-1}+R$，把各期新息的对数密度相加即得预测误差分解（prediction error decomposition）形式的对数似然，从而可以极大似然估计 Q 与 R，也可以用 EM 算法迭代。

实务应用 状态空间模型在量化中的三类用法

(1) **时变贝塔**：把 CAPM 的 β_t 设为随机游走状态，观测方程为 $r_t=\alpha+\beta_t r_{m,t}+v_t$，得到随市场状态漂移的对冲比率；(2) **动态因子**：把多个资产的共同成分设为状态，观测方程为因子载荷矩阵，即 Kalman 滤波版本的 PCA/动态因子模型，可处理缺失值与不定期发布的数据；(3) **配对交易的时变价差**：把协整向量 β_t 设为状态，比固定窗口 OLS 更能适应协整关系的缓慢漂移。三类用法的共同前提是 Q、R 的结构设定正确，Q 设得过大会让状态追逐噪声（等价于过拟合）。

1.7 协整、误差修正与格兰杰因果

1.7.1 协整与配对交易

定义 1.2 协整

若两个序列 y_t 与 x_t 都是 $I(1)$（一阶单整，即需差分一次才平稳），且存在非零常数 β 使得

$$u_t=y_t-\beta x_t-\mu\ \sim\ I(0) \tag{1.31}$$

则称 y_t 与 x_t **协整**（cointegrated），向量 $(1,-\beta)$ 为协整向量，u_t 为均衡误差。其中 μ 为长期均衡的截距。

小节 1.7.1 的关键在于「两个非平稳序列的某个线性组合变平稳」。经济上它是套利机制存在的数学表达：只要价差偏离均衡，套利者就会交易把它拉回。注意协整与「高相关」是两件不同的事：两条独立的随机游走可以因为共同趋势而高度相关，但价差是随机游走而非平稳的，做价差回归会落到伪回归陷阱。

Engle–Granger 两步法把检验与估计分开：第一步用 OLS 估计 $y_t=\mu+\beta x_t+u_t$，第二

步对残差 $\hat{u}_t$ 做 ADF 检验，但临界值必须用 Engle–Granger 专用临界值（比普通 ADF 更负，因为 $\hat{\beta}$ 是估计出来的）；拒绝单位根即支持协整。

1.7.2 误差修正模型

由 Granger 表示定理，若存在协整关系，则一定存在**误差修正模型**（error correction model, ECM）：

$$\Delta y_t = \varphi_0 + \alpha_y\big(y_{t-1} - \beta x_{t-1}\big) + \sum_{i=1}^{k} \gamma_i \Delta y_{t-i} + \sum_{i=1}^{k} \delta_i \Delta x_{t-i} + \varepsilon_t \tag{1.32}$$

其中 α_y 为调整速度（误差修正系数）、γ_i 与 δ_i 刻画短期动态。为使偏离被拉回均衡，要求 $-2 < \alpha_y < 0$；α_y 越负，回归速度越快。偏离均衡后的衰减遵循 $(1+\alpha_y)^h$，故偏离的半衰期为

$$h_{1/2} = \frac{\ln 0.5}{\ln(1+\alpha_y)} \tag{1.33}$$

例如 $\alpha_y = -0.15$ 给出 $\ln 0.5 / \ln 0.85 \approx 4.3$ 期，即价差偏离约四天后回到一半。实践中应把 ECM 的截距与结构突变虚拟变量一并纳入，否则「均衡」本身的漂移会被误当成调整速度。

实务应用　配对交易的执行清单

用协整做统计套利的标准流程是：筛选同行业、同驱动因子的资产对 $\to$ 用滚动窗口估计 (β, μ) $\to$ 计算价差 $z_t = (y_t - \hat{\mu} - \hat{\beta} x_t)/\hat{\sigma}_u$ $\to$ 在 $|z_t| > 2$ 建仓、回到 $|z_t| < 0.5$ 平仓 $\to$ 对 $|z_t| > 4$ 触发强制止损。两个必须的纪律：其一，滚动窗口长度决定 $\hat{\beta}$ 的偏差–方差权衡（窗口越长越稳、越短越适应），常用 60–120 个交易日；其二，必须用 ECM 的 α_y 估计持仓时间，若半衰期大于可承受的持仓期，则该组合的收益无法覆盖资金成本与交易成本。

1.7.3 Johansen 检验

当变量多于两个时，可能存在多个协整关系，Engle–Granger 的做法（指定一个被解释变量）不适用。Johansen 方法从向量误差修正模型（VECM）出发：

$$\Delta Y_t = \Pi Y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta Y_{t-i} + \varepsilon_t, \qquad \Pi = \alpha \beta^{\top} \tag{1.34}$$

其中 Y_t 为 n 维向量、Π 为 $n \times n$ 的长期影响矩阵、Γ_i 为短期动态矩阵、α 为调整速度矩阵、β 为协整向量矩阵。核心结论是：$\operatorname{rank}(\Pi) = r$ 就等于协整关系的个数，且 $r \le n-1$；$r = n$ 说明所有变量本身平稳，$r = 0$ 说明不存在协整。检验通过 Π 的降秩回归实现，统计量是其特征值 $\hat{\lambda}_i$ 的函数：

$$\text{迹检验：} \quad LR_{\text{trace}}(r) = -T \sum_{i=r+1}^{n} \ln\big(1 - \hat{\lambda}_i\big) \tag{1.35}$$

$$\text{最大特征值检验：} \quad LR_{\max}(r) = -T \ln\big(1 - \hat{\lambda}_{r+1}\big) \tag{1.36}$$

两式的原假设都是「协整秩为 r」。迹检验是「从少到多」逐层拒绝，最大特征值检验逐阶比较，两者结论不一致时应谨慎，并检查样本量是否足够。

例 1.3 二变量 Johansen 检验的数值判读

设 $n=2$、$T=500$，估计得特征值 $\hat\lambda_1=0.15$、$\hat\lambda_2=0.008$。(1) 迹检验 $r=0$：$LR_{\text{trace}}=-500\ln(0.85)\approx 500\times 0.1625\approx 81.3$，5% 临界值约 19.96，强烈拒绝「无协整」。(2) 迹检验 $r=1$：$LR_{\text{trace}}=-500\ln(0.992)\approx 500\times 0.00803\approx 4.0$，5% 临界值约 9.24，不能拒绝「秩为 1」。(3) 最大特征值检验 $r=0$：$-500\ln(0.85)\approx 81.3>$ 临界值 15.67，拒绝；$r=1$：$4.0<9.24$，不拒绝。两个检验一致地给出 $r=1$。结论：两个 $I(1)$ 序列之间存在唯一协整关系，可用 ECM 建模并做配对交易。

1.7.4 格兰杰因果

定义 1.3 Granger 因果性

在给定信息集 $\mathcal{F}_{t-1}$ 下，若 $\operatorname{Var}\big(y_t\mid\mathcal{F}_{t-1}\big)<\operatorname{Var}\big(y_t\mid\mathcal{F}_{t-1}\setminus\{x_s:s<t\}\big)$，则称 x **Granger 引起** y。在 ARMA 设定下，这等价于 y 的方程中所有 x 的滞后项系数联合为零。

检验方法是对 y 的方程做两次回归：受约束模型只含 y 的滞后项，无约束模型再加上 x 的 q 个滞后项，然后用

$$F=\frac{(\mathrm{RSS}_r-\mathrm{RSS}_u)/q}{\mathrm{RSS}_u/(T-k)}\ \sim\ F(q,\,T-k) \tag{1.37}$$

其中 RSS_r 与 RSS_u 分别为受约束与无约束残差平方和、k 为无约束模型的参数个数。例：$T=200$、$q=4$、$\mathrm{RSS}_r=100$、$\mathrm{RSS}_u=90$ 时 $F=\frac{2.5}{90/196}\approx 5.44$，超过 $F(4,196)$ 的 5% 临界值约 2.42，故拒绝「x 不引起 y」。

⚠ 风险警示 格兰杰因果的三条使用禁忌

(1) **不控制混杂变量**：若 x 与 y 同受第三个变量 z 驱动，x 的滞后项会以 z 的代理身份显著，得到的「因果」在加入 z 后消失。(2) **非平稳数据**：若 y、x 都是 $I(1)$ 且不平衡（无协整），F 统计量不服从 F 分布；此时必须改用 VECM 框架下的检验。(3) **线性与同期效应**：式 (1.37) 只能发现线性、滞后的可预测性。非线性依赖、同期因果、以及由条件异方差造成的伪依赖都无法识别；需要非线性版本或转移熵等工具，但转移熵在小样本下的估计偏差极大，须配合替代数据检验。

1.8 深度学习时间序列模型

1.8.1 从 RNN 到 LSTM

循环神经网络（RNN）用同一个权重矩阵在时间上共享参数：

$$h_t=\tanh\big(W_h h_{t-1}+W_x x_t+b\big) \tag{1.38}$$

其中 x_t 为 t 时刻的输入特征、h_t 为隐状态、W_h 与 W_x 为权重矩阵、b 为偏置。反向传播时梯度要经过 T 次 $W_h^\top$ 的连乘，其谱半径小于 1 时梯度指数衰减（梯度消失），大于 1 时爆炸——这就是 RNN 难以学习长依赖的原因。

LSTM 用门控与一条*加性*的记忆通道解决该问题：

$$f_t = \sigma\big(W_f[h_{t-1}, x_t] + b_f\big) \qquad \text{（遗忘门）} \tag{1.39}$$

$$i_t = \sigma\big(W_i[h_{t-1}, x_t] + b_i\big) \qquad \text{（输入门）} \tag{1.40}$$

$$\tilde{C}_t = \tanh\big(W_C[h_{t-1}, x_t] + b_C\big) \qquad \text{（候选记忆）} \tag{1.41}$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \qquad \text{（记忆单元更新）} \tag{1.42}$$

$$o_t = \sigma\big(W_o[h_{t-1}, x_t] + b_o\big) \qquad \text{（输出门）} \tag{1.43}$$

$$h_t = o_t \odot \tanh(C_t) \qquad \text{（隐状态）} \tag{1.44}$$

其中 $\sigma(\cdot)$ 为 logistic 函数、$\odot$ 为逐元素乘积、$[h_{t-1}, x_t]$ 为拼接向量。式 (1.42) 是 LSTM 的核心：C_t 沿时间的更新是*加法*，因此 $\partial C_t / \partial C_{t-1} = f_t$ 不会连乘成指数衰减，梯度可以跨越很多步传回。式 (1.39) 的遗忘门 f_t 由数据决定「丢弃多少旧记忆」，这正是它能处理「波动率机制切换」这类长记忆结构的机制基础。

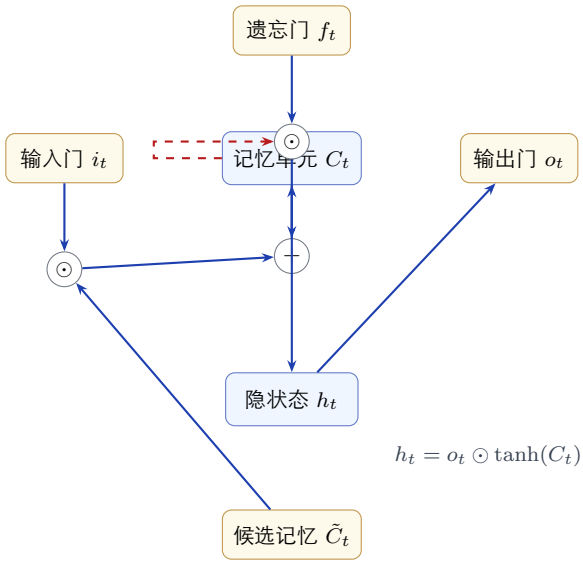


图 1.3　LSTM 单元的门控结构与加性记忆通道（对应 式 (1.42)）

图 1.3 中的关键结构是那条从 C_{t-1} 出发、经过遗忘门与加法节点回到 C_t 的*直通路径*：它没有任何非线性压缩，梯度可以近似无损地回传，这是 LSTM 相对朴素 RNN 的根本改进。GRU 是它的简化版本，把记忆单元与隐状态合并：

$$z_t = \sigma\big(W_z[h_{t-1}, x_t]\big) \qquad \text{（更新门）} \tag{1.45}$$

$$r_t = \sigma\big(W_r[h_{t-1}, x_t]\big) \qquad \text{（重置门）} \tag{1.46}$$

$$\tilde{h}_t = \tanh\big(W[r_t \odot h_{t-1}, x_t]\big), \qquad h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \tag{1.47}$$

其中 z_t 同时承担遗忘与输入的职责。GRU 参数比 LSTM 少约 25%，在中小规模金融数据集上往往表现相当甚至更好，是低信噪比场景下更稳妥的默认选择。

1.8.2 Transformer 与面向时间序列的变体

Transformer 用自注意力替代循环结构：

$$\mathrm{Attention}(Q,K,V)=\mathrm{softmax}\Big(\frac{QK^{\top}}{\sqrt{d_k}}\Big)V \tag{1.48}$$

其中 Q、K、V 分别为查询、键、值矩阵、d_k 为键的维度、$\sqrt{d_k}$ 用于防止内积随维度增大而饱和 softmax。多头注意力把表示空间切成 h 个子空间并行计算：

$$\begin{aligned}\mathrm{MultiHead}(Q,K,V)&=\mathrm{Concat}(\mathrm{head}_1,\dots,\mathrm{head}_h)\,W^{O}\\ \mathrm{head}_i&=\mathrm{Attention}(QW_i^{Q},\,KW_i^{K},\,VW_i^{V})\end{aligned} \tag{1.49}$$

由于注意力本身对序列顺序无感，必须注入位置信息。原版使用正弦位置编码：

$$\mathrm{PE}_{(pos,2i)}=\sin\!\big(pos/10000^{2i/d_{\mathrm{model}}}\big),\qquad \mathrm{PE}_{(pos,2i+1)}=\cos\!\big(pos/10000^{2i/d_{\mathrm{model}}}\big) \tag{1.50}$$

其中 pos 为时间位置、i 为维度索引、d_{model} 为模型维度。自注意力的复杂度为 $O(L^2)$（L 为序列长度），这直接催生了面向长序列的改进：

- **Informer**（2021）：用 ProbSparse 注意力只保留「查询稀疏度」高的键，把复杂度降到 $O(L\log L)$，并配以自注意力蒸馏，适合数百到上千步的长序列预测。
- **Autoformer**（2021）：先用自相关函数（ACF）聚集相似子序列，再用序列分解块显式分离趋势与季节成分，擅长强周期数据。
- **PatchTST**（2023）：把序列切成 Patch（思路来自 ViT），以通道独立方式建模，参数量与训练成本显著低于逐步建模的方案，对缺失值与多变量异质通道更稳健。
- **TFT**（Temporal Fusion Transformer, 2021）：引入静态协变量编码器、门控残差网络与可解释的多头注意力，能输出变量重要性与注意力权重，适合「既要预测又要归因」的风控与需求预测场景。

1.8.3 金融场景下的训练技巧

表 1.4 列出的容量优势在金融数据上很容易变成劣势，因为金融序列的信噪比极低：日频收益率可预测部分的 R^2 常在 0.01 以下，而模型参数量动辄 10^5 以上。因此训练流程的工程细节比网络结构更决定成败：

1. **样本权重**：按目标波动率倒数加权（或用样本唯一性加权），避免高波动时期主导损失函数；这本质上是把「波动率聚类」从噪声变成权重结构。
2. **时序交叉验证**：绝不能用随机 K 折。应使用滚动或扩展窗口，并在训练集与验证集之间留出 embargo 间隔（至少等于标签的前瞻期），否则重叠标签会造成信息泄漏，验证分数虚高。

表 1.4 深度学习时间序列模型的能力与适用场景对比

模型	计算复杂度	长序列能力	可解释性	适用场景
RNN	$O(L)$	弱（梯度消失）	低	短序列基线
LSTM	$O(L)$	中	低（可用门值诊断）	波动率、订单流
GRU	$O(L)$	中	低	中小样本的默认选择
Transformer	$O(L^2)$	中	中（注意力权重）	跨资产、多模态
Informer	$O(L \log L)$	强	中	长序列负荷/价格
PatchTST	$O(L^2/P^2)$	强	低	多变量、含缺失
TFT	$O(L^2)$	中	高	需要归因的预测

3. **特征标准化**：只用训练窗口的均值与标准差做 z 分数变换，再应用到验证集；用全样本标准化是最常见也最隐蔽的泄漏。

4. **正则化组合**：Dropout（0.1–0.5）、权重衰减（10^{-4} 量级）、LayerNorm（对时间序列比 BatchNorm 更稳，因为批内样本的时间分布不一致）、以及早停（以验证集损失为准，耐心 5–10 个 epoch）。

5. **输出层设计**：预测收益率方向时用排序损失或分位数损失代替均方误差，因为 MSE 对大波动样本极度敏感；预测波动率时在 log 空间建模以保证正值。

6. **集成与不确定性**：用 5–10 个不同随机种子的模型取平均（Deep Ensemble），或用 MC Dropout 给出预测分布，再用其分布而非点估计做仓位与风控。

⚠ 风险警示　低信噪比下的过拟合：一个必须量化的边界

金融数据中「样本量 × 信噪比」远小于自然语言或图像任务。假设日频数据 2500 个样本（约 10 年），标签 $R^2 \approx 0.005$，则有效信号的信息量极小，而一个含 10^5 参数的 LSTM 在训练集上轻松达到 $R^2 = 0.3$——这几乎全部是记忆。三个具体的防线：（1）要求「样本量 / 参数量 ≥ 10」，否则先降容量；（2）用 Deflated Sharpe Ratio 或 White's Reality Check 校正对多个模型配置的挑拣偏差（选了几十个配置中的最优，样本外表现必然被高估）；（3）任何深度模型都必须与「t 期均值」和 AR(1) 两个基线比较，若无法稳定超越，则不应上线。此外，模型在结构突变期的失效尤其危险：它不会给出警告，只会以更高置信度输出错误预测。

1.9 预测评估与 VaR 回测

1.9.1 点预测指标

设真实值为 y_i、预测值为 $\hat{y}_i$，常用的三个损失函数为

$$\mathrm{MSE}=\frac{1}{n}\sum_{i=1}^{n}(y_i-\hat{y}_i)^2,\qquad \mathrm{MAE}=\frac{1}{n}\sum_{i=1}^{n}|y_i-\hat{y}_i| \tag{1.51}$$

$$\mathrm{MAPE}=\frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{y_i-\hat{y}_i}{y_i}\right| \tag{1.52}$$

其中 n 为样本量。MSE 对大误差更敏感（适合关注方差的场景），MAE 更稳健；MAPE 在 y_i 接近零时爆炸，因此在收益率预测中几乎不可用，对价格或成交量预测才合适。此外还常用 $\mathrm{RMSE}=\sqrt{\mathrm{MSE}}$ 与样本外 $R^2=1-\mathrm{MSE}/\operatorname{Var}(y)$。

仅有指标不够，还要检验预测的*无偏性*与*有效性*：

$$y_t=a+b\hat{y}_t+u_t \tag{1.53}$$

即 Mincer–Zarnowitz 回归。理想预测应满足 $(a,b)=(0,1)$，可用联合 F 检验（或 Wald 检验）。若 $\hat{b}$ 显著小于 1，说明预测值方差过大（过度反应），把预测向样本均值收缩（乘以 $\hat{b}$）可以改进；若 a 显著非零，说明存在系统性偏差。

1.9.2 Diebold–Mariano 检验

比较两个模型时不能只看平均损失的大小，还要看差异是否显著。令 $d_t=L(e_{1t})-L(e_{2t})$（L 为平方损失或绝对损失），DM 统计量为

$$\mathrm{DM}=\frac{\bar{d}}{\sqrt{\widehat{\mathrm{LRV}}(d)/T}}\xrightarrow{d}\mathcal{N}(0,1) \tag{1.54}$$

其中 $\bar{d}$ 为损失差的样本均值、$\widehat{\mathrm{LRV}}(d)$ 为 d_t 的长期方差（用 Newey–West 等 HAC 估计量得到，滞后阶数经验取 $T^{1/3}$ 或 $4(T/100)^{2/9}$）。原假设是两个模型的期望损失相等。注意小样本下 DM 统计量偏小，Harvey 等（1997）建议使用修正版本 $DM^{*}=\mathrm{DM}\sqrt{(T+1-2h+h(h-1)/T)/T}$，其中 h 为预测步长。

例 1.4 DM 检验的数值判读

设 $T=250$，平方损失差的均值 $\bar{d}=0.021$，经 Newey–West（滞后 5 阶）估计的长期方差为 0.0625（对应标准差 0.25）。则标准误 $\mathrm{SE}(\bar{d})=\sqrt{0.0625/250}\approx 0.0158$，$\mathrm{DM}=0.021/0.0158\approx 1.33$。由于 $1.33<1.96$，在 5% 水平上不能拒绝「两模型精度相同」。此时即便模型 A 的样本外 MSE 比 B 低 3%，也不足以支持「A 更好」的结论——差异很可能来自噪声。

1.9.3 VaR 回测

如果 1% 的在险价值（Value at Risk, VaR）模型是对的，那么大约每 100 天应有 1 天损失超过 VaR。回测就是检验这个比例与集中程度。设样本长度 T、显著性水平 p、实际

例外次数为 x。

Kupiec 无条件覆盖检验（POF）的似然比统计量为

$$LR_{UC} = -2\ln\left[\frac{(1-p)^{T-x}p^{x}}{(1-x/T)^{T-x}(x/T)^{x}}\right] \sim \chi^2_1 \tag{1.55}$$

分子是「模型正确」时的似然，分母是「真实例外率等于样本例外率」时的似然。

例 1.5 Kupiec 检验：$T=1000$，$p=1\%$，$x=15$

代入式 (1.55)：$\ln\left[(1-p)^{T-x}p^{x}\right] = 985\ln 0.99 + 15\ln 0.01 \approx -9.900 - 69.078 = -78.977$；$\ln\left[(1-\hat{p})^{T-x}\hat{p}^{x}\right] = 985\ln 0.985 + 15\ln 0.015 \approx -14.887 - 62.996 = -77.882$，其中 $\hat{p} = x/T = 0.015$。于是 $LR_{UC} = -2(-78.977 + 77.882) \approx 2.19$。$\chi^2_1$ 的 5% 临界值为 3.84，故不能拒绝「例外率等于 1%」。但另一方面，$x=15$ 是期望值 10 的 1.5 倍，样本例外率 1.5% 已经偏高；若 $x=20$，则 $LR_{UC} \approx 7.3 > 3.84$，模型将被拒绝。这说明无条件覆盖检验对中等幅度的偏离并不敏感，必须再用独立性检验补足。

Christoffersen 条件覆盖检验把例外是否成簇纳入检验。记 n_{ij} 为「t 日为状态 i、$t+1$ 日为状态 j」的转移次数（1 表示例外，0 表示未例外），$\pi_0 = n_{01}/(n_{00}+n_{01})$、$\pi_1 = n_{11}/(n_{10}+n_{11})$、$\pi = (n_{01}+n_{11})/T$：

$$LR_{ind} = -2\ln\left[\frac{(1-\pi)^{n_{00}+n_{10}}\pi^{n_{01}+n_{11}}}{(1-\pi_0)^{n_{00}}\pi_0^{n_{01}}(1-\pi_1)^{n_{10}}\pi_1^{n_{11}}}\right] \sim \chi^2_1 \tag{1.56}$$

条件覆盖统计量为 $LR_{CC} = LR_{UC} + LR_{ind} \sim \chi^2_2$。以上例的数据结构取 $n_{00}=971$、$n_{01}=14$、$n_{10}=14$、$n_{11}=1$，可算得 $LR_{ind} \approx 1.52 < 3.84$，即例外在时间上未表现出显著聚集；若换成一个在危机后才抬升波动率的迟钝模型，例外会连续出现，n_{11} 变大，LR_{ind} 将显著。

除上述两个检验外，**动态分位数检验**（dynamic quantile, DQ）把 $\mathrm{Hit}_t = \mathbf{1}_{\{y_t < -\mathrm{VaR}_t\}} - p$ 对常数、滞后 Hit 与滞后 VaR 做回归，联合检验所有系数为零，可同时检出覆盖偏差、聚集与 VaR 对信息的反应迟钝。

核心要点 1.2　评估纪律：样本外、HAC、多模型校正

预测评估必须同时满足三条要求。第一，样本外：所有指标只在从未参与拟合的区间上计算，滚动窗口重估是唯一能反映真实部署效果的方式。第二，HAC：DM 与 Mincer–Zarnowitz 的标准误必须修正自相关与异方差，否则 t 统计量被系统性高估。第三，多模型校正：若从 50 个配置中挑出最优，其样本外表现必然被高估，须用白氏 Reality Check、SPA 检验或 Deflated Sharpe Ratio 校正。

本章小结

- 弱平稳要求均值恒定、自协方差只依赖滞后；AR 的平稳性与 MA 的可逆性分别由 $\phi(z)$、$\theta(z)$ 的根全部落在单位圆外保证，二者互为对偶（小节 1.2.1）。
- Box–Jenkins 四步流程（识别 → 估计 → 诊断 → 预测）的核心是诊断闭环：残差必须既是白噪声、又不含 ARCH 效应（算法 1.1）。

- GARCH(1,1) 的长期方差为 $\omega/(1-\alpha-\beta)$，冲击半衰期为 $\ln 0.5/\ln(\alpha+\beta)$；$\alpha+\beta=0.98$ 对应约 34 个交易日（小节 1.4.2）。
- 高频数据可用已实现波动率直接度量积分方差，HAR 用日、周、月三层成分逼近长记忆，其预测 R^2 远高于收益率方向预测。
- 状态空间模型把时变参数写成状态，卡尔曼滤波的预测步与更新步可由条件正态回归推出，稳态增益由信号–噪声比决定（小节 1.6.2）。
- 协整刻画非平稳序列的长期均衡，误差修正项的系数给出回归速度与半衰期；多变量情形用 Johansen 的迹检验与最大特征值检验确定协整秩（小节 1.7.3）。
- 深度学习在金融数据的核心矛盾是低信噪比与高容量，必须依靠时序交叉验证、样本权重、正则化组合与多模型校正来控制过拟合。
- 评估不止看 MSE/MAE，还要做 Mincer–Zarnowitz 无偏性检验与 DM 检验；VaR 回测需同时通过无条件覆盖（Kupiec）与独立性（Christoffersen）检验（小节 1.9.3）。

练习与思考

1. 证明 式 (1.6) 中的 $\gamma_0=\sigma^2/(1-\phi^2)$ 与 $\rho_k=\phi^k$，并推导 式 (1.7)。当 $\phi=0.95$、$\phi=-0.85$ 时半衰期各为多少期？负号会带来怎样的路径形态？
2. 设 MA(1) 的 $\theta=2$。写出 ρ_1 并说明为什么统计软件不会报告 $\hat{\theta}=2$。若强行使用 $\theta=2$ 做预测，与使用等价的可逆表示相比会有什么差别？
3. 用 式 (1.23) 计算：$\omega=0.02$、$\alpha=0.10$、$\beta=0.85$、当前 $\sigma^2_{t+1}=3.0$ 时的 1、5、20 步方差预测，以及长期波动率与半衰期。若把模型误设为 $\alpha+\beta=0.999$，长期方差会变成多少？这说明什么？
4. 假设你有 5 分钟高频数据，用 $M=78$ 计算 RV，并分别用 $M=13$ 与 $M=468$ 计算。从微观结构噪声的角度解释三者的偏差方向，并说明为什么 5 分钟是常见的折中。
5. 用 式 (1.29) 与 式 (1.30) 推导稳态方程 $P^2+QP-QR=0$，并计算 $Q/R=4$ 时的稳态增益 K^*。若状态是随机游走，为什么 K^* 不随时间趋于零？
6. 给定 $n_{00}=950$、$n_{01}=8$、$n_{10}=8$、$n_{11}=4$、$T=1000$、$p=1\%$，分别计算 LR_{UC} 与 LR_{ind}，判断该 VaR 模型的缺陷类型（覆盖不足、聚集，或两者兼有）。
7. 设计一个实验说明随机 K 折交叉验证如何在金融时间序列上产生信息泄漏：给出标签前瞻期 $h=5$、训练集与验证集随机划分的情形下，泄漏的具体传递路径，并说明 embargo 长度应如何设定。
8. 讨论：若某模型在回测区间 2010–2019 年的 R^2 为 0.02，而在 2020 年 3 月为 -0.35，这两个数字分别反映了什么问题？你会如何调整上线决策流程？

延伸阅读

- Box, G., Jenkins, G., Reinsel, G., and Ljung, G., *Time Series Analysis: Forecasting and Control*, 5th ed., Wiley, 2015. （Box–Jenkins 流程的原始出处，识别–估计–诊断–预测的方法论源头，第 6–8 章最值得精读。）
- Hamilton, J., *Time Series Analysis*, Princeton University Press, 1994. （单位根、协整、状态空间与卡尔曼滤波的标准参考，第 17–19 章讲清 ECM 与 Johansen 检验的推导。）
- Engle, R., "Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation", *Econometrica*, 1982. （ARCH 的开创性论文，理解条件异方差建模动机的必读文献。）
- Bollerslev, T., "Generalized Autoregressive Conditional Heteroskedasticity", *Journal of Econometrics*, 1986. （GARCH 的提出，含长期方差与持续性条件的完整讨论。）
- Andersen, T., Bollerslev, T., Diebold, F., and Labys, P., "Modeling and Forecasting Realized Volatility", *Econometrica*, 2003. （已实现波动率与 HAR 家族的理论与实证基础，含高频采样频率的偏差–方差权衡。）
- Corsi, F., "A Simple Approximate Long-Memory Model of Realized Volatility", *Journal of Financial Econometrics*, 2009. （HAR 模型原文，三尺度成分的经济解释与参数稳定性证据。）
- Diebold, F., and Mariano, R., "Comparing Predictive Accuracy", *Journal of Business & Economic Statistics*, 1995. （DM 检验原文；配合 Harvey 等 1997 年的小样本修正一并阅读。）
- Christoffersen, P., "Evaluating Interval Forecasts", *International Economic Review*, 1998. （条件覆盖检验的原始文献，VaR 回测中独立性检验的标准引用。）
- Zhou, H., et al., "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting", *AAAI*, 2021；Nie, Y., et al., "A Time Series is Worth 64 Words: Long-term Forecasting with Transformers", *ICLR*, 2023. （长序列与 Patch 化建模的两篇代表作，适合理解 $O(L^2)$ 瓶颈的工程应对。）