第一章 组合优化

前面几章分别解决了「预测什么」和「风险多大」的问题：因子模型给出预期收益与风险结构的估计，随机过程给出衍生品的定价与对冲。本章处理投资流程的最后一环——**组合优化**（portfolio optimization）：把预测信号、风险模型与各类现实约束，翻译成一组可执行的持仓权重 $\boldsymbol{w}$。这一步之所以困难，不在于最优化算法，而在于输入参数几乎总是估计值：一个被低估的协方差逆矩阵会把 1% 的收益预测放大成 30% 的极端权重。本章既给出经典模型的完整推导，也给出让模型在样本外存活下来的工程手段。

1.1 记号、问题设定与目标

1.1.1 从信号到权重

量化流程通常分三层：第一层是**信号**（signal），即对未来收益的预测，例如因子的 IC 加权合成值；第二层是**风险模型**（risk model），即协方差矩阵 $\boldsymbol{\Sigma}$ 的估计；第三层才是**组合构建**（portfolio construction），把二者与约束一起转成权重。同一套信号配上不同的组合构建方法，样本外信息比率可以相差 0.3 以上，因此这一层绝非「把信号除以波动率」这么简单。

定义 1.1　均值-方差组合问题

设有 N 个风险资产，权重向量为 $\boldsymbol{w}\in\mathbb{R}^N$，预期收益向量为 $\boldsymbol{\mu}\in\mathbb{R}^N$，协方差矩阵为 $\boldsymbol{\Sigma}\in\mathbb{R}^{N\times N}$ 且正定。投资者在预算约束下最大化「期望收益减去风险惩罚」：

$$\max_{\boldsymbol{w}} \quad \boldsymbol{w}^{\top}\boldsymbol{\mu}-\frac{\lambda}{2}\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w} \qquad \text{s.t.} \quad \mathbf{1}^{\top}\boldsymbol{w}=1 \tag{1.1}$$

其中 $\lambda>0$ 为**风险厌恶系数**，数值越大表示单位方差的边际收益要求越高；$\mathbf{1}$ 为全 1 向量。若允许持有现金，预算约束改为 $\mathbf{1}^{\top}\boldsymbol{w}\le 1$；若允许做空，则去掉 $\boldsymbol{w}\ge\mathbf{0}$。

组合的期望收益与方差分别为 $\mu_p=\boldsymbol{w}^{\top}\boldsymbol{\mu}$ 与 $\sigma_p^2=\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w}$，因此 式 (1.1) 等价于「在给定方差下最大化收益」的原始马科维茨表述。把 式 (1.1) 写成拉格朗日函数并利用 $\boldsymbol{\Sigma}$ 的对称性求导：

$$\mathcal{L}(\boldsymbol{w},\gamma)=\boldsymbol{w}^{\top}\boldsymbol{\mu}-\frac{\lambda}{2}\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w}-\gamma\left(\mathbf{1}^{\top}\boldsymbol{w}-1\right) \tag{1.2}$$

$$\frac{\partial\mathcal{L}}{\partial\boldsymbol{w}}=\boldsymbol{\mu}-\lambda\boldsymbol{\Sigma}\boldsymbol{w}-\gamma\mathbf{1}=\mathbf{0} \quad\Longrightarrow\quad \boldsymbol{w}=\frac{1}{\lambda}\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-\gamma\mathbf{1}\right) \tag{1.3}$$

把上式代入约束 $\mathbf{1}^{\top}\boldsymbol{w}=1$，记 $A=\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\mathbf{1}$、$B=\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$，得到 $B-\gamma A=\lambda$，即 $\gamma=(B-\lambda)/A$。整理后得到与风险厌恶无关的分解：

$$\boldsymbol{w}^{*}=\underbrace{\frac{\boldsymbol{\Sigma}^{-1}\mathbf{1}}{\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\mathbf{1}}}_{\boldsymbol{w}_{\text{gmvp}}}+\frac{1}{\lambda}\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-\frac{B}{A}\mathbf{1}\right) \tag{1.4}$$

第一项是**全局最小方差组合**（global minimum variance portfolio，GMVP），只依赖 $\boldsymbol{\Sigma}$，与预期收益完全无关；第二项是「基于预期收益的投机性倾斜」，其幅度与 $1/\lambda$ 成正比。当 $\lambda\to\infty$ 时权重收敛到 GMVP，当 $\lambda\to 0$ 时权重发散（需要无限杠杆），这就是式 (1.4) 的失效边界。

1.1.2 有效前沿的解析式

记 $C=\boldsymbol{\mu}^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$、$D=AC-B^{2}>0$（$\boldsymbol{\Sigma}$ 正定且 $\boldsymbol{\mu}$ 不与 $\mathbf{1}$ 共线时成立）。对任意目标收益 μ_p，最小方差组合为 $\boldsymbol{w}(\mu_p)=\boldsymbol{w}_g+\mu_p\boldsymbol{w}_h$，其中

$$\boldsymbol{w}_g=\frac{1}{D}\left(C\,\boldsymbol{\Sigma}^{-1}\mathbf{1}-B\,\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}\right),\qquad \boldsymbol{w}_h=\frac{1}{D}\left(A\,\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}-B\,\boldsymbol{\Sigma}^{-1}\mathbf{1}\right) \tag{1.5}$$

对应的方差为 $\sigma_p^{2}(\mu_p)=\left(A\mu_p^{2}-2B\mu_p+C\right)/D$，解出 μ_p 即得**有效前沿**（efficient frontier）的双曲线形式：

$$\mu_p=\frac{B}{A}\pm\sqrt{\frac{D}{A}}\sqrt{\sigma_p^{2}-\frac{1}{A}},\qquad \sigma_p^{2}\geq\frac{1}{A} \tag{1.6}$$

其中 $\pm$ 的上支（取正号）为有效前沿，下支为「无效边界」——同样方差下收益更低的组合。由式 (1.6) 可直接读出三个几何事实：顶点在 $(\sigma_p,\mu_p)=(1/\sqrt{A},\,B/A)$，即 GMVP；双曲线的渐近线斜率为 $\sqrt{D/A}$，代表高收益端每增加一单位风险的收益补偿；σ_p 关于 μ_p 是凸函数，这正是「分散化免费午餐」的数学表达。

直觉理解　为什么前沿是双曲线

协方差矩阵的二次型在权重空间中是一个椭球。预算约束 $\mathbf{1}^{\top}\boldsymbol{w}=1$ 是一个超平面，它与椭球相切的位置就是最小方差组合；随着目标收益平移这个超平面，切点扫出的轨迹在 (σ_p,μ_p) 平面上必然是双曲线的一支。直觉上，椭圆—双曲线的对偶关系说明：约束是线性的，而目标含二次项，因此前沿永远不会是直线（除非只有一个资产）。

1.1.3 无风险资产、切点组合与两基金分离

引入无风险资产（收益 r_f）后，投资者的可行集变成从点 $(0,r_f)$ 出发、与双曲线相切的直线，称为**资本市场线**（capital allocation line）。切点对应的风险组合称为**切点组合**（tangency portfolio），它最大化夏普比率：

$$\boldsymbol{w}_{\tan}=\frac{\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-r_f\mathbf{1}\right)}{\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-r_f\mathbf{1}\right)},\qquad \max_{\boldsymbol{w}}\ \frac{\mu_p-r_f}{\sigma_p}=\sqrt{\left(\boldsymbol{\mu}-r_f\mathbf{1}\right)^{\top}\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-r_f\mathbf{1}\right)} \tag{1.7}$$

其中 $\boldsymbol{\mu} - r_f\mathbf{1}$ 为超额收益向量，分母为超额收益的归一化因子。式 (1.7) 右侧的平方根常记为 $\mathrm{SR}_{\max}$，它同时是 式 (1.6) 中双曲线渐近线在「每单位风险收益」意义上的最优值。

定理 1.1 (两基金分离定理) 设 $\boldsymbol{\Sigma}$ 正定、$\boldsymbol{\mu}$ 与 $\mathbf{1}$ 不共线。

1. 任意两个不同的前沿组合 $\boldsymbol{w}_a$、$\boldsymbol{w}_b$ 可以生成整条前沿：$\boldsymbol{w}(\theta) = (1-\theta)\boldsymbol{w}_a + \theta\boldsymbol{w}_b$，$\theta \in \mathbb{R}$。
2. 存在无风险资产时，任何有效组合均可写成现金与切点组合的线性组合 $\boldsymbol{w}(\theta) = (1-\theta)\boldsymbol{w}_{\tan}$，$\theta$ 由风险偏好 λ 决定，且 $\theta = \mathrm{SR}_{\max}/(\lambda\sigma_{\tan})$。

证明. 第一部分的思路：由 式 (1.5) 知任意前沿组合是 $\boldsymbol{w}_g$ 与 $\boldsymbol{w}_h$ 的仿射组合，而 $\boldsymbol{w}_g, \boldsymbol{w}_h$ 张成二维仿射空间；两个不同前沿组合的差与 $\boldsymbol{w}_g, \boldsymbol{w}_h$ 的差平行，因此可以互相线性表出。第二部分的思路：切点组合与现金的组合在 (σ_p, μ_p) 平面上扫过资本市场线，而对给定 λ 的最优解必然落在资本市场线上（否则沿该直线移动可在同方差下提高收益），故其风险部分只能正比于 $\boldsymbol{w}_{\tan}$。 ■

核心要点 1.1 核心要点：有效前沿与切点组合

有效前沿由 $(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 完全决定，其解析式为 $\sigma_p^2(\mu_p) = (A\mu_p^2 - 2B\mu_p + C)/D$；引入无风险资产后，所有理性投资者持有同一个风险组合 $\boldsymbol{w}_{\tan} \propto \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu} - r_f\mathbf{1})$，差异只体现在现金比例上。这一结论对 $\boldsymbol{\mu}$ 的估计误差极其敏感：$\boldsymbol{\mu}$ 的一个标准差噪声会在 $\boldsymbol{\Sigma}^{-1}$ 的作用下被放大为成倍的权重误差（见 小节 1.2.2）。

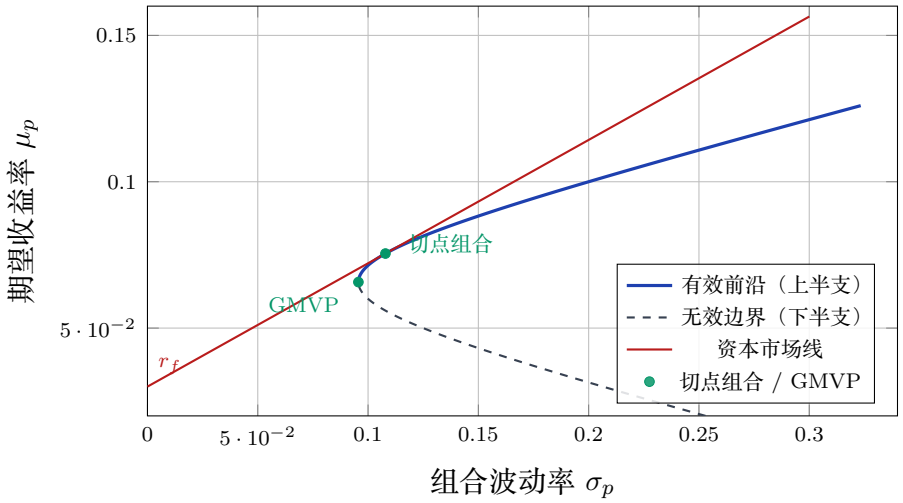


图 1.1 有效前沿、资本市场线与切点组合（两资产算例：$\sigma = (0.20, 0.10)$，$\rho = 0.2$，$\mu = (0.10, 0.06)$，$r_f = 0.03$）。切点组合位于 $(0.1079, 0.0755)$，其夏普比率为 0.4214，即资本市场线的斜率

图 1.1 用两资产算例画出全部几何要素。注意无效边界（虚线）在图形上是实曲线的一部分，但它永远不该被持有：相同波动率下，上半支的收益严格更高。实务中「最小方差组合」这一品牌产品的持仓恰好是图中的 GMVP 点，即 $(\sigma_p, \mu_p) = (9.56\%, 6.57\%)$，完全不需要任何收益预测。

1.2 估计误差与错误放大

1.2.1 样本估计的噪声

设真实收益服从 $r_t \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，用 T 期样本估计：

$$\hat{\boldsymbol{\mu}} = \frac{1}{T}\sum_{t=1}^{T} r_t, \qquad \hat{\boldsymbol{\Sigma}} = \frac{1}{T-1}\sum_{t=1}^{T}(r_t-\hat{\boldsymbol{\mu}})(r_t-\hat{\boldsymbol{\mu}})^{\top} \tag{1.8}$$

其中 r_t 为第 t 期的 N 维收益向量。$\hat{\boldsymbol{\mu}}$ 的标准误为 $\sigma_i/\sqrt{T}$：以年化波动率 20% 的股票为例，用 5 年（60 个月）月度数据估计年化期望收益，其标准误约为 $20\%/\sqrt{5} \approx 8.9\%$，与股票本身的长期超额收益同量级。换言之，**预期收益的估计信噪比通常小于 1**，而波动率与协方差的估计信噪比要高一个量级（协方差的标准误大致按 $\sqrt{2/T}$ 衰减）。

1.2.2 错误放大机制

考虑无约束版本 $\boldsymbol{w}^{*} = \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}/\lambda$。用 $\hat{\boldsymbol{\mu}} = \boldsymbol{\mu} + \varepsilon$ 代入，权重误差为 $\Delta\boldsymbol{w} = \boldsymbol{\Sigma}^{-1}\varepsilon/\lambda$，其协方差为 $\boldsymbol{\Sigma}^{-1}\mathrm{Var}(\varepsilon)\boldsymbol{\Sigma}^{-1}/\lambda^2$。在 $\varepsilon \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}/T)$ 下，$\mathrm{Var}(\Delta\boldsymbol{w}) = \boldsymbol{\Sigma}^{-1}/(\lambda^2 T)$，故组合层面的方差误差为

$$\mathbb{E}\left[\Delta\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\,\Delta\boldsymbol{w}\right] = \frac{1}{\lambda^2 T}\,\mathrm{tr}\left(\boldsymbol{\Sigma}^{-1}\boldsymbol{\Sigma}\right) = \frac{N}{\lambda^2 T} \tag{1.9}$$

其中 N 为资产数，T 为样本期数，λ 为风险厌恶系数。式 (1.9) 表明：**资产池扩大一倍，权重误差的能量也扩大一倍，与资产之间的相关性无关**。这就是「错误放大」（error maximization）的最简洁表达。

更有意义的是它对效用的影响。在无约束问题中，真最优组合的确定性等价为

$$\mathrm{CE}^{*} = \frac{\boldsymbol{\mu}^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}}{2\lambda},$$

而使用估计值 $\hat{\boldsymbol{\mu}}$ 所得组合的真实确定性等价为

$$\mathbb{E}\left[\mathrm{CE}(\hat{\boldsymbol{w}})\right] = \mathrm{CE}^{*} - \frac{N}{2\lambda T} \tag{1.10}$$

即期望效用损失恰为 $N/(2\lambda T)$。这个式子是本章最实用的数量级直觉：$N = 500$、$T = 60$（月）、$\lambda = 5$ 时，年化意义上的效用损失相当于白白损失约 $500/(2\times 5\times 60) = 0.83$，即接近 83% 的风险惩罚单位；把 T 提高到 240（20 年月度数据）则降到 0.21。降低 N（用因子或聚类压缩资产空间）、提高 T（更长的历史或用高频数据）、提高 λ（更保守）是三条并行有效的路径。

例 1.1　错误放大的数值演示

设两个资产：真实 $\boldsymbol{\mu} = (0.06, 0.06)$、$\sigma = (0.20, 0.20)$、$\rho = 0.9$，$\lambda = 4$，$T = 60$。此

时 $\boldsymbol{\Sigma}^{-1}$ 的条件数为

$$\kappa(\boldsymbol{\Sigma}) = \frac{1+\rho}{1-\rho} = \frac{1.9}{0.1} = 19$$

由于真实均值相同，$\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$ 恰为等权方向，理论上不应有任何「倾斜」。若估计误差使 $\hat{\boldsymbol{\mu}} = (0.06 + 0.02,\ 0.06)$，则 $\Delta\boldsymbol{\mu} = (0.02, 0)$，倾斜权重为

$$\Delta \boldsymbol{w} = \frac{1}{\lambda}\boldsymbol{\Sigma}^{-1}\Delta\boldsymbol{\mu} = \frac{1}{4}\cdot\frac{1}{0.04^2(1-0.9^2)}\begin{pmatrix} 0.04 & -0.036 \\ -0.036 & 0.04 \end{pmatrix}\begin{pmatrix} 0.02 \\ 0 \end{pmatrix} \approx \begin{pmatrix} 0.263 \\ -0.237 \end{pmatrix}$$

一个 2% 的均值估计误差（约为真实收益的 1/3）就制造了 26% 的超配与 24% 的低配。若 ρ 升到 0.99，同样误差会放大到 ±65% ——**相关性越高，$\boldsymbol{\Sigma}^{-1}$ 的条件数越大，同样的预测误差造成的持仓越极端。**

风险警示　均值-方差优化的失效条件

- **$\boldsymbol{\mu}$ 不可靠**：当 N 与 T 同阶或 $N > T$ 时，样本均值几乎全是噪声，优化器会系统性做多「被高估」的资产、做空「被低估」的资产，样本外表现常劣于等权。
- **$\boldsymbol{\Sigma}$ 奇异或病态**：$N > T$ 时 $\hat{\boldsymbol{\Sigma}}$ 秩亏，$\boldsymbol{\Sigma}^{-1}$ 不存在；即使 $N < T$，样本特征值的离散度也被 Marchenko–Pastur 律高估——当 $N/T = q$ 时，纯噪声矩阵的特征值张成区间 $[\sigma^2(1-\sqrt{q})^2, \sigma^2(1+\sqrt{q})^2]$，$q = 0.2$ 时上下界之比已达 6.9 倍，而真实的条件数可能是 1。
- **正态假设**：前沿公式依赖二次型，厚尾与跳跃会使真实极端损失远超 σ_p 所隐含的水平。
- **单期假设**：式 (1.1) 是一次性决策，忽略再平衡成本、路径依赖与流动性约束。

补充说明　样本夏普比率的偏误

在真实夏普比率为 0 的零假设下，N 个独立策略、T 期样本内最大夏普比率的期望约为 $\sqrt{2\ln N/T}$。取 $N = 100$、$T = 120$，该值约为 0.28。这意味着「回测夏普 0.28」完全可能来自纯噪声，评估因子时必须扣除这一多重检验偏差（详见第 7 章回测方法论）。

1.3 收缩估计与结构化协方差

1.3.1 Ledoit–Wolf 收缩

既然样本协方差在 N/T 不可忽略时系统性失真，最直接的补救是把它向一个结构简单、稳定但可能有偏的目标矩阵 F 收缩：

$$\hat{\boldsymbol{\Sigma}}_{\mathrm{LW}} = \delta F + (1-\delta)\hat{\boldsymbol{\Sigma}}, \qquad \delta \in [0,1] \tag{1.11}$$

其中 F 为**目标矩阵**（target），δ 为**收缩强度**（shrinkage intensity）。$\delta = 0$ 退化为样本

估计，$\delta = 1$ 完全采用先验结构。常用目标为常数相关矩阵 $F_{ii} = \hat{\sigma}_i^2$、$F_{ij} = \hat{\rho}\,\hat{\sigma}_i\hat{\sigma}_j$（$\hat{\rho}$ 为样本相关系数均值），或单因子目标 $F = \hat{\sigma}^2\left[\beta\beta^\top\right]$ + 对角项。

Ledoit–Wolf（2004）给出的最优收缩强度为最小化 $\mathbb{E}\left\|\delta F + (1-\delta)\hat{\boldsymbol{\Sigma}} - \boldsymbol{\Sigma}\right\|_F^2$ 的解：

$$\delta^* = \frac{\pi - \rho}{\gamma}, \qquad \pi = \sum_{i,j}\operatorname{Var}\left(\hat{\Sigma}_{ij}\right), \quad \rho = \sum_{i,j}\operatorname{Cov}\left(\hat{\Sigma}_{ij}, F_{ij}\right), \quad \gamma = \sum_{i,j}\left(F_{ij} - \hat{\Sigma}_{ij}\right)^2 \tag{1.12}$$

其中 π 度量样本协方差本身的噪声总量，ρ 度量噪声与目标之间的协方差，γ 是目标与样本之间的「结构距离」。直觉上，当样本噪声 π 相对结构距离 γ 很大时，δ^* 趋近 1，即完全信任结构。π 与 ρ 可用样本四阶矩一致估计，故 式 (1.12) 是数据驱动的，不含主观参数。

实务应用　实务中的用法

主流风险模型（如 Barra/Axioma 一类）并不直接收缩整个矩阵，而是「结构化 + 收缩」并用：先用因子结构把协方差分解为低秩因子部分与对角特质部分，再对特质方差按行业与市值分组收缩（贝叶斯收缩到组内中位数），最后对相关系数矩阵做特征值修正（将小于阈值的特征值拉平）。这样做的效果与等价的 Ledoit–Wolf 收缩相近，但保留了因子暴露的可解释性，便于施加因子约束。

1.3.2 因子协方差

若收益由 K 个因子解释（$K \ll N$），则 $r = Bf + u$，其中 B 为 $N \times K$ 因子载荷矩阵，f 为因子收益，u 为特质收益（$\operatorname{Cov}(f,u) = 0$，$\operatorname{Var}(u) = D$ 对角）。协方差为

$$\boldsymbol{\Sigma} = B\,\boldsymbol{\Sigma}_f\,B^\top + D \tag{1.13}$$

参数个数由 $O(N^2)$ 降到 $O(NK + N)$。取逆可由 Woodbury 公式高效完成：

$$\boldsymbol{\Sigma}^{-1} = D^{-1} - D^{-1}B\left(\boldsymbol{\Sigma}_f^{-1} + B^\top D^{-1}B\right)^{-1}B^\top D^{-1} \tag{1.14}$$

括号内是 $K \times K$ 小矩阵，因此 $N = 3000$、$K = 60$ 时求逆代价从 $O(N^3)$ 降到 $O(NK^2)$ 量级。因子模型的另一个好处是把组合风险分解为因子风险 $B^\top\boldsymbol{w}$ 与特质风险，使「风格暴露约束」可以直接写成对 $B^\top\boldsymbol{w}$ 的线性约束。

1.3.3 EWMA 与 DCC

等权历史协方差对所有观测一视同仁，但波动率具有聚集性与长记忆性。指数加权移动平均（EWMA）用衰减因子 λ 给近期观测更高权重：

$$\boldsymbol{\Sigma}_t = (1-\lambda)\,r_{t-1}r_{t-1}^\top + \lambda\,\boldsymbol{\Sigma}_{t-1}, \qquad \boldsymbol{\Sigma}_t = (1-\lambda)\sum_{k=1}^{\infty}\lambda^{k-1}r_{t-k}r_{t-k}^\top \tag{1.15}$$

其中 $\lambda \in (0,1)$ 为衰减因子。RiskMetrics 取 $\lambda = 0.94$（日频）、0.97（月频），对应波动的半衰期 $\ln 0.5 / \ln \lambda$ 分别为约 11 天与 23 个月。EWMA 的局限是把相关系数也一并平滑，且不保证正定（在高维下需强制修正）。

动态条件相关（DCC，Engle 2002）采用两步法：先对每个资产用 GARCH 拟合条件方差，得到标准化残差 z_t；再对 z_t 的「伪相关矩阵」施加同一标量 EWMA/GARCH 动态：

$$Q_t = (1-a-b)\bar{Q} + a\, z_{t-1} z_{t-1}^{\top} + b\, Q_{t-1}, \qquad R_t = \operatorname{diag}(Q_t)^{-1/2}\, Q_t\, \operatorname{diag}(Q_t)^{-1/2} \tag{1.16}$$

其中 $\bar{Q}$ 为 z_t 的无条件相关矩阵，$a, b \geq 0$ 且 $a + b < 1$ 保证平稳性。R_t 的对角线被强制为 1，条件协方差为 $\boldsymbol{\Sigma}_t = D_t R_t D_t$（$D_t = \operatorname{diag}(\sigma_{i,t})$）。DCC 的核心直觉是「波动率与相关性同向变动」：危机期间 a 主导，相关性整体抬升，组合分散化效果同时衰减——2008 年与 2020 年 3 月的数据都反复验证了这一点。

表 1.1　协方差矩阵估计方法对比

方法	参数个数	优点	失效条件
样本协方差	$O(N^2)$	无偏、计算简单	N/T 大时病态、噪声大、不可逆
常数相关收缩	$O(1)$ 收缩 $+O(N^2)$	大幅降低条件数、几乎无主观参数	真实相关结构异质（如危机相关性）时目标失真
单因子收缩	$O(N)$	与 CAPM 一致、易解释	多因子结构下特质部分被过度收缩
因子协方差	$O(NK)$	参数少、可施加因子约束、可解释	因子遗漏或载荷不稳定导致风险低估
EWMA	$O(1)$	捕捉时变波动、响应快	无均值回复、高维下不保证正定
DCC	$O(N)+2$	波动与相关联合建模	两步估计的效率损失、N 大时估计不稳

1.4 鲁棒组合优化

既然 $\boldsymbol{\mu}$ 与 $\boldsymbol{\Sigma}$ 都有误差，把不确定性显式写入模型比「先估计再优化」更诚实。鲁棒优化求解最坏情形下的最优：

$$\max_{\boldsymbol{w}} \min_{\boldsymbol{\mu} \in \mathcal{U}_{\mu}} \left[\boldsymbol{w}^{\top}\boldsymbol{\mu} - \frac{\lambda}{2} \boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w} \right], \qquad \text{s.t. } \mathbf{1}^{\top}\boldsymbol{w} = 1,\ \boldsymbol{w} \in \mathcal{W} \tag{1.17}$$

其中 $\mathcal{U}_{\mu}$ 是均值的不确定性集，$\mathcal{W}$ 为权重约束集。两类常用集合及其等价形式：

- **盒式不确定性**：$\mathcal{U}_\mu = \{\boldsymbol{\mu} : |\mu_i - \hat{\mu}_i| \le \varepsilon_i\}$。此时内层最小化逐分量取 $\hat{\mu}_i - \varepsilon_i \operatorname{sgn}(w_i)$，问题退化为「用收缩后的均值 $\hat{\mu}_i - \varepsilon_i$ 做普通 MVO」。这提供了一个极其实用的解释：**把每个资产的预期收益统一减去 ε，等价于对该资产做鲁棒处理**。
- **椭球不确定性**：$\mathcal{U}_\mu = \{\boldsymbol{\mu} : (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}})^\top \Omega^{-1} (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}}) \le \kappa^2\}$，其中 Ω 为估计误差的协方差、κ 为置信半径。此时内层最小值为 $\boldsymbol{w}^\top \hat{\boldsymbol{\mu}} - \kappa \left\| \Omega^{1/2} \boldsymbol{w} \right\|$，问题化为

$$\max_{\boldsymbol{w},\, t} \quad \boldsymbol{w}^\top \hat{\boldsymbol{\mu}} - \frac{\lambda}{2} \boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w} - \kappa\, t \qquad \text{s.t.} \quad \left\| \Omega^{1/2} \boldsymbol{w} \right\| \le t, \quad \mathbf{1}^\top \boldsymbol{w} = 1, \quad \boldsymbol{w} \in \mathcal{W} \tag{1.18}$$

式 (1.18) 是标准的**二阶锥规划**（second-order cone program，SOCP），可用内点法在多项式时间内求解。它与 式 (1.1) 的唯一区别是增加了范数项 $-\kappa t$：不确定性集越大（κ 越大），优化器越倾向于把风险预算分散到多个资产上，因为集中持仓在椭球的最坏方向上风险最高。

直觉理解　鲁棒性就是惩罚集中度

把 式 (1.18) 的 $-\kappa \left\| \Omega^{1/2} \boldsymbol{w} \right\|$ 看作一项「集中度惩罚」：$\kappa = 0$ 时退化为经典 MVO，$\kappa \to \infty$ 时最优解趋向最小方差或等风险贡献等「不依赖均值」的组合。因此 κ 实际上是一个可校准的旋钮，把「相信预测」连续地调成「不信任预测」。实务中常按「κ 等于多少倍的标准误」来设定，并用滚动窗口选择样本外信息比率最高的 κ。

1.5 Black–Litterman 模型

Black–Litterman（BL）用贝叶斯方法解决 $\boldsymbol{\mu}$ 不可靠的问题：以市场均衡隐含收益为先验，以主观观点为似然，输出后验均值。

第一步：反向优化得到先验。若市场组合 $\boldsymbol{w}_{\text{mkt}}$ 是均值-方差最优的，则由 式 (1.2) 解出隐含收益

$$\Pi = \delta\, \boldsymbol{\Sigma}\, \boldsymbol{w}_{\text{mkt}} \tag{1.19}$$

其中 δ 为市场风险厌恶系数（由市场夏普比率反推，$\delta = (\mu_{\text{mkt}} - r_f)/\sigma^2_{\text{mkt}}$，历史估计通常在 2–4 之间）。这一步的意义是：**市场价格本身已经包含了所有公开信息**，因此 Π 是「没有人有私有观点时」最合理的均值假设，且与市场组合自洽。

第二步：观点与不确定性。用 K 个观点表示 $P\boldsymbol{\mu} = Q + \varepsilon$，$\varepsilon \sim \mathcal{N}(\mathbf{0}, \Omega)$，其中 P 为 $K \times N$ 观点矩阵（每行是一个组合）、Q 为观点收益、Ω 为观点不确定性（对角时表示观点相互独立）。先验取 $\boldsymbol{\mu} \sim \mathcal{N}(\Pi, \tau\boldsymbol{\Sigma})$，$\tau$ 通常取 0.01–0.05，反映「先验比样本更可信」的先验强度。

第三步：后验。正态共轭给出

$$\boldsymbol{\mu}_{\text{BL}} = \Pi + \tau\boldsymbol{\Sigma} P^\top \left(P\, \tau\boldsymbol{\Sigma}\, P^\top + \Omega \right)^{-1} (Q - P\Pi) \tag{1.20}$$

其中 $(Q - P\Pi)$ 是观点与均衡的偏离，括号项是「偏离的置信度权重」。若采用 He–Litterman 设定 $\Omega = \tau P\boldsymbol{\Sigma}P^\top$，则后验对任一观点的预测值为 $P\boldsymbol{\mu}_{\mathrm{BL}} = \frac{1}{2}(P\Pi + Q)$，即后验恰好是先验与观点的等权平均——这是一个易于记忆且便于检查编码正确性的性质。

例 1.2　两资产 BL 后验计算

设 $\boldsymbol{w}_{\mathrm{mkt}} = (0.6, 0.4)$，$\boldsymbol{\Sigma} = \left(\begin{smallmatrix} 0.04 & 0.004 \\ 0.004 & 0.01 \end{smallmatrix}\right)$，$\delta = 2.5$，$\tau = 0.05$。先验：$\Pi = 2.5\,\boldsymbol{\Sigma}\boldsymbol{w}_{\mathrm{mkt}} = (0.064,\ 0.016)$，即市场隐含的收益差为 4.8%。观点：资产 1 未来一年的收益将比资产 2 高 3%，故 $P = (1, -1)$、$Q = 0.03$，取 $\Omega = \tau P\boldsymbol{\Sigma}P^\top = 0.0021$。由式 (1.20)：$Q - P\Pi = 0.03 - 0.048 = -0.018$，$\tau\boldsymbol{\Sigma}P^\top = (0.0018,\ -0.0003)^\top$，于是

$$\boldsymbol{\mu}_{\mathrm{BL}} = (0.064,\ 0.016) + \frac{(0.0018,\ -0.0003)^\top}{2 \times 0.0021} \times (-0.018) = (0.0563,\ 0.0173)$$

后验收益差为 3.9%，正是 4.8% 与 3.0% 的等权平均，与理论一致。观点的信息量体现在「把市场隐含的 4.8% 拉低到 3.9%」，从而降低资产 1 的配置诱惑；观点与市场偏离越大、Ω 越小，后验移动越多。

⚠ 风险警示　BL 的失效条件

BL 的稳健性来自先验，但它并非无懈可击：(1) τ 的选择没有客观标准，τ 越大观点权重越高，实务中不同机构取值从 $1/T$ 到 0.05 不等，结果差异可观；(2) Ω 若取对角但观点实际高度相关（例如「看多科技」与「看多成长」），会被重复计入，导致后验过度自信；(3) 式 (1.19) 假设市场组合是均值-方差有效的，在存在非交易资产、杠杆约束与噪声交易者的市场中并不成立；(4) BL 只修正均值，完全不处理 $\boldsymbol{\Sigma}$ 的估计误差，因此仍需与收缩估计配合使用。

1.6 风险平价与等风险贡献

1.6.1　风险贡献的定义与分解

定义 1.2　风险贡献与风险预算

组合波动率 $\sigma_p(\boldsymbol{w}) = \sqrt{\boldsymbol{w}^\top\boldsymbol{\Sigma}\boldsymbol{w}}$ 对权重的偏导为边际风险 $\partial\sigma_p/\partial w_i = (\boldsymbol{\Sigma}\boldsymbol{w})_i/\sigma_p$。定义资产 i 的**风险贡献**（risk contribution）为

$$\mathrm{RC}_i = w_i\frac{\partial\sigma_p}{\partial w_i} = \frac{w_i\,(\boldsymbol{\Sigma}\boldsymbol{w})_i}{\sigma_p}, \qquad \sum_{i=1}^{N}\mathrm{RC}_i = \frac{\boldsymbol{w}^\top\boldsymbol{\Sigma}\boldsymbol{w}}{\sigma_p} = \sigma_p \tag{1.21}$$

给定风险预算向量 $\mathbf{b} = (b_1, \ldots, b_N)$（$b_i > 0$，$\sum b_i = 1$），**风险预算组合**满足 $\mathrm{RC}_i = b_i\sigma_p$。当 $b_i = 1/N$ 时称为**等风险贡献**（equal risk contribution，ERC）组合。

式 (1.21) 的第二个等式（欧拉定理）说明风险贡献之和恰为组合波动率，因此 RC_i/σ_p 是一个合法的「风险份额」。注意风险贡献可以为负：做空一个与组合正相关的资产会降低风险，其 $\mathrm{RC}_i < 0$。

1.6.2 ERC 的拉格朗日推导

直接对 σ_p 施加等风险贡献约束是非凸的，但可以化为一个凸问题。考虑

$$\min_{\boldsymbol{w}>\mathbf{0}} \quad \frac{1}{2}\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w} - \sum_{i=1}^{N} b_i \ln w_i \tag{1.22}$$

命题 1.1 (风险预算解的 KKT 条件) 设 $\boldsymbol{\Sigma}$ 正定、$b_i > 0$。问题 式 (1.22) 有唯一解 $\boldsymbol{w}^* > \mathbf{0}$，且其归一化权重 $\tilde{\boldsymbol{w}} = \boldsymbol{w}^*/\mathbf{1}^{\top}\boldsymbol{w}^*$ 满足风险预算条件

$$\tilde{w}_i\,(\boldsymbol{\Sigma}\tilde{\boldsymbol{w}})_i = b_i\,\tilde{\sigma}_p^2, \qquad \text{即} \quad \mathrm{RC}_i = b_i\,\tilde{\sigma}_p \tag{1.23}$$

其中 $\tilde{\sigma}_p^2 = \tilde{\boldsymbol{w}}^{\top}\boldsymbol{\Sigma}\tilde{\boldsymbol{w}}$。特别地，$b_i = 1/N$ 时得到 ERC 组合。

证明. 目标函数在 $\boldsymbol{w} > \mathbf{0}$ 上严格凸（二次项正定，$-\ln$ 项凸），故驻点即全局最优。对 w_i 求偏导并令其为零：

$$(\boldsymbol{\Sigma}\boldsymbol{w}^*)_i - \frac{b_i}{w_i^*} = 0 \quad \Longrightarrow \quad w_i^*\,(\boldsymbol{\Sigma}\boldsymbol{w}^*)_i = b_i$$

两边对 i 求和，左边为 $\boldsymbol{w}^{*\top}\boldsymbol{\Sigma}\boldsymbol{w}^* = s^2$（记 $s = \mathbf{1}^{\top}\boldsymbol{w}^*$），右边为 1，故 $s^2 = 1$，即原始解已自动满足「风险归一化」（若改用 $\sum w_i = 1$ 的显式约束则需另行缩放，二者等价）。令 $\tilde{\boldsymbol{w}} = \boldsymbol{w}^*/s$，则 $\tilde{\sigma}_p^2 = s^2/s^2 \cdot \ldots$ 直接代入得 $\tilde{w}_i(\boldsymbol{\Sigma}\tilde{\boldsymbol{w}})_i = w_i^*(\boldsymbol{\Sigma}\boldsymbol{w}^*)_i/s^2 = b_i$，两边乘以 $\tilde{\sigma}_p^{-1}$ 并用 $\tilde{\sigma}_p = s$ 即得 $\mathrm{RC}_i = b_i\tilde{\sigma}_p$。 ■

例 1.3 四资产类别的 ERC 与 MVO 对比

取四个资产类别：股票（$\sigma = 18\%$，$\mu = 9\%$）、债券（6%，3%）、黄金（15%，5%）、商品（20%，6%），相关系数矩阵取

$$\begin{pmatrix} 1 & 0.10 & 0.05 & 0.20 \\ 0.10 & 1 & 0.05 & -0.10 \\ 0.05 & 0.05 & 1 & 0.25 \\ 0.20 & -0.10 & 0.25 & 1 \end{pmatrix}$$

求解 式 (1.22)（等风险预算）得 $\tilde{\boldsymbol{w}}_{\mathrm{ERC}} = (15.3\%, 52.4\%, 18.4\%, 13.9\%)$，四个资产的风险贡献均为 1.61%，之和等于组合波动率 6.43%。取 $\lambda = 3$ 求解式 (1.1) 得 $\boldsymbol{w}_{\mathrm{MVO}} = (60.3\%, 2.9\%, 25.5\%, 11.3\%)$，其波动率为 12.5%；GMVP 为 $(4.3\%, 80.0\%, 8.5\%, 7.2\%)$，波动率 5.36%。四组权重详见 表 1.2。

图 1.2 直观展示了三种方法的风险哲学差异：MVO 回答「哪里的收益风险比最高」，ERC 回答「如何让每一份风险预算各司其职」，GMVP 回答「如何在完全不预测收益的前提下最小化波动」。ERC 的权重与 $\boldsymbol{\mu}$ 无关，这是它在下行市场更稳健的根本原因，也是它在 $\boldsymbol{\mu}$ 不可靠时优于 MVO 的根本原因。

表 1.2　四种组合构建方法的权重与风险（小节 1.6.2 的算例）

方法	股票	债券	黄金	商品	组合波动率	组合收益
等权	25.0%	25.0%	25.0%	25.0%	9.83%	5.75%
GMVP	4.3%	80.0%	8.5%	7.2%	5.36%	3.64%
ERC	15.3%	52.4%	18.4%	13.9%	6.43%	4.51%
MVO（$\lambda = 3$）	60.3%	2.9%	25.5%	11.3%	12.50%	7.47%

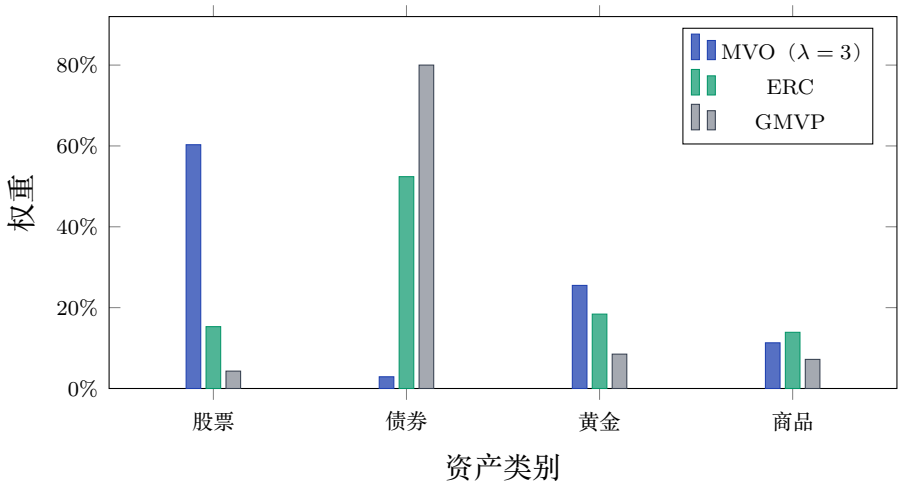


图 1.2　同一协方差矩阵下 MVO、ERC 与 GMVP 的权重对比。MVO 把 60% 押在夏普比率最高的股票上，ERC 把一半权重给债券以平衡风险贡献，GMVP 则几乎完全由债券构成

实务应用 风险平价的实践变体

教科书 ERC 假设资产可以自由加杠杆，但真实世界的最低风险资产（短期国债）波动率只有 1%–2%，直接做 ERC 会得到「99% 现金」的荒谬结果。实务中的桥水式「全天候」做法是：先用债券期货、股指期货把各资产类别的风险调整到同一水平（risk parity at target volatility），再等权配置。其代价是引入杠杆与保证金风险——2020 年 3 月的美元流动性冲击中，风险平价策略因杠杆被迫去化而出现显著回撤。

1.7 分层风险平价与最大分散度

1.7.1 HRP 算法

分层风险平价（hierarchical risk parity，HRP，López de Prado 2016）完全绕开 $\boldsymbol{\Sigma}^{-1}$，分三步构造组合：树聚类、准对角化、递归二分。第一步把相关系数转成距离：

$$d_{ij} = \sqrt{\frac{1-\rho_{ij}}{2}}, \qquad \rho_{ij} = \frac{\Sigma_{ij}}{\sqrt{\Sigma_{ii}\Sigma_{jj}}} \tag{1.24}$$

其中 ρ_{ij} 为相关系数，$d_{ij} \in [0,1]$。该距离是欧氏距离的一个合法变换，满足三角不等式，因此可以送入层次聚类（单链接、平均链接或 Ward 链接）。聚类结果形成一棵二叉树；把叶子按树的中序遍历重排，可得到一个**准对角矩阵**——高度相关的资产彼此相邻，因此「逆方差权重」在相邻块内分配即可避免跨块的伪分散化。

算法 1.1 分层风险平价（HRP）

输入： 协方差矩阵 $\boldsymbol{\Sigma}$（或相关矩阵与波动率），资产集合 $\{1,\dots,N\}$
输出： 组合权重 $\boldsymbol{w}$

1: 由 式 (1.24) 计算距离矩阵 d_{ij}，并做层次聚类得到二叉树
2: 按树的中序遍历重排资产，得到准对角化的 $\boldsymbol{\Sigma}$ 与对应的聚类列表
3: **for** 每一对相邻的簇对 (C_1, C_2)，自底向上 **do**
4: 计算簇方差 $V_k = \boldsymbol{w}_k^{\top}\boldsymbol{\Sigma}_k\boldsymbol{w}_k$，其中簇内权重 $\boldsymbol{w}_k$ 取逆方差权重 $1/\operatorname{diag}(\boldsymbol{\Sigma}_k)$
5: 计算簇间平分因子 $\alpha = 1 - \dfrac{V_1}{V_1+V_2}$
6: 把 C_1 的总权重乘以 α，把 C_2 的总权重乘以 $1-\alpha$
7: **end for**
8: **return** 每个资产的累积权重 $\boldsymbol{w}$

算法 1.1 的关键是第 5 行：簇内用逆方差权重（不涉及求逆），簇间按「簇方差的反比」分配。整个算法只使用 $\boldsymbol{\Sigma}$ 的对角元与簇内二次型，因此对 $\boldsymbol{\Sigma}$ 的非对角噪声极不敏感。文献报告在标准数据集上 HRP 的样本外波动率常低于 GMVP，而换手率与回撤更小。

1.7.2 最大分散度与最大去相关

最大分散度（maximum diversification，Choueifaty–Coignard 2008）最大化「加权平均波动率」与「组合波动率」之比：

$$\max_{\boldsymbol{w}} \ \mathrm{DR}(\boldsymbol{w}) = \frac{\boldsymbol{w}^\top \boldsymbol{\sigma}}{\sqrt{\boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}}}, \qquad \text{s.t. } \mathbf{1}^\top \boldsymbol{w} = 1,\ \boldsymbol{w} \geq \mathbf{0} \tag{1.25}$$

其中 $\boldsymbol{\sigma} = (\sigma_1, \ldots, \sigma_N)^\top$ 为各资产波动率。DR 的倒数就是组合的「分散化比率」，DR $= 1$ 表示组合等价于单一资产，DR $= \sqrt{N}$ 表示 N 个不相关且等波动资产。该问题是拟凸的，可通过变量替换化为二阶锥规划。若用相关矩阵替代协方差矩阵（即先做波动率标准化），则得到**最大去相关组合**：

$$\min_{\boldsymbol{w}} \ \frac{\boldsymbol{w}^\top R \boldsymbol{w}}{(\boldsymbol{w}^\top \boldsymbol{w})} \quad \Longleftrightarrow \quad \text{取} R \text{ 最小特征值对应的特征向量} \tag{1.26}$$

其中 R 为相关矩阵。这等价于对标准化收益做**主成分分析**并取最小方差的主成分方向——一个常被忽视的事实是：**最小特征值方向在样本内看起来是「最分散」的，但它恰恰是最容易被估计误差污染的方向**，因此纯 MDP/MDC 组合仍需收缩或约束保护。

1.8 Kelly 准则与分数 Kelly

1.8.1 离散赌局的最优下注

设每次下注以概率 p 赢、概率 $q = 1 - p$ 输，赔率 $b : 1$（即下注 1 元赢时净得 b 元，输时损失 1 元），下注比例为 f。长期增长率等于对数财富的期望：

$$g(f) = p \ln(1 + bf) + q \ln(1 - f) \tag{1.27}$$

令 $g'(f) = \dfrac{pb}{1 + bf} - \dfrac{q}{1 - f} = 0$，解得 **Kelly 比例**

$$f^* = \frac{pb - q}{b} = p - \frac{q}{b} = \frac{\text{期望净收益}}{\text{赔率}} \tag{1.28}$$

当 $pb \leq q$ 时期望净收益非正，$f^* \leq 0$，即不应下注。g 在 f^* 处取最大值，且 g 关于 f 在 f^* 附近二阶可微，因此过度下注的惩罚是不对称的：下注 $2f^*$ 的增长率通常远低于下注 f^* 的一半。

1.8.2 连续情形与 Merton 解的关系

设风险资产超额收益 $\mu - r$、波动率 σ，组合以恒定比例 f 投资于风险资产，则财富服从几何布朗运动，T 期的对数增长率期望为

$$g(f) = r + f(\mu - r) - \frac{f^2 \sigma^2}{2} \quad \Longrightarrow \quad f^* = \frac{\mu - r}{\sigma^2}, \qquad g(f^*) = r + \frac{1}{2}\left(\frac{\mu - r}{\sigma}\right)^2 \tag{1.29}$$

第二个等式极为重要：**最大对数增长率等于无风险利率加上夏普比率平方的一半**。取 SR $= 0.3$，超额增长率约 4.5%；取 SR $= 0.5$，约 12.5%。这解释了为什么机构愿意为 0.1 的夏普改进投入巨额成本。

例 1.4 Kelly 比例与过度下注的代价

设 $\mu - r = 6\%$、$\sigma = 20\%$，则 $f^* = 0.06/0.04 = 1.5$，即需要 150% 的杠杆才能达到最大增长率，最大超额增长率 $= 0.3^2/2 = 4.5\%$。若下注 $f = 0.75$（半 Kelly），增长率损失为

$$g(f^*) - g(f) = \frac{\sigma^2}{2}(f^* - f)^2 = \frac{0.04}{2} \times 0.75^2 = 1.125\%$$

即保留 $4.5\% - 1.125\% = 3.375\%$，为最优值的 75%，而组合波动率从 30% 降到 15%。若下注 $f = 2f^* = 3.0$，增长率 $= 0.06 \times 3 - 0.04 \times 9/2 = 0.18 - 0.18 = 0$——**两倍 Kelly 下注把长期增长率归零**。这就是「过度下注必然破产」的精确含义。

⚠ 风险警示 Kelly 准则的失效条件

Kelly 的最优性依赖三个假设，实务中一个都难以完全满足：（1）**参数已知**。$f^* = (\mu - r)/\sigma^2$ 对 μ 的敏感性是线性的，而 μ 的估计误差通常大于 μ 本身；若真实 $\mu - r = 3\%$ 而被估成 6%，实际下注已是两倍 Kelly，增长率归零。（2）**赔率与概率稳定**。真实收益的分布是时变的，牛市末期的「历史 Kelly」会给出最大杠杆。（3）**效用函数为对数**。Kelly 最大化长期增长率，但代价是沿途的回撤可以任意深；对数效用对回撤的容忍度远高于多数机构投资者的风险预算。因此实务几乎全部采用**分数 Kelly**（fractional Kelly，通常 1/4 到 1/2），其代价是增长率损失 $(1 - c^2)\,\mathrm{SR}^2/2$，收益是波动率线性下降。

1.9 CVaR 组合优化与 Rockafellar–Uryasev 线性化

1.9.1 从方差到尾部风险

方差把上行与下行同等对待，且不区分「小概率大损失」与「大概率小损失」。条件在险价值（CVaR）只关心尾部：

定义 1.3 VaR 与 CVaR

设组合损失 $L(\boldsymbol{w}) = -\boldsymbol{w}^\top r$，置信水平 $\beta \in (0,1)$。在险价值为 $\mathrm{VaR}_\beta = \min\{\nu : \mathbb{P}(L \le \nu) \ge \beta\}$，条件在险价值为

$$\mathrm{CVaR}_\beta = \frac{1}{1-\beta}\int_\beta^1 \mathrm{VaR}_u \, \mathrm{d}u = \min_{\nu \in \mathbb{R}} \left\{ \nu + \frac{1}{1-\beta}\,\mathbb{E}\left[(L(\boldsymbol{w}) - \nu)^+\right] \right\} \tag{1.30}$$

其中 $(x)^+ = \max(x, 0)$。对连续分布，$\mathrm{CVaR}_\beta = \mathbb{E}\left[L \mid L \ge \mathrm{VaR}_\beta\right]$，即超出 VaR 的平均损失。

对离散分布（情景模拟的常态），式 (1.30) 中的积分形式与条件期望不再等价：若情景等概率且尾部正好落在两个情景之间，则「超过 VaR 的平均损失」会高估 CVaR。必须使用右侧的最小化形式，这也正是它可以线性化的原因。

1.9.2 Rockafellar–Uryasev 线性化

设情景集合为 $\{r_1,\dots,r_S\}$，每个情景等概率 $1/S$。由 式 (1.30) 引入辅助变量 ν（ν 的最优值就是 VaR）与非负变量 u_s，得到线性规划：

$$\min_{\boldsymbol{w},\nu,\mathbf{u}} \quad \nu+\frac{1}{(1-\beta)S}\sum_{s=1}^{S}u_s \qquad \text{s.t.} \quad \begin{cases} u_s \ge -r_s^{\top}\boldsymbol{w}-\nu, & s=1,\dots,S \\ u_s \ge 0, & s=1,\dots,S \\ \mathbf{1}^{\top}\boldsymbol{w}=1, \quad \boldsymbol{w}\in\mathcal{W} & \end{cases} \tag{1.31}$$

由于目标函数关于 $(\boldsymbol{w},\nu,\mathbf{u})$ 是凸的（分片线性），且约束全部线性，式 (1.31) 是一个标准 LP，规模为 S 个约束加 $|\mathcal{W}|$ 个组合约束。可以证明 ν 的最优值等于 VaR_β，目标值等于 CVaR_β。更进一步，CVaR 是**一致性风险度量**（次可加、单调、正齐次、平移不变），而 VaR 不满足次可加性——这是机构选择 CVaR 作为优化目标而非约束的理论依据。

例 1.5　三情景的 CVaR 线性化

某组合在四个等概率情景下的收益为 $(9\%,3\%,-2\%,-10\%)$，取 $\beta=0.5$。损失为 $(-9\%,-3\%,2\%,10\%)$，按降序排列为 $10\%,2\%,-3\%,-9\%$。$\mathrm{VaR}_{0.5}=2\%$（因为 $\mathbb{P}(L\le 2\%)=0.5$）。由 式 (1.30) 的积分定义：$\mathrm{CVaR}_{0.5}=2\times\left[\frac{1}{4}\times 2\%+\frac{1}{4}\times 10\%\right]=6\%$，即最差一半情景的平均损失。用 式 (1.31) 验证：取 $\nu=2\%$，则 $u=(8\%,0,0,0)$，目标值 $=2\%+\frac{1}{0.5\times 4}\times 8\%=2\%+4\%=6\%$，与积分定义一致。注意目标函数在 $\nu\in[2\%,10\%]$ 上是常数，说明离散情景下最优 ν 不唯一——编码时不应假定 ν 唯一，而应直接使用目标值作为 CVaR。

补充说明　Rockafellar–Uryasev 的历史与影响

CVaR 的凸表示由 Rockafellar 与 Uryasev 在 2000 年前后系统化，其意义在于把「尾部风险约束」从非凸的 VaR 约束变成了可被内点法高效求解的 LP/SOCP。今天主流的均值-CVaR 组合优化、CVaR 风险预算、甚至深度学习中带尾部惩罚的损失函数，都建立在这个线性化技巧之上。

1.10 交易成本、换手约束与多期优化

1.10.1 成本建模

记当前持仓 $\boldsymbol{w}_0$，目标持仓 $\boldsymbol{w}$，交易向量 $\Delta\boldsymbol{w}=\boldsymbol{w}-\boldsymbol{w}_0$。常用成本函数

$$\mathrm{TC}(\boldsymbol{w})=\kappa\,\|\Delta\boldsymbol{w}\|_1+\eta\,\Delta\boldsymbol{w}^{\top}\boldsymbol{\Sigma}_{\text{illiq}}\Delta\boldsymbol{w}+\frac{1}{2}\,\Delta\boldsymbol{w}^{\top}\Lambda\Delta\boldsymbol{w} \tag{1.32}$$

其中 κ 为线性成本（买卖价差与佣金，按双边每单位计），η 为二次冲击系数（对应平方根或线性冲击模型的一阶近似），Λ 为交叉冲击矩阵，用于刻画「同时卖出高度相关资产会加剧冲击」。**除非 $\kappa=0$，最优解永远是稀疏的**（许多 w_i 恰好等于 $w_{0,i}$），因为线性成本在原点不可微，会产生「不交易区间」的次梯度条件。这一性质在实践中极为有用：它天然抑制了由微小信号波动引起的过度换手。

核心要点 1.2 核心要点：交易成本与有效前沿

计入线性成本后，最优解的次梯度条件为

$$\boldsymbol{\mu} - \lambda \boldsymbol{\Sigma} \boldsymbol{w} - \gamma \mathbf{1} \in \kappa \, \partial \left\| \Delta \boldsymbol{w} \right\|_1 \tag{1.33}$$

即当边际收益的偏离小于 κ 时，该资产保持原仓位不动。因此**交易成本把「连续有效前沿」变成了「带状有效前沿」**：落在带内的持仓不受小幅参数变化影响，这正是低换手策略估值更稳定的数学原因。

1.10.2 多期与动态规划

单期优化忽略了一个事实：今天的持仓会影响明天的成本。多期问题为

$$\max_{\{\boldsymbol{w}_t\}} \ \mathbb{E}\left[\sum_{t=0}^{T-1} \beta^t \left(\boldsymbol{w}_t^{\top} \boldsymbol{\mu}_t - \frac{\lambda}{2} \boldsymbol{w}_t^{\top} \boldsymbol{\Sigma}_t \boldsymbol{w}_t \right) - \sum_{t=0}^{T-1} \beta^{t+1} \mathrm{TC}\left(\boldsymbol{w}_{t+1} - \boldsymbol{w}_t \right) \right] \tag{1.34}$$

其中 β 为贴现因子，$\boldsymbol{\mu}_t$ 为时变预测。这类问题的解析解只在特殊情形下存在（例如成本为二次型时退化为「目标追踪」形式 $\boldsymbol{w}_t$ 向无摩擦最优解 $\boldsymbol{w}_t^{*}$ 平滑靠拢）。实务中普遍采用近似：把多期问题化为带惩罚项的单期问题，或使用 Gârleanu–Pedersen 型的「部分调整」规则——**每期只走完误差的一部分，且成本越高步长越小**。在没有能力估计时变 $\boldsymbol{\mu}$ 的情况下，用「持有期与换手惩罚」代替真正的动态规划，通常是性价比最高的选择。

1.11 动态组合管理：CPPI 与 Merton 解

1.11.1 买卖持有、常数混合与 CPPI

三种动态策略在同样的标的下产生截然不同的收益形状：

- **买入持有**（buy and hold）：不调仓，期末价值 $V_T = V_0 \, S_T / S_0$，关于标的收益是线性的。
- **常数混合**（constant mix）：恒定把比例 c 放在风险资产上并连续再平衡。可以证明（详见 小节 1.11.1）期末价值为 $V_T = V_0 \left(S_T / S_0 \right)^{c} \mathrm{e}^{\left[(1-c) r + \frac{1}{2} c (1-c) \sigma^2 \right] T}$，指数 $c < 1$ 意味着**凹**的收益曲线：市场下跌时它跌得少，上涨时也涨得少，但在震荡市中靠「低买高卖」获得**波动率收割**（volatility harvesting）。
- **CPPI**（constant proportion portfolio insurance，固定比例组合保险）：设最低可接受价值（floor）为 F，安全垫（cushion）为 $A_t - F$，则风险资产暴露为

$$E_t = \min \left\{ m \left(A_t - F \right), \ A_t \right\}, \qquad F = F_0 \, \mathrm{e}^{rT} \tag{1.35}$$

其中 $m > 1$ 为乘数，A_t 为组合总价值。连续再平衡下，安全垫的变化满足 $\mathrm{d}(A_t - F) = m(A_t - F) \, \mathrm{d}S_t / S_t$，故 $A_T - F = (A_0 - F)(S_T / S_0)^{m}$，即

$$A_T = F + (A_0 - F)\left(\frac{S_T}{S_0}\right)^m \tag{1.36}$$

式 (1.36) 是凸的（$m>1$），形象地说 CPPI 买了一份隐含的看涨期权：上涨时加速参与，下跌时自动降低暴露以保护本金。

例 1.6　常数混合的指数形式推导

设组合价值 A_t，恒把比例 c 投于价格 S_t 的风险资产（S 服从几何布朗运动，漂移 μ、波动 σ），其余投于无风险资产。则

$$\frac{\mathrm{d}A}{A} = c\,\frac{\mathrm{d}S}{S} + (1-c)\,r\,\mathrm{d}t = [c\mu + (1-c)r]\,\mathrm{d}t + c\sigma\,\mathrm{d}W_t$$

即 A 也是几何布朗运动，波动率为 $c\sigma$。用 $W_T = [\ln(S_T/S_0) - (\mu - \sigma^2/2)T]/\sigma$ 消去，得到

$$A_T = A_0\left(\frac{S_T}{S_0}\right)^c \exp\left\{\left[(1-c)r + \frac{c(1-c)\sigma^2}{2}\right]T\right\}$$

取 $r=0$、$\sigma=20\%$、$c=0.3$、$T=1$，则乘数因子为 $\exp(0.3\times 0.7\times 0.04/2) = 1.0042$，即震荡市中的超额收益约占 0.42%。这一项 $\tfrac{1}{2}c(1-c)\sigma^2 T$ 就是波动率收割的全部来源。

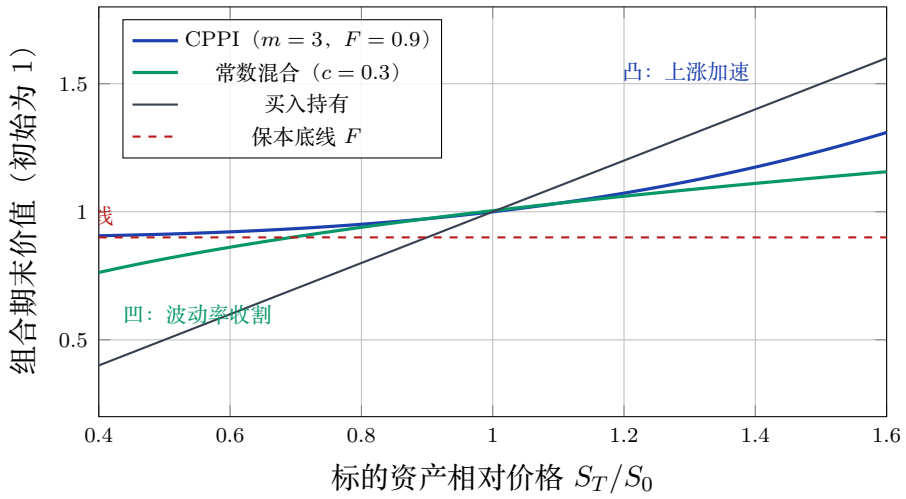


图 1.3　CPPI、常数混合与买入持有三种动态策略的期末价值曲线（估值日 $T=1$ 年，$r=0$，$\sigma=20\%$）。CPPI 的曲线位于保本底线之上且向上凸，常数混合的曲线向下凹，买入持有为直线

1.11.2　Merton 解

Merton（1969，1971）在连续时间下求解消费-投资问题：

$$\max_{c_t,\,\boldsymbol{w}_t}\ \mathbb{E}\left[\int_0^T \mathrm{e}^{-\rho t}U(c_t)\,\mathrm{d}t\right], \qquad U(c) = \frac{c^{1-\gamma}}{1-\gamma},\ \gamma>0 \tag{1.37}$$

其中 ρ 为主观贴现率，γ 为相对风险厌恶系数（CRRA），$\boldsymbol{w}_t$ 为风险资产权重。财富

动态为 $\mathrm{d}W_t = W_t\left[r + \boldsymbol{w}_t^\top(\boldsymbol{\mu} - r\mathbf{1}) - c_t/W_t\right]\mathrm{d}t + W_t\boldsymbol{w}_t^\top\boldsymbol{\Sigma}^{1/2}\mathrm{d}\boldsymbol{W}_t$。猜测值函数 $J(W) = K\,W^{1-\gamma}/(1-\gamma)$，代入 HJB 方程并对 $\boldsymbol{w}$ 求一阶条件：

$$\boldsymbol{w}^* = \frac{1}{\gamma}\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu} - r\mathbf{1}) = \frac{1}{\gamma}\,\frac{\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu} - r\mathbf{1})}{\mathbf{1}^\top\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu} - r\mathbf{1})}\cdot \mathrm{SR}_{\max} \tag{1.38}$$

即最优风险组合仍是切点组合 $\boldsymbol{w}_{\tan}$（两基金分离在连续时间下的再现），而杠杆由 $1/\gamma$ 决定。单风险资产情形退化为 式 (1.29) 的一般化：

$$w^* = \frac{\mu - r}{\gamma\sigma^2}, \qquad c^* = \left[\frac{\rho - (1-\gamma)\left(r + \frac{(\mu-r)^2}{2\gamma\sigma^2}\right)}{\gamma}\right] W \tag{1.39}$$

当 $\gamma = 1$（对数效用）时，式 (1.39) 的第一个式子即 Kelly 比例 $(\mu - r)/\sigma^2$，这给出了 Kelly 与 Merton 的统一图景：**Kelly 就是 CRRA 效用 $\gamma = 1$ 的特例**，$\gamma = 5$ 时最优杠杆降到 Kelly 的 1/5。

⚠ 风险警示　CPPI 与 Merton 解的失效条件

CPPI：(1) *跳空风险*。式 (1.36) 假定连续再平衡；若标的单日跳空下跌超过 $1/m$，安全垫会被一次性击穿。取 $m = 3$，跌幅超过 33% 即突破底线；2008 年 10 月与 2020 年 3 月都有个股单周跌幅超过该阈值。(2) *波动率上升*。m 固定时，标的波动率上升会显著提高触底概率，实务中需按波动率动态调整 m。(3) *流动性*。危机中风险资产流动性枯竭，减仓无法按模型价格成交，保本承诺形同虚设。**Merton 解**：假定投资机会集恒定（$\boldsymbol{\mu}$、$\boldsymbol{\Sigma}$、r 均为常数）。若参数时变（可预测的收益或波动率），最优权重不再是常数，需解含状态变量的 HJB 方程（Merton 1971 的可预测收益版本）。此外 CRRA 效用对极端回撤的容忍度与机构负债结构无关，实际配置需叠加负债约束与监管资本约束。

1.12 绩效归因

1.12.1 Brinson 三效应分解

归因回答「超额收益从哪里来」。把组合写成基准的行业（或资产类别）加权，记 $w_{p,i}$、$w_{b,i}$ 为组合与基准在各行业的权重（$\sum_i w_{p,i} = \sum_i w_{b,i} = 1$），$r_{p,i}$、$r_{b,i}$ 为行业内收益，$r_b = \sum_i w_{b,i} r_{b,i}$ 为基准总收益，则 Brinson–Hood–Beebower（BHB，1986）三效应为

$$A = \sum_i (w_{p,i} - w_{b,i})\, r_{b,i} \qquad \text{（配置效应）} \tag{1.40}$$

$$S = \sum_i w_{b,i}\,(r_{p,i} - r_{b,i}) \qquad \text{（选股效应）} \tag{1.41}$$

$$I = \sum_i (w_{p,i} - w_{b,i})\,(r_{p,i} - r_{b,i}) \qquad \text{（交互效应）} \tag{1.42}$$

三效应之和恰为超额收益 $r_p - r_b$（以 $r_p = \sum_i w_{p,i} r_{p,i}$ 代入即可验证）。**Brinson–Fachler**（BF，1985）把配置效应改为相对于基准总收益的偏离：

$$A^{\mathrm{BF}} = \sum_i \left(w_{p,i} - w_{b,i}\right)\left(r_{b,i} - r_b\right) \tag{1.43}$$

由 $\sum_i (w_{p,i} - w_{b,i}) = 0$ 立得 $A^{\mathrm{BF}} = A - r_b \cdot 0 = A$：**两种方法的配置效应总量相同，但行业层面的数值不同。**BF 的重心修正给出更合理的行业评价：在基准整体下跌 5% 的市场中，超配一个只跌 2% 的防御性行业应当在 BF 下记为正贡献，而在 BHB 下该行业贡献为负（因为 $r_{b,i} < 0$）。实务中大多数绩效系统默认使用 BF 的行业级配置效应。

例 1.7 Brinson 归因数值算例

设三个行业，权重与收益如下表。基准总收益 $r_b = 0.40\times10\%+0.35\times6\%+0.25\times4\% = 7.1\%$，组合总收益 $r_p = 0.50\times12\%+0.30\times5\%+0.20\times8\% = 9.1\%$，超额收益 2.0%。

行业	组合权重	基准权重	组合收益	基准收益
科技	50%	40%	12%	10%
医疗	30%	35%	5%	6%
能源	20%	25%	8%	4%

由式 (1.40)：$A = (0.10)(0.10) + (-0.05)(0.06) + (-0.05)(0.04) = 0.50\%$，$S = 0.40(0.02) + 0.35(-0.01) + 0.25(0.04) = 1.45\%$，$I = 0.10(0.02) + (-0.05)(-0.01) + (-0.05)(0.04) = 0.05\%$，合计 2.00%，与超额收益一致。改用 BF：科技 $(0.10)(0.10-0.071) = 0.29\%$，医疗 $(-0.05)(0.06-0.071) = 0.055\%$，能源 $(-0.05)(0.04-0.071) = 0.155\%$，合计仍为 0.50%。可见行业内排名被重新解释：BHB 认为「低配医疗」是负贡献（-0.30%），BF 则认为在一个基准收益 7.1% 的环境里低配一个只涨 6% 的行业是正贡献（$+0.055\%$），后者显然更符合直觉。

1.12.2 因子归因

行业归因无法回答「超额收益是选股能力还是风格暴露」。**因子归因**把主动收益投影到因子暴露变化上：

$$r_p - r_b = \sum_k \left(\beta_{p,k} - \beta_{b,k}\right) f_k + \sum_k \beta_{b,k} f_k + \alpha, \qquad \alpha = \text{无法被因子解释的残差} \tag{1.44}$$

其中 $\beta_{p,k}$、$\beta_{b,k}$ 为组合与基准对因子 k 的暴露，f_k 为因子收益。实务做法是同时对主动权重做风险模型归因（**风险归因**）与对主动收益做因子回归（**收益归因**），并把二者对齐：如果 α 的 t 值低于 2 而因子暴露变化的贡献占主动收益的 80%，那么「选股能力」的说法就不成立。

表 1.3 绩效归因方法对比

方法	分解维度	优点	局限
BHB 三效应	配置 / 选股 / 交互	恒等成立、易实现	行业级配置效应对基准方向敏感
Brinson–Fachler	配置（相对基准）/ 选股 / 交互	行业级解释更符合直觉	总量与 BHB 相同、不解决拟合问题
因子归因	风格暴露变化 / 特质	可区分 Beta 与 Alpha	依赖风险模型、因子共线时分解不唯一
多期归因（Carino）	几何链接的行业效应	多期可加、与累计收益一致	需要平滑因子、单期解释性下降

1.13 绩效指标

1.13.1 核心指标与失效条件

把绩效压缩成一个数字总要付出代价。下表列出最常用的六个指标及其隐含假设。

表 1.4 绩效指标速查与失效条件

指标	定义	解读	失效条件
夏普比率	$(\bar r_p - r_f)/\operatorname{sd}(r_p)$	每单位总风险的超额收益	收益自相关时年化偏误；对非正态收益失灵
索提诺比率	$(\bar r_p - T)/\operatorname{sd}_{\text{down}}$	只惩罚下行波动	目标收益 T 可被操纵；样本少时尾部不稳
卡玛比率	年化收益 / 最大回撤	单位回撤的收益效率	回撤是单一路径统计量，对样本区间极敏感
信息比率	$(\bar r_p - \bar r_b)/\operatorname{sd}(r_p - r_b)$	单位跟踪误差的主动收益	基准选择决定数值；跟踪误差小时爆炸
M^2	$r_f + \mathrm{SR}_p\,\sigma_b$	风险调整到基准水平后的收益	与夏普比率单调等价，无新增信息
上行捕获	上行月收益均值 / 基准上行月收益均值	牛市中跟涨能力	需与下行捕获配对解读

$$\mathrm{SR} = \frac{\bar r_p - r_f}{\operatorname{sd}(r_p)}, \qquad \mathrm{IR} = \frac{\bar r_p - \bar r_b}{\operatorname{sd}(r_p - r_b)}, \qquad \mathrm{Calmar} = \frac{\bar r_p^{\,\mathrm{ann}}}{\mathrm{MDD}} \tag{1.45}$$

其中 $\operatorname{sd}_{\text{down}} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\min(r_t - T, 0)^2}$ 为下行偏差，MDD 为最大回撤。最大回撤的严

格定义为

$$\mathrm{MDD} = \max_{0 \le s \le t \le T} \frac{V_s - V_t}{V_s}, \qquad V_t = \prod_{k=1}^{t} (1 + r_k) \tag{1.46}$$

即历史最高净值到其后的最低净值的最大跌幅，是路径依赖指标：它不能由收益率分布单独决定。

1.13.2 年化与自相关修正

月频夏普比率乘以 $\sqrt{12}$ 是默认做法，但当收益存在自相关时该换算会系统性高估。Lo（2002）给出的修正为

$$\mathrm{SR}^{\mathrm{ann}} = \mathrm{SR}^{\mathrm{monthly}} \times \frac{\sqrt{q}}{\sqrt{1 + 2\sum_{k=1}^{q-1} \frac{q-k}{q} \rho_k}}, \qquad q = 12 \tag{1.47}$$

其中 ρ_k 为收益的 k 阶自相关系数。若一阶自相关为 0.2，其余为零，则分母因子为 $\sqrt{1 + 2 \times \frac{11}{12} \times 0.2} = \sqrt{1.367} = 1.169$，年化夏普被高估约 17%。私募股权、房地产与低流动性信用策略的收益常呈现 0.3 以上的正自相关，其上报的夏普比率因此普遍偏高——估值平滑而非真实业绩是主要原因。

实务应用　指标使用的工程建议

（1）**永远报告区间**：用 block bootstrap 或滚动窗口给出夏普比率的置信区间，而不是单点。（2）**配对比较**：比较两个策略时用 Jobson–Korkie 检验（或 Memmel 修正）检验夏普比率之差的显著性，而不是比较两个点估计。（3）**路径指标单独看**：最大回撤与回撤持续期无法从夏普比率推出，必须单列。（4）**口径披露**：无风险利率、基准、复利方式、是否扣费必须写清楚，否则数值不可比。

1.14 代码实现：cvxpy 求解 MVO 与 ERC

下面两段代码给出本章两个最容易踩坑的模型的可运行实现。第一段是带权重上下限与做空约束的 MVO，第二段是用对数障碍凸化后的 ERC 求解，并验证风险贡献确实相等。

Listing 1.1　用 cvxpy 求解带约束的均值-方差优化（MVO）

```
import numpy as np
import cvxpy as cp

np.random.seed(0)
n = 8
mu = np.random.uniform(0.04, 0.12, n)
A = np.random.randn(n, n)
Sigma = A @ A.T / n + np.diag(np.random.uniform(0.01, 0.04, n))
```

```
lam = 5.0

w = cp.Variable(n)
objective = cp.Maximize(mu @ w - 0.5 * lam * cp.quad_form(w, Sigma))
constraints = [cp.sum(w) == 1, w >= 0, w <= 0.35]
prob = cp.Problem(objective, constraints)
prob.solve()

print("status:", prob.status)
print("weights:", np.round(w.value, 4))
print("expected return:", round(float(mu @ w.value), 4))
print("ex-ante volatility:", round(float(np.sqrt(w.value @ Sigma @ w.
    value)), 4))
```

Listing 1.2 用凸对数障碍形式求解等风险贡献（ERC）组合

```
import numpy as np
import cvxpy as cp

np.random.seed(0)
n = 8
A = np.random.randn(n, n)
Sigma = A @ A.T / n + np.diag(np.random.uniform(0.01, 0.04, n))
budget = np.ones(n) / n

y = cp.Variable(n, pos=True)
objective = cp.Minimize(0.5 * cp.quad_form(y, Sigma) - budget @ cp.log(y)
    )
prob = cp.Problem(objective, [cp.sum(y) == 1])
prob.solve()

w = y.value / y.value.sum()
vol = float(np.sqrt(w @ Sigma @ w))
rc = w * (Sigma @ w) / vol

print("status:", prob.status)
print("weights:", np.round(w, 4))
print("risk contributions:", np.round(rc, 4))
print("portfolio volatility:", round(vol, 4))
```

Listing 1.1 中若把 ‘lam‘ 设得极小（例如 0.01），优化器会把权重顶到上下限边界，这正是 节 1.2 所述错误放大的工程表现；listing 1.2 的关键是承认 ERC 不是「最小方差」问题，而是对数障碍下的风险预算问题，因此代码里没有出现 $\boldsymbol{\Sigma}^{-1}$。

本章小结

- 均值-方差问题的解可分解为 GMVP 与投机性倾斜（式 (1.4)），有效前沿为双曲线（式 (1.6)）；引入无风险资产后所有投资者持有同一 式 (1.7) 的切点组合。
- 预期收益的估计误差经 $\boldsymbol{\Sigma}^{-1}$ 放大，期望效用损失为 $N/(2\lambda T)$（式 (1.10)）；样

本相关矩阵的病态程度随 N/T 上升。

- 收缩（式 (1.11)）、因子结构（式 (1.13)）、EWMA 与 DCC（式 (1.16)）分别从「降低噪声」「降低维度」「引入时变」三个方向补救协方差估计。
- 鲁棒优化把不确定性集写成范数惩罚（式 (1.18)），Black–Litterman 用均衡先验加观点得到后验均值（式 (1.20)）。
- ERC 与风险预算的 KKT 条件为 $w_i(\boldsymbol{\Sigma}\boldsymbol{w})_i = b_i\sigma_p^2$（命题 1.1），其凸形式不含矩阵求逆；HRP 用聚类替代求逆（算法 1.1）。
- Kelly 比例 $f^* = (\mu - r)/\sigma^2$ 使对数增长率最大，最大值为 $r + \mathrm{SR}^2/2$；分数 Kelly 以 $(1-c^2)\mathrm{SR}^2/2$ 的增长率换取波动率的线性下降。
- CVaR 的 Rockafellar–Uryasev 形式把尾部风险优化变成线性规划（式 (1.31)），且 CVaR 是满足次可加性的一致性风险度量。
- 交易成本带来稀疏解与「带状前沿」（式 (1.33)）；绩效归因应给出 BHB/BF 配置效应与因子归因两套结果（表 1.3）。

练习与思考

1. 两资产情形下 $\boldsymbol{\Sigma} = \left(\begin{smallmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{smallmatrix}\right)$。证明 GMVP 权重为 $w_1 = \dfrac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}$，并说明当 $\rho \to 1$ 时该权重为何不收敛（提示：$\boldsymbol{\Sigma}$ 趋于奇异）。
2. 用 式 (1.10) 计算：若 $\lambda = 4$、$T = 120$、N 从 50 增加到 500，期望效用损失增加多少？若改为把 500 个资产压缩成 25 个因子，损失如何变化？
3. 验证 式 (1.24) 中的 d_{ij} 满足三角不等式，并说明为什么必须做 $\sqrt{(1-\rho)/2}$ 而不是直接使用 $1-\rho$。
4. 在 小节 1.6.2 的设定下，用 式 (1.22) 写出 KKT 方程组，并解释为什么 $b_i = 1/N$ 时解与 $\boldsymbol{\Sigma}$ 的对角元成反比（提示：考虑对角矩阵的特殊情形）。
5. 设某策略月均超额收益 0.6%，月波动 3%，一阶自相关 0.25。分别用朴素年化与式 (1.47) 的修正计算年化夏普比率，并解释差异来源。
6. 把 式 (1.31) 改写为「在 $\mathrm{CVaR}_\beta \le c$ 约束下最大化期望收益」的形式，并说明该问题仍是线性规划。
7. 在 小节 1.8.2 的设定下，求使长期增长率为零的临界下注比例（答案：$f = 2f^*$），并画出 $g(f)$ 随 f 变化的曲线，标出 f^* 与临界点。
8. 用 式 (1.35) 说明：若乘数 $m = 4$、安全垫占组合的 10%，标的单日下跌多少会使 CPPI 跌破保本底线？并讨论为什么杠杆型 CPPI 在跳空市场中会失效。

延伸阅读

- Markowitz, H., “Portfolio Selection”, *Journal of Finance*, 1952.（均值-方差框架的原始文献，读它的价值在于看清「收益-风险二维」这一抽象是如何被提出来的）

- Ledoit, O., and Wolf, M., "A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices", *Journal of Multivariate Analysis*, 2004.（收缩强度的最优公式，第 2 节给出了可直接实现的估计量）
- Black, F., and Litterman, R., "Global Portfolio Optimization", *Financial Analysts Journal*, 1992.（BL 模型的原始阐述，重点读「反向优化」的动机部分）
- Maillard, S., Roncalli, T., and Teïletche, J., "The Properties of Equally Weighted Risk Contribution Portfolios", *Journal of Portfolio Management*, 2010.（ERC 的解析性质与凸化证明）
- López de Prado, M., "Building Diversified Portfolios that Outperform Out of Sample", *Journal of Portfolio Management*, 2016.（HRP 算法原文，附有可直接复现的伪代码）
- Rockafellar, R. T., and Uryasev, S., "Optimization of Conditional Value-at-Risk", *Journal of Risk*, 2000.（CVaR 线性化的经典论文，是本章 式 (1.31) 的出处）
- Roncalli, T., *Introduction to Risk Parity and Budgeting*, CRC Press, 2013.（风险平价的系统性教材，覆盖 ERC、风险预算与多资产实施细节）
- Lo, A. W., "The Statistics of Sharpe Ratios", *Financial Analysts Journal*, 2002.（夏普比率的统计性质与自相关修正，是 式 (1.47) 的出处）