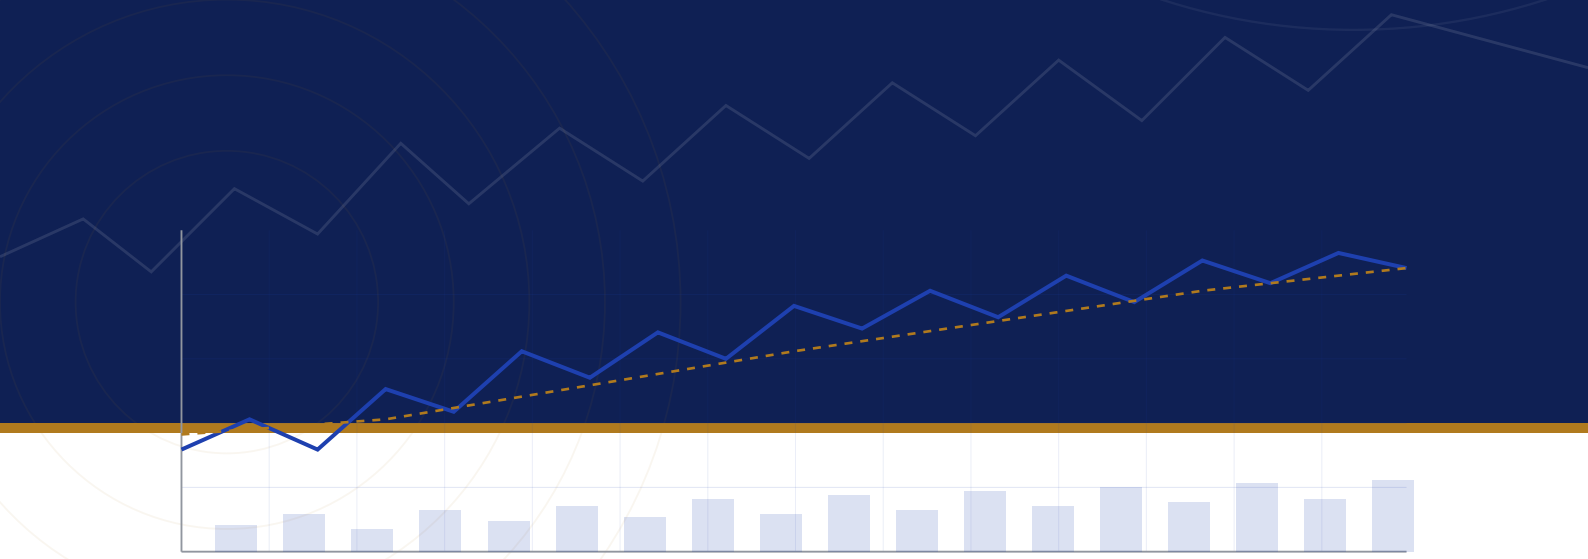
QUANTEX 内部讲义 · INTERNAL LECTURE NOTES

量化金融工程

Quantitative Financial Engineering

从金融体系与市场微观结构，到衍生品定价、随机分析与因子投资
——一份贯通 Q Quant 与 P Quant 的量化金融知识地图



全书结构（12 章 · 5 篇）

1 金融入门
2 金融科技
3 Web3 与加密金融
4 金融工程
5 金融数学
6 Q Quant：风险中性定价
7 P Quant：统计与策略
8 金融概率与统计
9 时间序列分析
10 随机过程
11 组合优化
12 美国证券从业资格

作者：Quantex
排版：XeLaTeX + ctex

版本：第二版（扩充修订）
2026 年 10 月 9 日

前言

本书是一份面向量化金融从业者、金融工程专业学生与转行者的系统化学习笔记，覆盖从金融市场基础到随机分析、从衍生品定价到因子投资的完整知识链条。全书 12 章，按「基础—工具—定价—统计—应用」的顺序编排，并在附录中给出公式速查、Python 工具链与术语中英对照。

为什么需要一份「量化金融工程」的整合笔记

市面上量化金融的教材与研究文献极其丰富：Hull 的《期权、期货及其他衍生产品》讲清了产品与市场，Shreve 的《金融随机分析》讲透了测度与鞅，Campbell–Lo–MacKinlay 建立了金融计量的方法论，Grinold–Kahn 则系统阐述了主动管理。但在实际学习与工作中，真正的困难往往不是「某一本书读不懂」，而是：

- **知识被割裂**：定价（Q Quant）与统计（P Quant）常被当作两个互不相干的领域，而它们共享同一套概率语言与数值工具；
- **「会用」与「懂」之间的断层**：能调用 Black–Scholes 公式，却说不清为什么风险中性测度存在、为什么波动率不变；
- **理论到工程的距离**：知道 GARCH 的定义，却没有一套可直接运行的代码与检验流程；
- **符号不统一**：不同教材对测度、期望、波动率、久期的记号各不相同，交叉阅读时成本极高。

本书的处理方式是：**用统一的符号体系与统一的叙事逻辑**，把上述内容组织成一条主线——「金融的本质是跨期与跨状态的风险定价；Q Quant 给出无套利约束下的相对价格，P Quant 给出真实测度下的统计规律，而二者都由随机过程与概率统计提供数学基础。」

内容组织：Q Quant 与 P Quant 的分野与统一

Q Quant（第 6、10 章为核心）

以风险中性测度 $\mathbb{Q}$ 为语言，研究「在无套利条件下衍生品应当值多少」。工具是鞅论、测度变换、随机微分方程与数值方法。对应岗位：衍生品定价、结构化产品、模型验证（Model Validation）、XVA。

P Quant（第 7–9、11 章为核心）
以真实测度 $\mathbb{P}$ 为语言，研究「未来实际会发生什么」，寻找可被统计验证的收益规律。工具是因子模型、时间序列、机器学习与组合优化。对应岗位：因子研究、量化策略、风险管理、组合管理。

需要强调的是：**二者的区别不是「对的」与「错的」，而是「用途」不同。**给奇异期权报价必须用 $\mathbb{Q}$（否则可以被无风险套利），做因子择时必须在 $\mathbb{P}$ 下检验（因为 $\mathbb{Q}$ 下的期望收益恒为无风险利率，不含任何 Alpha 信息）。混淆测度是量化面试中的经典陷阱，也是本书反复强调的红线。

第二版修订说明

本次修订在保留原有 12 章框架的基础上，做了三方面的系统性升级：

1. **排版重构**：重写统一导言区（`preamble.tex`），设计封面、统一章节标题样式、页眉页脚与配色方案；补齐目录层级、交叉引用（`cleveref`）、图表编号与算法环境；修复了旧版本中缺失字形（如警告图标显示为空白）与 PDF 书签乱码的问题。

2. **内容扩充**：为每一章补充了公式推导、数值算例、实务应用与风险警示；新增随机微分方程的推导细节、SABR 与局部波动率、XVA 框架、卡尔曼滤波与状态空间模型、已实现波动率与 HAR 模型、Kelly 准则与风险预算、机器学习选股等内容；并为资格证章节补充了可计算的例题。

3. **工程化与可视化**：新增 TikZ/pgfplots 绘制的定价与风险示意图（收益曲线、有效前沿、波动率微笑、二叉树、AMM 曲线、布朗路径等），新增可直接运行的 Python 代码片段，新增数学公式附录、Python 工具链附录与术语中英对照表，以及统一整理的参考文献。

阅读建议

- **零基础读者**：按第 1–5 章顺序阅读，先建立金融直觉与数学工具，再进入 Q/P Quant 的分野。
- **有金融背景、数学薄弱**：先读第 10 章（随机过程）与第 8 章（概率统计），再回到第 6 章（Q Quant）。
- **求职面试导向**：重点阅读第 4、6、7、11 章的公式与「实务应用」盒子，第 12 章了解美国证券从业资格体系；面试高频问题集中在测度变换、伊藤引理、希腊字母、因子模型与回测陷阱。
- **工程导向**：直接看附录 B（Python 工具链）与各章的代码示例，再回溯对应的数学推导。

关于符号、代码与免责声明

- 全书数学符号尽量统一，完整列表见「符号表」；不同文献的记号差异在相应位置会给出对照。
- 代码示例以 Python 生态为主（`numpy`、`pandas`、`statsmodels`、`arch`、`scipy`、`cvxpy` 等），为便于跨平台运行，变量名与注释一律使用英文。
- 本书是学习笔记的整理，**不构成任何投资建议**。所有模型的假设与局限都已在相应章节的「风险警示」中尽量说明；历史回测结果不代表未来收益。

Quantex
2026 年 10 月 9 日

阅读指南与全书地图

三条推荐阅读路径

本书 12 章并非必须线性阅读。根据目标不同，推荐三条路径：

目标	推荐路径
衍生品定价 / 卖方 Quant	第 4 章（产品与 BSM）→ 第 10 章（随机过程：伊藤引理、Girsanov）→ 第 6 章（测度变换、HJM/LMM、傅里叶定价）→ 第 5 章（蒙特卡洛与有限差分）
因子投资 / 买方 Quant	第 1 章（市场与工具）→ 第 8 章（统计推断与回归）→ 第 7 章（因子模型与 Alpha 研究）→ 第 9 章（时间序列与波动率）→ 第 11 章（组合优化）
金融科技 / 加密金融	第 2 章（FinTech 技术栈）→ 第 3 章（Web3、AMM 数学、Tokenomics）→ 第 2 章的风险与合规部分 → 附录 B（工具链）

全书地图


第一篇　金融与科技基础
第 1 章金融入门 · 第 2 章金融科技 · 第 3 章 Web3 与加密金融
第二篇　金融工程与金融数学
第 4 章金融工程（BSM、Greeks、波动率建模）· 第 5 章金融数学（利息理论、蒙特卡洛、有限差分）
第三篇　Q Quant：风险中性定价与随机分析
第 6 章 Q Quant（等价鞅测度、利率模型、信用与波动率衍生品）· 第 10 章随机过程（布朗运动、伊藤引理、Lévy 过程）
第四篇　P Quant：统计方法与机器学习
第 7 章 P Quant（因子模型、Alpha 研究、回测方法论）· 第 8 章概率统计 · 第 9 章时间序列（GARCH、状态空间、深度学习）
第五篇　组合管理与职业路径
第 11 章组合优化（Markowitz、收缩估计、风险平价、归因）· 第 12 章美国证券从业资格（SIE / Series 7 / 57 / 65 / 24）
数学基础层
概率论与统计推断（第 8 章）
随机微积分与测度论（第 10 章）
数值方法：MC / 有限差分（第 5 章）
贯穿全书，是第三、四篇的共同底座。
工程实现层
Python 量化工具链（附录 B）
波动率 / 因子 / 优化代码片段
术语中英对照（附录 C）

每章的核心问题

章	主题	要回答的核心问题	关键工具
1	金融入门	金融体系如何运转？资产价格由什么决定？	现值、久期与凸性、EMH
2	金融科技	大数据与 AI 如何重塑金融服务的交付？	评分卡、WOE、EL 模型、开放银行
3	Web3	去中心化金融的定价与风险逻辑是什么？	恒定乘积 AMM、无常损失、Tokenomics
4	金融工程	期权「应该」值多少钱？如何管理其风险？	无套利复制、BSM、Greeks、Heston
5	金融数学	定价与风险管理需要哪些计算工具？	年金、Nelson–Siegel、MC、Crank–Nicolson
6	Q Quant	如何在等价鞅测度下一致地为衍生品定价？	Girsanov、计价单位变换、HJM/LMM、FFT
7	P Quant	如何在真实测度下寻找可持续的 Alpha？	因子模型、IC/IR、回测与多重检验
8	概率统计	如何从含噪、肥尾、异方差的数据中做推断？	MLE/GMM、贝叶斯、EVT、Fama–MacBeth
9	时间序列	如何刻画并预测收益与波动率的动态？	ARIMA、GARCH 族、协整、LSTM/Transformer
10	随机过程	连续时间不确定性的数学语言是什么？	布朗运动、伊藤引理、Lévy、Feynman–Kac
11	组合优化	如何把预测转化为可承受风险的仓位？	Markowitz、收缩估计、风险平价、Kelly
12	从业资格	美国证券行业的知识体系与合规要求是什么？	SIE / Series 7 / 57 / 65 / 24 考点

如何使用书中的盒式环境

为便于快速定位信息，全书统一使用以下彩色盒子（见下页示例）：

- **核心要点**：每节最重要的一句话结论，按章编号，可用交叉引用指向；
- **定义 / 例 / 定理**：数学与金融概念的规范表述；
- **实务应用**：理论与真实市场实践之间的桥梁；
- **风险警示**：模型失效条件、历史教训与常见误用；
- **直觉理解**：用非技术语言解释公式背后的含义；
- **考试要点**：与从业资格考试相关的考点（主要见于第 12 章）。

核心要点 0.1

本书的写作原则是「**公式—直觉—应用—风险**」**四件套**：每个重要公式都尽量给出直观解释、实际用途与失效条件。只背公式而不理解适用边界，是量化工作与面试中最常见的失败模式。

符号表

本书尽量保持全书符号一致。下表列出最常用的记号；个别章节沿用经典文献的记号时，会在该处给出对照说明。

一、数学与概率记号

记号	含义	首次出现
X, Y, Z	随机变量（大写）；实现值用小写 x, y, z	第 8 章
$\{X_t\}_{t\in T}$, S_t	随机过程；S_t 通常指资产价格	第 10 章
$(\Omega, \mathcal{F}, \mathbb{P})$	概率空间：样本空间、σ-代数、概率测度	第 6 章
$\{\mathcal{F}_t\}$	信息流（filtration），$\mathcal{F}_t$ 表示 t 时刻可得的信息	第 6、10 章
$\mathbb{E}^{\mathbb{P}}[\cdot]$, $\mathbb{E}^{\mathbb{Q}}[\cdot]$	真实测度 / 风险中性测度下的期望	第 6 章
$\mathbb{P}$, $\mathbb{Q}$	真实世界测度 / 风险中性（等价鞅）测度	第 6 章
$\mathcal{N}(\mu, \sigma^2)$	正态分布；$\mathcal{N}(0,1)$ 为标准正态	第 8 章
$\Phi(\cdot)$, $\phi(\cdot)$	标准正态的累积分布函数 / 密度函数	第 4 章
W_t（或 B_t）	标准布朗运动（维纳过程）	第 10 章
N_t	泊松过程（强度 λ）	第 10 章
$\langle X, Y\rangle_t$	二次变差（quadratic variation）	第 10 章
$\mathcal{E}(\cdot)$	随机指数（Doléans-Dade exponential）	第 6 章
$\mathbf{1}_{\{A\}}$	事件 A 的示性函数	第 6 章
$\lvert x\rvert$, $\lVert \boldsymbol{w}\rVert$	绝对值 / 向量范数（默认 ℓ_2，ℓ_1 会下标标注）	第 11 章
$\mathrm{d}t$, $\frac{\partial f}{\partial x}$	微分与偏导数	第 5 章
μ, σ	漂移率（期望收益）与波动率	第 4 章
λ	风险的市场价格；在组合优化中亦作风险厌恶系数（以章内说明为准）	第 6、11 章
θ	模型参数向量；在利率模型中为长期均值	第 8、6 章
Σ, ρ	协方差矩阵与相关系数	第 11 章
$\boldsymbol{w}$, $\boldsymbol{\mu}$	组合权重向量与期望收益向量	第 11 章
$O(\cdot)$, $o(\cdot)$	渐近阶记号	第 5 章

二、金融与市场记号

记号	含义	首次出现
S_0, S_t, S_T	标的资产当前价格、t 时刻价格、到期价格	第 1 章
K, T, τ	行权价、到期时间、剩余期限（$\tau = T - t$）	第 4 章
C, P	看涨（Call）与看跌（Put）期权价格	第 4 章
F_0, $f(t,T)$	远期价格；t 时刻的瞬时远期利率	第 4、6 章
r, q, y	无风险利率、股息率、到期收益率	第 1、4 章
$B(0,T)$, $P(t,T)$	零息债券（贴现因子）价格	第 4、6 章
D, D^*, C_{conv}	麦考利久期、修正久期、凸性	第 1 章
$L_k(t)$	第 k 期远期 LIBOR/SOFR 利率	第 6 章
$\Delta, \Gamma, \Theta, \nu, \rho$	期权希腊字母：Delta、Gamma、Theta、Vega、Rho	第 4 章
σ_{impl}, σ_{loc}	隐含波动率、局部波动率	第 4 章
PD, LGD, EAD	违约概率、违约损失率、违约敞口	第 2 章
R, $Q(t)$, λ_t	回收率、生存概率、违约强度	第 4、6 章
VaR_α, ES_α	置信水平 α 下的在险价值 / 预期亏空	第 4 章
IC, IR, SR	信息系数、信息比率、夏普比率	第 7、11 章
w_i, b_i	资产权重、风险预算	第 11 章
x, y, k	自动做市商池中两种代币的数量与恒定乘积	第 3 章
$IL(\rho)$	无常损失（关于价格比 ρ）	第 3 章
HF	借贷协议健康因子	第 3 章

三、常用英文缩写

缩写	英文全称 / 中文	首次出现
BSM	Black–Scholes–Merton 期权定价模型	第 4 章
GBM	Geometric Brownian Motion，几何布朗运动	第 4 章
SDE / PDE	Stochastic / Partial Differential Equation，随机 / 偏微分方程	第 5、10 章
EMH	Efficient Market Hypothesis，有效市场假说	第 1 章
CAPM	Capital Asset Pricing Model，资本资产定价模型	第 7 章
FF3 / FF5	Fama–French 三因子 / 五因子模型	第 7 章
HJM	Heath–Jarrow–Morton 远期利率模型	第 6 章
LMM	LIBOR Market Model，LIBOR 市场模型	第 6 章
IRS / CDS	Interest Rate Swap / Credit Default Swap	第 4 章
CDO	Collateralized Debt Obligation，担保债务凭证	第 4 章
CVA / DVA / FVA	信用 / 债务 / 资金估值调整	第 4 章
XVA	各类估值调整的统称	第 4 章

缩写	英文全称 / 中文	首次出现
MC / QMC	Monte Carlo / Quasi-Monte Carlo，蒙特卡洛 / 拟蒙特卡洛	第 5 章
LSM	Least-Squares Monte Carlo（Longstaff–Schwartz）	第 6 章
FFT	Fast Fourier Transform，快速傅里叶变换	第 6 章
EVT / POT	Extreme Value Theory / Peaks Over Threshold	第 8 章
GARCH	Generalized ARCH，广义自回归条件异方差	第 9 章
ARIMA	自回归积分滑动平均模型	第 9 章
VECM	Vector Error Correction Model，向量误差修正模型	第 9 章
MLE / GMM	极大似然估计 / 广义矩方法	第 8 章
OLS / BLUE	普通最小二乘 / 最佳线性无偏估计	第 8 章
MCMC	Markov Chain Monte Carlo	第 8 章
HRP	Hierarchical Risk Parity，层次风险平价	第 11 章
ERC	Equal Risk Contribution，等风险贡献	第 11 章
OOS	Out-of-Sample，样本外	第 7 章
DSR	Deflated Sharpe Ratio，通缩夏普比率	第 7 章
HFT	High-Frequency Trading，高频交易	第 7 章
LOB / OFI	Limit Order Book / Order Flow Imbalance	第 7 章
AMM / CPMM	Automated Market Maker / Constant Product MM	第 3 章
TVL	Total Value Locked，总锁仓价值	第 3 章
MEV	Maximal Extractable Value，最大可提取价值	第 3 章
DAO	Decentralized Autonomous Organization	第 3 章
RegTech	Regulatory Technology，监管科技	第 2 章
KYC / AML	了解你的客户 / 反洗钱	第 2 章
SIE / GS / RR	证券行业基础考试 / 通用证券代表 / 注册代表	第 12 章
FINRA / SEC	美国金融业监管局 / 证券交易委员会	第 12 章

目 录

前言 . . . . . **ii**

阅读指南与全书地图 . . . . . **v**

符号表 . . . . . **ix**

第一章　金融入门 **1**

1.1　金融体系概览 1

1.1.1　货币市场与资本市场工具对比 1

1.1.2　一级市场、二级市场与流动性 1

1.1.3　交易所、场外市场与做市商 2

1.2　权益与固定收益工具 2

1.2.1　股利折现模型与 Gordon 增长模型 2

1.2.2　债券定价与到期收益率 3

1.2.3　久期：四种解释 3

1.2.4　久期近似、DV01 与凸性修正 4

1.2.5　久期对冲与免疫策略 6

1.2.6　股票指数编制方法 6

1.3　财务报表分析与勾稽关系 7

1.3.1　杜邦分解 7

1.4　资本预算：NPV 与 IRR 8

1.5　利率的期限结构 9

1.5.1　名义利率的分解 9

1.5.2　即期利率、远期利率与三大理论 10

1.6　有效市场假说与行为金融 11

1.6.1　三个层次的效率与检验方式 11

1.6.2　异象与 Grossman–Stiglitz 悖论 11

1.6.3　前景理论的价值函数 12

1.7　市场参与者与交易机制 12

1.7.1　参与者类型 12

1.7.2　订单类型与交易成本 12

第二章　金融科技 **16**

2.1　金融科技的定义与演进 16

2.1.1 四个阶段 . . . 16
2.1.2 技术栈的分层 . . . 17
2.2 数据基础设施 . . . 17
2.2.1 数据仓库、数据湖与湖仓一体 . . . 17
2.2.2 批处理、流处理与批流一体 . . . 17
2.3 信用评分卡 . . . 18
2.3.1 从数据到 WOE 与 IV . . . 18
2.3.2 评分刻度：从几率的对数到分数 . . . 19
2.3.3 预期损失与风险调整收益 . . . 20
2.3.4 评分模型的监控与压力测试 . . . 22
2.4 支付与清算基础设施 . . . 23
2.4.1 RTGS 与 DNS . . . 23
2.4.2 实时支付的运营含义 . . . 24
2.5 开放银行与数据合规 . . . 24
2.5.1 开放银行的技术与商业逻辑 . . . 24
2.5.2 合规框架：授权、最小化与跨境 . . . 24
2.6 模型风险治理 . . . 25
2.6.1 机器学习模型的特殊风险 . . . 25
2.6.2 SR 11-7 与三道防线 . . . 25
2.6.3 大语言模型在金融中的应用与局限 . . . 26
2.7 另类数据与量化平台 . . . 26
2.7.1 另类数据的价值与陷阱 . . . 26
2.7.2 量化研究与回测平台 . . . 27
第三章 Web3 与加密金融 . . . 31
3.1 Web3 的哲学与技术基础 . . . 31
3.2 区块链技术深度 . . . 31
3.2.1 哈希链与 Merkle 证明 . . . 31
3.2.2 共识机制与终局性 . . . 32
3.2.3 以太坊虚拟机与费率机制 . . . 33
3.3 智能合约与安全 . . . 34
3.3.1 Solidity 的关键要素 . . . 34
3.3.2 安全转账的实现 . . . 34
3.3.3 代币标准与实现细节 . . . 36
3.4 代币经济学与估值 . . . 36
3.4.1 代币的分类 . . . 36
3.4.2 交换方程及其循环论证问题 . . . 36
3.4.3 协议现金流折现 . . . 37
3.5 DeFi 协议数学 . . . 38
3.5.1 恒定乘积做市商 . . . 38

3.5.2 流动性份额与手续费收入 . . . 39
3.5.3 无常损失 . . . 40
3.5.4 借贷协议：Kink 利率模型与清算 . . . 42
3.5.5 MEV、抢跑与交易排序 . . . 43
3.6 扩容、跨链与治理 . . . 44
3.6.1 二层扩容的技术取舍 . . . 44
3.6.2 跨链桥的风险结构 . . . 44
3.6.3 DAO 治理与治理攻击 . . . 45
3.7 监管、估值实务与本章定位 . . . 45
3.7.1 监管框架 . . . 45
3.7.2 代码：计算无常损失与 LP 净收益 . . . 45
3.7.3 本章在全书中的位置 . . . 46
第四章 金融工程 . . . 49
4.1 金融工程方法论 . . . 49
4.1.1 核心工作循环 . . . 49
4.1.2 三类基本构造块 . . . 49
4.2 远期与期货定价 . . . 50
4.2.1 无套利定价与套利表 . . . 50
4.2.2 期货与远期的差异 . . . 51
4.3 期权基础与到期收益 . . . 51
4.3.1 收益函数与内在价值 . . . 51
4.3.2 看跌看涨平价 . . . 52
4.3.3 期权组合策略 . . . 52
4.4 Black–Scholes–Merton 模型 . . . 53
4.4.1 假设与标的动态 . . . 53
4.4.2 Delta 对冲与 BSM 方程 . . . 53
4.4.3 解析解与风险中性定价 . . . 54
4.4.4 隐含波动率与求解 . . . 54
4.5 期权希腊字母 . . . 56
4.5.1 显式解析式 . . . 56
4.5.2 希腊字母之间的关系与 Delta 对冲误差 . . . 57
4.6 波动率建模 . . . 58
4.6.1 波动率微笑与偏斜 . . . 58
4.6.2 局部波动率模型 . . . 58
4.6.3 随机波动率：Heston 模型 . . . 59
4.6.4 SABR 与市场惯例 . . . 59
4.7 结构化产品 . . . 59
4.7.1 保本票据 . . . 59
4.7.2 自动赎回产品（Autocallables）与雪球 . . . 59

4.8 利率衍生品 . . . 60
4.8.1 利率互换 . . . 60
4.8.2 互换期权与利率上下限 . . . 60
4.9 信用衍生品 . . . 61
4.9.1 信用违约互换 . . . 61
4.9.2 担保债务凭证与相关风险 . . . 61
4.9.3 XVA：估值调整框架 . . . 61
4.10 风险管理框架 . . . 62
4.10.1 在险价值与预期亏空 . . . 62
4.10.2 压力测试与情景分析 . . . 62
第五章 金融数学 . . . 65
5.1 利息理论 . . . 65
5.1.1 计息方式与利率换算 . . . 65
5.1.2 年金 . . . 65
5.1.3 贷款摊销 . . . 66
5.2 债券数学 . . . 67
5.2.1 全价、净价与收益率 . . . 67
5.2.2 久期、凸性与 DV01 . . . 67
5.2.3 收益率曲线的构建与拟合 . . . 68
5.3 期权定价的数学基础 . . . 69
5.3.1 无套利与风险中性定价 . . . 69
5.3.2 Black–Scholes 偏微分方程的推导 . . . 69
5.3.3 数值方法之一：二叉树模型 . . . 70
5.3.4 数值方法之二：有限差分法 . . . 70
5.4 蒙特卡洛方法 . . . 71
5.4.1 基本原理与误差 . . . 71
5.4.2 方差缩减与拟蒙特卡洛 . . . 71
5.4.3 用蒙特卡洛计算希腊字母 . . . 71
5.5 数值优化基础 . . . 74
5.5.1 无约束优化 . . . 74
5.5.2 约束优化与 KKT 条件 . . . 74
第六章 Q Quant：风险中性定价与衍生品 . . . 78
6.1 Q Quant 的哲学 . . . 78
6.2 测度论要点 . . . 78
6.2.1 概率空间、信息流与可测性 . . . 78
6.2.2 鞅、局部鞅与平方可积鞅 . . . 79
6.2.3 Radon–Nikodym 导数 . . . 79
6.3 Girsanov 定理与测度变换 . . . 80
6.3.1 从真实测度到风险中性测度 . . . 80

6.4 鞅定价方法与基本定理 . . . 81
6.4.1 两个基本定理 . . . 81
6.4.2 风险中性定价公式 . . . 81
6.4.3 计价单位变换与远期测度 . . . 81
6.5 利率模型 . . . 82
6.5.1 短期利率模型 . . . 82
6.5.2 Heath–Jarrow–Morton 框架 . . . 82
6.5.3 LIBOR 市场模型 . . . 83
6.6 信用衍生品定价 . . . 83
6.6.1 强度模型与生存概率 . . . 83
6.6.2 CDS 定价 . . . 84
6.6.3 相关违约与 Copula . . . 84
6.7 波动率衍生品 . . . 85
6.7.1 方差互换 . . . 85
6.7.2 VIX 指数 . . . 85
6.8 傅里叶变换方法 . . . 86
6.8.1 特征函数与 Carr–Madan 公式 . . . 86
6.8.2 Heston 模型的特征函数 . . . 86
6.9 数值实现专题 . . . 87
6.9.1 最小二乘蒙特卡洛 . . . 87
6.9.2 蒙特卡洛加速与傅里叶实现 . . . 87
第七章 P Quant：统计方法与量化策略 . . . 91
7.1 P Quant 的工作面 . . . 91
7.2 因子构建全流程 . . . 92
7.2.1 从原始信号到可用因子 . . . 92
7.2.2 行业与风格中性化 . . . 92
7.2.3 风险模型的截面估计 . . . 93
7.3 信息系数与因子评价 . . . 94
7.3.1 IC、Rank IC 与衰减 . . . 94
7.3.2 分层回测与多空组合 . . . 95
7.3.3 因子评价清单 . . . 95
7.4 主动管理基本定律 . . . 95
7.4.1 定律的推导 . . . 95
7.4.2 现实修正 . . . 96
7.5 机器学习选股 . . . 97
7.5.1 适用场景与模型选择 . . . 97
7.5.2 样本权重与标签设计 . . . 97
7.5.3 时序交叉验证与泄漏防控 . . . 98
7.6 回测方法论 . . . 98

7.6.1 偏差清单 . . . 98
7.6.2 多重检验的三个层次 . . . 98
7.6.3 实施缺口与交易成本 . . . 100
7.7 市场微观结构与最优执行 . . . 100
7.7.1 订单簿与价差分解 . . . 100
7.7.2 Kyle 模型的均衡推导 . . . 101
7.7.3 Almgren–Chriss 最优执行 . . . 101
7.8 代码实现：中性化与 IC 计算 . . . 103
第八章 金融概率与统计分析 . . . 107
8.1 概率论基础与分布族 . . . 107
8.1.1 随机变量、矩与特征函数 . . . 107
8.1.2 金融收益的分布族 . . . 107
8.2 估计方法 . . . 108
8.2.1 极大似然估计与渐近正态性 . . . 108
8.2.2 广义矩方法与最优权重 . . . 109
8.3 假设检验与多重检验 . . . 110
8.3.1 三种渐近等价检验 . . . 110
8.3.2 多重检验与 FDR . . . 110
8.4 Bootstrap 与重抽样 . . . 111
8.5 回归分析 . . . 112
8.5.1 OLS 的代数与几何 . . . 112
8.5.2 稳健标准误与 HAC . . . 113
8.5.3 面板数据与固定效应 . . . 113
8.5.4 Fama–MacBeth 回归 . . . 114
8.6 贝叶斯方法 . . . 114
8.6.1 共轭先验与后验推导 . . . 114
8.6.2 可信区间与置信区间 . . . 115
8.6.3 Black–Litterman 模型 . . . 115
8.6.4 马尔可夫链蒙特卡洛 . . . 116
8.7 惩罚回归 . . . 116
8.8 极值理论与尾部风险 . . . 117
8.8.1 GEV 与 GPD . . . 117
8.8.2 Hill 估计与阈值选择 . . . 119
8.9 数据清洗与平稳性 . . . 119
8.9.1 去极值与缺失值 . . . 119
8.9.2 平稳性与单位根 . . . 120
8.10 因果推断简介 . . . 120
8.11 代码实现：t 分布 MLE 与 POT/GPD . . . 120

第九章　时间序列分析 124
9.1　平稳性与模型识别 124
9.1.1　平稳性的两种定义 124
9.1.2　自相关函数与偏自相关函数 124
9.1.3　单位根检验：三种检验的逻辑差异 125
9.1.4　结构突变 126
9.2　ARMA 模型族：平稳性与可逆性 126
9.2.1　AR 模型与平稳性条件 126
9.2.2　MA 模型与可逆性 127
9.2.3　ARMA 与 ARIMA 127
9.2.4　季节模型 SARIMA 128
9.3　Box–Jenkins 建模流程 128
9.4　波动率建模：ARCH 与 GARCH 族 129
9.4.1　ARCH 模型 129
9.4.2　GARCH 模型与长期方差 130
9.4.3　GARCH 族的扩展 131
9.5　已实现波动率与 HAR 模型 132
9.5.1　已实现波动率 132
9.5.2　HAR 模型 132
9.6　状态空间模型与卡尔曼滤波 134
9.6.1　局部水平模型 134
9.6.2　卡尔曼滤波递推的推导 134
9.7　协整、误差修正与格兰杰因果 135
9.7.1　协整与配对交易 135
9.7.2　误差修正模型 136
9.7.3　Johansen 检验 136
9.7.4　格兰杰因果 137
9.8　深度学习时间序列模型 137
9.8.1　从 RNN 到 LSTM 137
9.8.2　Transformer 与面向时间序列的变体 139
9.8.3　金融场景下的训练技巧 139
9.9　预测评估与 VaR 回测 141
9.9.1　点预测指标 141
9.9.2　Diebold–Mariano 检验 141
9.9.3　VaR 回测 141
第十章　随机过程 145
10.1　随机过程基础 145
10.1.1　定义与分类 145
10.1.2　马尔可夫性质 145

10.1.3 鞅与 Doob–Meyer 分解 . . . 146
10.2 布朗运动 . . . 146
10.2.1 定义与基本性质 . . . 146
10.2.2 布朗运动的变换 . . . 147
10.3 伊藤积分 . . . 147
10.3.1 构造与伊藤等距 . . . 147
10.3.2 伊藤引理 . . . 148
10.4 随机微分方程 . . . 149
10.4.1 存在唯一性 . . . 149
10.4.2 Ornstein–Uhlenbeck 过程 . . . 149
10.5 跳跃过程 . . . 151
10.5.1 泊松过程与复合泊松过程 . . . 151
10.5.2 跳跃扩散模型与 Lévy 过程 . . . 151
10.5.3 二次变差与已实现方差 . . . 151
10.5.4 Lévy 过程与 Lévy–Khintchine 表示 . . . 152
10.6 鞅表示与市场完备性 . . . 152
10.7 测度变换与 Feynman–Kac 公式 . . . 153
10.7.1 Girsanov 定理 . . . 153
10.7.2 Feynman–Kac 公式 . . . 153
10.8 随机控制与美式期权 . . . 154
10.8.1 HJB 方程与 Merton 问题 . . . 154
10.8.2 Snell 包络与美式期权 . . . 154
第十一章 组合优化 . . . 157
11.1 记号、问题设定与目标 . . . 157
11.1.1 从信号到权重 . . . 157
11.1.2 有效前沿的解析式 . . . 158
11.1.3 无风险资产、切点组合与两基金分离 . . . 158
11.2 估计误差与错误放大 . . . 160
11.2.1 样本估计的噪声 . . . 160
11.2.2 错误放大机制 . . . 160
11.3 收缩估计与结构化协方差 . . . 161
11.3.1 Ledoit–Wolf 收缩 . . . 161
11.3.2 因子协方差 . . . 162
11.3.3 EWMA 与 DCC . . . 162
11.4 鲁棒组合优化 . . . 163
11.5 Black–Litterman 模型 . . . 164
11.6 风险平价与等风险贡献 . . . 165
11.6.1 风险贡献的定义与分解 . . . 165
11.6.2 ERC 的拉格朗日推导 . . . 166

11.7 分层风险平价与最大分散度 . . . 168
11.7.1 HRP 算法 . . . 168
11.7.2 最大分散度与最大去相关 . . . 168
11.8 Kelly 准则与分数 Kelly . . . 169
11.8.1 离散赌局的最优下注 . . . 169
11.8.2 连续情形与 Merton 解的关系 . . . 169
11.9 CVaR 组合优化与 Rockafellar–Uryasev 线性化 . . . 170
11.9.1 从方差到尾部风险 . . . 170
11.9.2 Rockafellar–Uryasev 线性化 . . . 171
11.10 交易成本、换手约束与多期优化 . . . 171
11.10.1 成本建模 . . . 171
11.10.2 多期与动态规划 . . . 172
11.11 动态组合管理：CPPI 与 Merton 解 . . . 172
11.11.1 买卖持有、常数混合与 CPPI . . . 172
11.11.2 Merton 解 . . . 173
11.12 绩效归因 . . . 174
11.12.1 Brinson 三效应分解 . . . 174
11.12.2 因子归因 . . . 175
11.13 绩效指标 . . . 176
11.13.1 核心指标与失效条件 . . . 176
11.13.2 年化与自相关修正 . . . 177
11.14 代码实现：cvxpy 求解 MVO 与 ERC . . . 177

第十二章 美国证券从业资格考试 . . . 181
12.1 SIE：证券行业基础考试 . . . 182
12.1.1 考试概述与知识领域 . . . 182
12.1.2 核心计算：债券收益率与税收等价 . . . 182
12.1.3 核心计算：期权基础盈亏 . . . 184
12.2 Series 7：通用证券代表 . . . 184
12.2.1 考试概述与知识领域 . . . 184
12.2.2 核心计算：保证金账户与追缴 . . . 184
12.3 Series 57：证券交易员 . . . 185
12.4 Series 65：统一投资顾问法律考试 . . . 186
12.4.1 核心计算：绩效指标 . . . 186
12.4.2 税后与通胀调整收益 . . . 187
12.5 Series 24：通用证券负责人 . . . 187
12.6 考证路径与量化从业者的取舍 . . . 189

附录 A 数学公式速查 . . . 191
A.1 常用概率分布 . . . 191

A.2 高斯积分与正态分布结论 . . . 191
A.3 矩阵代数与向量求导 . . . 192
A.4 概率论常用结论 . . . 193
A.5 随机分析核心公式 . . . 194
A.6 常用泰勒展开与近似 . . . 194
A.7 希腊字母表 . . . 196
A.8 数值方法速查 . . . 196

附录 B Python 量化工具链 . . . 197
B.1 环境与依赖 . . . 197
B.2 数据读取与清洗 . . . 198
B.3 描述统计与肥尾检验 . . . 198
B.4 波动率建模 . . . 199
B.5 因子研究 . . . 199
B.6 组合优化 . . . 200
B.7 衍生品定价 . . . 201
B.8 工程实践要点 . . . 202

附录 C 术语中英对照 . . . 203
C.1 市场与产品 . . . 203
C.2 定价与随机分析 . . . 204
C.3 统计、计量与机器学习 . . . 204
C.4 组合、风险与交易 . . . 205
C.5 金融科技、Web3 与监管 . . . 206

参考文献 . . . 208

第一章 金融入门

本章为全书建立金融学的概念底座与符号约定。量化方法之所以能在金融领域生效，是因为金融资产的价格、收益与风险可以被写成可计算的对象：现金流是时间序列，折现率是期限的函数，风险是随机变量的二阶或高阶矩。因此本章的目标不是罗列金融产品，而是把「金融语言」翻译成后面十章反复使用的数学语言。

核心要点 1.1

金融的本质是跨期资源配置：把资金富余部门的储蓄，通过金融工具与金融中介，引导到资金短缺部门的投资活动中。这一过程中同时发生两类交换——时间维度的交换（放弃今天的消费换取未来的现金流）与风险维度的交换（把不确定的现金流重新分配给愿意承担风险的一方）。任何金融工具的价格，都是这两类交换的定价结果。

1.1 金融体系概览

金融体系（Financial System）由四个支柱构成：金融市场（价格发现与流动性）、金融中介（信息生产与风险转换）、金融工具（权利义务的合约化）与监管框架（外部性与系统性风险的约束）。

1.1.1 货币市场与资本市场工具对比

按剩余期限划分，一年以内的债务工具属于**货币市场**（Money Market），一年以上属于**资本市场**（Capital Market）。两者的差异不只是期限，更在于信用风险结构、二级市场流动性与定价基准，见表 表 1.1。

回购协议的定价逻辑值得单独说明。若交易商以面值 F 的国债作抵押融入现金 P，约定 n 天后以 $P(1+R_{\text{repo}}\,n/360)$ 回购，则 R_{repo} 是隐含的抵押贷款利率。由于抵押品在违约时可直接被处置，回购利率通常显著低于同期限的无担保拆借利率，二者的差额被称为**抵押品便利**（collateral convenience）。2008 年危机中，回购市场因抵押品折价（haircut）突然上升而冻结，说明即使有抵押，流动性风险也不会自动消失。

1.1.2 一级市场、二级市场与流动性

一级市场（Primary Market）承担融资功能：发行人通过首次公开发行（IPO）、增发或债券发行获得资金。**二级市场**（Secondary Market）承担流动性功能：已发行证券在投资者之间转手，发行人不再获得资金。二级市场的存在反过来决定一级市场的发行成本——若一只股票无法在二级市场快速变现，投资者会要求更高的预期收益，发行折价随

表 1.1　货币市场与资本市场主要工具对比

工具	市场	期限与特征	定价与风险要点
国库券（T-bill）	货币	3、6、12 个月，贴现发行	以贴现率报价，信用风险近似为零，是短期无风险基准
商业票据（CP）	货币	最长 270 天（美国惯例）	由高评级企业发行，属无担保，展期风险是核心风险
大额存单（CD）	货币	3–12 个月，可转让	银行负债，二级市场存在报价价差，利率高于同期国库券
回购协议（Repo）	货币	隔夜至数月，以证券抵押融资	本质是抵押贷款；回购利率是货币市场最重要的资金价格
国债（T-note/Bond）	资本	2–30 年，附息	构建收益率曲线的基准，价格对利率高度敏感
公司债（Corporate）	资本	1–30 年，附息	收益率 = 基准利率 + 信用价差，含违约与流动性溢价

之扩大。

流动性可以从三个维度刻画：**宽度**（买卖价差）、**深度**（报价数量）、**弹性**（大额交易后价格恢复的速度）。三者不可混淆：价差很窄但深度不足的市场，遇到大单时同样会剧烈波动。

1.1.3　交易所、场外市场与做市商

交易所市场采用集中撮合、标准化合约与中央对手方清算，价格与成交信息透明；场外市场（OTC）由做市商双边报价，合约可以定制，但信息披露有限，2008 年前的信用违约互换市场即是典型。OTC 的替代品是「交易所化」：把标准化合约移入中央清算所，用保证金与逐日盯市控制对手方风险。

实务应用　做市商如何赚钱

做市商（Market Maker）同时挂出买价与卖价，以价差补偿三类成本：订单处理成本、库存风险的持有成本、以及与被更知情交易者成交的逆向选择成本。若某只股票报价为 10.00/10.02（单位：元），价差 0.02 元对应 20 个基点；做市商每成交一个来回获得 0.02 元，但若库存期间价格不利变动 0.10 元，则需成交 5 个来回才能弥补。这解释了为什么波动率上升时价差几乎同步扩大。

1.2 权益与固定收益工具

1.2.1　股利折现模型与 Gordon 增长模型

股票代表对公司剩余现金流的索取权，其内在价值等于未来股利的折现值：

$$P_0 = \sum_{t=1}^{\infty} \frac{D_t}{(1+r)^t} \tag{1.1}$$

其中 P_0 为当前股价，D_t 为第 t 期每股股利，r 为与该股票风险匹配的要求回报率。若股利以恒定速度 g 永续增长，即 $D_t = D_1(1+g)^{t-1}$，代入 式 (1.1) 得几何级数，在 $r > g$ 时收敛为 Gordon 增长模型：

$$P_0 = \frac{D_1}{r-g}, \qquad r > g \tag{1.2}$$

式 (1.2) 在实务中常被反解为资本成本：$r = D_1/P_0 + g$，即股利收益率加股利增长率。但这一定价式的稳健性很差。当 r 与 g 接近时，分母趋于零，估值对参数极端敏感：设 $D_1 = 1$ 元，$r = 8\%$，若 g 从 4% 升至 5%，价格从 25 元跳到 33.3 元，涨幅 33%；而一家长期增长率不可能高于名义 GDP 增速的企业，取值 $g = 5\%$ 本身就需要论证。

⚠ 风险警示　Gordon 模型的失效条件

该模型假定增长率恒定且永不超过折现率，忽略了高增长阶段的再投资回报与竞争格局变化。对不分红、周期性极强、或处于成长早期的公司，模型会给出无意义的结果。实务做法是两阶段或三阶段模型：前 n 年用显式预测股利，之后用 式 (1.2) 计算终值，再对终值部分单独做敏感性分析。

1.2.2　债券定价与到期收益率

附息债券的价格等于票息年金与面值现值之和：

$$P = \sum_{t=1}^{n} \frac{C}{(1+y)^t} + \frac{F}{(1+y)^n} \tag{1.3}$$

其中 C 为每期票息，F 为面值，n 为剩余付息期数，y 为到期收益率（Yield to Maturity，YTM）。**到期收益率**的定义是：使未来全部现金流的现值恰好等于当前价格的单一折现率。它是一个内部收益率，而非可观测的市场利率：想要得到 y，必须解一个 n 次多项式方程，实务上靠数值求根。

式 (1.3) 给出三条可用于校验直觉的性质：当 $y = C/F$ 时，价格等于面值（平价债券）；当 y 高于票息率时价格低于面值（折价债券）；y 上升，价格下降，且价格函数关于 y 是凸的。这三条性质在久期与凸性的讨论中被两次求导放大。

1.2.3　久期：四种解释

久期是债券分析中最重要的单一指标，也是被误用最多的指标。它至少有四种等价的解释。

定义 1.1　麦考利久期与修正久期

以到期收益率 y 折现，麦考利久期（Macaulay Duration）定义为现金流到期时间的现值加权平均：

$$D = \frac{\sum_{t=1}^{n} t \cdot PV(CF_t)}{P}, \qquad PV(CF_t) = \frac{CF_t}{(1+y)^t} \tag{1.4}$$

修正久期（Modified Duration）定义为 $D^* = D/(1+y)$，对半年付息一次且按年复利报价的债券，y 与付息频率须一致，通常写作 $D^* = D/(1+y/f)$。

小节 1.2.3 中的 D 有四种读法：

- **加权平均回款时间**：D 是投资者实际收回本息的平均等待年限。零息债券的 D 等于到期期限，付息债券的 D 严格小于到期期限，且票息越高 D 越短。
- **价格对收益率的一阶敏感度**：把价格写成 $P = \sum_t CF_t(1+y)^{-t}$ 并对 y 求导，得到 $\mathrm{d}P/\mathrm{d}y = -\frac{1}{1+y}\sum_t t\,PV(CF_t)$，而右侧求和的系数恰好是 $-D^*P$，于是有式 (1.5)。
- **现金流期限的平衡点**：D 是使资产与负债的利率风险相互抵消的期限匹配条件，这正是免疫策略的基础。
- **回收期的反面**：D 与会计上的回收期（payback period）完全不同，前者考虑货币时间价值与全部现金流，后者只数够本金的年数。

1.2.4　久期近似、DV01 与凸性修正

由一阶泰勒展开得到久期近似公式：

$$\frac{\Delta P}{P} \approx -D^* \,\Delta y \tag{1.5}$$

其中 Δy 为到期收益率的绝对变化（如 0.01 表示 100 个基点），D^* 为修正久期。另一个常用口径是基点价值（DV01，Dollar Value of a Basis Point），即收益率变动一个基点时债券价格的绝对变化：

$$\mathrm{DV01} = P \times D^* \times 10^{-4} \tag{1.6}$$

式 (1.6) 中系数 10^{-4} 对应一个基点（0.01%）。若某债券 $P = 100$ 元、$D^* = 6$，则 $\mathrm{DV01} = 0.06$ 元；对冲 1000 万元面值头寸所需的空头名义本金为 $1000 \times 6 = 6000$ 万元（用同一只债券对冲时按市值折算）。

久期近似只在 $|\Delta y|$ 很小时可靠，因为价格函数是凸的：收益率上升带来的价格下跌，小于收益率同等幅度下降带来的价格上涨。二阶项由凸性给出：

$$C_{\mathrm{conv}} = \frac{1}{P}\cdot\frac{1}{(1+y)^2}\sum_{t=1}^{n}\frac{t(t+1)\,CF_t}{(1+y)^t} \tag{1.7}$$

其中 CF_t 为第 t 期总现金流，$t(t+1)$ 权重来自二阶导数的系数。于是价格变动可以写为

$$\frac{\Delta P}{P} \approx -D^{*}\,\Delta y + \tfrac{1}{2}\,C_{\text{conv}}\,(\Delta y)^{2} \tag{1.8}$$

式 (1.8) 的第二项恒为非负，这正是「凸性是持有者的资产」的说法来源：在其他条件相同时，凸性越大的债券，在收益率大幅波动时的表现越好。

例 1.1　久期与凸性的数值修正

一张面值 100 元、票息率 5%、每年付息、3 年后到期的债券，当前 YTM 为 6%。由 式 (1.3) 得到现金流现值：第 1 年 $5/1.06 = 4.71698$，第 2 年 $5/1.06^{2} = 4.44998$，第 3 年 $105/1.06^{3} = 88.16332$，合计 $P = 97.33028$ 元。

由 式 (1.4)，加权时间之和为 $1\times 4.71698 + 2\times 4.44998 + 3\times 88.16332 = 278.12590$，故 $D = 278.12590/97.33028 = 2.8575$ 年，修正久期 $D^{*} = 2.8575/1.06 = 2.6957$ 年。

由 式 (1.7)，二阶加权和为 $1\cdot 2\cdot 4.71698 + 2\cdot 3\cdot 4.44998 + 3\cdot 4\cdot 88.16332 = 1110.36440$，故 $C_{\text{conv}} = 1110.36440/(97.33028\times 1.06^{2}) = 10.1503$，基点价值 DV01 $= 97.33028\times 2.6957\times 10^{-4} = 0.02624$ 元。

若收益率上升 100 个基点至 7%，精确重算得 $P' = 94.75137$ 元，实际跌幅 2.6504%。久期近似给出 -2.6957%，误差 4.5 个基点；凸性修正给出 $-2.6957\% + 0.5\times 10.1503\times 0.01^{2} = -2.6449\%$，误差收窄到 0.55 个基点，即精度提高约 8 倍。这就量化了 式 (1.8) 中二阶项的价值。

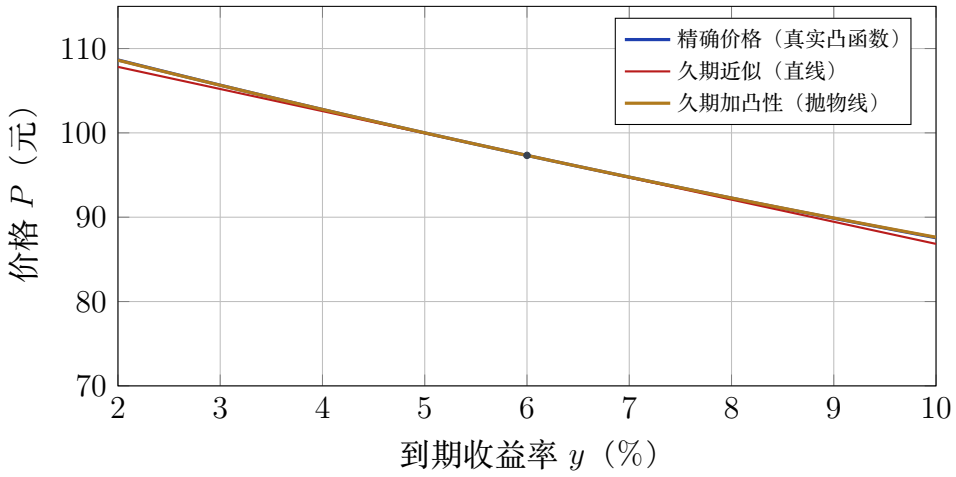


图 1.1　久期近似与凸性修正对债券价格的拟合效果

图 1.1 把 小节 1.2.4 的结论可视化：久期近似的直线在 $y = 6\%$ 附近贴合精确曲线，但向两侧迅速偏离；加上凸性项后，抛物线在 2% 至 10% 的整个区间几乎与精确价格重合。这正是风险管理中「凸性调整」的意义。

直觉理解　为什么凸性是好事

想象价格曲线是一张绷紧的弓。收益率上升与下降幅度相同时，弓的上弯让价格少跌多涨。用数学语言说，$\Delta P/P$ 关于 Δy 的二阶导数为正，因此 $P(y)$ 是凸函数，

由 Jensen 不等式，随机收益率下的平均价格高于按平均收益率定价的结果。这就是「波动率本身有价值」这一命题在债券上的第一次出现，第 4 章的期权价值与之同源。

1.2.5 久期对冲与免疫策略

久期匹配提供了两个经典应用。其一是**对冲**：若持有债券组合的 DV01 为 V，卖空另一只 DV01 为 v 的债券（或利率期货）数量 V/v，可使组合的净利率风险瞬时归零。其二是 **免疫**（Immunization）：养老基金的负债是一串确定的支付流，具有自己的久期 D_L。只要使资产久期 D_A 等于负债久期 D_L、且资产现值不小于负债现值，则收益率的微小变动对双方现值的影响相互抵消。若同时再令资产凸性 $C_A \geq C_L$，则在大幅波动下资产端仍占优，这就是所谓「免疫的充分条件」。

⚠ 风险警示　免疫是瞬时的

久期与凸性都随收益率与剩余期限变化：时间每过去一天，D_A 与 D_L 的缩短速度通常不同（除非资产与负债的现金流结构完全一致）。因此免疫必须**定期再平衡**，实务中按月或按收益率变动阈值触发调整。此外，久期对冲只消除收益率曲线**平行移动**的风险；若曲线发生扭曲（如 2 年下降、10 年上升），仅靠总久期中性仍会亏损，需要引入关键期限久期（key rate duration）做分点对冲。

1.2.6 股票指数编制方法

股票指数是把一组股票价格压缩为一个数字的规则，规则本身决定了指数的风险特征。三种主流加权方式及其含义见表 表 1.2。

表 1.2　股票指数编制方法与含义差异

加权方式	权重定义	代表性指数	含义与偏差
价格加权	$w_i = P_i / \sum_j P_j$	道琼斯工业平均指数	高价股影响被放大，与公司规模无关；拆股会使权重突变
市值加权	$w_i = P_i Q_i / \sum_j P_j Q_j$	标普 500、沪深 300	隐含「市场组合」，动量自我强化；大盘股主导，集中度上升
等权	$w_i = 1/N$	标普等权指数	隐含定期再平衡，天然具有反转（逆向）暴露；小盘股与流动性溢价更明显

一个数值例子能说明差异的量级。设三只股票价格分别为 100、50、10 元，市值分别为 2000、1000、100 亿元。价格加权下权重为 62.5%、31.25%、6.25%；市值加权下为 64.5%、32.3%、3.2%。若第三只股票上涨 50% 而另两只不动，价格加权指数上涨 3.1%，市值加权指数仅上涨 1.6%，等权指数则上涨 16.7%。同一批股票，收益相差十倍，说明「指数收益」这一说法必须附带加权方式才有意义。

补充说明　指数的可投资性

指数只有可复制才有投资价值。价格加权指数难以被精确复制（需按价格比例配置且受拆股扰动），因此追踪道指的基金必须持有大量现金以应对权重漂移。市值加权指数的可复制性最好，但需按自由流通市值（free float）调整权重，否则会高估战略持股比例高的公司权重——这是 MSCI 与标普在 2000 年代调整编制规则的主要原因。

1.3 财务报表分析与勾稽关系

三大报表并非三张独立的表，而是同一套经济活动的三个切面，通过**勾稽关系**相互约束。

1. **资产负债表**（Balance Sheet）：资产 = 负债 + 所有者权益，是某一时点的存量快照。
2. **利润表**（Income Statement）：收入 − 费用 = 净利润，是某一期间的流量记录；净利润扣除股利后进入资产负债表的留存收益。
3. **现金流量表**（Cash Flow Statement）：把权责发生制的净利润还原为收付实现制的现金变动，并区分经营、投资、融资三类活动；期末现金余额必须与资产负债表的货币资金衔接。

最重要的勾稽链条可以写成一条恒等式：**净利润**经非现金项目与营运资本调整得到 **经营活动现金流**，扣除资本支出得到**自由现金流**，自由现金流加上净融资额等于现金余额的变动。若一家公司连续三年净利润为正而经营活动现金流为负，通常意味着收入确认激进或应收账款异常膨胀，这是量化筛选中最常用的造假预警信号之一。

1.3.1　杜邦分解

净资产收益率（ROE）可以分解为三项乘积，每一项对应一种商业模式的驱动来源：

$$ROE = \frac{NI}{E} = \frac{NI}{S} \times \frac{S}{A} \times \frac{A}{E} = \text{净利率} \times \text{总资产周转率} \times \text{权益乘数} \tag{1.9}$$

其中 NI 为净利润，S 为营业收入，A 为总资产，E 为所有者权益。净利率反映定价能力与成本控制，总资产周转率反映资产使用效率，权益乘数 A/E 反映财务杠杆。

例 1.2　同样 15% 的 ROE，风险并不相同

甲公司走高价路线：净利率 20%，周转率 0.25，权益乘数 3.0，则 $ROE = 0.20 \times 0.25 \times 3.0 = 15\%$。乙公司走薄利多销路线：净利率 3%，周转率 2.0，权益乘数 2.5，则 $ROE = 0.03 \times 2.0 \times 2.5 = 15\%$。两家公司的股东回报相同，但风险结构完全不同：甲公司的利润依赖价格维持，一旦降价 20% 且成本刚性，净利率降至零；乙公司的利润依赖销量与周转，对需求冲击更敏感，但成本端具有规模弹性。若把甲公司的权益乘数从 3.0 提到 4.0 而其余不变，ROE 变为 20%，看似改善，实际是用更高的偿债压力换来的——这就是为什么杜邦分解必须连同资产负债率与利息覆盖倍数一起读。

表 1.3　核心财务比率分类与经验区间

类别	比率	计算式	解读与经验区间
盈利能力	净资产收益率 ROE	NI/E	长期可持续水平受行业竞争与杠杆约束
	总资产收益率 ROA	NI/A	剔除杠杆影响的经营效率指标
偿债能力	流动比率	CA/CL	通常 1.5 至 2.0；过高可能意味资产闲置
	利息覆盖倍数	$EBIT/I$	低于 3 时再融资风险显著上升
运营效率	总资产周转率	S/A	零售与快消可超过 2，重资产行业常低于 0.5
估值指标	市盈率 P/E	P/EPS	与增长率匹配时才可比，需区分静态与滚动口径
	市净率 P/B	$P/BVPS$	适用于净资产为价值主体的金融业

表 1.3 中的比率在量化选股中通常被进一步处理：先做行业中性化，再做极值处理，最后转成横截面排名，原因见第 7 章的因子构建流程。

1.4 资本预算：NPV 与 IRR

企业投资决策的核心判据是净现值（Net Present Value，NPV）：

$$\mathrm{NPV} = -C_0 + \sum_{t=1}^{T} \frac{C_t}{(1+r)^t} \tag{1.10}$$

其中 C_0 为初始投资（正值计），C_t 为第 t 期净现金流，r 为与项目风险匹配的资本成本。NPV 的经济含义是项目为企业股东创造的价值增量，因此决策规则是：独立项目取 $\mathrm{NPV} > 0$，互斥项目取 NPV 最大者。内部收益率（Internal Rate of Return，IRR）定义为使 NPV 等于零的折现率：

$$-C_0 + \sum_{t=1}^{T} \frac{C_t}{(1+\mathrm{IRR})^t} = 0 \tag{1.11}$$

IRR 的决策规则是与资本成本比较，取 $\mathrm{IRR} > r$。两个指标在独立项目上一致，但在互斥项目与非常规现金流下会冲突：IRR 是比率，忽略项目规模；且 式 (1.11) 是 T 次方程，符号变化多次时可能存在多个 IRR 或无实数解。

例 1.3　NPV 与 IRR 的冲突

两个互斥项目，资本成本 $r = 8\%$。项目 A 投资 100 万元，此后三年每年回收 41 万元；项目 B 投资 300 万元，此后三年每年回收 118 万元。由 式 (1.10)：A 的 $\mathrm{NPV} = -100 + 41 \times 2.5771 = 5.66$ 万元，IRR 约 11.0%；B 的 $\mathrm{NPV} = -300 + 118 \times 2.5771 = 4.10$ 万元，IRR 约 9.3%。按 IRR 应选 A，按 NPV 也应选 A。若把 B 的年现金流改为 125 万元，则 $\mathrm{NPV} = -300 + 125 \times 2.5771 = 22.14$ 万元，IRR 约 12.0%，此时两个判据仍一致。真正的冲突出现在「高 IRR、小规模」与「低 IRR、大规模」之间：把 A 改为投资 100 万元、年回收 45 万元（IRR 约 16.4%，NPV = 15.97 万元），B 保持年回收 125 万元（NPV = 22.14 万元），IRR 指向 A 而 NPV 指向 B。正确做法是坚持 NPV，因为 NPV 度量的是价值绝对增量，而 IRR 无法比较不同规模的增量投资回报。实务中还常用增量 IRR：对 B 相对 A 的增量现金流求 IRR，再与资本成本比较。

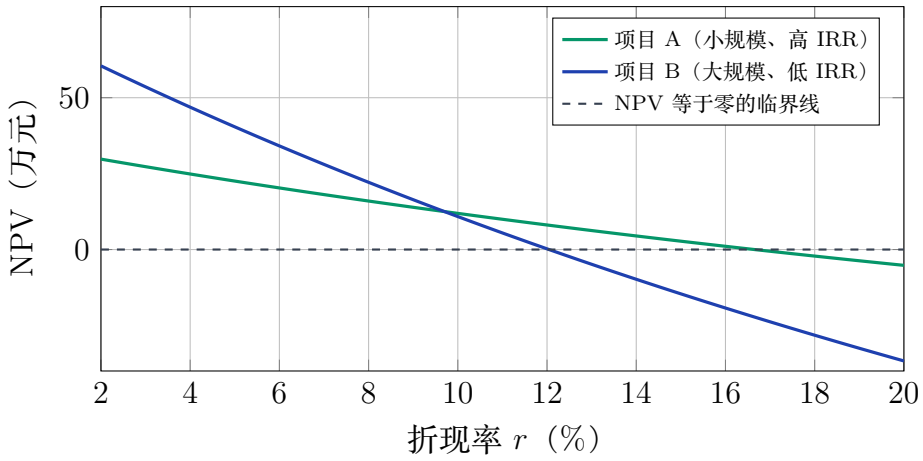


图 1.2　互斥项目的 NPV 曲线与 IRR 冲突

图 1.2 显示两条曲线在 $r \approx 10.4\%$ 处相交，该折现率称为**交叉率**。当资本成本低于交叉率时，项目 B 的 NPV 更高；高于交叉率时项目 A 更高——这解释了为什么低利率环境下企业倾向于投资大规模、长回收期的项目。

1.5 利率的期限结构

1.5.1　名义利率的分解

名义利率可以分解为三个部分：

$$r_{\text{nom}} = r_{\text{real}} + \pi^{e} + RP \tag{1.12}$$

其中 r_{real} 为实际无风险利率（反映社会的时间偏好与资本边际产出），π^{e} 为预期通胀率，RP 为风险溢价，包含违约风险、流动性风险与期限风险。注意 式 (1.12) 是可加形式的近似；精确的 Fisher 关系为 $(1 + r_{\text{nom}}) = (1 + r_{\text{real}})(1 + \pi^{e})$，在低通胀下两者差异为二阶小量，但在高通胀经济体（$\pi^{e} > 10\%$）必须以乘法形式计算。

1.5.2 即期利率、远期利率与三大理论

收益率曲线描述的是不同期限的即期利率 $y(0,T)$。由无套利关系，期限 T_1 与 T_2 之间的远期利率 $f(T_1,T_2)$ 由即期利率唯一确定：

$$\big(1+y(0,T_2)\big)^{T_2}=\big(1+y(0,T_1)\big)^{T_1}\big(1+f(T_1,T_2)\big)^{T_2-T_1} \tag{1.13}$$

式 (1.13) 的意思是：先投资到 T_2，与先投资到 T_1 再按远期利率续投到 T_2，两条路径必须给出相同的累计回报，否则套利者可以无风险获利。曲线的形态则由三个竞争性理论解释，见表 表 1.4。

表 1.4　收益率曲线三大理论对比

理论	核心主张	对上升曲线的解释	主要弱点
纯预期理论	远期利率等于市场对未来即期利率的预期	上升曲线意味着市场预期加息	忽略期限风险，无法解释长期平均向上的曲线形态
流动性偏好理论	投资者要求期限溢价补偿利率风险	上升曲线 = 加息预期 + 期限溢价	期限溢价本身不可直接观测，需模型估计
市场分割理论	各期限市场由不同资金供需主体分割	不同期限的供需失衡造成曲线形状	忽略套利力量，与曲线常同步移动的事实不符

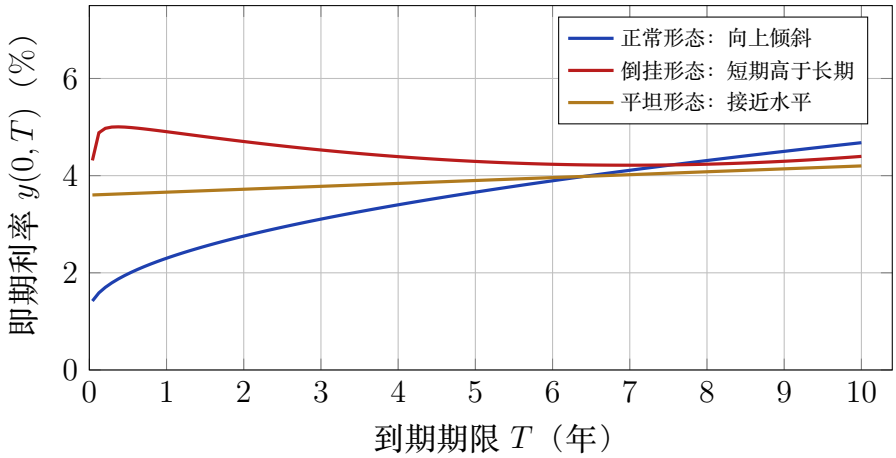


图 1.3　收益率曲线的三种典型形态（示意）

图 1.3 给出三种形态的示意。其中倒挂形态最具信息含量：短端利率由货币政策决定，长端由增长与通胀预期决定，当央行大幅收紧而市场预期未来增长走弱时，曲线倒挂。经验上，美国 2 年期与 10 年期国债利差转负之后，衰退通常在随后一至两年内出现，但 **倒挂是信号而非机制**：它给出概率倾向，给不出时点与幅度，且样本量极小（半个多世纪不足十次），任何把倒挂当作交易触发器的做法都要面对统计功效不足的问题。

⚠ 风险警示　期限结构的常见误用

第一，把远期利率直接当成市场预期。远期利率包含期限溢价与流动性溢价，当溢价波动时，远期利率的变化方向甚至可以与预期相反。第二，用历史平均利差做「均值回复」交易。在政策体制切换（如量化宽松的引入与退出）时，利差的均衡水平本身发生位移，历史均值不再是稳定的吸引子。第三，用单一曲线为所有信用等级的债券贴现。正确的做法是基准曲线加信用价差，而信用价差在危机中会与基准利率同时扩大，二者并非独立变量。

1.6 有效市场假说与行为金融

1.6.1　三个层次的效率与检验方式

Eugene Fama 将市场效率分为弱式、半强式与强式三个层次，每一层次对应一类可检验的命题：

- **弱式有效**：价格已反映全部历史交易信息，技术分析不能产生超额收益。检验方式是收益率的自相关检验与游程检验。
- **半强式有效**：价格已反映全部公开信息，基本面分析不能产生超额收益。检验方式是**事件研究**（event study）：计算事件窗口内的异常收益 $AR_t = R_t - \mathbb{E}[R_t \mid \text{因子模型}]$，再检验累计异常收益 CAR 是否显著为零。
- **强式有效**：价格反映包括内幕信息在内的全部信息，任何投资者都无法获得超额收益。检验方式是考察内部人交易与专业基金经理的业绩持续性。

1.6.2　异象与 Grossman–Stiglitz 悖论

动量效应（过去 3 至 12 个月的赢家在未来数月继续跑赢）与价值效应（低 P/B 组合长期跑赢高 P/B 组合）是最常被引用的两个异象。但异象的存在本身不等于市场无效：数据挖掘、样本外衰减、交易成本与容量约束都可能吞掉全部超额收益。这正是 Grossman 与 Stiglitz 在 1980 年提出的悖论：如果价格已经反映了全部信息，就没有人有动机去搜集信息；但如果没有人搜集信息，价格又不可能有效。因此真实市场必然处于**近似有效**状态，有效程度由信息搜集的边际成本决定。这一结论对量化从业者有直接含义——**超额收益的来源必然是某种信息优势或成本优势**，而不可能是「更聪明地算同一个数」。

实务应用　在量化研究中使用异象的三条纪律

其一，异象必须能在扣除交易成本后存活，尤其在换手率高时，需要用实施缺口（implementation shortfall）而非收盘价回测。其二，必须做样本外与多重检验校正：测试 100 个信号，即便全部无效，也会有约 5 个在 5% 水平显著，第 7 章讨论的 Deflated Sharpe Ratio 与 PBO 是标准处理。其三，必须问「谁在提供这笔超额收益」：若找不到对手方与交易动机，大概率是数据错误或幸存者偏差。

1.6.3 前景理论的价值函数

Kahneman 与 Tversky 的前景理论把决策权重从客观概率改为**概率权重** $\pi(p)$，把效用改为定义在盈亏上的**价值函数**：

$$v(x) = \begin{cases} x^{\alpha}, & x \geq 0, \\ -\lambda\,(-x)^{\beta}, & x < 0, \end{cases} \qquad \alpha, \beta \in (0, 1],\ \lambda > 1 \tag{1.14}$$

其中 x 为相对于参考点（reference point）的盈亏，α 与 β 为曲率参数，刻画边际敏感性递减，λ 为**损失厌恶系数**。Kahneman 与 Tversky 的实验估计 $\alpha \approx \beta \approx 0.88$、$\lambda \approx 2.25$，即同等金额的损失带来的痛苦约为收益带来快乐的两倍以上。

这两个参数直接映射到金融现象：$\lambda > 1$ 解释为什么投资者持有亏损股票过久、过早卖出盈利股票（处置效应）；v 在收益区的凹性解释为什么面对确定性收益时投资者风险厌恶；v 在损失区的凸性解释为什么面对确定性损失时投资者反而追求风险（赌一把）。

⚠ 风险警示　前景理论不是交易策略

价值函数中的参考点无法事先观测，λ 与 α 的估计值依赖实验任务、金额量级与文化背景，个体间差异极大。更重要的是，很多所谓「行为异象」在加入交易成本后会消失。把前景理论当作预测工具使用时，必须先明确参考点的可操作定义（如持仓成本、前期高点或指数基准），否则模型无法给出可检验的预测。

1.7 市场参与者与交易机制

1.7.1 参与者类型

- **散户投资者**（Retail Investors）：资金规模小、信息劣势明显，但其情绪波动本身构成可交易信号。
- **机构投资者**（Institutional Investors）：养老基金、主权财富基金、保险公司、共同基金与对冲基金。其委托代理结构决定了考核周期与风险约束。
- **做市商**（Market Makers）：提供双边报价并承担库存风险，收益来自价差。
- **高频交易商**（HFT）：以微秒级延迟捕捉订单流信息与跨市场价差，提供流动性的同时也在特定时刻消耗流动性。
- **监管机构**：美国证券交易委员会（SEC）、中国证券监督管理委员会（CSRC）、英国金融行为监管局（FCA）等，负责信息披露、市场秩序与系统性风险防范。

1.7.2 订单类型与交易成本

最常见的订单类型包括市价单（以当前对手价立即成交，承担价格不确定性）、限价单（指定价格，承担不能成交的风险）、以及止损单（触发后转为市价单）。订单类型的差异本质上是**执行风险**与**机会成本**之间的权衡：急迫的交易者用市价单支付价差，耐心的交

易者用限价单卖出流动性并面临逆向选择。量化策略的实盘表现与回测表现的差距，主要来自这一权衡的误估，相关方法在后续章节关于最优执行与交易成本模型的讨论中展开。

核心要点 1.2　本章的三个基础关系

一是价值关系：任何资产的价格等于其未来现金流按风险匹配折现率折现的现值，见 式 (1.1) 与 式 (1.3)。二是风险关系：价格对风险因子的敏感度可以泰勒展开，一阶项是久期或 Δ，二阶项是凸性或 Γ，见 式 (1.8)。三是信息关系：市场的有效程度由信息生产的边际成本决定，见 Grossman–Stiglitz 悖论。这三条关系在后续几乎所有章节中反复出现。

Listing 1.1　债券久期、凸性、DV01 与久期近似的数值验证

```python
import numpy as np

def bond_risk(face, coupon_rate, ytm, years, freq=1):
    """Price, Macaulay/modified duration, convexity and DV01 of a plain bond."""
    n = int(years * freq)
    c = face * coupon_rate / freq
    t = np.arange(1, n + 1)
    cf = np.full(n, c)
    cf[-1] += face
    disc = (1.0 + ytm / freq) ** (-t)
    pv = cf * disc
    price = pv.sum()
    mac = (t * pv).sum() / (price * freq)
    mod = mac / (1.0 + ytm / freq)
    conv = (pv * t * (t + 1)).sum() / (price * (1.0 + ytm / freq) ** 2) / freq ** 2
    dv01 = price * mod * 1e-4
    return price, mac, mod, conv, dv01

def price_at(face, coupon_rate, ytm, years, freq=1):
    n = int(years * freq)
    c = face * coupon_rate / freq
    t = np.arange(1, n + 1)
    cf = np.full(n, c)
    cf[-1] += face
    return float((cf * (1.0 + ytm / freq) ** (-t)).sum())

p, mac, mod, conv, dv01 = bond_risk(100.0, 0.05, 0.06, 3.0)
print("price=%.5f  D=%.4f  D*=%.4f  C=%.4f  DV01=%.5f" % (p, mac, mod, conv, dv01))

dy = 0.01
p1 = price_at(100.0, 0.05, 0.06 + dy, 3.0)
approx = -mod * dy
with_conv = -mod * dy + 0.5 * conv * dy ** 2
print("exact=%.4f%%  dur_only=%.4f%%  dur_conv=%.4f%%"
```

```
        % (100 * (p1 - p) / p, 100 * approx, 100 * with_conv))
# expected: exact=-2.6504%  dur_only=-2.6957%  dur_conv=-2.6449%
```

Listing 1.1 把 小节 1.2.4 的手算过程写成可复用的函数：改变 `coupon_rate` 或 `freq` 即可观察票息与付息频率对久期的影响。运行最后三行会打印出与手算一致的结果，可用于验证定价与风险指标的实现是否自洽。

本章小结

- 金融体系的功能是跨期与跨风险的资源配置；货币市场工具（国库券、商业票据、大额存单、回购）以低信用风险与高流动性为特征，是短期资金价格的基准。
- 资产定价的统一框架是「未来现金流按风险匹配折现率折现」：股利折现模型见式 (1.1)，债券定价见 式 (1.3)。
- 久期有四种解释（加权回款时间、一阶敏感度、期限平衡点、与回收期的区别），修正久期给出价格对收益率的一阶近似 式 (1.5)，凸性项 式 (1.8) 是二阶修正。
- DV01 把久期转成绝对金额，用于久期对冲与负债免疫；免疫只在瞬时成立，必须定期再平衡。
- 指数编制方式（价格加权、市值加权、等权）在同样标的上涨跌可以相差数倍，讨论「指数收益」必须说明加权规则。
- 三大报表通过净利润、留存收益与现金余额三条勾稽链相互约束；杜邦分解式 (1.9) 把 ROE 拆成盈利、效率与杠杆三类驱动。
- 资本预算以 NPV 为首要判据，IRR 在互斥项目与非常规现金流下会误导，必要时改算增量 IRR。
- 期限结构由预期、期限溢价与市场分割共同决定；远期利率由无套利关系式 (1.13) 确定，不能等同于市场预期。
- 市场效率由信息生产的边际成本决定(Grossman–Stiglitz)，前景理论用 式 (1.14) 刻画损失厌恶，但参考点不可观测。

练习与思考

1. 一张面值 1000 元、票息率 4%、每年付息、5 年到期的债券，当前 YTM 为 5%。请计算价格、麦考利久期、修正久期、凸性与 DV01，并用 式 (1.8) 估计 YTM 上升 50 个基点后的价格，与精确价格比较误差。
2. 某养老基金需在 8 年后支付 5000 万元，负债的修正久期为 7.4 年。现有两只债券：A 的修正久期 4.2 年、凸性 22，B 的修正久期 11.5 年、凸性 140。请给出免疫组合的权重，并说明为什么不选择全部持有 B。
3. 用 式 (1.13) 计算：若 1 年期即期利率为 3.0%、3 年期即期利率为 3.3%，求第 2 年至第 3 年的远期利率。若实际 1 年期远期利率报价为 4.0%，说明存在什么样的套利机会。

4. 三只股票的股价为 20、40、60 元，股数为 10、5、2 亿股。分别构造价格加权与市值加权指数（基期为 1000 点）。若第三只股票单日上涨 10%、其余不变，两种指数分别变动多少点？

5. 某公司净利率 8%、总资产周转率 1.2、权益乘数 2.0。若管理层希望把 ROE 提升到 25%，在净利率与周转率均无法改善的前提下，权益乘数需要达到多少？并说明这一变化对利息覆盖倍数的影响。

6. 设计一个事件研究方案，检验「并购公告后目标公司股价是否已充分反映信息」。需要给出事件窗口、估计窗口、异常收益的基准模型与统计检验量，并说明结果不显著时可能的三种解释。

7. 假设投资者的价值函数为 式 (1.14)，$\alpha = \beta = 0.88$，$\lambda = 2.25$，参考点为持仓成本。请计算盈利 10% 与亏损 10% 的价值函数值之比，并解释该比率如何产生处置效应。

延伸阅读

- Bodie, Z., Kane, A., and Marcus, A., *Investments*, 12th ed., McGraw-Hill, 2020.（第 2–3 章讲市场结构与工具，第 13–14 章讲久期与免疫，术语体系与本章一致）
- Fabozzi, F., *Bond Markets, Analysis, and Strategies*, 10th ed., MIT Press, 2021.（久期、凸性、DV01 与免疫策略的工程细节最完整，附大量数值算例）
- Fama, E., "Efficient Capital Markets: A Review of Theory and Empirical Work", *Journal of Finance*, 1970.（有效市场假说的原始分类，检验方法论的起点）
- Grossman, S., and Stiglitz, J., "On the Impossibility of Informationally Efficient Markets", *American Economic Review*, 1980.（信息成本与市场效率关系的经典悖论）
- Kahneman, D., and Tversky, A., "Prospect Theory: An Analysis of Decision under Risk", *Econometrica*, 1979.（价值函数与概率权重的原始论文，λ 的估计出处）
- Penman, S., *Financial Statement Analysis and Security Valuation*, 5th ed., McGraw-Hill, 2013.（三大报表勾稽关系与杜邦分解的系统处理）

第二章 金融科技

如果说第 1 章讨论的是金融的「经济学」——现金流的定价与风险的补偿，那么本章讨论的是金融的「工程学」——数据如何被采集与存储、信用如何被量化、支付如何被清算、模型如何被治理。金融科技（FinTech）常被描述为技术对金融的颠覆，但对量化从业者更准确的定位是：**技术改变了金融的生产函数**。它降低了信息获取成本、提高了风险计量的分辨率、压缩了交易与清算的时间尺度，但没有改变风险与收益必须匹配这一约束。

核心要点 2.1

FinTech 的价值来源可以归结为三类成本的下降：**搜寻成本**（把资金供需双方匹配起来，如 P2P 与智能投顾）、**验证成本**（确认交易对手的身份与信用，如 eKYC 与另类数据评分）、**执行成本**（完成交易与清算，如实时支付与分布式账本）。任何金融科技商业模式的可持续性，都可以用「它把哪一类成本降低了多少、降低了谁的」来检验。

2.1 金融科技的定义与演进

2.1.1 四个阶段

1. **FinTech 1.0（1866–1967）**：以电报、跨洋电缆与清算所为核心，金融信息第一次跨越地理边界高速传递，跨国支付与外汇市场得以形成。

2. **FinTech 2.0（1967–2008）**：ATM、信用卡网络、SWIFT 报文与电子交易所出现，金融业务从纸面迁移到电子系统。此阶段的关键是**流程标准化**。

3. **FinTech 3.0（2008–至今）**：移动支付、P2P 借贷、机器人投顾、区块链与云计算。此阶段的关键是**渠道去中介化**：终端用户可以直接触达金融产品的提供者。

4. **FinTech 4.0（正在形成）**：嵌入式金融（金融服务嵌入非金融场景）、开放银行、以生成式人工智能为核心的新型交互层。此阶段的关键是**决策自动化**。

补充说明　分期的用意

上述分期是行业惯例而非严格史实，争议点在于「3.0 是否已结束」。分期的价值在于提示每一阶段的核心约束：1.0 的约束是通信带宽，2.0 的约束是流程与凭证，3.0 的约束是信任与获客成本，4.0 的约束则是**模型可靠性与合规责任**。约束在哪里，监管与技术的焦点就在哪里。

2.1.2 技术栈的分层

金融科技的技术栈可以分成四层，各层的失败模式完全不同，见表 表 2.1。理解分层很重要，因为一次生产事故的责任归属往往取决于它发生在哪一层。

表 2.1 金融科技技术栈分层与失败模式

层次	典型组件	核心职责	主要失败模式
数据层	数据仓库、数据湖、Kafka、对象存储	采集、存储、版本化与血缘追踪	时点错配（point-in-time 缺失）、字段口径不一致、上游断流
计算层	Spark、Flink、Python 与 SQL 引擎、特征平台	特征加工、模型训练与批量评分	训练与推理特征不一致、回填数据泄露未来信息
模型层	评分卡、GBDT、深度学习、大语言模型	风险计量与决策输出	分布漂移、过拟合、不可解释导致合规拒绝
应用层	开放银行 API、支付网关、智能投顾前端	交互、授权与执行	认证失效、接口抖动、限额与风控规则冲突

2.2 数据基础设施

2.2.1 数据仓库、数据湖与湖仓一体

数据仓库（Data Warehouse）要求写入前先定义模式（schema-on-write），数据经过清洗与建模后以星型或雪花模型组织，适合结构化报表与指标口径统一。**数据湖**（Data Lake）先存储原始数据再按需解释（schema-on-read），适合非结构化数据与探索性分析，但容易退化为缺乏治理的「数据沼泽」。**湖仓一体**（Lakehouse）在对象存储之上叠加事务表格式（如 Delta Lake、Iceberg、Hudi），同时提供 ACID 事务与开放格式读取能力。

⚠ 风险警示　数据湖的三种典型事故

一是**口径漂移**：同一指标在报表、风控与营销三个系统中定义不同，导致同一客户在不同系统里风险等级相反。二是**时点错配**：用今天已修订的财务数据回测三年前的策略，相当于让策略读到未来信息，回测收益会被系统性高估。三是**血缘缺失**：上游字段含义变更无人知晓，模型输入悄然改变，表现衰减却被归因为「市场变了」。解决这三类问题的工程手段是统一的指标口径层、point-in-time 快照表与字段级血缘追踪。

2.2.2 批处理、流处理与批流一体

批处理（Batch）按固定周期处理有界数据集，吞吐高、延迟以小时或天计；流处理（Stream）处理无界数据流，延迟可到毫秒级，但需要处理乱序、重复与恰好一次语义。两种常见的融合架构是：

- **Lambda 架构**：批处理层提供准确的历史视图，速度层提供近似的实时视图，查询时合并。代价是同一套逻辑要维护两份实现，容易出现口径不一致。
- **Kappa 架构**：只用流处理，历史数据通过重放消息队列重建。逻辑单一，但对消息保留期与重放成本要求高。

对风控场景而言，延迟与准确性之间存在明确的经济权衡：实时反欺诈需要在毫秒内决定是否放行，因此只能使用预先计算的轻量特征；而贷后监控与模型迭代可以使用小时级或天级的完整数据。把两类需求混在一条链路里，通常导致两边都做不好。

实务应用　事件时间与处理时间

在流式风控中必须区分**事件时间**（交易实际发生的时刻）与**处理时间**（系统收到并计算该事件的时刻）。若以处理时间为窗口，一笔因网络延迟在次日到达的交易会被计入次日的统计，日终汇总与实时监控因此出现差异。工程上的做法是以事件时间为准并使用水位线（watermark）容忍有限迟到，同时明确「窗口关闭后是否允许修正」的策略并写入文档。

2.3 信用评分卡

信用评分是量化金融在金融科技领域最成熟、也最具经济价值的应用。一个完整的评分卡开发流程包含七个步骤，其中最容易被忽视的是前两步的数据准备与分箱。

2.3.1　从数据到 WOE 与 IV

设目标变量 $y=1$ 表示违约（坏客户）、$y=0$ 表示正常（好客户），$p=\mathbb{P}(y=1\mid \mathbf{x})$ 为违约概率。逻辑回归模型假设违约的对数几率是特征的线性函数：

$$\ln\left(\frac{p}{1-p}\right)=\beta_0+\beta_1 x_1+\beta_2 x_2+\cdots+\beta_k x_k \tag{2.1}$$

其中 $\mathbf{x}=(x_1,\dots,x_k)$ 为特征向量（连续变量通常先分箱并转为 WOE 编码），β_j 为待估系数。由于 式 (2.1) 的右侧可以取任意实数而左侧被限制在 $(-\infty,\infty)$，因此不需要对 p 施加额外约束，这是逻辑回归在评分卡中被长期采用的技术原因之一。反解 式 (2.1) 得

$$p=\frac{1}{1+\exp\bigl(-(\beta_0+\boldsymbol{\beta}^{\top}\mathbf{x})\bigr)} \tag{2.2}$$

证据权重（Weight of Evidence，WOE）把每个分箱的违约信息压缩为一个数：

$$\mathrm{WOE}_i=\ln\left(\frac{\text{该箱中好客户占比}}{\text{该箱中坏客户占比}}\right)=\ln\left(\frac{n_i^{\mathrm{good}}/N^{\mathrm{good}}}{n_i^{\mathrm{bad}}/N^{\mathrm{bad}}}\right) \tag{2.3}$$

其中 n_i^{good} 与 n_i^{bad} 分别为第 i 箱中好、坏客户数量，N^{good} 与 N^{bad} 为全样本的好、坏客户总数。WOE 为正表示该箱的好客户相对更集中（风险较低），WOE 为负表示风险

较高。WOE 之所以有用，是因为它把非线性关系单调化：在 式 (2.1) 中用 WOE 作为输入，等价于用各箱的对数几率差直接建模，从而使逻辑回归能够捕捉单调但非线性的关系。

信息量（Information Value，IV）度量某个变量对好坏区分的贡献：

$$\mathrm{IV} = \sum_{i=1}^{m} \left(\frac{n_i^{\mathrm{good}}}{N^{\mathrm{good}}} - \frac{n_i^{\mathrm{bad}}}{N^{\mathrm{bad}}} \right) \mathrm{WOE}_i \tag{2.4}$$

其中 m 为分箱数。式 (2.4) 的形式是相对熵（KL 散度）的一种近似，可以理解为「知道该变量后，关于好坏的判断不确定性的减少量」。经验判据为：$\mathrm{IV} < 0.02$ 预测力很弱，0.02 至 0.1 为弱，0.1 至 0.3 为中等，0.3 至 0.5 为强，超过 0.5 时应当警惕——如此之高的 IV 在真实业务数据中罕见，通常意味着该变量泄露了结果信息（例如用了催收记录去预测违约）。

2.3.2 评分刻度：从几率的对数到分数

模型输出的是概率，业务需要的是分数。二者之间用一个线性映射连接：

$$\mathrm{score} = A - B \ln(\mathrm{odds}), \qquad \mathrm{odds} = \frac{1-p}{p} \tag{2.5}$$

其中 p 为违约概率，odds 为好坏比（好客户与坏客户之比），A 为基准分数，B 为刻度因子。两个参数由两项业务约定唯一确定：基准好坏比 O_0 对应的基准分数 S_0，以及好坏比翻倍所需的分数增量 PDO（Points to Double the Odds）。由 式 (2.5) 在两点的差值可得

$$B = \frac{\mathrm{PDO}}{\ln 2}, \qquad A = S_0 + B \ln O_0 \tag{2.6}$$

式 (2.6) 是评分卡部署中最常被写错的公式，把 $\ln 2$ 写成 $\ln 10$ 会让所有分数的间距错约 3.3 倍。代入检验：若设 $S_0 = 600$ 分对应 $O_0 = 50:1$，$\mathrm{PDO} = 20$，则 $B = 20/0.69315 = 28.8539$，$A = 600 + 28.8539 \times 3.91202 = 712.87$。当 $\mathrm{odds} = 20:1$ 时，$\mathrm{score} = 712.87 - 28.8539 \times 2.99573 = 626.4$ 分；当 $\mathrm{odds} = 100:1$ 时，$\mathrm{score} = 712.87 - 28.8539 \times 4.60517 = 580.0$ 分。好坏比从 $20:1$ 升到 $100:1$（扩大 5 倍，即倍数 $\ln 5/\ln 2 = 2.32$ 次翻倍），分数上升 $2.32 \times 20 = 46.4$ 分，与表中结果一致。

例 2.1　由逻辑回归系数直接写出评分卡

假设模型含两个 WOE 编码变量，估计得 $\ln(p/(1-p)) = -2.20 - 0.85\,w_1 - 1.30\,w_2$，其中 w_1, w_2 为两变量的 WOE 值。注意好客户对应低违约率，而 WOE 为正表示好客户集中，因此系数为负是符合预期的。由 $\mathrm{odds} = (1-p)/p = \exp(-(\beta_0 + \beta_1 w_1 + \beta_2 w_2))$，代入 式 (2.5) 得 $\mathrm{score} = A - B\ln(\mathrm{odds}) = A + B(\beta_0 + \beta_1 w_1 + \beta_2 w_2)$。取 $A = 712.87$、$B = 28.8539$，则基准分 $= 712.87 + 28.8539 \times (-2.20) = 649.4$ 分；w_1 每增加一个单位（好客户占比的相对优势提高 e 倍），分数增加 $28.8539 \times (-0.85) = -24.5$ 分——符号之所以为负，是因为本例中 $\beta_1 < 0$ 而 WOE 已在编码方向上调正，实际

部署时必须核对 WOE 的定义方向，否则整张评分卡会反向。更常见的等价写法是把系数与 B 的乘积直接作为每箱的得分（scorecard points），从而把评分卡做成一张「查表相加」的规则表，便于业务与监管审阅。

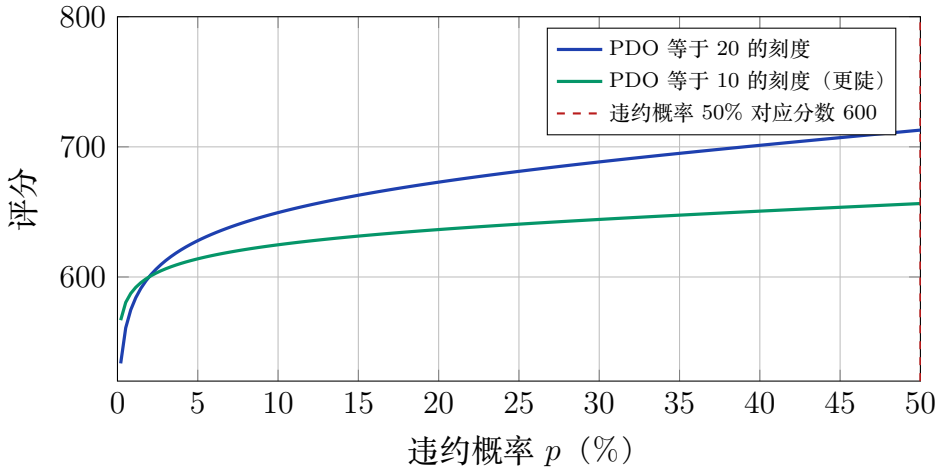


图 2.1　评分刻度映射曲线与 PDO 设定的影响

图 2.1 有两点值得强调。第一，映射曲线在低违约概率区域很陡：p 从 1% 降到 0.5%，好坏比从 99 升到 199，分数上升约 20 分；而在高违约概率区域几乎平坦：p 从 40% 升到 45%，分数只下降约 3 分。这意味着分数的分辨率在不同风险区间完全不同，用统一的分差阈值去区分「高风险名单」会在尾部失效。第二，PDO 越小曲线越陡，同一风险差异对应的分差越大；PDO 的选择应使业务上关心的风险差异落在 20 至 50 分的可解释区间内。

实务应用　分箱的工程约束

分箱（binning）需要同时满足四项约束：每箱样本量不低于总体的 5%（否则 WOE 的估计方差过大）、箱数控制在 5 至 10 个、WOE 随风险单调、且分箱边界可以写成业务语言的阈值（如「征信查询次数 0 次、1 至 2 次、3 至 5 次、6 次以上」）。纯粹由算法优化的分箱若边界不可解释，在监管质询时很难辩护。此外，分箱必须在训练集上确定并冻结，验证集与生产数据使用同一套边界，否则会引入信息泄露。

2.3.3　预期损失与风险调整收益

信用风险的第一性公式是预期损失：

$$EL = PD \times LGD \times EAD \tag{2.7}$$

其中 PD 为违约概率（通常取一年期口径），LGD 为违约损失率（$= 1 -$ 回收率），EAD 为违约时的风险敞口。三个参数的量纲与观测难度并不相同：PD 是最容易从评分卡估计的量，LGD 依赖抵押品处置与清偿顺序，EAD 在循环授信下还取决于违约前的额度使用率（通常用信用转换系数 CCF 建模）。

例 2.2　一笔贷款的预期损失与经济利润

某银行给一家中型企业发放 1 年期贷款，金额 1000 万元（EAD），贷款利率 7.5%，资金成本 3.0%，非预期损失的资本占用按贷款的 8% 计提，股东要求的资本回报率 12%。评分卡给出的 1 年期 $PD = 2.0\%$，历史同类敞口的回收率为 40%，故 $LGD = 60\%$。则

$$
\begin{aligned}
EL &= 0.02 \times 0.60 \times 1000 = 12.0 \text{ 万元}, \\
\text{利息收入} &= 1000 \times 7.5\% = 75.0 \text{ 万元}, \\
\text{资金成本} &= 1000 \times 3.0\% = 30.0 \text{ 万元}, \\
\text{经济利润} &= 75.0 - 30.0 - 12.0 - 1000 \times 8\% \times 12\% = 23.4 \text{ 万元}.
\end{aligned} \tag{2.8}
$$

其中最后一项 $1000 \times 8\% \times 12\% = 9.6$ 万元是资本占用成本。若该笔贷款的定价降到 6.0%，则经济利润变为 75.0 被替换为 60.0，结果为 8.4 万元，仅剩原来的三分之一。这解释了为什么小微企业贷款利率在表面上看「很高」（年化 8% 至 15%），而银行的实际利润仍然微薄：在 $PD = 2\%$、$LGD = 60\%$ 的假设下，仅预期损失就吞掉 1.2% 的利差，再加上资金成本与资本成本，能够留给风险的价差空间非常有限。

在 式 (2.7) 的基础上定义风险调整后的资本收益率：

$$
RAROC = \frac{\text{风险调整后的收益}}{\text{经济资本}} = \frac{\text{收入} - \text{成本} - EL}{\text{经济资本}} \tag{2.9}
$$

其中分母的经济资本对应非预期损失（Unexpected Loss），即在给定置信水平下损失超过 EL 的部分。式 (2.9) 的意义在于把风险显式地放进分母，从而可以比较不同风险等级的业务的资本效率：一笔 $PD = 0.5\%$ 的贷款与一笔 $PD = 6\%$ 的贷款，只有在资本占用与预期损失都被扣除之后，才能判断哪一笔真正为股东创造价值。

表 2.2　巴塞尔框架下的信用风险资本计量方法对比

方法	风险权重来源	数据要求	适用机构与局限
权重法（SA）	监管给定的外部评级映射表	仅需外部评级与敞口分类	中小银行易于实施；对低风险客户资本占用偏高，缺乏风险敏感性
内部评级法基础版（F-IRB）	机构自估 PD，LGD 与 EAD 用监管值	需通过监管验收的 PD 估计与评级体系	资本节约明显；但 PD 估计的顺周期性会把风险放大
内部评级法高级版（A-IRB）	PD、LGD、EAD 全部自估	需长期违约与回收数据、抵押品估值体系	风险敏感性最强；对数据治理与模型验证要求最高

表 2.2 的三种方法不是纯粹的精度递增关系，而是「资本敏感度」与「数据与治理成本」之间的权衡。选择更精细的方法意味着监管资本更贴近真实风险，但也意味着在数据质

量与模型治理上必须支付长期成本。内部评级法的另一个副作用是 **顺周期性**：经济下行时 PD 上升、抵押品价值下降导致 LGD 上升，资本要求随之提高，银行被迫收缩信贷，从而放大下行压力。这正是巴塞尔协议 III 引入逆周期资本缓冲与杠杆率底线的原因。

式 (2.7) 的结构可以用一张图直观拆开。把损失分布的横轴视为损失金额，预期损失是分布的均值，非预期损失是给定置信水平下的分位数与均值之差，而极端损失落在分位点之外，需要按压力情景单独准备资本。

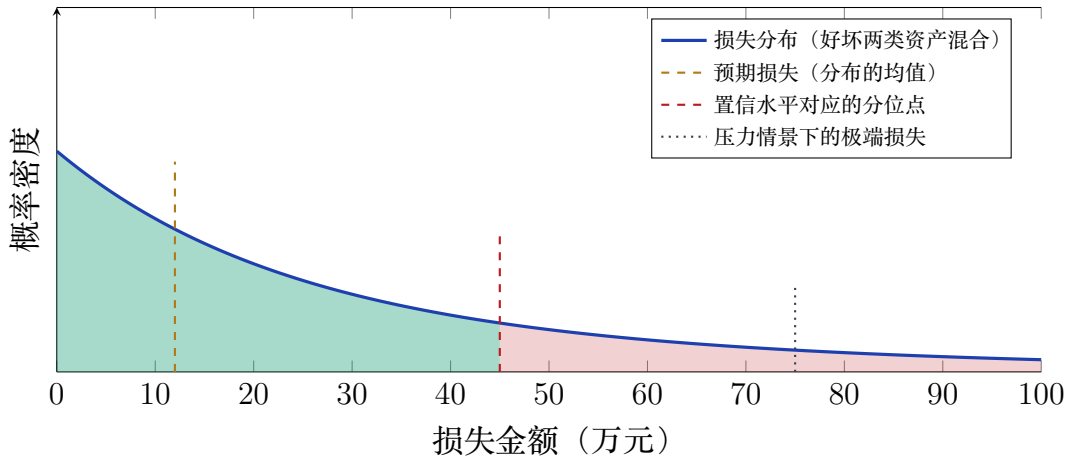


图 2.2　预期损失、非预期损失与极端损失在损失分布上的位置

图 2.2 中绿色区域对应预期损失，红色区域对应超出预期损失的尾部，其面积等于非预期损失发生的总概率。这张图解释了为什么银行同时需要 **拨备**（覆盖预期损失，计入损益）与**资本**（覆盖非预期损失，吸收冲击）：两者覆盖的是分布的不同部分，用拨备去吸收尾部损失会迅速耗尽，而用资本去覆盖预期损失则是低效的资本占用。

⚠ 风险警示　EL 模型的失效条件

第一，EL 是**期望**，不是上限。以 EL 作为损失预算而不保留非预期损失的资本，在 PD 低估时会被尾部损失击穿。第二，PD 通常来自历史样本，若样本期没有经历完整信用周期，估计值会被系统性低估，这一点在经济扩张期尤其危险。第三，三个参数并非独立：PD 与 LGD 在危机中同时上升（同一宏观因子驱动），把二者相乘时隐含的独立性假设会低估真实损失。第四，敞口口径必须与 PD 的期限一致，用一年期 PD 去乘多年期敞口会得到没有意义的数字。

2.3.4　评分模型的监控与压力测试

模型投产只是开始。上线后必须持续监控三类指标：**区分度**（如 KS 统计量、基尼系数、AUC 的月度变化）、**稳定性**（特征分布与分数分布的漂移）、以及**校准度**（预测违约率与实际违约率的一致性，常用二项检验与 Hosmer–Lemeshow 检验）。分布漂移最常用的度量是群体稳定性指数（Population Stability Index，PSI）：

$$\mathrm{PSI} = \sum_{i=1}^{m} (a_i - e_i) \ln\!\left(\frac{a_i}{e_i}\right) \tag{2.10}$$

其中 a_i 为当期第 i 箱的样本占比，e_i 为建模期（基准期）第 i 箱的占比，m 为箱数。式 (2.10) 与 式 (2.4) 结构相同，都是相对熵，只是把「好坏的区分」换成了「时间上的分布变化」。经验阈值为：小于 0.1 视为稳定，0.1 至 0.25 需要关注并做归因，超过 0.25 通常触发模型重训或降级使用。

例 2.3 PSI 的数值计算

某特征分为四箱，基准期占比为 $e = (0.40, 0.30, 0.20, 0.10)$，当期占比为 $a = (0.30, 0.30, 0.24, 0.16)$。逐箱计算 $(a_i - e_i)\ln(a_i/e_i)$：第一箱 $(-0.10)\ln 0.75 = 0.02877$；第二箱 $0 \times \ln 1 = 0$；第三箱 $0.04 \times \ln 1.20 = 0.00729$；第四箱 $0.06 \times \ln 1.60 = 0.02821$。合计 PSI $= 0.0643$，小于 0.1，判定为稳定。但若把当期占比改为 $a = (0.20, 0.25, 0.28, 0.27)$，同样的四箱计算得 0.1155、0.0163、0.0419、0.1326，合计 PSI $= 0.3063$，超过 0.25，触发重训评估。注意 PSI 对尾箱尤其敏感：第四箱占比从 10% 升到 27% 贡献了总 PSI 的 43%，这提示监控报告必须同时给出逐箱贡献，否则无法定位漂移来源。

压力测试与 PSI 监控是互补的：PSI 回答「已经发生了什么变化」，压力测试回答「如果发生某种宏观冲击会怎样」。标准做法是把宏观变量（GDP 增速、失业率、房价指数）与 PD、LGD 建立卫星模型，设定轻度、中度、重度三档情景，计算资本充足率在情景下的路径，并对最脆弱的组合制定处置预案。

2.4 支付与清算基础设施

2.4.1 RTGS 与 DNS

支付系统的清算机制分为两类。**实时全额结算**（RTGS）逐笔全额、实时完成资金划转，消除了结算延迟带来的对手方风险，但要求参与者保持充足的日间流动性；**延迟净额结算**（DNS）在结算周期内轧差后再划转净额，流动性效率高，但在轧差完成前存在敞口——这是「赫斯塔特风险」（Herstatt risk）的来源。现代大型支付系统通常采用「RTGS 处理大额、DNS 处理零售」的混合模式。

表 2.3　主要支付清算机制与标准对比

机制或标准	适用范围	关键特征	主要风险与约束
RTGS	大额跨行支付、证券交收	逐笔全额、实时、央行货币结算	日间流动性压力大，需排队管理与透支便利
DNS	零售批量支付、卡组织清算	周期轧差、净额划转、成本低	结算前存在对手方敞口，需会员信用限额
ISO 20022	跨境与国内报文	结构化数据字段，可承载汇款用途与合规信息	迁移期新旧报文并存，字段映射易丢信息
实时支付系统	零售即时转账	全年无休、秒级到账、限额管理	不可撤销，欺诈与误操作损失难以追回

表 2.3 中的 ISO 20022 值得单独说明：它把传统的定长报文字段替换为可扩展的 XML

结构，使「谁付给谁、为什么付」这类信息能够随款项一起传递，从而支持制裁名单筛查、反洗钱监测与自动对账。其代价是报文体积膨胀与新旧系统的映射成本，跨境迁移期通常需要报文转换网关做双向翻译，而字段语义的丢失是迁移项目中最常见的故障源。

2.4.2 实时支付的运营含义

实时支付把「到账」的等待时间从数小时压缩到数秒，这带来三个结构性变化。第一，**流动性管理**的粒度从日变为秒，参与机构需要在央行账户保持更高的日间余额，或依赖流动性节约机制（LSM）做双边与多边轧差。第二，**欺诈窗口**被压缩，但一旦放行便不可撤销，因此风控必须前移到预授权阶段，模型延迟预算通常在百毫秒量级。第三，**对账逻辑**必须改变：批处理时代的 T+1 对账不再适用，需要基于唯一端到端标识的实时状态机来跟踪每笔支付的生命周期。

补充说明　TPS 数字的口径

行业内常引用「峰值每秒数十万笔」的交易处理能力。比较这类数字时必须核对四点：统计的是单系统还是全链路（含银行核心与清算所）、峰值窗口是秒级还是一分钟均值、是否包含重复计数（如扫码支付中商户收款与用户付款各计一次）、以及是否在营销活动等极端场景下达到。口径不同，同一系统的 TPS 差异可以达到一个数量级，这也是容量规划中必须自建压测基准的原因。

2.5 开放银行与数据合规

2.5.1 开放银行的技术与商业逻辑

开放银行（Open Banking）通过标准化的应用程序接口（API）把账户信息与支付发起能力开放给持牌第三方。其核心不是技术，而是**数据主体对自身数据的控制权**：客户授权第三方读取其在银行的交易记录，或直接发起支付。主要制度包括欧盟的支付服务指令第二版（PSD2）、英国开放银行标准、以及美国的金融数据交换标准（FDX）。

对量化从业者而言，开放银行带来的直接价值是更完整的客户现金流数据，可用于更精细的偿付能力评估；风险则是数据链条变长后新增的攻击面，以及第三方倒闭时的数据处置问题。

2.5.2 合规框架：授权、最小化与跨境

- **欧盟 GDPR**：以「合法基础」为前提处理个人数据，要求目的限制、数据最小化、存储期限限制、数据主体权利（访问、更正、删除、可携带），并对自动化决策（含画像）设置限制与解释要求。
- **欧盟 PSD2**：在支付领域落实账户访问与支付发起两类接口，要求强客户认证（SCA），并规定第三方只能在客户明示授权范围内访问数据。
- **中国《个人信息保护法》**：要求处理个人信息具备合法性基础与单独同意（对敏感个

人信息）、目的明确与最小必要、境内存储与跨境提供的前置条件（安全评估、认证或标准合同）。

风险警示　合规的三条红线

其一，**超范围使用**：客户授权读取账户信息用于信贷审批，却被用于营销或转售给关联方，属于典型违规。其二，**无限期留存**：数据保留期限未定义，或删除请求无法在系统层面真正执行（例如备份与特征库中仍有副本）。其三，**跨境与再委托**：把数据传给境外云服务商或其子处理者时未做合规评估。这三类问题在技术上都表现为「数据流图与授权范围不一致」，因此合规审计的第一步永远是画出完整的数据血缘图，而不是检查某一份合同。

2.6 模型风险治理

2.6.1　机器学习模型的特殊风险

传统评分卡由少量变量与单调约束构成，其行为可以被业务人员理解并在一页纸上说明；机器学习模型（尤其是梯度提升树与深度网络）用数百上千个特征拟合复杂的交互关系，精度更高，但带来四类新风险：**过拟合**（样本内表现远优于样本外）、**不可解释**（无法向监管与客户说明拒绝理由）、**脆弱性**（对输入分布的微小偏移敏感，如对抗样本）、以及**可复现性**（依赖库版本、随机种子与数据快照，缺一不可）。

2.6.2　SR 11-7 与三道防线

美国联邦储备委员会 2011 年发布的 SR 11-7 指引给出了模型风险管理的通用框架，其核心是把模型风险治理拆成三个相互独立的角色，见表 表 2.4。

表 2.4　模型风险治理的三道防线与关键动作

防线	承担主体	关键动作	失效表现
第一道：开发与使用	业务条线与模型开发团队	模型文档、假设清单、开发与验证数据分离、上线前自测	自我验证流于形式，问题在投产后才暴露
第二道：独立验证	独立于开发的模型验证团队	概念合理性、数据质量、代码复现、基准对比、敏感性分析与结果分析	验证报告只做合规性陈述，不做真正的复现与挑战
第三道：内部审计	内部审计部门	评估前两道防线的流程有效性与执行一致性	审计只查文档是否齐全，不追查执行证据

表 2.4 中第二道防线的实质是**复现**：独立团队用同一份数据与同一份代码能否得到同样的结果，用更简单的基准模型（如逻辑回归或单一决策树）能否接近复杂模型的精度。若一个复杂模型相对简单模型的提升不足几个基点，却需要付出数倍的验证与维护成本，正确的结论往往是放弃复杂模型。

实务应用　可解释性的工程实现

在信用决策等受监管场景中，模型解释不是锦上添花而是准入门槛。常用手段包括：使用 SHAP 值给出单笔申请的逐特征贡献（可生成「拒绝理由」），用部分依赖图（PDP）与累积局部效应（ALE）检查特征影响是否单调合理，用单调约束（monotonic constraints）在训练阶段强制「收入越高、违约概率越低」，以及用代理模型（如深度不超过三层的决策树）拟合复杂模型的决策面。需要强调的是：解释工具的稳定性本身需要检验，两次运行的 SHAP 值若差异很大，基于它出具的拒绝理由同样不可靠。

2.6.3　大语言模型在金融中的应用与局限

大语言模型（LLM）在金融领域的现实应用集中在文本密集型环节：财报与公告的结构化抽取、合同条款比对、客服问答、代码与研报辅助生成、以及合规材料初筛。它带来的效率提升是真实的，但其失效模式与传统模型截然不同，必须在部署前明确：

- **幻觉**：模型会生成语法流畅但与事实不符的内容，包括虚构的财务数字与不存在的法条。缓解手段是强制检索增强（RAG）并附引用来源、对数值型输出要求逐字摘录原文位置、以及设置「无法确认时回答不知道」的拒答策略。即使如此，也无法保证零幻觉，因此关键决策必须有人类复核环节。
- **不可复现**：同一提示在不同时间、不同温度参数或不同模型版本下可能给出不同答案。监管场景要求可追溯，因此必须固定模型版本、记录完整提示与参数、并保存输出用于事后审计。
- **合规与保密**：把客户数据或未公开信息发送给外部模型服务商可能构成数据出境或泄密。可行方案是本地化部署或使用具备数据处理协议的私有实例。
- **责任归属**：模型没有法律主体资格，最终责任仍在机构与持牌人。把 LLM 输出直接作为投资建议或信用决策依据，在多数司法辖区都不满足「适当性」与「可解释性」要求。

风险警示　不能交给大语言模型的三类任务

一是**最终数值决策**：授信额度、风险定价、投资建议，这些必须有可审计的确定性模型与人工签字。二是**合规判断**：法条适用与制裁名单认定涉及法律责任，模型输出只能作为线索。三是**实时交易执行**：LLM 的延迟与不确定性不适合毫秒级闭环控制。把这三类任务交给 LLM，本质上是用不可验证的组件承担可验证的责任，属于典型的模型风险失配。

2.7 另类数据与量化平台

2.7.1　另类数据的价值与陷阱

另类数据（Alternative Data）指传统财报与行情之外的数据源：卫星影像、信用卡消费流水、应用下载与使用时长、物流与供应链记录、招聘岗位数量、社交媒体情绪等。评

估另类数据时应当依次检验四个问题：

1. **覆盖偏差**（coverage bias）：样本是否代表整体？信用卡面板通常偏向特定银行与特定人群，用它推断全行业消费增速会产生系统偏差。

2. **幸存者偏差**（survivorship bias）：数据集中是否只包含仍然存续的实体？若已退市的公司被剔除，回测中的成长性会被高估。

3. **时点一致性**（point-in-time）：数据在历史上实际可获得的时刻与当前数据集中的时间戳是否一致？很多数据集在后期做过回溯修订，直接用修订后的历史序列回测等于使用未来信息。

4. **拥挤度**：若同一数据源被大量资金使用，其预测能力会被套利活动迅速侵蚀。评估拥挤度可以观察数据供应商的客户数、以及该信号相关策略的容量与换手率。

例 2.4　覆盖率外推的偏差量级

某信用卡面板仅覆盖全国约 8% 的消费支付，且集中于一线城市与特定发卡行。若该面板显示某月消费同比下降 5%，而分析者直接把它当作全国消费增速，当真实全国消费仅下降 2% 时，误差为 3 个百分点。若策略使用该信号做多空配置并假设行业收入弹性为 1.5，则预期的基本面差被放大到 4.5 个百分点，相当于把信号强度高估了一倍以上。正确的处理方式是把面板数据与官方口径做历史回归，估计缩放系数与偏差项，并在样本外持续校验映射关系是否稳定；一旦映射关系断裂（例如发卡行调整了数据上报逻辑），必须先修复映射再使用信号。

2.7.2　量化研究与回测平台

量化策略的标准生命周期为：数据清洗、因子构建、组合构建、回测、绩效分析、实盘执行。工程上最容易出问题的环节是「研究环境与生产环境不一致」：研究用 pandas 在内存中处理全量数据，生产用流式计算分片增量，同一个因子在两处的实现细节（空值填充、复权方式、停牌处理）不同，导致实盘表现与回测不符。

表 2.5 的选择原则是：研究阶段追求**迭代速度**，生产阶段追求**保真度**。可行的做法是在研究阶段用向量化框架做因子筛选，再用事件驱动框架对候选策略做高保真复算，最后用生产同构的撮合模拟做最终确认，每一个阶段的结论都必须能够被上一阶段的实现所解释。

核心要点 2.2　本章的三条主线

一是**数据的时间属性**：无论数据湖、评分卡还是另类数据，最致命的错误都是时点错配——用未来才知道的信息解释过去，见 式 (2.10) 的监控逻辑、表 2.1 的分层 与 小节 2.7.1 的外推偏差。二是**风险参数的乘法结构**：$EL = PD \times LGD \times EAD$ 是信用风险的第一性公式，见 式 (2.7)，其失效主要来自参数相关性与样本期偏短。三是**模型的可验证性**：模型的复杂度必须与可验证性匹配，SR 11-7 的三道防线与表 2.4 的第二道防线都以「独立复现」为核心。

表 2.5　主流回测与数据平台的适用场景对比

工具或平台	语言与生态	优势	局限
Backtrader	Python	事件驱动、支持多品种与多周期、文档完整	单机运行，大数据量下性能受限，缺少因子研究能力
Zipline 系列	Python	与因子研究流程衔接好、内置交易日历与滑点模型	维护活跃度波动，扩展自定义数据源成本较高
VectorBT	Python 与 NumPy	向量化回测速度极快，适合参数扫描与因子筛选	事件顺序与撮合逻辑简化，不适合复杂订单类型
自研低延迟引擎	C++ 或 Rust	完全可控、微秒级延迟、可复现生产撮合逻辑	开发与验证成本高，需要独立的正确性测试体系

Listing 2.1　评分卡流程：分箱、WOE 与 IV、逻辑回归与评分刻度映射

```
import numpy as np
import pandas as pd
from sklearn.linear_model import LogisticRegression

def woe_iv(df, feature, target, bins=5):
    """Bin a numeric feature by quantile and compute WOE/IV per bin."""
    df = df[[feature, target]].dropna().copy()
    df["bin"] = pd.qcut(df[feature], q=bins, duplicates="drop")
    g = df.groupby("bin", observed=True)[target].agg(["count", "sum"])
    g.columns = ["n", "bad"]
    g["good"] = g["n"] - g["bad"]
    g["dist_good"] = g["good"] / g["good"].sum()
    g["dist_bad"] = g["bad"] / g["bad"].sum()
    g["woe"] = np.log(g["dist_good"] / g["dist_bad"])
    g["iv_bin"] = (g["dist_good"] - g["dist_bad"]) * g["woe"]
    return g, float(g["iv_bin"].sum())

def score_map(p, base_score=600.0, base_odds=50.0, pdo=20.0):
    """Map default probability to a scorecard score."""
    b = pdo / np.log(2.0)
    a = base_score + b * np.log(base_odds)
    return a - b * np.log((1.0 - p) / p)

rng = np.random.default_rng(7)
n = 4000
data = pd.DataFrame({
    "income": rng.lognormal(10.5, 0.5, n),
    "util": rng.uniform(0.0, 1.0, n),
})
logit = -1.2 - 0.9 * (data["income"] - 10.5) + 2.0 * (data["util"] - 0.5)
data["target"] = rng.binomial(1, 1.0 / (1.0 + np.exp(-logit)))

```

```
table, iv = woe_iv(data, "util", "target", bins=5)
print(table[["n", "bad", "woe", "iv_bin"]].round(4))
print("IV(util) = %.4f" % iv)

data["woe_util"] = data["util"].map(
    lambda v: table["woe"].iloc[min(int(v * 5), 4)])
model = LogisticRegression().fit(data[["woe_util"]], data["target"])
p_hat = model.predict_proba(data[["woe_util"]])[:, 1]
print("intercept=%.4f  coef=%.4f" % (model.intercept_[0], model.coef_[0,
    0]))
print("score at p=0.02: %.1f" % score_map(0.02))
print("score at p=0.01: %.1f" % score_map(0.01))
```

Listing 2.1 把本节的三组公式串成一条可运行的链路：`woe_iv` 实现 式 (2.3) 与 式 (2.4)，`score_map` 实现 式 (2.5) 与 式 (2.6)，中间的逻辑回归对应 式 (2.1)。注意示例中的映射函数只用于说明刻度换算，真实部署时必须把 WOE 分箱表冻结并存档，并用独立的验证样本重新计算 KS 与分数分布，避免示例代码中的样本内估计被误用。

本章小结

- 金融科技的价值来自搜寻、验证、执行三类成本的下降；技术栈分为数据、计算、模型、应用四层，各层的失败模式不同，见 表 2.1。
- 数据仓库与数据湖的关键分歧是模式定义与治理时机；批流一体的两种实现是 Lambda 与 Kappa，选择取决于口径一致性与重放成本。
- 评分卡流程为分箱、WOE、IV、逻辑回归、刻度映射；WOE 与 IV 的公式见 式 (2.3) 与 式 (2.4)，其本质是相对熵。
- 评分刻度由基准分数、基准好坏比与 PDO 三者唯一确定，见 式 (2.5) 与 式 (2.6)；PDO 决定曲线的陡峭程度，映射曲线在尾部趋于平坦。
- 预期损失 $EL = PD \times LGD \times EAD$ 是信用风险的第一性公式，风险调整收益 RAROC 把预期损失与经济资本放入分母，见 式 (2.9)。
- 巴塞尔框架下权重法、F-IRB 与 A-IRB 的差别是资本敏感度与治理成本的权衡，内部评级法存在顺周期性。
- 模型监控需要同时跟踪区分度、稳定性与校准度，PSI 见 式 (2.10)，阈值 0.1 与 0.25 分别对应关注与重训。
- 支付基础设施的核心权衡是流动性与结算风险，RTGS 与 DNS 分别偏向两端，ISO 20022 提升了信息载荷但引入映射风险。
- 模型风险治理的关键是独立复现；大语言模型适用于文本密集型辅助工作，不适用于最终数值决策、合规判断与实时执行。
- 另类数据的四项检验为覆盖偏差、幸存者偏差、时点一致性与拥挤度，其中时点错配是回测虚高的最常见原因。

练习与思考

1. 某评分卡的基准设定为 500 分对应好坏比 1 : 1，PDO 为 40。请计算 A 与 B，并求出好坏比为 30 : 1 与 300 : 1 时对应的分数，验证两者之差是否为 2×40 分。
2. 一个特征的五个分箱中，好客户占比依次为 $0.30, 0.25, 0.20, 0.15, 0.10$，坏客户占比依次为 $0.05, 0.10, 0.20, 0.25, 0.40$。请计算各箱 WOE 与整体 IV，并判断该变量的预测力等级。
3. 一笔 500 万元、1 年期的小微贷款，$PD = 4\%$、$LGD = 55\%$、资金成本 3.5%、资本占用比例 8%、资本回报要求 15%、非利息成本 1.0%。请计算使 $RAROC$ 不低于 15% 的最低贷款利率。
4. 某模型的分数分布基准期五箱占比依次为 20%、30%、25%、15%、10%，当期占比依次为 12%、24%、26%、20%、18%。请计算 PSI，指出贡献最大的两箱，并说明是否应触发重训。
5. 请设计一个评估替代数据信用评分公平性的方案：需要说明如何定义受保护群体、选用哪些公平性度量（如不同群体的通过率差异、条件违约率差异）、以及当「公平性」与「区分度」冲突时应如何决策。
6. 某机构打算用大语言模型自动生成贷后催收话术并直接发送给客户。请列出至少四项必须在部署前完成的控制措施，并说明每一项对应哪种风险。
7. 给定一个包含 10 年日频数据的信用卡消费面板，请写出检验其「时点一致性」的具体步骤，并说明如果发现数据曾在第三年被整体修订过，应如何修正回测设计。

延伸阅读

- Siddiqi, N., *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Risk Scorecards*, Wiley, 2006.（分箱、WOE、IV 与评分刻度换算的实务操作手册）
- Basel Committee on Banking Supervision, *Basel III: Finalising Post-crisis Reforms*, Bank for International Settlements, 2017.（信用风险资本计量方法、杠杆率与逆周期缓冲的制度文本）
- Board of Governors of the Federal Reserve System, *SR 11-7: Guidance on Model Risk Management*, 2011.（三道防线与模型验证要求的原始指引，篇幅短但被广泛援引）
- Lopez de Prado, M., *Advances in Financial Machine Learning*, Wiley, 2018.（数据时点错配、特征重要性与回测偏差的系统处理，第 4 至 7 章最相关）
- Provost, F., and Fawcett, T., *Data Science for Business*, O'Reilly, 2013.（把 WOE、IV 这类指标解释为信息增益的通俗读本，适合建立直觉）
- 《中华人民共和国个人信息保护法》与欧盟 *General Data Protection Regulation* 全文。（数据处理的合法性基础、最小必要原则与跨境传输条件的第一手条款）

第三章 Web3 与加密金融

3.1 Web3 的哲学与技术基础

Web3 的叙事起点并不是技术，而是一次所有权结构的重新分配。Web1 时代用户可以读取网页但无法写回内容；Web2 时代用户可以生产内容，但账户、身份与数据沉淀在平台公司的服务器上，价值捕获权归平台；Web3 的诉求是让用户在读取、写入之外额外获得**拥有权**——账户由私钥控制，资产由链上状态定义，协议规则由智能合约强制执行而非由公司政策决定。

这一诉求是否在经济学上成立，是量化从业者真正关心的问题。去中心化不是免费的：它用冗余计算、冗余存储和冗长的共识过程，换取了「无需信任第三方」这一属性。因此 Web3 系统的成本结构与传统金融科技有着本质差别——后者的边际成本主要来自服务器与人力，前者的边际成本主要由共识开销与状态存储开销构成。理解这一点，才能理解为什么链上交易的费率会随拥堵剧烈波动，也才能理解为什么大量所谓「上链」的业务在成本上根本不成立。

核心要点 3.1　Web3 的四层结构

Web3 系统可以分解为四层，任一层失效都会导致上层业务不可用：**共识层**（区块链：PoW、PoS 等）决定「谁有权追加账本」，提供抗审查与最终一致性；**执行层**（智能合约、EVM）决定「状态如何被修改」，提供可组合性；**激励层**（代币经济）决定「谁来维护系统、维护者得到什么」，提供安全性预算；**数据层**（链上状态与去中心化存储）决定「状态在哪里、以什么成本被读取」。

补充说明　本节的记号约定

本章涉及大量与第 4 章共通的符号，为保持一致，统一约定：S 表示资产价格或标的资产，x, y 表示流动性池中两种代币的存量，k 表示不变量，ρ 表示价格比例，r 表示利率（在 DeFi 语境下为借贷年化利率）。链上金额一律以代币最小单位的整数表示，因此本章的连续数学建模均隐含「单笔交易相对池深度足够小」的近似前提。

3.2 区块链技术深度

3.2.1　哈希链与 Merkle 证明

区块链的本体是一串由哈希指针连接的区块。若记第 n 个区块头的哈希为 H_n，则区块头的结构可写为

$$H_n = \mathrm{Hash}\big(\mathrm{prev}(H_{n-1}),\ \mathrm{root},\ t_n,\ \mathrm{nonce}\big) \tag{3.1}$$

其中 prev 为前驱哈希，root 为该区块内交易的 Merkle 根，t_n 为时间戳，nonce 为工作量证明所需的随机数。改写任一历史区块中的一笔交易，会使该区块的 Merkle 根改变，进而改变其区块头哈希，并迫使攻击者重算其后所有区块——这就是「不可篡改」的技术含义，如式 (3.1) 所示。

Merkle 树的价值在于验证的**对数复杂度**。若有 n 笔交易，验证「第 i 笔交易确实被打包」只需要该交易到根路径上的 $\lceil \log_2 n \rceil$ 个兄弟哈希。比特币一个区块约 2000–4000 笔交易，因此一颗完整的 Merkle 证明只有 12 个左右的哈希（约 384 字节），一部手机即可验证一笔转账被链上确认，而无需下载数百 GB 的区块数据。

直觉理解　为什么是「对数」而不是「线性」

线性验证要求验证者拥有全部数据，这在资源上等价于「成为全节点」。Merkle 证明把验证者的存储需求从 $O(n)$ 降到 $O(\log n)$，代价是验证者必须信任「链头是最长链」这一前提。因此轻节点的安全性弱于全节点：它验证的是「某笔交易在某个区块里」，而不是「该区块确实属于最重链」。

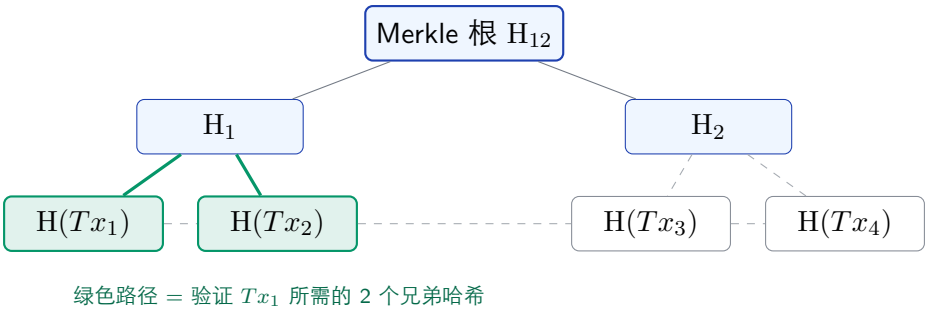


图 3.1　Merkle 树的验证路径

如图 3.1所示，验证 Tx_1 只需 $\mathrm{H}(Tx_2)$ 与 H_2 两个哈希。攻击者若要伪造 Tx_1 而不被发现，必须同时构造出与 H_2 相符的伪造数据，这在哈希函数的抗碰撞假设下不可行。

3.2.2　共识机制与终局性

「共识」解决的是分布式系统中最古老的问题：在存在恶意节点与网络分区的条件下，如何让所有诚实节点对同一份账本达成一致。不同机制的差别主要体现在三个维度：**安全性预算**（攻击成本来自算力、资本还是许可身份）、**终局性类型**（概率终局还是确定性终局）、**性能**（吞吐与延迟）。

表 3.1中最容易被忽略的一列是「终局性」。概率终局意味着「交易被回滚的概率随时间指数衰减」，这对交易所的提现确认数有直接要求；确定性终局意味着「一旦最终确认，除非超过三分之一的质押被罚没，交易不可逆」，这对结算类业务更友好。

表 3.1　主流共识机制的对比

机制	代表链	安全预算来源	终局性	主要代价
PoW	Bitcoin	算力（电力与硬件）	概率终局（约 6 个区块）	能耗极高，吞吐约 7 TPS
PoS	Ethereum	质押资本（罚没机制）	确定性终局（约 2 个 epoch）	富者愈富、质押集中化
DPoS	EOS、TRON	选举出的少数验证人	确定性终局	验证人数量少，抗审查弱
PBFT 类	Hyperledger	许可身份	即时确定性终局	需已知成员，扩展性受限

风险警示　终局性与经济安全预算

PoS 的安全性建立在「攻击成本大于收益」这一经济假设上。若某条链的总质押价值为 V，攻击者需要控制约三分之一（33%）的质押即可实施某些分叉攻击，则安全预算可粗略量化为 $\frac{1}{3}V$。当链上锁定的资产规模远超原生代币的质押市值时，这条不等式会被打破——这正是「跨链桥持有资产多于共识层市值」时最危险的结构。2022 年多起桥攻击的共同点并非密码学被攻破，而是经济安全预算不足。

3.2.3　以太坊虚拟机与费率机制

EVM 是一台基于栈的图灵完备状态机，其「图灵完备」带来的直接后果是停机问题不可判定，因此必须以显式计价的方式来限制执行开销，这就是 Gas。在一笔交易中，费用的基本关系为

$$\text{费用} = \text{Gas 消耗量} \times \text{Gas 单价} \tag{3.2}$$

其中 Gas 消耗量由指令序列决定（存储写入远贵于算术运算），Gas 单价则由市场供需决定。EIP-1559 之后，单价被拆分为两部分：

$$\text{Gas 单价} = \text{基础费} + \text{优先费}, \qquad \text{基础费} = b_{n-1}\left(1 + \tfrac{1}{8} \cdot \tfrac{u_{n-1} - u^*}{u^*}\right) \tag{3.3}$$

其中 b_{n-1} 为上一区块的基础费，u_{n-1} 为上一区块的实际用量，u^* 为目标用量（约 1500 万 Gas）。基础费被销毁而非支付给验证者，优先费则作为小费归验证者。如式 (3.3) 所示，当区块用量超过目标时，基础费按每区块最多 12.5% 的幅度上升，这一设计把「费用」从拍卖品变成了可预测的拥堵价格。

实务应用　Gas 成本应从工程角度评估

链上业务的可行性判断标准非常朴素：单笔业务的链上成本是否小于该业务创造的毛利。以以太坊主网为例，一次 ERC-20 转账约消耗 5 万 Gas，一次 Uniswap V3 的复杂兑换可能消耗 15 万–20 万 Gas。当基础费为 10 gwei 时，前者成本约 0.0005

ETH；当基础费飙升至 200 gwei 时，同样一笔操作的成本提高 20 倍。因此大量高频、小额的支付类应用最终迁移到二层网络或专用链，其决策依据正是这一条成本不等式，而非技术偏好。

3.3 智能合约与安全

3.3.1 Solidity 的关键要素

Solidity 是以太坊生态最主流的合约语言。对量化从业者而言，真正需要掌握的并不是语法细节，而是三类与资金安全直接相关的问题：**状态变量的存储成本**（决定合约的经济可行性）、**外部调用的控制权转移**（决定重入风险的边界）、**整数与精度**（决定会计记账是否自洽）。

定义 3.1　重入攻击 Reentrancy

重入攻击指合约在向外部地址转账或调用外部合约时，将控制权暂时交给该外部地址，而该地址在回调中再次进入原合约的同一函数。若原合约在外部调用之后才更新自身状态（例如把用户余额置零），则攻击者可在余额尚未清零时反复提取资金。防御的核心原则是**检查–生效–交互**（Checks-Effects-Interactions）：先校验前置条件，再更新自身状态，最后执行外部调用；并以互斥锁（`nonReentrant`）作为纵深防御。

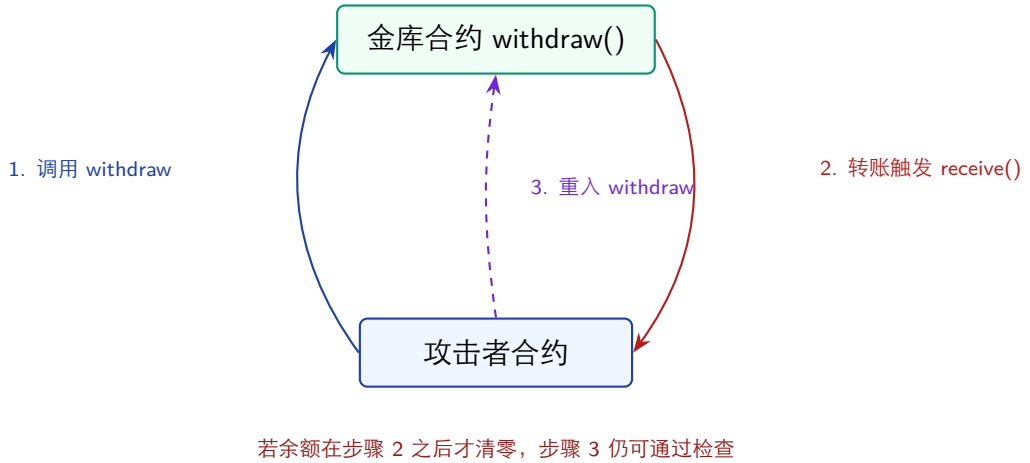


图 3.2　重入攻击的控制流与状态更新时序

图 3.2给出了重入攻击的机制。修复方式是唯一的：把「扣减余额」放在「转账」之前，使第二次进入时余额已为零。

3.3.2 安全转账的实现

下面给出一个完整可读的最小提款合约，它同时使用了检查–生效–交互模式与互斥锁。

Listing 3.1　防重入的提款合约（检查–生效–交互 + 互斥锁）

```solidity
// SPDX-License-Identifier: MIT
pragma solidity ^0.8.20;

contract SafeVault {
    mapping(address => uint256) public balance;

    bool private locked;

    modifier nonReentrant() {
        require(!locked, "reentrant call");
        locked = true;
        _;
        locked = false;
    }

    function deposit() external payable {
        require(msg.value > 0, "zero deposit");
        balance[msg.sender] += msg.value;
    }

    function withdraw() external nonReentrant {
        uint256 amount = balance[msg.sender];
        require(amount > 0, "nothing to withdraw");

        balance[msg.sender] = 0;            // effects first

        (bool ok, ) = msg.sender.call{value: amount}("");   // interaction last
        require(ok, "transfer failed");
    }

    function totalBalance() external view returns (uint256) {
        return address(this).balance;
    }
}
```

Listing 3.1中 `balance[msg.sender] = 0` 一行位于外部调用之前，这是与 The DAO 事件（2016 年 6 月，约 360 万 ETH 被转移）中受损代码的关键差别。

⚠ 风险警示　代码清单之外的三类常见错误

其一，**价格来源单一**：直接使用 AMM 池的瞬时储备作为预言机，可被闪电贷在单笔交易内操纵，正确做法是使用时间加权平均价格并校验偏离幅度。其二，**授权额度无上限**：`approve` 设为最大值会把资产控制权长期交给第三方合约，一旦该合约被攻破，损失与用户余额同阶。其三，**升级权限集中**：代理模式下的管理员可在不通知用户的情况下替换实现逻辑，这使「代码即法律」的承诺退化为「管理员即法律」。

表 3.2　主流代币标准的适用范围与陷阱

标准	设计目标	使用中的典型陷阱
ERC-20	同质化代币（可分割、可互换）	`transfer` 无返回值；对非合约地址的转账可能静默失败，需用 `SafeERC20` 包装
ERC-721	非同质化代币（每个 tokenId 唯一）	批量转移与授权逻辑复杂，`safeTransferFrom` 存在回调重入面
ERC-1155	同一合约内混合同质化与非同质化	余额以「id → 数量」映射表示，会计逻辑与 ERC-20 不通用
ERC-4626	收益金库的代币化份额	首笔存款存在份额价格操纵（通胀攻击）风险，需设置最小份额

3.3.3　代币标准与实现细节

表 3.2中 ERC-4626 的通胀攻击值得单独说明：若金库在总份额极小时被攻击者用极少量资产抬高份额单价，后续存款者的份额会被向下取整为零。标准解法是在初始化时锁定一笔最小流动性（类似 Uniswap 的 `MINIMUM_LIQUIDITY`）。

3.4 代币经济学与估值

3.4.1　代币的分类

- **支付类代币**：BTC、LTC，目标是承担价值储藏与交换媒介职能；
- **功能类代币**：ETH（支付 Gas）、FIL（支付存储），需求与实际资源消耗挂钩；
- **治理类代币**：UNI、AAVE，持有者获得修改协议参数的投票权；
- **证券类代币**：代表传统资产（股权、债权、不动产）的链上凭证，受证券法约束；
- **非同质化代币**：艺术品、游戏道具、身份凭证等唯一性资产。

分类的意义在于确定估值方法：功能类代币可以对应现金流，治理类代币对应控制权期权，支付类代币则更接近货币需求函数。

3.4.2　交换方程及其循环论证问题

最常被引用的代币估值起点是货币经济学中的交换方程：

$$MV = PQ \tag{3.4}$$

其中 M 为代币的货币供给（流通市值），V 为流通速度（单位时间内同一单位货币被使用的次数），P 为链上商品与服务的价格水平，Q 为实际交易数量。若把 M 解出，便得到所谓「代币价格」：

$$M = \frac{PQ}{V} \quad \Longrightarrow \quad \text{单枚代币价格} = \frac{PQ}{V \cdot n} \tag{3.5}$$

其中 n 为流通代币数量。如式 (3.5) 所示，估值结果与 V 成反比，而 V 恰恰是最不可观测、也最容易被操纵的参数。

⚠ 风险警示　交换方程的循环论证

用式 (3.4) 给代币估值存在两重逻辑问题。第一，Q 通常用「链上交易额」度量，而链上交易额中包含大量刷量交易与同一笔资金的循环转账，V 与 Q 会同步被人为抬高，估值结果对刷量高度敏感。第二，该方程描述的是货币的**交易需求**，而绝大多数代币并未被用作支付媒介，其价格由投机需求驱动；把投机需求塞进交易需求方程，等于用结论去假定前提。第一代「代币价值 = 链上交易额除以流速」的模型普遍给出比市场价高一个数量级的结果，正是这一循环论证的后果。

3.4.3　协议现金流折现

对真正产生收入的协议，更可靠的方法是回到现金流折现。若协议在第 t 期的收入为 R_t，收入中归代币持有者的比例为 β，代币总供给为 n，折现率为 r，则单枚代币的内在价值为

$$V_0 = \frac{1}{n} \sum_{t=1}^{\infty} \frac{\beta\, R_t}{(1+r)^t} \tag{3.6}$$

其中 β 是关键参数：若协议收入全部归国库而不分配给代币，则 $\beta = 0$，代币价值只能来自治理权，式 (3.6) 退化为零。这就是「治理代币无现金流」争议的数学表达。

例 3.1　用协议现金流估算代币价值

某去中心化交易协议的年化手续费收入为 $R_0 = 3.0$ 亿美元，且收入以每年 $g = 8\%$ 增长，协议治理投票决定将其中 $\beta = 50\%$ 用于回购并分配给质押者，流通代币数量 $n = 6$ 亿枚，折现率取 $r = 15\%$。由永续增长公式

$$V_0 = \frac{1}{n} \cdot \frac{\beta R_0\,(1+g)}{r-g} = \frac{1}{6\times 10^{8}} \cdot \frac{0.5 \times 3.0 \times 10^{8} \times 1.08}{0.15 - 0.08} \approx 0.386 \text{ 美元/枚}$$

小节 3.4.3的结果对折现率极为敏感：若把 r 从 15% 调到 25%，价值降至 $0.5 \times 3.0 \times 10^8 \times 1.08/(0.25-0.08)/6\times 10^8 \approx 0.159$ 美元/枚，降幅 59%。这提示我们，对高增长假设的协议估值，稳健的表述方式是给出「在什么折现率下价格才合理」而非单点结论。

3.5 DeFi 协议数学

3.5.1 恒定乘积做市商

定义 3.2 恒定乘积做市商 CPMM

恒定乘积做市商维护两种代币的储备 x 与 y，并要求其乘积在每次交易后不小于一个不变量 k：

$$x \cdot y = k \tag{3.7}$$

交易者向池中注入 Δx 的 X 代币，获得 Δy 的 Y 代币，储备更新为 $(x+\Delta x,\ y-\Delta y)$，且新储备仍满足 $x'y' = k$（忽略手续费）。

由小节 3.5.1可直接得到「支付多少 Δx 才能取出给定 Δy」的关系式：

$$\Delta x = \frac{x\,\Delta y}{y - \Delta y} \qquad \Longleftrightarrow \qquad \Delta y = \frac{y\,\Delta x}{x + \Delta x} \tag{3.8}$$

如式 (3.8) 所示，输出量关于输入量是凹函数：投入翻倍并不能使输出翻倍。池内两种代币的瞬时交换比例由隐函数求导得到：

$$x\,\mathrm{d}y + y\,\mathrm{d}x = 0 \quad \Longrightarrow \quad -\frac{\mathrm{d}y}{\mathrm{d}x} = \frac{y}{x} \tag{3.9}$$

其中 $-\mathrm{d}y/\mathrm{d}x$ 表示「卖出 1 单位 X 能换回多少 Y」，即边际价格。式 (3.9) 说明 CPMM 的报价完全由储备比例决定，池中没有独立的做市商报价，也没有订单簿。

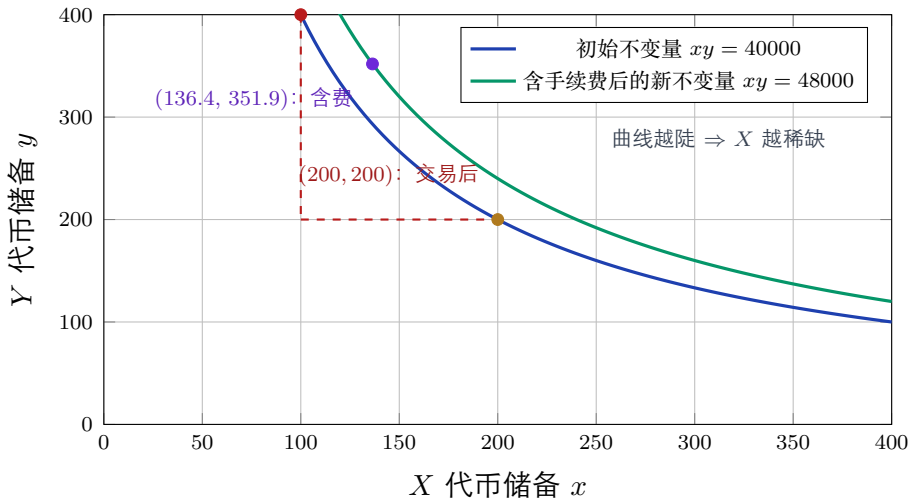


图 3.3　恒定乘积双曲线与一次交易前后的位置变化

图 3.3中的红色虚线是一次「用 100 单位 X 换 Y」的交易：储备从 $(100, 400)$ 沿曲线滑到 $(200, 200)$，交易者平均成交价为 $200/100 = 2$，而成交前的边际价格是 $400/100 = 4$。两者之差就是滑点。

核心要点 3.2　滑点公式与价格冲击

在忽略手续费的情形下，一次性用 Δx 换取 Y 代币的**执行价格与边际价格之比**为

$$\frac{\text{平均成交价}}{\text{成交前边际价}} = \frac{\Delta y/\Delta x}{y/x} = \frac{x}{x+\Delta x} = 1 - \frac{\Delta x}{x+\Delta x} \tag{3.10}$$

因此**相对滑点**恰为 $\dfrac{\Delta x}{x+\Delta x}$，它只依赖于「交易量占池中该代币储备的比例」。当 $\Delta x = x$ 时滑点为 50%，当 $\Delta x = 0.01x$ 时滑点约为 1%。这条公式是评估链上交易执行质量的第一准则。

例 3.2　滑点的数值计算

设某 ETH/USDC 池储备为 $x = 100$ ETH、$y = 200000$ USDC，边际价格为 2000 USDC/ETH。交易者卖出 $\Delta x = 10$ ETH。由式 (3.8)：

$$\Delta y = \frac{200000 \times 10}{100 + 10} = 18181.8 \text{ USDC}$$

执行价格为 1818.2 USDC/ETH，相对边际价格的滑点为 $\frac{10}{110} = 9.09\%$。若该池深度翻倍至 200 ETH，同样卖出 10 ETH 的滑点降为 $\frac{10}{210} = 4.76\%$，近似与池深度成反比。

3.5.2　流动性份额与手续费收入

流动性提供者（LP）按存入时两种代币的价值比例获得份额。若池中原有价值为 V_{pool}，LP 存入价值 V_{in}，则其份额为

$$s = \frac{V_{\text{in}}}{V_{\text{pool}} + V_{\text{in}}} \tag{3.11}$$

手续费按交易额的比例 ϕ 收取，并留在池中。若一段时间内累计交易额为 V_{vol}（以池中某一代币计价），则 LP 的手续费收入近似为

$$\text{费收} \approx s \cdot \phi \cdot V_{\text{vol}} \tag{3.12}$$

如式 (3.11) 与式 (3.12) 所示，LP 的收益结构是「确定性的费收减去不确定性的价格损失」。后一项正是下一小节的主题。

表 3.3中的 Stableswap 不变量在 $A \to 0$ 时退化为 CPMM，在 $A \to \infty$ 时退化为 CSMM，因此 A 可理解为「池对锚定关系的信心」。当市场价偏离锚定时，若不及时调低 A，池会成为套利者的提款机。

表 3.3　三类 AMM 不变量的对比

类型	不变量形式	适用场景	主要问题
恒定和（CSMM）	$x+y=k$	锚定 1:1 的稳定币兑换	储备可被单侧耗尽，无法维持锚定
恒定积（CPMM）	$xy=k$	波动性资产对	大额交易滑点高，资金效率低
混合（Stableswap）	$An^n\sum x_i+\prod x_i=k$	稳定币与同锚定资产	参数 A 需随锚定偏离动态调整

3.5.3　无常损失

定义 3.3　无常损失 Impermanent Loss

无常损失指 LP 在池中的持仓价值，相对于「存入时等值的两种代币各自持有」的价值之差，用比例表示。设价格比例 $\rho=P_1/P_0$ 为相对存入时刻的价格倍数，则

$$IL(\rho)=\frac{2\sqrt{\rho}}{1+\rho}-1 \tag{3.13}$$

当 $\rho=1$ 时 $IL=0$；只要 $\rho\neq 1$，IL 恒为负，因此无常损失在价格发生任何变动时都会出现，只是幅度可能很小。

下面给出式 (3.13) 的完整推导。设存入时 Y 代币计价的价格为 P_0，池中储备为 (x_0,y_0)，且以 Y 计价的池价值为

$$V_0=2\,x_0P_0 \tag{3.14}$$

这是因为在 CPMM 最优配置下 $x_0P_0=y_0$，两种代币价值各占一半。价格变为 $P_1=\rho P_0$ 后，套利者会把池内比例调整到新的边际价格，即 $y_1/x_1=P_1$，同时维持不变量 $x_1y_1=x_0y_0$。联立两式可解出

$$x_1=x_0\sqrt{\frac{P_0}{P_1}}=\frac{x_0}{\sqrt{\rho}},\qquad y_1=y_0\sqrt{\frac{P_1}{P_0}}=y_0\sqrt{\rho} \tag{3.15}$$

如式 (3.15) 所示，价格上升时 LP 被动卖出上涨的资产、买入下跌的资产（这正是「自动再平衡」的另一面：逆向选择）。LP 持仓以 Y 计价的价值为

$$V_1=x_1P_1+y_1=\frac{x_0}{\sqrt{\rho}}\cdot\rho P_0+y_0\sqrt{\rho}=x_0P_0\sqrt{\rho}+x_0P_0\sqrt{\rho}=\sqrt{\rho}\,V_0 \tag{3.16}$$

而「持有不动」策略的价值为 $V_{\text{HODL}}=x_0P_1+y_0=x_0P_0\rho+x_0P_0=\frac{V_0}{2}(1+\rho)$。两者相除即得式 (3.13)。

图 3.4揭示了无常损失的两个重要性质：其一，$IL(\rho)=IL(1/\rho)$，价格翻倍与价格腰斩造成的损失完全相同；其二，曲线在 $\rho=1$ 附近的二阶近似为 $IL\approx-\frac{(\rho-1)^2}{8}$，说明小幅

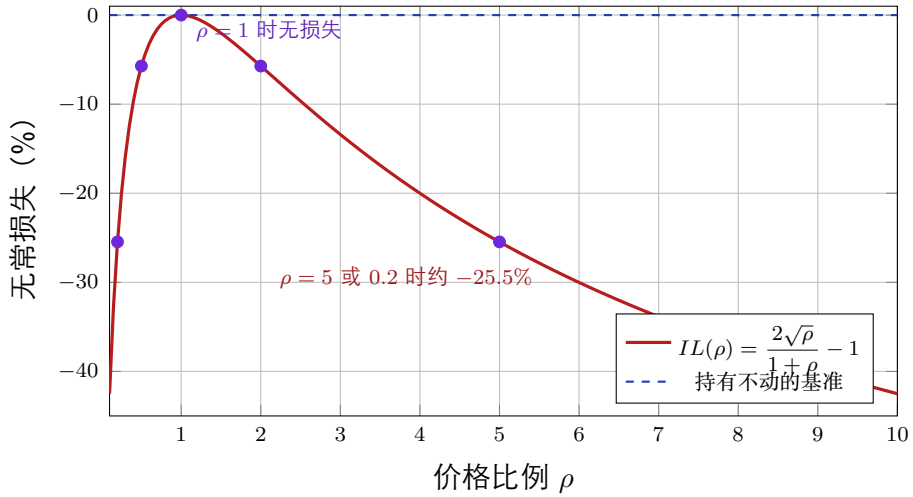


图 3.4　无常损失关于价格比例的函数，曲线关于 $\rho = 1$ 左右对称

波动下损失是「波动幅度的平方」量级，因此高频小幅震荡对 LP 的伤害远小于一次趋势行情。

例 3.3　无常损失的数值验证

某 LP 向 ETH/USDC 池存入 1 ETH 与 10000 USDC，此时 $P_0 = 10000$ USDC/ETH，池价值 $V_0 = 20000$ USDC。价格上涨 25% 至 $P_1 = 12500$ USDC/ETH，即 $\rho = 1.25$。由式 (3.15)：$x_1 = 1/\sqrt{1.25} = 0.89443$ ETH，$y_1 = 10000 \times \sqrt{1.25} = 11180.3$ USDC。LP 持仓价值为

$$V_1 = 0.89443 \times 12500 + 11180.3 \approx 11180.3 + 11180.3 = 22360.7 \text{ USDC}$$

若选择持有不动，价值为 $1 \times 12500 + 10000 = 22500$ USDC。差额为 -139.3 USDC，相对损失 -0.619%。用式 (3.13) 直接验算：

$$IL(1.25) = \frac{2\sqrt{1.25}}{1+1.25} - 1 = \frac{2.23607}{2.25} - 1 = -0.619\%$$

两种算法一致。注意：损失相对值很小，但 LP 的绝对持仓从 1 ETH 降到约 0.894 ETH，若之后价格继续上涨，这部分「少赚的 ETH」会持续放大。

例 3.4　手续费能否覆盖无常损失

某池的手续费率为 $\phi = 0.3\%$，池总价值 1000 万美元。某 LP 占池份额 $s = 1\%$。在一个月内 ETH 价格从 3000 美元上涨至 3750 美元（$\rho = 1.25$），期间池内累计成交额为 4000 万美元。

先算无常损失：由小节 3.5.3，$|IL| = 0.619\%$，即 LP 因价格偏离损失约 $0.619\% \times sV_{\text{pool}} = 0.619\% \times 10^5 = 619$ 美元。再算手续费收入：由式 (3.12)，费收 $= 1\% \times 0.3\% \times 4 \times 10^7 = 1200$ 美元。净收益为 $+581$ 美元，手续费覆盖了无常损失。若成交额只有 1000 万美元，费收降为 300 美元，净收益变为 -319 美元。

盈亏平衡所需的成交额满足 $s\phi V^*_{\text{vol}} = |IL| \cdot sV_{\text{pool}}$，即

$$V^*_{\text{vol}} = \frac{|IL(\rho)|}{\phi} V_{\text{pool}} = \frac{0.00619}{0.003} \times 10^7 \approx 2063 \text{ 万美元}$$

即一个月内池的换手率需达到约 2.06 倍。作为经验法则，$\rho = 2$ 时 $|IL| = 5.72\%$，所需换手率约为 19 倍/月——多数零售币对难以持续达到这一水平，这正是「LP 长期跑输持有」现象的数量解释。

直觉理解　无常损失为什么叫「无常」

「无常」(impermanent) 一词源于一种辩护性说法：只要价格回到存入时的水平，损失就会消失。这在数学上确实成立——$IL(1) = 0$，且在加回手续费后 $\rho = 1$ 时 LP 严格优于持有。但这一说法有严重误导性：价格路径一旦偏离并停留在偏离后的水平，损失就永久「兑现」为少持有的资产数量，与是否卖出无关。更准确的表述是「再平衡损失」：LP 在价格上行趋势中持续卖出上涨资产，在趋势行情中必然跑输持有者。

3.5.4　借贷协议：Kink 利率模型与清算

超额抵押借贷协议中，利率由资金利用率 U 内生决定。利用率定义为

$$U = \frac{\text{总借款}}{\text{总存款}} \tag{3.17}$$

两段式（kink）利率模型写成

$$r(U) = \begin{cases} r_0 + \dfrac{U}{U^*}(r_1 - r_0), & U \le U^* \\ r_1 + \dfrac{U - U^*}{1 - U^*}(r_2 - r_1), & U > U^* \end{cases} \tag{3.18}$$

其中 r_0 为利用率趋零时的基础利率，r_1 为拐点利率，U^* 为最优利用率（通常取 0.8–0.9），r_2 为利用率趋近 1 时的极端利率。式 (3.18) 的设计意图是：在 U^* 以下，利率对利用率不敏感以鼓励借款；在 U^* 以上，利率陡峭上升以吸引存款、抑制借款，防止出现「无钱可提」的流动性危机。

图 3.5的参数取自 Aave 类协议的典型设定。曲线在 U^* 处连续但不可导，这是刻意的：不可导意味着利率的边际变化在拐点处跃升，从而在接近满利用率时给出极强的价格信号。

借款人的偿债能力用健康因子度量：

$$HF = \frac{\sum_i C_i \cdot \text{LT}_i}{B}, \qquad \text{加权清算阈值} = \frac{\sum_i C_i \,\text{LT}_i}{\sum_i C_i} \tag{3.19}$$

其中 C_i 为第 i 种抵押品以计价货币折算的价值，LT_i 为其清算阈值（例如 ETH 取 0.825），B 为借款总额。$HF < 1$ 时任何地址均可触发清算，清算人以折扣价获得抵押品，并支付一笔清算罚金给协议金库。

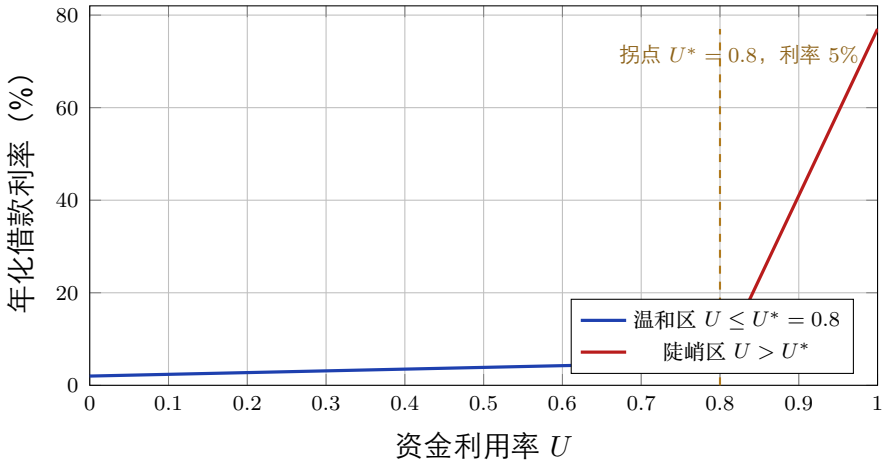


图 3.5　两段式 Kink 利率曲线（基础利率 2%，拐点 5%，极端 77%）

例 3.5　健康因子与清算触发价格

某用户存入 10 ETH，当时价格 2000 USDC/ETH，即抵押价值 20000 USDC；借出 12000 USDC 的稳定币；ETH 的清算阈值 LT = 0.825。则

$$HF = \frac{20000 \times 0.825}{12000} = 1.375$$

保持其他条件不变，触发清算（$HF = 1$）的 ETH 价格为

$$P^* = \frac{B}{\text{数量} \times \text{LT}} = \frac{12000}{10 \times 0.825} = 1454.5 \text{ USDC/ETH}$$

即 ETH 下跌 27.3% 时进入清算区。若用户把借款额降到 10000 USDC，则 $P^* = 1212.1$，安全垫扩大到 39.4%。若用户同时存入波动性更高的另类币（LT = 0.60）作为第二抵押品，其混合清算阈值为 $\frac{20000\times0.825+5000\times0.60}{25000} = 0.78$，安全垫进一步收窄。

⚠ 风险警示　清算与预言机：DeFi 的两处结构性脆弱

第一，清算依赖**预言机价格**而非真实成交价。当预言机更新延迟或依赖单一交易所时，攻击者可用闪电贷在该交易所瞬间砸盘，使链上预言机读数下跌，从而以极低成本触发并接管大量清算头寸。第二，清算在**拥堵时最需要却最难执行**。市场剧烈下跌时 Gas 价格飙升，清算机器人因利润不足而退出，坏账在协议内累积。2022 年多起借贷协议坏账事件均属于这一类型——不是价格模型错了，而是「清算激励」在极端时点失效。

3.5.5　MEV、抢跑与交易排序

区块生产者（或排序者）对交易顺序拥有裁量权，而顺序本身具有价值，这部分价值称为 MEV（最大可提取价值）。在 AMM 场景中，MEV 有精确的数学形式：设某笔待处理交易将把价格从 P 推至 P'，则夹在它前面的抢先交易可获的无风险利润约为

$$\text{MEV} \;=\; \big(P' - P\big) \cdot q \;-\; \text{Gas}, \tag{3.20}$$

其中 q 为抢先交易的规模，$P' - P$ 为被推高的价格。如式 (3.20) 所示，利润与被夹交易的规模成正相关，因此大额订单在链上会被系统性地「围猎」。

表 3.4　MEV 的主要类型与受害者

类型	提取机制	直接受害方
三明治攻击	在目标交易前后各插入一笔，赚取价格差	提交大额兑换的交易者
清算套利	抢先提交触发清算的交易，赚取清算折扣	被清算的借款人（罚金叠加）
DEX 套利	消除不同池之间的价差	报价偏离的池（即其 LP）
时间强盗	重组区块以抢占高价值交易	原区块生产者

表 3.4表明 MEV 并非「黑客行为」，而是排序权的自然租金。工程上的应对手段包括：用户设置严格滑点上限、使用隐私交易通道（交易在被打包前不进入公开内存池）、以及协议层面的批量拍卖（把排序权公开竞价，并将收益返还给用户或协议）。

3.6 扩容、跨链与治理

3.6.1　二层扩容的技术取舍

表 3.5　两类 Rollup 的对比

维度	Optimistic Rollup	zk-Rollup
正确性保证	欺诈证明（挑战期默认有效）	有效性证明（数学即刻验证）
提现延迟	通常 7 天（等待挑战窗口）	分钟级
链上成本	仅提交状态根与压缩数据	需验证证明，成本较高
通用性	兼容 EVM，迁移成本低	早期受电路约束，通用性较弱
主要风险	挑战者缺位导致无效状态被接受	证明系统实现漏洞、可信设置

表 3.5的取舍可以概括为：Optimistic Rollup 用「时间」换成本，zk-Rollup 用「计算」换即时性。对量化业务而言，提现延迟直接决定了资金周转效率，因此两者在资金成本上的差别往往大于手续费差别。

3.6.2　跨链桥的风险结构

跨链桥之所以成为攻击重灾区，原因在于它把「两条独立共识的资产」用「第三方验证」连接起来，从而引入了一个额外的信任假设。常见设计有三类：锁定–铸造（源链锁定、

目标链铸造映射资产）、流动性池（两侧各备流动性）、轻客户端验证（在目标链上验证源链共识）。

风险警示　桥的中心化风险与「安全预算倒挂」

锁定–铸造桥的验证者集合若由多签控制，则桥的安全性等于多签的安全性，而非两条链的安全性。更根本的问题是**安全预算倒挂**：桥中锁定的资产价值 A 常常远超验证者质押的价值 D，只要 $A > D$，理性攻击者就有动机直接攻破验证者而不必攻击任一条链。2022 年 Ronin 桥与 Wormhole 桥的事件都符合这一结构。评估桥的安全性时，通用方法是比较 A 与「验证者质押总值 × 攻破所需比例」。

3.6.3　DAO 治理与治理攻击

DAO 用代币投票替代公司章程。这一机制面临三类系统性缺陷：**投票权与利益不对称**（借贷协议中的治理代币可被借出并用于投票，借款人获得投票权却无经济后果）、**低投票率**（多数提案的实际投票率低于 10%，少数大户可轻易达到通过阈值）、**提案与执行的时序漏洞**（若投票权在快照后仍可转移，则存在「买票–投票–卖票」的瞬时攻击）。

实务应用　治理设计的工程约束

较稳健的治理设计通常包含四项约束：投票权按时间加权（需锁定一段时间才计入）、提案门槛与执行延迟（给出退出窗口）、国库支出需多签与时间锁双重确认、以及关键参数（抵押率、清算阈值、预言机地址）的变更需更长延迟。这些约束的共同作用是**把「瞬时控制」变成「持续控制」**，从而提高攻击成本。

3.7 监管、估值实务与本章定位

3.7.1　监管框架

美国证券法使用 Howey 测试判定某项安排是否构成「投资合同」：是否投入资金、是否存在共同事业、是否期待利润、利润是否来自他人的努力。四项同时成立则构成证券。欧盟的 MiCA 于 2024 年起分阶段实施，对稳定币发行方与加密资产服务提供商设定资本与披露要求。中国香港实行虚拟资产服务提供商（VASP）发牌制度，要求平台满足托管隔离、反洗钱与适当性评估。新加坡则主要通过支付服务法框架监管。

补充说明　监管差异对量化策略的实际影响

监管辖区的差异会直接改变策略的可行集：在要求客户资产隔离托管的辖区，交易所内部的对冲与再抵押受到限制，跨交易所套利的资金调度速度下降；在禁止向零售投资者销售衍生品的辖区，链上永续合约的资金费率套利只能通过离岸实体执行。因此合规不是策略之外的约束，而是策略参数的一部分。

3.7.2　代码：计算无常损失与 LP 净收益

下面这段 Python 代码实现了式 (3.13)，并回答小节 3.5.3中的盈亏平衡问题。

Listing 3.2 计算无常损失曲线与手续费盈亏平衡换手率

```python
import numpy as np

def impermanent_loss(rho):
    """Loss of an LP relative to holding, as a fraction (<= 0)."""
    rho = np.asarray(rho, dtype=float)
    return 2.0 * np.sqrt(rho) / (1.0 + rho) - 1.0

def pool_reserves(x0, y0, rho):
    """Reserves after arbitrage restores the marginal price to rho * P0.
       """
    return x0 / np.sqrt(rho), y0 * np.sqrt(rho)

def breakeven_turnover(rho, fee_rate):
    """Pool turnover (volume / TVL) needed to offset IL."""
    return -impermanent_loss(rho) / fee_rate

if __name__ == "__main__":
    for rho in (0.5, 0.8, 1.25, 2.0, 5.0):
        x1, y1 = pool_reserves(1.0, 10000.0, rho)
        v_lp = x1 * 10000.0 * rho + y1
        v_hodl = 1.0 * 10000.0 * rho + 10000.0
        print(f"rho={rho:5.2f}  IL={impermanent_loss(rho):8.4%}"
              f"  check={(v_lp / v_hodl - 1.0):9.5%}"
              f"  turnover={breakeven_turnover(rho, 0.003):7.2f}x")

    curve = impermanent_loss(np.linspace(0.1, 10.0, 400))
    print("worst case in [0.1, 10]:", f"{curve.min():.4%}")
```

运行 listing 3.2会输出与图 3.4一致的结果，其中 IL 与 check 两列分别对应式 (3.13) 的解析式与逐笔模拟，二者差值应在 10^{-12} 量级，可用于验证推导。

3.7.3 本章在全书中的位置

加密金融的定价问题与第 4 章的传统衍生品定价共享同一套无套利逻辑：AMM 的瞬间报价等价于一个深度有限的做市商，滑点公式式 (3.10) 与第 4 章的流动性折价是同一现象的两种表述；无常损失式 (3.13) 与第 4 章的 Delta 对冲损益同源，都是「在价格变动中被迫调整持仓」的代价。链上永续合约的资金费率机制、期权金库的自动做市策略，本质上都是把第 4 章的希腊字母管理交给智能合约执行。因此理解本章的数学，关键在于识别它与传统金融工程的同构关系，而非把它当作一套独立的新体系。

本章小结

- Web3 用共识开销换取「无需可信第三方」，其成本结构决定了链上业务必须在高费率环境下仍具备正毛利。
- Merkle 证明把轻节点的验证复杂度降到 $O(\log n)$，代价是必须信任链头选择；PoW 提供概率终局，PoS 与 BFT 类协议提供确定性终局。

- CPMM 的不变量 $xy = k$ 直接给出报价 y/x 与滑点 $\Delta x/(x + \Delta x)$；池深度是唯一决定执行质量的内生变量。
- 无常损失满足 $IL(\rho) = \frac{2\sqrt{\rho}}{1+\rho} - 1$，关于 $\rho = 1$ 对称，小幅波动下约为 $-(\rho-1)^2/8$。
- LP 是否值得做取决于换手率能否超过 $|IL|/\phi$；$\rho = 2$ 时按 0.3% 费率计算需要约 19 倍月换手。
- 借贷协议的风险集中在预言机读数与清算激励：$HF < 1$ 只是触发条件，能否被清算取决于当时的经济激励。
- MEV 是排序权的租金；跨链桥的根本风险是「锁定资产价值大于验证者质押价值」的安全预算倒挂。

练习与思考

1. 设某 CPMM 池中 X 与 Y 的储备分别为 500 与 1000。若某交易者先用 50 单位 X 兑换 Y，再用得到的 Y 全部换回 X（忽略手续费），最终持有的 X 是增加还是减少？请用两笔交易后的储备严格计算，并解释结论对流动性与交易者的含义。
2. 证明只有两笔交易时输出量对交易顺序敏感：证明 $\Delta y^{(1)} + \Delta y^{(2)} > \Delta y^{(1+2)}$ 当且仅当 $\Delta x_1 \Delta x_2 > 0$，并说明这与「分拆订单可以降低成本」的说法是否矛盾。
3. 某 LP 存入时两种代币价值各为 50000 美元。若价格比例变为 $\rho = 1.5$，求无常损失比例、LP 的持仓价值，以及相对于持有不动的美元损失。若费率为 0.05%，求盈亏平衡的月换手率。
4. 某借贷协议参数为 $U^* = 0.85$、$r_0 = 0\%$、$r_1 = 4\%$、$r_2 = 100\%$。当利用率从 0.85 上升到 0.95 时，借款利率上升多少个百分点？存款利率约为 $r(U) \cdot U \cdot (1 - \text{储备金率})$，若储备金率为 10%，求两种利用率下的存款利率。
5. 利用式 (3.18) 推导：当 $U \to 1$ 时存款利率的极限值为多少？该极限为何在工程上是必要的？
6. 某用户存入 5 ETH（价格 1800 USDC，LT = 0.80）与 20000 USDC（LT = 0.90），借出 15000 USDC。求当前健康因子，以及仅由 ETH 价格下跌触发清算的临界价格。
7. 某锁定–铸造跨链桥中锁定资产价值 6 亿美元，验证者多签需 5/8 个密钥，每个验证者平均质押 2000 万美元。若攻击者控制 5 个验证者，其成本与被窃取资产之比是多少？请据此评论该桥的安全边际。
8. 编写代码：对 listing 3.2进行扩展，加入「LP 头寸的美元价值随时间演化」的模拟，设价格按几何布朗运动演化，比较 LP 与持有不动的期望收益差，并验证该差值是否近似等于 $-\frac{1}{8}\mathbb{E}[(\rho-1)^2]$。

延伸阅读

- Uniswap 白皮书（Hayden Adams 等，2019–2021），给出了 CPMM 与集中流动性的原始数学，尤其是流动性区间的份额计算。

- Buterin, V., *Ethereum White Paper*，2014。理解账户模型与状态机抽象的最短路径。
- Daian, P. 等，“Flash Boys 2.0: Frontrunning in Decentralized Exchanges”，2019。首次系统性刻画 MEV 与交易排序市场，是理解链上微观结构的关键文献。
- Aave 与 Compound 的官方文档中关于利率模型、清算阈值与储备金的参数说明，可用于核对式 (3.18) 的取值。
- Harvey, C. 等，“DeFi and the Future of Finance”，2021。对 DeFi 的机制与风险做了较完整的综述，适合作为本章的延伸阅读。

第四章 金融工程

金融工程（Financial Engineering）是运用数学、统计学与计算机科学来设计、定价与管理金融产品的学科。它的独特之处在于：**定价与风险管理的答案不依赖于「未来会怎样」的主观预测，而只依赖于「复制成本是多少」这一无套利约束。**

4.1 金融工程方法论

4.1.1 核心工作循环

金融工程的实务流程可以概括为一个闭环：

$$\text{识别需求} \to \text{产品设计} \to \text{定价建模} \to \text{风险度量与对冲} \to \text{执行与生命周期管理}$$

核心要点 4.1

金融工程的第一性原理是**复制（replication）**：如果两个投资组合在任意未来状态下的现金流完全相同，它们在今天必须具有相同的价格。所有衍生品定价公式都是这一句话的推论，所有对冲策略都是在构造这样的复制组合。

4.1.2 三类基本构造块

几乎所有的金融产品都可以由三个基本构造块拼装而成，理解这一点比记住具体产品更重要：

表 4.1　金融产品的三个基本构造块

构造块	现金流特征	典型产品
无风险债券	确定性的未来现金流（本金与利息）	国债、零息债、货币市场工具
远期承诺	双方在到期日必须履约（对称的收益）	远期、期货、利率互换
期权权利	买方有权利无义务（不对称的收益）	期权、可转债、结构化产品

任何结构化产品都可以写成「债券 + 若干期权」的组合。例如保本票据 = 零息债券 + 看涨期权多头；自动赎回产品 = 附息债券 + 一系列敲出期权空头 + 敲入看跌期权多头。这一视角的价值在于：它把「复杂产品如何定价」转化成了「如何给一堆期权定价」，后者有成熟的方法论。

4.2 远期与期货定价

4.2.1 无套利定价与套利表

考虑标的资产现价 S_0、无风险利率 r、到期时间 T 的远期合约。以远期价格 F_0 成交、到期以 F_0 买入标的，两种复制路径的现金流如下：

表 4.2　远期的复制与套利表（$t=0$ 建仓，T 到期）

策略	$t=0$ 现金流	$t=T$ 现金流
买入远期（交割价 F_0）	0	$S_T - F_0$
买入现货并持有	$-S_0$	S_T
买入现货（借 S_0）	0	$S_T - S_0 \mathrm{e}^{rT}$
复制组合	0	$S_T - S_0 \mathrm{e}^{rT}$

两条 $t=0$ 现金流为零的路径在 T 时刻的现金流必须相同（否则可以套利），因此：

$$F_0 = S_0 \, \mathrm{e}^{rT} \tag{4.1}$$

考虑持有成本后，更一般的形式为：

$$F_0 = S_0 \, \mathrm{e}^{(r+u-y)T} \tag{4.2}$$

其中 u 为存储成本率（商品），y 为便利收益（convenience yield，持有现货带来的隐性收益）。对于支付连续股息率 q 的股票指数：

$$F_0 = S_0 \, \mathrm{e}^{(r-q)T} \tag{4.3}$$

例 4.1　股指期货定价与套利检验

设指数现价 $S_0 = 4500$，无风险利率 $r = 4\%$，指数股息率 $q = 1.8\%$，剩余期限 $T = 0.5$ 年。理论期货价格为

$$F_0 = 4500 \times \mathrm{e}^{(0.04-0.018)\times 0.5} = 4500 \times \mathrm{e}^{0.011} = 4549.8.$$

若市场上 6 个月股指期货报价为 4560，则期货相对理论值高估 10.2 点。套利操作是：**卖空期货、买入指数现货（或用 ETF 复制），并持有至到期**。到期时基差收敛，锁定约 $4560 - 4549.8 = 10.2$ 点的无风险利润（未计交易成本与保证金占用）。如果这 10.2 点小于「融券成本 + 冲击成本 + 保证金资金占用」，则套利不可行——这正是现实中基差可以长期偏离理论值的原因。

表 4.3　期货与远期的对比

特征	远期（Forward）	期货（Futures）
交易场所	场外（OTC），双边协商	交易所，中央对手方清算（CCP）
标准化	完全定制	标准化合约
信用风险	双边信用风险，需 ISDA/CSA 管理	CCP 承担，会员分担违约基金
保证金	通常无（或有 CSA 初始保证金）	逐日盯市（mark-to-market）
流动性	低，平仓困难	高，可随时对冲
价格差异	理论基准	因每日结算产生凸性调整

4.2.2　期货与远期的差异

补充说明　期货价格与远期价格为何略有不同

期货每日盯市，盈利可以立即再投资、亏损需要立即补充资金，因此**利率与期货价格正相关时，期货多头比远期多头更有利**（赚钱时利率高、再投资收益率高）。严格结果是：$F_{\text{futures}} \approx F_{\text{forward}} \exp\left(\frac{1}{2}\sigma^2 T^2\right)$ 的一阶修正（Cox–Ingersoll–Ross）。在 $r = 5\%$、$\sigma = 20\%$、$T = 1$ 的典型情形下差异约为 0.02%，实务中通常忽略；但在利率期货（如欧洲美元、国债期货）中这一差异不可忽略。

4.3 期权基础与到期收益

4.3.1　收益函数与内在价值

欧式看涨与看跌期权在到期日的收益分别为：

$$C_T = \max(S_T - K,\, 0), \qquad P_T = \max(K - S_T,\, 0) \tag{4.4}$$

在到期之前的任意时刻，期权价值可以分解为内在价值与时间价值：

$$V_t = \underbrace{\max(S_t - K, 0)}_{\text{内在价值}} + \underbrace{\text{时间价值}}_{\geq 0} \tag{4.5}$$

直觉理解　为什么美式看涨期权不会提前行权（无股息时）

提前行权放弃了两样东西：(1) 行权价 K 的时间价值（本可以晚点付钱）；(2) 期权在标的下跌时的保护价值（内在价值有下限 0，而持股没有）。因此在无股息、无摩擦的市场里，美式看涨与欧式看涨同价。**但只要标的支付足够高的股息，或者利率极高，提前行权就可能是最优的**——这正是股指期权与外汇期权需要认真处理提前行权边界的原因。

4.3.2 看跌看涨平价

买入看涨期权并持有现金 Ke^{-rT}，与买入看跌期权并持有标的，在到期日的收益完全相同：

$$C + Ke^{-rT} = P + S_0 \tag{4.6}$$

这是金融工程中最基本的复制关系，其重要性体现在三方面：

1. **定价一致性**：只要知道三个价格，第四个必须满足该关系，否则存在无风险套利；
2. **平价可以被市场数据检验**：如果 $C + Ke^{-rT} - P - S_0 \neq 0$，其偏差的规模就是套利成本的下界；
3. **可用来提取信息**：把平价关系两边同时加减可得「隐含远期价格」$F_0 = S_0 e^{rT} = C - P + Ke^{-rT}$，因此期权市场可以反推出市场对未来股息的预期。

例 4.2　用期权价格反推隐含股息率

设 $S_0 = 100$、$r = 5\%$、$T = 0.25$，平值附近看涨 $C = 4.20$、看跌 $P = 3.05$、$K = 100$。由平价关系得到隐含远期价格

$$F_0 = C - P + Ke^{-rT} = 4.20 - 3.05 + 100 \times e^{-0.0125} = 1.15 + 98.7576 = 99.908,$$

而理论无股息远期价格为 $100 \times e^{0.0125} = 101.258$。两者之差说明市场隐含了正股息：由 $S_0 e^{(r-q)T} = 99.908$ 解得 $q = r - \frac{\ln(99.908/100)}{T} = 0.05 + 0.00368/0.25 \approx 6.5\%$。这正是「期权平价提取股息预期」的用法。

4.3.3 期权组合策略

期权组合的本质是对收益曲线形状的下注。图 4.1 给出四个经内组合的到期收益。

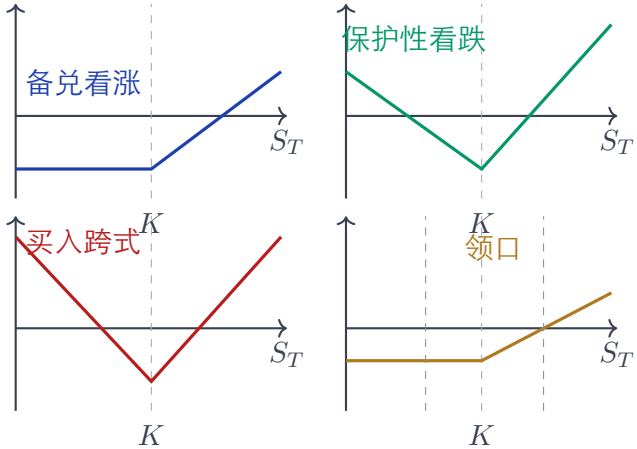


图 4.1　四个常见期权组合的到期收益（纵轴为相对期初的损益）

表 4.4　主要期权策略的风险收益特征

策略	构成与适用观点	主要风险
备兑看涨	持股 + 卖出看涨。温和看涨、以放弃上行换取权利金	标的大跌时保护有限
保护性看跌	持股 + 买入看跌。看涨但需下行保护	权利金持续侵蚀收益
买入跨式	同时买入同行权价看涨与看跌。预期大幅波动但方向不明	需足够大的波动才盈利，时间损耗严重
卖出跨式	同时卖出看涨与看跌。预期波动收敛	理论上亏损无上限，尾部风险极高
牛市价差	买入低行权价看涨 + 卖出高行权价看涨	收益封顶，成本较低
蝶式	卖出两个平值期权、买入两侧虚值期权	需要精确的价格落点
领口	持股 + 买入看跌 + 卖出看涨	上下都被截断，适合区间预期

4.4 Black–Scholes–Merton 模型

4.4.1　假设与标的动态

BSM 建立在以下假设之上：标的服从几何布朗运动、无摩擦市场（无交易成本与税）、可连续交易与卖空、常数无风险利率与常数波动率、标的在期权存续期内不支付股息、无套利机会。

$$\mathrm{d}S_t = \mu S_t\,\mathrm{d}t + \sigma S_t\,\mathrm{d}W_t \tag{4.7}$$

由伊藤引理（详见第 10 章）可得对数价格服从正态分布：

$$\ln S_T \sim \mathcal{N}\!\left(\ln S_0 + \left(\mu - \tfrac{1}{2}\sigma^2\right)T,\ \sigma^2 T\right) \tag{4.8}$$

其中 $-\frac{1}{2}\sigma^2$ 项被称为**伊藤修正**：它说明在存在波动的情况下，**几何平均增长率（对数收益的期望）小于算术平均增长率** μ。这一项是波动率拖累（volatility drag）的数学来源。

4.4.2　Delta 对冲与 BSM 方程

构造「买入一份期权、卖出 Δ 份标的」的组合 $\Pi = V - \Delta S$。在 $[t, t+\mathrm{d}t]$ 上：

$$\mathrm{d}\Pi = \mathrm{d}V - \Delta\,\mathrm{d}S = \left(\frac{\partial V}{\partial t} + \tfrac{1}{2}\sigma^2 S^2\frac{\partial^2 V}{\partial S^2}\right)\mathrm{d}t + \left(\frac{\partial V}{\partial S} - \Delta\right)\mathrm{d}S \tag{4.9}$$

取 $\Delta = \frac{\partial V}{\partial S}$ 可完全消除随机项，此后组合在 $\mathrm{d}t$ 内是无风险的，必须获得无风险收益：

$$\mathrm{d}\Pi = r\Pi\,\mathrm{d}t = r\left(V - S\frac{\partial V}{\partial S}\right)\mathrm{d}t \tag{4.10}$$

令两式相等，即得 Black–Scholes 偏微分方程：

$$\frac{\partial V}{\partial t}+\tfrac{1}{2}\sigma^2 S^2\frac{\partial^2 V}{\partial S^2}+rS\frac{\partial V}{\partial S}-rV=0 \tag{4.11}$$

核心要点 4.2

BSM 方程中不出现漂移率 μ，这是整个理论的支点。它的经济含义是：期权的价格只取决于波动率这一不确定性的大小，而与投资者对标的涨跌的主观预期无关——因为预期已经被「用标的做对冲」这个动作消掉了。这一性质被称为**偏好无关（preference-free）**，也是风险中性定价的直观来源。

4.4.3 解析解与风险中性定价

以欧式看涨期权为终端条件求解 式 (4.11)，或等价地在风险中性测度 $\mathbb{Q}$ 下取期望：

$$C=\mathrm{e}^{-rT}\,\mathbb{E}^{\mathbb{Q}}\big[(S_T-K)^+\big] \tag{4.12}$$

在 $\mathbb{Q}$ 下 $S_T=S_0\exp\Big((r-\tfrac{1}{2}\sigma^2)T+\sigma\sqrt{T}Z\Big)$，$Z\sim\mathcal{N}(0,1)$，积分可得：

$$C=S_0\,N(d_1)-K\mathrm{e}^{-rT}N(d_2) \tag{4.13}$$

$$d_1=\frac{\ln(S_0/K)+\left(r+\tfrac{1}{2}\sigma^2\right)T}{\sigma\sqrt{T}},\qquad d_2=d_1-\sigma\sqrt{T} \tag{4.14}$$

其中 $N(\cdot)$ 为标准正态累积分布函数。看跌期权由平价关系给出 $P=K\mathrm{e}^{-rT}N(-d_2)-S_0N(-d_1)$。

例 4.3　平值期权的定价与计算复核

设 $S_0=K=100$、$r=5\%$、$\sigma=20\%$、$T=1$ 年。则

$$d_1=\frac{0+(0.05+0.02)\times 1}{0.2}=0.35,\qquad d_2=0.15.$$

查表得 $N(0.35)=0.6368$、$N(0.15)=0.5596$，于是

$$C=100\times 0.6368-100\times\mathrm{e}^{-0.05}\times 0.5596=63.68-95.1229\times 0.5596=10.45.$$

由平价关系 $P=C-S_0+K\mathrm{e}^{-rT}=10.45-100+95.12=5.57$。注意 C 明显大于内在价值 0，其中 $10.45-0=10.45$ 全部是时间价值——平值期权的时间价值最大，这是 Theta 在平值附近最陡的根本原因。

4.4.4 隐含波动率与求解

隐含波动率是把市场价格代入 BSM 公式后反解出的 σ。由于 BSM 价格关于 σ 单调递增，该反解唯一，可用 Newton–Raphson 迭代高效求得（导数正好是 Vega）：

$$\sigma_{n+1} = \sigma_n - \frac{C_{\mathrm{BSM}}(\sigma_n) - C_{\mathrm{mkt}}}{\nu(\sigma_n)}, \qquad \nu = S_0 \phi(d_1)\sqrt{T} \tag{4.15}$$

Listing 4.1 BSM 定价与 Newton 法反解隐含波动率

```python
import numpy as np
from scipy.stats import norm

def bsm(S, K, r, sigma, T, kind="call"):
    """Black-Scholes price of a European option (no dividends)."""
    d1 = (np.log(S / K) + (r + 0.5 * sigma ** 2) * T) / (sigma * np.sqrt(T))
    d2 = d1 - sigma * np.sqrt(T)
    if kind == "call":
        return S * norm.cdf(d1) - K * np.exp(-r * T) * norm.cdf(d2)
    return K * np.exp(-r * T) * norm.cdf(-d2) - S * norm.cdf(-d1)

def vega(S, K, r, sigma, T):
    d1 = (np.log(S / K) + (r + 0.5 * sigma ** 2) * T) / (sigma * np.sqrt(T))
    return S * norm.pdf(d1) * np.sqrt(T)

def implied_vol(price, S, K, r, T, kind="call", tol=1e-10, max_iter=100):
    """Newton-Raphson with a bisection safeguard on the moneyness bounds."""
    lo, hi = 1e-4, 5.0
    if not (bsm(S, K, r, lo, T, kind) <= price <= bsm(S, K, r, hi, T, kind)):
        return np.nan                       # violates no-arbitrage bounds
    sigma = 0.2
    for _ in range(max_iter):
        diff = bsm(S, K, r, sigma, T, kind) - price
        if abs(diff) < tol:
            return sigma
        v = vega(S, K, r, sigma, T)
        if v < 1e-8:                        # deep OTM / near expiry: fall back
            sigma = 0.5 * (lo + hi)
            if bsm(S, K, r, sigma, T, kind) < price:
                lo = sigma
            else:
                hi = sigma
            continue
        sigma -= diff / v
        sigma = float(np.clip(sigma, lo, hi))
    return sigma
```

⚠ 风险警示　隐含波动率的三个陷阱

1. **不是预测**：隐含波动率是市场对未来波动率的定价，包含风险溢价，系统性高于随后实现的波动率；
2. **不是常数**：同一标的、同一时刻，不同行权价与不同期限的隐含波动率系统性不同（微笑与期限结构），因此「BSM 是错的」这一说法更准确的表达是「BSM 只是一个把价格翻译成波动率的约定」；
3. **反解可能失败**：当价格违反无套利边界（低于内在价值、或高于标的价）时无解；当 Vega 趋于零时数值不稳定，必须用二分法兜底。

4.5 期权希腊字母

4.5.1　显式解析式

希腊字母是期权价格对各风险因子的敏感度，也是交易台风险系统的通用语言。下表给出无股息欧式期权的解析式，其中 $\phi(\cdot)$ 为标准正态密度函数。

表 4.5　欧式看涨期权的希腊字母解析式

希腊字母	定义	看涨期权解析式	经济含义
Δ	$\frac{\partial V}{\partial S}$	$N(d_1)$	标的每变动 1 元，期权价值变动 Δ 元；也是对冲所需标的份数
Γ	$\frac{\partial^2 V}{\partial S^2}$	$\frac{\phi(d_1)}{S\sigma\sqrt{T}}$	Delta 的变化率；衡量对冲误差的曲率
ν（Vega）	$\frac{\partial V}{\partial \sigma}$	$S\phi(d_1)\sqrt{T}$	波动率每变动 1 个百分点（0.01）的价值变化
Θ	$\frac{\partial V}{\partial t}$	$-\frac{S\phi(d_1)\sigma}{2\sqrt{T}} - rK\mathrm{e}^{-rT}N(d_2)$	每经过一天损失的时间价值
ρ	$\frac{\partial V}{\partial r}$	$KT\mathrm{e}^{-rT}N(d_2)$	利率每变动 1 个百分点的价值变化

核心要点 4.3

Gamma 是期权的「加速度计」：平值（ATM）近到期期权的 Gamma 极高，标的的微小变动就会使 Delta 剧烈改变，因此**对冲频率必须相应提高**。Vega 则在平值附近最大、在长期限上最大——这意味着**长期平值期权是最贵的波动率敞口**。交易员正是通过组合不同的 Δ、Γ、ν 敞口来表达对市场方向、波动幅度与期限结构的观点。

4.5.2 希腊字母之间的关系与 Delta 对冲误差

BSM 方程本身就是希腊字母之间的一个恒等式：

$$\Theta + \tfrac{1}{2}\sigma^2 S^2 \Gamma + rS\Delta - rV = 0 \tag{4.16}$$

它说明时间损耗（$\Theta < 0$）必然被 Gamma 收益所补偿：持有正 Gamma 的组合在标的大幅波动中获益，代价是每天支付时间价值。做市商的核心工作就是让「Gamma 收益」长期覆盖「Theta 成本」。

另一方面，由于无法连续对冲，实际 PnL 与理论值之间存在离散化误差。在 Δt 后重新对冲的近似 PnL 为：

$$\mathrm{PnL} \approx \underbrace{\Theta\,\Delta t}_{\text{时间损耗}} + \underbrace{\tfrac{1}{2}\Gamma\,(\Delta S)^2}_{\text{Gamma 收益}} \approx \tfrac{1}{2}\Gamma S^2\left(\sigma^2_{\text{realized}} - \sigma^2_{\text{implied}}\right)\Delta t \tag{4.17}$$

直觉理解　一句话记住 Delta 对冲的盈亏本质

式 式 (4.17) 说明：**做多期权（正 Gamma）并在市场上对冲，等价于做多波动率。**当实际波动率高于你买入时的隐含波动率，你就赚钱；反之则亏钱。这解释了为什么「卖出期权收取权利金」在没有波动率优势时是一个负期望的策略——它并不是「稳赚权利金」，而是「做空波动率」。

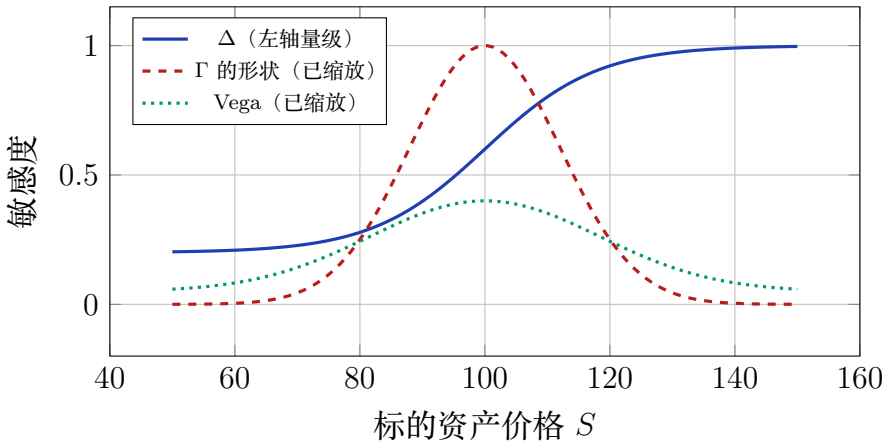


图 4.2　Delta、Gamma 与 Vega 随标的价格的变化（示意）

如 图 4.2 所示，Delta 呈 S 形（在深度实值趋于 1、深度虚值趋于 0），Gamma 与 Vega 均在平值附近达到峰值，但 Vega 的峰更宽——因为 Vega 同时受波动率与期限影响，而 Gamma 在临近到期时会急剧集中。

4.6 波动率建模

4.6.1 波动率微笑与偏斜

若 BSM 完全正确，不同行权价的隐含波动率应该完全相同（一条水平线）。但真实市场呈现系统性的形状：

- **外汇市场**：微笑。两端虚值期权的隐含波动率都高于平值，因为汇率大幅双向跳动的风险被定价；
- **股票市场**：**偏斜（skew）**。低行权价（虚值看跌）的隐含波动率显著高于高行权价，反映市场对崩盘风险的定价——即**杠杆效应**：股价下跌时波动率上升；
- **期限结构**：短期偏斜最陡，随期限拉长而平缓，长期趋于水平。

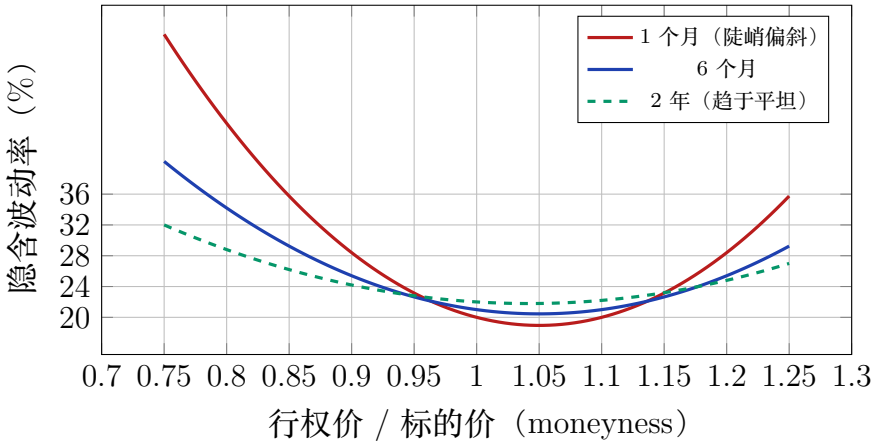


图 4.3　股票指数隐含波动率的偏斜与期限结构（示意）

4.6.2 局部波动率模型

Dupire (1994) 证明：给定完整的期权价格曲面 $C(K,T)$，存在唯一的确定性函数 $\sigma_L(S,t)$ 使得 BSM 的框架能精确重现所有市场价格：

$$\sigma_L^2(K,T) = \frac{\frac{\partial^2 C}{\partial T^2} + rK\frac{\partial C}{\partial K}}{\frac{1}{2}K^2\frac{\partial^2 C}{\partial K^2}} \tag{4.18}$$

⚠ 风险警示　局部波动率的「虚假动力学」

局部波动率模型可以完美拟合今天的波动率曲面，但它对**曲面未来如何演化**的预测通常很糟糕：它隐含的「波动率随机性」与标的的相关性被人为锁定，导致用该模型给远期起始期权（forward-start）或障碍期权定价时出现系统性偏差。这正是随机波动率模型（Heston、SABR）在实务中更受青睐的原因：**拟合能力与动力学合理性是两件不同的事**。

4.6.3 随机波动率：Heston 模型

Heston（1993）让波动率本身也成为随机过程：

$$\mathrm{d}S_t = \mu S_t\,\mathrm{d}t + \sqrt{v_t}\,S_t\,\mathrm{d}W_t^S \tag{4.19}$$

$$\mathrm{d}v_t = \kappa(\theta - v_t)\,\mathrm{d}t + \xi\sqrt{v_t}\,\mathrm{d}W_t^v \tag{4.20}$$

其中 v_t 为瞬时方差，κ 为均值回复速度，θ 为长期方差，ξ 为波动率的波动率（vol-of-vol），且 $\mathrm{d}W_t^S\mathrm{d}W_t^v = \rho\,\mathrm{d}t$。股票市场通常估计出 $\rho < 0$（约 -0.6 至 -0.8），这正是**杠杆效应**的参数化，也是 Heston 能生成真实偏斜的原因。

Feller 条件 $2\kappa\theta \geq \xi^2$ 保证方差过程不触及零。Heston 模型存在对数价格特征函数的解析解，因此可以配合傅里叶方法（第 6 章）实现半解析定价，这是它在业界流行的关键。

4.6.4 SABR 与市场惯例

SABR（Hagan 等，2002）对远期价格与波动率建模：

$$\mathrm{d}F_t = \alpha_t F_t^{\beta}\,\mathrm{d}W_t^1, \qquad \mathrm{d}\alpha_t = \nu\alpha_t\,\mathrm{d}W_t^2, \qquad \mathrm{d}W^1\mathrm{d}W^2 = \rho\,\mathrm{d}t \tag{4.21}$$

SABR 的流行不是因为更「正确」，而是因为它有**渐近解析的隐含波动率近似公式**，在给定 α, β, ρ, ν 后可以极快地生成整条微笑曲线，且参数具有清晰的市场含义（ρ 控偏斜、ν 控曲率、α 控水平）。对利率市场而言，这种「可校准、可插值、可平滑」的实用价值往往高于理论纯净性。

4.7 结构化产品

4.7.1 保本票据

保本票据（Principal-Protected Note, PPN）= 零息债券 + 看涨期权多头：

$$V_0 = \underbrace{K\mathrm{e}^{-rT}}_{\text{保本部分}} + \underbrace{\lambda\,C_0}_{\text{参与上行}}, \qquad \lambda = \frac{1 - K\mathrm{e}^{-rT}}{C_0} \tag{4.22}$$

其中 λ 为参与率。由式 式 (4.22) 可见：**利率越高、期限越长、波动率越低，参与率越高**。这解释了为什么「保本 + 高参与率」在低利率环境中几乎不可能同时实现——这是 2010 年代后全球低利率环境下保本型产品萎缩的直接原因。

4.7.2 自动赎回产品（Autocallables）与雪球

自动赎回结构在观察日检验标的价格：若高于敲出障碍（通常为期初的 100%），产品提前赎回并支付累计票息；若跌破敲入障碍（通常为期初的 70%–80%），到期时承担标的下跌的损失。

投资者实质上卖出了一个敲出期权并买入了一个敲入看跌期权，因而是「卖出波动率 + 卖出尾部保护」的组合：

$$V_{\text{autocall}} = \underbrace{B(0,T)}_{\text{债券}} - \underbrace{\sum_i \text{KO}_i}_{\text{敲出期权空头}} + \underbrace{\text{KI Put}}_{\text{敲入看跌多头}} \tag{4.23}$$

⚠ 风险警示　雪球类产品的真实风险

这类产品的票息本质上来自**卖出波动率与尾部保护**，而不是「无风险的固定收益」。2015 年与 2024 年 A 股、以及 2018–2020 年间的多轮快速下跌中，大量雪球产品集中敲入，投资者在「以为有票息保护」的情况下承担了显著的本金损失。关键风险特征是：**长期横盘或小幅上涨时收益良好，一旦发生快速深跌，损失以标的跌幅线性呈现，且没有上限保护**。产品越「看起来稳健」，越需要检查它隐含卖出了什么。

4.8 利率衍生品

4.8.1　利率互换

利率互换（IRS）中，固定端支付固定利率 K，浮动端支付 SOFR（历史上为 LIBOR）。在无套利条件下，互换利率等于使互换初始价值为零的固定利率：

$$K = \frac{1 - B(0,T_n)}{\sum_{i=1}^{n} \tau_i B(0,T_i)} \tag{4.24}$$

其中 $B(0,T_i)$ 为贴现因子，τ_i 为计息期长度。分子可以理解为「用浮动端换固定端」的净现值：支出浮动相当于在 T_n 支付 1 元（通过浮动端复利累积），因此互换的定价完全由贴现曲线决定。

4.8.2　互换期权与利率上下限

Caplet（单期利率上限）是标的为远期利率的看涨期权，其 Black 公式为：

$$\text{Caplet} = \tau\, B(0,T_{i+1})\Big[F_i N(d_1) - K N(d_2)\Big], \qquad d_{1,2} = \frac{\ln(F_i/K) \pm \frac{1}{2}\sigma_i^2 T_i}{\sigma_i \sqrt{T_i}} \tag{4.25}$$

其中 F_i 为远期利率，σ_i 为该 Caplet 的 Black 波动率。**把一系列 Caplet 的波动率拼起来就得到 Cap 波动率曲面**，它是利率市场最重要的校准输入之一。互换期权（swaption）则是标的为互换利率的期权，与 Cap 一起构成了利率波动率曲面的两个维度（Cap–Swaption 校准是利率建模的经典难点）。

4.9 信用衍生品

4.9.1 信用违约互换

CDS 买方定期支付保费（价差 s），在参考实体违约时获得 $(1-R)$ 的赔偿，其中 R 为回收率。让「保费现值 = 保护现值」即可求保本价差：

$$s \approx \frac{(1-R)\sum_i B(0,t_i)\,[Q(t_{i-1})-Q(t_i)]}{\sum_i \tau_i B(0,t_i) Q(t_i)} \tag{4.26}$$

其中 $Q(t)$ 为生存概率（至 t 仍未违约的概率）。**在平坦的违约强度与贴现率假设下，上式化简为一个非常有用的近似** $s \approx (1-R)\lambda$，其中 λ 为违约强度（风险率）。例如 $R = 40\%$、$\lambda = 2\%$ 时，$s \approx 0.6 \times 2\% = 120$ 个基点。这个关系说明了为什么 CDS 价差是**市场对违约概率的实时报价**——观察 CDS 价差的变化就等于观察市场隐含违约概率的变化。

4.9.2 担保债务凭证与相关风险

CDO 把信用风险池按承担损失的顺序分层（tranche）：优先层（Senior）、夹层级（Mezzanine）、权益层（Equity）。损失自下而上吸收，因此**权益层承担最先发生的损失，优先层只在损失超过一定门槛后才受损**。

定价的核心困难是**违约相关性**：一个由 100 个平均违约概率 2% 的贷款组成的池子，如果违约完全独立，权益层几乎必然亏损、优先层几乎无风险；但如果所有贷款同时违约（相关 = 1），优先层也会被击穿。Gaussian Copula 提供了刻画这种相关性的框架：

$$X_i = \sqrt{\rho}\,Z + \sqrt{1-\rho}\,\varepsilon_i, \qquad Z, \varepsilon_i \sim \mathcal{N}(0,1) \text{ 独立} \tag{4.27}$$

⚠ 风险警示　Gaussian Copula 与 2008 年危机

Gaussian Copula 模型的问题不是数学错误，而是**把「相关性」简化成了一个常数，并且严重低估了尾部同时违约的概率**。它无法刻画：违约在压力期高度聚集、回收率在危机中同时下降（ρ 与 R 而非独立）、以及流动性消失时价格的断崖。2008 年的教训是：**当模型的关键参数（相关性）无法用历史数据可靠估计时，用它推导出的分层评级就是脆弱的**。现代实践倾向于 t-Copula（更厚的联合尾部）、因子模型加压力情景，并对相关性做敏感性上下限分析。

4.9.3 XVA：估值调整框架

金融危机后，衍生品定价从「无风险价值」演化为「无风险价值 + 一系列估值调整」：

$$V_{\text{total}} = V_{\text{risk-free}} - \text{CVA} + \text{DVA} - \text{FVA} - \text{MVA} - \text{KVA} \tag{4.28}$$

表 4.6　XVA 家族的构成

调整项	含义	驱动因素
CVA	交易对手违约给我方带来的预期损失	对手 CDS 价差、敞口分布
DVA	我方自身违约带来的「收益」（会计上有争议）	自身 CDS 价差
FVA	为抵押品融资的成本或收益	资金成本、抵押品条款
MVA	初始保证金的资金占用成本	IM 模型（SIMM）
KVA	资本占用对应的资本成本	监管资本要求

4.10 风险管理框架

4.10.1　在险价值与预期亏空

在置信水平 α 与持有期 h 下，在险价值（VaR）定义为损失分布的 α 分位数：

$$\mathrm{VaR}_\alpha = \inf\{x : \mathbb{P}(L > x) \le 1 - \alpha\} \tag{4.29}$$

正态假设下的参数化形式为 $\mathrm{VaR}_\alpha = \mu + \sigma z_\alpha$，其中 z_α 为标准正态的 α 分位数。

预期亏空（ES，亦称 CVaR）是超过 VaR 之后的平均损失：

$$\mathrm{ES}_\alpha = \mathbb{E}\left[L \mid L > \mathrm{VaR}_\alpha\right] \tag{4.30}$$

核心要点 4.4

VaR 有两个致命缺陷：(1) **不满足次可加性**，即 $\mathrm{VaR}(A+B)$ 可能大于 $\mathrm{VaR}(A)+\mathrm{VaR}(B)$，这意味着「分散化」在 VaR 度量下可能显示为增加风险，与直觉和监管目标冲突；(2) **对尾部形状不敏感**，只报告分位点，完全不告诉我们分位点以外的损失有多大。ES 满足包括次可加性在内的一致性风险度量公理，因而被 Basel III 的市场风险框架（FRTB）采纳。但要注意：**ES 的可回测性差于 VaR**，因为尾部的样本极少，检验功效低。

4.10.2　压力测试与情景分析

历史情景：2008 年全球金融危机、2020 年新冠冲击、2022 年加息周期、2015 年 A 股流动性危机。假设情景：权益下跌 30% 同时信用价差扩大 200bp、利率上升 200bp 同时波动率翻倍、本币贬值 20% 同时资本外流等复合冲击。

实务应用　压力测试的工程要点

- 情景必须是**一致的多资产冲击**：不能只跌股票而不动信用价差与波动率，因为现实中这些变量的相关性在压力期会显著上升；

- 必须反映**非线性与凸性**：期权组合在极端冲击下的损失不能靠 Delta 线性外推，至少要包含 Gamma 与 Vega 的影响；
- 必须包含**流动性折价**：压力情形下的变现成本通常是最主要的损失来源；
- 情景的来源应当可追溯（历史重演、监管规定、专家判断），并明确标注假设，而不是只给一个数字。

本章小结

- 金融工程的第一性原理是无套利复制；远期价格 $F_0 = S_0 \mathrm{e}^{(r+u-y)T}$，期权必须满足平价关系 $C + K\mathrm{e}^{-rT} = P + S_0$。
- BSM 方程不含漂移率 μ，因为 Delta 对冲已经消去了方向性风险；定价只依赖波动率。
- 希腊字母是风险语言：$\Delta = N(d_1)$、$\Gamma = \phi(d_1)/(S\sigma\sqrt{T})$、$\nu = S\phi(d_1)\sqrt{T}$，并且满足恒等式 $\Theta + \frac{1}{2}\sigma^2 S^2\Gamma + rS\Delta - rV = 0$。
- 离散对冲的 PnL 近似为 $\frac{1}{2}\Gamma S^2(\sigma^2_{\text{realized}} - \sigma^2_{\text{implied}})\Delta t$——做多期权即做多波动率。
- 波动率微笑与偏斜是市场对尾部风险的定价；局部波动率能拟合曲面但动力学不可靠，Heston 与 SABR 是实务主流。
- 结构化产品（保本票据、自动赎回、雪球）都可以拆成「债券 + 期权」，票息越「稳健」越要检查隐含卖出了什么风险。
- 信用衍生品的核心是违约强度与相关性；Gaussian Copula 的失败是 2008 年的重要数学教训。
- 风险管理中 ES 优于 VaR（一致性），但可回测性更差；压力测试必须是一致、非线性且可追溯的。

练习与思考

1. 设 $S_0 = 80$、$r = 3\%$、连续股息率 $q = 4\%$、$T = 2$。求理论远期价格。若市场价格为 76，请写出完整的套利操作与利润（忽略成本）。
2. 用看跌看涨平价证明：欧式看涨期权价格必须落在 $\left[\max(S_0\mathrm{e}^{-qT} - K\mathrm{e}^{-rT}, 0),\ S_0\mathrm{e}^{-qT}\right]$ 区间内，并解释上下界的金融含义。
3. 已知 $\Delta = N(d_1)$，请推导 $\Gamma = \phi(d_1)/(S\sigma\sqrt{T})$，并说明为什么 Γ 在临近到期且平值时爆炸。
4. 某投资者卖出 3 个月平值跨式期权，收取权利金 8 元（$S_0 = K = 100$，$\sigma = 25\%$）。请计算到期时盈亏平衡的两个价格，并解释为什么「波动率下降」比「标的上涨」对该策略更不利。
5. 某 5 年期 CDS 参考实体回收率 35%，市场报价 180bp。请用近似公式估计隐含的

年度违约强度，并说明该近似的两个主要误差来源。

6. 某雪球产品敲入线为期初的 75%，敲出线为 100%，期限 2 年，票息年化 15%。请分别讨论「一年后标的上涨 10% 」与「一年后标的下跌 30%」两种情形下投资者的实际收益，并从卖波动率的角度解释票息的来源。

延伸阅读

- Hull, J. C., *Options, Futures, and Other Derivatives*, 10th ed., Pearson, 2018.（产品、希腊字母与实务细节的标准教材，第 4–6、15–20 章）
- Black, F., and Scholes, M., "The Pricing of Options and Corporate Liabilities", *Journal of Political Economy*, 1973, 81(3): 637–654.（定价理论的起点，值得读原论文的推导思路）
- Merton, R. C., "Theory of Rational Option Pricing", *Bell Journal of Economics*, 1973, 4(1): 141–183.（把复制思想推至一般化，含提前行权边界）
- Heston, S. L., "A Closed-Form Solution for Options with Stochastic Volatility", *Review of Financial Studies*, 1993, 6(2): 327–343.（随机波动率与特征函数方法）
- Hagan, P. S., et al., "Managing Smile Risk", *Wilmott Magazine*, 2002.（SABR 模型与市场微笑的参数化惯例）
- Li, D. X., "On Default Correlation: A Copula Function Approach", *Journal of Fixed Income*, 2000, 9(4): 43–54.（理解 CDO 定价与 2008 年教训的必读文献）
- Brigo, D., and Mercurio, F., *Interest Rate Models — Theory and Practice*, 2nd ed., Springer, 2006.（利率衍生品与波动率曲面的系统参考）

第五章 金融数学

第 4 章讨论的是金融工程的**定价原理**，本章讨论支撑这些原理的**计算与数学工具**：利息理论是现金流折现的语言，债券数学是利率风险的度量，偏微分方程、树方法与蒙特卡洛是三大定价引擎，数值优化则是把「模型」变成「决策」的桥梁。

5.1 利息理论

5.1.1 计息方式与利率换算

三种基本计息方式的终值分别为

$$\text{单利：}\quad A = P(1+rt) \tag{5.1}$$

$$\text{复利：}\quad A = P(1+i)^{t} \tag{5.2}$$

$$\text{连续复利：}\quad A = P\mathrm{e}^{\delta t} \tag{5.3}$$

其中 P 为本金，i 为每期实际利率，δ 为**利息力**（force of interest）。三者满足 $\mathrm{e}^{\delta} = 1+i$，即 $\delta = \ln(1+i)$。连续复利在理论上最重要，因为指数函数在求导与积分下形式优美，几乎所有随机模型都使用连续复利。

若一年计息 m 次，名义年利率记为 $i^{(m)}$，则它与实际年利率 i 的关系为

$$1+i = \left(1+\frac{i^{(m)}}{m}\right)^{m} \quad\Longrightarrow\quad i^{(m)} = m\left[(1+i)^{1/m}-1\right] \tag{5.4}$$

例 5.1　复利的威力与利率换算

名义年利率 12%、按月计息（$m=12$）时，实际年利率为 $(1+0.12/12)^{12}-1 = 1.01^{12}-1 = 12.68\%$。若改为连续复利，则 $\delta = 12\%$ 对应的实际年利率为 $\mathrm{e}^{0.12}-1 = 12.75\%$。**同一句「年利率 12%」在不同计息口径下相差 75 个基点**——这正是监管要求披露「年化百分率（APR）」与「实际年利率（EAR）」的原因。

5.1.2 年金

年金（annuity）是等间隔的一系列等额现金流。以贴现因子 $v = 1/(1+i)$、贴现率 $d = i/(1+i) = 1-v$ 表示，常用现值公式如下表。

表 5.1　常用年金现值公式

类型	现值	说明
期末付年金 $a_{\overline{n}\vert}$	$\dfrac{1-v^n}{i}$	每期末支付 1 元，共 n 期
期初付年金 $\ddot{a}_{\overline{n}\vert}$	$\dfrac{1-v^n}{d}$	每期初支付，比期末付多一期利息
永续年金 $a_{\overline{\infty}\vert}$	$\dfrac{1}{i}$	无限期，是 Gordon 增长模型的基础
m 次年金 $a^{(m)}_{\overline{n}\vert}$	$\dfrac{1-v^n}{i^{(m)}}$	每年支付 m 次
递增年金 $(Ia)_{\overline{n}\vert}$	$\dfrac{\ddot{a}_{\overline{n}\vert}-nv^n}{i}$	支付额为 $1,2,\dots,n$
递减年金 $(Da)_{\overline{n}\vert}$	$\dfrac{n-a_{\overline{n}\vert}}{i}$	支付额为 $n,n-1,\dots,1$

直觉理解　永续年金为什么是 $1/i$

假设利率 5%，永续年金每期 1 元的价值是 $1/0.05=20$ 元。一个等价的解释是：把 20 元存入银行，每年产生 1 元利息，本金永远不动。**这个「本金 × 利率 = 永续收益」的直觉是全部估值倍数（P/E、Cap Rate、资本化率）的根源**：任何永续现金流的价值都等于「现金流 ÷ 贴现率」。

5.1.3　贷款摊销

等额本息贷款的每期还款额 R 满足 $L=R\,a_{\overline{n}\vert}$，故

$$R=\frac{L\,i}{1-(1+i)^{-n}} \tag{5.5}$$

第 k 期的利息与本金部分分别为

$$I_k=R\left(1-v^{n-k+1}\right),\qquad P_k=R\,v^{n-k+1} \tag{5.6}$$

例 5.2　房贷摊销的第一期与最后一期

贷款 $L=100$ 万元，年利率 4.9%（月利率 $i=0.40833\%$），期限 30 年（$n=360$ 期）。由 式 (5.5) 得月供

$$R=\frac{1000000\times 0.0040833}{1-(1.0040833)^{-360}}\approx 5307\ \text{元}.$$

第一期利息 $I_1=1000000\times 0.0040833=4083$ 元，本金仅偿还 $5307-4083=1224$ 元，**利息占月供的 77%**。而最后一期的本金部分为 $P_{360}=R\,v^{1}=5307/1.0040833\approx 5286$ 元，利息仅约 21 元。这种「前期几乎全付利息」的结构是等额本息的核心特征，也是提前还款在第 5–10 年最划算（节省的利息最多）的原因。

5.2 债券数学

5.2.1 全价、净价与收益率

债券价格等于未来现金流的现值：

$$P = \sum_{t=1}^{n} \frac{C}{(1+y)^t} + \frac{F}{(1+y)^n} \tag{5.7}$$

其中 C 为票息、F 为面值、y 为到期收益率（YTM）。在两次付息日之间交易时，需区分：

$$P_{\text{dirty}} = P_{\text{clean}} + \text{AI}, \qquad \text{AI} = C \times \frac{\text{自上次付息日起的天数}}{\text{付息期天数}} \tag{5.8}$$

⚠ 风险警示　YTM 的三个隐含假设

到期收益率是债券市场最常用的报价方式，但它隐含了三个通常不成立的假设：(1) **持有至到期且不发生违约**；(2) **所有票息都能以相同的 y 再投资**；(3) **收益率曲线是水平的**（用同一个 y 贴现所有期限）。因此当曲线陡峭或陡峭反转时，用 YTM 比较不同期限债券会产生误导——正确的做法是使用**即期利率曲线**逐期贴现，或用持有期收益（horizon return）做情景分析。

5.2.2 久期、凸性与 DV01

麦考利久期是现金流到期时间的现值加权平均：

$$D = \frac{\sum_{t=1}^{n} t \cdot PV(CF_t)}{P}, \qquad PV(CF_t) = \frac{CF_t}{(1+y)^t} \tag{5.9}$$

修正久期与美元久期（DV01）分别为

$$D^* = \frac{D}{1 + y/f}, \qquad \text{DV01} = D^* \times P \times 10^{-4} \tag{5.10}$$

其中 f 为每年付息次数。凸性衡量久期随收益率的变化率：

$$C_{\text{conv}} = \frac{1}{P} \sum_{t=1}^{n} \frac{t(t+1)\,CF_t}{(1+y)^{t+2}} \tag{5.11}$$

于是价格对收益率变动 Δy 的二阶近似为

$$\frac{\Delta P}{P} \approx -D^* \,\Delta y + \tfrac{1}{2} C_{\text{conv}} \,(\Delta y)^2 \tag{5.12}$$

例 5.3　久期与凸性的一次完整计算

面值 100、票息 6%、每年付息、剩余 5 年、收益率 5% 的债券：现金流为 $6,6,6,6,106$，现值为 $5.714, 5.442, 5.183, 4.936, 83.054$，合计 $P = 104.330$。按式 (5.9) 计算得 $D = 467.161/104.330 = 4.478$ 年，故 $D^* = 4.478/1.05 = 4.265$，$\mathrm{DV01} = 4.265 \times 104.330 \times 10^{-4} = 0.0445$ 元。按式 (5.11) 计算得 $C_{\text{conv}} \approx 23.44$。当收益率上升 100bp 时，二阶近似给出

$$\frac{\Delta P}{P} \approx -4.265 \times 0.01 + \tfrac{1}{2} \times 23.44 \times 0.0001 = -4.147\%,$$

而真实价格在 6% 收益率下恰好为 100（因为票息等于收益率），即真实跌幅为 $100/104.330 - 1 = -4.150\%$。**近似误差仅 0.003 个百分点**——这就是为什么久期与凸性足以支撑日常的利率风险限额管理。

核心要点 5.1

久期有四种等价解释，理解任何一种都能在实务中正确使用它：(1) 现金流的**现值加权平均到期时间**；(2) 价格对收益率的**弹性**（负号）；(3) 债券实现**免疫（immunization）**所需持有的时间——在这一点上价格风险与再投资风险恰好抵消；(4) **利率风险的敞口规模**，DV01 因此成为交易台的基本限额单位。

5.2.3　收益率曲线的构建与拟合

市场上可观测的只有附息债券的价格，因此必须先把它们「剥离（bootstrap）」成零息利率曲线。递归逻辑是：短端零息利率由短期工具直接给出，长端则用「长债价格 − 已知短端现金流现值」反解。

例 5.4　两步 bootstrap

已知 1 年期零息利率 $z_1 = 4.0\%$；一张 2 年期、票息 4.5%、年付一次、面值 100 的债券价格为 100.5。第一年现金流现值为 $4.5/1.04 = 4.3269$。第二年的现金流现值为 $100.5 - 4.3269 = 96.1731 = 104.5/(1+z_2)^2$，故

$$(1+z_2)^2 = \frac{104.5}{96.1731} = 1.08658 \;\Longrightarrow\; z_2 = 4.239\%.$$

继续用 3 年期债券反解 z_3，即可得到整条零息曲线。**实务中会先用 Nelson–Siegel 之类参数化模型拟合整条曲线，再从中提取零息利率**，以避免逐点 bootstrap 在数据稀疏或报价噪声较大时产生锯齿状的远期利率。

Nelson–Siegel 模型把曲线分解为水平、斜率与曲率三个成分：

$$y(\tau) = \beta_0 + \beta_1 \frac{1 - \mathrm{e}^{-\tau/\lambda}}{\tau/\lambda} + \beta_2 \left(\frac{1 - \mathrm{e}^{-\tau/\lambda}}{\tau/\lambda} - \mathrm{e}^{-\tau/\lambda} \right) \tag{5.13}$$

其中 β_0 为长期水平（水平因子），β_1 控制短端斜率（斜率因子），β_2 控制中段驼峰（曲率因子），λ 控制衰减速度。Svensson 模型再加一个驼峰项：

$$y(\tau) = y_{\mathrm{NS}}(\tau;\beta_0,\beta_1,\beta_2,\lambda_1) + \beta_3\left(\frac{1-\mathrm{e}^{-\tau/\lambda_2}}{\tau/\lambda_2} - \mathrm{e}^{-\tau/\lambda_2}\right) \tag{5.14}$$

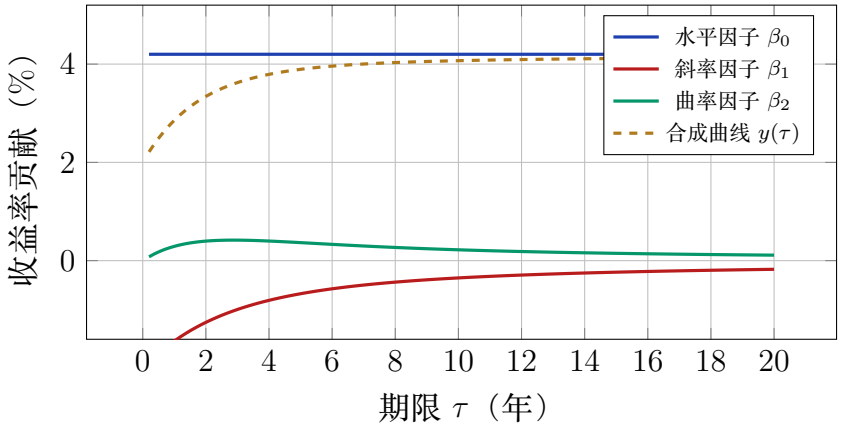


图 5.1　Nelson–Siegel 模型的三个成分与合成收益率曲线

如 图 5.1 所示，水平因子决定长期水平，斜率因子决定曲线的陡峭程度，曲率因子决定中段是否出现驼峰。**三个因子的经济解释分别对应「长期通胀预期」「货币政策周期」与「期限溢价的中期波动」**，这使 Nelson–Siegel 不仅是拟合工具，也是宏观分析的载体。

5.3 期权定价的数学基础

5.3.1　无套利与风险中性定价

在等价鞅测度 $\mathbb{Q}$ 下，任意未定权益的现值为其折现期望收益：

$$V_t = \mathrm{e}^{-r(T-t)}\,\mathbb{E}^{\mathbb{Q}}[H(S_T)\mid \mathcal{F}_t] \tag{5.15}$$

这一结论的严格基础（测度变换与鞅表示）见第 6、10 章。本章关注的是**如何计算这个期望**：解析解（极少数情形）、树方法、有限差分、蒙特卡洛。

5.3.2　Black–Scholes 偏微分方程的推导

设 $V(t,S)$ 为期权价值。构造自融资的对冲组合 $\Pi = V - \Delta S$，则

$$\mathrm{d}\Pi = \mathrm{d}V - \Delta\,\mathrm{d}S = \left(\frac{\partial V}{\partial t} + \tfrac{1}{2}\sigma^2 S^2\frac{\partial^2 V}{\partial S^2}\right)\mathrm{d}t + \left(\frac{\partial V}{\partial S} - \Delta\right)\mathrm{d}S \tag{5.16}$$

选取 $\Delta = \partial V/\partial S$ 消去随机项，组合在 $\mathrm{d}t$ 内无风险，故必须满足 $\mathrm{d}\Pi = r\Pi\,\mathrm{d}t = r(V - \Delta S)\,\mathrm{d}t$。令两式的 $\mathrm{d}t$ 系数相等，整理得 Black–Scholes 方程：

$$\frac{\partial V}{\partial t} + \tfrac{1}{2}\sigma^2 S^2\frac{\partial^2 V}{\partial S^2} + rS\frac{\partial V}{\partial S} - rV = 0 \tag{5.17}$$

补充说明　推导中真正的关键一步

上述推导最容易被忽略的一步是：「组合无风险」意味着它必须赚取无风险利率。这一步之所以成立，前提是存在一个可以自由借贷的无风险资产，且市场无摩擦。如果放宽这两个条件，得到的就不是 BSM 方程，而是带融资价差与交易成本的非线性定价问题——这类问题通常只能用控制论或数值方法处理。

5.3.3　数值方法之一：二叉树模型

Cox–Ross–Rubinstein（CRR）树把连续时间离散化为「每步上涨 u 或下跌 d」，参数选取使离散过程的波动率与连续过程匹配：

$$u = \mathrm{e}^{\sigma\sqrt{\Delta t}}, \qquad d = \mathrm{e}^{-\sigma\sqrt{\Delta t}} = \frac{1}{u}, \qquad p = \frac{\mathrm{e}^{r\Delta t} - d}{u - d} \tag{5.18}$$

其中风险中性概率 p 不是主观概率，而是使**标的的期望收益率等于无风险利率**的概率：$\mathbb{E}^{\mathbb{Q}}[S_{t+\Delta t}] = pSu + (1-p)Sd = S\mathrm{e}^{r\Delta t}$。

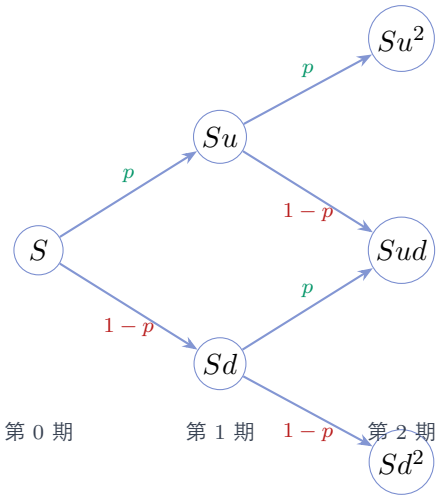


图 5.2　两步 CRR 二叉树：风险中性概率 p 使标的期望收益等于无风险利率

定价采用**向后递推**：在到期日取收益函数，然后逐层回溯 $V = \mathrm{e}^{-r\Delta t}\,[pV_u + (1-p)V_d]$。对于**美式期权**，每一步还要比较「继续持有价值」与「立即行权价值」，取较大者：

$$V_{\text{American}} = \max\left\{H(S),\ \mathrm{e}^{-r\Delta t}\,[pV_u + (1-p)V_d]\right\} \tag{5.19}$$

CRR 树的收敛阶为 $O(1/M)$（M 为步数），但用于障碍期权等不连续收益产品时会出现**锯齿状振荡**，需要用「平滑化」或有限差分方法处理。

5.3.4　数值方法之二：有限差分法

把 BSM 方程 式 (5.17) 中的时间与价格导数用差分近似，得到 θ 格式（$\theta = 0$ 显式、$\theta = 1$ 隐式、$\theta = \tfrac{1}{2}$ Crank–Nicolson）：

$$\frac{V_j^{n+1}-V_j^n}{\Delta t}+\theta\,\mathcal{L}V_j^{n+1}+(1-\theta)\,\mathcal{L}V_j^n=0 \tag{5.20}$$

其中 $\mathcal{L}$ 为空间差分算子（含一阶与二阶中心差分）。三种格式的性质差异显著：

表 5.2　有限差分格式的对比

格式	时间精度	稳定性	实务要点
显式 ($\theta=0$)	$O(\Delta t)$	条件稳定 $\Delta t \le \frac{1}{2}\Delta x^2/\sigma^2 S_{\max}^2$	实现最简单，但时间步长受严格限制
隐式 ($\theta=1$)	$O(\Delta t)$	无条件稳定	需要解三对角方程组（Thomas 算法）
Crank–Nicolson ($\theta=\frac{1}{2}$)	$O(\Delta t^2)$	无条件稳定	精度最高，但对非光滑初值会产生振荡，需前几步用隐式启动（Rannacher）

直觉理解　稳定性条件的来源

显式格式每算一步，信息只能传播到相邻的一个网格点，因此时间步长必须足够小，使「网格传播速度」不低于「价格扩散速度」。当 Δt 过大时，数值解会出现正负交替的振荡——这不是精度问题，而是**数值格式本身不稳定**，无论把网格加密到什么程度都无法消除。这也是为什么实盘系统更偏好隐式或 Crank–Nicolson 格式。

5.4 蒙特卡洛方法

5.4.1　基本原理与误差

欧式期权的蒙特卡洛估计为

$$\hat{V}=\mathrm{e}^{-rT}\frac{1}{N}\sum_{i=1}^{N}H\left(S_T^{(i)}\right),\qquad S_T^{(i)}=S_0\exp\left(\left(r-\tfrac{\sigma^2}{2}\right)T+\sigma\sqrt{T}Z_i\right) \tag{5.21}$$

其标准误为 $\mathrm{SE}=\hat{\sigma}_V/\sqrt{N}$，因此收敛速度为 $O(N^{-1/2})$——**每提高一位精度需要 100 倍的样本量**。这正是方差缩减技术至关重要的原因。

5.4.2　方差缩减与拟蒙特卡洛

图 5.3 说明：在双对数坐标下，$O(N^{-1/2})$ 是一条斜率 $-1/2$ 的直线，而拟蒙特卡洛的斜率接近 -1。**但在高维问题（如 100 个标的的篮子期权）中，拟蒙特卡洛的优势会显著衰减**，这是低差异序列的有效维数限制所致。

5.4.3　用蒙特卡洛计算希腊字母

直接用差分法（重新模拟一次）计算 Greeks 会引入偏差且成本高昂。两种正统方法是：

表 5.3　蒙特卡洛方差缩减技术

技术	原理	典型收益
对偶变量	用 $(Z, -Z)$ 成对模拟，利用收益函数的单调性使误差反相关	方差降低 50%–90%
控制变量	$\hat{V}_{\text{cv}} = \hat{V} - \beta(\hat{C} - \mathbb{E}[C])$，用已知期望的相关量修正	取决于相关性，可降低一个数量级
重要性抽样	改变抽样分布使「重要区域」样本更密，再按似然比加权	深度虚值期权极有效
分层抽样	把样本空间分层，每层分配固定样本量	低维问题效果显著
拟蒙特卡洛	用 Sobol/Halton 低差异序列替代伪随机数	收敛近 $O(N^{-1})$
多级蒙特卡洛	用不同步长的路径组合，把计算量集中在粗粒度上	路径依赖产品可降一至两个数量级

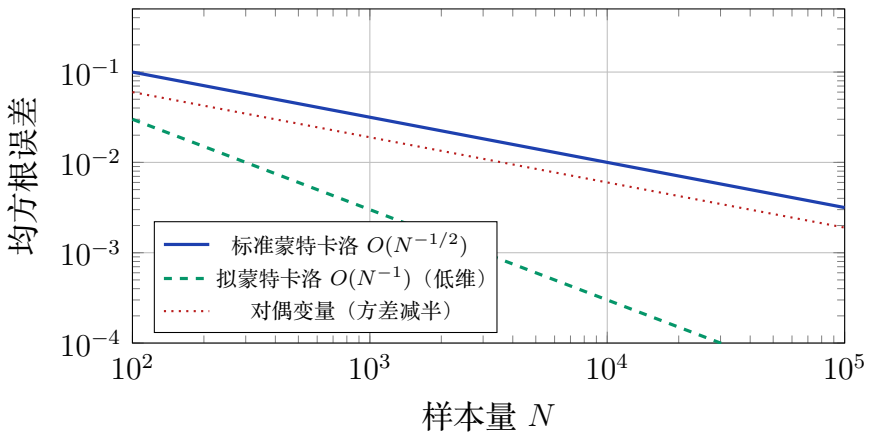


图 5.3　蒙特卡洛与拟蒙特卡洛的收敛速度对比（双对数坐标）

$$\text{路径导数法（pathwise）：}\quad \Delta = \mathbb{E}^{\mathbb{Q}}\left[\mathrm{e}^{-rT} H'(S_T)\frac{S_T}{S_0}\right] \tag{5.22}$$

$$\text{似然比法（likelihood ratio）：}\quad \Delta = \mathbb{E}^{\mathbb{Q}}\left[\mathrm{e}^{-rT} H(S_T)\frac{Z}{S_0\sigma\sqrt{T}}\right] \tag{5.23}$$

路径导数法方差更小，但要求收益函数几乎处处可微（数字期权等不连续收益会失效）；似然比法对收益函数没有光滑性要求，但方差更大。**这一权衡是实务中 Greeks 计算的核心工程问题。**

Listing 5.1　蒙特卡洛定价与对偶变量的方差缩减验证

```python
import numpy as np
from scipy.stats import norm

def bsm_call(S, K, r, sigma, T):
    d1 = (np.log(S / K) + (r + 0.5 * sigma ** 2) * T) / (sigma * np.sqrt(T))
    d2 = d1 - sigma * np.sqrt(T)
    return S * norm.cdf(d1) - K * np.exp(-r * T) * norm.cdf(d2)

def mc_call(S, K, r, sigma, T, n, antithetic=True, seed=0):
    """Return (price, standard error) of a European call by Monte Carlo."""
    rng = np.random.default_rng(seed)
    if antithetic:
        z = rng.standard_normal(n // 2)
        z = np.concatenate([z, -z])
    else:
        z = rng.standard_normal(n)
    ST = S * np.exp((r - 0.5 * sigma ** 2) * T + sigma * np.sqrt(T) * z)
    payoff = np.exp(-r * T) * np.maximum(ST - K, 0.0)
    return payoff.mean(), payoff.std(ddof=1) / np.sqrt(payoff.size)

S, K, r, sigma, T = 100.0, 100.0, 0.05, 0.20, 1.0
print("analytic :", round(bsm_call(S, K, r, sigma, T), 4))
for n in (10_000, 100_000):
    plain = mc_call(S, K, r, sigma, T, n, antithetic=False)
    anti = mc_call(S, K, r, sigma, T, n, antithetic=True)
    print(f"n={n:>7d}  plain={plain[0]:.4f} (se {plain[1]:.4f})"
          f"  antithetic={anti[0]:.4f} (se {anti[1]:.4f})")
```

5.5 数值优化基础

5.5.1 无约束优化

$$\text{梯度下降：}\quad x_{k+1} = x_k - \alpha_k \nabla f(x_k) \tag{5.24}$$

$$\text{牛顿法：}\quad x_{k+1} = x_k - \left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k) \tag{5.25}$$

梯度下降每步只利用一阶信息，收敛线性；牛顿法利用二阶信息，在最优解附近二次收敛，但需要计算并求逆 Hessian 矩阵（$O(n^3)$ 且可能非正定）。拟牛顿法（BFGS）通过迭代更新 Hessian 的近似，在两者之间取得平衡，是实务中的默认选择。

5.5.2 约束优化与 KKT 条件

一般约束优化问题为

$$\min_{x} \; f(x) \quad \text{s.t.} \quad g_i(x) \le 0,\; h_j(x) = 0 \tag{5.26}$$

其拉格朗日函数与 KKT 条件为

$$\mathcal{L}(x, \lambda, \mu) = f(x) + \sum_i \lambda_i g_i(x) + \sum_j \mu_j h_j(x) \tag{5.27}$$

$$\text{平稳性：}\quad \nabla_x \mathcal{L} = 0 \tag{5.28}$$

$$\text{原始可行性：}\quad g_i(x) \le 0,\; h_j(x) = 0 \tag{5.29}$$

$$\text{对偶可行性：}\quad \lambda_i \ge 0 \tag{5.30}$$

$$\text{互补松弛：}\quad \lambda_i g_i(x) = 0 \tag{5.31}$$

核心要点 5.2

互补松弛条件 $\lambda_i g_i(x) = 0$ 是约束优化的核心：**要么约束不起作用（$g_i < 0$，$\lambda_i = 0$），要么约束恰好取等号且对应一个正的影子价格（$g_i = 0$，$\lambda_i > 0$）**。在组合优化中，λ_i 就是「放松该约束一单位能带来多少目标函数改善」，因此它直接对应着**约束的机会成本**——例如「单票权重上限收紧 1% 会损失多少预期收益」。当约束是凸集时，KKT 条件也是充分条件。

Listing 5.2 用牛顿法反解零息利率曲线（bootstrap 的数值版本）

```python
import numpy as np
from scipy.optimize import brentq

def bootstrap_zero(prices, coupons, maturities):
```

```
    """Recover zero rates from coupon bond prices, shortest maturity
       first."""
    zeros, dfs = [], []
    for price, cpn, T in sorted(zip(prices, coupons, maturities),
                                key=lambda x: x[2]):
        # known cash flows from already-bootstrapped short maturities
        pv_known = sum(cpn * df for df in dfs)
        # remaining cash flow at maturity: cpn + 100 (notional)
        target_df = (price - pv_known) / (cpn + 100.0)

        def obj(z):
            return np.exp(-z * T) - target_df

        z = brentq(obj, -0.5, 1.5, xtol=1e-12)
        zeros.append(z)
        dfs.append(np.exp(-z * T))
    return np.array(zeros), np.array(dfs)

prices = [100.5, 99.2, 101.3]
coupons = [4.5, 4.0, 5.0]
maturities = [2.0, 3.0, 4.0]
z, df = bootstrap_zero(prices, coupons, maturities)
for T, rate, d in zip(maturities, z, df):
    print(f"T={T:.1f}y  zero={rate:.4%}  discount={d:.6f}")
```

⚠ 风险警示　数值方法选择的三条经验

1. **维数低、需要提前行权**：用树或有限差分。树方法实现简单且能自然处理美式期权；有限差分更适合障碍、回望等边界条件复杂的合约。
2. **维数高、路径依赖**：用蒙特卡洛。多标的、多观察日的产品几乎只能靠模拟，但要注意美式期权需要用 LSM 之类的回归方法近似最优停时。
3. **需要快速重复定价（如日内风控）**：用傅里叶方法或参数化近似（SABR 公式），它们能在毫秒级给出整条价格曲线。

反过来，最常见的错误是「用最熟悉的方法而不是最合适的方法」——例如用蒙特卡洛给一个只需有限差分的单标的障碍期权定价，代价是数十倍的计算时间与更大的误差。

本章小结

- 利息理论的核心是等价换算：$\mathrm{e}^{\delta}=1+i=\left(1+i^{(m)}/m\right)^{m}$；年金现值公式 $a_{\overline{n}|}=(1-v^{n})/i$ 是全部估值倍数的基础。
- 债券价格对收益率的二阶近似为 $\Delta P/P\approx -D^{*}\Delta y+\tfrac{1}{2}C_{\text{conv}}(\Delta y)^{2}$；久期的四种解释（加权时间、价格弹性、免疫期限、风险敞口）在实务中各有用途。

- 收益率曲线必须先 bootstrap 成零息曲线；Nelson–Siegel 把曲线分解为水平、斜率、曲率三个因子，兼具拟合与宏观解释功能。
- BSM 方程来自「Delta 对冲消除随机项 + 无风险组合必须赚取无风险利率」这两步。
- 树方法适合提前行权与低维问题（收敛 $O(1/M)$）；有限差分适合复杂边界条件（Crank–Nicolson 二阶精度且无条件稳定）；蒙特卡洛适合高维与路径依赖（收敛 $O(N^{-1/2})$）。
- 方差缩减（对偶变量、控制变量、重要性抽样、QMC、MLMC）是让蒙特卡洛可用起来的关键；Greeks 的计算必须在路径导数法（低方差、需光滑）与似然比法（通用、高方差）之间权衡。
- 约束优化的 KKT 条件给出了「约束的影子价格」，是组合优化中理解权重上限、换手约束等限制成本的语言。

练习与思考

1. 证明 $\delta = \ln(1+i)$，并计算名义年利率 8%、按季度计息时的利息力 δ 与实际年利率。
2. 某人 30 岁开始每年年末存入 2 万元，年化收益 5%，60 岁停止存入并立即开始每年年末取出固定金额，期望领到 85 岁。请计算每年可领取的金额（保留两位小数）。
3. 某债券面值 100、票息 5%、年付一次、剩余 4 年、收益率 6%。请计算其价格、麦考利久期、修正久期、DV01 与凸性，并用二阶近似估计收益率上升 200bp 后的价格变化。
4. 用 CRR 参数 $u = \mathrm{e}^{\sigma\sqrt{\Delta t}}$、$d = 1/u$ 证明风险中性概率 $p = (\mathrm{e}^{r\Delta t} - d)/(u - d)$，并说明当 r、σ 与 Δt 取何值时 p 会落在 $[0,1]$ 之外（这在实践中会发生吗?）。
5. 设某期权收益函数的路径导数估计方差为 σ_1^2，似然比估计方差为 σ_2^2 且 $\sigma_2^2 = 4\sigma_1^2$。若模拟成本相同，两种方法各需要多少样本量才能达到相同的标准误？在什么情形下应该选择似然比法?
6. 写出带权重上限约束 $0 \le w_i \le u_i$ 的最小方差组合问题的 KKT 条件，并解释当某个 u_i 起作用时，对应的拉格朗日乘子的经济含义。

延伸阅读

- Hull, J. C., *Options, Futures, and Other Derivatives*, 10th ed., Pearson, 2018.（第 4–6 章讲清久期、凸性与利率风险，附录给出树方法与有限差分的实现细节）
- Glasserman, P., *Monte Carlo Methods in Financial Engineering*, Springer, 2003.（蒙特卡洛与方差缩减的权威参考，含 Greeks 计算的系统论述）
- Kloeden, P. E., and Platen, E., *Numerical Solution of Stochastic Differential Equations*, Springer, 1992.（随机微分方程数值解的标准参考）

- Filipović, D., *Term-Structure Models: A Graduate Course*, Springer, 2009.（收益率曲线建模与拟合的系统教材）
- Nelson, C. R., and Siegel, A. F., "Parsimonious Modeling of Yield Curves", *Journal of Business*, 1987, 60(4): 473–489.（Nelson–Siegel 模型的原始文献）
- Cox, J. C., Ross, S. A., and Rubinstein, M., "Option Pricing: A Simplified Approach", *Journal of Financial Economics*, 1979, 7(3): 229–263.（二叉树定价的原始文献，推导极为清晰）
- Rockafellar, R. T., and Uryasev, S., "Optimization of Conditional Value-at-Risk", *Journal of Risk*, 2000, 2(3): 21–41.（凸优化在风险度量中的经典应用，第 11 章会用到）

第六章 Q Quant：风险中性定价与衍生品

6.1 Q Quant 的哲学

Q Quant 得名于风险中性测度 $\mathbb{Q}$。其核心理念是：在无套利假设下，存在一个与真实测度 $\mathbb{P}$ 等价的测度 $\mathbb{Q}$，使得所有资产的**折现价格过程都是鞅**。一旦完成测度变换，衍生品定价就退化为一个纯粹的积分问题。

核心要点 6.1

Q Quant 关心的是**相对定价**：给定市场上已有产品的价格，如何**一致地**（无套利地）为其他衍生品定价。因此 Q Quant 的答案不依赖任何对未来收益的主观预测，只依赖「市场已经给出的价格」与「复制关系的数学结构」。核心工具是鞅论、测度变换与随机分析。

直觉理解　Q Quant 与 P Quant 的分工

同一个资产，在 $\mathbb{Q}$ 下的期望收益率恒等于**无风险利率** r，因此 $\mathbb{Q}$ 下的时间序列不含任何 **Alpha 信息**——这正是「用 $\mathbb{Q}$ 测度回测策略」毫无意义的原因。反过来，$\mathbb{P}$ 下的期望收益率包含风险溢价，用它给奇异期权报价则会产生可以被无风险套利的错误价格。**测度不是「哪个更真实」的问题，而是「要回答什么问题」的问题。**

6.2 测度论要点

6.2.1　概率空间、信息流与可测性

概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 由样本空间、事件集合（σ-代数）与概率测度构成。**信息流（filtration）** $\{\mathcal{F}_t\}_{t\geq 0}$ 是一族递增的 σ-代数，$\mathcal{F}_t$ 表示 t 时刻可得的全部信息。

两个技术概念在定价中反复出现：

- **适应（adapted）**：X_t 是 $\mathcal{F}_t$-可测的，即 t 时刻的值不依赖未来信息；
- **可料（predictable）**：X_t 由 t^- 时刻的信息决定。**交易策略必须是可料的**——否则就等价于允许利用未来信息套利。

定义 6.1　条件期望的关键性质

设 $\mathcal{F}\subseteq\mathcal{G}\subseteq\mathcal{H}$ 为 σ-代数，X 可积，则

$$\mathbb{E}\left[\mathbb{E}[X\mid\mathcal{G}]\mid\mathcal{F}\right]=\mathbb{E}\left[X\mid\mathcal{F}\right]\qquad\text{（塔性质）}\tag{6.1}$$

$$\mathbb{E}\left[Y\mathbb{E}[X\mid\mathcal{G}]\mid\mathcal{F}\right]=Y\,\mathbb{E}\left[X\mid\mathcal{F}\right]\qquad(Y\text{ 为}\mathcal{F}\text{-可测})\tag{6.2}$$

$$\mathbb{E}\left[\mathbb{E}[X\mid\mathcal{F}]\right]=\mathbb{E}[X]\qquad\text{（全期望公式）}\tag{6.3}$$

塔性质是鞅论一切结论的起点：它说明用更少的信息做预测，等于先用更多信息预测再取平均。

6.2.2　鞅、局部鞅与平方可积鞅

称适应过程 M_t **为鞅**，若 $\mathbb{E}|M_t|<\infty$ 且

$$\mathbb{E}\left[M_t\mid\mathcal{F}_s\right]=M_s,\qquad\forall\,s\le t\tag{6.4}$$

三个层次的鞅概念在技术上是必要的：

表 6.1　鞅的三个层次与用途

概念	定义要点	为什么需要
鞅	$\mathbb{E}[M_t\mid\mathcal{F}_s]=M_s$ 且 $\mathbb{E}\lvert M_t\rvert<\infty$	公平博弈；折现价格过程的原型
局部鞅	存在停时序列 $\tau_n\uparrow\infty$ 使 M^{τ_n} 为鞅	伊藤积分 $\int H\,\mathrm{d}W$ 一般只是局部鞅
平方可积鞅	$\sup_t\mathbb{E}[M_t^2]<\infty$	保证伊藤等距与鞅表示定理可用

⚠ 风险警示　局部鞅不是鞅：这不是技术细节

一个经典的例子是「双倍下注」策略：它看起来能保证盈利，但所需资金无上限，其财富过程是局部鞅而非鞅，因此**不能对之使用可选停止定理**。在定价中，这对应着「策略看起来无风险套利，实际需要无限融资或无限次交易」的情形。**实务含义是：任何依赖「无限制加仓」或「无限次调仓」的策略，在真实市场中都可能因为资金或流动性约束而失败**——LTCM 与若干期权卖方爆仓案例的本质都在这里。

6.2.3　Radon–Nikodym 导数

若测度 $\mathbb{Q}$ 关于 $\mathbb{P}$ 绝对连续（$\mathbb{Q}\ll\mathbb{P}$），则存在密度 $\mathrm{d}\mathbb{Q}/\mathrm{d}\mathbb{P}$ 使得

$$\mathbb{E}^{\mathbb{Q}}[X]=\mathbb{E}^{\mathbb{P}}\left[\frac{\mathrm{d}\mathbb{Q}}{\mathrm{d}\mathbb{P}}X\right]\tag{6.5}$$

在连续时间中，该密度通常写成指数鞅（随机指数）形式：

$$\left.\frac{\mathrm{d}\mathbb{Q}}{\mathrm{d}\mathbb{P}}\right|_{\mathcal{F}_t} = \mathcal{E}\left(-\int_0^{\cdot} \lambda_s \,\mathrm{d}W_s^{\mathbb{P}}\right)_t = \exp\left(-\int_0^t \lambda_s \,\mathrm{d}W_s^{\mathbb{P}} - \frac{1}{2}\int_0^t \lambda_s^2 \,\mathrm{d}s\right) \tag{6.6}$$

其中 λ_t 为**风险的市场价格（market price of risk）**。本书统一采用 式 (6.6) 的符号约定（第 10 章使用同一约定）。

6.3 Girsanov 定理与测度变换

定理 6.1 (Girsanov) 设 λ_t 满足 Novikov 条件 $\mathbb{E}^{\mathbb{P}}\left[\exp\left(\frac{1}{2}\int_0^T \lambda_s^2 \,\mathrm{d}s\right)\right] < \infty$，并令 $\mathrm{d}\mathbb{Q}/\mathrm{d}\mathbb{P}$ 如 式 (6.6) 所定义。则

$$W_t^{\mathbb{Q}} = W_t^{\mathbb{P}} + \int_0^t \lambda_s \,\mathrm{d}s \tag{6.7}$$

是 $\mathbb{Q}$ 下的标准布朗运动。

证明思路. 对 $W_t^{\mathbb{Q}}$ 应用伊藤引理可以验证 $Z_t = \exp\left(\mathrm{i}uW_t^{\mathbb{Q}} + \frac{1}{2}u^2 t\right)$ 在 $\mathbb{Q}$ 下是鞅（即 $\mathbb{E}^{\mathbb{Q}}[Z_t \mid \mathcal{F}_s] = Z_s$），从而 $W_t^{\mathbb{Q}}$ 在 $\mathbb{Q}$ 下的特征函数为 $\mathrm{e}^{-u^2 t/2}$，这正是标准正态的特征函数。由 Lévy 刻画定理即得结论。 ■

6.3.1 从真实测度到风险中性测度

设标的在 $\mathbb{P}$ 下服从几何布朗运动 $\mathrm{d}S_t = \mu S_t \mathrm{d}t + \sigma S_t \mathrm{d}W_t^{\mathbb{P}}$。取 $\lambda = (\mu - r)/\sigma$（即夏普比率），由 式 (6.7) 有 $\mathrm{d}W_t^{\mathbb{P}} = \mathrm{d}W_t^{\mathbb{Q}} - \lambda \,\mathrm{d}t$，代入得

$$\mathrm{d}S_t = (\mu - \sigma\lambda)\, S_t \,\mathrm{d}t + \sigma S_t \,\mathrm{d}W_t^{\mathbb{Q}} = r S_t \,\mathrm{d}t + \sigma S_t \,\mathrm{d}W_t^{\mathbb{Q}} \tag{6.8}$$

核心要点 6.2

Girsanov 定理的金融含义可以概括为一句话：**测度变换只改变漂移率，不改变波动率。**因此从 $\mathbb{P}$ 换到 $\mathbb{Q}$ 时，我们不需要知道 μ（它是不可靠的、依赖主观预期的），只需要知道 r（市场可观测量）与 σ（可从期权价格反解）。这是 BSM 公式能被广泛使用的根本原因，也是它被称为「偏好无关」定价的原因。

例 6.1 测度变换下的漂移修正

设 $\mu = 10\%$、$r = 3\%$、$\sigma = 20\%$，则 $\lambda = (0.10 - 0.03)/0.20 = 0.35$。在 $\mathbb{P}$ 下，一年后 $\ln S_T$ 的期望为 $\ln S_0 + (\mu - \frac{1}{2}\sigma^2) = \ln S_0 + 0.08$；在 $\mathbb{Q}$ 下为 $\ln S_0 + (r - \frac{1}{2}\sigma^2) = \ln S_0 + 0.01$。**两者的差异 0.07 完全来自漂移项的替换，波动率项的 0.20 完全不变。**这也解释了为什么期货价格（在 $\mathbb{Q}$ 下无漂移）不能用来估计真实预期收益率。

6.4 鞅定价方法与基本定理

6.4.1 两个基本定理

定理 6.2 (第一基本资产定价定理) 市场无套利机会 $\iff$ 存在与 $\mathbb{P}$ 等价的鞅测度 $\mathbb{Q}$（使得所有折现资产价格为 $\mathbb{Q}$-鞅）。

定理 6.3 (第二基本资产定价定理) 市场完备（所有未定权益都可复制）$\iff$ 等价鞅测度唯一。

补充说明　不完备市场意味着什么

当市场不完备时（例如随机波动率模型中有两个风险源但只有一个可交易的风险资产），等价鞅测度有无穷多个，对应无穷多个「无套利」价格区间。此时定价需要额外准则：校准到市场波动率曲面（第 4 章的 Heston、SABR 做法）、效用无差异定价、或最小方差对冲。**「理论上无唯一价格」正是不完备市场模型必须校准的原因。**

6.4.2 风险中性定价公式

以货币市场账户 $B_t = \mathrm{e}^{rt}$ 为计价单位，任意未定权益 H_T 的价格为

$$V_t = B_t \, \mathbb{E}^{\mathbb{Q}}\left[\frac{H_T}{B_T} \middle| \mathcal{F}_t \right] = \mathrm{e}^{-r(T-t)} \, \mathbb{E}^{\mathbb{Q}}[H_T \mid \mathcal{F}_t] \tag{6.9}$$

6.4.3 计价单位变换与远期测度

任意正的可交易资产 N_t 都可以作为计价单位。在对应的测度 $\mathbb{Q}^N$ 下，以 N 计价的相对价格过程是鞅：

$$\frac{V_t}{N_t} = \mathbb{E}^{\mathbb{Q}^N}\left[\frac{H_T}{N_T} \middle| \mathcal{F}_t \right] \tag{6.10}$$

例 6.2　T-远期测度：为什么远期利率是鞅

取零息债券为计价单位 $N_t = P(t,T)$，得到 T-远期测度 $\mathbb{Q}^T$。**此时任何在 T 时刻支付 1 元的资产的远期价格在 $\mathbb{Q}^T$ 下都是鞅。**具体地，远期利率与远期 LIBOR 在对应测度下是鞅：

$$L(t;T_i,T_{i+1}) = \mathbb{E}^{\mathbb{Q}^{T_{i+1}}}[L(T_i;T_i,T_{i+1}) \mid \mathcal{F}_t] \, .$$

这一结论的实际威力在于：它让利率衍生品的定价不再需要模拟贴现因子的联合分布，而只需处理一个鞅——这是 LIBOR 市场模型（小节 6.5.3）能够落地的理论基础。

表 6.2　三个主要短期利率模型的对比

模型	动态	优点与局限	曲线拟合
Vasicek	$\mathrm{d}r_t = \kappa(\theta - r_t)\mathrm{d}t + \sigma \mathrm{d}W_t$	有解析解、仿射结构；**利率可能为负**	只能拟合部分曲线
CIR	$\mathrm{d}r_t = \kappa(\theta - r_t)\mathrm{d}t + \sigma\sqrt{r_t}\mathrm{d}W_t$	保证非负（Feller 条件 $2\kappa\theta \geq \sigma^2$）；无解析债券期权解	只能拟合部分曲线
Hull–White	$\mathrm{d}r_t = (\theta(t) - a r_t)\,\mathrm{d}t + \sigma \mathrm{d}W_t$	**精确拟合初始曲线**；有解析解，实务主流	完全拟合

6.5 利率模型

6.5.1　短期利率模型

Vasicek 模型的解与分布为

$$r_t = \theta + (r_0 - \theta)\mathrm{e}^{-\kappa t} + \sigma \int_0^t \mathrm{e}^{-\kappa(t-s)}\,\mathrm{d}W_s, \qquad r_t \sim \mathcal{N}\left(\theta + (r_0 - \theta)\mathrm{e}^{-\kappa t},\ \frac{\sigma^2}{2\kappa}\left(1 - \mathrm{e}^{-2\kappa t}\right)\right) \tag{6.11}$$

其中均值回复的半衰期为 $\ln 2/\kappa$。零息债券价格具有**仿射形式**：

$$P(t,T) = A(t,T)\,\mathrm{e}^{-B(t,T)r_t}, \qquad B(t,T) = \frac{1 - \mathrm{e}^{-\kappa(T-t)}}{\kappa} \tag{6.12}$$

$A(t,T)$ 的具体表达式可由求解 PDE 得到。仿射结构意味着**债券价格的对数是状态变量的线性函数**，因此校准与定价可以化为线性代数问题，这是短率模型在实务中高效的原因。

例 6.3　均值回复速度的直观含义

设 $\kappa = 0.5$、$\theta = 5\%$、$r_0 = 2\%$、$\sigma = 1.5\%$。半衰期为 $\ln 2/0.5 = 1.39$ 年，即偏离长期均值的一半会在约 1.4 年内被消除。10 年后 r 的期望为 $0.05 + (0.02 - 0.05)\mathrm{e}^{-5} = 4.98\%$，几乎完全回到长期均值。参数 κ **直接决定了「利率冲击的记忆长度」**：κ 越大，曲线短端对冲击越不敏感（因为很快回归），这也是为什么 κ 的估计值会显著影响利率衍生品的对冲比率。

6.5.2　Heath–Jarrow–Morton 框架

HJM 直接对整条远期利率曲线建模：

$$\mathrm{d}f(t,T) = \alpha(t,T)\,\mathrm{d}t + \sigma(t,T)\,\mathrm{d}W_t \tag{6.13}$$

定理 6.4 (HJM 无套利漂移条件) 在风险中性测度 $\mathbb{Q}$ 下，为使债券价格无套利，漂移项**完全由波动率结构决定**：

$$\alpha(t,T) = \sigma(t,T)\int_t^T \sigma(t,s)\,\mathrm{d}s \tag{6.14}$$

证明思路. 从债券价格与远期利率的关系 $P(t,T)=\exp\left(-\int_t^T f(t,s)\mathrm{d}s\right)$ 出发，对 t 求导并应用伊藤引理，得到 $\mathrm{d}P/P$ 的漂移与波动率表达式。再要求 $\mathrm{d}P/P = r_t\mathrm{d}t +$ 鞅项（即在 $\mathbb{Q}$ 下折现债券价格为鞅），对比漂移项即可解出 式 (6.14)。 ■

⚠ 风险警示　HJM 的两个实务陷阱

1. **漂移条件是非线性约束**：$\alpha = \sigma\int\sigma$ 意味着不能独立地指定漂移与波动率。一旦波动率结构被设定，漂移就被锁死；若校准后的波动率结构不与市场一致，模型会产生「不可能」的远期曲线动态（例如所有远期利率同时向同一方向漂移而无套利机会）。
2. **维度爆炸**：HJM 对连续统的远期利率建模，直接用蒙特卡洛模拟整条曲线在计算上不可行。实务中必须通过主成分分析（PCA）降到 2–3 个因子。**这是 HJM 从理论走向实践的必经一步。**

6.5.3　LIBOR 市场模型

LMM（又称 BGM）对离散的远期 LIBOR/SOFR 利率直接建模：

$$\frac{\mathrm{d}L_k(t)}{L_k(t)} = \mu_k(t)\,\mathrm{d}t + \sigma_k(t)\,\mathrm{d}W_t^k \tag{6.15}$$

其关键优势在于**每个 L_k 在对应的远期测度 $\mathbb{Q}^{T_{k+1}}$ 下是鞅**（漂移为零），因此可以直接用 Black 公式给 Caplet 定价，市场报价的波动率可以直接作为模型输入：

$$\mathrm{Caplet}_k = \tau_k\,P(0,T_{k+1})\Big[L_k(0)N(d_1) - KN(d_2)\Big] \tag{6.16}$$

📈 实务应用　市场模型为什么赢了

LMM 的成功不是数学上更优美，而是**工程上可校准**：它把模型参数直接对应到市场可交易的 Cap/Floor 报价，校准结果可以被交易台直接检验，定价结果与市场报价的差异可以归因到具体合约。**在金融工程中，「能被市场数据检验」往往比「理论上更一般」更有价值。**LIBOR 退出历史舞台后，同一套方法论被移植到 SOFR 期限利率与 OIS 曲线上。

6.6 信用衍生品定价

6.6.1　强度模型与生存概率

在约化形式模型中，违约时间 τ 是强度为 λ_t 的**首跳时间**（Cox 过程），生存概率为

$$\mathbb{Q}(\tau > T \mid \mathcal{F}_t) = \mathbb{E}^{\mathbb{Q}}\left[\exp\left(-\int_t^T \lambda_s \, \mathrm{d}s\right) \middle| \mathcal{F}_t\right] \tag{6.17}$$

在常数强度下简化为 $Q(T) = \mathrm{e}^{-\lambda T}$，**即违约强度就是风险率（hazard rate）**。

6.6.2 CDS 定价

CDS 的保本价差由「保护现值 = 保费现值」给出：

$$s = \frac{(1-R)\sum_i B(0,t_i)\,[Q(t_{i-1}) - Q(t_i)]}{\sum_i \tau_i B(0,t_i) Q(t_i)} \tag{6.18}$$

例 6.4　从违约强度到 CDS 价差

设违约强度 $\lambda = 2\%$、回收率 $R = 40\%$、平坦贴现率 5%、5 年期年付一次。生存概率 $Q(t) = \mathrm{e}^{-0.02t}$ 给出 $Q(1) = 0.9802, \ldots, Q(5) = 0.9048$；保护现值 $= 0.6\sum \mathrm{e}^{-0.05t_i}\,[Q(t_{i-1}) - Q(t_i)] = 0.6 \times 0.08227 = 0.04936$；保费年金 $= \sum \mathrm{e}^{-0.05t_i} Q(t_i) = 4.0729$。于是

$$s = \frac{0.04936}{4.0729} = 1.212\% \approx 121 \text{ bp},$$

与近似式 $s \approx (1-R)\lambda = 0.6 \times 2\% = 120$ bp 非常接近。**这个近似式的实用价值在于：它允许交易员在脑中把 CDS 价差直接翻译成违约强度**，例如「5 年期 CDS 报价 300bp、回收率 40%」意味着市场隐含的年度违约概率约 5%。

6.6.3 相关违约与 Copula

分层产品（CDO、篮子）的定价核心是违约相关性。高斯因子 Copula 模型假设

$$X_i = \sqrt{\rho}\, Z + \sqrt{1-\rho}\, \varepsilon_i, \qquad Z, \varepsilon_i \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,1) \tag{6.19}$$

违约发生在 X_i 低于阈值 $c_i = \Phi^{-1}(p_i)$ 时，其中 p_i 为个体违约概率。

⚠ 风险警示　Gaussian Copula 的失败：不是数学错，而是模型错

高斯 Copula 有两个致命缺陷：(1) **尾部独立**——高斯分布的相关结构在极端分位数上趋于独立，因此 **它系统性地低估了「同时违约」的概率**，而这正是分层产品最关心的风险；(2) **相关性被当作常数**——现实中违约相关性在压力期急剧上升，且回收率会同时下降（与违约率负相关），模型无法捕捉这种联动。现代实践使用 t-Copula（更厚的联合尾部）或双因子/多因子结构，并对相关性做敏感性区间分析，而不是给出一个点估计。**2008 年的教训可以表述为：当模型的唯一关键参数无法可靠估计时，评级结果就是脆弱的。**

6.7 波动率衍生品

6.7.1 方差互换

方差互换的收益取决于实现方差与执行方差的差额：

$$\text{Payoff} = N \times \left(\sigma^2_{\text{realized}} - K_{\text{var}}\right) \tag{6.20}$$

其核心结果是**方差可以用一整条期权价格曲线静态复制**：

$$\mathbb{E}^{\mathbb{Q}}\left[\sigma^2_{\text{realized}}\right] = \frac{2\mathrm{e}^{rT}}{T}\left[\int_0^{F_0} \frac{P(K)}{K^2}\,\mathrm{d}K + \int_{F_0}^{\infty} \frac{C(K)}{K^2}\,\mathrm{d}K\right] \tag{6.21}$$

直觉理解　为什么方差可以被静态复制

关键在于**对数合约**：由伊藤引理，$\mathrm{d}\ln S_t = \frac{\mathrm{d}S_t}{S_t} - \frac{1}{2}\sigma_t^2\mathrm{d}t$，因此 $\frac{1}{T}\int_0^T \sigma_t^2\mathrm{d}t = \frac{2}{T}\left[\int \frac{\mathrm{d}S_t}{S_t} - \ln\frac{S_T}{S_0}\right]$。左边是我们想复制的实现方差，右边第一项是动态交易标的的损益（可以用 Delta 对冲实现），第二项是 $\ln S_T$ 的函数——**而任何关于 S_T 的光滑函数都可以用行权价连续的期权组合静态复制**。把 $-\ln(S_T/F_0)$ 按 $1/K^2$ 的权重展开，就得到 式 (6.21)。**这解释了为什么方差互换不需要动态对冲，只要一次性买入整条虚值期权带。**

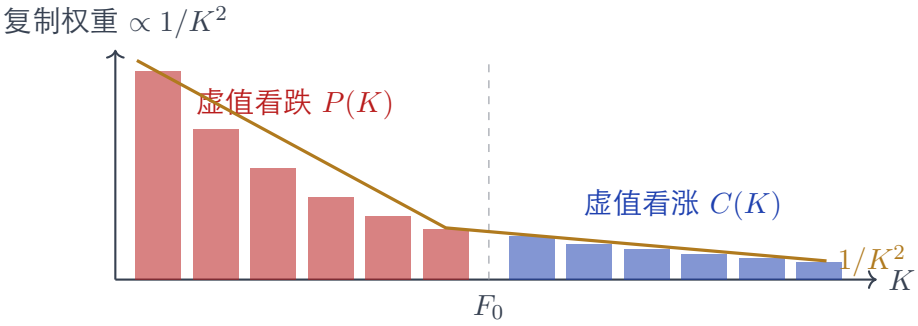


图 6.1　方差互换的静态复制：以 $1/K^2$ 为权重买入整条虚值期权带

6.7.2 VIX 指数

VIX 是 S&P 500 未来 30 天预期波动率的度量，其计算本质上是 式 (6.21) 的离散化：

$$\text{VIX}^2 = \frac{2\mathrm{e}^{rT}}{T}\sum_i \frac{\Delta K_i}{K_i^2}\,\mathrm{e}^{rT}Q(K_i) - \frac{1}{T}\left(\frac{F}{K_0} - 1\right)^2 \tag{6.22}$$

其中 $Q(K_i)$ 为虚值期权中间价，K_0 为低于并最接近远期价格 F 的行权价，最后一项来自离散行权价对连续积分的修正。

实务应用　VIX 交易的三条实务要点

- VIX **不可直接交易**：可交易的是 VIX 期货与期权，而期货价格包含了从当前到到期日的波动率预期路径，因此 VIX 期货曲线通常是向上倾斜的（正向市场）；
- **做空波动率有正期望但尾部风险极大**：VIX ETN（如 VXX）在低波动期持续阴跌，但在 2018 年 2 月 5 日「波动率末日」单日跌幅超过 80%，杠杆型产品几乎归零；
- **复制需要滚动**：由于 式 (6.21) 需要整条期权带，而 VIX 期货只覆盖一个 30 天窗口，长期做空波动率必须不断滚动期货合约，承担展期成本（roll cost）。

6.8 傅里叶变换方法

6.8.1　特征函数与 Carr–Madan 公式

对很多模型（Heston、方差 Gamma、NIG、CGMY），期权价格没有初等解析式，但**对数价格的特征函数有解析式**：

$$\psi_T(u) = \mathbb{E}^{\mathbb{Q}}\left[\mathrm{e}^{\mathrm{i}u \ln S_T}\right] \tag{6.23}$$

Carr–Madan（1999）利用傅里叶逆变换给出看涨期权价格：

$$C(k,T) = \frac{\mathrm{e}^{-\alpha k}}{\pi}\int_0^{\infty} \mathrm{e}^{-\mathrm{i}vk}\,\psi_T(v-\mathrm{i}(\alpha+1))\,\mathrm{d}v, \qquad k=\ln K \tag{6.24}$$

其中 $\alpha>0$ 为阻尼因子，用于保证积分收敛（要求 $\mathbb{E}[S_T^{\alpha+1}]<\infty$）。由于该积分对所有行权价 k 形式相同，可以用**一次 FFT 同时算出整条期权价格曲线**，这正是傅里叶方法在实务中极具吸引力的原因。

6.8.2　Heston 模型的特征函数

Heston 模型的特征函数（采用 Albrecher 等「little trap」的数值稳定形式）为

$$\begin{aligned}\psi_T(u) = \exp&\left\{\mathrm{i}u\left(\ln S_0 + rT\right)\right\}\\ &\times\exp\left\{\frac{\kappa\theta}{\xi^2}\left[\left(\kappa-\rho\xi\mathrm{i}u-d\right)T - 2\ln\frac{1-g\mathrm{e}^{-dT}}{1-g}\right]\right\}\\ &\times\exp\left\{\frac{v_0}{\xi^2}\cdot\frac{\left(\kappa-\rho\xi\mathrm{i}u-d\right)\left(1-\mathrm{e}^{-dT}\right)}{1-g\mathrm{e}^{-dT}}\right\}\end{aligned} \tag{6.25}$$

其中

$$d=\sqrt{\left(\rho\xi\mathrm{i}u-\kappa\right)^2+\xi^2\left(\mathrm{i}u+u^2\right)}, \qquad g=\frac{\kappa-\rho\xi\mathrm{i}u-d}{\kappa-\rho\xi\mathrm{i}u+d} \tag{6.26}$$

⚠ 风险警示　Heston 特征函数的数值陷阱

原始文献中的「标准形式」在某些参数区域会因复对数分支切割而产生特征函数不连续，导致数值积分出现伪振荡、价格甚至为负。Albrecher 等指出该问题来自 $\ln(1-ge^{-dT})$ 与 $\ln(1-g)$ 的相位选择，改用 式 (6.25) 的等价形式可完全避免。这是「公式正确但实现错误」的经典案例，也提醒我们：解析公式的数值稳定性必须被验证，而不能因为「有闭式解」就假定实现没问题。

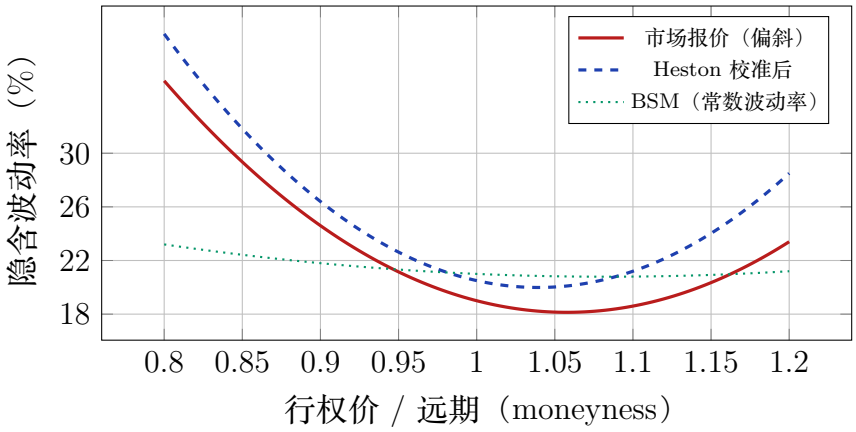


图 6.2　Heston 模型对市场偏斜的拟合能力：单因子随机波动率能捕捉大部分偏斜，但在极短期限的两翼仍存在系统性偏差

6.9 数值实现专题

6.9.1　最小二乘蒙特卡洛

美式与百慕大期权的最优行权策略无法解析求解，LSM 方法用**回归近似继续持有价值**。

⚠ 风险警示　LSM 的三个实践要点

1. **只在实值路径上回归**：把虚值路径纳入回归会引入严重偏差（它们永远不会被行权）；
2. **得到的是下偏估计**：因为回归给出的是次优行权策略，价格会系统性偏低；
3. **不要在回归中引入未来信息**：必须使用同一时刻的可观测状态变量，否则会得到高于真实价格的上偏结果——这是回测与定价中最危险的一类错误。

6.9.2　蒙特卡洛加速与傅里叶实现

- **多级蒙特卡洛（MLMC）**：把估计量分解为不同步长的层级 $\hat{Y}=\sum_{l=0}^{L}\hat{Y}_l$，其中 $\hat{Y}_l$ 为相邻层级之差。由于粗层级的方差大但成本低、细层级的方差小但成本高，最优样本分配 $n_l \propto \sqrt{\mathrm{Var}[Y_l]/C_l}$ 可使总计算量下降一个数量级以上；
- **GPU 加速**：路径生成与收益计算天然并行，适合向量化到 GPU；

算法 6.1　最小二乘蒙特卡洛（LSM）定价美式期权

输入： 模拟路径 $\{S_{t_m}^{(i)}\}$（$i=1,\dots,N$，$m=0,\dots,M$），行权价 K，折现因子 $\Delta = \mathrm{e}^{-r\Delta t}$
输出： 期权价格估计 $\hat{V}_0$

初始化到期现金流 $V^{(i)} \leftarrow \max(K - S_T^{(i)}, 0)$（看跌）
for $m = M-1$ 到 1 **do**
　　记 $Y^{(i)} \leftarrow V^{(i)} \cdot \Delta$　　// 继续持有价值的样本实现
　　选取基函数 $\phi_1, \dots, \phi_J$（常用 $1, S, S^2$ 或 Laguerre 多项式）
　　仅在实值路径上用最小二乘拟合 $Y^{(i)} \approx \sum_j \beta_j \phi_j(S_{t_m}^{(i)})$
　　记拟合值 $\hat{C}^{(i)}$，行权收益 $H^{(i)} \leftarrow \max(K - S_{t_m}^{(i)}, 0)$
　　if $H^{(i)} > \hat{C}^{(i)}$ **then**
　　　　$V^{(i)} \leftarrow H^{(i)}$　　// 行权，记为当前现金流
　　else
　　　　$V^{(i)} \leftarrow Y^{(i)}$　　// 继续持有
　　end if
end for
return $\frac{1}{N}\sum_i V^{(i)} \cdot \Delta$

- **随机数质量**：必须使用可复现的生成器与足够长的周期，并对低差异序列做随机化（scrambling）以获得误差估计。

Listing 6.1　Heston 特征函数与 Carr-Madan 数值积分

```python
import numpy as np
from scipy.integrate import quad

def heston_cf(u, S0, r, T, v0, kappa, theta, xi, rho):
    """Characteristic function of log S_T under Q (Albrecher et al. form)."""
    u = np.asarray(u, dtype=complex)
    d = np.sqrt((rho * xi * 1j * u - kappa) ** 2 + xi ** 2 * (1j * u + u ** 2))
    g = (kappa - rho * xi * 1j * u - d) / (kappa - rho * xi * 1j * u + d)
    exp_dT = np.exp(-d * T)
    c1 = (kappa * theta / xi ** 2) * ((kappa - rho * xi * 1j * u - d) * T
                                      - 2.0 * np.log((1 - g * exp_dT) /
                                                     (1 - g)))
    c2 = (v0 / xi ** 2) * ((kappa - rho * xi * 1j * u - d)
                           * (1 - exp_dT) / (1 - g * exp_dT))
    return np.exp(1j * u * (np.log(S0) + r * T)) * np.exp(c1 + c2)

def carr_madan_call(K, S0, r, T, v0, kappa, theta, xi, rho, alpha=1.5, n=2000):
    """Carr-Madan integration over v in [0, v_max] with a trapezoid rule."""
    k = np.log(K)
    v_max, dv = 200.0, 200.0 / n
    v = np.linspace(dv, v_max, n)
```

```
    psi = heston_cf(v - 1j * (alpha + 1), S0, r, T, v0, kappa, theta, xi,
        rho)
    integrand = np.real(np.exp(-1j * v * k) * psi)
    return np.exp(-alpha * k) / np.pi * np.trapezoid(integrand, dx=dv)

# A typical calibrated parameter set (equity index, T = 1y)
p = dict(S0=100.0, r=0.03, T=1.0, v0=0.04, kappa=1.8, theta=0.045,
         xi=0.6, rho=-0.75)
for K in (80, 90, 100, 110, 120):
    print(f"K={K:>3d}  C={carr_madan_call(K, **p):8.4f}")
```

本章小结

- Q Quant 的语言是等价鞅测度：无套利 $\Longleftrightarrow$ 存在 $\mathbb{Q}$（第一基本定理），完备 $\Longleftrightarrow$ $\mathbb{Q}$ 唯一（第二基本定理）。
- Girsanov 定理说明测度变换只改漂移、不改波动率；风险的市场价格 $\lambda = (\mu - r)/\sigma$ 是两者之间的桥梁。
- 计价单位变换是利率与外汇衍生品定价的通用工具：在 T-远期测度下远期利率是鞅，这使 LMM 可以直接校准到 Caplet 报价。
- 短期利率模型（Vasicek、CIR、Hull–White）以仿射结构换取解析性；HJM 用波动率结构决定漂移，代价是维度爆炸；LMM 以市场可校准性取胜。
- 信用定价的核心是违约强度与相关性；高斯 Copula 的失效在于尾部独立与常数相关性。
- 方差互换可以被整条虚值期权带静态复制（式 (6.21)），VIX 是它的离散化。
- 傅里叶定价（Carr–Madan）用特征函数一次算出整条价格曲线，但必须注意 Heston 特征函数的复对数分支问题。
- LSM 用回归近似最优行权策略，是美式/百慕大期权的主流方法，但只能在实值路径上回归，且结果天然下偏。

练习与思考

1. 设 $\mathbb{P}$ 下 $\mathrm{d}S_t = 0.12 S_t \mathrm{d}t + 0.25 S_t \mathrm{d}W_t^{\mathbb{P}}$，$r = 4\%$。求风险的市场价格 λ，写出 $\mathbb{Q}$ 下 S_t 的 SDE，并计算 $\mathbb{E}^{\mathbb{Q}}[\ln S_T]$ 与 $\mathbb{E}^{\mathbb{P}}[\ln S_T]$ 之差。

2. 证明：若 N_t 与 M_t 都是正的可交易资产价格，则在测度 $\mathbb{Q}^N$ 下 M_t/N_t 是鞅。并说明为什么这个结论能解释「用债券作计价单位时远期价格是鞅」。

3. 在 Vasicek 模型下，若 $\kappa = 0.8$、$\sigma = 2\%$，请计算利率冲击的半衰期，并说明半衰期变短会如何影响 5 年期零息债券的对冲比率 $B(0,5)$。

4. 用 CDS 价差近似公式 $s \approx (1-R)\lambda$ 回答：若某公司 5 年期 CDS 从 150bp 扩大到 450bp、回收率维持 40%，隐含的年度违约概率如何变化？这个变化在数学上等价

于违约概率上升了多少倍？

5. 解释为什么方差互换的复制组合中，权重与行权价的平方成反比，并说明若只使用有限个行权价（例如 20 个），复制误差主要来自哪两个区域。
6. 在 LSM 算法中，如果把回归基函数从 $(1, S, S^2)$ 增加到 10 个多项式，分别讨论对价格估计偏差与方差的影响，并说明为什么「基函数越多越好」是错的。

延伸阅读

- Shreve, S. E., *Stochastic Calculus for Finance II: Continuous-Time Models*, Springer, 2004.（测度变换与鞅定价的最佳入门，第 5 章讲透 Girsanov 与计价单位变换）
- Musiela, M., and Rutkowski, M., *Martingale Methods in Financial Modelling*, 2nd ed., Springer, 2005.（利率与信用衍生品的鞅方法系统参考）
- Brigo, D., and Mercurio, F., *Interest Rate Models — Theory and Practice*, 2nd ed., Springer, 2006.（LMM 校准与利率波动率曲面，实务细节极其丰富）
- Heath, D., Jarrow, R., and Morton, A., "Bond Pricing and the Term Structure of Interest Rates", *Econometrica*, 1992, 60(1): 77–105.（HJM 漂移条件的原始文献）
- Heston, S. L., "A Closed-Form Solution for Options with Stochastic Volatility", *Review of Financial Studies*, 1993, 6(2): 327–343.（随机波动率与特征函数）
- Carr, P., and Madan, D. B., "Option Valuation Using the Fast Fourier Transform", *Journal of Computational Finance*, 1999, 2(4): 61–73.（傅里叶定价的奠基性论文）
- Demeterfi, K., Derman, E., Kamal, M., and Zou, J., "More Than You Ever Wanted to Know About Volatility Swaps", *Goldman Sachs Quantitative Strategies Research Notes*, 1999.（方差互换静态复制的经典推导）
- Longstaff, F. A., and Schwartz, E. S., "Valuing American Options by Simulation: A Simple Least-Squares Approach", *Review of Financial Studies*, 2001, 14(1): 113–147.（LSM 原始文献）

第七章 P Quant：统计方法与量化策略

Q Quant 在风险中性测度 $\mathbb{Q}$ 下为衍生品定价，P Quant 则在真实测度 $\mathbb{P}$ 下回答一个更朴素、也更难的问题：未来实际会发生什么？本章沿「数据 → 信号 → 因子 → 组合 → 执行 → 验证」这条主线展开，把因子投资、机器学习选股、回测统计校验与市场微观结构串成一个完整工作流，并始终追问同一个问题：这个结论在样本外还剩多少。

7.1 P Quant 的工作面

P Quant 得名于真实世界测度 $\mathbb{P}$。它不假定无套利已经把所有价格钉死，而是承认价格里既有风险补偿，也有错误定价，并用统计方法把其中可重复的部分提取出来。

核心要点 7.1　P Quant 与 Q Quant 的分工

P Quant 问的是“实际会发生什么”，因此它的核心资产是可重复的预测与可控制的风险暴露；Q Quant 问的是“在无套利世界应该值多少”，核心资产是复制组合与校准精度。两者的失效条件不同：P Quant 死于样本外失效，Q Quant 死于模型设定与流动性假设。

直觉理解　为什么 P Quant 更依赖统计纪律

在风险中性世界里，只要复制组合正确，价格就是唯一的；在真实测度下不存在这样的唯一性定理，任何“我发现了一个规律”的结论都必须与“我试了多少次才找到它”一起汇报。这正是本章后半部分反复讨论多重检验与回测过拟合的原因。

表 7.1　P Quant 工作流的六个环节与产出物

环节	输入	产出物	主要失效模式
数据清洗	原始行情与财务	干净面板	幸存者偏差、复权错误
信号构建	面板数据	原始信号	前视偏差、极端值污染
中性化	原始信号与风险暴露	纯净因子	过度中性化削减 Alpha
组合优化	因子与协方差	目标权重	估计误差放大
执行	目标权重与订单簿	成交明细	冲击成本、时滞
验证	全部历史	可信的绩效结论	数据窥探、过拟合

表 7.1 的第三列提醒我们：每一步都有明确的交付物，而不是“感觉不错”的曲线。后文各节依次深入这六个环节。

7.2 因子构建全流程

7.2.1 从原始信号到可用因子

一个因子在进入组合之前，必须走完一条标准化流水线。缺失这三步中的任何一步，都可能让一个真实有效的信号在实证中表现平庸，或让一个无效信号表现得过于优秀。

定义 7.1 因子构建流水线

给定 t 时刻的横截面信号 $\{s_{i,t}\}_{i=1}^{n}$，因子构建流水线依次执行：

1. **去极值**（Winsorize）：把 $s_{i,t}$ 截断到 $[\text{med} - k \cdot \text{MAD},\ \text{med} + k \cdot \text{MAD}]$；
2. **标准化**（Standardize）：减去横截面均值、除以横截面标准差，得到 $z_{i,t}$；
3. **缺失值处理**：剔除停牌与无数据股票，或按行业均值填补；
4. **中性化**（Neutralize）：对 $z_{i,t}$ 回归掉行业哑变量与风格暴露，取残差。

其中 med 为横截面中位数，MAD 为中位数绝对偏差，k 常取 3；i 为股票编号，t 为交易日。

⚠ 风险警示 为什么必须先去极值

若先标准化再去极值，一个 10 倍标准差的观测会把横截面标准差本身抬高约 $\sqrt{1 + 100/n}$，在 $n = 500$ 时约抬高 10%，于是同一天内其余 499 只股票的标准分被系统性压缩，因子横截面分布的形状被单只股票扭曲。顺序错误引入的不是随机噪声，而是可预测的偏差。

7.2.2 行业与风格中性化

中性化的目的是把一个“可能只是市值或行业押注”的信号，还原成纯粹的特质信息。做法是横截面回归

$$z_{i,t} = \alpha_t + \sum_{g=1}^{G} \beta_{g,t} I_{i,g} + \sum_{j=1}^{K} \gamma_{j,t} x_{i,j,t} + \tilde{z}_{i,t} \tag{7.1}$$

其中 $z_{i,t}$ 为标准化后的原始信号，$I_{i,g}$ 为股票 i 属于行业 g 的哑变量（共 G 个行业），$x_{i,j,t}$ 为第 j 个风格暴露（如对数市值、60 日波动率），$\tilde{z}_{i,t}$ 为回归残差，也就是中性化后的因子值。若采用加权最小二乘，权重常取 $\sqrt{\text{自由流通市值}}$，理由是大市值股票的因子暴露估计更稳定，而市值本身又是最重要的风格维度。

ℹ 补充说明 中性化的代价

行业与风格暴露合计可能解释原始信号方差的 30% 至 60%。中性化在削掉这些“搭车”收益的同时，也削掉了与它们相关的真实 Alpha。实务中的做法是保留两版因子（原始版与中性版）分别回测，只有当两版的 IC 同号且中性版的信息比率更高时，才认定信号本身有效。

表 7.2　Barra 风格因子的经济含义与典型构建方式

因子	方向	经济含义与构建要点
Size	负	对数自由流通市值。小盘股长期有溢价，但流动性与容量受限
Value	正	账面市值比、盈利收益率、现金流价格比的合成，需行业中性
Momentum	正	过去 12 个月收益剔除最近 1 个月，短期反转会污染该因子
Volatility	负	残差波动率与日收益标准差，低波动异象在多数市场存在
Liquidity	负	换手率与 Amihud 非流动性，高流动性股票风险调整收益更高
Leverage	负	资产负债率与账面杠杆，高杠杆公司在信用收缩期表现更差
Growth	负	盈利与营收增速，高成长预期往往伴随估值回落

表 7.2 中七个风格因子构成多数商业风险模型的主干。它们的共同特征是：暴露可由公开数据在每月末一次性计算，因此可以被所有参与者同时观测，属于“共同知识型”风险维度。

7.2.3　风险模型的截面估计

Barra 型风险模型假设个股收益由因子收益与特质收益线性生成

$$r_{i,t} = \sum_{j=1}^{K} X_{i,j,t-1} f_{j,t} + u_{i,t} \tag{7.2}$$

其中 $r_{i,t}$ 为股票 i 在 t 期的收益，$X_{i,j,t-1}$ 为期初已知的因子暴露，$f_{j,t}$ 为待估因子收益，$u_{i,t}$ 为特质收益。写成矩阵形式 $r_t = X_{t-1} f_t + u_t$，加权最小二乘估计为

$$\hat{f}_t = \left(X_{t-1}^{\top} W_t X_{t-1}\right)^{-1} X_{t-1}^{\top} W_t \, r_t \tag{7.3}$$

其中 $W_t = \mathrm{diag}(w_{1,t}, \dots, w_{n,t})$ 为权重矩阵。当 W_t 正比于特质方差矩阵的逆时，式 (7.3) 即为广义最小二乘，估计量达到最小方差；实务中用市值平方根近似这一理想权重。

因子收益序列存在自相关与异方差，因此因子协方差矩阵的估计需要稳健化。Newey–West 估计量为

$$\hat{\Sigma}_f = \hat{\Gamma}_0 + \sum_{l=1}^{L} \left(1 - \frac{l}{L+1}\right) \left(\hat{\Gamma}_l + \hat{\Gamma}_l^{\top}\right) \tag{7.4}$$

其中 $\hat{\Gamma}_l = \frac{1}{T}\sum_{t=l+1}^{T} \hat{f}_t \hat{f}_{t-l}^{\top}$ 为滞后 l 阶自协方差，L 为带宽（月度数据常取 $L=2$ 至 5）。括号内的线性衰减是 Bartlett 核，它保证 $\hat{\mathbf{\Sigma}}_f$ 半正定。最后仍需做特征值调整，把过小的特征值抬到安全下界，因为组合优化器会精确地利用任何被低估的风险方向。

7.3 信息系数与因子评价

7.3.1 IC、Rank IC 与衰减

信息系数度量因子在横截面上的预测能力

$$IC_t = \mathrm{Corr}(s_{i,t},\ r_{i,t+1}), \qquad RankIC_t = \mathrm{Corr}(\mathrm{rank}(s_{i,t}),\ \mathrm{rank}(r_{i,t+1})) \tag{7.5}$$

其中 $s_{i,t}$ 为 t 期末已知的因子值，$r_{i,t+1}$ 为下一期收益，$\mathrm{rank}(\cdot)$ 为横截面秩。Rank IC 即 Spearman 秩相关，对极端值稳健，因此是行业内的默认报告口径。

单期 IC 是极不稳定的统计量。若横截面有 n 只股票，IC_t 的标准误约为 $1/\sqrt{n-3}$；在 $n=500$ 时约为 0.045。这意味着单日 $IC=0.05$ 完全可能是噪声。判断因子有效性应看长期平均

$$\overline{IC} = \frac{1}{T}\sum_{t=1}^{T} IC_t, \qquad \mathrm{SE}(\overline{IC}) = \frac{\mathrm{sd}(IC_t)}{\sqrt{T/\tau}} \tag{7.6}$$

其中 τ 为 IC 序列的自相关时间（自相关衰减到 $1/\mathrm{e}$ 所需的期数），T/τ 可理解为*有效独立期数*。例：月度 IC 均值 0.04、月度标准差 0.09、自相关半衰期约 1 个月，则 $\tau \approx 1.44$，十年 120 期的有效样本约 83，$\mathrm{SE}(\overline{IC}) \approx 0.0099$，$t$ 值约 4.0，在 1% 水平显著。若忽略自相关直接取 $\mathrm{SE} = 0.09/\sqrt{120} = 0.0082$，会把 t 值夸大到 4.9。

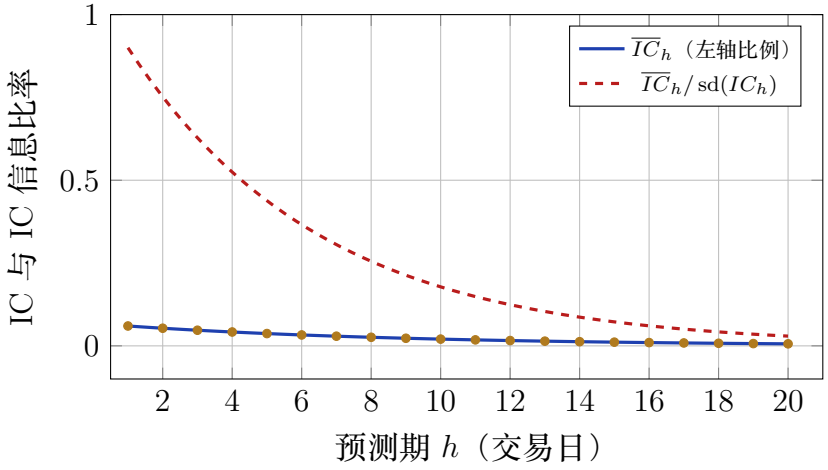


图 7.1　因子 IC 与 IC 信息比率随预测期的衰减：指数衰减意味着半衰期约 5.8 个交易日，持仓周期应与衰减速度匹配

图 7.1 画出一条典型量价因子的衰减曲线。IC 从 $h=1$ 的 0.06 衰减到 $h=10$ 的 0.020 左右，半衰期 $h_{1/2} = \ln 2/0.12 \approx 5.8$ 个交易日。若持仓周期取 20 天，虽然单次交易的

信号仍在，但信号已衰减到峰值的约 10%，大部分持仓期是在“无信息”状态下承担风险。这解释了为什么高换手因子必须配高频调仓，也解释了交易成本为什么会吃掉大部分毛收益。

7.3.2 分层回测与多空组合

把股票按因子值排序等分为 Q 层，计算每层等权或市值加权的下期收益，若因子有效则单调性应当明显。用最高层与最低层构造多空组合

$$r_t^{\mathrm{LS}} = \frac{1}{|Q^+|}\sum_{i\in Q^+} r_{i,t} - \frac{1}{|Q^-|}\sum_{i\in Q^-} r_{i,t} \tag{7.7}$$

其中 Q^+ 与 Q^- 分别为因子值最高与最低的一层。多空收益序列的年化信息比率为

$$IR^{\mathrm{LS}} = \frac{\mathbb{E}\left[r_t^{\mathrm{LS}}\right]}{\mathrm{sd}\left(r_t^{\mathrm{LS}}\right)}\sqrt{A} \tag{7.8}$$

其中 A 为年化期数（日频取 252，月频取 12）。注意这里用总波动而非超额收益跟踪误差，因此 IR^{LS} 是可比的“因子强度”指标，与组合层面的 IR 并不等价。

例 7.1　单调性与换手率的联合判读

某月频因子在 3000 只股票上分为五层，过去十年（120 期）的年化超额收益依次为 $Q_1 = -6.1\%$、$Q_2 = -1.8\%$、$Q_3 = 0.4\%$、$Q_4 = 3.6\%$、$Q_5 = 7.9\%$，多空组合年化收益 14.0%、年化波动 7.5%，故 $IR^{\mathrm{LS}} = 1.87$。同时统计因子换手率：期均单边换手率 28%，按 10 个基点的双边成本计，年成本约 $0.28 \times 2 \times 12 \times 0.0010 = 6.7\%$，扣费后多空收益降至约 7.3%，$IR^{\mathrm{LS}}$ 降至约 0.98。若分层单调性存在但换手率超过 60%，则成本将吞掉全部多空收益，此时应先做信号平滑降低换手，而不是加杠杆放大毛收益。

7.3.3 因子评价清单

实务应用　因子拥挤度的三种度量

业界常用三种信号判断因子是否过度拥挤：一是该因子多空组合的管理规模估算，二是因子收益与因子波动率之比在近两年的异常抬升，三是同因子不同数据供应商版本的收益相关性上升。三者同时触发时，通常意味着该因子的 Alpha 已被套利掉大半，应降低暴露并提高分散度。

7.4 主动管理基本定律

7.4.1 定律的推导

主动管理基本定律把信息质量、下注广度与信息比率联系起来。设组合由 N 个相互独立的下注构成，第 k 个下注的主动权重为 w_k，残差收益为 r_k，并假定每个下注具备相

表 7.3　因子评价指标与判读门槛

指标	典型门槛	判读要点
平均 IC	$\lvert\overline{IC}\rvert > 0.02$	日频 0.02 已属可用，月频可达 0.04
IC 信息比率	> 0.3	均值与标准差之比，衡量信号稳定性
分层单调性	五层单调	非单调常意味着信号与风险暴露纠缠
换手率	与衰减匹配	日频 $< 30\%$、月频 $< 50\%$ 较现实
容量	覆盖多只股票	容量受流动性与冲击成本约束
多空最大回撤	小于年化收益	回撤深于年化收益说明尾部风险集中
因子相关性	与已知因子 < 0.5	相关性过高只是重复暴露，不贡献增量信息

同的预测能力：$\mathrm{Corr}(w_k, r_k) = IC$，且各下注收益的残差波动为 σ。

在主动风险预算 σ_{active} 的约束下，最大化 $\sum_k w_k \mathbb{E}[r_k]$。把残差收益分解为可预测部分与噪声 $r_k = \mathbb{E}[r_k] + \varepsilon_k$，预测误差方差为 ω^2，则最优下注为 $w_k = \mathbb{E}[r_k]/\omega$，即对残差收益的贝叶斯收缩。

命题 7.1 (主动管理基本定律) 在上述独立同分布假设下，最优组合的信息比率为

$$IR \approx IC \cdot \sqrt{N} \tag{7.9}$$

其中 IC 为单个下注的信息系数，N 为独立下注次数（Breadth）。

证明. 记第 k 个下注的主动收益为 $w_k r_k$。预测能力 IC 意味着 $\mathbb{E}[r_k \mid s_k] = IC \cdot \sigma \cdot \tilde{s}_k$，其中 $\tilde{s}_k$ 为标准化信号，σ 为残余波动。选择 $w_k = \mathbb{E}[r_k \mid s_k]/\sigma^2$ 以最大化 $\sum_k \mathbb{E}[w_k r_k]$，主动收益均值为 $\sum_k \mathbb{E}[w_k r_k] = \sum_k \mathbb{E}\big[(\mathbb{E}[r_k \mid s_k]/\sigma^2)\mathbb{E}[r_k \mid s_k]\big] = N \cdot IC^2$。主动风险为 $\sqrt{\sum_k w_k^2 \sigma^2} = \sqrt{N \cdot IC^2} = IC\sqrt{N}$。两者相除即得 $IR \approx IC\sqrt{N}$。 ■

7.4.2　现实修正

式 (7.9) 的两个假设都不成立：下注并非独立，约束也阻止我们把所有信念表达出来。修正形式为

$$IR \approx IC \cdot \sqrt{N_{\text{eff}}} \cdot TC \tag{7.10}$$

其中 $N_{\text{eff}} = N/(1 + (N-1)\bar{\rho})$ 为有效下注数，$\bar{\rho}$ 为下注间平均相关系数，TC 为转移系数（Transfer Coefficient），即组合权重与理想主动权重的相关系数，取值于 $[-1, 1]$，反映约束、行业限制与做空限制带来的损耗。

直觉理解　广度的数量级直觉

$\bar{\rho}=0.1$ 且 $N=500$ 时，$N_{\text{eff}}\approx 500/50.9\approx 9.8$，$\sqrt{N_{\text{eff}}}\approx 3.1$，仅为 $\sqrt{500}\approx 22.4$ 的 14%。这说明“多下注”必须真的独立；在同一风格内增加 100 只股票，并不提供 100 份独立信息，只提供约 2 份。

例 7.2　年化 IR 的完整推算

某日频多因子模型的单期 $IC=0.03$，每日持有 400 只股票的横截面信号，调仓 20 次因此 $N=400\times 20=8000$。取 $\bar{\rho}=0.15$，则 $N_{\text{eff}}=8000/(1+7999\times 0.15)\approx 6.7$，$\sqrt{N_{\text{eff}}}\approx 2.58$。设 $TC=0.7$，代入 式 (7.10) 得 $IR\approx 0.03\times 2.58\times 0.7\approx 0.054$，这是单期（约 12.6 个交易日）的信息比率。按每年约 20 个这样的持有期折算，年化 $IR\approx 0.054\times\sqrt{20}\approx 0.24$。若天真地用 $IR\approx IC\sqrt{N}$，会得到 $0.03\times 89.4\approx 2.68$，夸大十倍以上——这正是许多内部研究报告中“理论 IR”与实际绩效差距的主要来源。

7.5 机器学习选股

7.5.1　适用场景与模型选择

机器学习在量化选股中的价值不在于替代经济学直觉，而在于用高维特征去逼近非线性条件期望 $\mathbb{E}[r_{i,t+1}\mid \mathbf{x}_{i,t}]$。三类模型各有明确的适用场景。

表 7.4　机器学习选股模型的适用场景与注意事项

模型	适用场景	主要风险
线性回归	少量经济含义明确的因子	无法捕捉交互项与非线性
GBDT	截面样本多、特征含类别变量	对时序漂移敏感，需频繁重训
随机森林	特征噪声大、需要稳健基线	外推能力弱，难以预测极端收益
神经网络	特征维度极高、样本量足够	参数量大，样本外衰减快
集成组合	追求稳定性与低相关性	训练与维护成本高

7.5.2　样本权重与标签设计

金融面板数据的样本并非等质量，可用三类权重区分。

- **唯一性权重**：重叠标签（如持有期为 20 天但每日采样）会重复使用同一段收益，应给每个标签按重叠次数倒数赋权；
- **时间衰减权重**：越久远的样本市场结构差异越大，用半衰期 1 至 2 年的指数权重降权；
- **收益幅度权重**：以绝对收益或波动率倒数加权，可降低高波动期的杠杆式主导。

标签设计同样重要。回归标签（下一期收益）保留幅度信息但受极端值支配；分类标签（收益三分位或是否跑赢基准）稳健但丢失幅度；三重障碍法（Triple Barrier）同时设定止盈、止损与时间上限，把路径信息纳入标签，更适合日内与短周期策略。

7.5.3 时序交叉验证与泄漏防控

标准 k-折交叉验证在金融面板上必然泄漏：训练集与测试集在时间上交错，而标签本身跨越多个交易日。正确做法是 Purged k-折加 embargo：先按时间切分为 k 个连续块，然后把与测试块标签区间重叠的训练样本剔除（Purging），再在测试块之后额外丢弃 h 天的样本（Embargo），其中 h 为标签持有期。

算法 7.1 Purged k-折交叉验证与 embargo

输入： 样本时间戳 t_i，标签区间 $[t_i, t_i + h]$，折数 k，禁运长度 e
输出： 每折的训练索引与测试索引

按时间排序样本，等分为 k 个连续块 $B_1, \dots, B_k$
for $j = 1$ 到 k **do**
    测试集置为 B_j
    对每个候选训练样本，若其标签区间与 B_j 的时间区间相交则剔除
    再剔除时间落在 B_j 结束之后 e 天内的样本
    return 该折的（训练集，测试集）
end for

⚠ 风险警示　特征重要性不等于因果关系

用 GBDT 的增益或置换重要性排序特征，很容易被前视型特征主导。典型例子：用当日收盘价与当日成交量之比构造“量价背离”特征，再用当日收益作标签，重要性极高但完全无法交易。检查方法是对每个高重要性特征追问两个问题：该特征在 t 时刻的真实可得时间戳是什么？把它整体滞后一天后重要性还剩多少？

7.6 回测方法论

7.6.1 偏差清单

回测是量化研究中最容易产生虚假结论的环节。下表把常见偏差按可检测性排列。

7.6.2 多重检验的三个层次

假设我们测试了 m 个策略变体，得到一个 Sharpe 比率最高的版本。问题是：这个最大值有多少来自真实信号，多少来自噪声？

第一层：**Bonferroni** 校正把单次显著性水平除以试验次数，$p_i^{\text{Bonf}} = \min(m p_i, 1)$，控制族错误率（FWER）。它过于保守，当 $m = 100$ 时要求单个 p 值小于 0.0005。

第二层：**Benjamini–Hochberg FDR** 控制假发现比例。把 p 值升序排列 $p_{(1)} \le \cdots \le p_{(m)}$，取最大的 i 满足

表 7.5　回测偏差清单与检测方法

偏差	后果	检测与修正
幸存者偏差	高估收益	使用含退市股票的完整历史成分
前视偏差	严重高估	特征打时间戳，财报按公告日而非报告期对齐
复权错误	收益失真	用前复权价计算收益，除权日用总收益口径
数据窥探	显著性失效	记录全部试验次数，做多重检验校正
交易成本忽视	高估净收益	加入冲击成本与延迟，做容量测试
参数过拟合	样本外崩塌	Purged k-折、DSR、PBO 检验
不可交易性	收益不可实现	剔除涨跌停、停牌与低流动性标的

$$p_{(i)} \le \frac{i}{m}\,\alpha \tag{7.11}$$

并拒绝前 i 个假设。其中 α 为目标 FDR 水平（常取 5%）。当 $m=100$、$\alpha=0.05$ 时，最小的 p 值只需小于 0.0005 看似相同，但第 10 个只需小于 0.005，比 Bonferroni 宽松得多，因此在因子筛选中更实用。

第三层：对最大 Sharpe 比率本身做校正。Deflated Sharpe Ratio 给出

$$DSR = \Phi\left(\frac{\left(\widehat{SR} - SR_0\right)\sqrt{T-1}}{\sqrt{1-\hat{\gamma}_3\widehat{SR}+\frac{\hat{\gamma}_4-1}{4}\widehat{SR}^2}}\right) \tag{7.12}$$

其中 $\widehat{SR}$ 为观测到的（非年化）Sharpe 比率，T 为样本长度，$\hat{\gamma}_3$ 为收益偏度，$\hat{\gamma}_4$ 为收益峰度，SR_0 为多重检验下的期望最大值

$$SR_0 = \sqrt{\mathrm{Var}(\widehat{SR})}\left[(1-\gamma)\,\Phi^{-1}\!\left(1-\frac{1}{m}\right)+\gamma\,\Phi^{-1}\!\left(1-\frac{1}{me}\right)\right] \tag{7.13}$$

其中 $\gamma \approx 0.5772$ 为 Euler–Mascheroni 常数，$\mathrm{Var}(\widehat{SR})$ 为不同试验间 Sharpe 比率的方差。

例 7.3　DSR 的实际杀伤力

设某策略日频 Sharpe 比率 $\widehat{SR}=0.08$（年化约 1.27），样本 $T=1000$ 天，偏度 $\hat{\gamma}_3=-0.3$，峰度 $\hat{\gamma}_4=6$。研究者共试验 $m=50$ 个变体，变体间 Sharpe 比率的标准差为 0.05。代入 式 (7.13)：$\Phi^{-1}(1-1/50)=2.054$，$\Phi^{-1}(1-1/(50\mathrm{e}))=\Phi^{-1}(0.99264)=2.44$，故 $SR_0=0.05\times(0.4228\times 2.054+0.5772\times 2.44)=0.05\times(0.868+1.409)=0.114$。由于 $\widehat{SR}<SR_0$，式 (7.12) 的分子为负，$DSR\approx\Phi(-2.2)\approx 1.4\%$。也就是说，在 50 次试验的背景下，这个看起来年化 Sharpe 1.27 的策略连 5% 的显著性都达不到。

补充工具：White's Reality Check 用 bootstrap 检验"最优策略的真实绩效是否为零"，对策略集合的最大值做数据挖掘矫正；PBO（Probability of Backtest Overfitting）则用组合对称交叉验证（CSCV）估计"样本内最优策略在样本外落到中位数以下"的概率，$PBO > 0.5$ 是明确的过拟合警报。

⚠ 风险警示　回测过拟合的数学本质

若研究者测试 m 个真实绩效为零的策略，最优样本 Sharpe 比率的期望约为 $\sqrt{\mathrm{Var}(\widehat{SR})} \cdot \mathbb{E}[\max_m Z] \approx 0.05 \times 2.1 = 0.105$（$m = 50$ 时），对应年化 1.66。也就是说，*只要试验次数足够多，在完全没有 Alpha 的数据上也能稳定找到年化 Sharpe 超过 1.6 的策略*。回测报告若不披露试验次数，其 Sharpe 比率没有统计意义。

7.6.3　实施缺口与交易成本

回测与实盘的差距称为实施缺口（Implementation Shortfall），由四部分组成：决策价格与下单价格之间的延迟成本、买卖价差成本、市场冲击成本与机会成本（未成交部分）。冲击成本的常用模型为平方根律

$$\text{Impact} \approx \eta \, \sigma_{\text{daily}} \sqrt{\frac{Q}{V_{\text{daily}}}} \tag{7.14}$$

其中 Q 为下单股数，V_{daily} 为该股票日均成交量，σ_{daily} 为日波动率，η 为经验常数（美股大盘股常用 0.3 至 0.8）。例：$\eta = 0.5$、$\sigma_{\text{daily}} = 2\%$、$Q/V = 10\%$，则冲击成本约 $0.5 \times 0.02 \times 0.316 = 0.32\%$，单边成本已超过日频因子单期预期收益 $IC \cdot \sigma = 0.03 \times 2\% = 0.06\%$ 的五倍。这是容量约束的核心来源：规模越大，越只能交易低频、低换手的因子。

7.7 市场微观结构与最优执行

7.7.1　订单簿与价差分解

限价订单簿（Limit Order Book）在每个价位维护价格、数量与队列优先级。由它派生的三个量最常用：买卖价差 $s = p^a - p^b$；中间价 $m = (p^a + p^b)/2$；订单流不平衡 $\mathrm{OFI}_t = \Delta V_t^b - \Delta V_t^a$，其中 V^b、V^a 为最优买卖档的挂单量。OFI 对短期价格变动有显著预测力，是日内做市与执行算法的核心输入。

价差可分解为三部分：订单处理成本、存货持有成本与逆向选择成本。在 Glosten–Milgrom 模型里，做市商面对一部分知情交易者，每笔成交都包含信息含量，因此必须用价差补偿与知情者交易的损失，均衡价差满足

$$s = \frac{2\mu}{1-\mu}\,(\theta - \bar{v}) \tag{7.15}$$

其中 μ 为知情交易者比例，θ 为知情者眼中的资产价值，$\bar{v}$ 为做市商的先验均值。当 $\mu \to 0$ 时价差趋于零，市场近似无摩擦。

7.7.2 Kyle 模型的均衡推导

Kyle(1985)模型用一个交易日刻画信息如何被逐步定价。设资产清算价值 $v \sim \mathcal{N}(v_0, \Sigma_0)$，知情交易者知道 v，提交市价单数量 x；噪声交易者提交 $u \sim \mathcal{N}(0, \sigma_u^2)$，与 v 独立；做市商只观测到总订单流 $y = x + u$，并按线性规则定价，且赚取零期望利润。

定理 7.1 (Kyle 模型的线性均衡) 若做市商定价 $p = v_0 + \lambda y$，知情交易者提交 $x = \beta(v - v_0)$，则唯一线性均衡为

$$\beta = \frac{\sigma_u}{\sqrt{\Sigma_0}}, \qquad \lambda = \frac{1}{2}\sqrt{\frac{\Sigma_0}{\sigma_u^2}} = \frac{1}{2\sigma_u}, \qquad \mathbb{E}[\pi_{\text{insider}}] = \frac{1}{2}\sigma_u\sqrt{\Sigma_0} \tag{7.16}$$

其中 λ 为价格冲击系数（Kyle's Lambda），即每单位订单流引起的价格变动。

证明. 先给定 λ，求解知情者的最优下单量。其期望利润为

$$\mathbb{E}[\pi \mid v] = \mathbb{E}\big[(v - v_0 - \lambda(x+u))\,x \mid v\big] = x(v - v_0) - \lambda x^2$$

对 x 求导并令其为 0，得 $x^* = (v - v_0)/(2\lambda)$，故 $\beta = 1/(2\lambda)$。

再做市商的零利润条件要求 $p = \mathbb{E}[v \mid y]$。由正态投影公式 $\mathbb{E}[v \mid y] = v_0 + \frac{\mathrm{Cov}(v,y)}{\mathrm{Var}(y)}(y - \mathbb{E}[y])$，且 $\mathrm{Cov}(v, y) = \mathrm{Cov}\big(v, \beta(v - v_0) + u\big) = \beta\Sigma_0$，$\mathrm{Var}(y) = \beta^2\Sigma_0 + \sigma_u^2$，因此 $\lambda = \dfrac{\beta\Sigma_0}{\beta^2\Sigma_0 + \sigma_u^2}$。

把 $\beta = 1/(2\lambda)$ 代入并化简：分母为 $\frac{\Sigma_0}{4\lambda^2} + \sigma_u^2$，故 $\lambda = \dfrac{\Sigma_0/(2\lambda)}{\Sigma_0/(4\lambda^2) + \sigma_u^2}$，两边同乘分母得 $\frac{\Sigma_0}{4\lambda} + \lambda\sigma_u^2 = \frac{\Sigma_0}{2\lambda}$，即 $\lambda\sigma_u^2 = \frac{\Sigma_0}{4\lambda}$，于是 $\lambda^2 = \frac{\Sigma_0}{4\sigma_u^2}$，取正根得 $\lambda = \frac{1}{2}\sqrt{\Sigma_0/\sigma_u^2} = 1/(2\sigma_u)$，从而 $\beta = \sigma_u/\sqrt{\Sigma_0}$。最后把 x^* 代回期望利润即得 $\mathbb{E}[\pi] = \frac{\beta\Sigma_0}{2} = \frac{1}{2}\sigma_u\sqrt{\Sigma_0}$。 ■

直觉理解　Kyle's Lambda 的读法

λ 同时是三个东西：市场的价格冲击系数（每 1 单位订单流推动价格多少）、流动性深度的倒数（λ 越小越深）、以及知情者信息的"税率"。当噪声交易量 σ_u 上升时 λ 下降，因为知情者的订单更容易被噪声淹没；当信息不确定性 $\sqrt{\Sigma_0}$ 上升时 λ 上升，因为做市商更怕与知情者成交。

例 7.4　Kyle 均衡的数值计算

设 $v_0 = 50$ 元、$\Sigma_0 = 4$（即事前价格标准差 2 元）、噪声订单量标准差 $\sigma_u = 10000$ 股。代入 式 (7.16) 得 $\lambda = \frac{1}{2}\sqrt{4/10^8} = \frac{1}{2} \times 2 \times 10^{-4} = 1.0 \times 10^{-4}$ 元/股，即每 1 万股净买入推动价格上涨 1 元；$\beta = 10^4/2 = 5000$ 股/元。若真实价值高于事前均值 1 元，知情者最优下单 $x^* = 1/(2\lambda) = 5000$ 股，期望利润 $\mathbb{E}[\pi] = \frac{1}{2} \times 10^4 \times 2 = 10^4$ 元。注意知情者的期望利润只依赖于 σ_u 与 $\sqrt{\Sigma_0}$，与其私有信息的实现值无关——这是竞争性噪声环境下的一个反直觉但深刻的结论。

7.7.3 Almgren–Chriss 最优执行

执行问题问的是：给定要在 T 时间内卖出 X_0 股，如何分配下单节奏？卖掉越快，冲击成本越高；卖得越慢，价格波动风险越大。Almgren–Chriss 把这个权衡写成期望成本加风险惩罚的最小化问题。设 $t_k = k\tau$，持仓 x_k，每期卖出 $n_k = x_{k-1} - x_k$，价格满足

$$S_k = S_{k-1} + \sigma\sqrt{\tau}\,\xi_k - \gamma\, n_k, \qquad \tilde{S}_k = S_{k-1} - \frac{1}{2}s\,\operatorname{sgn}(n_k) - \eta\,\frac{n_k}{\tau} \tag{7.17}$$

其中 σ 为价格波动率，γ 为永久冲击系数，η 为临时冲击系数，s 为买卖价差，$\tilde{S}_k$ 为实际成交价。实现价差为 $C = \sum_{k=1}^{N} n_k(S_0 - \tilde{S}_k)$，目标是最小化 $\mathbb{E}[C] + \kappa_r \operatorname{Var}(C)$，其中 κ_r 为风险厌恶系数。

定理 7.2 (线性冲击下的最优执行轨迹) 在上述设定下，若忽略价差项 s，最优持仓路径为指数衰减

$$x_k = X_0\,\frac{\sinh\big(\kappa(T - t_k)\big)}{\sinh(\kappa T)}, \qquad \kappa \approx \sqrt{\frac{\kappa_r \sigma^2}{\eta}} \tag{7.18}$$

其中 sinh 为双曲正弦，κ 为执行速率（单位 1/ 时间）。当 $\kappa T \to 0$ 时轨迹退化为匀速卖出（TWAP），即最小化冲击成本；当 κT 很大时轨迹前重后轻，即优先压缩风险暴露。

证明思路. 把 x_k 视为决策变量，期望成本可写成二次型 $\mathbb{E}[C] = \frac{1}{2}\gamma X_0^2 + \eta \sum_{k=1}^{N} \frac{n_k^2}{\tau}$，方差为 $\operatorname{Var}(C) = \sigma^2 \tau \sum_{k=1}^{N} x_{k-1}^2$。目标函数对 x_k 是凸二次函数，一阶条件给出二阶线性差分方程 $\frac{\eta}{\tau}(x_{k+1} - 2x_k + x_{k-1}) = \kappa_r \sigma^2 \tau\, x_k$，边界条件为 $x_0 = X_0$、$x_N = 0$。该方程的通解为 $x_k = A\mathrm{e}^{\kappa t_k} + B\mathrm{e}^{-\kappa t_k}$，代入边界条件即得 式 (7.18)，其中 $\cosh(\kappa\tau) = 1 + \frac{\kappa_r \sigma^2 \tau^2}{2\eta}$，在小步长下近似为 $\kappa \approx \sqrt{\kappa_r \sigma^2/\eta}$。 ■

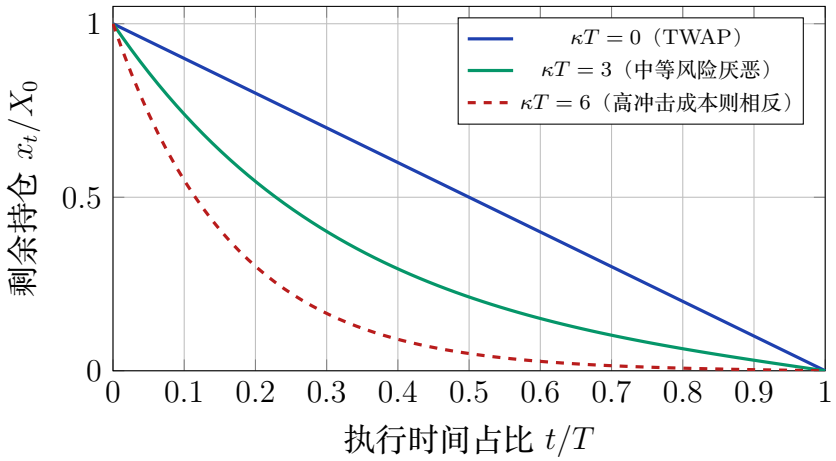


图 7.2　Almgren–Chriss 最优执行轨迹：κ 越大越前重后轻，把风险暴露集中在执行早期

图 7.2 给出三条轨迹。$\kappa T = 0$ 是 TWAP，最小化冲击成本但全程承担价格风险；$\kappa T = 6$ 时前 20% 的时间就完成了约 70% 的卖出量。决定 κ 大小的关键是比率 $\kappa_r \sigma^2/\eta$：波动率越高、风险厌恶越强、临时冲击越便宜，就越应当快速执行。

例 7.5　五年期对冲基金的执行成本权衡

某基金需在 5 个交易日内卖出 $X_0 = 10^6$ 股某美股，当前价 $S_0 = 50$ 元，日波动率 $\sigma_{\text{daily}} = 2\%$，临时冲击 $\eta = 2.0 \times 10^{-6}$ 元 · 日/股 ^{2}，永久冲击 $\gamma = 1.0 \times 10^{-7}$ 元/股。取风险厌恶 κ_r 使 $\kappa_r \sigma^2 = 0.4$（单位：元/股 ^{2}/日），则 $\kappa = \sqrt{0.4/2.0 \times 10^{-6}} \approx 447$ /日，$\kappa T \approx 2235 \gg 1$。这意味着在纯二次冲击模型下，最优解会把绝大部分股票在极短时间内抛出。现实中这种情况不会发生，因为冲击成本函数在快速交易时迅

速非线性上升，因此实务上必须在 式 (7.17) 中加入幂律冲击项或参与率上限约束，把 κT 压回 1 至 5 的区间，再按 式 (7.18) 生成日内曲线。

表 7.6　执行算法比较

算法	目标	优点	主要缺陷
TWAP	均匀成交	简单、低冲击	不响应流动性变化
VWAP	跟随成交量	降低冲击	需成交量预测，易被识别
POV	固定参与率	控制冲击	完成时间不确定
IS	最小化实施缺口	显式权衡风险	需波动率与冲击参数标定
自适应	动态学习	应对流动性突变	参数不稳定，过拟合风险

⚠ 风险警示　微观结构模型的失效条件

Kyle 与 Almgren–Chriss 的共同假设是：冲击对订单流近似线性、噪声交易量平稳、做市商竞争充分。在以下情形它们会显著低估成本：一是订单流本身包含大量同向的机构订单（“订单流毒性”上升，λ 非线性放大）；二是市场出现跳跃或新闻冲击，波动率参数突然抬升数倍；三是标的流动性极差（小盘股、部分转债），此时冲击函数近似阶跃而非线性，模型给出的 TWAP 曲线会造成严重的价格崩塌。

7.8 代码实现：中性化与 IC 计算

Listing 7.1　因子去极值、标准化、行业与风格中性化及 IC 计算

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
from scipy.stats import spearmanr

rng = np.random.default_rng(7)
dates = pd.date_range("2020-01-01", periods=60, freq="B")
industries = ["tech", "fin", "health", "energy", "cons"]

rows = []
for d in dates:
    n = 300
    ind = rng.choice(industries, size=n)
    logmcap = rng.normal(10.0, 1.2, size=n)
    vol60 = np.abs(rng.normal(0.25, 0.06, size=n))
    signal = 0.3 * logmcap - 0.5 * vol60 + rng.normal(0, 1.0, size=n)
    fwd_ret = 0.01 * signal + 0.02 * logmcap + rng.normal(0, 0.03, size=n
        )
    rows.append(pd.DataFrame({"date": d, "industry": ind, "logmcap":
        logmcap,
                              "vol60": vol60, "signal": signal, "fwd_ret"
                                  : fwd_ret}))
```

```
panel = pd.concat(rows, ignore_index=True)

def winsorize(s, k=3.0):
    med = s.median()
    mad = (s - med).abs().median()
    lo, hi = med - k * 1.4826 * mad, med + k * 1.4826 * mad
    return s.clip(lo, hi)

def neutralize(df):
    z = winsorize(df["signal"])
    z = (z - z.mean()) / z.std()
    dummies = pd.get_dummies(df["industry"], drop_first=True).astype(
        float)
    X = pd.concat([dummies, df[["logmcap", "vol60"]]], axis=1)
    X = sm.add_constant(X)
    res = sm.OLS(z.values, X.values).fit()
    return z.values - res.fittedvalues

panel["factor"] = panel.groupby("date", group_keys=False).apply(
    neutralize)
ic = panel.groupby("date").apply(
    lambda g: spearmanr(g["factor"], g["fwd_ret"])[0])
print("mean rank IC = %.4f" % ic.mean(), "| IC IR = %.3f" % (ic.mean() /
    ic.std()))
```

Listing 7.2 分层回测与多重检验（Benjamini–Hochberg FDR）调整

```
import numpy as np
import pandas as pd
from scipy.stats import norm, spearmanr

rng = np.random.default_rng(11)

def layered_backtest(factor, fwd_ret, n_layers=5):
    df = pd.DataFrame({"factor": factor, "fwd_ret": fwd_ret})
    df["layer"] = pd.qcut(df["factor"].rank(method="first"), n_layers,
        labels=False)
    layer_ret = df.groupby("layer")["fwd_ret"].mean()
    ls = layer_ret.iloc[-1] - layer_ret.iloc[0]
    return layer_ret, ls

n_days, n_stocks = 800, 400
panel_factor = rng.normal(size=(n_days, n_stocks))
panel_ret = 0.03 * panel_factor + rng.normal(scale=0.03, size=(n_days,
    n_stocks))
layer_hist = np.array([layered_backtest(panel_factor[t], panel_ret[t])[1]
                       for t in range(n_days)])
ir = layer_hist.mean() / layer_hist.std() * np.sqrt(252)
print("long-short annualized IR = %.2f" % ir)

def bh_fdr(pvals, alpha=0.05):
```

```
    pvals = np.asarray(pvals)
    order = np.argsort(pvals)
    m = pvals.size
    thresh = alpha * (np.arange(1, m + 1)) / m
    passed = pvals[order] <= thresh
    k = np.max(np.flatnonzero(passed)) + 1 if passed.any() else 0
    rejected = np.zeros(m, dtype=bool)
    rejected[order[:k]] = True
    return rejected

# 200 trials with a genuinely zero signal: report how many look
    significant
pvals = []
for _ in range(200):
    noise = rng.normal(size=(n_days, n_stocks))
    ret = rng.normal(scale=0.03, size=(n_days, n_stocks))
    ics = [spearmanr(noise[t], ret[t])[0] for t in range(n_days)]
    tstat = np.mean(ics) / (np.std(ics, ddof=1) / np.sqrt(n_days))
    pvals.append(2 * (1 - norm.cdf(abs(tstat))))
print("raw p<0.05 count =", int(np.sum(np.array(pvals) < 0.05)),
      "| BH FDR survivors =", int(bh_fdr(pvals).sum()))
```

listings 7.1 and 7.2 给出两段可直接运行的实现。前者展示了 小节 7.2.1 的完整流水线，注意中性化必须按交易日分组进行，绝不能在全样本上做标准化，否则会用未来信息估计横截面均值与标准差。后者的最后一段刻意用纯噪声生成 200 个策略：在 5% 水平上通常有 8 至 12 个“显著”，而 Benjamini–Hochberg 调整后基本全部被剔除。这是式 (7.11) 最直观的演示。

核心要点 7.2　P Quant 的两条铁律

第一，任何信号在进入组合之前必须完成去极值、标准化与中性化，并且按日分组计算，否则回测结果不可解释。第二，任何绩效结论必须与试验次数、成本假设和样本外检验方式一起报告；缺少这三项的 Sharpe 比率不能作为决策依据。

本章小结

- 因子构建流水线为去极值、标准化、缺失值处理、行业与风格中性化四步，顺序不可调换；中性化用横截面回归 式 (7.1) 取残差，权重常取市值平方根。
- Barra 型风险模型把收益分解为 $Xf+u$，因子收益用加权最小二乘估计 式 (7.3)，因子协方差需用 Newey–West 与特征值调整稳健化。
- IC 与 Rank IC 衡量横截面预测能力，其信噪比必须用有效独立期数折算；持仓周期应与 IC 半衰期匹配。
- 主动管理基本定律 $IR \approx IC\sqrt{N}$，现实修正为 $IC\sqrt{N_{\text{eff}}}TC$，下注相关性会摧毁广度带来的全部优势。
- 机器学习选股必须配 Purged k-折与 embargo、样本权重与标签区间管理，否则

特征重要性与样本外绩效均不可信。

- 回测的三层多重检验校正分别是 Bonferroni、Benjamini–Hochberg FDR 与 DSR/PBO；不披露试验次数的回测报告没有统计意义。
- 微观结构层面，Kyle 模型给出 $\lambda = \frac{1}{2}\sqrt{\Sigma_0/\sigma_u^2}$，Almgren–Chriss 给出指数衰减的最优执行轨迹，二者共同决定策略的容量上限。

练习与思考

1. 设某月频因子在 2000 只股票上的月均 Rank IC 为 0.035，IC 序列标准差为 0.08，自相关时间 $\tau = 1.5$ 个月。样本共 96 个月。请计算 $\overline{IC}$ 的标准误与 t 值，并判断该因子在 5% 水平上是否显著。若不考虑自相关，t 值会被高估多少？
2. 推导 命题 7.1 时假定各下注收益独立。若下注分为 10 个行业组，组内相关系数 0.3、组间相关系数 0，每组 50 个下注，求 N_{eff} 与信息比率相对独立情形的衰减比例。
3. 在 Kyle 模型中，取 $\Sigma_0 = 9$、$\sigma_u = 30000$。求 λ、β 与知情者期望利润；若噪声交易量翻倍，λ 与期望利润各如何变化？请解释为什么知情者的期望利润会随噪声交易量上升。
4. 用 式 (7.18) 计算 $X_0 = 2 \times 10^6$ 股、$T = 1$ 日、$\kappa = 5$ /日条件下的最优持仓路径（取 $N = 5$ 段），并与 TWAP 比较前两段的卖出量差异。
5. 编写代码复现 listing 7.2 中 200 个纯噪声策略的检验，分别统计未校正、Bonferroni 与 Benjamini–Hochberg 三种方法下的“显著”策略数，并解释三者差异。
6. 某策略在 60 次参数试验中取得最优年化 Sharpe 1.5，样本 750 天，试验间 Sharpe 标准差 0.06。用 式 (7.13) 与 式 (7.12) 计算 DSR，并讨论该策略是否值得实盘配置。

延伸阅读

- Grinold, R., and Kahn, R., *Active Portfolio Management*, 2nd ed., McGraw-Hill, 2000.（第 6 章给出主动管理基本定律的完整推导与转移系数的实务讨论）
- Ang, A., *Asset Management: A Systematic Approach to Factor Investing*, Oxford University Press, 2014.（把因子投资、风险模型与组合构建放在统一框架下，适合建立全局图景）
- Kyle, A., “Continuous Auctions and Insider Trading”, *Econometrica*, 1985.（微观结构领域的奠基论文，模型虽短但均衡推导值得逐行复现）
- Almgren, R., and Chriss, N., “Optimal Execution of Portfolio Transactions”, *Journal of Risk*, 2000.（最优执行的经典参考，含离散与连续两种推导与成本分解）
- López de Prado, M., *Advances in Financial Machine Learning*, Wiley, 2018.（Purged k-折、DSR 与 PBO 的原始出处，回测方法论章节最实用）
- Bailey, D., and López de Prado, M., “The Deflated Sharpe Ratio”, *Journal of Portfolio Management*, 2014.（多重检验下绩效显著性校正的标准文献，附完整公式与数值示例）

第八章 金融概率与统计分析

金融数据与教科书里的独立同分布样本有一段距离：收益的尾部比正态厚得多，波动率会成簇出现，横截面上的个体差异与时间效应纠缠在一起，而研究者又往往在同一个数据集上反复试验。本章按「分布假定—估计—检验—回归—贝叶斯—尾部」的顺序铺设 P Quant 的统计基础设施，并在每一个环节标出金融数据的特殊之处。

8.1 概率论基础与分布族

8.1.1 随机变量、矩与特征函数

随机变量 X 的分布由累积分布函数 $F_X(x)=\mathbb{P}(X\le x)$ 完全刻画，若 F_X 绝对连续则概率密度为 $f_X(x)=\mathrm{d}F_X(x)/\mathrm{d}x$。分布的形态由矩与特征函数描述

$$\mu'_k=\mathbb{E}\left[X^k\right],\qquad \mu_k=\mathbb{E}\left[(X-\mathbb{E}[X])^k\right],\qquad \gamma_1=\frac{\mu_3}{\mu_2^{3/2}},\qquad \gamma_2=\frac{\mu_4}{\mu_2^2}-3 \tag{8.1}$$

其中 μ'_k 为 k 阶原点矩，μ_k 为 k 阶中心矩，γ_1 为偏度，γ_2 为超额峰度（正态分布下为 0）。$\gamma_2>0$ 意味着肥尾：极端事件比正态预测的更频繁。以标准正态为基准，$|Z|>3$ 的概率约为 0.27%；而自由度 $\nu=5$ 的 t 分布对应概率约为 1.9%，是正态的 7 倍。这正是风险管理不能简单套用正态假设的原因。

⚠ 风险警示　厚尾下样本矩的失效

当 $\nu\le 4$ 时 t 分布的四阶矩不存在，样本峰度的期望不收敛，用有限样本估计的峰度会随样本长度剧烈跳动，且系统性低估真实尾部厚度。当 $\nu\le 2$ 时连方差都不存在，样本标准差不再是有效的离散度度量。因此对高频收益，宁可报告分位数与分位数间距，也不要报告标准差。

矩母函数 $M_X(t)=\mathbb{E}[\mathrm{e}^{tX}]$ 并非总存在（厚尾分布常常没有），而特征函数 $\phi_X(t)=\mathbb{E}[\mathrm{e}^{\mathrm{i}tX}]$ 对任意分布都存在，且唯一决定分布。这一性质是 Fourier 变换类期权定价方法的基础：只要知道标的对数价格的特征函数，就能通过数值积分反演密度或直接计算期权价格。常用性质包括 $\phi_{aX+b}(t)=\mathrm{e}^{\mathrm{i}bt}\phi_X(at)$，以及独立随机变量和的特征函数等于各自特征函数之积。

8.1.2 金融收益的分布族

表 8.1 中最常用的两个是学生 t 分布与广义误差分布。t 分布的密度为

表 8.1　金融收益建模常用的分布族对比

分布	尾部行为	典型参数	适用与局限
正态	指数衰减	μ, σ	基准模型；对日频收益严重低估尾部
对数正态	指数衰减	μ, σ	适用于价格；收益仍非正态
学生 t	幂律	ν	日频收益首选；ν 常估在 3 至 6
偏 t	幂律且不对称	ν, λ	刻画下跌尾部更厚；参数估计较难
GED	幂律可变	ν	$\nu<2$ 厚尾、$\nu>2$ 薄尾
稳定分布	幂律	$\alpha,\beta,\gamma,\delta$	方差可能无穷；α 常估在 1.6 至 1.9
GEV	幂律	ξ, μ, σ	建模极值块最大值
GPD	幂律	ξ, β	超阈值超额损失，EVT 风险度量核心

$$f(x;\nu)=\frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)}\left(1+\frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}} \tag{8.2}$$

其中 $\nu>0$ 为自由度，$\Gamma(\cdot)$ 为 Gamma 函数。当 $\nu\to\infty$ 时 $f(x;\nu)$ 逐点收敛到标准正态密度；ν 越小尾部越厚。GED 的密度为

$$f(x;\nu)=\frac{\nu\,\exp\left(-\frac{1}{2}\left|x/\lambda\right|^{\nu}\right)}{\lambda\,2^{1+1/\nu}\,\Gamma(1/\nu)},\qquad \lambda=\left(\frac{2^{-2/\nu}\,\Gamma(1/\nu)}{\Gamma(3/\nu)}\right)^{1/2} \tag{8.3}$$

其中 ν 控制尾部形状（$\nu=2$ 退化为正态），λ 为尺度参数，其取值由方差归一化条件决定。GED 在 GARCH 族的实证中比正态显著改善对数似然，且在 $\nu>2$ 时可以刻画比正态更薄的尾部，因此适用范围比 t 分布更宽。

图 8.1 用对数密度作图，因为直接画密度时尾部差异在视觉上会被完全压缩。在 $|x|=6$ 处，正态的对数密度约为 -18.4，而 $t(5)$ 的对应值约为 -11.2，二者相差约 7.2，即概率相差约 $\mathrm{e}^{7.2}\approx 1300$ 倍。把这一差异代入日频 VaR：若日波动率为 2%，正态假设下 99.9% 的 VaR 约为 $2\%\times 3.09=6.2\%$，而 $t(5)$ 假设下同一分位数对应的倍数约为 5.9，VaR 约为 11.8%，几乎翻倍。低估的这 5.6 个百分点在压力期就是真实的资本缺口。

8.2 估计方法

8.2.1　极大似然估计与渐近正态性

设样本 $x_1,\dots,x_n$ 独立同分布，密度为 $f(x;\theta)$，$\theta\in\Theta\subset\mathbb{R}^p$。对数似然为 $\ell(\theta)=\sum_{i=1}^{n}\ln f(x_i;\theta)$，极大似然估计为

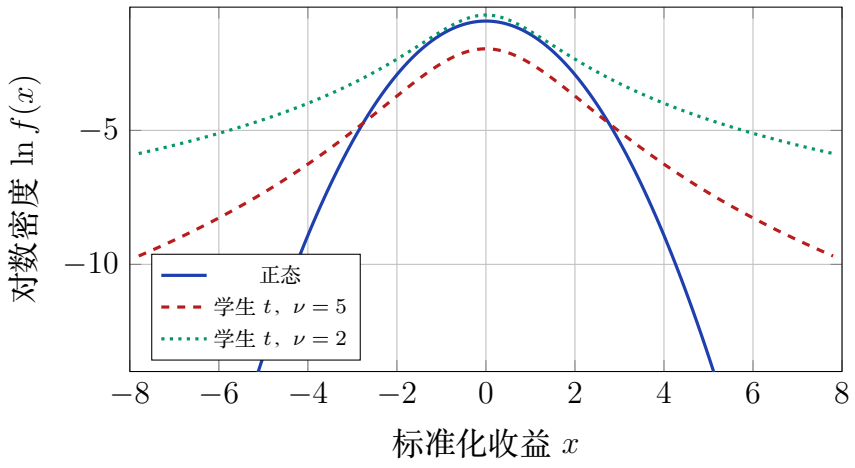


图 8.1　正态分布与 t 分布的尾部对比：在 $|x|=6$ 处，$t(5)$ 的对数密度比正态高约 7 个自然对数单位，对应概率相差千倍

$$\hat{\theta}_{\mathrm{MLE}} = \arg\max_{\theta\in\Theta} \ell(\theta) \tag{8.4}$$

在正则条件下，$\hat{\theta}_{\mathrm{MLE}}$ 具有一致性与渐近正态性

$$\sqrt{n}\left(\hat{\theta}_{\mathrm{MLE}} - \theta_0\right) \xrightarrow{\mathrm{d}} \mathcal{N}\!\left(0,\ \mathcal{I}(\theta_0)^{-1}\right), \qquad \mathcal{I}(\theta) = -\mathbb{E}\!\left[\frac{\partial^2 \ln f(X;\theta)}{\partial \theta^2}\right] \tag{8.5}$$

其中 $\mathcal{I}(\theta)$ 为 Fisher 信息矩阵，θ_0 为真值。由 Cramér–Rao 下界，任何无偏估计量的方差都不小于 $\mathcal{I}(\theta_0)^{-1}/n$，因此 MLE 渐近达到最小方差。实务中用观测信息矩阵 $\hat{\mathcal{I}} = -\frac{1}{n}\sum_{i} \frac{\partial^2 \ln f(x_i;\hat\theta)}{\partial\theta^2}$ 或外积形式 $\frac{1}{n}\sum_i \left(\frac{\partial \ln f(x_i;\hat\theta)}{\partial\theta}\right)\left(\frac{\partial \ln f(x_i;\hat\theta)}{\partial\theta}\right)^{\top}$ 代入即可得到标准误。

例 8.1　学生 t 分布自由度的矩估计与 MLE

对某指数 3000 个日对数收益做标准化后，样本超额峰度为 4.8。由 $t(\nu)$ 的超额峰度公式 $\gamma_2 = 6/(\nu-4)$（$\nu>4$），矩估计给出 $\nu \approx 4 + 6/4.8 = 5.25$。经验上 t 分布的 MLE 在 ν 较小时会给出比矩估计略大的值，本例中若 MLE 输出 $\hat\nu = 5.6$，则对应的理论超额峰度为 $6/1.6 = 3.75$，低于样本峰度 4.8。这一差异并不矛盾：样本峰度本身方差极大，MLE 是在整个似然面上做权衡，而不是硬性匹配四阶矩。listing 8.1 给出可直接运行的实现。

8.2.2　广义矩方法与最优权重

当密度难以写出但矩条件明确时，GMM 更合适。设矩条件为 $\mathbb{E}[g(X_i,\theta_0)] = 0$，$g \in \mathbb{R}^q$ 且 $q \ge p$，样本矩为 $\bar g_n(\theta) = \frac{1}{n}\sum_{i=1}^{n} g(X_i,\theta)$，则

$$\hat{\theta}_{\mathrm{GMM}} = \arg\min_{\theta\in\Theta}\ \bar g_n(\theta)^{\top} W_n\, \bar g_n(\theta) \tag{8.6}$$

其中 W_n 为 $q\times q$ 的权重矩阵。若取 $W_n = S^{-1}$，$S = \mathbb{E}[g(X_i,\theta_0)g(X_i,\theta_0)^{\top}]$ 为矩条件的协方差矩阵，则 $\hat\theta_{\mathrm{GMM}}$ 是渐近有效的，其渐近方差为 $(G^{\top}S^{-1}G)^{-1}$，$G = \mathbb{E}[\frac{\partial g(X_i,\theta_0)}{\partial\theta}]$。实

践中的两步法：第一步用 $W_n = I$ 得到一致估计 $\hat{\theta}_1$，用它估计 $\hat{S}$，第二步用 $W_n = \hat{S}^{-1}$ 重新最小化。

矩条件个数超过参数个数（$q > p$）时模型存在过度识别，可用 J 检验考察矩条件是否成立

$$J = n\,\bar{g}_n(\hat{\theta})^\top \hat{S}^{-1} \bar{g}_n(\hat{\theta}) \xrightarrow{\mathrm{d}} \chi^2_{q-p} \tag{8.7}$$

其中 χ^2_{q-p} 为自由度 $q-p$ 的卡方分布。J 统计量过大意味着数据拒绝了模型隐含的矩关系，例如在资产定价中意味着因子无法解释横截面收益。

8.3 假设检验与多重检验

8.3.1 三种渐近等价检验

设原假设 $H_0 : \theta = \theta_0$ 把参数约束到 $p-r$ 维子空间，无约束 MLE 为 $\hat{\theta}$，约束 MLE 为 $\tilde{\theta}$。三种经典检验为

$$LR = 2\left(\ell(\hat{\theta}) - \ell(\tilde{\theta})\right) \xrightarrow{\mathrm{d}} \chi^2_r \tag{8.8}$$

$$W = n\left(\hat{\theta} - \theta_0\right)^\top \hat{\mathcal{I}} \left(\hat{\theta} - \theta_0\right) \xrightarrow{\mathrm{d}} \chi^2_r \tag{8.9}$$

$$S = n\,\bar{s}(\theta_0)^\top \hat{\mathcal{I}}^{-1} \bar{s}(\theta_0) \xrightarrow{\mathrm{d}} \chi^2_r, \qquad \bar{s}(\theta) = \frac{1}{n}\sum_{i=1}^{n} \frac{\partial \ln f(x_i;\theta)}{\partial \theta} \tag{8.10}$$

其中 $\bar{s}(\theta)$ 为得分函数（score），r 为约束个数，$\hat{\mathcal{I}}$ 为观测信息矩阵。三者在 H_0 下渐近同分布，有限样本中的表现不同：Wald 检验对参数的重新参数化不敏感（不满足不变性），Score 检验只需在 H_0 下估计，适合约束估计困难的场景；LR 检验通常最稳健，但需要同时求解两个优化问题。

表 8.2　三种经典检验在金融应用中的选择

检验	需要的估计	优点	典型金融用途
LR	无约束与约束 MLE	最优不变性	检验 GARCH 参数约束、模型阶数
Wald	无约束 MLE	计算最简便	检验因子载荷是否为零、Granger 因果
Score	仅约束下估计	只需估一次	检验附加因子是否提供增量信息

8.3.2 多重检验与 FDR

因子研究几乎总是在同一数据集上试验大量假设。若对 m 个真实无效的信号逐一用 5% 水平检验，期望假发现数为 $0.05m$；当 $m = 200$ 时约 10 个。控制假发现比例（FDR）

的 Benjamini–Hochberg 程序把 p 值排序后取

$$k = \max\left\{ i : \; p_{(i)} \le \frac{i}{m}\,\alpha \right\} \tag{8.11}$$

并拒绝前 k 个假设，其中 α 为目标 FDR。与原假设全为真时的 Bonferroni 校正 $p_{(i)} \le \alpha/m$ 相比，BH 在备择假设较多时严格更宽松。两个程序的差别在 表 8.3 中用一个 $m = 200$ 的例子说明。

表 8.3　$m = 200$ 次真实无效检验下的假发现控制对比（$\alpha = 5\%$，均为期望值）

控制程序	最小 p 值门槛	第 10 小 p 值门槛	期望假发现数
不校正	0.0500	0.0500	10.0
Bonferroni（FWER）	0.00025	0.00025	0.05
Benjamini–Hochberg（FDR）	0.00025	0.00250	≤ 0.10

表 8.3 显示 BH 的判据随序位放宽，因此在因子筛选中能保留更多真信号。需要强调的是：FDR 控制的是*被拒绝假设中假发现的比例期望*，它不保证每一个被选中的因子都真实有效，因此在实盘配置前仍需样本外验证与成本核算。

实务应用　极值理论在银行内部模型中的实际用法

按巴塞尔市场风险框架，银行内部模型需同时报告 97.5% 的 ES 与压力情景下的损失。实务流程是：先用 GARCH 类模型得到条件波动率的过滤序列（把波动率聚集剥离），再对标准化残差做 POT/GPD 拟合，最后把 GPD 分位数乘回当期波动率，得到随市场状态调整的 EVT-VaR 与 EVT-ES。这样做的好处是 99.9% 这类极端分位不再依赖单一的历史窗口，同时保留了波动的时变特征。

风险警示　多重检验导致的假发现

若研究者不记录试验次数，FDR 与 DSR 类校正都无从实施。更隐蔽的问题是“隐式多重检验”：试用多个数据供应商、多个预处理方式、多个回测区间，每次只报告最好的一次。控制这类偏差的唯一办法是在项目开始时就登记全部试验配置，并在报告中披露总试验次数。

8.4 Bootstrap 与重抽样

Bootstrap 用重抽样模拟统计量的抽样分布，无需假定分布的解析形式。独立同分布情形下有两种基本做法：非参数 bootstrap 从原始样本中有放回抽取 n 个观测；参数 bootstrap 从拟合分布 $\hat{F}$ 中抽样。对统计量 $\hat{\theta}$，其标准误由 B 次重抽样估计

$$\widehat{\mathrm{SE}}_{\mathrm{boot}}(\hat{\theta}) = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}\left(\hat{\theta}^{(b)} - \bar{\theta}^{*}\right)^{2}}, \qquad \bar{\theta}^{*} = \frac{1}{B}\sum_{b=1}^{B}\hat{\theta}^{(b)} \tag{8.12}$$

其中 $\hat{\theta}^{(b)}$ 为第 b 次重抽样得到的估计值，B 常取 1000 至 10000。百分位置信区间直接取 $\{\hat{\theta}^{(b)}\}$ 的 $\alpha/2$ 与 $1-\alpha/2$ 分位数。

金融时间序列不满足独立性，直接对单点重抽样会破坏自相关结构，因此需要块方法：移动块 bootstrap 把序列切成等长块 L 后对有放回的块序列拼接；平稳 bootstrap 的块长服从几何分布（期望 $1/q$），在保持平稳性的同时避免块边界的生硬拼接。块长 L 的选取遵循 $L \propto n^{1/3}$ 的经验法则，更严谨的做法是用 Politis–White 自动选择程序。对波动率、自相关与 Sharpe 比率这类依赖序列结构的统计量，块 bootstrap 与独立 bootstrap 的置信区间宽度可以相差一倍以上。

补充说明　bootstrap 的三个适用边界

第一，样本量太小时 bootstrap 会复制原始样本的偶然特征，$n < 30$ 时结论不可靠；第二，统计量不连续或依赖极端分位数（如最大值、极值指数）时，普通 bootstrap 会系统性低估不确定性，需要用 m 折 bootstrap 或子抽样；第三，序列存在结构突变（regime shift）时，重抽样会把两个不同机制的数据混合，得到无意义的区间。

8.5 回归分析

8.5.1　OLS 的代数与几何

对模型 $y = X\beta + \varepsilon$，$\mathbb{E}[\varepsilon \mid X] = 0$，最小化残差平方和 $\|y - X\beta\|^2$ 得一阶条件 $X^\top (y - X\hat{\beta}) = 0$，即正规方程

$$X^\top X\hat{\beta} = X^\top y, \qquad \hat{\beta} = (X^\top X)^{-1} X^\top y, \qquad \hat{y} = Py, \quad P = X(X^\top X)^{-1}X^\top \tag{8.13}$$

其中 P 为投影矩阵，它把 y 正交投影到 X 的列空间上，残差 $e = (I - P)y$ 与 X 的每一列正交。几何上 OLS 就是找列空间中离 y 最近的点，而 $R^2 = 1 - \|e\|^2 / \|y - \bar{y}\mathbf{1}\|^2$ 度量这个投影解释了多少变异。若 X 列满秩且 $\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I$，则 $\mathrm{Var}(\hat{\beta} \mid X) = \sigma^2 (X^\top X)^{-1}$，$\hat{\sigma}^2 = \|e\|^2 / (n - k)$。

定理 8.1 (Gauss–Markov)　在 $\mathbb{E}[\varepsilon \mid X] = 0$ 与 $\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I$ 下，OLS 估计量 $\hat{\beta}$ 是 β 的最佳线性无偏估计（BLUE）：任何其他线性无偏估计量 $\tilde{\beta} = Cy$ 都满足 $\mathrm{Var}(\tilde{\beta} \mid X) - \mathrm{Var}(\hat{\beta} \mid X) \succeq 0$。

证明思路. 无偏性要求 $CX = I$。把 C 写成 $C = (X^\top X)^{-1}X^\top + D$，由 $CX = I$ 得 $DX = 0$。于是 $\mathrm{Var}(\tilde{\beta} \mid X) = \sigma^2 CC^\top = \sigma^2 \left[(X^\top X)^{-1} + DD^\top\right] = \mathrm{Var}(\hat{\beta} \mid X) + \sigma^2 DD^\top$，其中交叉项因 $DX = 0$ 而消失，而 $DD^\top$ 半正定，故结论成立。 ■

注意证明完全依赖 $\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I$：一旦存在异方差或自相关，右端多出的 $DD^\top$ 可以被选得为负，OLS 就不再是最优的，这正是 表 8.4 中稳健标准误与 GLS 存在的理由。

8.5.2 稳健标准误与 HAC

金融回归几乎必然违反同方差与无自相关假设。White 异方差一致性估计量为

$$\widehat{\mathrm{Var}}_{\mathrm{White}}(\hat{\beta}) = (X^\top X)^{-1} \left(\sum_{i=1}^{n} e_i^2 \, x_i x_i^\top \right) (X^\top X)^{-1} \tag{8.14}$$

其中 x_i 为第 i 个观测的解释变量行向量，e_i 为残差。存在自相关时改用 Newey–West 的 HAC 形式

$$\hat{S}_{\mathrm{HAC}} = \hat{\Gamma}_0 + \sum_{l=1}^{L} \left(1 - \frac{l}{L+1}\right) \left(\hat{\Gamma}_l + \hat{\Gamma}_l^\top\right), \qquad \hat{\Gamma}_l = \frac{1}{n} \sum_{t=l+1}^{n} e_t x_t \, e_{t-l} x_{t-l}^\top \tag{8.15}$$

其中 L 为带宽，常按 $L \approx 4(n/100)^{2/9}$ 的经验公式选取，$\hat{S}_{\mathrm{HAC}}$ 再代入三明治公式 $(X^\top X)^{-1} \hat{S}_{\mathrm{HAC}} (X^\top X)^{-1}$。系数标准误在 HAC 修正下通常会变大，因为正自相关意味着有效样本量小于名义样本量。

表 8.4　回归标准误的选择指南

设定	估计量	使用条件与代价
经典	$\hat{\sigma}^2 (X^\top X)^{-1}$	同方差且无自相关；金融数据中很少成立
White	三明治形式	异方差但无自相关；样本小时偏乐观
Newey–West	HAC 三明治	兼有异方差与自相关；带宽选择影响结果
聚类	按个体或时间聚类	组内任意相关；组数太少时失效

例 8.2　聚类标准误对显著性的影响

某面板回归估计市值因子对下期收益的系数为 0.0042，按个体聚类的标准误为 0.0009（$t = 4.7$），按时间聚类（月度，共 120 个时间点）的标准误为 0.0021（$t = 2.0$）。两者相差一倍以上，原因是残差在时间维度上高度相关：同一月的所有股票共享市场冲击，个体聚类无法捕捉这一共同成分。若因子只在少数几个月贡献收益，正确的标准误应接近后者，结论也会从“强显著”退化为“边际显著”。报告回归结果时，必须说明标准误的聚类维度，并优先报告更保守的版本。

8.5.3 面板数据与固定效应

面板数据同时具有个体维度 i 与时间维度 t。若遗漏的个体特征 α_i 与解释变量相关，混合 OLS 会产生遗漏变量偏误。固定效应模型通过组内变换消除 α_i

$$y_{it} - \bar{y}_i = \beta^\top (x_{it} - \bar{x}_i) + (\varepsilon_{it} - \bar{\varepsilon}_i), \qquad \bar{y}_i = \frac{1}{T} \sum_{t=1}^{T} y_{it} \tag{8.16}$$

其中 $\bar{y}_i$、$\bar{x}_i$ 为个体时间均值。这一变换等价于为每个个体加一个哑变量，代价是损失 n 个自由度并抹掉所有不随时间变化的变量（如行业归属）的系数。随机效应模型则假定 α_i 与 x_{it} 不相关，用 GLS 提高效率；Hausman 检验通过比较两套系数的差异来判断该假定是否成立，拒绝则使用固定效应。金融应用的常见折中是双向固定效应：同时加入个体效应与时间效应，时间效应自动吸收市场层面的共同冲击。

8.5.4 Fama–MacBeth 回归

资产定价实证的标准做法是 Fama–MacBeth 两步法，它把横截面溢价与横截面相关性同时纳入推断。

1. 对每只资产 i 做时间序列回归 $r_{it} = \alpha_i + \beta_i^{\top} f_t + \varepsilon_{it}$，得到载荷估计 $\hat{\beta}_i$；
2. 对每期 t 做横截面回归 $r_{it} = \lambda_{0t} + \lambda_t^{\top} \hat{\beta}_i + \eta_{it}$，得到因子溢价的逐期估计 $\hat{\lambda}_t$；
3. 对 $\{\hat{\lambda}_t\}$ 取时间平均 $\bar{\lambda} = \frac{1}{T}\sum_t \hat{\lambda}_t$，标准误为 $\mathrm{sd}(\hat{\lambda}_t)/\sqrt{T}$（可再用 Newey–West 修正自相关）。

该方法的关键优点是它自动处理横截面残差的相关性：因为每期只做一次横截面回归，残差在时间上取平均后，横截面相关被“折叠”进 $\hat{\lambda}_t$ 的方差中，不需要估计巨大的横截面协方差矩阵。其代价是忽略了载荷的估计误差（errors-in-variables），在资产数较少或 β 估计不精确时会低估真实标准误。

例 8.3 Fama–MacBeth 数值示例

对 500 只股票、240 个月的样本，按上述步骤得到某因子的逐期溢价序列，月均溢价 $\bar{\lambda} = 0.42\%$，逐期溢价的标准差 $\mathrm{sd}(\hat{\lambda}_t) = 2.6\%$。则标准误为 $2.6\%/\sqrt{240} = 0.168\%$，$t$ 值为 $0.42/0.168 = 2.5$，在 5% 水平上显著。若逐期溢价存在一阶自相关 $\rho = 0.25$，有效样本量降为 $240 \times \frac{1-0.25}{1+0.25} \approx 144$，修正后的标准误为 $2.6\%/\sqrt{144} = 0.217\%$，$t$ 值降至 1.9，显著性恰好消失。这个例子再次说明：时间序列相关是金融实证中最重要的标准误来源之一。

8.6 贝叶斯方法

8.6.1 共轭先验与后验推导

贝叶斯推断把参数视为随机变量，通过贝叶斯定理更新信念

$$\pi(\theta \mid D) = \frac{\mathcal{L}(D \mid \theta)\,\pi(\theta)}{\int \mathcal{L}(D \mid \theta')\,\pi(\theta')\,\mathrm{d}\theta'} \propto \mathcal{L}(D \mid \theta)\,\pi(\theta) \tag{8.17}$$

其中 $\pi(\theta)$ 为先验，$\mathcal{L}(D \mid \theta)$ 为似然，$\pi(\theta \mid D)$ 为后验，分母为边缘似然（证据），与 θ 无关，因此在推断中可以只保留比例关系。

最常用的共轭结构是正态—正态。设 $x_1, \dots, x_n \mid \mu \sim \mathcal{N}(\mu, \sigma^2)$，$\sigma^2$ 已知，先验 $\mu \sim \mathcal{N}(\mu_0, \tau_0^2)$，则后验仍为正态

$$\mu \mid D \sim \mathcal{N}\big(\mu_n,\ \tau_n^2\big)\,, \qquad \mu_n = \frac{\frac{1}{\tau_0^2}\mu_0 + \frac{n}{\sigma^2}\bar{x}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \qquad \frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2} \tag{8.18}$$

其中 $\bar{x}$ 为样本均值。后验均值是先验均值与样本均值的*精度加权平均*，精度（方差的倒数）直接相加。这一形式正是贝叶斯收缩的来源：当 n 小时后验靠近先验，当 n 大时后验靠近样本均值，收缩强度由信噪比 $n\tau_0^2/\sigma^2$ 自动决定。

例 8.4　基金收益均值的贝叶斯收缩

某基金过去 36 个月的月均超额收益为 $\bar{x} = 0.55\%$，月度收益标准差为 $\sigma = 4\%$，故样本均值的标准误为 $4\%/\sqrt{36} = 0.67\%$。若行业先验设定为“真正具备选股能力的基金月均超额收益为 $\mu_0 = 0.10\%$、跨基金标准差 $\tau_0 = 0.30\%$”，代入 式 (8.18)：样本精度 $n/\sigma^2 = 36/16 = 2.25$，先验精度 $1/\tau_0^2 = 11.1$，后验均值 $\mu_n = (11.1 \times 0.10 + 2.25 \times 0.55)/(11.1 + 2.25) = (1.11 + 1.24)/13.35 = 0.176\%$。后验均值只有样本均值的 32%。这一收缩与“三年业绩不足以证明能力”的直觉一致，也与 式 (8.18) 的精度加权逻辑一致。

8.6.2　可信区间与置信区间

频率派的 95% 置信区间含义是：重复抽样中有 95% 的区间包含真值，真值本身是固定的。贝叶斯 95% 可信区间的含义是：给定数据与先验，θ 落在该区间的后验概率为 95%。在平坦先验下两者数值常接近，但在小样本、有信息先验或存在边界约束时差异显著。风险管理中需要回答“亏损超过阈值的主观概率是多少”，这类问题只有可信区间能直接作答，因此贝叶斯方法在压力测试与情景分析中更自然。

8.6.3　Black–Litterman 模型

Black–Litterman 模型把市场均衡隐含收益与投资者主观观点融合，是贝叶斯收缩在组合构建中最成功的应用。其推导分三步。

第一步：由市场均衡反推隐含收益。若市场组合就是均值—方差最优组合，则其权重 w_{mkt} 必满足一阶条件，于是

$$\Pi = \delta\, \boldsymbol{\Sigma}\, w_{\text{mkt}} \tag{8.19}$$

其中 Π 为隐含均衡收益向量，$\boldsymbol{\Sigma}$ 为收益协方差矩阵，w_{mkt} 为市值权重，δ 为风险厌恶系数（常用市场 Sharpe 比率反解）。这一先验的好处是它与市场组合自洽，因此不会在无观点时给出极端权重。

第二步：把观点写成线性约束。观点表示为

$$P\,\mu = Q + \epsilon, \qquad \epsilon \sim \mathcal{N}(0, \Omega) \tag{8.20}$$

其中 P 为 $k \times n$ 的观点选择矩阵，Q 为观点收益向量，Ω 为观点不确定性的对角矩阵。例如“科技板块将跑赢大盘 2%”对应 P 的一行在科技板块权重为 1、其余为 0，$Q = 0.02$；“资

产 A 比资产 B 多涨 1%”对应一行为 1 与 -1。

第三步：正态—正态共轭给出后验。把 μ 的先验取为 $\mathcal{N}(\Pi, \tau\Sigma)$，观点似然为 $\mathcal{N}(P\mu, \Omega)$，直接套用 式 (8.18) 的矩阵形式即得

$$\mathbb{E}[\mu \mid \text{views}] = \Pi + \tau\Sigma P^{\top}\left(P\,\tau\Sigma\,P^{\top} + \Omega\right)^{-1}(Q - P\Pi) \tag{8.21}$$

$$\mathrm{Cov}(\mu \mid \text{views}) = \Sigma + \tau\Sigma - \tau\Sigma P^{\top}\left(P\,\tau\Sigma\,P^{\top} + \Omega\right)^{-1} P\,\tau\Sigma \tag{8.22}$$

其中 τ 为刻画先验不确定性的标量（常取 0.02 至 0.10）。式 (8.21) 的结构非常直观：后验均值等于先验加上“观点与先验的偏离”乘以一个增益矩阵；当观点不确定性 $\Omega \to 0$（极度自信）时，后验均值趋向满足 $P\mu = Q$ 的最小调整解；当 $\Omega \to \infty$（完全不信）时后验回到 Π。

直觉理解　Black–Litterman 为什么比直接给预期收益稳健

直接给主观预期收益，等价于在均值—方差优化器中输入一组未被协方差结构约束的数字，优化器会把这些数字放大成极端权重。BL 的做法是先给市场均衡一个基准，再把观点作为对基准的*偏离*输入，偏离的幅度由 Ω 与 τ 共同封顶。因此 BL 组合的权重对观点强度不敏感，这正是它在实务中被广泛采用的原因。

8.6.4　马尔可夫链蒙特卡洛

当后验没有解析形式时，MCMC 通过构造以后验为平稳分布的马尔可夫链来抽样。Metropolis–Hastings 算法给定当前状态 θ 与提议分布 $q(\theta' \mid \theta)$，以概率

$$a(\theta, \theta') = \min\left\{1,\ \frac{\pi(\theta' \mid D)\, q(\theta \mid \theta')}{\pi(\theta \mid D)\, q(\theta' \mid \theta)}\right\} \tag{8.23}$$

接受提议 θ'，否则保持在 θ。其中 $\pi(\theta \mid D)$ 为目标后验，比例形式使归一化常数自动消去，这是 MH 能够在高维下工作的关键。Gibbs 抽样是 MH 的特例：轮流从各分量的完全条件分布 $\pi(\theta_j \mid \theta_{-j}, D)$ 中抽样，接受概率恒为 1，在条件分布可解析抽样时效率极高。

Hamiltonian Monte Carlo（HMC）引入辅助动量变量，利用后验对数的梯度沿哈密顿动力学模拟轨迹，再由 MH 步骤校正数值误差。相比随机游走型 MH，HMC 在高维参数空间中能以更少的步数获得低自相关的样本。NUTS（No-U-Turn Sampler）自动选择轨迹长度，是 Stan 与 PyMC 的默认采样器。判断 MCMC 是否收敛的标准做法是运行多条链并计算 $\hat{R}$ 统计量（要求 $\hat{R} < 1.01$）与有效样本量（ESS）。

8.7 惩罚回归

高维特征下普通最小二乘会过拟合。惩罚回归在损失函数中加入系数惩罚项

$$\hat{\beta}^{\text{Ridge}} = \arg\min_{\beta} \ \|y - X\beta\|^2 + \lambda \|\beta\|_2^2 \tag{8.24}$$

$$\hat{\beta}^{\text{Lasso}} = \arg\min_{\beta} \ \|y - X\beta\|^2 + \lambda \|\beta\|_1 \tag{8.25}$$

$$\hat{\beta}^{\text{ENet}} = \arg\min_{\beta} \ \|y - X\beta\|^2 + \lambda \left(\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right) \tag{8.26}$$

其中 $\lambda \geq 0$ 控制惩罚强度，$\alpha \in [0,1]$ 在 Lasso 与 Ridge 之间插值。Ridge 的解为 $\hat{\beta}^{\text{Ridge}} = (X^\top X + \lambda I)^{-1} X^\top y$，它把系数向零收缩但不置零，因此不做变量选择；Lasso 的 L_1 惩罚在零点不可微，使得解在 λ 足够大时恰好稀疏。几何解释是：L_1 球的顶点落在坐标轴上，等高线与球的切点大概率在顶点，而 L_2 球是光滑的，切点不会精确落在坐标轴上。

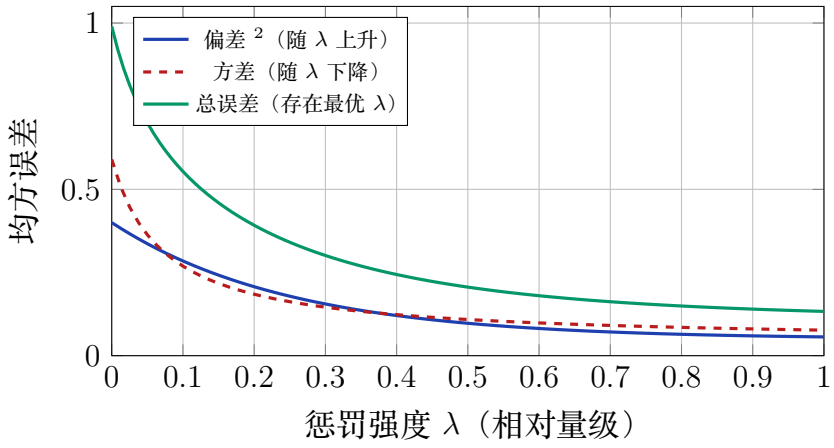


图 8.2　惩罚回归的偏差—方差权衡：总误差在中间某个 λ^* 处最小，两端分别对应过拟合与欠拟合

图 8.2 展示权衡的全貌。$\lambda \to 0$ 时方差大、偏差小；$\lambda \to \infty$ 时系数全被压向零，偏差主导。实践中的 λ 通过时间序列交叉验证选取，并且必须使用与机器学习选股相同的 Purged k-折结构，否则验证集误差会被信息泄漏压低，选出的 λ 偏小、模型偏复杂。

⚠ 风险警示　惩罚回归在因子研究中的两个陷阱

第一，惩罚项不区分因果与相关：若把未来收益相关的特征（如未来披露的财务数据）放入 X，Lasso 会稳定地把它选出来，稀疏性反而强化了前视偏差。第二，λ 与 α 的调参本身构成多重检验，在 表 8.3 的意义下会把样本内的最优惩罚参数“挑选”得更乐观，因此最终绩效必须在独立的样本外区间上重新评估。

8.8 极值理论与尾部风险

8.8.1　GEV 与 GPD

极值理论（EVT）专门研究样本极端值的分布极限。Fisher–Tippett 定理指出，若适当标准化后的块最大值收敛，则极限必为广义极值分布

$$G(z)=\exp\left\{-\left(1+\xi\frac{z-\mu}{\sigma}\right)^{-1/\xi}\right\},\qquad 1+\xi\frac{z-\mu}{\sigma}>0 \tag{8.27}$$

其中 μ 为位置参数，$\sigma>0$ 为尺度参数，ξ 为形状参数。$\xi>0$ 对应 Fréchet 型（幂律尾，金融收益的典型情形），$\xi=0$ 对应 Gumbel 型（指数尾），$\xi<0$ 对应 Weibull 型（有界尾）。

比块最大值更节省数据的是超阈值法（POT）。Pickands–Balkema–de Haan 定理指出，对足够大的阈值 u，超额损失 $Y=X-u$ 的条件分布近似为广义 Pareto 分布

$$\bar{F}_u(y)=\mathbb{P}(X-u>y\mid X>u)=\left(1+\frac{\xi y}{\beta}\right)^{-1/\xi},\qquad y>0,\ \beta>0 \tag{8.28}$$

其中 β 为尺度参数，ξ 与 式 (8.27) 中的形状参数含义一致。由 式 (8.28) 可反解任意高水平的 VaR 与 ES。设 n 为样本总量，N_u 为超过阈值的观测数，则

$$\widehat{\mathrm{VaR}}_q=u+\frac{\hat\beta}{\hat\xi}\left[\left(\frac{n}{N_u}(1-q)\right)^{-\hat\xi}-1\right] \tag{8.29}$$

$$\widehat{\mathrm{ES}}_q=\frac{\widehat{\mathrm{VaR}}_q}{1-\hat\xi}+\frac{\hat\beta-\hat\xi u}{1-\hat\xi},\qquad \hat\xi<1 \tag{8.30}$$

其中 q 为置信水平（如 0.999）。式 (8.30) 要求 $\hat\xi<1$，否则 ES 发散——这提醒我们，若估计出的形状参数接近或超过 1，数据的尾部厚到使一阶矩不存在，任何基于均值的风险度量都失去意义。

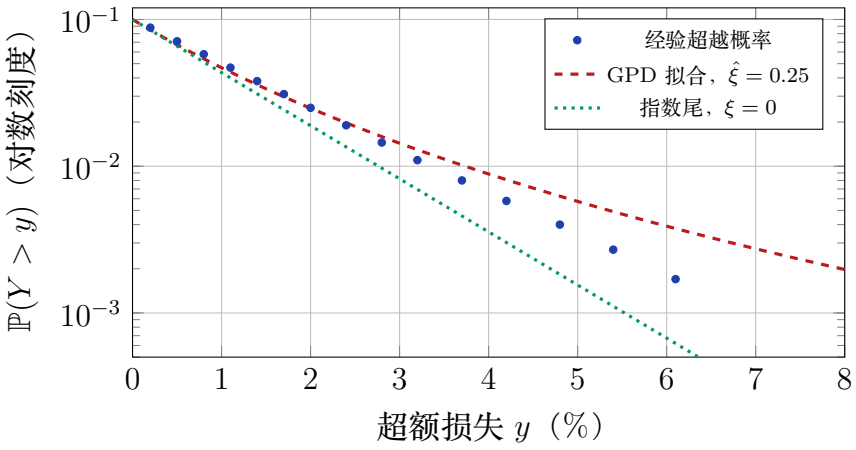


图 8.3　POT 方法的 GPD 尾拟合：对数刻度下幂律尾（直线）与指数尾（弯曲）的差异在 $y>3\%$ 后清晰可见

图 8.3 的关键读法是对数刻度下的形状：GPD 的超越概率 $\bar{F}_u(y)\propto y^{-1/\xi}$，取对数后是斜率为 $-1/\xi$ 的直线。若经验点在这张图上明显向上偏离指数尾的曲线，就说明尾部是幂律而非指数，用正态或指数模型度量极高分位的风险会系统性低估。

8.8.2 Hill 估计与阈值选择

在 $\xi > 0$ 的假设下，Hill 估计量给出形状参数的非参数估计

$$\hat{\xi}^{\text{Hill}} = \frac{1}{k}\sum_{j=1}^{k} \ln X_{(n-j+1)} - \ln X_{(n-k)}, \qquad k = N_u \tag{8.31}$$

其中 $X_{(1)} \le \cdots \le X_{(n)}$ 为顺序统计量，k 为使用的最大观测个数。Hill 估计量对 k 敏感：k 太小时方差大，k 太大时混入非尾部分布造成偏差，实践中通过 Hill 图寻找 $\hat{\xi}$ 对 k 相对平稳的平台区间。阈值 u 的选择是 POT 方法的核心难点，常用诊断手段包括平均超额函数图（均值余函数在阈值以上应呈线性）与参数稳定性图（$\hat{\xi}$ 与 $\hat{\beta}$ 随 u 变化平稳）。

例 8.5 POT 拟合与 EVT-VaR/ES 计算

某股票指数 2500 个交易日（约十年）的日对数收益，取 5% 分位对应的损失为阈值 $u = 2.0\%$，超过阈值的观测 $N_u = 125$。用 GPD 拟合超额损失得 $\hat{\xi} = 0.25$、$\hat{\beta} = 1.2\%$。计算 $q = 99.9\%$ 水平的 VaR：$(n/N_u)(1-q) = (2500/125)\times 0.001 = 0.02$，$0.02^{-0.25} = \mathrm{e}^{0.25\times 3.912} = \mathrm{e}^{0.978} = 2.66$，故 $\widehat{\mathrm{VaR}}_{0.999} = 2.0\% + \frac{1.2\%}{0.25}(2.66-1) = 2.0\% + 4.8\% \times 1.66 = 9.97\%$。再算 ES：$\widehat{\mathrm{ES}}_{0.999} = \frac{9.97\%}{0.75} + \frac{1.2\% - 0.25\times 2.0\%}{0.75} = 13.29\% + \frac{0.70\%}{0.75} = 13.29\% + 0.93\% = 14.22\%$。作为对照，若假定正态且日波动率 1.2%，99.9% 的 VaR 约为 $1.2\% \times 3.09 = 3.7\%$，ES 约为 $1.2\% \times 4.06 = 4.9\%$。EVT 给出的 ES 是正态假设的近三倍。在组合规模 100 亿元的情形下，两者对应的尾部损失相差约 9.3 亿元——这解释了为什么监管资本计量与内部压力测试都要求使用厚尾模型。

8.9 数据清洗与平稳性

8.9.1 去极值与缺失值

金融面板的极端值既可能是错误数据，也可能是真实的风险事件，处理时必须区分。中位数绝对偏差为

$$\mathrm{MAD} = \mathrm{median}\left(|x_i - \mathrm{median}(x)|\right), \qquad \hat{\sigma}_{\text{robust}} = 1.4826\,\mathrm{MAD} \tag{8.32}$$

其中常数 1.4826 使 $\hat{\sigma}_{\text{robust}}$ 在正态数据下与样本标准差一致。与标准差相比，MAD 的崩溃点是 50%，即接近一半的观测被污染后仍然稳健，而标准差的崩溃点是 0%。缩尾（Winsorize）把超出 $[\mathrm{median} - k\hat{\sigma}_{\text{robust}},\ \mathrm{median} + k\hat{\sigma}_{\text{robust}}]$ 的值替换为边界值，通常取 $k = 3$，从而在保留样本量的同时限制单个观测的影响力。

缺失值的处理方式取决于缺失机制。完全随机缺失可用均值或中位数填补；与可观测变量相关的缺失适合用回归或 k 近邻填补；与缺失值本身相关的非随机缺失（如业绩差的基金停止披露）则任何填补都会引入偏差，只能通过敏感性分析量化。多重插补通过对填补模型加入随机扰动生成 M 个完整数据集（M 常取 5 至 20），分别估计后再用 Rubin 规则合并，从而把填补的不确定性计入标准误。链式方程多重插补（MICE）允许每个变量使用不同的条件模型，是目前处理混合类型金融面板的默认方法。

8.9.2 平稳性与单位根

平稳性是用时间序列做统计推断的前提。弱平稳要求均值与方差不随时间变化、自协方差只依赖于时间间隔。ADF 检验回归

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^{p} \delta_i \Delta y_{t-i} + \varepsilon_t \tag{8.33}$$

原假设为 $H_0 : \gamma = 0$（存在单位根），备择假设为 $\gamma < 0$（平稳）。注意该检验的分布是非标准的 Dickey–Fuller 分布，不能直接用正态临界值；滞后阶数 p 通常按 AIC 或 BIC 选取。KPSS 检验的逻辑正好相反：原假设为平稳（趋势平稳），因此“ADF 不拒绝 + KPSS 拒绝”支持单位根，“ADF 拒绝 + KPSS 不拒绝”支持平稳，两者都拒绝通常意味着存在结构突变。Phillips–Perron 检验则通过非参数修正处理残差自相关，无需设定滞后阶数。

补充说明　价格、收益与波动率序列的平稳性差异

价格序列通常含单位根（$I(1)$），收益序列通常平稳（$I(0)$），而波动率序列虽然平稳但自相关极强，接近长记忆过程。这一层次差异决定了建模顺序：先对价格差分得到收益，再对收益建模均值方程，最后对残差平方建模波动率方程。若跳过差分直接对价格回归，即使两个独立的价格序列也会给出高 R^2 与显著 t 值，这就是伪回归（spurious regression）。

8.10 因果推断简介

相关性不足以支撑“某因素导致了某收益”的结论。金融中常用两类准实验方法。双重差分（DID）比较处理组与对照组在政策前后的变化差

$$y_{it} = \alpha + \beta_1 \mathrm{Treat}_i + \beta_2 \mathrm{Post}_t + \delta \left(\mathrm{Treat}_i \times \mathrm{Post}_t\right) + \varepsilon_{it} \tag{8.34}$$

其中 δ 为政策效应。DID 成立的关键假设是平行趋势：若无政策，处理组与对照组的时间趋势应当一致，这一假设需要用政策前的数据检验。合成控制法在只有一个处理单位（如某国、某交易所）时更适用：用其他单位的加权组合构造一个“合成对照组”，使它在政策前尽可能贴合处理单位的路径，然后把政策后的差异归因于处理。两类方法的共同弱点是都无法排除与处理同时发生的其他冲击，因此在解读金融领域的自然实验时必须同时报告替代解释。

8.11 代码实现：t 分布 MLE 与 POT/GPD

Listing 8.1　用极大似然估计学生 t 分布自由度并与矩估计对比

```
import numpy as np
import pandas as pd
from scipy import stats, optimize
```

```

rng = np.random.default_rng(3)
returns = stats.t.rvs(df=5.0, size=3000, random_state=7) * 0.012
returns = returns - returns.mean()

def neg_loglik(params, x):
    nu, loc, scale = params
    if nu <= 2.05 or scale <= 0:
        return 1e10
    return -np.sum(stats.t.logpdf(x, df=nu, loc=loc, scale=scale))

fit = optimize.minimize(neg_loglik, x0=np.array([6.0, 0.0, 0.01]),
                        args=(returns,), method="Nelder-Mead",
                        options={"xatol": 1e-6, "fatol": 1e-8, "maxiter":
                            4000})
nu_hat, loc_hat, scale_hat = fit.x
print("MLE df = %.2f  loc = %.5f  scale = %.5f" % (nu_hat, loc_hat,
    scale_hat))

excess_kurt = stats.kurtosis(returns, fisher=True, bias=False)
nu_moment = 4.0 + 6.0 / excess_kurt if excess_kurt > 0 else np.inf
print("sample excess kurtosis = %.2f -> moment df = %.2f" % (excess_kurt,
     nu_moment))
normal_ll = np.sum(stats.norm.logpdf(returns, loc=returns.mean(), scale=
    returns.std()))
print("loglik gain over normal = %.1f" % (-fit.fun - normal_ll))
```

Listing 8.2　POT 方法拟合 GPD 并计算极端分位的 VaR 与 ES

```
import numpy as np
from scipy import stats

rng = np.random.default_rng(21)
n = 2500
losses = np.abs(stats.t.rvs(df=4.0, size=n, random_state=5)) * 0.012
u = np.quantile(losses, 0.95)
excess = losses[losses > u] - u
n_u = excess.size
print("threshold = %.4f  exceedances = %d" % (u, n_u))

xi, loc, beta = stats.genpareto.fit(excess, floc=0.0)
print("GPD xi = %.3f  beta = %.4f" % (xi, beta))

def evt_var_es(losses, u, xi, beta, q=0.999):
    n, n_u = losses.size, int(np.sum(losses > u))
    factor = (n / n_u * (1.0 - q)) ** (-xi)
    var_q = u + beta / xi * (factor - 1.0)
    es_q = var_q / (1.0 - xi) + (beta - xi * u) / (1.0 - xi)
    return var_q, es_q

var_999, es_999 = evt_var_es(losses, u, xi, beta, 0.999)
```

```
sigma = losses.std()
print("EVT  VaR99.9 = %.4f  ES99.9 = %.4f" % (var_999, es_999))
print("Normal VaR99.9 = %.4f  ES99.9 = %.4f"
      % (sigma * 3.0902, sigma * stats.norm.pdf(3.0902) / 0.001))
print("empirical worst 5 losses:", np.sort(losses)[-5:])
```

listings 8.1 and 8.2 给出两段可直接运行的实现。第一段把 MLE 与 小节 8.2.1 的矩估计并排比较，并报告相对正态分布的对数似然增益——这是判断是否需要厚尾模型的直接依据。第二段实现 式 (8.29) 与 式 (8.30)，并与正态假设下的结果以及经验最差损失对照。若 EVT 的 $\widehat{\mathrm{ES}}$ 明显小于经验最差损失，说明阈值取得太高、超越观测太少，应下调阈值重新拟合。

核心要点 8.1　统计推断在金融数据上的三条纪律

第一，先看尾部再谈均值：报告的每一个均值与 Sharpe 比率都应附上基于厚尾或 EVT 的区间；第二，标准误必须稳健：面板数据用双向聚类，时间序列用 HAC，极值用 bootstrap；第三，区分统计显著与经济显著：一个 t 值为 2.5 的因子，若扣掉交易成本后收益归零，它在经济上不显著。

本章小结

- 金融收益的尾部远厚于正态：$\nu = 5$ 的 t 分布在 $|x| = 6$ 处的概率密度比正态高约三个数量级，直接决定极高分位风险度量的准确性。
- MLE 在正则条件下渐近正态且达到 Cramér–Rao 下界；GMM 在矩条件框架下以 $W_n = S^{-1}$ 达到渐近有效，J 检验用于诊断过度识别。
- LRT、Wald 与 Score 检验渐近等价但有限样本表现不同；多重检验必须用 Bonferroni 或 Benjamini–Hochberg FDR 校正，前提是如实记录试验次数。
- bootstrap 需按数据结构选择：独立数据用普通 bootstrap，时间序列用移动块或平稳 bootstrap，权重的选择直接决定区间宽度。
- 回归推断的关键在于标准误：White 处理异方差，Newey–West 处理自相关，聚类处理组内相关；Fama–MacBeth 用逐期横截面回归绕开协方差矩阵估计。
- 贝叶斯方法的核心是共轭更新 式 (8.18) 的精度加权，Black–Litterman 是它在组合构建中的成功应用，MCMC 解决后验无解析形式的情形。
- 极值理论用 GPD 拟合超阈值超额损失，给出远超正态假设的 VaR 与 ES，是监管资本与压力测试的必备工具。

练习与思考

1. 设某资产日收益服从 t 分布，自由度 $\nu = 4$。请说明为何其四阶矩不存在，并解释这对样本峰度估计意味着什么。若把 ν 改为 6，结论如何变化？
2. 用 式 (8.18) 计算：先验 $\mu \sim \mathcal{N}(0.05, 0.10^2)$（年化收益），样本 $n = 200$ 天的日均收

益 0.06%、日标准差 1.5%。求后验均值与后验标准差，并解释收缩幅度为何与你预期的一致。

3. 在小节 8.8.2 中，若阈值下调为 $u = 1.5\%$、$N_u = 250$，重新拟合得 $\hat{\xi} = 0.22$、$\hat{\beta} = 1.1\%$。重算 $q = 99.9\%$ 的 VaR 与 ES，并讨论阈值变化对结果的影响方向。

4. 对 Black–Litterman 模型，设两只资产的协方差矩阵为 $\boldsymbol{\Sigma} = \begin{pmatrix} 0.04 & 0.01 \\ 0.01 & 0.09 \end{pmatrix}$，市场权重各 50%，$\delta = 2.5$。求 Π；再设观点为“资产 1 比资产 2 多涨 3%”，$\Omega = 0.0001$、$\tau = 0.05$，用式 (8.21) 求后验均值。

5. 解释为什么 Ridge 回归不产生稀疏解而 Lasso 会产生，并用 L_1、L_2 球的几何图形说明。若特征高度相关，Elastic Net 相比 Lasso 有什么优势？

6. 写出检验“某因子月均溢价为零”的三种检验统计量形式，并说明在只有 60 个月样本、残差存在自相关时应优先选择哪一种，理由是什么。

延伸阅读

- Greene, W., *Econometric Analysis*, 8th ed., Pearson, 2018. （假设检验、面板数据与稳健标准误的标准教材，推导完整且例子丰富）
- McNeil, A., Frey, R., and Embrechts, P., *Quantitative Risk Management*, 2nd ed., Princeton University Press, 2015. （第 7 章系统讲解 EVT、POT 与 EVT-VaR/ES，是尾部风险建模的权威参考）
- Efron, B., and Tibshirani, R., *An Introduction to the Bootstrap*, Chapman and Hall, 1993. （bootstrap 的原始系统论述，块方法与置信区间的构造讲得最清楚）
- Gelman, A., Carlin, J., Stern, H., Dunson, D., Vehtari, A., and Rubin, D., *Bayesian Data Analysis*, 3rd ed., CRC Press, 2013. （贝叶斯推断与 MCMC 的标准参考，包含收敛诊断与模型检验）
- Black, F., and Litterman, R., “Global Portfolio Optimization”, *Financial Analysts Journal*, 1992. （Black–Litterman 模型的原始文献，推导简洁，直觉解释至今最清晰）
- Harvey, C., Liu, Y., and Zhu, H., “...and the Cross-Section of Expected Returns”, *Review of Financial Studies*, 2016. （用多重检验框架重估因子显著性，是理解 FDR 在因子研究中作用的必读文献）

第九章 时间序列分析

金融数据几乎全部以时间序列的形式出现：日收益率、分钟级成交价、逐笔订单流、宏观月度指标。时间序列分析的任务，是从这些带有序结构的观测中分离出三类成分——可预测的动态（趋势、周期、自回归结构）、可建模的波动率（条件异方差）、以及不可约的噪声。本章按「线性均值模型 → 条件波动率模型 → 高频与状态空间 → 协整与因果 → 深度学习 → 评估与回测」的顺序展开，并始终强调一个原则：模型复杂度必须由样本外表现与失效条件来约束，而不是由样本内拟合优度来驱动。

9.1 平稳性与模型识别

9.1.1 平稳性的两种定义

定义 9.1 严平稳与弱平稳

若对任意 k 与任意时刻集合 $t_1 < \cdots < t_k$，联合分布 $(y_{t_1}, \ldots, y_{t_k})$ 与 $(y_{t_1+h}, \ldots, y_{t_k+h})$ 相同，则称 $\{y_t\}$ 为**严平稳**（strictly stationary）。若仅要求前两阶矩满足

$$\mathbb{E}[y_t] = \mu, \qquad \operatorname{Cov}(y_t, y_{t-k}) = \gamma_k \quad (\text{不依赖 } t) \tag{9.1}$$

则称 $\{y_t\}$ 为**弱平稳**（weakly stationary）或协方差平稳，其中 μ 为常数均值、γ_k 为滞后 k 阶的自协方差、$\gamma_0 = \operatorname{Var}(y_t)$ 为常数方差。

弱平稳是绝大多数线性时间序列模型的建模前提，也是假设检验的对象。实践中常见的偏离有三类：确定性趋势（如名义 GDP）、随机趋势（单位根，如股价对数）、季节性与结构突变。三类偏离的处理方式完全不同：趋势可以用回归或差分消除，单位根需要差分并检验，而结构突变会污染参数估计。小节 9.1.1 中的 γ_k 只依赖于滞后阶数 k 而不依赖绝对时刻 t，这正是「时间平移不变」含义在二阶矩层面的体现。

9.1.2 自相关函数与偏自相关函数

把自协方差标准化即得**自相关函数**（autocorrelation function, ACF）：

$$\rho_k = \frac{\gamma_k}{\gamma_0}, \qquad \hat{\rho}_k = \frac{\sum_{t=k+1}^{T} (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{T} (y_t - \bar{y})^2} \tag{9.2}$$

其中 T 为样本量、$\bar{y}$ 为样本均值、$\hat{\rho}_k$ 为滞后 k 阶的样本自相关。在「序列为白噪声」的原假设下，$\hat{\rho}_k$ 的近似标准差为 $\mathrm{SE}(\hat{\rho}_k) \approx 1/\sqrt{T}$，因此 95% 置信带约为 $\pm 1.96/\sqrt{T}$；当 $T = 1000$ 时该带宽约为 ± 0.062，凡是超出这条带子的 $\hat{\rho}_k$ 都值得进一步追究。

偏自相关函数（partial ACF, PACF）度量剔除中间滞后项之后的「直接」相关：

$$\alpha_k = \operatorname{Corr}\big(y_t,\, y_{t-k} \,\big|\, y_{t-1}, \ldots, y_{t-k+1}\big) \tag{9.3}$$

其样本版本可由 Yule–Walker 方程配合 Durbin–Levinson 递推 $O(Tk)$ 计算。ACF 与 PACF 的联合使用构成了线性模型定阶的经典工具，具体模式见表 9.1。

表 9.1　ACF 与 PACF 的识别模式（模型定阶的第一步）

模型	理论 ACF	理论 PACF
AR(p)	拖尾（指数或振荡衰减）	p 阶后截尾
MA(q)	q 阶后截尾	拖尾
ARMA(p,q)	拖尾	拖尾
ARIMA(p,d,q)	差分后同 ARMA	差分后同 ARMA

直觉理解　ACF 与 PACF 的分工

ACF 回答「相隔 k 期的两个观测有多像」，PACF 回答「在已知最近 $k-1$ 期的情况下，第 k 期滞后还能额外提供多少信息」。若 y_t 由 y_{t-1} 驱动、y_{t-1} 又由 y_{t-2} 驱动，则 ACF 会一路衰减下去（拖尾），而 PACF 在第 2 阶就截断为零——因为第 2 阶滞后被 y_{t-1} 完全「解释」掉了。这正是 AR(1) 的 ACF 拖尾、PACF 一阶截尾的原因。

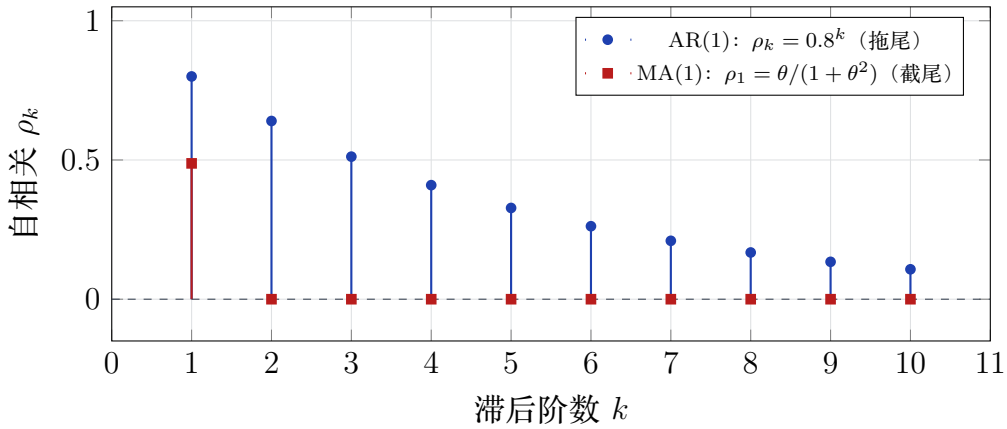


图 9.1　AR(1) 与 MA(1) 的自相关函数对比（$\phi = 0.8$，$\theta = 0.8$）

图 9.1 直观展示了识别逻辑：AR(1) 的 ACF 以几何速度 0.8^k 拖尾，MA(1) 的 ACF 在 $k \geq 2$ 处严格为零。注意 MA(1) 的 $\rho_1 = \theta/(1+\theta^2)$ 关于变换 $\theta \mapsto 1/\theta$ 不变，因此单看 ACF 无法区分 $\theta = 0.8$ 与 $\theta = 1.25$——这正是需要**可逆性**条件的原因。

9.1.3　单位根检验：三种检验的逻辑差异

差分是否必要，取决于序列是否存在单位根。三类检验的原假设不同，混用会导致结论互相矛盾：

- **ADF 检验**（Augmented Dickey–Fuller）回归 $\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^{k} \delta_i \Delta y_{t-i} + \varepsilon_t$，原假设 $H_0 : \gamma = 0$（存在单位根），备择为平稳。t 统计量的临界值来自 Dickey–Fuller 分布而非正态分布，5% 临界值约 -2.86（无趋势）与 -3.41（含趋势）。
- **KPSS 检验**把原假设反过来：H_0 为（趋势）平稳。因此 ADF 与 KPSS 同时不拒绝是常见结果，说明样本对「接近单位根」这一区域没有足够分辨力。
- **PP 检验**（Phillips–Perron）用非参数方式修正残差中的序列相关与异方差，避免 ADF 中滞后阶数选择的主观性，但在强负相关 MA 误差下容易过度拒绝。

⚠ 风险警示　伪回归：高 R^2 也可能是假象

Granger 与 Newbold（1974）的模拟显示：让两条*相互独立*的随机游走做 OLS 回归，R^2 常常超过 0.8，t 统计量动辄大于 4，但 Durbin–Watson 统计量接近 0。原因是一阶单整序列的样本矩以非标准速率发散，常规的 t 与 F 分布完全失效。因此在做任何跨资产的回归之前，必须先检验单整阶数；若被解释变量与解释变量都是 $I(1)$，则要么差分建模，要么检验协整（见后文）。

9.1.4　结构突变

结构突变（structural break）指数据生成过程的参数在某个时点发生跳变，如 2008 年金融危机、2020 年 3 月流动性枯竭、监管规则变更。常见检验包括已知断点下的 Chow 检验，以及未知断点下的 Bai–Perron 多断点检验。Perron（1989）指出一个关键事实：若真实过程是「趋势平稳 + 一次大的水平突变」，而研究者忽略该突变直接做 ADF，检验会系统性地不拒绝单位根——把确定性突变误判为随机趋势。这意味着单位根结论必须与结构突变检验联合解读，否则极易得到错误的差分阶数。

9.2 ARMA 模型族：平稳性与可逆性

9.2.1　AR 模型与平稳性条件

p 阶自回归模型 AR(p) 写作

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t \tag{9.4}$$

其中 c 为常数项、ϕ_i 为自回归系数、ε_t 为白噪声（$\mathbb{E}[\varepsilon_t] = 0$、$\mathrm{Var}(\varepsilon_t) = \sigma^2$、$\mathrm{Cov}(\varepsilon_t, \varepsilon_s) = 0$ 当 $t \neq s$）。引入滞后算子 L（$L y_t = y_{t-1}$）可写成 $\phi(L) y_t = c + \varepsilon_t$，其中 $\phi(L) = 1 - \phi_1 L - \cdots - \phi_p L^p$。

核心要点 9.1　平稳性条件与可逆性条件的对偶

AR 部分的多项式 $\phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p$ 的*全部根*都落在单位圆外时，AR(p) 才是弱平稳的；MA 部分的多项式 $\theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$ 的全部根都落在单位圆外时，MA(q) 才是*可逆*的。平稳性保证「现在可以写成过去冲击的收敛加权和」，可逆性保证「冲击可以写成现在与过去的收敛加权和」——两者是同一枚硬币的两

面，都对应把 z 的幂级数在 $|z|\le 1$ 内展开。

以 AR(1) 为例可以看清条件的作用。把 $y_t = c + \phi y_{t-1} + \varepsilon_t$ 向前迭代：

$$y_t = \frac{c}{1-\phi} + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j} \tag{9.5}$$

该 MA(∞) 表示收敛（从而二阶矩有限）当且仅当 $|\phi|<1$，此时

$$\mathbb{E}[y_t] = \frac{c}{1-\phi}, \qquad \gamma_0 = \frac{\sigma^2}{1-\phi^2}, \qquad \rho_k = \phi^k \tag{9.6}$$

其中 γ_0 由 Yule–Walker 方程 $\gamma_0 = \phi\gamma_1 + \sigma^2$ 与 $\gamma_1 = \phi\gamma_0$ 联立得到，而 $\rho_k = \phi^k$ 直接来自 $\gamma_k = \phi\gamma_{k-1}$ 的递推。式 (9.6) 给出一个可操作的数量级直觉：自相关衰减到一半所需期数为

$$h_{1/2} = \frac{\ln 0.5}{\ln |\phi|} \tag{9.7}$$

当 $\phi = 0.9$ 时 $h_{1/2}\approx 6.6$ 期，$\phi = 0.8$ 时 $h_{1/2}\approx 3.1$ 期。换句话说，日频 AR(1) 系数从 0.8 提高到 0.9，冲击的记忆长度几乎翻倍。

9.2.2 MA 模型与可逆性

q 阶移动平均模型 MA(q) 定义为

$$y_t = \mu + \varepsilon_t + \theta_1\varepsilon_{t-1} + \cdots + \theta_q\varepsilon_{t-q} \tag{9.8}$$

其中 μ 为均值、θ_j 为移动平均系数。有限阶 MA 过程永远是弱平稳的——它是有限个白噪声的线性组合，前两阶矩不随 t 变化，无需任何参数约束。对 MA(1)：$\gamma_0 = \sigma^2(1+\theta^2)$、$\gamma_1 = \sigma^2\theta$、$\gamma_k = 0$ $(k\ge 2)$，故

$$\rho_1 = \frac{\theta}{1+\theta^2}, \qquad \rho_k = 0 \quad (k\ge 2) \tag{9.9}$$

可逆性要求 $|\theta|<1$，即 $\theta(z) = 1+\theta z$ 的根 $z = -1/\theta$ 落在单位圆外。由于 θ 与 $1/\theta$ 产生完全相同的 ACF，若不施加可逆性约束，参数将不可识别；统计软件默认报告可逆的那个根，因此「$\theta = 1.25$」的估计通常会被改写成「$\theta = 0.8$」。

9.2.3 ARMA 与 ARIMA

把 AR 与 MA 合并即得 ARMA(p,q)：

$$\phi(L)y_t = c + \theta(L)\varepsilon_t, \qquad \phi(L) = 1 - \sum_{i=1}^{p}\phi_i L^i, \quad \theta(L) = 1 + \sum_{j=1}^{q}\theta_j L^j \tag{9.10}$$

ARMA 的平稳性完全由 $\phi(z)$ 决定，可逆性完全由 $\theta(z)$ 决定，两者互不干扰。对 ARMA(1,1)，其一阶自相关为

$$\rho_1 = \frac{(1+\phi\theta)(\phi+\theta)}{1+2\phi\theta+\theta^2} \tag{9.11}$$

而对 $k \geq 2$ 有 $\rho_k = \phi\rho_{k-1}$——即 ACF 在 1 阶之后呈现纯 AR(1) 的几何衰减。例如 $\phi = 0.6$、$\theta = 0.3$ 时 $\rho_1 = 1.062/1.45 \approx 0.732$，$\rho_2 \approx 0.439$。

对非平稳但差分后平稳的序列，采用 ARIMA(p, d, q)：

$$\phi(L)(1-L)^d y_t = c + \theta(L)\varepsilon_t \tag{9.12}$$

其中 d 为差分阶数，$(1-L)^d$ 为 d 阶差分算子，$(1-L)y_t = \Delta y_t$。差分阶数并非越大越好：若序列其实已平稳而仍然差分，会在 MA 部分引入一个接近 -1 的根，即「过差分」，使 $\theta(z)$ 出现单位根、可逆性被破坏，并放大高频噪声。**判断原则**：以单位根检验与原序列 ACF 的衰减速度交叉验证，通常 $d \leq 2$。

9.2.4 季节模型 SARIMA

季节性 ARIMA 记作 SARIMA$(p, d, q)(P, D, Q)_s$，其形式为

$$\phi(L)\Phi(L^s)(1-L)^d(1-L^s)^D y_t = \theta(L)\Theta(L^s)\varepsilon_t \tag{9.13}$$

其中 s 为季节周期（月度数据 $s = 12$、季度数据 $s = 4$）、$\Phi(L^s)$ 与 $\Theta(L^s)$ 分别为季节自回归与季节移动平均多项式、D 为季节差分阶数。以电力消费的月度数据为例，$(1-L^{12})$ 消除「同月同比」之外的年内周期，$D = 1$ 即可让季节 ACF 上 $12, 24, 36$ 处的尖峰消失。金融日频数据的季节结构远弱于宏观数据，但日内效应（开盘与收盘的波动率尖峰）可以用 $s = 48$（半小时采样）的同类模型刻画。

9.3 Box–Jenkins 建模流程

Box–Jenkins 方法把建模拆成四步闭环，其价值在于把「模型选择」从一次性判断变成可迭代的诊断过程。

算法 9.1 的第 7–9 步是最容易被跳过、却最能决定成败的部分：均值方程残差若仍含 ARCH 效应，则普通最小二乘的标准误被低估、置信区间过窄、t 检验偏激进。诊断阶段的核心统计量是 Ljung–Box Q 检验

$$Q = T(T+2)\sum_{k=1}^{m}\frac{\hat{\rho}_k^2}{T-k} \;\sim\; \chi^2_{m-p-q} \tag{9.14}$$

其中 m 为考察的最大滞后阶数（经验取法 $m \approx \min(20, T/5)$）、$\hat{\rho}_k$ 为残差自相关。Q 显著说明还有结构没有提取干净。

阶数选择常用信息准则：

$$\mathrm{AIC} = -2\ln\hat{L} + 2k, \qquad \mathrm{BIC} = -2\ln\hat{L} + k\ln T, \qquad \mathrm{HQ} = -2\ln\hat{L} + 2k\ln\ln T \tag{9.15}$$

其中 $\hat{L}$ 为极大似然值、k 为待估参数个数。BIC 的惩罚随 $\ln T$ 增长，因此比 AIC 更保守、更倾向于简约模型；当两个模型 AIC 相差小于 2 时，可以认为它们在样本内表现上无法区分。

算法 9.1 Box–Jenkins 四步建模流程

输入： 平稳化后的序列 $y_1,\dots,y_T$，最大阶数 $p_{\max},q_{\max}$
输出： 通过诊断检验的模型 $\widehat{\mathrm{ARMA}}(p,q)$

识别：计算 ACF/PACF，结合 AIC/BIC 在 $p\le p_{\max},q\le q_{\max}$ 内搜索
估计：用条件极大似然或精确极大似然估计 (ϕ,θ,σ^2,c)
while 诊断未通过 **do**
    诊断：检验残差 $\hat\varepsilon_t$ 是否为白噪声（Ljung–Box Q 检验）
        并检查残差方差的 ARCH 效应（$\hat\varepsilon_t^2$ 的 ACF）
    if 存在显著自相关 **then**
        调整 p,q（或引入季节项、结构突变虚拟变量）后重新估计
    else if 存在显著 ARCH 效应 **then**
        转波动率建模（表 9.2），对均值方程残差拟合 GARCH 族
    end if
end while
预测：递推条件均值 $\hat y_{T+h|T}$ 并给出预测区间
return $(\hat\phi,\hat\theta,\hat\sigma^2)$ 与 h 步预测

实务应用　实务中的默认配置

多数卖方与买方研究在日频资产收益率上都使用「常数均值 + 低阶结构」的配置：均值方程取 AR(1) 或纯常数，波动率方程取 GARCH(1,1) 或 GJR，分布取学生 t。原因有三：日收益率自相关的经济幅度极小（$|\phi|<0.1$，扣掉交易成本后基本不可交易）；高阶模型在滚动窗口中的参数不稳定性抵消了样本内增益；而波动率部分的自相关是真实且稳健的，值得投入建模预算。

9.4 波动率建模：ARCH 与 GARCH 族

9.4.1 ARCH 模型

Engle（1982）注意到收益率的平方存在显著自相关，于是把方差设为过去冲击的函数：

$$r_t=\mu_t+\varepsilon_t,\qquad \varepsilon_t=\sigma_t z_t,\qquad z_t\sim \text{i.i.d.}(0,1) \tag{9.16}$$

$$\sigma_t^2=\omega+\sum_{i=1}^{q}\alpha_i\varepsilon_{t-i}^2 \tag{9.17}$$

其中 r_t 为收益率、μ_t 为条件均值、σ_t^2 为条件方差、z_t 为标准化新息（常取标准正态或标准化学生 t）、$\omega>0$ 为基准方差、$\alpha_i\ge 0$ 度量第 i 阶冲击对当前方差的影响。ARCH 的实质是：今天的方差由最近 q 期「意外的大小」决定。其缺陷在于记忆太短——要让波动率冲击衰减得足够慢，往往需要 $q>10$ 甚至几十个参数。

9.4.2 GARCH 模型与长期方差

Bollerslev（1986）用「方差的滞后项」替代大量冲击滞后项：

$$\sigma_t^2 = \omega + \sum_{i=1}^{q} \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^{p} \beta_j \sigma_{t-j}^2 \tag{9.18}$$

其中 β_j 为方差自回归系数。金融实践中最常用的是 GARCH(1, 1)：

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \tag{9.19}$$

只需三个参数就能刻画「大波动跟着大波动」的聚集现象。取无条件期望可得**长期方差**

$$\bar{\sigma}^2 = \mathbb{E}[\sigma_t^2] = \frac{\omega}{1-\alpha-\beta}, \qquad \text{要求} \alpha+\beta<1 \tag{9.20}$$

其中 $\alpha+\beta$ 称为**持续性**（persistence），度量一次波动率冲击的衰减速度；$\alpha+\beta \to 1$ 时长期方差发散，对应 IGARCH 模型（波动率冲击永不衰减）。把式 (9.19) 反复代入可得到 ARCH(∞) 表示

$$\sigma_t^2 = \frac{\omega}{1-\beta} + \alpha \sum_{j=0}^{\infty} \beta^j \varepsilon_{t-1-j}^2 \tag{9.21}$$

这说明 GARCH(1,1) 其实是一个几何衰减的记忆核，β 就是核的衰减率。冲击的半衰期由持续性直接给出：

$$h_{1/2} = \frac{\ln 0.5}{\ln(\alpha+\beta)} \tag{9.22}$$

例 9.1 GARCH(1,1) 的长期波动率、半衰期与预测

设日频参数为 $\omega = 0.01$、$\alpha = 0.08$、$\beta = 0.90$（收益率以百分数计，故方差单位为「百分数平方」）。(1) 持续性 $\alpha+\beta = 0.98$，由式 (9.20) 得长期方差 $\bar{\sigma}^2 = 0.01/0.02 = 0.50$，长期日波动率 $\bar{\sigma} = 0.707\%$；按 252 个交易日年化得 $0.707 \times \sqrt{252} \approx 11.2\%$。(2) 由式 (9.22)，半衰期 $h_{1/2} = \ln 0.5 / \ln 0.98 \approx 34.3$ 个交易日，即一次波动率冲击约需 34 天衰减一半，正好对应图 9.2 中长达数周的「高位平台」。(3) h 步方差预测为

$$\mathbb{E}_t[\sigma_{t+h}^2] = \bar{\sigma}^2 + (\alpha+\beta)^{h-1}\left(\sigma_{t+1}^2 - \bar{\sigma}^2\right) \tag{9.23}$$

若当前 $\sigma_{t+1} = 1.4\%$（即 $\sigma_{t+1}^2 = 1.96$），则 1 天后方差预测为 $0.50 + 0.98^0 \times (1.96 - 0.50) = 1.96$，10 天后为 $0.50 + 0.98^9 \times 1.46 \approx 0.50 + 1.216 = 1.72$，对应波动率 1.31%；预测值以半衰期速度回归长期水平。

式 (9.23) 的推导只用到一步。把方差方程推进一步并取条件期望：

$$\sigma_{t+h}^2 = \omega + (\alpha+\beta)\sigma_{t+h-1}^2 + \alpha \sigma_{t+h-1}^2 \left(z_{t+h-1}^2 - 1\right) \tag{9.24}$$

其中最后一项的条件期望为零（z_{t+h-1} 与 $\mathcal{F}_{t+h-2}$ 独立且均值为零，故 $\mathbb{E}_t[\sigma_{t+h-1}^2(z_{t+h-1}^2-1)] = 0$），于是得到以一阶线性差分方程递推的预测公式 (9.23)：每一期的方差预测值按比例 $(\alpha+\beta)$ 向长期方差 $\bar{\sigma}^2$ 收缩。

图 9.2 是「波动率聚集」最直接的图示：第 35–50 个交易日附近，$|r_t|$ 的散点明显变密变大，而条件波动率 σ_t 相应抬升并缓慢回落。注意 σ_t 是平滑的（它由递推产生），而 $|r_t|$ 是噪声的——这正是「波动率可预测、收益率方向不可预测」这一经验规律的可视化。

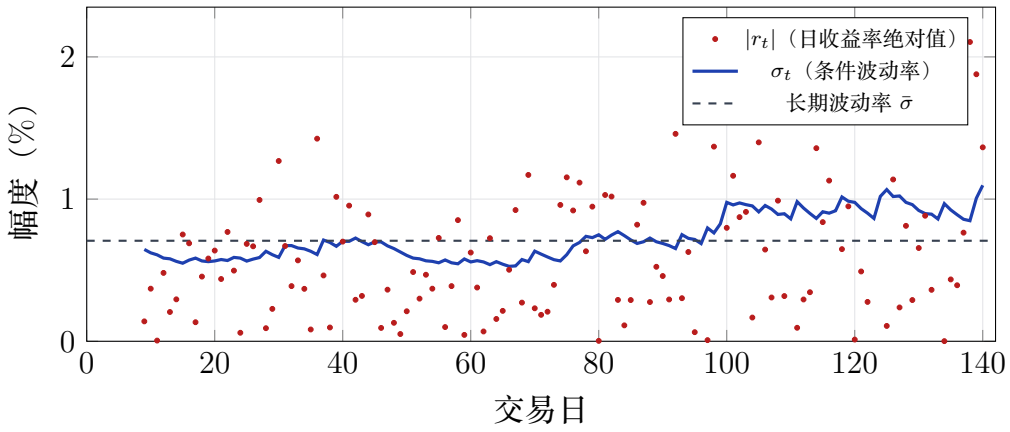


图 9.2　GARCH(1,1) 模拟：$\omega = 0.01$、$\alpha = 0.08$、$\beta = 0.90$ 下的波动率聚集

9.4.3　GARCH 族的扩展

表 9.2　主要 GARCH 族模型对比

模型	方差方程的核心形式	主要捕捉的特征	额外参数
ARCH(q)	$\sigma_t^2 = \omega + \sum \alpha_i \varepsilon_{t-i}^2$	波动率聚集	q 个
GARCH(1,1)	$\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$	聚集 + 长记忆	0
EGARCH	$\ln\sigma_t^2 = \omega + \beta\ln\sigma_{t-1}^2 + \gamma z_{t-1} + \alpha(\lvert z_{t-1}\rvert - \mathbb{E}\lvert z\rvert)$	杠杆效应（对数形式，无符号约束）	1
GJR-GARCH	$\sigma_t^2 = \omega + (\alpha + \gamma\mathbf{1}_{\{\varepsilon_{t-1}<0\}})\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$	杠杆效应（直接形式）	1
FIGARCH	$(1-\phi L)(1-L)^d\varepsilon_t^2 = \omega + (1-\beta L)v_t$	长记忆（d 分数阶）	1
DCC-GARCH	分两步：单变量 GARCH + 动态相关矩阵 Q_t	时变相关性（多资产）	多于 1

表 9.2 中的非对称模型针对的是「杠杆效应」：股价下跌时波动率上升的幅度大于同等幅度上涨时的上升。在 GJR 形式下，$\gamma > 0$ 表示负冲击的额外影响；其平稳性条件相应改为 $\alpha + \gamma/2 + \beta < 1$（若 z_t 对称，负冲击概率为 1/2）。EGARCH 用对数方差建模，天然保证 $\sigma_t^2 > 0$，且无需对参数施加非负约束，但代价是 σ_t^2 的解析多步预测不可得，需要模拟。FIGARCH 通过分数阶差分 $d \in (0,1)$ 刻画「长记忆」：冲击的自相关以 k^{2d-1} 的幂律速度衰减而非几何速度衰减，半衰期的概念在此不再适用（记忆长度是尺度依赖的）。

⚠ 风险警示　GARCH 的三条失效边界

（1）**结构突变**：GARCH 把波动率水平的变化解释为「持续性冲击」，但若真实原因是机制切换（如 2020 年 3 月的流动性危机、波动率目标型基金的被动抛售），估计出的 $\alpha + \beta$ 会接近 1（伪高持续性），而模型对下一次突变毫无预警。Lamoureux 与 Lastrapes（1990）证明，忽略结构突变会系统性高估持续性。（2）**非对称与跳跃**：GARCH 的方差方程只含 ε^2，天生对称；遇到跳跃型事件（单日 $\pm 10\%$）时，一次

巨大残差会把 σ_t 抬得很高并缓慢衰减，而这与真实的「事件驱动、快速回落」形态不符。(3) **数据频率**：参数估计高度依赖采样频率。日频估出的 $\alpha+\beta$ 与 5 分钟频估出的值不可直接比较；把日频参数套用到日内波动率预测上会严重高估日内方差。

9.5 已实现波动率与 HAR 模型

9.5.1 已实现波动率

当高频数据可得时，我们不必再「用模型推断波动率」，而可以直接度量它。把一天分成 M 个等间隔区间，第 i 个区间的高频收益率为 $r_{t,i}$，则**已实现波动率**（realized volatility, RV）定义为

$$\mathrm{RV}_t = \sum_{i=1}^{M} r_{t,i}^2 \xrightarrow[M\to\infty]{} \int_t^{t+1} \sigma_s^2 \,\mathrm{d}s =: \mathrm{IV}_t \tag{9.25}$$

其中 IV_t 为积分方差（integrated variance）。收敛的数学依据是二次变差理论（详见第 10 章）：连续半鞅的已实现二次变差依概率收敛到其二次变差过程。在理想的无摩擦、无跳跃市场里，RV_t 是 IV_t 的一致估计量。

现实中 M 的选择是一个偏差–方差权衡：M 太小则度量误差大（方差高），M 太大则微观结构噪声（买卖价差跳动、不同步报价、离散价格）主导，使 RV 上偏且自相关被污染。实用折中通常是 5 分钟采样（$M\approx 78$，对应 6.5 小时交易时段），或采用 5 分钟 RV 加「已实现核」「预平均」等噪声稳健估计量。

9.5.2 HAR 模型

HAR（Heterogeneous AutoRegressive）模型由 Corsi（2009）提出，用一个简单的线性回归概括「不同时间尺度的市场参与者」这一直觉：

$$\mathrm{RV}_t^{(d)} = c + \beta_d \,\mathrm{RV}_{t-1}^{(d)} + \beta_w \,\mathrm{RV}_{t-1}^{(w)} + \beta_m \,\mathrm{RV}_{t-1}^{(m)} + u_t \tag{9.26}$$

其中 $\mathrm{RV}^{(d)}$ 为日度 RV、$\mathrm{RV}^{(w)} = \frac{1}{5}\sum_{j=1}^{5}\mathrm{RV}_{t-j}^{(d)}$ 为周度均值、$\mathrm{RV}^{(m)} = \frac{1}{22}\sum_{j=1}^{22}\mathrm{RV}_{t-j}^{(d)}$ 为月度均值、u_t 为扰动项。三类参与者（日内投机者、周度调仓者、月度机构）分别对应三个尺度，因此模型只需三个参数就能逼近长记忆行为。

表 9.3　HAR 模型的三个时间尺度

频率	记号	计算方式	经济含义
日	$\mathrm{RV}^{(d)}$	当日 5 分钟收益平方和	日内交易者的当日信息
周	$\mathrm{RV}^{(w)}$	过去 5 日 RV 均值	周度调仓者的风险预算
月	$\mathrm{RV}^{(m)}$	过去 22 日 RV 均值	长期机构的波动率目标

表 9.3 中的三个成分相加构成了「波动率的三层记忆」。典型估计结果满足 β_w 与 β_m 都显著为正，且三者之和接近 1（如 $0.36+0.42+0.20=0.98$），这正是长记忆特征的参数

化体现；日度回归的 R^2 通常在 0.5–0.65 区间，远高于收益率方向预测的 R^2（后者常在 0.01 以下，见后文关于低信噪比的讨论）。由于 u_t 存在异方差与序列相关，HAR 的推断必须使用 HAC（Newey–West）稳健标准误。

Listing 9.1 用 `arch` 拟合 GARCH(1,1) 并做波动率预测

```
import numpy as np
from arch import arch_model

rng = np.random.default_rng(42)
n, omega, alpha, beta = 2000, 0.01, 0.08, 0.90
sigma2 = np.empty(n)
eps = np.empty(n)
sigma2[0] = omega / (1.0 - alpha - beta)
z = rng.standard_normal(n)
for t in range(1, n):
    sigma2[t] = omega + alpha * eps[t - 1] ** 2 + beta * sigma2[t - 1]
    eps[t] = np.sqrt(sigma2[t]) * z[t]

am = arch_model(eps, mean="Constant", vol="Garch", p=1, q=1, dist="t")
res = am.fit(disp="off")
print(res.params)

persistence = res.params["alpha[1]"] + res.params["beta[1]"]
print("persistence =", round(persistence, 4))
print("half life   =", round(np.log(0.5) / np.log(persistence), 2))
print("long run sd =", round(np.sqrt(res.params["omega"] / (1 -
    persistence)), 4))

fc = res.forecast(horizon=10, reindex=False)
print(np.sqrt(fc.variance.values[-1]))
```

listing 9.1 中的长期波动率由 $\sqrt{\hat{\omega}/(1-\hat{\alpha}-\hat{\beta})}$ 计算，与 式 (9.20) 一致；参数 `dist="t"` 让新息服从标准化学生 t 分布，这对金融收益率是必要的——正态新息会低估尾部风险，也会使 ω 的估计有偏。注意代码用的是模拟数据，便于复现；换成真实收益率序列时，只需把 `eps` 替换为 `100 * np.diff(np.log(prices))`（乘以 100 是为了数值稳定）。

Listing 9.2 HAR 回归与 HAC 稳健标准误

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

rng = np.random.default_rng(7)
n = 1500
r = 0.01 * rng.standard_normal(n)
rv = np.abs(r) + 0.2 * rng.random(n)          # daily realized volatility
    proxy

df = pd.DataFrame({"rv": rv})
df["rv_d"] = df["rv"].shift(1)
```

```
df["rv_w"] = df["rv"].rolling(5).mean().shift(1)
df["rv_m"] = df["rv"].rolling(22).mean().shift(1)
df = df.dropna()

y = np.log(df["rv"])                                  # log transform keeps rv positive
X = sm.add_constant(df[["rv_d", "rv_w", "rv_m"]])
res = sm.OLS(y, X).fit(cov_type="HAC", cov_kwds={"maxlags": 10})
print(res.params)
print(res.bse)
print(res.rsquared)
```

listing 9.2 用对数变换保证预测值非负，并用 `maxlags=10` 的 HAC 协方差修正残差自相关导致的低估标准误。若要复现 式 (9.26) 中「三尺度」的解释，可把 `rv_w` 与 `rv_m` 换成用真实高频数据构造的周、月均值；若只关心预测精度，把被解释变量换成 RV_t 与「已实现半方差」（上涨与下跌分开）往往还能再提升。

9.6 状态空间模型与卡尔曼滤波

线性均值与波动率模型都假定参数在样本期内固定。但很多金融关系本身是时变的：对冲比率随市场状态漂移、因子暴露随风格轮动变化、潜在增长率缓慢漂移。状态空间模型把这类「不可观测的时变参数」显式写成状态变量，卡尔曼滤波则给出在线递推解。

9.6.1 局部水平模型

最简单也最常用的状态空间模型是**局部水平模型**（local level model）：

$$y_t = \underbrace{x_t}_{\text{潜在水平}} + v_t, \qquad v_t \sim \mathcal{N}(0, R) \tag{9.27}$$

$$x_t = x_{t-1} + w_t, \qquad w_t \sim \mathcal{N}(0, Q) \tag{9.28}$$

其中 y_t 为观测值（如某只 ETF 的每日对数价格）、x_t 为不可观测的随机游走水平、v_t 为观测噪声（波动率 R）、w_t 为状态噪声（波动率 Q）、二者相互独立。信号–噪声比 Q/R 决定滤波器对观测的信任程度。

9.6.2 卡尔曼滤波递推的推导

记 $x_{t|t-1} = \mathbb{E}[x_t \mid y_1, \dots, y_{t-1}]$、$P_{t|t-1} = \mathrm{Var}(x_t \mid y_1, \dots, y_{t-1})$，带 $t|t$ 的量同理。由式 (9.28) 与全期望、全方差公式立即得到**预测步**：

$$x_{t|t-1} = x_{t-1|t-1}, \qquad P_{t|t-1} = P_{t-1|t-1} + Q \tag{9.29}$$

关键在于**更新步**。给定 $y_1, \dots, y_{t-1}$，条件联合分布中 (x_t, y_t) 是二维正态，其中 $y_t = x_t + v_t$，故 $\mathrm{Cov}(x_t, y_t \mid \mathcal{F}_{t-1}) = P_{t|t-1}$，$\mathrm{Var}(y_t \mid \mathcal{F}_{t-1}) = P_{t|t-1} + R$。对联合正态而言，条件期望就是线性回归，回归系数为 $\mathrm{Cov} / \mathrm{Var}$，于是

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + R}, \qquad x_{t|t} = x_{t|t-1} + K_t \underbrace{(y_t - x_{t|t-1})}_{\text{新息}}, \qquad P_{t|t} = (1 - K_t) P_{t|t-1} \tag{9.30}$$

其中 K_t 为**卡尔曼增益**（Kalman gain）。第二式的含义是：把预测误差按增益比例回写到状态上；第三式是「条件方差 = 先验方差 × 残差比例」。式 (9.29) 与 (9.30) 交替迭代即得整个滤波路径。

例 9.2　卡尔曼增益的稳态解

设 $Q=R=1$。稳态时 $P_{t|t-1}=P$ 为常数，代入 式 (9.30) 的第三式并以式 (9.29) 更新一步，得 $P=\left(1-\frac{P}{P+R}\right)(P+Q)=\frac{PR}{P+R}+Q$。以 $Q=R=1$ 代入得 $P^2+P-1=0$，取正根 $P=(\sqrt{5}-1)/2\approx 0.618$。于是稳态增益 $K^*=P/(P+R)=0.618/1.618\approx 0.382$。经济含义：当状态噪声与观测噪声等大时，滤波器每次只把 38.2% 的新息写进状态，其余 61.8% 视为噪声丢弃。Q/R 越大（状态越活跃）K^* 越接近 1；$Q/R\to 0$（状态近乎常数）时 $K^*\to 0$，滤波器退化为「取全样本平均」。

小节 9.6.2 中的 0.382 与 0.618 恰是黄金分割的两个倒数关系，这并非巧合，而是二次方程 $P^2+QP-QR=0$ 在 $Q=R$ 时的自然结果。滤波的另一个副产品是似然函数：新息 $y_t-x_{t|t-1}$ 的方差为 $P_{t|t-1}+R$，把各期新息的对数密度相加即得预测误差分解（prediction error decomposition）形式的对数似然，从而可以极大似然估计 Q 与 R，也可以用 EM 算法迭代。

实务应用　状态空间模型在量化中的三类用法

(1) **时变贝塔**：把 CAPM 的 β_t 设为随机游走状态，观测方程为 $r_t=\alpha+\beta_t r_{m,t}+v_t$，得到随市场状态漂移的对冲比率；(2) **动态因子**：把多个资产的共同成分设为状态，观测方程为因子载荷矩阵，即 Kalman 滤波版本的 PCA/动态因子模型，可处理缺失值与不定期发布的数据；(3) **配对交易的时变价差**：把协整向量 β_t 设为状态，比固定窗口 OLS 更能适应协整关系的缓慢漂移。三类用法的共同前提是 Q、R 的结构设定正确，Q 设得过大会让状态追逐噪声（等价于过拟合）。

9.7 协整、误差修正与格兰杰因果

9.7.1　协整与配对交易

定义 9.2　协整

若两个序列 y_t 与 x_t 都是 $I(1)$（一阶单整，即需差分一次才平稳），且存在非零常数 β 使得

$$u_t=y_t-\beta x_t-\mu\ \sim\ I(0) \tag{9.31}$$

则称 y_t 与 x_t **协整**（cointegrated），向量 $(1,-\beta)$ 为协整向量，u_t 为均衡误差。其中 μ 为长期均衡的截距。

小节 9.7.1 的关键在于「两个非平稳序列的某个线性组合变平稳」。经济上它是套利机制存在的数学表达：只要价差偏离均衡，套利者就会交易把它拉回。注意协整与「高相关」是两件不同的事：两条独立的随机游走可以因为共同趋势而高度相关，但价差是随机游走而非平稳的，做价差回归会落到伪回归陷阱。

Engle–Granger 两步法把检验与估计分开：第一步用 OLS 估计 $y_t=\mu+\beta x_t+u_t$，第二

步对残差 $\hat{u}_t$ 做 ADF 检验，但临界值必须用 Engle–Granger 专用临界值（比普通 ADF 更负，因为 $\hat{\beta}$ 是估计出来的）；拒绝单位根即支持协整。

9.7.2 误差修正模型

由 Granger 表示定理，若存在协整关系，则一定存在**误差修正模型**（error correction model, ECM）：

$$\Delta y_t = \varphi_0 + \alpha_y\big(y_{t-1} - \beta x_{t-1}\big) + \sum_{i=1}^{k} \gamma_i \Delta y_{t-i} + \sum_{i=1}^{k} \delta_i \Delta x_{t-i} + \varepsilon_t \tag{9.32}$$

其中 α_y 为调整速度（误差修正系数）、γ_i 与 δ_i 刻画短期动态。为使偏离被拉回均衡，要求 $-2 < \alpha_y < 0$；α_y 越负，回归速度越快。偏离均衡后的衰减遵循 $(1+\alpha_y)^h$，故偏离的半衰期为

$$h_{1/2} = \frac{\ln 0.5}{\ln(1+\alpha_y)} \tag{9.33}$$

例如 $\alpha_y = -0.15$ 给出 $\ln 0.5 / \ln 0.85 \approx 4.3$ 期，即价差偏离约四天后回到一半。实践中应把 ECM 的截距与结构突变虚拟变量一并纳入，否则「均衡」本身的漂移会被误当成调整速度。

实务应用　配对交易的执行清单

用协整做统计套利的标准流程是：筛选同行业、同驱动因子的资产对 $\to$ 用滚动窗口估计 (β, μ) $\to$ 计算价差 $z_t = (y_t - \hat{\mu} - \hat{\beta} x_t)/\hat{\sigma}_u$ $\to$ 在 $|z_t| > 2$ 建仓、回到 $|z_t| < 0.5$ 平仓 $\to$ 对 $|z_t| > 4$ 触发强制止损。两个必须的纪律：其一，滚动窗口长度决定 $\hat{\beta}$ 的偏差–方差权衡（窗口越长越稳、越短越适应），常用 60–120 个交易日；其二，必须用 ECM 的 α_y 估计持仓时间，若半衰期大于可承受的持仓期，则该组合的收益无法覆盖资金成本与交易成本。

9.7.3 Johansen 检验

当变量多于两个时，可能存在多个协整关系，Engle–Granger 的做法（指定一个被解释变量）不适用。Johansen 方法从向量误差修正模型（VECM）出发：

$$\Delta Y_t = \Pi Y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta Y_{t-i} + \varepsilon_t, \qquad \Pi = \alpha \beta^{\top} \tag{9.34}$$

其中 Y_t 为 n 维向量、Π 为 $n \times n$ 的长期影响矩阵、Γ_i 为短期动态矩阵、α 为调整速度矩阵、β 为协整向量矩阵。核心结论是：$\operatorname{rank}(\Pi) = r$ 就等于协整关系的个数，且 $r \le n-1$；$r = n$ 说明所有变量本身平稳，$r = 0$ 说明不存在协整。检验通过 Π 的降秩回归实现，统计量是其特征值 $\hat{\lambda}_i$ 的函数：

$$\text{迹检验：} \quad LR_{\text{trace}}(r) = -T \sum_{i=r+1}^{n} \ln\big(1 - \hat{\lambda}_i\big) \tag{9.35}$$

$$\text{最大特征值检验：} \quad LR_{\max}(r) = -T \ln\big(1 - \hat{\lambda}_{r+1}\big) \tag{9.36}$$

两式的原假设都是「协整秩为 r」。迹检验是「从少到多」逐层拒绝，最大特征值检验逐阶比较，两者结论不一致时应谨慎，并检查样本量是否足够。

例 9.3　二变量 Johansen 检验的数值判读

设 $n=2$、$T=500$，估计得特征值 $\hat\lambda_1=0.15$、$\hat\lambda_2=0.008$。(1) 迹检验 $r=0$：$LR_{\text{trace}}=-500\ln(0.85)\approx 500\times 0.1625\approx 81.3$，5% 临界值约 19.96，强烈拒绝「无协整」。(2) 迹检验 $r=1$：$LR_{\text{trace}}=-500\ln(0.992)\approx 500\times 0.00803\approx 4.0$，5% 临界值约 9.24，不能拒绝「秩为 1」。(3) 最大特征值检验 $r=0$：$-500\ln(0.85)\approx 81.3>$ 临界值 15.67，拒绝；$r=1$：$4.0<9.24$，不拒绝。两个检验一致地给出 $r=1$。结论：两个 $I(1)$ 序列之间存在唯一协整关系，可用 ECM 建模并做配对交易。

9.7.4　格兰杰因果

定义 9.3　Granger 因果性

在给定信息集 $\mathcal{F}_{t-1}$ 下，若 $\operatorname{Var}\big(y_t\mid\mathcal{F}_{t-1}\big)<\operatorname{Var}\big(y_t\mid\mathcal{F}_{t-1}\setminus\{x_s:s<t\}\big)$，则称 x **Granger 引起** y。在 ARMA 设定下，这等价于 y 的方程中所有 x 的滞后项系数联合为零。

检验方法是对 y 的方程做两次回归：受约束模型只含 y 的滞后项，无约束模型再加上 x 的 q 个滞后项，然后用

$$F=\frac{(\mathrm{RSS}_r-\mathrm{RSS}_u)/q}{\mathrm{RSS}_u/(T-k)}\ \sim\ F(q,\,T-k) \tag{9.37}$$

其中 RSS_r 与 RSS_u 分别为受约束与无约束残差平方和、k 为无约束模型的参数个数。例：$T=200$、$q=4$、$\mathrm{RSS}_r=100$、$\mathrm{RSS}_u=90$ 时 $F=\frac{2.5}{90/196}\approx 5.44$，超过 $F(4,196)$ 的 5% 临界值约 2.42，故拒绝「x 不引起 y」。

⚠ 风险警示　格兰杰因果的三条使用禁忌

(1) **不控制混杂变量**：若 x 与 y 同受第三个变量 z 驱动，x 的滞后项会以 z 的代理身份显著，得到的「因果」在加入 z 后消失。(2) **非平稳数据**：若 y、x 都是 $I(1)$ 且不平衡（无协整），F 统计量不服从 F 分布；此时必须改用 VECM 框架下的检验。(3) **线性与同期效应**：式 (9.37) 只能发现线性、滞后的可预测性。非线性依赖、同期因果、以及由条件异方差造成的伪依赖都无法识别；需要非线性版本或转移熵等工具，但转移熵在小样本下的估计偏差极大，须配合替代数据检验。

9.8 深度学习时间序列模型

9.8.1　从 RNN 到 LSTM

循环神经网络（RNN）用同一个权重矩阵在时间上共享参数：

$$h_t=\tanh\big(W_h h_{t-1}+W_x x_t+b\big) \tag{9.38}$$

其中 x_t 为 t 时刻的输入特征、h_t 为隐状态、W_h 与 W_x 为权重矩阵、b 为偏置。反向传播时梯度要经过 T 次 $W_h^\top$ 的连乘，其谱半径小于 1 时梯度指数衰减（梯度消失），大于 1 时爆炸——这就是 RNN 难以学习长依赖的原因。

LSTM 用门控与一条加性的记忆通道解决该问题：

$$
\begin{aligned}
f_t &= \sigma\big(W_f[h_{t-1}, x_t] + b_f\big) && \text{（遗忘门）} && (9.39)\\
i_t &= \sigma\big(W_i[h_{t-1}, x_t] + b_i\big) && \text{（输入门）} && (9.40)\\
\tilde{C}_t &= \tanh\big(W_C[h_{t-1}, x_t] + b_C\big) && \text{（候选记忆）} && (9.41)\\
C_t &= f_t \odot C_{t-1} + i_t \odot \tilde{C}_t && \text{（记忆单元更新）} && (9.42)\\
o_t &= \sigma\big(W_o[h_{t-1}, x_t] + b_o\big) && \text{（输出门）} && (9.43)\\
h_t &= o_t \odot \tanh(C_t) && \text{（隐状态）} && (9.44)
\end{aligned}
$$

其中 $\sigma(\cdot)$ 为 logistic 函数、$\odot$ 为逐元素乘积、$[h_{t-1}, x_t]$ 为拼接向量。式 (9.42) 是 LSTM 的核心：C_t 沿时间的更新是加法，因此 $\partial C_t / \partial C_{t-1} = f_t$ 不会连乘成指数衰减，梯度可以跨越很多步传回。式 (9.39) 的遗忘门 f_t 由数据决定「丢弃多少旧记忆」，这正是它能处理「波动率机制切换」这类长记忆结构的机制基础。

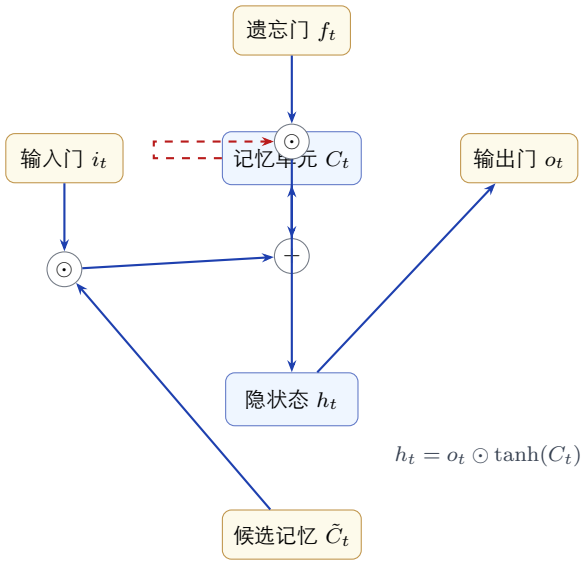


图 9.3　LSTM 单元的门控结构与加性记忆通道（对应 式 (9.42)）

图 9.3 中的关键结构是那条从 C_{t-1} 出发、经过遗忘门与加法节点回到 C_t 的直通路径：它没有任何非线性压缩，梯度可以近似无损地回传，这是 LSTM 相对朴素 RNN 的根本改进。GRU 是它的简化版本，把记忆单元与隐状态合并：

$$
\begin{aligned}
z_t &= \sigma\big(W_z[h_{t-1}, x_t]\big) && \text{（更新门）} && (9.45)\\
r_t &= \sigma\big(W_r[h_{t-1}, x_t]\big) && \text{（重置门）} && (9.46)\\
\tilde{h}_t &= \tanh\big(W[r_t \odot h_{t-1}, x_t]\big), \qquad h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t && && (9.47)
\end{aligned}
$$

其中 z_t 同时承担遗忘与输入的职责。GRU 参数比 LSTM 少约 25%，在中小规模金融数据集上往往表现相当甚至更好，是低信噪比场景下更稳妥的默认选择。

9.8.2 Transformer 与面向时间序列的变体

Transformer 用自注意力替代循环结构：

$$\mathrm{Attention}(Q,K,V)=\mathrm{softmax}\Big(\frac{QK^{\top}}{\sqrt{d_k}}\Big)V \tag{9.48}$$

其中 Q、K、V 分别为查询、键、值矩阵、d_k 为键的维度、$\sqrt{d_k}$ 用于防止内积随维度增大而饱和 softmax。多头注意力把表示空间切成 h 个子空间并行计算：

$$\begin{aligned}\mathrm{MultiHead}(Q,K,V)&=\mathrm{Concat}(\mathrm{head}_1,\dots,\mathrm{head}_h)\,W^{O}\\ \mathrm{head}_i&=\mathrm{Attention}(QW_i^{Q},\,KW_i^{K},\,VW_i^{V})\end{aligned} \tag{9.49}$$

由于注意力本身对序列顺序无感，必须注入位置信息。原版使用正弦位置编码：

$$\mathrm{PE}_{(pos,2i)}=\sin\!\big(pos/10000^{2i/d_{\mathrm{model}}}\big),\qquad \mathrm{PE}_{(pos,2i+1)}=\cos\!\big(pos/10000^{2i/d_{\mathrm{model}}}\big) \tag{9.50}$$

其中 pos 为时间位置、i 为维度索引、d_{model} 为模型维度。自注意力的复杂度为 $O(L^2)$（L 为序列长度），这直接催生了面向长序列的改进：

- **Informer**（2021）：用 ProbSparse 注意力只保留「查询稀疏度」高的键，把复杂度降到 $O(L\log L)$，并配以自注意力蒸馏，适合数百到上千步的长序列预测。
- **Autoformer**（2021）：先用自相关函数（ACF）聚集相似子序列，再用序列分解块显式分离趋势与季节成分，擅长强周期数据。
- **PatchTST**（2023）：把序列切成 Patch（思路来自 ViT），以通道独立方式建模，参数量与训练成本显著低于逐步建模的方案，对缺失值与多变量异质通道更稳健。
- **TFT**（Temporal Fusion Transformer, 2021）：引入静态协变量编码器、门控残差网络与可解释的多头注意力，能输出变量重要性与注意力权重，适合「既要预测又要归因」的风控与需求预测场景。

9.8.3 金融场景下的训练技巧

表 9.4 列出的容量优势在金融数据上很容易变成劣势，因为金融序列的信噪比极低：日频收益率可预测部分的 R^2 常在 0.01 以下，而模型参数量动辄 10^5 以上。因此训练流程的工程细节比网络结构更决定成败：

1. **样本权重**：按目标波动率倒数加权（或用样本唯一性加权），避免高波动时期主导损失函数；这本质上是把「波动率聚类」从噪声变成权重结构。
2. **时序交叉验证**：绝不能用随机 K 折。应使用滚动或扩展窗口，并在训练集与验证集之间留出 embargo 间隔（至少等于标签的前瞻期），否则重叠标签会造成信息泄漏，验证分数虚高。

表 9.4　深度学习时间序列模型的能力与适用场景对比

模型	计算复杂度	长序列能力	可解释性	适用场景
RNN	$O(L)$	弱（梯度消失）	低	短序列基线
LSTM	$O(L)$	中	低（可用门值诊断）	波动率、订单流
GRU	$O(L)$	中	低	中小样本的默认选择
Transformer	$O(L^2)$	中	中（注意力权重）	跨资产、多模态
Informer	$O(L \log L)$	强	中	长序列负荷/价格
PatchTST	$O(L^2/P^2)$	强	低	多变量、含缺失
TFT	$O(L^2)$	中	高	需要归因的预测

3. **特征标准化**：只用训练窗口的均值与标准差做 z 分数变换，再应用到验证集；用全样本标准化是最常见也最隐蔽的泄漏。

4. **正则化组合**：Dropout（0.1–0.5）、权重衰减（10^{-4} 量级）、LayerNorm（对时间序列比 BatchNorm 更稳，因为批内样本的时间分布不一致）、以及早停（以验证集损失为准，耐心 5–10 个 epoch）。

5. **输出层设计**：预测收益率方向时用排序损失或分位数损失代替均方误差，因为 MSE 对大波动样本极度敏感；预测波动率时在 log 空间建模以保证正值。

6. **集成与不确定性**：用 5–10 个不同随机种子的模型取平均（Deep Ensemble），或用 MC Dropout 给出预测分布，再用其分布而非点估计做仓位与风控。

⚠ 风险警示　低信噪比下的过拟合：一个必须量化的边界

金融数据中「样本量 × 信噪比」远小于自然语言或图像任务。假设日频数据 2500 个样本（约 10 年），标签 $R^2 \approx 0.005$，则有效信号的信息量极小，而一个含 10^5 参数的 LSTM 在训练集上轻松达到 $R^2 = 0.3$——这几乎全部是记忆。三个具体的防线：（1）要求「样本量 / 参数量 ≥ 10」，否则先降容量；（2）用 Deflated Sharpe Ratio 或 White's Reality Check 校正对多个模型配置的挑拣偏差（选了几十个配置中的最优，样本外表现必然被高估）；（3）任何深度模型都必须与「t 期均值」和 AR(1) 两个基线比较，若无法稳定超越，则不应上线。此外，模型在结构突变期的失效尤其危险：它不会给出警告，只会以更高置信度输出错误预测。

9.9 预测评估与 VaR 回测

9.9.1 点预测指标

设真实值为 y_i、预测值为 $\hat{y}_i$，常用的三个损失函数为

$$\mathrm{MSE}=\frac{1}{n}\sum_{i=1}^{n}(y_i-\hat{y}_i)^2,\qquad \mathrm{MAE}=\frac{1}{n}\sum_{i=1}^{n}|y_i-\hat{y}_i| \tag{9.51}$$

$$\mathrm{MAPE}=\frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{y_i-\hat{y}_i}{y_i}\right| \tag{9.52}$$

其中 n 为样本量。MSE 对大误差更敏感（适合关注方差的场景），MAE 更稳健；MAPE 在 y_i 接近零时爆炸，因此在收益率预测中几乎不可用，对价格或成交量预测才合适。此外还常用 $\mathrm{RMSE}=\sqrt{\mathrm{MSE}}$ 与样本外 $R^2=1-\mathrm{MSE}/\operatorname{Var}(y)$。

仅有指标不够，还要检验预测的*无偏性*与*有效性*：

$$y_t=a+b\hat{y}_t+u_t \tag{9.53}$$

即 Mincer–Zarnowitz 回归。理想预测应满足 $(a,b)=(0,1)$，可用联合 F 检验（或 Wald 检验）。若 $\hat{b}$ 显著小于 1，说明预测值方差过大（过度反应），把预测向样本均值收缩（乘以 $\hat{b}$）可以改进；若 a 显著非零，说明存在系统性偏差。

9.9.2 Diebold–Mariano 检验

比较两个模型时不能只看平均损失的大小，还要看差异是否显著。令 $d_t=L(e_{1t})-L(e_{2t})$（L 为平方损失或绝对损失），DM 统计量为

$$\mathrm{DM}=\frac{\bar{d}}{\sqrt{\widehat{\mathrm{LRV}}(d)/T}}\ \xrightarrow{d}\ \mathcal{N}(0,1) \tag{9.54}$$

其中 $\bar{d}$ 为损失差的样本均值、$\widehat{\mathrm{LRV}}(d)$ 为 d_t 的长期方差（用 Newey–West 等 HAC 估计量得到，滞后阶数经验取 $T^{1/3}$ 或 $4(T/100)^{2/9}$）。原假设是两个模型的期望损失相等。注意小样本下 DM 统计量偏小，Harvey 等（1997）建议使用修正版本 $DM^{*}=\mathrm{DM}\sqrt{(T+1-2h+h(h-1)/T)/T}$，其中 h 为预测步长。

例 9.4 DM 检验的数值判读

设 $T=250$，平方损失差的均值 $\bar{d}=0.021$，经 Newey–West（滞后 5 阶）估计的长期方差为 0.0625（对应标准差 0.25）。则标准误 $\mathrm{SE}(\bar{d})=\sqrt{0.0625/250}\approx 0.0158$，$\mathrm{DM}=0.021/0.0158\approx 1.33$。由于 $1.33<1.96$，在 5% 水平上不能拒绝「两模型精度相同」。此时即便模型 A 的样本外 MSE 比 B 低 3%，也不足以支持「A 更好」的结论——差异很可能来自噪声。

9.9.3 VaR 回测

如果 1% 的在险价值（Value at Risk, VaR）模型是对的，那么大约每 100 天应有 1 天损失超过 VaR。回测就是检验这个比例与集中程度。设样本长度 T、显著性水平 p、实际

例外次数为 x。

Kupiec 无条件覆盖检验（POF）的似然比统计量为

$$LR_{UC} = -2\ln\left[\frac{(1-p)^{T-x}p^{x}}{(1-x/T)^{T-x}(x/T)^{x}}\right] \sim \chi^2_1 \tag{9.55}$$

分子是「模型正确」时的似然，分母是「真实例外率等于样本例外率」时的似然。

例 9.5 Kupiec 检验：$T=1000$，$p=1\%$，$x=15$

代入 式 (9.55)：$\ln\left[(1-p)^{T-x}p^{x}\right] = 985\ln 0.99 + 15\ln 0.01 \approx -9.900 - 69.078 = -78.977$；$\ln\left[(1-\hat{p})^{T-x}\hat{p}^{x}\right] = 985\ln 0.985 + 15\ln 0.015 \approx -14.887 - 62.996 = -77.882$，其中 $\hat{p} = x/T = 0.015$。于是 $LR_{UC} = -2(-78.977 + 77.882) \approx 2.19$。$\chi^2_1$ 的 5% 临界值为 3.84，故不能拒绝「例外率等于 1%」。但另一方面，$x=15$ 是期望值 10 的 1.5 倍，样本例外率 1.5% 已经偏高；若 $x=20$，则 $LR_{UC} \approx 7.3 > 3.84$，模型将被拒绝。这说明无条件覆盖检验对中等幅度的偏离并不敏感，必须再用独立性检验补足。

Christoffersen 条件覆盖检验把例外是否成簇纳入检验。记 n_{ij} 为「t 日为状态 i、$t+1$ 日为状态 j」的转移次数（1 表示例外，0 表示未例外），$\pi_0 = n_{01}/(n_{00}+n_{01})$、$\pi_1 = n_{11}/(n_{10}+n_{11})$、$\pi = (n_{01}+n_{11})/T$：

$$LR_{ind} = -2\ln\left[\frac{(1-\pi)^{n_{00}+n_{10}}\pi^{n_{01}+n_{11}}}{(1-\pi_0)^{n_{00}}\pi_0^{n_{01}}(1-\pi_1)^{n_{10}}\pi_1^{n_{11}}}\right] \sim \chi^2_1 \tag{9.56}$$

条件覆盖统计量为 $LR_{CC} = LR_{UC} + LR_{ind} \sim \chi^2_2$。以上例的数据结构取 $n_{00}=971$、$n_{01}=14$、$n_{10}=14$、$n_{11}=1$，可算得 $LR_{ind} \approx 1.52 < 3.84$，即例外在时间上未表现出显著聚集；若换成一个在危机后才抬升波动率的迟钝模型，例外会连续出现，n_{11} 变大，LR_{ind} 将显著。

除上述两个检验外，**动态分位数检验**（dynamic quantile, DQ）把 $\mathrm{Hit}_t = \mathbf{1}_{\{y_t < -\mathrm{VaR}_t\}} - p$ 对常数、滞后 Hit 与滞后 VaR 做回归，联合检验所有系数为零，可同时检出覆盖偏差、聚集与 VaR 对信息的反应迟钝。

核心要点 9.2　评估纪律：样本外、HAC、多模型校正

预测评估必须同时满足三条要求。第一，样本外：所有指标只在从未参与拟合的区间上计算，滚动窗口重估是唯一能反映真实部署效果的方式。第二，HAC：DM 与 Mincer–Zarnowitz 的标准误必须修正自相关与异方差，否则 t 统计量被系统性高估。第三，多模型校正：若从 50 个配置中挑出最优，其样本外表现必然被高估，须用白氏 Reality Check、SPA 检验或 Deflated Sharpe Ratio 校正。

本章小结

- 弱平稳要求均值恒定、自协方差只依赖滞后；AR 的平稳性与 MA 的可逆性分别由 $\phi(z)$、$\theta(z)$ 的根全部落在单位圆外保证，二者互为对偶（小节 9.2.1）。
- Box–Jenkins 四步流程（识别 → 估计 → 诊断 → 预测）的核心是诊断闭环：残差必须既是白噪声、又不含 ARCH 效应（算法 9.1）。

- GARCH(1,1) 的长期方差为 $\omega/(1-\alpha-\beta)$，冲击半衰期为 $\ln 0.5/\ln(\alpha+\beta)$；$\alpha+\beta=0.98$ 对应约 34 个交易日（小节 9.4.2）。
- 高频数据可用已实现波动率直接度量积分方差，HAR 用日、周、月三层成分逼近长记忆，其预测 R^2 远高于收益率方向预测。
- 状态空间模型把时变参数写成状态，卡尔曼滤波的预测步与更新步可由条件正态回归推出，稳态增益由信号–噪声比决定（小节 9.6.2）。
- 协整刻画非平稳序列的长期均衡，误差修正项的系数给出回归速度与半衰期；多变量情形用 Johansen 的迹检验与最大特征值检验确定协整秩（小节 9.7.3）。
- 深度学习在金融数据的核心矛盾是低信噪比与高容量，必须依靠时序交叉验证、样本权重、正则化组合与多模型校正来控制过拟合。
- 评估不止看 MSE/MAE，还要做 Mincer–Zarnowitz 无偏性检验与 DM 检验；VaR 回测需同时通过无条件覆盖（Kupiec）与独立性（Christoffersen）检验（小节 9.9.3）。

练习与思考

1. 证明 式 (9.6) 中的 $\gamma_0=\sigma^2/(1-\phi^2)$ 与 $\rho_k=\phi^k$，并推导 式 (9.7)。当 $\phi=0.95$、$\phi=-0.85$ 时半衰期各为多少期？负号会带来怎样的路径形态？
2. 设 MA(1) 的 $\theta=2$。写出 ρ_1 并说明为什么统计软件不会报告 $\hat{\theta}=2$。若强行使用 $\theta=2$ 做预测，与使用等价的可逆表示相比会有什么差别？
3. 用 式 (9.23) 计算：$\omega=0.02$、$\alpha=0.10$、$\beta=0.85$、当前 $\sigma^2_{t+1}=3.0$ 时的 1、5、20 步方差预测，以及长期波动率与半衰期。若把模型误设为 $\alpha+\beta=0.999$，长期方差会变成多少？这说明什么？
4. 假设你有 5 分钟高频数据，用 $M=78$ 计算 RV，并分别用 $M=13$ 与 $M=468$ 计算。从微观结构噪声的角度解释三者的偏差方向，并说明为什么 5 分钟是常见的折中。
5. 用 式 (9.29) 与 式 (9.30) 推导稳态方程 $P^2+QP-QR=0$，并计算 $Q/R=4$ 时的稳态增益 K^*。若状态是随机游走，为什么 K^* 不随时间趋于零？
6. 给定 $n_{00}=950$、$n_{01}=8$、$n_{10}=8$、$n_{11}=4$、$T=1000$、$p=1\%$，分别计算 LR_{UC} 与 LR_{ind}，判断该 VaR 模型的缺陷类型（覆盖不足、聚集，或两者兼有）。
7. 设计一个实验说明随机 K 折交叉验证如何在金融时间序列上产生信息泄漏：给出标签前瞻期 $h=5$、训练集与验证集随机划分的情形下，泄漏的具体传递路径，并说明 embargo 长度应如何设定。
8. 讨论：若某模型在回测区间 2010–2019 年的 R^2 为 0.02，而在 2020 年 3 月为 -0.35，这两个数字分别反映了什么问题？你会如何调整上线决策流程？

延伸阅读

- Box, G., Jenkins, G., Reinsel, G., and Ljung, G., *Time Series Analysis: Forecasting and Control*, 5th ed., Wiley, 2015. （Box–Jenkins 流程的原始出处，识别–估计–诊断–预测的方法论源头，第 6–8 章最值得精读。）
- Hamilton, J., *Time Series Analysis*, Princeton University Press, 1994. （单位根、协整、状态空间与卡尔曼滤波的标准参考，第 17–19 章讲清 ECM 与 Johansen 检验的推导。）
- Engle, R., "Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation", *Econometrica*, 1982. （ARCH 的开创性论文，理解条件异方差建模动机的必读文献。）
- Bollerslev, T., "Generalized Autoregressive Conditional Heteroskedasticity", *Journal of Econometrics*, 1986. （GARCH 的提出，含长期方差与持续性条件的完整讨论。）
- Andersen, T., Bollerslev, T., Diebold, F., and Labys, P., "Modeling and Forecasting Realized Volatility", *Econometrica*, 2003. （已实现波动率与 HAR 家族的理论与实证基础，含高频采样频率的偏差–方差权衡。）
- Corsi, F., "A Simple Approximate Long-Memory Model of Realized Volatility", *Journal of Financial Econometrics*, 2009. （HAR 模型原文，三尺度成分的经济解释与参数稳定性证据。）
- Diebold, F., and Mariano, R., "Comparing Predictive Accuracy", *Journal of Business & Economic Statistics*, 1995. （DM 检验原文；配合 Harvey 等 1997 年的小样本修正一并阅读。）
- Christoffersen, P., "Evaluating Interval Forecasts", *International Economic Review*, 1998. （条件覆盖检验的原始文献，VaR 回测中独立性检验的标准引用。）
- Zhou, H., et al., "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting", *AAAI*, 2021；Nie, Y., et al., "A Time Series is Worth 64 Words: Long-term Forecasting with Transformers", *ICLR*, 2023. （长序列与 Patch 化建模的两篇代表作，适合理解 $O(L^2)$ 瓶颈的工程应对。）

第十章 随机过程

随机过程是量化金融的数学心脏。本章的目标是建立**连续时间不确定性的语言**：从布朗运动与伊藤积分，到跳跃过程、测度变换与 Feynman–Kac 公式。掌握这一章，第 6 章的定价结果就不再是「神秘的公式」，而是同一套数学的必然推论。

10.1 随机过程基础

10.1.1 定义与分类

随机过程是定义在概率空间上的时间索引随机变量族 $\{X_t\}_{t\in T}$。按时间索引与状态空间分类：

表 10.1 随机过程的分类与金融应用

时间 / 状态	典型过程	金融应用
离散时间、离散状态	马尔可夫链	信用评级迁移、状态转换模型
离散时间、连续状态	ARMA、GARCH	收益率与波动率的时间序列建模
连续时间、离散状态	泊松过程、Cox 过程	违约事件、交易到达、跳跃风险
连续时间、连续状态	布朗运动、扩散过程	期权定价、利率模型、组合理论

10.1.2 马尔可夫性质

若过程的未来条件分布只依赖当前状态，则称其具有马尔可夫性质：

$$\mathbb{P}\left(X_{t+s}\in A \mid \mathcal{F}_t\right)=\mathbb{P}\left(X_{t+s}\in A \mid X_t\right) \tag{10.1}$$

金融模型大量使用这一假设（例如「资产价格的未来分布只依赖当前价格」），原因是它使**条件期望成为状态与时间的函数**，从而把随机问题转化为 PDE 问题。但马尔可夫假设是一个模型选择而非事实：动量、波动率聚集与长期记忆现象都**违反**马尔可夫性，这也是需要 ARIMA、GARCH、状态空间模型的根本原因。

10.1.3 鞅与 Doob–Meyer 分解

定义 10.1　鞅与停时

适应过程 M_t 若满足 $\mathbb{E}\,|M_t| < \infty$ 且 $\mathbb{E}[M_t \mid \mathcal{F}_s] = M_s$（$s \le t$），称为鞅。随机变量 τ 若满足 $\{\tau \le t\} \in \mathcal{F}_t$ 对一切 t 成立，称为**停时**（stopping time）。

定理 10.1 (可选停止定理)　设 M_t 为鞅，τ 为停时。在适当可积条件下（例如 τ 有界，或 M 一致可积）：

$$\mathbb{E}\,[M_\tau] = \mathbb{E}\,[M_0] \tag{10.2}$$

风险警示　可选停止定理的可积条件不可省略

若去掉可积条件，会得到明显错误的结论。经典反例是「双倍下注」：每输一次就把赌注加倍，策略最终必以盈利 1 元离场，于是 $\mathbb{E}[M_\tau] > \mathbb{E}[M_0]$。问题在于该策略所需的资金无上限（$\tau$ 无界且 M 不一致可积）。**量化实践中的对应风险是：任何依赖「无限资金」或「无限次加仓」的策略（如马丁格尔、部分期权卖方策略）在有限资金下都会以小概率的巨额亏损收场。**理解这一点，比记住定理的严格条件更有实务价值。

补充说明　Doob–Meyer 分解的直观

相当广泛的一类过程可以唯一分解为「鞅 + 可料的有界变差过程」：$X_t = M_t + A_t$。在金融中，A_t 就是**可预测的漂移（收益来源）**，M_t 是**不可预测的波动（风险来源）**。把收益率分解为这两个部分，是理解「Alpha 与 Beta」「收益与风险」的数学语言。

10.2 布朗运动

10.2.1 定义与基本性质

标准布朗运动（维纳过程）W_t 满足：

1. $W_0 = 0$ 几乎必然；
2. **独立增量**：$0 \le s < t$ 时，$W_t - W_s$ 与 $\mathcal{F}_s$ 独立；
3. **平稳正态增量**：$W_t - W_s \sim \mathcal{N}(0, t-s)$；
4. **路径连续**：$t \mapsto W_t$ 以概率 1 连续。

核心要点 10.1

布朗运动有两个反直觉但极重要的性质：(1) 样本路径**处处连续但处处不可微**，因此不能用普通微积分处理，必须发展伊藤积分；(2) 在 $[0,t]$ 上的**二次变差恰好等于** t：$\langle W \rangle_t = t$。第二条是全部随机微积分的根源：它意味着 $(\mathrm{d}W_t)^2 = \mathrm{d}t$，即「随机性的平方不是高阶小量」。

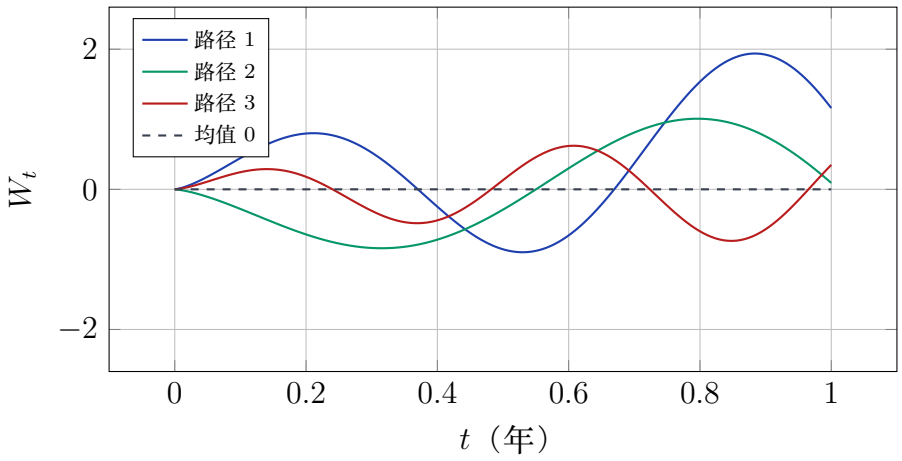


图 10.1　三条布朗运动路径：路径连续、波动幅度随 $\sqrt{t}$ 增长，且几乎必然不光滑

10.2.2　布朗运动的变换

$$\text{标度性质：}\quad cW_{t/c^2} \text{ 也是布朗运动} \tag{10.3}$$

$$\text{时间反演：}\quad tW_{1/t}\ (t>0),\ W_0=0 \text{ 也是布朗运动} \tag{10.4}$$

$$\text{反射原理：}\quad \mathbb{P}\left(\max_{0\le s\le t} W_s \ge a\right) = 2\mathbb{P}\left(W_t \ge a\right) = 2\left(1-\Phi\left(a/\sqrt{t}\right)\right) \tag{10.5}$$

由反射原理可得首达时 $\tau_a=\inf\{t: W_t=a\}$（$a>0$）的分布：

$$\mathbb{P}\left(\tau_a \le t\right) = 2\left(1-\Phi\left(\frac{a}{\sqrt{t}}\right)\right), \qquad \mathbb{E}\left[\tau_a\right]=\infty \tag{10.6}$$

直觉理解　为什么「等不到就永远等不到」

式 (10.6) 说明首达时的期望是无穷大：布朗运动平均需要无限长时间才能到达任意给定水平。这意味着（在纯布朗运动模型下）「距离某个价位只差一点」并不是买入的理由——模型的记忆是零的。**现实中之所以有人用「均值回复」或「支撑位」交易，前提是标的存在均值回复或状态依赖的漂移，而不是纯布朗运动。**区分「随机游走」与「均值回复」是随机过程建模的第一个决策，也是最关键的一个。

10.3 伊藤积分

10.3.1　构造与伊藤等距

普通黎曼积分对布朗运动不适用（路径无界变差）。伊藤积分的构造分两步：先对简单可料过程（分段常数的左连续过程）定义

$$\int_0^T \phi_t \,\mathrm{d}W_t = \sum_{i=0}^{n-1} \phi_{t_i}\left(W_{t_{i+1}} - W_{t_i}\right) \tag{10.7}$$

再通过 L^2 极限推广到一般可料过程。**取左端点(可料性)是伊藤积分区别于 Stratonovich 积分的关键，它保证了积分是鞅（而不是带漂移的过程）。**

定理 10.2 (伊藤等距) 对于满足 $\mathbb{E}\int_0^T \phi_t^2 \mathrm{d}t < \infty$ 的可料过程 ϕ，

$$\mathbb{E}\left[\left(\int_0^T \phi_t \,\mathrm{d}W_t\right)^2\right] = \mathbb{E}\left[\int_0^T \phi_t^2 \,\mathrm{d}t\right] \tag{10.8}$$

伊藤等距是蒙特卡洛定价的理论基础：**它把「积分的不确定性」转化成了「被积函数平方的时间积分」，从而给出了可控的方差表达式。**

10.3.2 伊藤引理

定理 10.3 (伊藤引理，一维) 设 X_t 满足 $\mathrm{d}X_t = \mu_t \mathrm{d}t + \sigma_t \mathrm{d}W_t$，$f(t,x) \in C^{1,2}$，则

$$\mathrm{d}f(t, X_t) = \left(\frac{\partial f}{\partial t} + \mu_t \frac{\partial f}{\partial x} + \frac{1}{2}\sigma_t^2 \frac{\partial^2 f}{\partial x^2}\right)\mathrm{d}t + \sigma_t \frac{\partial f}{\partial x}\,\mathrm{d}W_t \tag{10.9}$$

证明思路. 对 f 做二阶泰勒展开，保留到 $\mathrm{d}t$ 阶：$\mathrm{d}f = f_t \mathrm{d}t + f_x \mathrm{d}X + \frac{1}{2} f_{xx}(\mathrm{d}X)^2$。关键在于 $(\mathrm{d}X)^2 = \sigma^2 (\mathrm{d}W)^2 + O(\mathrm{d}t^{3/2}) = \sigma^2 \mathrm{d}t$（因为 $(\mathrm{d}W)^2 = \mathrm{d}t$），于是二阶项不消失，这正是一般微积分与随机微积分的分水岭。 ■

在 d 维情形下，若 $\mathrm{d}X_t^i = \mu^i \mathrm{d}t + \sum_j \sigma^{ij} \mathrm{d}W_t^j$，则

$$\mathrm{d}f = \left(\frac{\partial f}{\partial t} + \sum_i \mu^i \frac{\partial f}{\partial x_i} + \frac{1}{2}\sum_{i,j} \left(\sigma\sigma^{\top}\right)^{ij} \frac{\partial^2 f}{\partial x_i \partial x_j}\right)\mathrm{d}t + \sum_{i,j} \sigma^{ij} \frac{\partial f}{\partial x_i}\,\mathrm{d}W_t^j \tag{10.10}$$

由此得到两个核心运算规则：

$$\text{乘积法则：}\quad \mathrm{d}(X_t Y_t) = X_t \,\mathrm{d}Y_t + Y_t \,\mathrm{d}X_t + \mathrm{d}\langle X, Y\rangle_t \tag{10.11}$$

$$\text{分部积分：}\quad \int_0^T X_t \,\mathrm{d}Y_t = X_T Y_T - X_0 Y_0 - \int_0^T Y_t \,\mathrm{d}X_t - \langle X, Y\rangle_T \tag{10.12}$$

例 10.1 几何布朗运动的对数形式

设 $\mathrm{d}S_t = \mu S_t \mathrm{d}t + \sigma S_t \mathrm{d}W_t$，取 $f(S) = \ln S$。由 $f_x = 1/S$、$f_{xx} = -1/S^2$，式 (10.9) 给出

$$\mathrm{d}\ln S_t = \left(\mu - \frac{1}{2}\sigma^2\right)\mathrm{d}t + \sigma\,\mathrm{d}W_t,$$

积分得 $S_t = S_0 \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma W_t\right)$，且 $\ln S_T \sim \mathcal{N}\left(\ln S_0 + (\mu - \frac{1}{2}\sigma^2)T,\ \sigma^2 T\right)$。**注意 $-\frac{1}{2}\sigma^2$ 这一项：它说明波动率会侵蚀复合增长率——年化波动率 40% 的策略，其几何平均收益比算术平均低约 0.08（8 个百分点），这是「高波动长期跑输」的数学根源，也是波动率拖累（volatility drag）的准确表述。**

10.4 随机微分方程

10.4.1 存在唯一性

定理 10.4 (SDE 解的存在唯一性) 若 $\mu(t,x)$、$\sigma(t,x)$ 满足 Lipschitz 条件与线性增长条件：

$$|\mu(t,x)-\mu(t,y)|+|\sigma(t,x)-\sigma(t,y)|\le K\,|x-y|\,,\qquad |\mu(t,x)|+|\sigma(t,x)|\le K\,(1+|x|) \tag{10.13}$$

则 SDE $\mathrm{d}X_t=\mu(t,X_t)\mathrm{d}t+\sigma(t,X_t)\mathrm{d}W_t$ 存在唯一的强解。

补充说明　为什么金融模型经常「违规」

Black–Scholes 与 Vasicek 满足上述条件，但很多金融模型**不满足**：CIR 模型的扩散项 $\sigma\sqrt{r}$ 在 $r=0$ 处不满足 Lipschitz 条件（因此需要 Feller 条件保证非负）；Heston 的方差过程、以及各类跳跃过程都需要更弱的条件与更精细的分析。**实务含义是：这些模型在状态变量接近边界时的行为需要单独验证**——例如 CIR 在利率接近零时的数值实现必须防止出现负利率。

10.4.2 Ornstein–Uhlenbeck 过程

OU 过程是最重要的均值回复模型：

$$\mathrm{d}X_t=\theta\,(\mu-X_t)\,\mathrm{d}t+\sigma\,\mathrm{d}W_t \tag{10.14}$$

其显式解与分布为

$$X_t=\mu+(X_0-\mu)\,\mathrm{e}^{-\theta t}+\sigma\int_0^t \mathrm{e}^{-\theta(t-s)}\,\mathrm{d}W_s,\qquad X_t\sim\mathcal{N}\!\left(\mu+(X_0-\mu)\mathrm{e}^{-\theta t},\ \frac{\sigma^2}{2\theta}\left(1-\mathrm{e}^{-2\theta t}\right)\right) \tag{10.15}$$

当 $t\to\infty$ 时，X_t 收敛到**平稳分布** $\mathcal{N}\left(\mu,\ \sigma^2/(2\theta)\right)$。半衰期为 $\ln 2/\theta$。

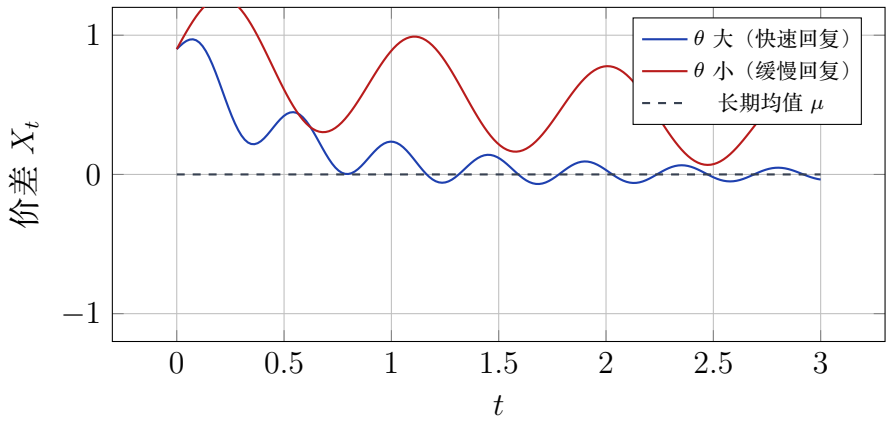


图 10.2　OU 过程：θ 决定回复速度，$\sigma^2/(2\theta)$ 决定平稳波动幅度

实务应用　OU 过程在配对交易中的完整用法

配对交易的价差常被建模为 OU 过程，参数可用 AR(1) 回归精确估计。设 $X_{t+\Delta} = a + bX_t + \varepsilon_t$，则

$$\theta = -\frac{\ln b}{\Delta}, \qquad \mu = \frac{a}{1-b}, \qquad \sigma = \mathrm{sd}(\varepsilon)\sqrt{\frac{2\theta}{1-b^2}}.$$

交易规则通常取「z 分数」$z_t = (X_t - \mu)/\sqrt{\sigma^2/(2\theta)}$：$z > 2$ 做空价差、$z < -2$ 做多价差、$|z| < 0.5$ 平仓。**三个必须检查的前提**：(1) 协整关系在样本外仍成立（用 Johansen 检验或滚动检验）；(2) 半衰期与回测周期匹配——若半衰期 60 天而策略持有期 3 天，则信号没有意义；(3) 交易成本与融券成本不能超过均值回复带来的收益，这通常是最容易忽略的一环。

Listing 10.1　布朗运动的二次变差验证与 OU 参数估计

```python
import numpy as np

def quadratic_variation(n_steps=2000, n_paths=400, T=1.0, seed=7):
    """Realised QV of W should converge to T as the grid gets finer."""
    rng = np.random.default_rng(seed)
    dt = T / n_steps
    dW = rng.standard_normal((n_paths, n_steps)) * np.sqrt(dt)
    W = np.cumsum(dW, axis=1)
    qv = np.sum(np.diff(W, axis=1, prepend=0.0) ** 2, axis=1)
    return qv.mean(), qv.std(ddof=1) / np.sqrt(n_paths), T

def estimate_ou(x, dt=1.0):
    """Estimate theta, mu, sigma of dX = theta(mu - X)dt + sigma dW by AR(1)."""
    x = np.asarray(x, dtype=float)
    x0, x1 = x[:-1], x[1:]
    b, a = np.polyfit(x0, x1, 1)          # x1 = a + b * x0 + eps
    resid = x1 - (a + b * x0)
    theta = -np.log(b) / dt
    mu = a / (1.0 - b)
    sigma = resid.std(ddof=2) * np.sqrt(2.0 * theta / (1.0 - b ** 2))
    half_life = np.log(2.0) / theta
    return dict(theta=theta, mu=mu, sigma=sigma, half_life=half_life)

print("QV test (mean, se, T):", quadratic_variation())
# Simulate an OU path and recover its parameters
rng = np.random.default_rng(1)
theta_t, mu_t, sigma_t, n = 0.35, 0.0, 0.20, 5000
x = np.zeros(n)
for t in range(1, n):
    x[t] = x[t - 1] + theta_t * (mu_t - x[t - 1]) + sigma_t * rng.standard_normal()
print("OU estimates:", {k: round(v, 4) for k, v in estimate_ou(x).items()})
```

10.5 跳跃过程

10.5.1 泊松过程与复合泊松过程

强度为 λ 的泊松过程 N_t 满足 $N_0 = 0$、独立增量、$N_t - N_s \sim \text{Poisson}\,(\lambda(t-s))$。复合泊松过程把每次跳跃的幅度也随机化：

$$J_t = \sum_{i=1}^{N_t} Y_i, \qquad Y_i \overset{\text{i.i.d.}}{\sim} F \tag{10.16}$$

10.5.2 跳跃扩散模型与 Lévy 过程

Merton（1976）在几何布朗运动上叠加复合泊松跳跃：

$$\frac{\mathrm{d}S_t}{S_{t^-}} = \left(\mu - \lambda\bar{k}\right)\mathrm{d}t + \sigma\,\mathrm{d}W_t + \mathrm{d}J_t \tag{10.17}$$

其中 $\bar{k} = \mathbb{E}[Y_i] - 1$ 为跳跃幅度的期望相对变化，$\lambda\bar{k}$ 是从漂移中扣除的补偿项（保证风险中性下期望收益率仍为 r）。

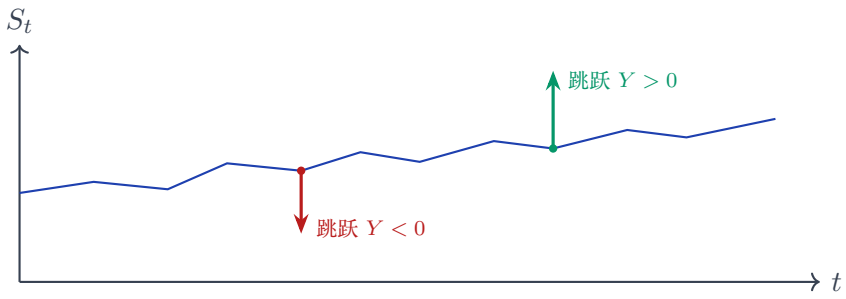


图 10.3　跳跃扩散过程：连续扩散叠加稀疏的大幅跳跃

10.5.3 二次变差与已实现方差

这是连接连续时间理论与高频数据的桥梁。对连续扩散过程，

$$\langle X\rangle_T = \lim_{|\Pi|\to 0}\sum_{i}\left(X_{t_{i+1}} - X_{t_i}\right)^2 = \int_0^T \sigma_s^2\,\mathrm{d}s \tag{10.18}$$

但当存在跳跃时，二次变差包含了跳跃的平方和：

$$\langle X\rangle_T = \int_0^T \sigma_s^2\,\mathrm{d}s + \sum_{0<s\le T}(\Delta X_s)^2 \tag{10.19}$$

核心要点 10.2

上式是高频计量经济学最重要的方程之一：它告诉我们**已实现方差（RV）估计的是「连续波动 + 跳跃」的总和，而不是「波动率」本身**。若要分离出连续部分，需要使用**双幂变差（bipower variation）**：它在跳跃存在时仍收敛到 $\int \sigma^2 \mathrm{d}s$。因此「RV 减去双幂变差」就给出了跳跃部分的估计——这是把跳跃风险纳入风险管理与波动率预测（HAR-J 模型）的标准做法（详见第 9 章）。

10.5.4 Lévy 过程与 Lévy–Khintchine 表示

Lévy 过程是具有平稳独立增量与随机连续路径的过程。其特征函数由 Lévy–Khintchine 公式给出：

$$\mathbb{E}\left[\mathrm{e}^{\mathrm{i}uX_t}\right] = \exp\left[t\left(\mathrm{i}bu - \frac{1}{2}\sigma^2 u^2 + \int_{\mathbb{R}} \left(\mathrm{e}^{\mathrm{i}ux} - 1 - \mathrm{i}ux\mathbf{1}_{\{|x|<1\}}\right)\nu(\mathrm{d}x)\right)\right] \tag{10.20}$$

其中 (b, σ^2, ν) 为特征三元组，ν 为 Lévy 测度，控制跳跃的频率与幅度分布。常见金融 Lévy 模型包括 Variance Gamma（VG）、Normal Inverse Gaussian（NIG）与 CGMY，它们的共同优势是**能用更少的参数刻画比正态更厚的尾部与更陡的短期偏斜**。

表 10.2　连续与跳跃模型的取舍

模型	能刻画的现象	代价
几何布朗运动	连续波动、对数正态	无法生成微笑与偏斜
跳跃扩散（Merton）	短期偏斜、微笑	校准参数增多；风险不完全可对冲
随机波动率（Heston）	期限结构、波动率聚集	短期微笑拟合能力有限
Lévy 过程（VG/NIG/CGMY）	多期限尾部形状	参数经济含义弱，校准不稳定
跳跃 + 随机波动率	最接近市场曲面	计算量大，模型风险与过拟合风险高

10.6 鞅表示与市场完备性

定理 10.5 (鞅表示定理)　在布朗运动生成的（完备）信息流下，任意平方可积鞅 M_t 都可以表示为

$$M_t = M_0 + \int_0^t H_s \,\mathrm{d}W_s \tag{10.21}$$

该定理保证了完备市场中所有未定权益都可以由标的与现金**动态复制**（Delta 对冲），也保证了「无套利价格 = 复制成本」这一等价关系的严格性。

表 10.3　市场完备性的判定

情形	判定	例子
$n \geq d$（可交易资产数不少于风险源数）	市场完备，$\mathbb{Q}$ 唯一	BSM：1 个资产、1 个风险源
$n < d$	市场不完备，$\mathbb{Q}$ 不唯一	Heston：1 个资产、2 个风险源

直觉理解　不完备市场为什么会给出一段价格区间

在 Heston 模型中，波动率风险无法用标的完全对冲。不同投资者对「波动率风险值多少钱」有不同看法，于是**每一个看法都对应一个合法的等价鞅测度，也就对应一个「无套利」的期权价格**。市场之所以能达成一个价格，是因为存在期权本身作为交易工具（加入期权后市场重新完备）。这解释了一个看似矛盾的现象：**「期权价格由期权市场的供需与波动率风险溢价决定」在数学上并不是缺陷，而是不完备性的必然结果**。

10.7 测度变换与 Feynman–Kac 公式

10.7.1　Girsanov 定理

定理 10.6 (Girsanov)　设 λ_t 满足 Novikov 条件 $\mathbb{E}^{\mathbb{P}}\left[\exp\left(\frac{1}{2}\int_0^T \lambda_s^2 \mathrm{d}s\right)\right] < \infty$，定义 $\frac{\mathrm{d}\mathbb{Q}}{\mathrm{d}\mathbb{P}}\big|_{\mathcal{F}_t} = \mathcal{E}\left(-\int_0^{\cdot} \lambda_s \mathrm{d}W_s^{\mathbb{P}}\right)_t$，则

$$W_t^{\mathbb{Q}} = W_t^{\mathbb{P}} + \int_0^t \lambda_s \, \mathrm{d}s \tag{10.22}$$

是 $\mathbb{Q}$ 下的标准布朗运动。在金融中 $\lambda_t = (\mu_t - r)/\sigma_t$，**即风险的市场价格（等于夏普比率）**。

补充说明　与第 6 章的符号约定一致

本书统一采用 式 (10.22) 的约定：密度过程带负号、布朗运动平移带正号。第 6 章的测度变换定义与 Girsanov 表述采用完全相同的形式。**读者在阅读其他文献时会遇到符号相反的等价写法（密度带正号、平移带负号），两者都对，只要在同一处保持一致即可**。

代入可得 $\mathbb{Q}$ 下标的动态：$\mathrm{d}S_t = rS_t\mathrm{d}t + \sigma S_t \mathrm{d}W_t^{\mathbb{Q}}$。**漂移从 μ 变为 r，波动率 σ 完全不变**——这正是「风险中性化只改漂移」的准确含义。

10.7.2　Feynman–Kac 公式

定理 10.7 (Feynman–Kac)　若 $u(t,x)$ 满足带源项的抛物型 PDE

$$\frac{\partial u}{\partial t} + \mu(t,x)\frac{\partial u}{\partial x} + \frac{1}{2}\sigma^2(t,x)\frac{\partial^2 u}{\partial x^2} - r(t,x)u + f(t,x) = 0, \qquad u(T,x) = g(x) \tag{10.23}$$

则

$$u(t,x)=\mathbb{E}\left[\int_t^T \mathrm{e}^{-\int_t^s r(\tau,X_\tau)\mathrm{d}\tau} f(s,X_s)\,\mathrm{d}s+\mathrm{e}^{-\int_t^T r(\tau,X_\tau)\mathrm{d}\tau} g(X_T)\;\middle|\; X_t=x\right] \tag{10.24}$$

核心要点 10.3

Feynman–Kac 公式是量化金融的「罗塞塔石碑」：它把**偏微分方程（PDE）、随机微分方程（SDE）与条件期望**三种表述连接为同一件事。由此可以得到三个实用推论：(1) 能用 PDE 数值方法（有限差分）解的，也能用蒙特卡洛解，反之亦然——选择取决于维度；(2) 第 6 章的风险中性定价公式正是 $f=0$、r 常数时的特例；(3) 含「连续收益流」（如分红、票息、持有成本）的产品可以用 $f\neq 0$ 直接处理。

10.8 随机控制与美式期权

10.8.1 HJB 方程与 Merton 问题

动态规划原理把最优控制问题转化为 **Hamilton–Jacobi–Bellman（HJB）方程**。以 Merton（1969, 1971）的连续时间消费–投资问题为例：

$$\max_{c_t,\ \pi_t}\ \mathbb{E}\left[\int_0^T \mathrm{e}^{-\rho t}U(c_t)\,\mathrm{d}t+U(W_T)\right] \tag{10.25}$$

在 CRRA 效用 $U(c)=c^{1-\gamma}/(1-\gamma)$ 下，最优股票配置为

$$\pi^{*}=\frac{\mu-r}{\gamma\sigma^{2}},\qquad \text{等价地}\qquad \pi^{*}=\frac{1}{\gamma}\cdot\frac{\text{夏普比率}}{\text{波动率}} \tag{10.26}$$

直觉理解　Merton 比率的可读性

式 (10.26) 说明最优仓位与**夏普比率成正比、与波动率成反比、与风险厌恶成反比**。若 $\mu-r=6\%$、$\sigma=20\%$、$\gamma=3$，则 $\pi^{*}=1.5$（150% 仓位，需要杠杆）。这个公式的实务价值在于它把「该不该加杠杆」变成了一道可计算题：要么提高夏普比率（选股），要么降低波动率（分散），要么降低风险厌恶（但那是心理参数，难以改变）。注意该解假设投资机会集恒定——一旦引入随机利率或随机波动率，最优仓位会变成状态依赖的，这就是「择时」在理论上的位置。

10.8.2 Snell 包络与美式期权

美式期权的最优行权问题是一个**最优停时**问题，其价值由 Snell 包络给出：

$$V_t=\sup_{\tau\in\mathcal{T}_{t,T}}\ \mathbb{E}^{\mathbb{Q}}\left[\mathrm{e}^{-r(\tau-t)}H(X_\tau)\mid\mathcal{F}_t\right] \tag{10.27}$$

即「在所有停时上取下确界」。这一定义解释了为什么美式期权定价比欧式困难：它需要在**整个时间维度上做最优决策**，等价于一个自由边界问题（Free Boundary Problem）。

树方法与有限差分通过逐层比较「继续持有 vs 立即行权」隐式求解；LSM 则用回归近似继续持有价值（算法见第 6 章）。

本章小结

- 马尔可夫性把随机问题化为 PDE；鞅刻画「公平博弈」；停时的可积条件不可省略（马丁格尔反例）。
- 布朗运动连续但处处不可微，二次变差 $\langle W\rangle_t = t$ 是随机微积分的根源。
- 伊藤引理的核心是保留二阶项：$\mathrm{d}f = f_t\mathrm{d}t + f_x\mathrm{d}X + \frac{1}{2}f_{xx}(\mathrm{d}X)^2$，由此得到乘积法则与分部积分公式。
- OU 过程是均值回复的标准模型，参数可用 AR(1) 回归估计，半衰期 $\ln 2/\theta$ 决定策略周期。
- 跳跃使二次变差包含跳跃平方和；双幂变差可以分离连续波动与跳跃，这是已实现波动率研究（第 9 章）的基础。
- 鞅表示定理给出完备市场中的动态复制；$n < d$ 时不完备，$\mathbb{Q}$ 不唯一，价格成为区间。
- Girsanov 定理（本书统一符号约定）说明测度变换只改漂移；Feynman–Kac 连接 PDE、SDE 与期望。
- HJB 方程给出连续时间最优控制（Merton 比率）；Snell 包络刻画美式期权的最优行权。

练习与思考

1. 用伊藤引理计算 $\mathrm{d}\left(W_t^2\right)$ 与 $\mathrm{d}\left(\mathrm{e}^{aW_t}\right)$，并由此验证 $\mathbb{E}\left[W_t^2\right] = t$、$\mathbb{E}\left[\mathrm{e}^{aW_t}\right] = \mathrm{e}^{a^2t/2}$。
2. 证明布朗运动的首达时 τ_a 满足 $\mathbb{P}(\tau_a \le t) = 2\left(1 - \Phi\left(a/\sqrt{t}\right)\right)$（提示：使用反射原理），并说明为什么 $\mathbb{E}[\tau_a] = \infty$ 与该分布在 $t \to \infty$ 时的衰减速度有关。
3. 设 $\mathrm{d}X_t = \theta(\mu - X_t)\mathrm{d}t + \sigma\mathrm{d}W_t$，$\theta = 0.4$、$\mu = 0$、$\sigma = 0.25$。求平稳分布、半衰期，以及「从 $X_0 = 1$ 出发回复到 0.5 以内」所需时间的期望近似值。
4. 已知某高频数据的已实现方差 $RV = 0.048$、双幂变差 $BV = 0.036$（年化）。请估计连续波动部分与跳跃部分，并说明为什么两者之和与 RV 的差异可以作为跳跃检验统计量。
5. 对 Heston 模型（1 个可交易资产、2 个风险源），解释为什么市场不完备，并说明「加入方差互换作为可交易资产」后市场如何重新完备。
6. 用 Merton 比率公式回答：若某策略的夏普比率 0.8、波动率 25%，风险厌恶系数 4，最优仓位是多少？若希望把仓位限制在 100% 以内，在风险厌恶不变的前提下需要把波动率降到多少？

延伸阅读

- Karatzas, I., and Shreve, S. E., *Brownian Motion and Stochastic Calculus*, 2nd ed., Springer, 1991.（随机分析的严格参考，鞅论与伊藤积分的标准出处）
- Øksendal, B., *Stochastic Differential Equations: An Introduction with Applications*, 6th ed., Springer, 2003.（SDE 与 HJB 的经典教材，Merton 问题讲得很清楚）
- Shreve, S. E., *Stochastic Calculus for Finance II: Continuous-Time Models*, Springer, 2004.（最适合量化从业者的入门到进阶路径）
- Cont, R., and Tankov, P., *Financial Modelling with Jump Processes*, Chapman & Hall/CRC, 2004.（跳跃与 Lévy 过程的系统教材）
- Applebaum, D., *Lévy Processes and Stochastic Calculus*, 2nd ed., Cambridge University Press, 2009.（Lévy–Khintchine 表示的严格处理）
- Merton, R. C., "Optimum Consumption and Portfolio Rules in a Continuous-Time Model", *Journal of Economic Theory*, 1971, 3(4): 373–413.（连续时间最优控制的奠基论文）
- Andersen, T. G., Bollerslev, T., Diebold, F. X., and Labys, P., "Modeling and Forecasting Realized Volatility", *Econometrica*, 2003, 71(2): 579–625.（已实现波动率的理论与实证，连接本章与第 9 章）

第十一章 组合优化

前面几章分别解决了「预测什么」和「风险多大」的问题：因子模型给出预期收益与风险结构的估计，随机过程给出衍生品的定价与对冲。本章处理投资流程的最后一环——**组合优化**（portfolio optimization）：把预测信号、风险模型与各类现实约束，翻译成一组可执行的持仓权重 $\boldsymbol{w}$。这一步之所以困难，不在于最优化算法，而在于输入参数几乎总是估计值：一个被低估的协方差逆矩阵会把 1% 的收益预测放大成 30% 的极端权重。本章既给出经典模型的完整推导，也给出让模型在样本外存活下来的工程手段。

11.1 记号、问题设定与目标

11.1.1 从信号到权重

量化流程通常分三层：第一层是**信号**（signal），即对未来收益的预测，例如因子的 IC 加权合成值；第二层是**风险模型**（risk model），即协方差矩阵 $\boldsymbol{\Sigma}$ 的估计；第三层才是**组合构建**（portfolio construction），把二者与约束一起转成权重。同一套信号配上不同的组合构建方法，样本外信息比率可以相差 0.3 以上，因此这一层绝非「把信号除以波动率」这么简单。

定义 11.1　均值-方差组合问题

设有 N 个风险资产，权重向量为 $\boldsymbol{w}\in\mathbb{R}^N$，预期收益向量为 $\boldsymbol{\mu}\in\mathbb{R}^N$，协方差矩阵为 $\boldsymbol{\Sigma}\in\mathbb{R}^{N\times N}$ 且正定。投资者在预算约束下最大化「期望收益减去风险惩罚」：

$$\max_{\boldsymbol{w}} \quad \boldsymbol{w}^{\top}\boldsymbol{\mu}-\frac{\lambda}{2}\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w} \qquad \text{s.t.} \quad \mathbf{1}^{\top}\boldsymbol{w}=1 \tag{11.1}$$

其中 $\lambda>0$ 为**风险厌恶系数**，数值越大表示单位方差的边际收益要求越高；$\mathbf{1}$ 为全 1 向量。若允许持有现金，预算约束改为 $\mathbf{1}^{\top}\boldsymbol{w}\le 1$；若允许做空，则去掉 $\boldsymbol{w}\ge\mathbf{0}$。

组合的期望收益与方差分别为 $\mu_p=\boldsymbol{w}^{\top}\boldsymbol{\mu}$ 与 $\sigma_p^2=\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w}$，因此 式 (11.1) 等价于「在给定方差下最大化收益」的原始马科维茨表述。把 式 (11.1) 写成拉格朗日函数并利用 $\boldsymbol{\Sigma}$ 的对称性求导：

$$\mathcal{L}(\boldsymbol{w},\gamma)=\boldsymbol{w}^{\top}\boldsymbol{\mu}-\frac{\lambda}{2}\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w}-\gamma\left(\mathbf{1}^{\top}\boldsymbol{w}-1\right) \tag{11.2}$$

$$\frac{\partial\mathcal{L}}{\partial\boldsymbol{w}}=\boldsymbol{\mu}-\lambda\boldsymbol{\Sigma}\boldsymbol{w}-\gamma\mathbf{1}=\mathbf{0} \quad\Longrightarrow\quad \boldsymbol{w}=\frac{1}{\lambda}\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-\gamma\mathbf{1}\right) \tag{11.3}$$

把上式代入约束 $\mathbf{1}^{\top}\boldsymbol{w}=1$，记 $A=\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\mathbf{1}$、$B=\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$，得到 $B-\gamma A=\lambda$，即 $\gamma=(B-\lambda)/A$。整理后得到与风险厌恶无关的分解：

$$\boldsymbol{w}^{*}=\underbrace{\frac{\boldsymbol{\Sigma}^{-1}\mathbf{1}}{\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\mathbf{1}}}_{\boldsymbol{w}_{\text{gmvp}}}+\frac{1}{\lambda}\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-\frac{B}{A}\mathbf{1}\right) \tag{11.4}$$

第一项是**全局最小方差组合**（global minimum variance portfolio，GMVP），只依赖 $\boldsymbol{\Sigma}$，与预期收益完全无关；第二项是「基于预期收益的投机性倾斜」，其幅度与 $1/\lambda$ 成正比。当 $\lambda\to\infty$ 时权重收敛到 GMVP，当 $\lambda\to 0$ 时权重发散（需要无限杠杆），这就是式 (11.4) 的失效边界。

11.1.2 有效前沿的解析式

记 $C=\boldsymbol{\mu}^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$、$D=AC-B^{2}>0$（$\boldsymbol{\Sigma}$ 正定且 $\boldsymbol{\mu}$ 不与 $\mathbf{1}$ 共线时成立）。对任意目标收益 μ_p，最小方差组合为 $\boldsymbol{w}(\mu_p)=\boldsymbol{w}_g+\mu_p\boldsymbol{w}_h$，其中

$$\boldsymbol{w}_g=\frac{1}{D}\left(C\,\boldsymbol{\Sigma}^{-1}\mathbf{1}-B\,\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}\right),\qquad \boldsymbol{w}_h=\frac{1}{D}\left(A\,\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}-B\,\boldsymbol{\Sigma}^{-1}\mathbf{1}\right) \tag{11.5}$$

对应的方差为 $\sigma_p^{2}(\mu_p)=\left(A\mu_p^{2}-2B\mu_p+C\right)/D$，解出 μ_p 即得**有效前沿**（efficient frontier）的双曲线形式：

$$\mu_p=\frac{B}{A}\pm\sqrt{\frac{D}{A}}\sqrt{\sigma_p^{2}-\frac{1}{A}},\qquad \sigma_p^{2}\geq\frac{1}{A} \tag{11.6}$$

其中 $\pm$ 的上支（取正号）为有效前沿，下支为「无效边界」——同样方差下收益更低的组合。由式 (11.6) 可直接读出三个几何事实：顶点在 $(\sigma_p,\mu_p)=(1/\sqrt{A},\,B/A)$，即 GMVP；双曲线的渐近线斜率为 $\sqrt{D/A}$，代表高收益端每增加一单位风险的收益补偿；σ_p 关于 μ_p 是凸函数，这正是「分散化免费午餐」的数学表达。

直觉理解　为什么前沿是双曲线

协方差矩阵的二次型在权重空间中是一个椭球。预算约束 $\mathbf{1}^{\top}\boldsymbol{w}=1$ 是一个超平面，它与椭球相切的位置就是最小方差组合；随着目标收益平移这个超平面，切点扫出的轨迹在 (σ_p,μ_p) 平面上必然是双曲线的一支。直觉上，椭圆—双曲线的对偶关系说明：约束是线性的，而目标含二次项，因此前沿永远不会是直线（除非只有一个资产）。

11.1.3 无风险资产、切点组合与两基金分离

引入无风险资产（收益 r_f）后，投资者的可行集变成从点 $(0,r_f)$ 出发、与双曲线相切的直线，称为**资本市场线**（capital allocation line）。切点对应的风险组合称为**切点组合**（tangency portfolio），它最大化夏普比率：

$$\boldsymbol{w}_{\tan}=\frac{\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-r_f\mathbf{1}\right)}{\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-r_f\mathbf{1}\right)},\qquad \max_{\boldsymbol{w}}\ \frac{\mu_p-r_f}{\sigma_p}=\sqrt{\left(\boldsymbol{\mu}-r_f\mathbf{1}\right)^{\top}\boldsymbol{\Sigma}^{-1}\left(\boldsymbol{\mu}-r_f\mathbf{1}\right)} \tag{11.7}$$

其中 $\boldsymbol{\mu} - r_f \mathbf{1}$ 为超额收益向量，分母为超额收益的归一化因子。式 (11.7) 右侧的平方根常记为 $\mathrm{SR}_{\max}$，它同时是 式 (11.6) 中双曲线渐近线在「每单位风险收益」意义上的最优值。

定理 11.1 (两基金分离定理) 设 $\boldsymbol{\Sigma}$ 正定、$\boldsymbol{\mu}$ 与 $\mathbf{1}$ 不共线。

1. 任意两个不同的前沿组合 $\boldsymbol{w}_a$、$\boldsymbol{w}_b$ 可以生成整条前沿：$\boldsymbol{w}(\theta) = (1-\theta)\boldsymbol{w}_a + \theta \boldsymbol{w}_b$，$\theta \in \mathbb{R}$。
2. 存在无风险资产时，任何有效组合均可写成现金与切点组合的线性组合 $\boldsymbol{w}(\theta) = (1-\theta)\boldsymbol{w}_{\tan}$，$\theta$ 由风险偏好 λ 决定，且 $\theta = \mathrm{SR}_{\max}/(\lambda \sigma_{\tan})$。

证明. 第一部分的思路：由 式 (11.5) 知任意前沿组合是 $\boldsymbol{w}_g$ 与 $\boldsymbol{w}_h$ 的仿射组合，而 $\boldsymbol{w}_g, \boldsymbol{w}_h$ 张成二维仿射空间；两个不同前沿组合的差与 $\boldsymbol{w}_g, \boldsymbol{w}_h$ 的差平行，因此可以互相线性表出。第二部分的思路：切点组合与现金的组合在 (σ_p, μ_p) 平面上扫过资本市场线，而对给定 λ 的最优解必然落在资本市场线上（否则沿该直线移动可在同方差下提高收益），故其风险部分只能正比于 $\boldsymbol{w}_{\tan}$。 ■

核心要点 11.1　核心要点：有效前沿与切点组合

有效前沿由 $(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 完全决定，其解析式为 $\sigma_p^2(\mu_p) = (A\mu_p^2 - 2B\mu_p + C)/D$；引入无风险资产后，所有理性投资者持有同一个风险组合 $\boldsymbol{w}_{\tan} \propto \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu} - r_f \mathbf{1})$，差异只体现在现金比例上。这一结论对 $\boldsymbol{\mu}$ 的估计误差极其敏感：$\boldsymbol{\mu}$ 的一个标准差噪声会在 $\boldsymbol{\Sigma}^{-1}$ 的作用下被放大为成倍的权重误差（见 小节 11.2.2）。

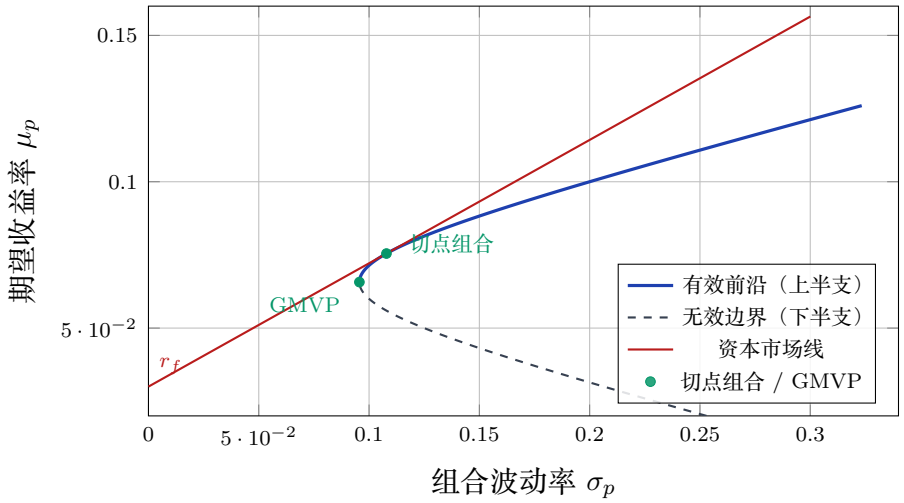


图 11.1　有效前沿、资本市场线与切点组合（两资产算例：$\sigma = (0.20, 0.10)$，$\rho = 0.2$，$\mu = (0.10, 0.06)$，$r_f = 0.03$）。切点组合位于 $(0.1079, 0.0755)$，其夏普比率为 0.4214，即资本市场线的斜率

图 11.1 用两资产算例画出全部几何要素。注意无效边界（虚线）在图形上是实曲线的一部分，但它永远不该被持有：相同波动率下，上半支的收益严格更高。实务中「最小方差组合」这一品牌产品的持仓恰好是图中的 GMVP 点，即 $(\sigma_p, \mu_p) = (9.56\%, 6.57\%)$，完全不需要任何收益预测。

11.2 估计误差与错误放大

11.2.1 样本估计的噪声

设真实收益服从 $r_t \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，用 T 期样本估计：

$$\hat{\boldsymbol{\mu}} = \frac{1}{T}\sum_{t=1}^{T} r_t, \qquad \hat{\boldsymbol{\Sigma}} = \frac{1}{T-1}\sum_{t=1}^{T}(r_t-\hat{\boldsymbol{\mu}})(r_t-\hat{\boldsymbol{\mu}})^{\top} \tag{11.8}$$

其中 r_t 为第 t 期的 N 维收益向量。$\hat{\boldsymbol{\mu}}$ 的标准误为 $\sigma_i/\sqrt{T}$：以年化波动率 20% 的股票为例，用 5 年（60 个月）月度数据估计年化期望收益，其标准误约为 $20\%/\sqrt{5} \approx 8.9\%$，与股票本身的长期超额收益同量级。换言之，**预期收益的估计信噪比通常小于 1**，而波动率与协方差的估计信噪比要高一个量级（协方差的标准误大致按 $\sqrt{2/T}$ 衰减）。

11.2.2 错误放大机制

考虑无约束版本 $\boldsymbol{w}^{*} = \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}/\lambda$。用 $\hat{\boldsymbol{\mu}} = \boldsymbol{\mu} + \varepsilon$ 代入，权重误差为 $\Delta\boldsymbol{w} = \boldsymbol{\Sigma}^{-1}\varepsilon/\lambda$，其协方差为 $\boldsymbol{\Sigma}^{-1}\mathrm{Var}(\varepsilon)\boldsymbol{\Sigma}^{-1}/\lambda^2$。在 $\varepsilon \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}/T)$ 下，$\mathrm{Var}(\Delta\boldsymbol{w}) = \boldsymbol{\Sigma}^{-1}/(\lambda^2 T)$，故组合层面的方差误差为

$$\mathbb{E}\left[\Delta\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\,\Delta\boldsymbol{w}\right] = \frac{1}{\lambda^2 T}\,\mathrm{tr}\left(\boldsymbol{\Sigma}^{-1}\boldsymbol{\Sigma}\right) = \frac{N}{\lambda^2 T} \tag{11.9}$$

其中 N 为资产数，T 为样本期数，λ 为风险厌恶系数。式 (11.9) 表明：**资产池扩大一倍，权重误差的能量也扩大一倍，与资产之间的相关性无关**。这就是「错误放大」（error maximization）的最简洁表达。

更有意义的是它对效用的影响。在无约束问题中，真最优组合的确定性等价为

$$\mathrm{CE}^{*} = \frac{\boldsymbol{\mu}^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}}{2\lambda},$$

而使用估计值 $\hat{\boldsymbol{\mu}}$ 所得组合的真实确定性等价为

$$\mathbb{E}\left[\mathrm{CE}(\hat{\boldsymbol{w}})\right] = \mathrm{CE}^{*} - \frac{N}{2\lambda T} \tag{11.10}$$

即期望效用损失恰为 $N/(2\lambda T)$。这个式子是本章最实用的数量级直觉：$N = 500$、$T = 60$（月）、$\lambda = 5$ 时，年化意义上的效用损失相当于白白损失约 $500/(2\times 5\times 60) = 0.83$，即接近 83% 的风险惩罚单位；把 T 提高到 240（20 年月度数据）则降到 0.21。降低 N（用因子或聚类压缩资产空间）、提高 T（更长的历史或用高频数据）、提高 λ（更保守）是三条并行有效的路径。

例 11.1　错误放大的数值演示

设两个资产：真实 $\boldsymbol{\mu} = (0.06, 0.06)$、$\sigma = (0.20, 0.20)$、$\rho = 0.9$，$\lambda = 4$，$T = 60$。此

时 $\boldsymbol{\Sigma}^{-1}$ 的条件数为

$$\kappa(\boldsymbol{\Sigma}) = \frac{1+\rho}{1-\rho} = \frac{1.9}{0.1} = 19$$

由于真实均值相同，$\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$ 恰为等权方向，理论上不应有任何「倾斜」。若估计误差使 $\hat{\boldsymbol{\mu}} = (0.06 + 0.02,\ 0.06)$，则 $\Delta\boldsymbol{\mu} = (0.02, 0)$，倾斜权重为

$$\Delta \boldsymbol{w} = \frac{1}{\lambda}\boldsymbol{\Sigma}^{-1}\Delta\boldsymbol{\mu} = \frac{1}{4}\cdot\frac{1}{0.04^2(1-0.9^2)}\begin{pmatrix} 0.04 & -0.036 \\ -0.036 & 0.04 \end{pmatrix}\begin{pmatrix} 0.02 \\ 0 \end{pmatrix} \approx \begin{pmatrix} 0.263 \\ -0.237 \end{pmatrix}$$

一个 2% 的均值估计误差（约为真实收益的 1/3）就制造了 26% 的超配与 24% 的低配。若 ρ 升到 0.99，同样误差会放大到 ±65% ——**相关性越高，$\boldsymbol{\Sigma}^{-1}$ 的条件数越大，同样的预测误差造成的持仓越极端。**

⚠ 风险警示　均值-方差优化的失效条件

- **$\boldsymbol{\mu}$ 不可靠**：当 N 与 T 同阶或 $N > T$ 时，样本均值几乎全是噪声，优化器会系统性做多「被高估」的资产、做空「被低估」的资产，样本外表现常劣于等权。
- **$\boldsymbol{\Sigma}$ 奇异或病态**：$N > T$ 时 $\hat{\boldsymbol{\Sigma}}$ 秩亏，$\boldsymbol{\Sigma}^{-1}$ 不存在；即使 $N < T$，样本特征值的离散度也被 Marchenko–Pastur 律高估——当 $N/T = q$ 时，纯噪声矩阵的特征值张成区间 $[\sigma^2(1-\sqrt{q})^2, \sigma^2(1+\sqrt{q})^2]$，$q = 0.2$ 时上下界之比已达 6.9 倍，而真实的条件数可能是 1。
- **正态假设**：前沿公式依赖二次型，厚尾与跳跃会使真实极端损失远超 σ_p 所隐含的水平。
- **单期假设**：式 (11.1) 是一次性决策，忽略再平衡成本、路径依赖与流动性约束。

ℹ 补充说明　样本夏普比率的偏误

在真实夏普比率为 0 的零假设下，N 个独立策略、T 期样本内最大夏普比率的期望约为 $\sqrt{2\ln N/T}$。取 $N = 100$、$T = 120$，该值约为 0.28。这意味着「回测夏普 0.28」完全可能来自纯噪声，评估因子时必须扣除这一多重检验偏差（详见第 7 章回测方法论）。

11.3 收缩估计与结构化协方差

11.3.1　Ledoit–Wolf 收缩

既然样本协方差在 N/T 不可忽略时系统性失真，最直接的补救是把它向一个结构简单、稳定但可能有偏的目标矩阵 F 收缩：

$$\hat{\boldsymbol{\Sigma}}_{\text{LW}} = \delta F + (1-\delta)\hat{\boldsymbol{\Sigma}}, \qquad \delta \in [0,1] \tag{11.11}$$

其中 F 为**目标矩阵**（target），δ 为**收缩强度**（shrinkage intensity）。$\delta = 0$ 退化为样本

估计，$\delta = 1$ 完全采用先验结构。常用目标为常数相关矩阵 $F_{ii} = \hat{\sigma}_i^2$、$F_{ij} = \hat{\rho}\,\hat{\sigma}_i\hat{\sigma}_j$（$\hat{\rho}$ 为样本相关系数均值），或单因子目标 $F = \hat{\sigma}^2\left[\beta\beta^\top\right]$ + 对角项。

Ledoit–Wolf（2004）给出的最优收缩强度为最小化 $\mathbb{E}\left\|\delta F + (1-\delta)\hat{\boldsymbol{\Sigma}} - \boldsymbol{\Sigma}\right\|_F^2$ 的解：

$$\delta^* = \frac{\pi - \rho}{\gamma}, \qquad \pi = \sum_{i,j}\operatorname{Var}\left(\hat{\Sigma}_{ij}\right), \quad \rho = \sum_{i,j}\operatorname{Cov}\left(\hat{\Sigma}_{ij}, F_{ij}\right), \quad \gamma = \sum_{i,j}\left(F_{ij} - \hat{\Sigma}_{ij}\right)^2 \tag{11.12}$$

其中 π 度量样本协方差本身的噪声总量，ρ 度量噪声与目标之间的协方差，γ 是目标与样本之间的「结构距离」。直觉上，当样本噪声 π 相对结构距离 γ 很大时，δ^* 趋近 1，即完全信任结构。π 与 ρ 可用样本四阶矩一致估计，故 式 (11.12) 是数据驱动的，不含主观参数。

实务应用　实务中的用法

主流风险模型（如 Barra/Axioma 一类）并不直接收缩整个矩阵，而是「结构化 + 收缩」并用：先用因子结构把协方差分解为低秩因子部分与对角特质部分，再对特质方差按行业与市值分组收缩（贝叶斯收缩到组内中位数），最后对相关系数矩阵做特征值修正（将小于阈值的特征值拉平）。这样做的效果与等价的 Ledoit–Wolf 收缩相近，但保留了因子暴露的可解释性，便于施加因子约束。

11.3.2　因子协方差

若收益由 K 个因子解释（$K \ll N$），则 $r = Bf + u$，其中 B 为 $N \times K$ 因子载荷矩阵，f 为因子收益，u 为特质收益（$\operatorname{Cov}(f,u) = 0$，$\operatorname{Var}(u) = D$ 对角）。协方差为

$$\boldsymbol{\Sigma} = B\,\boldsymbol{\Sigma}_f\,B^\top + D \tag{11.13}$$

参数个数由 $O(N^2)$ 降到 $O(NK + N)$。取逆可由 Woodbury 公式高效完成：

$$\boldsymbol{\Sigma}^{-1} = D^{-1} - D^{-1}B\left(\boldsymbol{\Sigma}_f^{-1} + B^\top D^{-1}B\right)^{-1}B^\top D^{-1} \tag{11.14}$$

括号内是 $K \times K$ 小矩阵，因此 $N = 3000$、$K = 60$ 时求逆代价从 $O(N^3)$ 降到 $O(NK^2)$ 量级。因子模型的另一个好处是把组合风险分解为因子风险 $B^\top\boldsymbol{w}$ 与特质风险，使「风格暴露约束」可以直接写成对 $B^\top\boldsymbol{w}$ 的线性约束。

11.3.3　EWMA 与 DCC

等权历史协方差对所有观测一视同仁，但波动率具有聚集性与长记忆性。指数加权移动平均（EWMA）用衰减因子 λ 给近期观测更高权重：

$$\boldsymbol{\Sigma}_t = (1-\lambda)\,r_{t-1}r_{t-1}^\top + \lambda\,\boldsymbol{\Sigma}_{t-1}, \qquad \boldsymbol{\Sigma}_t = (1-\lambda)\sum_{k=1}^{\infty}\lambda^{k-1}r_{t-k}r_{t-k}^\top \tag{11.15}$$

其中 $\lambda \in (0,1)$ 为衰减因子。RiskMetrics 取 $\lambda = 0.94$（日频）、0.97（月频），对应波动的半衰期 $\ln 0.5 / \ln \lambda$ 分别为约 11 天与 23 个月。EWMA 的局限是把相关系数也一并平滑，且不保证正定（在高维下需强制修正）。

动态条件相关（DCC，Engle 2002）采用两步法：先对每个资产用 GARCH 拟合条件方差，得到标准化残差 z_t；再对 z_t 的「伪相关矩阵」施加同一标量 EWMA/GARCH 动态：

$$Q_t = (1 - a - b)\bar{Q} + a\, z_{t-1} z_{t-1}^{\top} + b\, Q_{t-1}, \qquad R_t = \operatorname{diag}(Q_t)^{-1/2}\, Q_t\, \operatorname{diag}(Q_t)^{-1/2} \tag{11.16}$$

其中 $\bar{Q}$ 为 z_t 的无条件相关矩阵，$a, b \geq 0$ 且 $a + b < 1$ 保证平稳性。R_t 的对角线被强制为 1，条件协方差为 $\boldsymbol{\Sigma}_t = D_t R_t D_t$（$D_t = \operatorname{diag}(\sigma_{i,t})$）。DCC 的核心直觉是「波动率与相关性同向变动」：危机期间 a 主导，相关性整体抬升，组合分散化效果同时衰减——2008 年与 2020 年 3 月的数据都反复验证了这一点。

表 11.1　协方差矩阵估计方法对比

方法	参数个数	优点	失效条件
样本协方差	$O(N^2)$	无偏、计算简单	N/T 大时病态、噪声大、不可逆
常数相关收缩	$O(1)$ 收缩 $+O(N^2)$	大幅降低条件数、几乎无主观参数	真实相关结构异质（如危机相关性）时目标失真
单因子收缩	$O(N)$	与 CAPM 一致、易解释	多因子结构下特质部分被过度收缩
因子协方差	$O(NK)$	参数少、可施加因子约束、可解释	因子遗漏或载荷不稳定导致风险低估
EWMA	$O(1)$	捕捉时变波动、响应快	无均值回复、高维下不保证正定
DCC	$O(N) + 2$	波动与相关联合建模	两步估计的效率损失、N 大时估计不稳

11.4 鲁棒组合优化

既然 $\boldsymbol{\mu}$ 与 $\boldsymbol{\Sigma}$ 都有误差，把不确定性显式写入模型比「先估计再优化」更诚实。鲁棒优化求解最坏情形下的最优：

$$\max_{\boldsymbol{w}} \min_{\boldsymbol{\mu} \in \mathcal{U}_{\mu}} \left[\boldsymbol{w}^{\top}\boldsymbol{\mu} - \frac{\lambda}{2} \boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w} \right], \qquad \text{s.t. } \mathbf{1}^{\top}\boldsymbol{w} = 1,\ \boldsymbol{w} \in \mathcal{W} \tag{11.17}$$

其中 $\mathcal{U}_{\mu}$ 是均值的不确定性集，$\mathcal{W}$ 为权重约束集。两类常用集合及其等价形式：

- **盒式不确定性**：$\mathcal{U}_\mu = \{\boldsymbol{\mu} : |\mu_i - \hat{\mu}_i| \le \varepsilon_i\}$。此时内层最小化逐分量取 $\hat{\mu}_i - \varepsilon_i \operatorname{sgn}(w_i)$，问题退化为「用收缩后的均值 $\hat{\mu}_i - \varepsilon_i$ 做普通 MVO」。这提供了一个极其实用的解释：**把每个资产的预期收益统一减去 ε，等价于对该资产做鲁棒处理**。
- **椭球不确定性**：$\mathcal{U}_\mu = \{\boldsymbol{\mu} : (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}})^\top \Omega^{-1} (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}}) \le \kappa^2\}$，其中 Ω 为估计误差的协方差、κ 为置信半径。此时内层最小值为 $\boldsymbol{w}^\top \hat{\boldsymbol{\mu}} - \kappa \left\| \Omega^{1/2} \boldsymbol{w} \right\|$，问题化为

$$\max_{\boldsymbol{w},\, t} \quad \boldsymbol{w}^\top \hat{\boldsymbol{\mu}} - \frac{\lambda}{2} \boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w} - \kappa\, t \qquad \text{s.t.} \quad \left\| \Omega^{1/2} \boldsymbol{w} \right\| \le t, \quad \mathbf{1}^\top \boldsymbol{w} = 1, \quad \boldsymbol{w} \in \mathcal{W} \tag{11.18}$$

式 (11.18) 是标准的**二阶锥规划**（second-order cone program，SOCP），可用内点法在多项式时间内求解。它与 式 (11.1) 的唯一区别是增加了范数项 $-\kappa t$：不确定性集越大（κ 越大），优化器越倾向于把风险预算分散到多个资产上，因为集中持仓在椭球的最坏方向上风险最高。

直觉理解　鲁棒性就是惩罚集中度

把 式 (11.18) 的 $-\kappa \left\| \Omega^{1/2} \boldsymbol{w} \right\|$ 看作一项「集中度惩罚」：$\kappa = 0$ 时退化为经典 MVO，$\kappa \to \infty$ 时最优解趋向最小方差或等风险贡献等「不依赖均值」的组合。因此 κ 实际上是一个可校准的旋钮，把「相信预测」连续地调成「不信任预测」。实务中常按「κ 等于多少倍的标准误」来设定，并用滚动窗口选择样本外信息比率最高的 κ。

11.5 Black–Litterman 模型

Black–Litterman（BL）用贝叶斯方法解决 $\boldsymbol{\mu}$ 不可靠的问题：以市场均衡隐含收益为先验，以主观观点为似然，输出后验均值。

第一步：反向优化得到先验。若市场组合 $\boldsymbol{w}_{\text{mkt}}$ 是均值-方差最优的，则由 式 (11.2) 解出隐含收益

$$\Pi = \delta\, \boldsymbol{\Sigma}\, \boldsymbol{w}_{\text{mkt}} \tag{11.19}$$

其中 δ 为市场风险厌恶系数（由市场夏普比率反推，$\delta = (\mu_{\text{mkt}} - r_f)/\sigma^2_{\text{mkt}}$，历史估计通常在 2–4 之间）。这一步的意义是：**市场价格本身已经包含了所有公开信息**，因此 Π 是「没有人有私有观点时」最合理的均值假设，且与市场组合自洽。

第二步：观点与不确定性。用 K 个观点表示 $P\boldsymbol{\mu} = Q + \varepsilon$，$\varepsilon \sim \mathcal{N}(\mathbf{0}, \Omega)$，其中 P 为 $K \times N$ 观点矩阵（每行是一个组合）、Q 为观点收益、Ω 为观点不确定性（对角时表示观点相互独立）。先验取 $\boldsymbol{\mu} \sim \mathcal{N}(\Pi, \tau\boldsymbol{\Sigma})$，$\tau$ 通常取 0.01–0.05，反映「先验比样本更可信」的先验强度。

第三步：后验。正态共轭给出

$$\boldsymbol{\mu}_{\text{BL}} = \Pi + \tau\boldsymbol{\Sigma} P^\top \left(P\, \tau\boldsymbol{\Sigma}\, P^\top + \Omega \right)^{-1} (Q - P\Pi) \tag{11.20}$$

其中 $(Q - P\Pi)$ 是观点与均衡的偏离，括号项是「偏离的置信度权重」。若采用 He–Litterman 设定 $\Omega = \tau P\boldsymbol{\Sigma}P^\top$，则后验对任一观点的预测值为 $P\boldsymbol{\mu}_{\mathrm{BL}} = \frac{1}{2}(P\Pi + Q)$，即后验恰好是先验与观点的等权平均——这是一个易于记忆且便于检查编码正确性的性质。

例 11.2　两资产 BL 后验计算

设 $\boldsymbol{w}_{\mathrm{mkt}} = (0.6, 0.4)$，$\boldsymbol{\Sigma} = \left(\begin{smallmatrix} 0.04 & 0.004 \\ 0.004 & 0.01 \end{smallmatrix}\right)$，$\delta = 2.5$，$\tau = 0.05$。先验：$\Pi = 2.5\,\boldsymbol{\Sigma}\boldsymbol{w}_{\mathrm{mkt}} = (0.064,\ 0.016)$，即市场隐含的收益差为 4.8%。观点：资产 1 未来一年的收益将比资产 2 高 3%，故 $P = (1, -1)$、$Q = 0.03$，取 $\Omega = \tau P\boldsymbol{\Sigma}P^\top = 0.0021$。由 式 (11.20)：$Q - P\Pi = 0.03 - 0.048 = -0.018$，$\tau\boldsymbol{\Sigma}P^\top = (0.0018,\ -0.0003)^\top$，于是

$$\boldsymbol{\mu}_{\mathrm{BL}} = (0.064,\ 0.016) + \frac{(0.0018,\ -0.0003)^\top}{2 \times 0.0021} \times (-0.018) = (0.0563,\ 0.0173)$$

后验收益差为 3.9%，正是 4.8% 与 3.0% 的等权平均，与理论一致。观点的信息量体现在「把市场隐含的 4.8% 拉低到 3.9%」，从而降低资产 1 的配置诱惑；观点与市场偏离越大、Ω 越小，后验移动越多。

⚠ 风险警示　BL 的失效条件

BL 的稳健性来自先验，但它并非无懈可击：（1）τ 的选择没有客观标准，τ 越大观点权重越高，实务中不同机构取值从 $1/T$ 到 0.05 不等，结果差异可观；（2）Ω 若取对角但观点实际高度相关（例如「看多科技」与「看多成长」），会被重复计入，导致后验过度自信；（3）式 (11.19) 假设市场组合是均值-方差有效的，在存在非交易资产、杠杆约束与噪声交易者的市场中并不成立；（4）BL 只修正均值，完全不处理 $\boldsymbol{\Sigma}$ 的估计误差，因此仍需与收缩估计配合使用。

11.6 风险平价与等风险贡献

11.6.1　风险贡献的定义与分解

定义 11.2　风险贡献与风险预算

组合波动率 $\sigma_p(\boldsymbol{w}) = \sqrt{\boldsymbol{w}^\top\boldsymbol{\Sigma}\boldsymbol{w}}$ 对权重的偏导为边际风险 $\partial\sigma_p/\partial w_i = (\boldsymbol{\Sigma}\boldsymbol{w})_i/\sigma_p$。定义资产 i 的**风险贡献**（risk contribution）为

$$\mathrm{RC}_i = w_i\frac{\partial\sigma_p}{\partial w_i} = \frac{w_i\,(\boldsymbol{\Sigma}\boldsymbol{w})_i}{\sigma_p}, \qquad \sum_{i=1}^{N}\mathrm{RC}_i = \frac{\boldsymbol{w}^\top\boldsymbol{\Sigma}\boldsymbol{w}}{\sigma_p} = \sigma_p \tag{11.21}$$

给定风险预算向量 $\mathbf{b} = (b_1, \ldots, b_N)$（$b_i > 0$，$\sum b_i = 1$），**风险预算组合**满足 $\mathrm{RC}_i = b_i\sigma_p$。当 $b_i = 1/N$ 时称为**等风险贡献**（equal risk contribution，ERC）组合。

式 (11.21) 的第二个等式（欧拉定理）说明风险贡献之和恰为组合波动率，因此 RC_i/σ_p 是一个合法的「风险份额」。注意风险贡献可以为负：做空一个与组合正相关的资产会降低风险，其 $\mathrm{RC}_i < 0$。

11.6.2 ERC 的拉格朗日推导

直接对 σ_p 施加等风险贡献约束是非凸的，但可以化为一个凸问题。考虑

$$\min_{\boldsymbol{w}>\mathbf{0}} \quad \frac{1}{2}\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w} - \sum_{i=1}^{N} b_i \ln w_i \tag{11.22}$$

命题 11.1 (风险预算解的 KKT 条件) 设 $\boldsymbol{\Sigma}$ 正定、$b_i > 0$。问题 式 (11.22) 有唯一解 $\boldsymbol{w}^* > \mathbf{0}$，且其归一化权重 $\tilde{\boldsymbol{w}} = \boldsymbol{w}^*/\mathbf{1}^{\top}\boldsymbol{w}^*$ 满足风险预算条件

$$\tilde{w}_i \left(\boldsymbol{\Sigma}\tilde{\boldsymbol{w}}\right)_i = b_i \, \tilde{\sigma}_p^2, \qquad \text{即} \quad \mathrm{RC}_i = b_i \, \tilde{\sigma}_p \tag{11.23}$$

其中 $\tilde{\sigma}_p^2 = \tilde{\boldsymbol{w}}^{\top}\boldsymbol{\Sigma}\tilde{\boldsymbol{w}}$。特别地，$b_i = 1/N$ 时得到 ERC 组合。

证明. 目标函数在 $\boldsymbol{w} > \mathbf{0}$ 上严格凸（二次项正定，$-\ln$ 项凸），故驻点即全局最优。对 w_i 求偏导并令其为零：

$$\left(\boldsymbol{\Sigma}\boldsymbol{w}^*\right)_i - \frac{b_i}{w_i^*} = 0 \quad \Longrightarrow \quad w_i^* \left(\boldsymbol{\Sigma}\boldsymbol{w}^*\right)_i = b_i$$

两边对 i 求和，左边为 $\boldsymbol{w}^{*\top}\boldsymbol{\Sigma}\boldsymbol{w}^* = s^2$（记 $s = \mathbf{1}^{\top}\boldsymbol{w}^*$），右边为 1，故 $s^2 = 1$，即原始解已自动满足「风险归一化」（若改用 $\sum w_i = 1$ 的显式约束则需另行缩放，二者等价）。令 $\tilde{\boldsymbol{w}} = \boldsymbol{w}^*/s$，则 $\tilde{\sigma}_p^2 = s^2/s^2 \cdot \ldots$ 直接代入得 $\tilde{w}_i(\boldsymbol{\Sigma}\tilde{\boldsymbol{w}})_i = w_i^*(\boldsymbol{\Sigma}\boldsymbol{w}^*)_i/s^2 = b_i$，两边乘以 $\tilde{\sigma}_p^{-1}$ 并用 $\tilde{\sigma}_p = s$ 即得 $\mathrm{RC}_i = b_i\tilde{\sigma}_p$。 ■

例 11.3 四资产类别的 ERC 与 MVO 对比

取四个资产类别：股票（$\sigma = 18\%$，$\mu = 9\%$）、债券（6%，3%）、黄金（15%，5%）、商品（20%，6%），相关系数矩阵取

$$\begin{pmatrix} 1 & 0.10 & 0.05 & 0.20 \\ 0.10 & 1 & 0.05 & -0.10 \\ 0.05 & 0.05 & 1 & 0.25 \\ 0.20 & -0.10 & 0.25 & 1 \end{pmatrix}$$

求解 式 (11.22)（等风险预算）得 $\tilde{\boldsymbol{w}}_{\mathrm{ERC}} = (15.3\%, 52.4\%, 18.4\%, 13.9\%)$，四个资产的风险贡献均为 1.61%，之和等于组合波动率 6.43%。取 $\lambda = 3$ 求解式 (11.1) 得 $\boldsymbol{w}_{\mathrm{MVO}} = (60.3\%, 2.9\%, 25.5\%, 11.3\%)$，其波动率为 12.5%；GMVP 为 (4.3%, 80.0%, 8.5%, 7.2%)，波动率 5.36%。四组权重详见 表 11.2。

图 11.2 直观展示了三种方法的风险哲学差异：MVO 回答「哪里的收益风险比最高」，ERC 回答「如何让每一份风险预算各司其职」，GMVP 回答「如何在完全不预测收益的前提下最小化波动」。ERC 的权重与 $\boldsymbol{\mu}$ 无关，这是它在下行市场更稳健的根本原因，也是它在 $\boldsymbol{\mu}$ 不可靠时优于 MVO 的根本原因。

表 11.2　四种组合构建方法的权重与风险（小节 11.6.2 的算例）

方法	股票	债券	黄金	商品	组合波动率	组合收益
等权	25.0%	25.0%	25.0%	25.0%	9.83%	5.75%
GMVP	4.3%	80.0%	8.5%	7.2%	5.36%	3.64%
ERC	15.3%	52.4%	18.4%	13.9%	6.43%	4.51%
MVO（$\lambda = 3$）	60.3%	2.9%	25.5%	11.3%	12.50%	7.47%

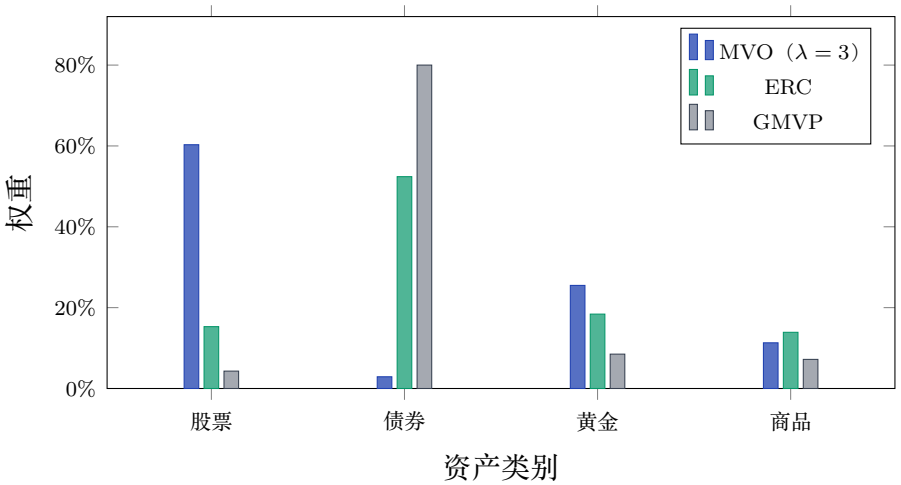


图 11.2　同一协方差矩阵下 MVO、ERC 与 GMVP 的权重对比。MVO 把 60% 押在夏普比率最高的股票上，ERC 把一半权重给债券以平衡风险贡献，GMVP 则几乎完全由债券构成

实务应用　风险平价的实践变体

教科书 ERC 假设资产可以自由加杠杆，但真实世界的最低风险资产（短期国债）波动率只有 1%–2%，直接做 ERC 会得到「99% 现金」的荒谬结果。实务中的桥水式「全天候」做法是：先用债券期货、股指期货把各资产类别的风险调整到同一水平（risk parity at target volatility），再等权配置。其代价是引入杠杆与保证金风险——2020 年 3 月的美元流动性冲击中，风险平价策略因杠杆被迫去化而出现显著回撤。

11.7 分层风险平价与最大分散度

11.7.1　HRP 算法

分层风险平价（hierarchical risk parity，HRP，López de Prado 2016）完全绕开 $\boldsymbol{\Sigma}^{-1}$，分三步构造组合：树聚类、准对角化、递归二分。第一步把相关系数转成距离：

$$d_{ij} = \sqrt{\frac{1-\rho_{ij}}{2}}, \qquad \rho_{ij} = \frac{\Sigma_{ij}}{\sqrt{\Sigma_{ii}\Sigma_{jj}}} \tag{11.24}$$

其中 ρ_{ij} 为相关系数，$d_{ij} \in [0,1]$。该距离是欧氏距离的一个合法变换，满足三角不等式，因此可以送入层次聚类（单链接、平均链接或 Ward 链接）。聚类结果形成一棵二叉树；把叶子按树的中序遍历重排，可得到一个**准对角矩阵**——高度相关的资产彼此相邻，因此「逆方差权重」在相邻块内分配即可避免跨块的伪分散化。

算法 11.1　分层风险平价（HRP）

输入： 协方差矩阵 $\boldsymbol{\Sigma}$（或相关矩阵与波动率），资产集合 $\{1,\dots,N\}$
输出： 组合权重 $\boldsymbol{w}$

1: 由 式 (11.24) 计算距离矩阵 d_{ij}，并做层次聚类得到二叉树
2: 按树的中序遍历重排资产，得到准对角化的 $\boldsymbol{\Sigma}$ 与对应的聚类列表
3: **for** 每一对相邻的簇对 (C_1, C_2)，自底向上 **do**
4:　　计算簇方差 $V_k = \boldsymbol{w}_k^{\top}\boldsymbol{\Sigma}_k\boldsymbol{w}_k$，其中簇内权重 $\boldsymbol{w}_k$ 取逆方差权重 $1/\operatorname{diag}(\boldsymbol{\Sigma}_k)$
5:　　计算簇间平分因子 $\alpha = 1 - \dfrac{V_1}{V_1 + V_2}$
6:　　把 C_1 的总权重乘以 α，把 C_2 的总权重乘以 $1-\alpha$
7: **end for**
8: **return** 每个资产的累积权重 $\boldsymbol{w}$

算法 11.1 的关键是第 5 行：簇内用逆方差权重（不涉及求逆），簇间按「簇方差的反比」分配。整个算法只使用 $\boldsymbol{\Sigma}$ 的对角元与簇内二次型，因此对 $\boldsymbol{\Sigma}$ 的非对角噪声极不敏感。文献报告在标准数据集上 HRP 的样本外波动率常低于 GMVP，而换手率与回撤更小。

11.7.2　最大分散度与最大去相关

最大分散度（maximum diversification，Choueifaty–Coignard 2008）最大化「加权平均波动率」与「组合波动率」之比：

$$\max_{\boldsymbol{w}} \ \mathrm{DR}(\boldsymbol{w}) = \frac{\boldsymbol{w}^\top \boldsymbol{\sigma}}{\sqrt{\boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}}}, \qquad \text{s.t. } \mathbf{1}^\top \boldsymbol{w} = 1,\ \boldsymbol{w} \geq \mathbf{0} \tag{11.25}$$

其中 $\boldsymbol{\sigma} = (\sigma_1, \ldots, \sigma_N)^\top$ 为各资产波动率。DR 的倒数就是组合的「分散化比率」，DR $= 1$ 表示组合等价于单一资产，DR $= \sqrt{N}$ 表示 N 个不相关且等波动资产。该问题是拟凸的，可通过变量替换化为二阶锥规划。若用相关矩阵替代协方差矩阵（即先做波动率标准化），则得到**最大去相关组合**：

$$\min_{\boldsymbol{w}} \ \frac{\boldsymbol{w}^\top R \boldsymbol{w}}{(\boldsymbol{w}^\top \boldsymbol{w})} \quad \Longleftrightarrow \quad \text{取} R \text{ 最小特征值对应的特征向量} \tag{11.26}$$

其中 R 为相关矩阵。这等价于对标准化收益做**主成分分析**并取最小方差的主成分方向——一个常被忽视的事实是：**最小特征值方向在样本内看起来是「最分散」的，但它恰恰是最容易被估计误差污染的方向**，因此纯 MDP/MDC 组合仍需收缩或约束保护。

11.8 Kelly 准则与分数 Kelly

11.8.1 离散赌局的最优下注

设每次下注以概率 p 赢、概率 $q = 1 - p$ 输，赔率 $b : 1$（即下注 1 元赢时净得 b 元，输时损失 1 元），下注比例为 f。长期增长率等于对数财富的期望：

$$g(f) = p \ln(1 + bf) + q \ln(1 - f) \tag{11.27}$$

令 $g'(f) = \dfrac{pb}{1 + bf} - \dfrac{q}{1 - f} = 0$，解得 **Kelly 比例**

$$f^* = \frac{pb - q}{b} = p - \frac{q}{b} = \frac{\text{期望净收益}}{\text{赔率}} \tag{11.28}$$

当 $pb \leq q$ 时期望净收益非正，$f^* \leq 0$，即不应下注。g 在 f^* 处取最大值，且 g 关于 f 在 f^* 附近二阶可微，因此过度下注的惩罚是不对称的：下注 $2f^*$ 的增长率通常远低于下注 f^* 的一半。

11.8.2 连续情形与 Merton 解的关系

设风险资产超额收益 $\mu - r$、波动率 σ，组合以恒定比例 f 投资于风险资产，则财富服从几何布朗运动，T 期的对数增长率期望为

$$g(f) = r + f(\mu - r) - \frac{f^2 \sigma^2}{2} \quad \Longrightarrow \quad f^* = \frac{\mu - r}{\sigma^2}, \qquad g(f^*) = r + \frac{1}{2}\left(\frac{\mu - r}{\sigma}\right)^2 \tag{11.29}$$

第二个等式极为重要：**最大对数增长率等于无风险利率加上夏普比率平方的一半**。取 SR $= 0.3$，超额增长率约 4.5%；取 SR $= 0.5$，约 12.5%。这解释了为什么机构愿意为 0.1 的夏普改进投入巨额成本。

例 11.4 Kelly 比例与过度下注的代价

设 $\mu - r = 6\%$、$\sigma = 20\%$，则 $f^* = 0.06/0.04 = 1.5$，即需要 150% 的杠杆才能达到最大增长率，最大超额增长率 $= 0.3^2/2 = 4.5\%$。若下注 $f = 0.75$（半 Kelly），增长率损失为

$$g(f^*) - g(f) = \frac{\sigma^2}{2}(f^* - f)^2 = \frac{0.04}{2} \times 0.75^2 = 1.125\%$$

即保留 $4.5\% - 1.125\% = 3.375\%$，为最优值的 75%，而组合波动率从 30% 降到 15%。若下注 $f = 2f^* = 3.0$，增长率 $= 0.06 \times 3 - 0.04 \times 9/2 = 0.18 - 0.18 = 0$——**两倍 Kelly 下注把长期增长率归零**。这就是「过度下注必然破产」的精确含义。

⚠ 风险警示　Kelly 准则的失效条件

Kelly 的最优性依赖三个假设，实务中一个都难以完全满足：（1）**参数已知**。$f^* = (\mu - r)/\sigma^2$ 对 μ 的敏感性是线性的，而 μ 的估计误差通常大于 μ 本身；若真实 $\mu - r = 3\%$ 而被估成 6%，实际下注已是两倍 Kelly，增长率归零。（2）**赔率与概率稳定**。真实收益的分布是时变的，牛市末期的「历史 Kelly」会给出最大杠杆。（3）**效用函数为对数**。Kelly 最大化长期增长率，但代价是沿途的回撤可以任意深；对数效用对回撤的容忍度远高于多数机构投资者的风险预算。因此实务几乎全部采用**分数 Kelly**（fractional Kelly，通常 1/4 到 1/2），其代价是增长率损失 $(1 - c^2)\,\mathrm{SR}^2/2$，收益是波动率线性下降。

11.9 CVaR 组合优化与 Rockafellar–Uryasev 线性化

11.9.1　从方差到尾部风险

方差把上行与下行同等对待，且不区分「小概率大损失」与「大概率小损失」。条件在险价值（CVaR）只关心尾部：

定义 11.3 VaR 与 CVaR

设组合损失 $L(\boldsymbol{w}) = -\boldsymbol{w}^\top r$，置信水平 $\beta \in (0,1)$。在险价值为 $\mathrm{VaR}_\beta = \min\{\nu : \mathbb{P}(L \le \nu) \ge \beta\}$，条件在险价值为

$$\mathrm{CVaR}_\beta = \frac{1}{1-\beta}\int_\beta^1 \mathrm{VaR}_u \, \mathrm{d}u = \min_{\nu \in \mathbb{R}} \left\{ \nu + \frac{1}{1-\beta}\,\mathbb{E}\left[(L(\boldsymbol{w}) - \nu)^+\right] \right\} \tag{11.30}$$

其中 $(x)^+ = \max(x, 0)$。对连续分布，$\mathrm{CVaR}_\beta = \mathbb{E}\left[L \mid L \ge \mathrm{VaR}_\beta\right]$，即超出 VaR 的平均损失。

对离散分布（情景模拟的常态），式 (11.30) 中的积分形式与条件期望不再等价：若情景等概率且尾部正好落在两个情景之间，则「超过 VaR 的平均损失」会高估 CVaR。必须使用右侧的最小化形式，这也正是它可以线性化的原因。

11.9.2 Rockafellar–Uryasev 线性化

设情景集合为 $\{r_1,\dots,r_S\}$，每个情景等概率 $1/S$。由 式 (11.30) 引入辅助变量 ν（ν 的最优值就是 VaR）与非负变量 u_s，得到线性规划：

$$\min_{\boldsymbol{w},\nu,\mathbf{u}} \quad \nu+\frac{1}{(1-\beta)S}\sum_{s=1}^{S}u_s \qquad \text{s.t.} \quad \begin{cases} u_s \ge -r_s^{\top}\boldsymbol{w}-\nu, & s=1,\dots,S \\ u_s \ge 0, & s=1,\dots,S \\ \mathbf{1}^{\top}\boldsymbol{w}=1, \quad \boldsymbol{w}\in\mathcal{W} & \end{cases} \tag{11.31}$$

由于目标函数关于 $(\boldsymbol{w},\nu,\mathbf{u})$ 是凸的（分片线性），且约束全部线性，式 (11.31) 是一个标准 LP，规模为 S 个约束加 $|\mathcal{W}|$ 个组合约束。可以证明 ν 的最优值等于 VaR_β，目标值等于 CVaR_β。更进一步，CVaR 是**一致性风险度量**（次可加、单调、正齐次、平移不变），而 VaR 不满足次可加性——这是机构选择 CVaR 作为优化目标而非约束的理论依据。

例 11.5　三情景的 CVaR 线性化

某组合在四个等概率情景下的收益为 $(9\%,3\%,-2\%,-10\%)$，取 $\beta=0.5$。损失为 $(-9\%,-3\%,2\%,10\%)$，按降序排列为 $10\%,2\%,-3\%,-9\%$。$\mathrm{VaR}_{0.5}=2\%$（因为 $\mathbb{P}(L\le 2\%)=0.5$）。由 式 (11.30) 的积分定义：$\mathrm{CVaR}_{0.5}=2\times\big[\tfrac14\times 2\%+\tfrac14\times 10\%\big]=6\%$，即最差一半情景的平均损失。用 式 (11.31) 验证：取 $\nu=2\%$，则 $u=(8\%,0,0,0)$，目标值 $=2\%+\frac{1}{0.5\times 4}\times 8\%=2\%+4\%=6\%$，与积分定义一致。注意目标函数在 $\nu\in[2\%,10\%]$ 上是常数，说明离散情景下最优 ν 不唯一——编码时不应假定 ν 唯一，而应直接使用目标值作为 CVaR。

补充说明　Rockafellar–Uryasev 的历史与影响

CVaR 的凸表示由 Rockafellar 与 Uryasev 在 2000 年前后系统化，其意义在于把「尾部风险约束」从非凸的 VaR 约束变成了可被内点法高效求解的 LP/SOCP。今天主流的均值-CVaR 组合优化、CVaR 风险预算、甚至深度学习中带尾部惩罚的损失函数，都建立在这个线性化技巧之上。

11.10 交易成本、换手约束与多期优化

11.10.1 成本建模

记当前持仓 $\boldsymbol{w}_0$，目标持仓 $\boldsymbol{w}$，交易向量 $\Delta\boldsymbol{w}=\boldsymbol{w}-\boldsymbol{w}_0$。常用成本函数

$$\mathrm{TC}(\boldsymbol{w})=\kappa\,\|\Delta\boldsymbol{w}\|_1+\eta\,\Delta\boldsymbol{w}^{\top}\boldsymbol{\Sigma}_{\text{illiq}}\Delta\boldsymbol{w}+\frac12\,\Delta\boldsymbol{w}^{\top}\Lambda\Delta\boldsymbol{w} \tag{11.32}$$

其中 κ 为线性成本（买卖价差与佣金，按双边每单位计），η 为二次冲击系数（对应平方根或线性冲击模型的一阶近似），Λ 为交叉冲击矩阵，用于刻画「同时卖出高度相关资产会加剧冲击」。**除非 $\kappa=0$，最优解永远是稀疏的**（许多 w_i 恰好等于 $w_{0,i}$），因为线性成本在原点不可微，会产生「不交易区间」的次梯度条件。这一性质在实践中极为有用：它天然抑制了由微小信号波动引起的过度换手。

核心要点 11.2　核心要点：交易成本与有效前沿

计入线性成本后，最优解的次梯度条件为

$$\boldsymbol{\mu} - \lambda \boldsymbol{\Sigma} \boldsymbol{w} - \gamma \mathbf{1} \in \kappa \, \partial \left\| \Delta \boldsymbol{w} \right\|_1 \tag{11.33}$$

即当边际收益的偏离小于 κ 时，该资产保持原仓位不动。因此**交易成本把「连续有效前沿」变成了「带状有效前沿」**：落在带内的持仓不受小幅参数变化影响，这正是低换手策略估值更稳定的数学原因。

11.10.2　多期与动态规划

单期优化忽略了一个事实：今天的持仓会影响明天的成本。多期问题为

$$\max_{\{\boldsymbol{w}_t\}} \; \mathbb{E}\left[\sum_{t=0}^{T-1} \beta^t \left(\boldsymbol{w}_t^{\top} \boldsymbol{\mu}_t - \frac{\lambda}{2} \boldsymbol{w}_t^{\top} \boldsymbol{\Sigma}_t \boldsymbol{w}_t \right) - \sum_{t=0}^{T-1} \beta^{t+1} \mathrm{TC}\left(\boldsymbol{w}_{t+1} - \boldsymbol{w}_t \right) \right] \tag{11.34}$$

其中 β 为贴现因子，$\boldsymbol{\mu}_t$ 为时变预测。这类问题的解析解只在特殊情形下存在（例如成本为二次型时退化为「目标追踪」形式 $\boldsymbol{w}_t$ 向无摩擦最优解 $\boldsymbol{w}_t^{*}$ 平滑靠拢）。实务中普遍采用近似：把多期问题化为带惩罚项的单期问题，或使用 Gârleanu–Pedersen 型的「部分调整」规则——**每期只走完误差的一部分，且成本越高步长越小**。在没有能力估计时变 $\boldsymbol{\mu}$ 的情况下，用「持有期与换手惩罚」代替真正的动态规划，通常是性价比最高的选择。

11.11 动态组合管理：CPPI 与 Merton 解

11.11.1　买卖持有、常数混合与 CPPI

三种动态策略在同样的标的下产生截然不同的收益形状：

- **买入持有**（buy and hold）：不调仓，期末价值 $V_T = V_0 \, S_T / S_0$，关于标的收益是线性的。
- **常数混合**（constant mix）：恒定把比例 c 放在风险资产上并连续再平衡。可以证明（详见 小节 11.11.1）期末价值为 $V_T = V_0 \left(S_T / S_0 \right)^{c} \mathrm{e}^{\left[(1-c) r + \frac{1}{2} c (1-c) \sigma^2 \right] T}$，指数 $c < 1$ 意味着**凹**的收益曲线：市场下跌时它跌得少，上涨时也涨得少，但在震荡市中靠「低买高卖」获得**波动率收割**（volatility harvesting）。
- **CPPI**（constant proportion portfolio insurance，固定比例组合保险）：设最低可接受价值（floor）为 F，安全垫（cushion）为 $A_t - F$，则风险资产暴露为

$$E_t = \min\left\{ m \left(A_t - F \right), \; A_t \right\}, \qquad F = F_0 \, \mathrm{e}^{rT} \tag{11.35}$$

其中 $m > 1$ 为乘数，A_t 为组合总价值。连续再平衡下，安全垫的变化满足 $\mathrm{d}(A_t - F) = m(A_t - F) \, \mathrm{d}S_t / S_t$，故 $A_T - F = (A_0 - F)(S_T / S_0)^{m}$，即

$$A_T = F + (A_0 - F)\left(\frac{S_T}{S_0}\right)^m \tag{11.36}$$

式 (11.36) 是凸的（$m>1$），形象地说 CPPI 买了一份隐含的看涨期权：上涨时加速参与，下跌时自动降低暴露以保护本金。

例 11.6　常数混合的指数形式推导

设组合价值 A_t，恒把比例 c 投于价格 S_t 的风险资产（S 服从几何布朗运动，漂移 μ、波动 σ），其余投于无风险资产。则

$$\frac{\mathrm{d}A}{A} = c\,\frac{\mathrm{d}S}{S} + (1-c)\,r\,\mathrm{d}t = [c\mu + (1-c)r]\,\mathrm{d}t + c\sigma\,\mathrm{d}W_t$$

即 A 也是几何布朗运动，波动率为 $c\sigma$。用 $W_T = [\ln(S_T/S_0) - (\mu - \sigma^2/2)T]/\sigma$ 消去，得到

$$A_T = A_0\left(\frac{S_T}{S_0}\right)^c \exp\left\{\left[(1-c)r + \frac{c(1-c)\sigma^2}{2}\right]T\right\}$$

取 $r=0$、$\sigma=20\%$、$c=0.3$、$T=1$，则乘数因子为 $\exp(0.3\times 0.7\times 0.04/2) = 1.0042$，即震荡市中的超额收益约占 0.42%。这一项 $\frac{1}{2}c(1-c)\sigma^2 T$ 就是波动率收割的全部来源。

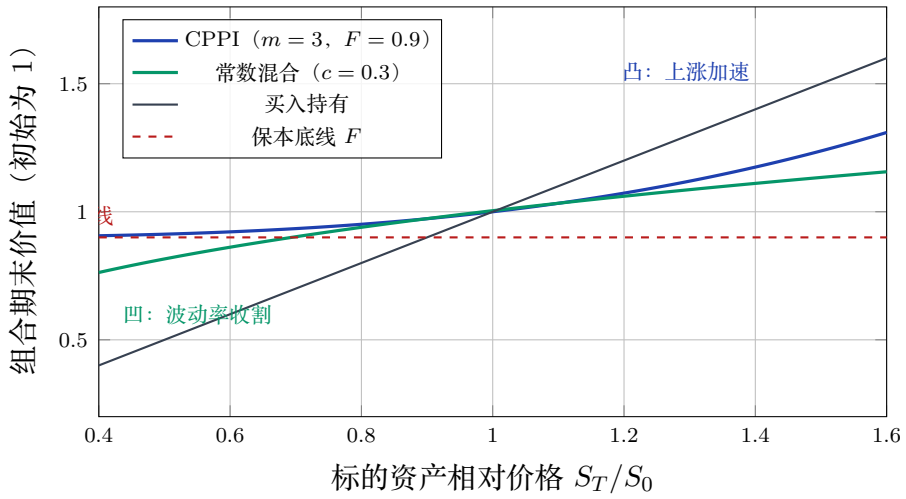


图 11.3　CPPI、常数混合与买入持有三种动态策略的期末价值曲线（估值日 $T=1$ 年，$r=0$，$\sigma=20\%$）。CPPI 的曲线位于保本底线之上且向上凸，常数混合的曲线向下凹，买入持有为直线

11.11.2　Merton 解

Merton（1969，1971）在连续时间下求解消费-投资问题：

$$\max_{c_t,\ \boldsymbol{w}_t} \mathbb{E}\left[\int_0^T \mathrm{e}^{-\rho t}U(c_t)\,\mathrm{d}t\right], \qquad U(c) = \frac{c^{1-\gamma}}{1-\gamma},\ \gamma>0 \tag{11.37}$$

其中 ρ 为主观贴现率，γ 为相对风险厌恶系数（CRRA），$\boldsymbol{w}_t$ 为风险资产权重。财富

动态为 $\mathrm{d}W_t = W_t\left[r + \boldsymbol{w}_t^\top(\boldsymbol{\mu} - r\mathbf{1}) - c_t/W_t\right]\mathrm{d}t + W_t\boldsymbol{w}_t^\top\boldsymbol{\Sigma}^{1/2}\mathrm{d}\boldsymbol{W}_t$。猜测值函数 $J(W) = K\,W^{1-\gamma}/(1-\gamma)$，代入 HJB 方程并对 $\boldsymbol{w}$ 求一阶条件：

$$\boldsymbol{w}^* = \frac{1}{\gamma}\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu} - r\mathbf{1}) = \frac{1}{\gamma}\,\frac{\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu} - r\mathbf{1})}{\mathbf{1}^\top\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu} - r\mathbf{1})}\cdot \mathrm{SR}_{\max} \tag{11.38}$$

即最优风险组合仍是切点组合 $\boldsymbol{w}_{\tan}$（两基金分离在连续时间下的再现），而杠杆由 $1/\gamma$ 决定。单风险资产情形退化为 式 (11.29) 的一般化：

$$w^* = \frac{\mu - r}{\gamma\sigma^2}, \qquad c^* = \left[\frac{\rho - (1-\gamma)\left(r + \frac{(\mu-r)^2}{2\gamma\sigma^2}\right)}{\gamma}\right] W \tag{11.39}$$

当 $\gamma = 1$（对数效用）时，式 (11.39) 的第一个式子即 Kelly 比例 $(\mu - r)/\sigma^2$，这给出了 Kelly 与 Merton 的统一图景：**Kelly 就是 CRRA 效用 $\gamma = 1$ 的特例**，$\gamma = 5$ 时最优杠杆降到 Kelly 的 1/5。

⚠ 风险警示　CPPI 与 Merton 解的失效条件

CPPI：(1) *跳空风险*。式 (11.36) 假定连续再平衡；若标的单日跳空下跌超过 $1/m$，安全垫会被一次性击穿。取 $m = 3$，跌幅超过 33% 即突破底线；2008 年 10 月与 2020 年 3 月都有个股单周跌幅超过该阈值。(2) *波动率上升*。m 固定时，标的波动率上升会显著提高触底概率，实务中需按波动率动态调整 m。(3) *流动性*。危机中风险资产流动性枯竭，减仓无法按模型价格成交，保本承诺形同虚设。**Merton 解**：假定投资机会集恒定（$\boldsymbol{\mu}$、$\boldsymbol{\Sigma}$、r 均为常数）。若参数时变（可预测的收益或波动率），最优权重不再是常数，需解含状态变量的 HJB 方程（Merton 1971 的可预测收益版本）。此外 CRRA 效用对极端回撤的容忍度与机构负债结构无关，实际配置需叠加负债约束与监管资本约束。

11.12 绩效归因

11.12.1　Brinson 三效应分解

归因回答「超额收益从哪里来」。把组合写成基准的行业（或资产类别）加权，记 $w_{p,i}$、$w_{b,i}$ 为组合与基准在各行业的权重（$\sum_i w_{p,i} = \sum_i w_{b,i} = 1$），$r_{p,i}$、$r_{b,i}$ 为行业内收益，$r_b = \sum_i w_{b,i} r_{b,i}$ 为基准总收益，则 Brinson–Hood–Beebower（BHB，1986）三效应为

$$A = \sum_i (w_{p,i} - w_{b,i})\, r_{b,i} \qquad \text{（配置效应）} \tag{11.40}$$

$$S = \sum_i w_{b,i}\,(r_{p,i} - r_{b,i}) \qquad \text{（选股效应）} \tag{11.41}$$

$$I = \sum_i (w_{p,i} - w_{b,i})\,(r_{p,i} - r_{b,i}) \qquad \text{（交互效应）} \tag{11.42}$$

三效应之和恰为超额收益 $r_p - r_b$（以 $r_p = \sum_i w_{p,i} r_{p,i}$ 代入即可验证）。**Brinson–Fachler**（BF，1985）把配置效应改为相对于基准总收益的偏离：

$$A^{\mathrm{BF}} = \sum_i \left(w_{p,i} - w_{b,i}\right)\left(r_{b,i} - r_b\right) \tag{11.43}$$

由 $\sum_i (w_{p,i} - w_{b,i}) = 0$ 立得 $A^{\mathrm{BF}} = A - r_b \cdot 0 = A$：**两种方法的配置效应总量相同，但行业层面的数值不同**。BF 的重心修正给出更合理的行业评价：在基准整体下跌 5% 的市场中，超配一个只跌 2% 的防御性行业应当在 BF 下记为正贡献，而在 BHB 下该行业贡献为负（因为 $r_{b,i} < 0$）。实务中大多数绩效系统默认使用 BF 的行业级配置效应。

例 11.7 Brinson 归因数值算例

设三个行业，权重与收益如下表。基准总收益 $r_b = 0.40\times10\%+0.35\times6\%+0.25\times4\% = 7.1\%$，组合总收益 $r_p = 0.50\times12\%+0.30\times5\%+0.20\times8\% = 9.1\%$，超额收益 2.0%。

行业	组合权重	基准权重	组合收益	基准收益
科技	50%	40%	12%	10%
医疗	30%	35%	5%	6%
能源	20%	25%	8%	4%

由式 (11.40)：$A = (0.10)(0.10) + (-0.05)(0.06) + (-0.05)(0.04) = 0.50\%$，$S = 0.40(0.02) + 0.35(-0.01) + 0.25(0.04) = 1.45\%$，$I = 0.10(0.02) + (-0.05)(-0.01) + (-0.05)(0.04) = 0.05\%$，合计 2.00%，与超额收益一致。改用 BF：科技 $(0.10)(0.10-0.071) = 0.29\%$，医疗 $(-0.05)(0.06-0.071) = 0.055\%$，能源 $(-0.05)(0.04-0.071) = 0.155\%$，合计仍为 0.50%。可见行业内排名被重新解释：BHB 认为「低配医疗」是负贡献（-0.30%），BF 则认为在一个基准收益 7.1% 的环境里低配一个只涨 6% 的行业是正贡献（$+0.055\%$），后者显然更符合直觉。

11.12.2 因子归因

行业归因无法回答「超额收益是选股能力还是风格暴露」。**因子归因**把主动收益投影到因子暴露变化上：

$$r_p - r_b = \sum_k \left(\beta_{p,k} - \beta_{b,k}\right) f_k + \sum_k \beta_{b,k} f_k + \alpha, \qquad \alpha = \text{无法被因子解释的残差} \tag{11.44}$$

其中 $\beta_{p,k}$、$\beta_{b,k}$ 为组合与基准对因子 k 的暴露，f_k 为因子收益。实务做法是同时对主动权重做风险模型归因（**风险归因**）与对主动收益做因子回归（**收益归因**），并把二者对齐：如果 α 的 t 值低于 2 而因子暴露变化的贡献占主动收益的 80%，那么「选股能力」的说法就不成立。

表 11.3　绩效归因方法对比

方法	分解维度	优点	局限
BHB 三效应	配置 / 选股 / 交互	恒等成立、易实现	行业级配置效应对基准方向敏感
Brinson–Fachler	配置（相对基准）/ 选股 / 交互	行业级解释更符合直觉	总量与 BHB 相同、不解决拟合问题
因子归因	风格暴露变化 / 特质	可区分 Beta 与 Alpha	依赖风险模型、因子共线时分解不唯一
多期归因（Carino）	几何链接的行业效应	多期可加、与累计收益一致	需要平滑因子、单期解释性下降

11.13 绩效指标

11.13.1　核心指标与失效条件

把绩效压缩成一个数字总要付出代价。下表列出最常用的六个指标及其隐含假设。

表 11.4　绩效指标速查与失效条件

指标	定义	解读	失效条件
夏普比率	$(\bar r_p - r_f)/\,\mathrm{sd}(r_p)$	每单位总风险的超额收益	收益自相关时年化偏误；对非正态收益失灵
索提诺比率	$(\bar r_p - T)/\,\mathrm{sd}_{\mathrm{down}}$	只惩罚下行波动	目标收益 T 可被操纵；样本少时尾部不稳
卡玛比率	年化收益 / 最大回撤	单位回撤的收益效率	回撤是单一路径统计量，对样本区间极敏感
信息比率	$(\bar r_p - \bar r_b)/\,\mathrm{sd}(r_p - r_b)$	单位跟踪误差的主动收益	基准选择决定数值；跟踪误差小时爆炸
M^2	$r_f + \mathrm{SR}_p\,\sigma_b$	风险调整到基准水平后的收益	与夏普比率单调等价，无新增信息
上行捕获	上行月收益均值 / 基准上行月收益均值	牛市中跟涨能力	需与下行捕获配对解读

$$\mathrm{SR} = \frac{\bar r_p - r_f}{\mathrm{sd}(r_p)}, \qquad \mathrm{IR} = \frac{\bar r_p - \bar r_b}{\mathrm{sd}(r_p - r_b)}, \qquad \mathrm{Calmar} = \frac{\bar r_p^{\,\mathrm{ann}}}{\mathrm{MDD}} \tag{11.45}$$

其中 $\mathrm{sd}_{\mathrm{down}} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\min(r_t - T, 0)^2}$ 为下行偏差，MDD 为最大回撤。最大回撤的严

格定义为

$$\mathrm{MDD} = \max_{0 \le s \le t \le T} \frac{V_s - V_t}{V_s}, \qquad V_t = \prod_{k=1}^{t} (1 + r_k) \tag{11.46}$$

即历史最高净值到其后的最低净值的最大跌幅，是路径依赖指标：它不能由收益率分布单独决定。

11.13.2 年化与自相关修正

月频夏普比率乘以 $\sqrt{12}$ 是默认做法，但当收益存在自相关时该换算会系统性高估。Lo（2002）给出的修正为

$$\mathrm{SR}^{\mathrm{ann}} = \mathrm{SR}^{\mathrm{monthly}} \times \frac{\sqrt{q}}{\sqrt{1 + 2\sum_{k=1}^{q-1} \frac{q-k}{q} \rho_k}}, \qquad q = 12 \tag{11.47}$$

其中 ρ_k 为收益的 k 阶自相关系数。若一阶自相关为 0.2，其余为零，则分母因子为 $\sqrt{1 + 2 \times \frac{11}{12} \times 0.2} = \sqrt{1.367} = 1.169$，年化夏普被高估约 17%。私募股权、房地产与低流动性信用策略的收益常呈现 0.3 以上的正自相关，其上报的夏普比率因此普遍偏高——估值平滑而非真实业绩是主要原因。

实务应用　指标使用的工程建议

（1）**永远报告区间**：用 block bootstrap 或滚动窗口给出夏普比率的置信区间，而不是单点。（2）**配对比较**：比较两个策略时用 Jobson–Korkie 检验（或 Memmel 修正）检验夏普比率之差的显著性，而不是比较两个点估计。（3）**路径指标单独看**：最大回撤与回撤持续期无法从夏普比率推出，必须单列。（4）**口径披露**：无风险利率、基准、复利方式、是否扣费必须写清楚，否则数值不可比。

11.14 代码实现：cvxpy 求解 MVO 与 ERC

下面两段代码给出本章两个最容易踩坑的模型的可运行实现。第一段是带权重上下限与做空约束的 MVO，第二段是用对数障碍凸化后的 ERC 求解，并验证风险贡献确实相等。

Listing 11.1　用 cvxpy 求解带约束的均值-方差优化（MVO）

```
import numpy as np
import cvxpy as cp

np.random.seed(0)
n = 8
mu = np.random.uniform(0.04, 0.12, n)
A = np.random.randn(n, n)
Sigma = A @ A.T / n + np.diag(np.random.uniform(0.01, 0.04, n))
```

```
lam = 5.0

w = cp.Variable(n)
objective = cp.Maximize(mu @ w - 0.5 * lam * cp.quad_form(w, Sigma))
constraints = [cp.sum(w) == 1, w >= 0, w <= 0.35]
prob = cp.Problem(objective, constraints)
prob.solve()

print("status:", prob.status)
print("weights:", np.round(w.value, 4))
print("expected return:", round(float(mu @ w.value), 4))
print("ex-ante volatility:", round(float(np.sqrt(w.value @ Sigma @ w.
    value)), 4))
```

Listing 11.2 用凸对数障碍形式求解等风险贡献（ERC）组合

```
import numpy as np
import cvxpy as cp

np.random.seed(0)
n = 8
A = np.random.randn(n, n)
Sigma = A @ A.T / n + np.diag(np.random.uniform(0.01, 0.04, n))
budget = np.ones(n) / n

y = cp.Variable(n, pos=True)
objective = cp.Minimize(0.5 * cp.quad_form(y, Sigma) - budget @ cp.log(y)
    )
prob = cp.Problem(objective, [cp.sum(y) == 1])
prob.solve()

w = y.value / y.value.sum()
vol = float(np.sqrt(w @ Sigma @ w))
rc = w * (Sigma @ w) / vol

print("status:", prob.status)
print("weights:", np.round(w, 4))
print("risk contributions:", np.round(rc, 4))
print("portfolio volatility:", round(vol, 4))
```

Listing 11.1 中若把 ‘lam‘ 设得极小（例如 0.01），优化器会把权重顶到上下限边界，这正是 节 11.2 所述错误放大的工程表现；listing 11.2 的关键是承认 ERC 不是「最小方差」问题，而是对数障碍下的风险预算问题，因此代码里没有出现 $\boldsymbol{\Sigma}^{-1}$。

本章小结

- 均值-方差问题的解可分解为 GMVP 与投机性倾斜（式 (11.4)），有效前沿为双曲线（式 (11.6)）；引入无风险资产后所有投资者持有同一 式 (11.7) 的切点组合。

- 预期收益的估计误差经 $\boldsymbol{\Sigma}^{-1}$ 放大，期望效用损失为 $N/(2\lambda T)$（式 (11.10)）；样本相关矩阵的病态程度随 N/T 上升。
- 收缩（式 (11.11)）、因子结构（式 (11.13)）、EWMA 与 DCC（式 (11.16)）分别从「降低噪声」「降低维度」「引入时变」三个方向补救协方差估计。
- 鲁棒优化把不确定性集写成范数惩罚（式 (11.18)），Black–Litterman 用均衡先验加观点得到后验均值（式 (11.20)）。
- ERC 与风险预算的 KKT 条件为 $w_i(\boldsymbol{\Sigma}\boldsymbol{w})_i = b_i\sigma_p^2$（命题 11.1），其凸形式不含矩阵求逆；HRP 用聚类替代求逆（算法 11.1）。
- Kelly 比例 $f^* = (\mu - r)/\sigma^2$ 使对数增长率最大，最大值为 $r + \mathrm{SR}^2/2$；分数 Kelly 以 $(1-c^2)\mathrm{SR}^2/2$ 的增长率换取波动率的线性下降。
- CVaR 的 Rockafellar–Uryasev 形式把尾部风险优化变成线性规划（式 (11.31)），且 CVaR 是满足次可加性的一致性风险度量。
- 交易成本带来稀疏解与「带状前沿」（式 (11.33)）；绩效归因应给出 BHB/BF 配置效应与因子归因两套结果（表 11.3）。

练习与思考

1. 两资产情形下 $\boldsymbol{\Sigma} = \left(\begin{smallmatrix}\sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2\end{smallmatrix}\right)$。证明 GMVP 权重为 $w_1 = \dfrac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}$，并说明当 $\rho \to 1$ 时该权重为何不收敛（提示：$\boldsymbol{\Sigma}$ 趋于奇异）。
2. 用 式 (11.10) 计算：若 $\lambda = 4$、$T = 120$、N 从 50 增加到 500，期望效用损失增加多少？若改为把 500 个资产压缩成 25 个因子，损失如何变化？
3. 验证 式 (11.24) 中的 d_{ij} 满足三角不等式，并说明为什么必须做 $\sqrt{(1-\rho)/2}$ 而不是直接使用 $1-\rho$。
4. 在 小节 11.6.2 的设定下，用 式 (11.22) 写出 KKT 方程组，并解释为什么 $b_i = 1/N$ 时解与 $\boldsymbol{\Sigma}$ 的对角元成反比（提示：考虑对角矩阵的特殊情形）。
5. 设某策略月均超额收益 0.6%，月波动 3%，一阶自相关 0.25。分别用朴素年化与式 (11.47) 的修正计算年化夏普比率，并解释差异来源。
6. 把 式 (11.31) 改写为「在 $\mathrm{CVaR}_\beta \le c$ 约束下最大化期望收益」的形式，并说明该问题仍是线性规划。
7. 在 小节 11.8.2 的设定下，求使长期增长率为零的临界下注比例（答案：$f = 2f^*$），并画出 $g(f)$ 随 f 变化的曲线，标出 f^* 与临界点。
8. 用 式 (11.35) 说明：若乘数 $m = 4$、安全垫占组合的 10%，标的单日下跌多少会使 CPPI 跌破保本底线？并讨论为什么杠杆型 CPPI 在跳空市场中会失效。

延伸阅读

› Markowitz, H., “Portfolio Selection”, *Journal of Finance*, 1952.（均值-方差框架的原

始文献，读它的价值在于看清「收益-风险二维」这一抽象是如何被提出来的）

- Ledoit, O., and Wolf, M., "A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices", *Journal of Multivariate Analysis*, 2004.（收缩强度的最优公式，第 2 节给出了可直接实现的估计量）
- Black, F., and Litterman, R., "Global Portfolio Optimization", *Financial Analysts Journal*, 1992.（BL 模型的原始阐述，重点读「反向优化」的动机部分）
- Maillard, S., Roncalli, T., and Teïletche, J., "The Properties of Equally Weighted Risk Contribution Portfolios", *Journal of Portfolio Management*, 2010.（ERC 的解析性质与凸化证明）
- López de Prado, M., "Building Diversified Portfolios that Outperform Out of Sample", *Journal of Portfolio Management*, 2016.（HRP 算法原文，附有可直接复现的伪代码）
- Rockafellar, R. T., and Uryasev, S., "Optimization of Conditional Value-at-Risk", *Journal of Risk*, 2000.（CVaR 线性化的经典论文，是本章 式 (11.31) 的出处）
- Roncalli, T., *Introduction to Risk Parity and Budgeting*, CRC Press, 2013.（风险平价的系统性教材，覆盖 ERC、风险预算与多资产实施细节）
- Lo, A. W., "The Statistics of Sharpe Ratios", *Financial Analysts Journal*, 2002.（夏普比率的统计性质与自相关修正，是 式 (11.47) 的出处）

第十二章 美国证券从业资格考试

本章覆盖 FINRA 旗下的核心证券从业资格考试：SIE、Series 7、Series 57、Series 65、Series 24。这些考试是进入美国证券行业的关键门槛，也是量化金融从业者理解监管框架与业务规则的重要参考。与其他章节不同，本章的重点是可计算：每个知识领域都配有公式与数值例题。

⚠ 风险警示　考试参数具有时效性

本章列出的题量、时长、通过分数与费用来自编写时的 FINRA 公开大纲。**FINRA 会定期调整考试结构、费用与通过标准**，报考前务必以 `finra.org` 的最新《Content Outline》为准。

表 12.1　五门核心考试对比

考试	定位	计分题	时长	通过线	前置/担保
SIE	行业基础（人人可考）	75	1h45m	70%	无前置、无需担保
Series 7	通用证券代表	125	3h45m	72%	需 SIE + 雇主担保
Series 57	证券交易员	50	1h45m	70%	需 SIE + 雇主担保
Series 65	投资顾问法	130	3h	72%	无担保要求
Series 24	通用证券负责人	150	3h45m	70%	需 Series 7 类资格 + 担保

核心要点 12.1

这五门考试的分工可以这样理解：**SIE 考「行业常识」，Series 7 考「产品与客户」，Series 57 考「交易台规则」，Series 65 考「受托责任与投资建议」，Series 24 考「监督与合规管理」**。对量化从业者而言，Series 57 与 Series 24 的内容最接近日常工作场景（做市义务、订单报告、净资本）。

表 12.2　SIE 四大知识领域及权重

权重	领域	核心考点
16%	资本市场	SEC/FINRA/MSRB/美联储职能、一级与二级市场、ATS 与暗池、货币政策与财政政策
44%	产品理解	权益（普通股/优先股/ADR/认股权证）、债券（国债/市政债/公司债）、打包产品（基金/ETF/REIT/年金）、期权基础、风险类型
31%	交易、账户与禁止行为	现金账户与保证金账户、订单类型、T+1 结算、KYC 与适合性、内幕交易（10b-5）、AML
9%	监管框架	1933 证券法、1934 证券交易法、1940 投资公司法、1940 投资顾问法

12.1 SIE：证券行业基础考试

12.1.1　考试概述与知识领域

12.1.2　核心计算：债券收益率与税收等价

SIE 与 Series 7 都会考债券的三种收益率。设年票息 C、面值 F、当前价格 P、剩余期数 n：

$$\text{当前收益率：}\quad CY = \frac{C}{P} \tag{12.1}$$

$$\text{到期收益率：}\quad P = \sum_{t=1}^{n} \frac{C}{(1+y)^t} + \frac{F}{(1+y)^n} \tag{12.2}$$

$$\text{税收等价收益率：}\quad TEY = \frac{r_{\text{muni}}}{1-t} \tag{12.3}$$

其中 式 (12.3) 是市政债与应税债券的比较工具：t 为投资者的边际税率，r_{muni} 为免税市政债收益率。

例 12.1　市政债与公司债的选择

某投资者边际税率 $t = 35\%$（联邦 + 州）。免税市政债收益率 3.2%，一只同等风险的公司债收益率 4.6%。市政债的税收等价收益率为 $TEY = 0.032/(1-0.35) = 4.92\%$，**高于公司债的 4.6%，因此市政债更优**。换个角度看：公司债的税后收益为 $4.6\% \times (1-0.35) = 2.99\% < 3.2\%$，结论一致。**当税率较低（例如 $t = 12\%$）时，$TEY = 3.64\% < 4.6\%$，应税债券反而更优**——这就是为什么市政债的主要持有者是高税率个人与保险公司。

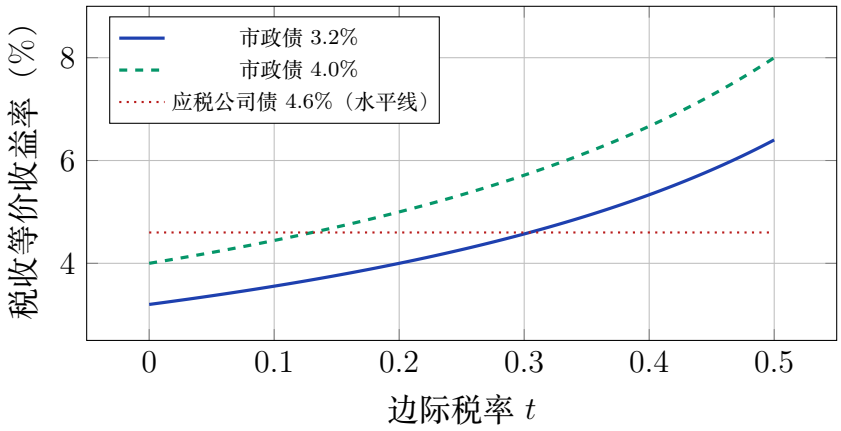


图 12.1　税收等价收益率随边际税率的变化：与应税债券水平线的交点即为「无差异税率」

表 12.3　四个基本期权头寸的盈亏平衡与最大盈亏

头寸	盈亏平衡点	最大盈利	最大亏损
买入看涨	K + 权利金	无上限	权利金
卖出看涨	K + 权利金	权利金	无上限
买入看跌	K − 权利金	K − 权利金	权利金
卖出看跌	K − 权利金	权利金	K − 权利金
备兑看涨	S_0 − 权利金	$(K - S_0)$ + 权利金	S_0 − 权利金
保护性看跌	S_0 + 权利金	无上限	S_0 − 权利金

12.1.3 核心计算：期权基础盈亏

考试要点 Series 7 高频考点

期权在 Series 7 中约占 30–35 题，几乎全部围绕三件事：(1) **画盈亏图 (Profit/Loss Diagram)**；(2) **算盈亏平衡点**；(3) **算保证金要求**。考试技巧：所有计算都从「最大风险 = 最大损失」出发，因为最大损失决定了保证金要求，而保证金计算是失分最多的题型。

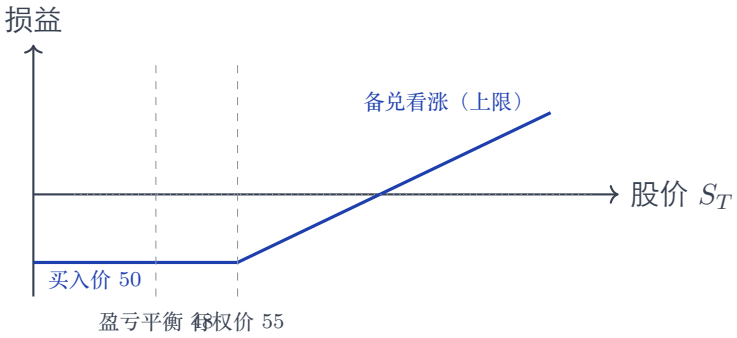


图 12.2 备兑看涨的损益图（买入 50 元股票、卖出 55 元看涨收权利金 2 元）：最大盈利 7 元、盈亏平衡 48 元

12.2 Series 7：通用证券代表

12.2.1 考试概述与知识领域

Series 7 是注册代表的旗舰考试，通过后可交易几乎所有证券产品。知识领域可归纳为四块：

1. **为客户寻求业务**：客户画像、税务考量（短期与长期资本利得、成本基础计算 FIFO/LIFO/特定识别）、退休计划（传统/Roth IRA、401(k)、403(b)、SEP、SIMPLE）、教育储蓄（529、Coverdell ESA）；
2. **评估客户财务画像与风险**：各类证券产品、市政债（GO 与 Revenue）、美国政府证券（T-Bills/Notes/Bonds、TIPS、STRIPS）、公司债、打包产品、期权策略、保证金账户；
3. **开立、维护与关闭账户**：账户文档、确认与对账单、投诉处理与记录保存；
4. **获取并验证客户买卖指示**：订单类型、执行与结算、交易报告。

12.2.2 核心计算：保证金账户与追缴

美国证券交易的保证金规则由 **Regulation T**（初始保证金，通常 50%）与 **FINRA 4210**（维持保证金，多头通常 25%）共同约束。

以多头为例，设买入价 P_0、股数 N、初始保证金比例 m_0、维持保证金比例 m：借款额 $L = NP_0(1-m_0)$，账户权益为 $E = NP - L$。**追缴（margin call）发生在权益恰好等于维持保证金要求时**：

$$\frac{NP_{\text{call}} - L}{NP_{\text{call}}} = m \quad \Longrightarrow \quad P_{\text{call}} = \frac{L}{N(1-m)} = \frac{P_0(1-m_0)}{1-m} \tag{12.4}$$

例 12.2　多头保证金追缴价的计算

以每股 60 元买入 100 股，共 6000 元，按 Reg T 借入 50% 即 3000 元，维持保证金 25%。由 式 (12.4)：

$$P_{\text{call}} = \frac{60 \times (1-0.5)}{1-0.25} = \frac{30}{0.75} = 40 \text{ 元}.$$

验证：价格跌到 40 元时，市值 4000 元、权益 $4000 - 3000 = 1000$ 元，恰好为市值的 25%。**若价格继续下跌，投资者必须在规定时间内补足保证金，否则经纪商将强制平仓。**注意初始保证金越低，追缴线越高（离现价越近），这就是「高杠杆容易被震出」的数学原因。

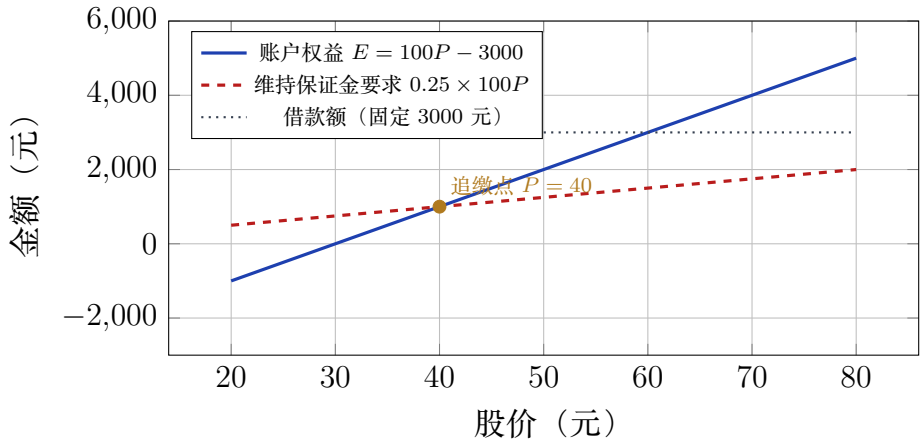


图 12.3　多头保证金账户：权益线与维持保证金要求的交点即追缴价

补充说明　空头与期权的保证金差异

空头的逻辑与多头相反：卖出股票的所得计入信用余额（credit balance），维持保证金通常为 30%，追缴价满足 MV = 信用余额/1.30。期权的保证金规则更复杂：**备兑看涨不需要额外保证金**（因为股票已作为担保），**而裸卖看涨理论风险无限，其保证金要求通常为「权利金 + 标的市值的一定比例」**；裸卖看跌的保证金则基于行权价与权利金。考试中最容易被忽略的一点是：**价差策略（spread）的保证金只按两个行权价之差计算**，而不是分别计算两条腿——这正是价差策略的资金效率来源。

12.3 Series 57：证券交易员

Series 57 面向股票、公司债与市政债交易员，**是与量化交易岗位最相关的一门考试。**

表 12.4　Series 57 的知识领域与交易台实务

权重	领域	核心考点
58%	交易活动与禁止行为	做市义务与报价规则、操纵行为（洗售 Wash Sales、Matched Orders、Painting the Tape、Spoofing/Layering）、MNPI 与内幕交易、最佳执行、禁止前端运行、净资本规则 15c3-1
26%	订单处理与交易报告	订单审计追踪（OATS 迁移至 CAT）、大额交易报告、场外交易处理
16%	一般证券知识与监管	监管机构分工、记录保存（17a-3/17a-4）、AML 与 OFAC 制裁合规

考试要点　Spoofing 与 Layering：算法交易时代的红线

Spoofing 指挂出并不打算成交的大额订单以影响市场对其他参与者判断，在成交前撤单；**Layering** 则是在多个价位挂出多层虚假订单。二者在 2010 年《多德–弗兰克法案》后被明确列为非法。对量化团队的含义是：**任何「用订单流误导市场」的订单生成逻辑都不是策略优化，而是违法行为**，必须在合规审查与代码层面同时设防（例如对「高频撤单率」设置硬性监控阈值）。

12.4 Series 65：统一投资顾问法律考试

Series 65 是成为注册投资顾问(RIA/IAR)的代表性资格，其核心是 **受托责任(Fiduciary Duty）与投资顾问法**。

12.4.1　核心计算：绩效指标

Series 65 会考察一组绩效与风险调整指标，务必区分分母：

$$\text{夏普比率：}\quad SR = \frac{R_p - R_f}{\sigma_p} \qquad \text{（分母为总风险）} \tag{12.5}$$

$$\text{特雷诺比率：}\quad TR = \frac{R_p - R_f}{\beta_p} \qquad \text{（分母为系统性风险）} \tag{12.6}$$

$$\text{詹森 Alpha：}\quad \alpha_p = R_p - [R_f + \beta_p (R_m - R_f)] \qquad \text{（CAPM 定价的偏离）} \tag{12.7}$$

$$\text{信息比率：}\quad IR = \frac{R_p - R_b}{\sigma (R_p - R_b)} \qquad \text{（分母为跟踪误差）} \tag{12.8}$$

例 12.3　同样 12% 收益，哪个基金经理更好

无风险利率 3%，市场收益 10%。基金 A：$R_p = 12\%$、$\sigma_p = 18\%$、$\beta = 1.2$；基金 B：$R_p = 12\%$、$\sigma_p = 12\%$、$\beta = 1.0$。则

$$SR_A = \frac{0.12 - 0.03}{0.18} = 0.50, \qquad TR_A = \frac{0.09}{1.2} = 0.075, \qquad \alpha_A = 0.006;$$
$$SR_B = \frac{0.09}{0.12} = 0.75, \qquad TR_B = \frac{0.09}{1.0} = 0.09, \qquad \alpha_B = 0.02.$$

其中 $\alpha_A = 0.12 - [0.03 + 1.2 \times 0.07] = 0.006$，$\alpha_B = 0.12 - [0.03 + 1.0 \times 0.07] = 0.02$。**三个指标一致地给出 B 更优**：相同的绝对收益下，B 用更低的总风险与更低的系统性风险实现，且超额收益中真正属于「选股能力」的部分（Alpha）更大。考试要点是：**当组合充分分散时，特雷诺比率与夏普比率结论一致；当组合未充分分散时，应当使用夏普比率，因为它惩罚了可分散风险。**

12.4.2　税后与通胀调整收益

$$\text{税后收益：} \quad R_{\text{after-tax}} = R_{\text{pretax}}\,(1 - t) \tag{12.9}$$

$$\text{实际（通胀调整）收益：} \quad R_{\text{real}} = \frac{1 + R_{\text{nominal}}}{1 + i} - 1 \approx R_{\text{nominal}} - i \tag{12.10}$$

考试要点　两个高频陷阱

(1) **不能用「名义收益 − 通胀」当作精确的实际收益**，正确做法是 $(1 + R) / (1 + i) - 1$（考试中的选项往往两者都给，需要用近似与精确区分）；(2) **长期资本利得与短期资本利得的税率不同**，计算税后收益时必须先判断持有期，且**市政债利息免征联邦所得税**——这也是 式 (12.3) 存在的原因。

12.5 Series 24：通用证券负责人

Series 24 是管理级资格，考的是**监督与合规架构**而非产品细节。

补充说明　净资本规则的两个直觉

SEC Rule 15c3-1 要求在券商资产与负债之间维持一个最低的「净资本」缓冲，其思想是：**保证券商在市场剧烈波动时仍有能力履行对客户的义务**。Rule 15c3-3（客户保护规则）则要求把客户证券与自有证券隔离，并通过「准备金账户（reserve bank account）」确保客户资产不被挪用。对量化团队而言，这两条规则的实务含义是：**策略的资金占用不只包括保证金，还包括券商的监管资本成本**——这也是 XVA 中 KVA（资本估值调整）存在的现实根源。

表 12.5　Series 24 的四大领域

权重	领域	核心考点
24%	投资银行与研究监管	包销（Firm Commitment）与代销（Best Efforts）、注册流程与招股说明书、尽职调查、研究分析师隔离、安静期
19%	交易与做市监管	做市商义务、Regulation SHO 卖空规则、大宗与异常交易报告
29%	客户账户与销售实践	账户审批与监督、适合性与 Reg BI、AML 计划、隐私规则 Reg S-P、投诉处理、老年人财务剥削报告
28%	运营与财务监管	净资本规则 15c3-1、客户保护规则 15c3-3、记录保存 17a-3/17a-4、FOCUS 报告、年度审计、业务连续性（BCP）与网络安全

表 12.6　典型考证路径对照

职业方向	必要考试	辅助/加分考试
注册代表 / 经纪人	SIE + Series 7	Series 63 或 66
交易员（自营/做市）	SIE + Series 57	Series 7
投资顾问（RIA/IAR）	Series 65	Series 7（可选）
合规 / 负责人	Series 24	Series 7、63/65
量化研究员 / 分析师	通常无强制要求	Series 7/57 有助于理解业务与合规边界

12.6 考证路径与量化从业者的取舍

实务应用　量化从业者应该如何取舍

对量化研究员而言，这些考试的价值不在于数学深度（考试的数学远简单于日常工作），而在于四点：

1. **合规边界的可执行化**：知道哪些订单行为违法（Spoofing、前端运行、洗售），才能把合规规则写进代码与风控阈值；
2. **业务语汇**：与交易台、销售、合规沟通时能使用共同术语，减少误解成本；
3. **职业许可**：需要与客户互动或提供建议的岗位必须有相应资格；
4. **产品广度**：考试覆盖了策略可能触及的几乎所有证券类型及其交易规则（结算周期、报告要求）。

本章小结

- 五门考试的分工：SIE（行业常识）→ Series 7（产品与客户）、57（交易台规则）、65（受托责任与投资建议）、24（监督与合规管理）。
- 债券的三种收益率：当前收益率 C/P、到期收益率（解 式 (12.2)）、税收等价收益率 $TEY = r_{\text{muni}}/(1-t)$。
- 多头保证金的追缴价 $P_{\text{call}} = P_0(1-m_0)/(1-m)$；杠杆越高，追缴线离现价越近。
- 期权的盈亏平衡与最大损失是保证金计算的基础；价差策略的保证金按行权价之差计算。
- 风险调整绩效指标的分母各不相同：夏普用 σ_p、特雷诺用 β_p、信息比率用跟踪误差；组合未充分分散时应看夏普比率。
- 税后收益 $R(1-t)$、实际收益 $(1+R)/(1+i)-1$；市政债利息免联邦税，这是 TEY 的用途。
- Series 24 的核心是净资本（15c3-1）与客户保护（15c3-3）——它们最终以资本成本的形式进入量化策略的成本核算。

练习与思考

1. 某投资者边际税率 24%，免税市政债收益率 2.8%。要使其与应税债券无差异，应税债券的收益率应为多少？若市场上同等风险的应税债券报价 3.5%，应选择哪一个？

2. 以每股 45 元买入 200 股，初始保证金 50%，维持保证金 30%。求追缴价，并说明如果初始保证金降到 40%，追缴价如何变化。

3. 某投资者买入 100 股（每股 50 元）并卖出 1 张 55 元看涨期权（权利金 2 元）。请

写出最大盈利、最大亏损与盈亏平衡点，并说明该策略在什么市场情形下最优。

4. 基金 C 的收益 15%、标准差 20%、$\beta = 1.3$；无风险利率 3%，市场收益 10%。请计算夏普比率、特雷诺比率与詹森 Alpha，并判断其超额收益主要来自选股还是承担系统性风险。
5. 某投资者名义收益 8%，通胀 3%，适用税率 20%，且收益全部为短期资本利得。请计算其税后实际收益（分别用近似公式与精确公式）。
6. 解释为什么「裸卖看涨期权」的保证金要求高于「备兑看涨」，并说明在 Series 24 的净资本规则视角下，这两种头寸对券商资本占用的差异。

延伸阅读

- FINRA, *Content Outlines for the SIE, Series 7, Series 57, Series 65 and Series 24 Examinations*, Financial Industry Regulatory Authority, 2024.（唯一的权威大纲，报考前必读）
- U.S. Securities and Exchange Commission, *Regulation Best Interest: The Broker-Dealer Standard of Conduct*, Release No. 34-86031, 2019.（适合性与最佳利益规则的法规原文）
- Basel Committee on Banking Supervision, *Basel III: Finalising Post-Crisis Reforms*, Bank for International Settlements, 2017.（与净资本、杠杆率要求对照阅读，理解资本约束的全貌）
- Hull, J. C., *Options, Futures, and Other Derivatives*, 10th ed., Pearson, 2018.（第 3 章关于保证金机制的讲解比考试教材更清晰）
- Hasbrouck, J., *Empirical Market Microstructure*, Oxford University Press, 2007.（理解做市义务、订单类型与交易报告背后的市场结构）

附录 A 数学公式速查

本附录汇总全书反复使用的数学结论，便于快速查阅。所有公式均可在正文相应章节找到来源说明。

A.1 常用概率分布

表 A.1　连续分布的密度函数与矩

分布	密度函数 $f(x)$	均值	方差
正态 $\mathcal{N}(\mu,\sigma^2)$	$\dfrac{1}{\sigma\sqrt{2\pi}}\exp\left(-\dfrac{(x-\mu)^2}{2\sigma^2}\right)$	μ	σ^2
对数正态	$\dfrac{1}{x\sigma\sqrt{2\pi}}\exp\left(-\dfrac{(\ln x-\mu)^2}{2\sigma^2}\right),\ x>0$	$\mathrm{e}^{\mu+\sigma^2/2}$	$(\mathrm{e}^{\sigma^2}-1)\mathrm{e}^{2\mu+\sigma^2}$
学生 t（ν 自由度）	$\dfrac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)}\left(1+\dfrac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$	0（$\nu>1$）	$\dfrac{\nu}{\nu-2}$（$\nu>2$）
指数（速率 λ）	$\lambda\mathrm{e}^{-\lambda x},\ x\ge 0$	$1/\lambda$	$1/\lambda^2$
伽马 (α,β)	$\dfrac{\beta^\alpha}{\Gamma(\alpha)}x^{\alpha-1}\mathrm{e}^{-\beta x}$	α/β	α/β^2
贝塔 (a,b)	$\dfrac{x^{a-1}(1-x)^{b-1}}{B(a,b)},\ x\in(0,1)$	$\dfrac{a}{a+b}$	$\dfrac{ab}{(a+b)^2(a+b+1)}$
帕累托（α 尾指数）	$\dfrac{\alpha x_m^\alpha}{x^{\alpha+1}},\ x\ge x_m$	$\dfrac{\alpha x_m}{\alpha-1}$（$\alpha>1$）	$\dfrac{x_m^2\alpha}{(\alpha-1)^2(\alpha-2)}$（$\alpha>2$）

补充说明　关于 t 分布与金融收益

学生 t 分布是刻画金融收益率肥尾的最简模型。自由度 ν 越小尾部越厚；$\nu\le 2$ 时方差不存在，$\nu\le 4$ 时四阶矩不存在——这意味着**样本峰度在选择 ν 较小时本身就是不稳定的统计量**。实务中股票日收益的拟合值常在 $\nu\in[3,6]$ 之间。

A.2 高斯积分与正态分布结论

$$\int_{-\infty}^{\infty}\mathrm{e}^{-ax^2+bx}\,\mathrm{d}x=\sqrt{\frac{\pi}{a}}\exp\left(\frac{b^2}{4a}\right),\quad a>0 \tag{A.1}$$

$$\mathbb{E}[\mathrm{e}^{\theta Z}]=\mathrm{e}^{\theta^2/2},\quad Z\sim\mathcal{N}(0,1) \tag{A.2}$$

$$\mathbb{E}[Z\,\mathbf{1}_{\{Z>c\}}]=\phi(c),\qquad \mathbb{E}[\mathbf{1}_{\{Z>c\}}]=1-\Phi(c) \tag{A.3}$$

$$\mathbb{E}[(Z-c)^+]=\phi(c)-c\,(1-\Phi(c)) \tag{A.4}$$

表 A.2　离散分布与极限定理

分布 / 定理	概率函数或结论	关键记号
二项 $B(n,p)$	$P(X=k)=\binom{n}{k}p^k(1-p)^{n-k}$	均值 np，方差 $np(1-p)$
泊松 (λ)	$P(X=k)=\dfrac{\lambda^k \mathrm{e}^{-\lambda}}{k!}$	均值 = 方差 = λ
几何（成功概率 p）	$P(X=k)=(1-p)^{k-1}p$	无记忆性
中心极限定理	$\dfrac{\sqrt{n}(\bar{X}_n-\mu)}{\sigma}\xrightarrow{d}\mathcal{N}(0,1)$	独立同分布、方差有限
大数定律	$\bar{X}_n\xrightarrow{p}\mu$	弱收敛 / 依概率收敛

最后一行是 Black–Scholes 公式中「看涨期权期望收益」的核心积分，也是 $\mathbb{E}[(Z-c)^+]=\phi(c)-c\Phi(-c)$ 这一常用形式的来源。

核心要点 A.1　正态尾部的 Mills 比率

当 $c\to\infty$ 时

$$1-\Phi(c)\sim\frac{\phi(c)}{c}\left(1-\frac{1}{c^2}+\frac{3}{c^4}-\cdots\right),$$

因此在深度虚值区域，期权价格的相对误差对波动率极为敏感：这是隐含波动率在极端行权价上不稳定、以及方差互换复制需要在尾部做外推的根本原因。

A.3 矩阵代数与向量求导

$$(AB)^{-1}=B^{-1}A^{-1} \tag{A.5}$$

$$(A+UCV)^{-1}=A^{-1}-A^{-1}U\left(C^{-1}+VA^{-1}U\right)^{-1}VA^{-1}\quad\text{（Woodbury 恒等式）} \tag{A.6}$$

$$\frac{\partial}{\partial x}\left(a^Tx\right)=a,\qquad\frac{\partial}{\partial x}\left(x^TAx\right)=(A+A^T)x \tag{A.7}$$

$$\frac{\partial}{\partial X}\ln\det X=\left(X^{-1}\right)^T,\qquad\frac{\partial}{\partial X}\operatorname{tr}(AX)=A^T \tag{A.8}$$

$$\frac{\partial}{\partial X}\operatorname{tr}\left(X^{-1}A\right)=-\left(X^{-1}AX^{-1}\right)^T \tag{A.9}$$

对协方差矩阵求导是组合优化与多元统计的核心运算。若 $\boldsymbol{\Sigma}$ 对称，则 $\frac{\partial}{\partial \boldsymbol{w}}\left(\boldsymbol{w}^T\boldsymbol{\Sigma}\boldsymbol{w}\right)=2\boldsymbol{\Sigma}\boldsymbol{w}$，这正是最小方差组合一阶条件 $2\boldsymbol{\Sigma}\boldsymbol{w}=\lambda\mathbf{1}$ 的来源。

表 A.3　常用矩阵分解与用途

分解	形式	金融用途
Cholesky	$\boldsymbol{\Sigma} = LL^T$（$\boldsymbol{\Sigma}$ 正定）	生成相关随机数、蒙特卡洛路径
特征分解	$\boldsymbol{\Sigma} = Q\Lambda Q^T$（对称）	主成分分析、风险因子提取
奇异值分解	$X = U\Sigma V^T$	因子模型降维、条件数诊断
谱条件数	$\kappa = \lambda_{\max}/\lambda_{\min}$	判断 $\boldsymbol{\Sigma}^{-1}$ 是否放大估计误差

A.4 概率论常用结论

条件期望的性质

$$\mathbb{E}[X \mid \mathcal{F}] = X \quad \text{若} X \text{ 为} \mathcal{F}\text{-可测} \tag{A.10}$$

$$\mathbb{E}\left[\mathbb{E}[X \mid \mathcal{F}]\right] = \mathbb{E}[X] \quad \text{（全期望公式）} \tag{A.11}$$

$$\mathbb{E}\left[\mathbb{E}[X \mid \mathcal{F}_2] \mid \mathcal{F}_1\right] = \mathbb{E}\left[X \mid \mathcal{F}_1\right], \quad \mathcal{F}_1 \subseteq \mathcal{F}_2 \quad \text{（塔性质）} \tag{A.12}$$

$$\operatorname{Var}(X) = \mathbb{E}\left[\operatorname{Var}(X \mid \mathcal{F})\right] + \operatorname{Var}\left(\mathbb{E}[X \mid \mathcal{F}]\right) \quad \text{（方差分解）} \tag{A.13}$$

塔性质是鞅论一切结论的起点：它说明「用更少的信息做预测，等于先用更多信息预测再取平均」。

常用不等式

- **Jensen 不等式**：φ 为凸函数时 $\varphi(\mathbb{E}[X]) \le \mathbb{E}[\varphi(X)]$。由 $\ln$ 的凹性可得几何平均不超过算术平均；由凸性可得 $\mathbb{E}[\max(X,0)] \ge \max(\mathbb{E}[X],0)$。

- **Cauchy–Schwarz**：$|\mathbb{E}[XY]| \le \sqrt{\mathbb{E}[X^2]\mathbb{E}[Y^2]}$，因此相关系数满足 $|\rho| \le 1$。

- **Markov**：$P(X \ge a) \le \mathbb{E}[X]/a$（$X \ge 0$）。

- **Chebyshev**：$P(|X-\mu| \ge k\sigma) \le 1/k^2$——与真实肥尾分布相比，该界在金融数据上通常过于乐观，这正是极值理论存在的理由。

- **Hölder**：$\mathbb{E}[|XY|] \le \left(\mathbb{E}[|X|^p]\right)^{1/p}\left(\mathbb{E}[|Y|^q]\right)^{1/q}$，$\frac{1}{p}+\frac{1}{q}=1$。

A.5 随机分析核心公式

$$\text{伊藤引理：}\quad \mathrm{d}f(t,X_t)=\left(\frac{\partial f}{\partial t}+\mu_t\frac{\partial f}{\partial x}+\frac{1}{2}\sigma_t^2\frac{\partial^2 f}{\partial x^2}\right)\mathrm{d}t+\sigma_t\frac{\partial f}{\partial x}\mathrm{d}W_t \tag{A.14}$$

$$\text{乘积法则：}\quad \mathrm{d}(X_tY_t)=X_t\,\mathrm{d}Y_t+Y_t\,\mathrm{d}X_t+\mathrm{d}\langle X,Y\rangle_t \tag{A.15}$$

$$\text{分部积分：}\quad \int_0^T X_t\,\mathrm{d}Y_t=X_TY_T-X_0Y_0-\int_0^T Y_t\,\mathrm{d}X_t-\langle X,Y\rangle_T \tag{A.16}$$

$$\text{伊藤等距：}\quad \mathbb{E}\left[\left(\int_0^T\phi_t\,\mathrm{d}W_t\right)^2\right]=\mathbb{E}\left[\int_0^T\phi_t^2\,\mathrm{d}t\right] \tag{A.17}$$

$$\text{二次变差：}\quad \langle W\rangle_T=\lim_{|\Pi|\to 0}\sum_i\left(W_{t_{i+1}}-W_{t_i}\right)^2=T \tag{A.18}$$

几何布朗运动 $S_t=S_0\exp\left((\mu-\frac{1}{2}\sigma^2)t+\sigma W_t\right)$ 的推导，以及风险中性漂移替换 $\mu\to r$ 的过程，见第 10 章与第 6 章。

A.6 常用泰勒展开与近似

$$\mathrm{e}^x\approx 1+x+\frac{x^2}{2},\qquad \ln(1+x)\approx x-\frac{x^2}{2} \tag{A.19}$$

$$(1+x)^n\approx 1+nx+\frac{n(n-1)}{2}x^2,\qquad \sqrt{1+x}\approx 1+\frac{x}{2}-\frac{x^2}{8} \tag{A.20}$$

$$\frac{1}{1-x}\approx 1+x+x^2,\qquad N(d+h)\approx N(d)+\phi(d)h \tag{A.21}$$

实务应用　用这些近似做什么

- 对数收益与简单收益的关系：$r_{\text{simple}}\approx r_{\log}+\frac{1}{2}r_{\log}^2$，因此用对数收益做回归会系统性低估高波动期的真实收益；
- 凸性调整：$\Delta P/P\approx -D^*\Delta y+\frac{1}{2}C_{\text{conv}}(\Delta y)^2$，利率大幅变动时二阶项不可忽略；
- 期权希腊字母的局部线性近似：$\Delta V\approx\Delta\cdot\Delta S+\frac{1}{2}\Gamma(\Delta S)^2+\nu\,\Delta\sigma+\Theta\,\Delta t$，这是风险系统日常 PnL 归因（PnL attribution）的基础。

表 A.4　希腊字母与常用含义

小写	大写	LaTeX	读音	金融中的常见用法
α	A	`\alpha`	alpha	超额收益（Jensen's alpha）、显著性水平
β	B	`\beta`	beta	因子暴露、系统性风险、第一类错误
γ	Γ	`\gamma`	gamma	风险厌恶系数；Γ 为期权 Gamma
δ	Δ	`\delta`	delta	收缩强度；Δ 为期权 Delta
ε	E	`\varepsilon`	epsilon	扰动项、特质收益
θ	Θ	`\theta`	theta	参数向量；Θ 为期权时间损耗
κ	K	`\kappa`	kappa	均值回复速度
λ	Λ	`\lambda`	lambda	风险价格、违约强度、风险厌恶、特征值
μ	M	`\mu`	mu	期望收益 / 漂移率
ν	N	`\nu`	nu	自由度；期权 Vega（ν）
ξ	Ξ	`\xi`	xi	波动率的波动率（vol-of-vol）
ρ	P	`\rho`	rho	相关系数；期权 Rho（利率敏感度）
σ	Σ	`\sigma`	sigma	波动率；Σ 为协方差矩阵
τ	T	`\tau`	tau	剩余期限、违约时间
ϕ	Φ	`\phi`	phi	标准正态密度 / 累积分布函数
χ	X	`\chi`	chi	卡方分布
ψ	Ψ	`\psi`	psi	特征函数
ω	Ω	`\omega`	omega	观点不确定性矩阵、长期方差

A.7 希腊字母表

风险警示

ν、ρ、λ、θ 是全书中多义最严重的四个符号：ν 既是自由度又是 Vega，ρ 既是相关系数又是期权 Rho，λ 既可以是风险价格也可以是风险厌恶系数，θ 既可以是参数向量也可以是长期均值。阅读时务必以当章正文的定义为准，不要跨章套用。

A.8 数值方法速查

表 A.5　核心数值方法的收敛性质

方法	收敛阶	要点
二分法	线性 $(1/2)^n$	稳健但慢；只要求连续性与符号变化
Newton–Raphson	二次	需要导数；用于隐含波动率反解（用 Vega 作导数）
割线法	超线性 ≈ 1.618	无需导数，用于曲线 bootstrap 求根
蒙特卡洛	$O(N^{-1/2})$	与维数无关，误差 $\propto \mathrm{sd}/\sqrt{N}$
拟蒙特卡洛（Sobol）	约 $O(N^{-1})$	低差异序列，高维时优势衰减
二叉树（CRR）	$O(1/M)$	M 为步数；美式期权可直接向后递推
Crank–Nicolson	$O(\Delta t^2 + \Delta x^2)$	无条件稳定，但可能出现振荡（需 Rannacher 启动）
快速傅里叶变换	一次算出全行权价	需求出特征函数解析式（仿射模型）

直觉理解　为什么蒙特卡洛在高维下胜出

二叉树与有限差分在 d 维问题上的计算量按 M^d 增长（维数灾难），而蒙特卡洛的误差几乎与 d 无关（只依赖被估量的方差）。这解释了为什么带随机波动率、多标的、路径依赖的结构化产品几乎只能靠蒙特卡洛定价。

附录 B Python 量化工具链

本附录给出从数据到回测的最小可用工具链。代码全部为可直接运行的 Python 片段，变量与注释使用英文以保证跨平台可执行。

B.1 环境与依赖

Listing B.1 推荐的环境准备方式（uv 与 conda 二选一）

```
# Option 1: uv (fast, modern)
uv venv .venv && source .venv/bin/activate
uv pip install numpy pandas scipy statsmodels arch scikit-learn cvxpy \
               matplotlib pyarrow yfinance numba

# Option 2: conda
conda create -n quant python=3.11 -y
conda activate quant
pip install -r requirements.txt
```

表 B.1 量化金融常用 Python 库与分工

库	职责	典型用途
numpy	向量化数值计算、随机数生成	蒙特卡洛路径、线性代数
pandas	带标签的时间序列与表格运算	数据对齐、重采样、滚动窗口
scipy	优化、插值、统计分布、求根	隐含波动率反解、曲线拟合
statsmodels	计量经济学模型	OLS/GLS、ARIMA、协整、面板
arch	条件异方差模型	GARCH/EGARCH/GJR、波动率预测
scikit-learn	机器学习与预处理	因子非线性建模、交叉验证
cvxpy	凸优化建模（DSL）	均值–方差、风险平价、CVaR 优化
numba	即时编译加速	逐路径回测、期权定价循环
pyarrow / parquet	列式存储	大规模行情与因子数据

B.2 数据读取与清洗

Listing B.2 价格数据对齐、复权与缺失值处理

```python
import numpy as np
import pandas as pd

def load_prices(path: str, tickers: list[str]) -> pd.DataFrame:
    """Load adjusted close prices and align them on a common calendar."""
    px = pd.read_parquet(path)                    # MultiIndex or wide format
    px = px.loc[:, tickers].sort_index()
    px = px[~px.index.duplicated(keep="last")]
    px = px.ffill(limit=5)                        # short gaps only
    px = px.dropna(how="any")                     # keep the common history
    return px

def log_returns(px: pd.DataFrame) -> pd.DataFrame:
    r = np.log(px / px.shift(1)).dropna(how="all")
    return r.replace([np.inf, -np.inf], np.nan).dropna(how="any")
```

⚠ 风险警示　三个最常见的清洗错误

1. **用未复权价格计算收益**：除权除息日会出现虚假的巨额负收益，因子测试结果被彻底污染；
2. **用 `ffill()` 无长度限制地填补停牌与退市**：会把「无交易」伪装成「零波动」，压低协方差估计并制造虚假的平稳性；
3. **只保留当前仍在交易的股票**：典型的幸存者偏差，对价值与困境反转类因子的影响尤其大。

B.3 描述统计与肥尾检验

Listing B.3 收益率描述统计：年化、偏度、峰度、Jarque–Bera

```python
import numpy as np
import pandas as pd
from scipy import stats

def summary_stats(r: pd.Series, periods: int = 252) -> pd.Series:
    ann_ret = r.mean() * periods
    ann_vol = r.std(ddof=1) * np.sqrt(periods)
    downside = r[r < 0].std(ddof=1) * np.sqrt(periods)
    return pd.Series({
        "ann_return": ann_ret,
        "ann_vol": ann_vol,
        "sharpe": ann_ret / ann_vol if ann_vol > 0 else np.nan,
        "sortino": ann_ret / downside if downside > 0 else np.nan,
```

```
        "skew": stats.skew(r),
        "excess_kurtosis": stats.kurtosis(r),
        "jb_pvalue": stats.jarque_bera(r).pvalue,
        "max_drawdown": (r.add(1).cumprod().cummax()
                         - r.add(1).cumprod()).max(),
    })
```

核心要点 B.1　判断「肥尾」的正确姿势

`excess_kurtosis` 为正只说明样本呈现出厚尾，**并不证明总体四阶矩存在**。在 t 分布且 $\nu \le 4$ 时，样本峰度的抽样分布极不稳定。更稳健的做法是：(1) 用 Hill 估计或 GPD 拟合尾指数；(2) 直接比较经验分位数与正态分位数在 $1\%/0.1\%$ 分位上的差异。

B.4 波动率建模

Listing B.4　用 arch 拟合 GARCH(1,1)-t 并预测年化波动率

```
import numpy as np
from arch import arch_model

def garch_forecast(returns: np.ndarray, horizon: int = 5) -> dict:
    """Fit GARCH(1,1) with Student-t errors and forecast volatility."""
    r = 100.0 * returns                          # percentage scale is
        stabler
    res = arch_model(r, mean="Constant", vol="Garch", p=1, q=1,
                     dist="t").fit(disp="off")
    fc = res.forecast(horizon=horizon, reindex=False)
    var = fc.variance.values[-1]                 # in (%)^2
    ann_vol = np.sqrt(var * 252.0) / 100.0       # back to decimals
    alpha, beta = res.params["alpha[1]"], res.params["beta[1]"]
    half_life = np.log(0.5) / np.log(alpha + beta)
    return {"params": res.params, "ann_vol": ann_vol,
            "half_life_days": half_life, "loglik": res.loglikelihood}
```

补充说明　持久性与半衰期

GARCH(1,1) 的波动率冲击半衰期为 $-\ln 2/\ln(\alpha+\beta)$。当 $\alpha+\beta=0.95$ 时约 13.5 天，0.99 时约 69 天。若估计出的 $\alpha+\beta$ 逼近甚至超过 1，说明模型认为波动率冲击永不衰减，此时点预测虽然可用，但长期方差 $\omega/(1-\alpha-\beta)$ 已无意义——这通常意味着样本中存在结构突变或长记忆，应考虑 FIGARCH 或加入机制转换。

B.5 因子研究

Listing B.5　因子中性化与信息系数（IC）计算

```
import numpy as np
```

```python
import pandas as pd
import statsmodels.api as sm

def neutralize(factor: pd.Series, exposures: pd.DataFrame) -> pd.Series:
    """Cross-sectional OLS: factor ~ industry dummies + style exposures.
       """
    y = factor.dropna()
    X = exposures.loc[y.index]
    X = sm.add_constant(X)
    resid = sm.OLS(y, X, hasconst=True).fit().resid
    return resid

def rank_ic(factor: pd.DataFrame, fwd_ret: pd.DataFrame) -> pd.Series:
    """Cross-sectional Spearman correlation per date."""
    ic = {}
    for dt in factor.index.intersection(fwd_ret.index):
        f, r = factor.loc[dt], fwd_ret.loc[dt]
        mask = f.notna() & r.notna()
        if mask.sum() > 30:
            ic[dt] = f[mask].corr(r[mask], method="spearman")
    return pd.Series(ic).sort_index()

def ic_report(ic: pd.Series, periods: int = 252) -> dict:
    return {"IC_mean": ic.mean(), "IC_std": ic.std(ddof=1),
            "ICIR": ic.mean() / ic.std(ddof=1) * np.sqrt(periods),
            "t_stat": ic.mean() / ic.std(ddof=1) * np.sqrt(len(ic)),
            "positive_ratio": (ic > 0).mean()}
```

实务应用　IC 与 IR 的经验尺度

横截面 RankIC 的月频均值若能达到 0.03–0.05 已属良好，0.05 以上通常意味着较强的选股能力（或尚未被修正的前视偏差）。月频 ICIR 在 0.5 左右是可用的水准。注意：**IC 的绝对值远小于直觉预期**，这正是「基本定律」中需要用广度 $\sqrt{\text{Breadth}}$ 去放大信号的原因。

B.6 组合优化

Listing B.6　用 cvxpy 求解带约束的均值–方差与等风险贡献组合

```python
import numpy as np
import cvxpy as cp

def min_variance(mu: np.ndarray, cov: np.ndarray, w_max: float = 0.1):
    n = len(mu)
    w = cp.Variable(n)
    cons = [cp.sum(w) == 1, w >= 0, w <= w_max]
    prob = cp.Problem(cp.Minimize(cp.quad_form(w, cov)), cons)
    prob.solve()
    return w.value
```

```python

def max_utility(mu: np.ndarray, cov: np.ndarray, lam: float = 5.0):
    n = len(mu)
    w = cp.Variable(n)
    cons = [cp.sum(w) == 1, w >= 0]
    obj = cp.Maximize(mu @ w - 0.5 * lam * cp.quad_form(w, cov))
    cp.Problem(obj, cons).solve()
    return w.value

def risk_parity(cov: np.ndarray, budget: np.ndarray | None = None):
    """Solve for equal (or budgeted) risk contributions via convex program."""
    n = cov.shape[0]
    b = np.ones(n) / n if budget is None else budget / budget.sum()
    y = cp.Variable(n, nonneg=True)
    port_var = cp.quad_form(y, cov)
    obj = cp.Minimize(port_var - b @ cp.log(y))
    cp.Problem(obj).solve()
    w = y.value / y.value.sum()
    return w
```

直觉理解　风险平价的建模技巧

上面把「等风险贡献」写成了凸优化问题，而不是直接解非线性方程组。技巧在于：最小化 $y^T\Sigma y - \sum_i b_i \ln y_i$ 的一阶条件恰好是 $2(\Sigma y)_i = b_i / y_i$，即 $y_i(\Sigma y)_i \propto b_i$，还原成权重后就是「风险贡献等于预算」。这类**把均衡条件写成优化目标**的思路，在组合管理中非常常用。

B.7 衍生品定价

Listing B.7　Black–Scholes 定价、Newton 法反解隐含波动率与蒙特卡洛验证

```python
import numpy as np
from scipy.stats import norm

def bsm_price(S, K, r, sigma, T, kind="call"):
    d1 = (np.log(S / K) + (r + 0.5 * sigma ** 2) * T) / (sigma * np.sqrt(T))
    d2 = d1 - sigma * np.sqrt(T)
    if kind == "call":
        return S * norm.cdf(d1) - K * np.exp(-r * T) * norm.cdf(d2)
    return K * np.exp(-r * T) * norm.cdf(-d2) - S * norm.cdf(-d1)

def implied_vol(price, S, K, r, T, kind="call", tol=1e-8, max_iter=100):
    sigma = 0.2
    for _ in range(max_iter):
        diff = bsm_price(S, K, r, sigma, T, kind) - price
        vega = S * norm.pdf((np.log(S / K) + (r + 0.5 * sigma ** 2) * T)
                            / (sigma * np.sqrt(T))) * np.sqrt(T)
```

```
        if abs(diff) < tol:
            break
        sigma -= diff / vega
    return sigma

def bsm_mc(S, K, r, sigma, T, n=200_000, seed=42):
    rng = np.random.default_rng(seed)
    z = rng.standard_normal(n)
    ST = S * np.exp((r - 0.5 * sigma ** 2) * T + sigma * np.sqrt(T) * z)
    payoff = np.maximum(ST - K, 0.0)
    return np.exp(-r * T) * payoff.mean(), payoff.std(ddof=1) / np.sqrt(n
        )
```

⚠ 风险警示　Newton 法反解隐含波动率的失效场景

当 Vega 趋于 0 时（深度虚值、临近到期），Newton 迭代会剧烈震荡或发散。实务中的处理方式是：(1) 先做无套利检查（价格是否落在内在价值与标的价之间）；(2) 用二分法或 Brent 法作为兜底；(3) 对波动率曲面做 SVI/SABR 参数化后再插值，而不是逐点反解。对全期限、全行权价的逐点反解很容易产生「日历套利」与「蝶式套利」的假象。

B.8 工程实践要点

表 B.2　从研究到生产的常见工程陷阱

陷阱	症状与对策
随机数不可复现	回测结果无法重现。对策：统一使用 `np.random.default_rng(seed)`，并把种子写入配置。
浮点比较	用 `==` 比较价格或权重导致误判。对策：用 `np.isclose` 与绝对/相对容差。
循环写得太慢	Python 逐行循环处理数百万行行情。对策：向量化，或对嵌套路径循环使用 `numba.njit`。
内存爆炸	一次性加载十年全市场逐笔数据。对策：Parquet + 按日期分区、分块处理、`dtype` 降位。
时间对齐错误	把不同时区的收盘价直接相减，或用未来公布的财报。对策：统一时区与交易日历，严格使用「公告日 + 1」作为可用日。
参数硬编码	换一个市场就全盘失效。对策：把交易成本、涨跌停、停牌规则做成显式参数并记录版本。

核心要点 B.2　可复现性是量化研究的第一生产力

一份研究结果如果不能被别人（包括三个月后的你自己）用同一份数据与代码复现出来，它的价值为零。最小要求是：**数据快照 + 代码版本 + 随机种子 + 参数配置**四件套齐全，并且把「研究环境」与「生产环境」的差异显式记录在案。

附录 C 术语中英对照

阅读英文文献与面试时，术语的英文表达往往比中文更常用。下表按主题分组，每条给出英文、中文与一句话解释（含所在章节）。

C.1 市场与产品

英文	中文	说明与章节
Primary / Secondary Market	一级 / 二级市场	证券首次发行与后续流通市场（第 1 章）
Money Market	货币市场	期限不超过一年的短期资金市场（第 1 章）
Repurchase Agreement (Repo)	回购协议	以证券为抵押的短期融资，是货币市场核心工具（第 1 章）
Commercial Paper	商业票据	企业发行的短期无担保票据（第 1 章）
Yield Curve	收益率曲线	不同期限的无风险收益率关系（第 1 章）
Duration / Convexity	久期 / 凸性	债券价格对利率的一阶 / 二阶敏感度（第 1、5 章）
Immunization	免疫策略	用久期与凸性匹配资产负债的利率风险（第 1 章）
DuPont Analysis	杜邦分解	把 ROE 拆成净利率、周转率与权益乘数（第 1 章）
Forward / Futures	远期 / 期货	场外与交易所的远期合约（第 4 章）
Swap / Swaption	互换 / 互换期权	交换现金流的合约与其期权（第 4 章）
Cap / Floor	利率上限 / 下限	一系列利率看涨 / 看跌期权（第 4 章）
Autocallable	自动赎回结构	触发障碍即提前赎回的结构化产品（第 4 章）
Credit Default Swap (CDS)	信用违约互换	转移参考实体违约风险的合约（第 4 章）
Collateralized Debt Obligation	担保债务凭证	把信用风险池分层的结构化产品（第 4 章）
Municipal Bond / TEY	市政债 / 税收等价收益率	免税债券与应税债券的收益比较（第 12 章）

C.2 定价与随机分析

英文	中文	说明与章节
No-Arbitrage	无套利	定价的第一性原理（第 4、6 章）
Law of One Price	一价定律	相同现金流必须有相同价格（第 4 章）
Equivalent Martingale Measure	等价鞅测度	风险中性测度（第 6 章）
Radon–Nikodym Derivative	Radon–Nikodym 导数	测度变换的密度过程（第 6 章）
Girsanov Theorem	Girsanov 定理	漂移变换：改变测度只改漂移不改波动率（第 6、10 章）
Numéraire	计价单位	用于折现的基准资产（第 6 章）
Market Completeness	市场完备性	所有未定权益可复制的条件（第 6、10 章）
Feynman–Kac Formula	Feynman–Kac 公式	连接 PDE 与期望的桥梁（第 10 章）
Itô's Lemma	伊藤引理	随机微积分的链式法则（第 10 章）
Quadratic Variation	二次变差	布朗运动的「时间刻度」（第 10 章）
Geometric Brownian Motion	几何布朗运动	BSM 的标的假设（第 4、10 章）
Ornstein–Uhlenbeck Process	OU 过程	均值回复过程，用于利率与配对交易（第 10 章）
Jump Diffusion	跳跃扩散	加入跳跃的连续时间模型（第 10 章）
Lévy Process	Lévy 过程	平稳独立增量的通用跳跃过程（第 10 章）
Implied / Local Volatility	隐含 / 局部波动率	从期权价格反解 / Dupire 公式推出的波动率（第 4 章）
Volatility Smile / Skew	波动率微笑 / 偏斜	隐含波动率随行权价变化的形态（第 4 章）
Stochastic Volatility	随机波动率	Heston 等模型（第 4、6 章）
Variance Swap	方差互换	交易实现方差的衍生品（第 6 章）
Fast Fourier Transform Pricing	傅里叶定价	用特征函数一次算出整条期权价格曲线（第 6 章）
Least-Squares Monte Carlo	最小二乘蒙特卡洛	美式 / 百慕大期权定价（第 6 章）
XVA (CVA/DVA/FVA)	估值调整	交易对手信用、自身信用与资金成本调整（第 4 章）

C.3 统计、计量与机器学习

英文	中文	说明与章节
Stylized Facts	程式化事实	收益的肥尾、波动率聚集等经验规律（第 9 章）
Volatility Clustering	波动率聚集	大波动后跟大波动（第 9 章）
Leverage Effect	杠杆效应	负收益对波动率影响更强（第 9 章）
Heteroskedasticity	异方差	方差不恒定（第 8、9 章）
Autocorrelation (ACF/PACF)	自相关 / 偏自相关	时间序列识别工具（第 9 章）
Cointegration	协整	非平稳序列间的长期均衡关系（第 9 章）
Error Correction Model	误差修正模型	协整系统的短期动态（第 9 章）
State-Space Model	状态空间模型	潜变量与观测方程的框架（第 9 章）
Kalman Filter	卡尔曼滤波	状态空间模型的递推估计（第 9 章）
Realized Volatility	已实现波动率	高频收益平方和（第 9 章）
HAR Model	HAR 模型	已实现波动的多尺度（日/周/月）回归（第 9 章）
Extreme Value Theory	极值理论	尾部建模的理论基础（第 8 章）
Peaks Over Threshold	超阈值法	用 GPD 拟合尾部（第 8 章）
Maximum Likelihood / GMM	极大似然 / 广义矩	两类主流估计方法（第 8 章）
Shrinkage Estimator	收缩估计	用结构化目标矩阵稳定样本协方差（第 11 章）
Bayesian Shrinkage	贝叶斯收缩	Black–Litterman 的本质（第 8、11 章）
Fama–MacBeth Regression	Fama–MacBeth 两步回归	资产定价的标准检验方法（第 8 章）
Look-Ahead Bias	前视偏差	使用了未来信息（第 7 章）
Survivorship Bias	幸存者偏差	样本只剩存活个体（第 7 章）
Data Snooping	数据窥探	反复试探导致假显著（第 7 章）
Purged K-Fold	净化交叉验证	带间隔的时间序列交叉验证（第 7 章）
Deflated Sharpe Ratio	通缩夏普比率	对多重检验修正后的夏普（第 7 章）
Implementation Shortfall	实施缺口	决策价格与最终成交价的差异（第 7 章）

C.4 组合、风险与交易

英文	中文	说明与章节
Mean–Variance Optimization	均值–方差优化	Markowitz 框架（第 11 章）

英文	中文	说明与章节
Efficient Frontier	有效前沿	给定风险下收益最高的组合集合（第 11 章）
Tangency Portfolio	切点组合	最优风险资产组合（第 11 章）
Two-Fund Separation	两基金分离	所有有效组合可由两个基金张成（第 11 章）
Risk Parity / ERC	风险平价 / 等风险贡献	让各资产风险贡献相等（第 11 章）
Risk Budgeting	风险预算	指定各资产的风险贡献比例（第 11 章）
Hierarchical Risk Parity	层次风险平价	用聚类替代矩阵求逆（第 11 章）
Maximum Diversification	最大分散度	最大化分散度比率（第 11 章）
Kelly Criterion	Kelly 准则	最大化对数增长率的仓位（第 11 章）
Value at Risk / Expected Shortfall	在险价值 / 预期亏空	分位数与尾部均值风险度量（第 4 章）
Coherent Risk Measure	一致性风险度量	满足次可加性等公理的度量（第 4 章）
Backtesting	回测 / 风险回测	检验策略或风险模型的样本外表现（第 7、9 章）
Kupiec / Christoffersen Test	覆盖率 / 独立性检验	VaR 回测的两种标准检验（第 9 章）
Performance Attribution	绩效归因	把超额收益分解为配置与选股（第 11 章）
Information Coefficient / Ratio	信息系数 / 信息比率	信号质量与风险调整后主动收益（第 7 章）
Fundamental Law of Active Management	主动管理基本定律	$IR \approx IC\sqrt{\text{Breadth}}$（第 7 章）
Limit Order Book	限价订单簿	微观结构的核心数据结构（第 7 章）
Order Flow Imbalance	订单流不平衡	买卖压力的度量（第 7 章）
Market Impact	市场冲击	交易对价格的反作用（第 7、11 章）
Adverse Selection	逆向选择	做市商面对知情交易者的损失（第 7 章）

C.5 金融科技、Web3 与监管

英文	中文	说明与章节
Open Banking	开放银行	通过 API 开放银行数据（第 2 章）
Weight of Evidence / IV	WOE / 信息量	评分卡特征变换与筛选（第 2 章）
Expected Loss	预期损失	$EL = PD \times LGD \times EAD$（第 2 章）
RAROC	风险调整资本收益率	用经济资本衡量的收益率（第 2 章）

英文	中文	说明与章节
Model Risk Management	模型风险治理	美联储 SR 11-7 框架（第 2 章）
RegTech / SupTech	监管科技	用技术降低合规成本（第 2 章）
Automated Market Maker	自动做市商	用不变量定价的链上做市（第 3 章）
Constant Product Formula	恒定乘积公式	$xy = k$（第 3 章）
Impermanent Loss	无常损失	做市相对持有的机会成本（第 3 章）
Total Value Locked	总锁仓价值	协议内锁定的资产规模（第 3 章）
Maximal Extractable Value	最大可提取价值	排序交易获取的额外收益（第 3 章）
Rollup (Optimistic / ZK)	二层汇总	把执行搬到链下的扩容方案（第 3 章）
Reentrancy Attack	重入攻击	智能合约经典漏洞（第 3 章）
Tokenomics	代币经济学	代币供给、激励与价值捕获设计（第 3 章）
Howey Test	Howey 测试	判断是否构成证券的美国判例标准（第 3 章）
MiCA	加密资产市场监管法案	欧盟加密资产监管框架（第 3 章）
Know Your Customer	了解你的客户	客户身份识别义务（第 2、12 章）
Anti-Money Laundering	反洗钱	可疑交易监测与报告（第 12 章）
Fiduciary Duty	受托责任	投资顾问的最高行为标准（第 12 章）
Suitability / Reg BI	适合性 / 最佳利益规则	向客户推荐产品时的义务（第 12 章）

参考文献

本表按主题整理了全书涉及的经典文献与标准教材，既可作为引用出处，也可作为进一步学习的路线图。条目按「主题—作者姓氏」排列，格式遵循经济学与金融学通行规范。

参考文献

一、资产定价与组合管理

[1] Markowitz, H., "Portfolio Selection", *Journal of Finance*, 1952, 7(1): 77–91.

[2] Sharpe, W. F., "Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk", *Journal of Finance*, 1964, 19(3): 425–442.

[3] Fama, E. F., "Efficient Capital Markets: A Review of Theory and Empirical Work", *Journal of Finance*, 1970, 25(2): 383–417.

[4] Fama, E. F., and French, K. R., "Common Risk Factors in the Returns on Stocks and Bonds", *Journal of Financial Economics*, 1993, 33(1): 3–56.

[5] Carhart, M. M., "On Persistence in Mutual Fund Performance", *Journal of Finance*, 1997, 52(1): 57–82.

[6] Fama, E. F., and French, K. R., "A Five-Factor Asset Pricing Model", *Journal of Financial Economics*, 2015, 116(1): 1–22.

[7] Grossman, S. J., and Stiglitz, J. E., "On the Impossibility of Informationally Efficient Markets", *American Economic Review*, 1980, 70(3): 393–408.

[8] Shiller, R. J., "Do Stock Prices Move Too Much to Be Justified by Subsequent Changes in Dividends?", *American Economic Review*, 1981, 71(3): 421–436.

[9] Kahneman, D., and Tversky, A., "Prospect Theory: An Analysis of Decision under Risk", *Econometrica*, 1979, 47(2): 263–291.

[10] Cochrane, J. H., *Asset Pricing*, Revised Edition, Princeton University Press, 2005.

[11] Grinold, R. C., and Kahn, R. N., *Active Portfolio Management*, 2nd Edition, McGraw-Hill, 2000.

[12] Black, F., and Litterman, R., "Global Portfolio Optimization", *Financial Analysts Journal*, 1992, 48(5): 28–43.

[13] Ledoit, O., and Wolf, M., "Honey, I Shrunk the Sample Covariance Matrix", *Journal of Portfolio Management*, 2004, 30(4): 110–119.

[14] Maillard, S., Roncalli, T., and Teïletche, J., "The Properties of Equally Weighted Risk Contribution Portfolios", *Journal of Portfolio Management*, 2010, 36(4): 60–70.

[15] López de Prado, M., "Building Diversified Portfolios that Outperform Out of Sample", *Journal of Portfolio Management*, 2016, 42(4): 59–69.

[16] Kelly, J. L., "A New Interpretation of Information Rate", *Bell System Technical Journal*, 1956, 35(4): 917–926.

[17] Merton, R. C., "Lifetime Portfolio Selection under Uncertainty: The Continuous-Time Case", *Review of Economics and Statistics*, 1969, 51(3): 247–257.

[18] Merton, R. C., "Optimum Consumption and Portfolio Rules in a Continuous-Time

Model", *Journal of Economic Theory*, 1971, 3(4): 373–413.

[19] Artzner, P., Delbaen, F., Eber, J.-M., and Heath, D., "Coherent Measures of Risk", *Mathematical Finance*, 1999, 9(3): 203–228.

[20] Rockafellar, R. T., and Uryasev, S., "Optimization of Conditional Value-at-Risk", *Journal of Risk*, 2000, 2(3): 21–41.

[21] Bailey, D. H., and López de Prado, M., "The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality", *Journal of Portfolio Management*, 2014, 40(5): 94–107.

[22] Harvey, C. R., Liu, Y., and Zhu, H., "…and the Cross-Section of Expected Returns", *Review of Financial Studies*, 2016, 29(1): 5–68.

[23] White, H., "A Reality Check for Data Snooping", *Econometrica*, 2000, 68(5): 1097–1126.

[24] Benjamini, Y., and Hochberg, Y., "Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing", *Journal of the Royal Statistical Society, Series B*, 1995, 57(1): 289–300.

[25] Grinold, R. C., "The Fundamental Law of Active Management", *Journal of Portfolio Management*, 1989, 15(3): 30–37.

[26] Choueifaty, Y., and Coignard, Y., "Toward Maximum Diversification", *Journal of Portfolio Management*, 2008, 35(1): 40–51.

[27] RiskMetrics Group, *RiskMetrics Technical Document*, 4th Edition, J.P. Morgan/Reuters, 1996.

[28] Gu, S., Kelly, B., and Xiu, D., "Empirical Asset Pricing via Machine Learning", *Review of Financial Studies*, 2020, 33(5): 2223–2273.

二、衍生品定价与金融工程

[29] Black, F., and Scholes, M., "The Pricing of Options and Corporate Liabilities", *Journal of Political Economy*, 1973, 81(3): 637–654.

[30] Merton, R. C., "Theory of Rational Option Pricing", *Bell Journal of Economics and Management Science*, 1973, 4(1): 141–183.

[31] Cox, J. C., Ross, S. A., and Rubinstein, M., "Option Pricing: A Simplified Approach", *Journal of Financial Economics*, 1979, 7(3): 229–263.

[32] Merton, R. C., "Option Pricing When Underlying Stock Returns Are Discontinuous", *Journal of Financial Economics*, 1976, 3(1–2): 125–144.

[33] Heston, S. L., "A Closed-Form Solution for Options with Stochastic Volatility with Applications to Bond and Currency Options", *Review of Financial Studies*, 1993, 6(2): 327–343.

[34] Dupire, B., "Pricing with a Smile", *Risk*, 1994, 7(1): 18–20.

[35] Hagan, P. S., Kumar, D., Lesniewski, A. S., and Woodward, D. E., "Managing Smile Risk", *Wilmott Magazine*, 2002, September: 84–108.

[36] Black, F., "The Pricing of Commodity Contracts", *Journal of Financial Economics*, 1976, 3(1–2): 167–179.

[37] Hull, J., and White, A., "Pricing Interest-Rate-Derivative Securities", *Review of Financial Studies*, 1990, 3(4): 573–592.

[38] Merton, R. C., "On the Pricing of Corporate Debt: The Risk Structure of Interest Rates", *Journal of Finance*, 1974, 29(2): 449–470.

[39] Jarrow, R. A., and Turnbull, S. M., "Pricing Derivatives on Financial Securities Subject to Credit Risk", *Journal of Finance*, 1995, 50(1): 53–85.

[40] Duffie, D., and Singleton, K. J., "Modeling Term Structures of Defaultable Bonds", *Review of Financial Studies*, 1999, 12(4): 687–720.

[41] Li, D. X., "On Default Correlation: A Copula Function Approach", *Journal of Fixed Income*, 2000, 9(4): 43–54.

[42] Carr, P., and Madan, D. B., "Option Valuation Using the Fast Fourier Transform", *Journal of Computational Finance*, 1999, 2(4): 61–73.

[43] Albrecher, H., Mayer, P., Schoutens, W., and Tistaert, J., "The Little Heston Trap", *Wilmott Magazine*, 2007, January: 83–92.

[44] Demeterfi, K., Derman, E., Kamal, M., and Zou, J., "More Than You Ever Wanted to Know About Volatility Swaps", *Goldman Sachs Quantitative Strategies Research Notes*, 1999.

[45] Longstaff, F. A., and Schwartz, E. S., "Valuing American Options by Simulation: A Simple Least-Squares Approach", *Review of Financial Studies*, 2001, 14(1): 113–147.

[46] Glasserman, P., *Monte Carlo Methods in Financial Engineering*, Springer, 2003.

[47] Hull, J. C., *Options, Futures, and Other Derivatives*, 10th Edition, Pearson, 2018.

[48] Brigo, D., and Mercurio, F., *Interest Rate Models — Theory and Practice*, 2nd Edition, Springer, 2006.

三、利率模型与期限结构

[49] Vasicek, O., "An Equilibrium Characterization of the Term Structure", *Journal of Financial Economics*, 1977, 5(2): 177–188.

[50] Cox, J. C., Ingersoll, J. E., and Ross, S. A., "A Theory of the Term Structure of Interest Rates", *Econometrica*, 1985, 53(2): 385–407.

[51] Heath, D., Jarrow, R., and Morton, A., "Bond Pricing and the Term Structure of Interest Rates: A New Methodology for Contingent Claims Valuation", *Econometrica*, 1992, 60(1): 77–105.

[52] Brace, A., Gatarek, D., and Musiela, M., "The Market Model of Interest Rate Dynamics", *Mathematical Finance*, 1997, 7(2): 127–155.

[53] Jamshidian, F., "LIBOR and Swap Market Models and Measures", *Finance and Stochastics*, 1997, 1(4): 293–330.

[54] Filipović, D., *Term-Structure Models: A Graduate Course*, Springer, 2009.

四、随机分析与概率论

[55] Itô, K., "On Stochastic Differential Equations", *Memoirs of the American Mathematical Society*, 1951, 4: 1–51.

[56] Girsanov, I. V., "On Transforming a Certain Class of Stochastic Processes by Abso-

lutely Continuous Substitution of Measures", *Theory of Probability and Its Applications*, 1960, 5(3): 285–301.

[57] Karatzas, I., and Shreve, S. E., *Brownian Motion and Stochastic Calculus*, 2nd Edition, Springer, 1991.

[58] Øksendal, B., *Stochastic Differential Equations: An Introduction with Applications*, 6th Edition, Springer, 2003.

[59] Shreve, S. E., *Stochastic Calculus for Finance II: Continuous-Time Models*, Springer, 2004.

[60] Musiela, M., and Rutkowski, M., *Martingale Methods in Financial Modelling*, 2nd Edition, Springer, 2005.

[61] Duffie, D., *Dynamic Asset Pricing Theory*, 3rd Edition, Princeton University Press, 2001.

[62] Kloeden, P. E., and Platen, E., *Numerical Solution of Stochastic Differential Equations*, Springer, 1992.

[63] Cont, R., and Tankov, P., *Financial Modelling with Jump Processes*, Chapman & Hall/CRC, 2004.

[64] Applebaum, D., *Lévy Processes and Stochastic Calculus*, 2nd Edition, Cambridge University Press, 2009.

五、计量经济学、时间序列与统计

[65] Engle, R. F., "Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation", *Econometrica*, 1982, 50(4): 987–1007.

[66] Bollerslev, T., "Generalized Autoregressive Conditional Heteroskedasticity", *Journal of Econometrics*, 1986, 31(3): 307–327.

[67] Nelson, D. B., "Conditional Heteroskedasticity in Asset Returns: A New Approach", *Econometrica*, 1991, 59(2): 347–370.

[68] Engle, R. F., "Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models", *Journal of Business and Economic Statistics*, 2002, 20(3): 339–350.

[69] Dickey, D. A., and Fuller, W. A., "Distribution of the Estimators for Autoregressive Time Series with a Unit Root", *Journal of the American Statistical Association*, 1979, 74(366): 427–431.

[70] Engle, R. F., and Granger, C. W. J., "Co-Integration and Error Correction: Representation, Estimation, and Testing", *Econometrica*, 1987, 55(2): 251–276.

[71] Johansen, S., "Estimation and Hypothesis Testing of Cointegration Vectors in Gaussian Vector Autoregressive Models", *Econometrica*, 1991, 59(6): 1551–1580.

[72] Hamilton, J. D., *Time Series Analysis*, Princeton University Press, 1994.

[73] Campbell, J. Y., Lo, A. W., and MacKinlay, A. C., *The Econometrics of Financial Markets*, Princeton University Press, 1997.

[74] Tsay, R. S., *Analysis of Financial Time Series*, 3rd Edition, Wiley, 2010.

[75] Cont, R., "Empirical Properties of Asset Returns: Stylized Facts and Statistical

Issues", *Quantitative Finance*, 2001, 1(2): 223–236.

[76] Andersen, T. G., Bollerslev, T., Diebold, F. X., and Labys, P., "Modeling and Forecasting Realized Volatility", *Econometrica*, 2003, 71(2): 579–625.

[77] Corsi, F., "A Simple Approximate Long-Memory Model of Realized Volatility", *Journal of Financial Econometrics*, 2009, 7(2): 174–196.

[78] Nelson, C. R., and Siegel, A. F., "Parsimonious Modeling of Yield Curves", *Journal of Business*, 1987, 60(4): 473–489.

[79] Kupiec, P. H., "Techniques for Verifying the Accuracy of Risk Measurement Models", *Journal of Derivatives*, 1995, 3(2): 73–84.

[80] Christoffersen, P. F., "Evaluating Interval Forecasts", *International Economic Review*, 1998, 39(4): 841–862.

[81] Diebold, F. X., and Mariano, R. S., "Comparing Predictive Accuracy", *Journal of Business and Economic Statistics*, 1995, 13(3): 253–263.

[82] Embrechts, P., Klüppelberg, C., and Mikosch, T., *Modelling Extremal Events for Insurance and Finance*, Springer, 1997.

[83] McNeil, A. J., Frey, R., and Embrechts, P., *Quantitative Risk Management: Concepts, Techniques and Tools*, Princeton University Press, 2005.

[84] Tibshirani, R., "Regression Shrinkage and Selection via the Lasso", *Journal of the Royal Statistical Society, Series B*, 1996, 58(1): 267–288.

[85] Hoerl, A. E., and Kennard, R. W., "Ridge Regression: Biased Estimation for Nonorthogonal Problems", *Technometrics*, 1970, 12(1): 55–67.

六、机器学习与深度学习

[86] Hochreiter, S., and Schmidhuber, J., "Long Short-Term Memory", *Neural Computation*, 1997, 9(8): 1735–1780.

[87] Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., and Bengio, Y., "Learning Phrase Representations Using RNN Encoder–Decoder for Statistical Machine Translation", *Proceedings of EMNLP*, 2014: 1724–1734.

[88] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I., "Attention Is All You Need", *Advances in Neural Information Processing Systems*, 2017.

[89] Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., and Zhang, W., "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting", *Proceedings of AAAI*, 2021.

[90] Wu, H., Xu, J., Wang, J., and Long, M., "Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting", *Advances in Neural Information Processing Systems*, 2021.

[91] Nie, Y., Nguyen, N. H., Sinthong, P., and Kalagnanam, J., "A Time Series Is Worth 64 Words: Long-Term Forecasting with Transformers", *International Conference on Learning Representations (ICLR)*, 2023.

[92] Lim, B., Arık, S. Ö., Loeff, N., and Pfister, T., "Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting", *International Journal of*

Forecasting, 2021, 37(4): 1748–1764.

七、市场微观结构与交易

[93] Kyle, A. S., "Continuous Auctions and Insider Trading", *Econometrica*, 1985, 53(6): 1315–1335.

[94] Glosten, L. R., and Milgrom, P. R., "Bid, Ask and Transaction Prices in a Specialist Market with Heterogeneously Informed Traders", *Journal of Financial Economics*, 1985, 14(1): 71–100.

[95] Almgren, R., and Chriss, N., "Optimal Execution of Portfolio Transactions", *Journal of Risk*, 2001, 3(2): 5–39.

[96] O'Hara, M., *Market Microstructure Theory*, Blackwell, 1995.

[97] Hasbrouck, J., *Empirical Market Microstructure*, Oxford University Press, 2007.

八、金融科技、加密金融与监管

[98] Akerlof, G. A., "The Market for 'Lemons': Quality Uncertainty and the Market Mechanism", *Quarterly Journal of Economics*, 1970, 84(3): 488–500.

[99] Nakamoto, S., "Bitcoin: A Peer-to-Peer Electronic Cash System", 2008.

[100] Buterin, V., "Ethereum: A Next-Generation Smart Contract and Decentralized Application Platform", Ethereum White Paper, 2014.

[101] Wood, G., "Ethereum: A Secure Decentralised Generalised Transaction Ledger", Ethereum Yellow Paper, 2014.

[102] Adams, H., Zinsmeister, N., Salem, M., Keefer, R., and Robinson, D., "Uniswap v2 Core", Uniswap Whitepaper, 2020.

[103] Egorov, M., "StableSwap — Efficient Mechanism for Stablecoin Liquidity", Curve Whitepaper, 2019.

[104] Gudgeon, L., Perez, D., Harz, D., Livshits, B., and Gervais, A., "DeFi Protocols for Loanable Funds: Interest Rates, Liquidity and Market Efficiency", *Proceedings of the ACM Conference on Advances in Financial Technologies (AFT)*, 2020.

[105] Daian, P., Goldfeder, S., Kell, T., Li, Y., Zhao, X., Bentov, I., Breidenbach, L., and Juels, A., "Flash Boys 2.0: Frontrunning in Decentralized Exchanges, Miner Extractable Value, and Consensus Instability", *IEEE Symposium on Security and Privacy*, 2020.

[106] Basel Committee on Banking Supervision, *Amendment to the Capital Accord to Incorporate Market Risks*, Bank for International Settlements, 1996.

[107] Basel Committee on Banking Supervision, *Basel III: Finalising Post-Crisis Reforms*, Bank for International Settlements, 2017.

[108] Basel Committee on Banking Supervision, *Minimum Capital Requirements for Market Risk*, Bank for International Settlements, 2019.

[109] FINRA, *Content Outlines for the SIE, Series 7, Series 57, Series 65 and Series 24 Examinations*, Financial Industry Regulatory Authority, 2024.

[110] U.S. Securities and Exchange Commission, *Regulation Best Interest: The Broker-Dealer Standard of Conduct*, Release No. 34-86031, 2019.